

Introducción a la Ciencia de Datos

Problema, datos y workflow

Curso de Data Science

Semana 1 · Clase 1

Propósito de la clase

Comprender la Ciencia de Datos como un proceso interdisciplinario que transforma observaciones en evidencia para apoyar decisiones.

Al finalizar, podremos

- ▶ distinguir problema, dato, modelo, evidencia y decisión;
- ▶ reconocer objetivos descriptivos, predictivos y prescriptivos;
- ▶ explicar las etapas generales de un proyecto de datos;
- ▶ caracterizar fuentes, tipos y limitaciones de los datos;
- ▶ formular un problema inicial de movilidad urbana.

Pregunta de apertura

Situación

Una empresa de movilidad quiere “mejorar el servicio”.

Pregunta clave

¿Qué necesitamos precisar antes de abrir un dataset?

- ▶ ¿Quién utilizará el resultado?
- ▶ ¿Qué decisión debe tomar?
- ▶ ¿Qué representa una observación?
- ▶ ¿Qué resultado se quiere modificar?
- ▶ ¿Cómo sabremos si aporta valor?

¿Qué es la Ciencia de Datos?

Campo interdisciplinario que desarrolla métodos para:

- ① obtener conocimiento a partir de datos;
- ② comunicar evidencia sobre un fenómeno;
- ③ apoyar decisiones bajo objetivos y restricciones.

No se reduce a

Programar, entrenar modelos, producir gráficos o acumular datos.

Idea central

La pregunta y la decisión determinan el producto apropiado.

Los datos representan, no reproducen

Un dato es un registro producido por un proceso de observación.

Fenómeno	Registro posible	Lo que puede quedar fuera
Demora de un viaje	Hora programada y hora real	Tráfico, incidentes, criterio de registro
Ubicación	Coordenadas GPS	Precisión, pérdida de señal, contexto vial
Experiencia	Reclamo o encuesta	Personas que no responden, lenguaje, expectativas

Pregunta clave

¿Qué representa este campo, cómo se obtuvo y cuándo estuvo disponible?

De los datos a la decisión



problema → datos → representación → análisis → evidencia → decisión →
evaluación

- ▶ El ciclo es **iterativo**, no una línea rígida.
- ▶ Un hallazgo puede obligar a revisar la pregunta inicial.
- ▶ Un modelo estima; una decisión incorpora objetivos, costos y responsabilidades.

Preguntas que puede responder un proyecto

Objetivo	Pregunta típica	Ejemplo de movilidad
Describir	¿Qué ocurrió?	¿Dónde se concentran las demoras?
Diagnosticar	¿Qué factores se asocian?	¿Qué acompaña demoras mayores?
Predecir	¿Qué valor no conocemos?	¿Cuánto demorará el próximo viaje?
Prescribir	¿Qué acción conviene?	¿A qué zona reasignar un vehículo?
Monitorear	¿Qué está cambiando?	¿Se degradó la puntualidad?

Estas preguntas pueden conectarse, pero no son equivalentes.

Describir no es predecir

Descripción

Resume observaciones mediante frecuencias, medias, cuantiles, distribuciones o segmentos.

Predicción

Estima un resultado desconocido o futuro y se evalúa sobre casos no utilizados para ajustar el modelo.

Pregunta clave

Saber dónde ocurrieron demoras, ¿permite anticipar la demora del próximo viaje?

Predecir no es decidir

Predicción

Demora esperada: 18 minutos

Decisión

Reasignar vehículo, mantener distribución o solicitar apoyo.

Para decidir también necesitamos:

- ▶ costos, beneficios, capacidad y restricciones;
- ▶ horizonte temporal y consecuencias de los errores;
- ▶ responsables de ejecutar y revisar.

Una predicción precisa puede ser inútil si no modifica ninguna acción.

Una disciplina interdisciplinaria

Perspectiva	Contribución
Estadística	Variabilidad, inferencia, incertidumbre y evaluación
Matemática y optimización	Relaciones, objetivos, restricciones y selección
Computación	Representación, algoritmos y eficiencia
Ingeniería de software	Reproducibilidad, pruebas, operación y monitoreo
Conocimiento del dominio	Significado, plausibilidad y restricciones reales
Comunicación	Evidencia comprensible para usuarios y responsables

Formular antes de modelar

- ▶ **Unidad:** ¿qué representa una fila?
- ▶ **Usuario:** ¿quién usará el resultado?
- ▶ **Objetivo:** ¿qué se quiere mejorar?
- ▶ **Acción:** ¿qué puede hacerse?
- ▶ **Horizonte:** ¿para cuándo se necesita?
- ▶ **Datos:** ¿qué estará disponible?
- ▶ **Restricciones:** ¿qué límites existen?
- ▶ **Valor:** ¿cómo se evaluará la utilidad?

La unidad cambia la pregunta

Unidad de análisis	Pregunta resultante
Viaje	¿Este viaje llegará con demora?
Vehículo	¿Qué vehículos acumulan más retrasos?
Zona y franja horaria	¿Dónde y cuándo aumenta la demanda?
Día	¿Cómo cambia la puntualidad a lo largo del tiempo?

Conclusión

No existe una fila “natural”: la unidad se elige según el problema y la decisión.

Workflow de un proyecto de datos

- ➊ Comprender la necesidad y la decisión.
- ➋ Establecer baseline y criterios de éxito.
- ➌ Recolectar, comprender y auditar datos.
- ➍ Preparar una representación analítica.
- ➎ Analizar o modelar sin fuga de información.
- ➏ Evaluar desempeño, utilidad y riesgos.
- ➐ Comunicar o desplegar con monitoreo.
- ➑ Iterar con nueva evidencia.

Es un proceso de decisión con evidencia, no una sucesión de algoritmos.

KDD y CRISP-DM

KDD

Selección → limpieza → transformación →
minería → interpretación

Enfatiza el descubrimiento de conocimiento desde los datos.

CRISP-DM

Negocio → datos → preparación → modelado →
evaluación → despliegue

Conecta necesidad, trabajo analítico y uso.

Ambas metodologías se aplican como ciclos con retroalimentación.

Tipos de datos según su estructura

Tipo	Característica	Ejemplo
Estructurados	Esquema tabular definido	Viajes en Parquet o base SQL
Semiestructurados	Claves y estructura flexible	Respuesta JSON de una API
No estructurados	Requieren representación adicional	Texto, audio o imágenes

La estructura condiciona almacenamiento, controles de calidad, métodos de análisis y costo de integración.

Fuentes y procedencia

- ▶ **Observacionales**: registran procesos sin intervención controlada.
- ▶ **Experimentales**: provienen de intervenciones diseñadas.
- ▶ **Simulados**: son generados por un modelo.
- ▶ **Primarios**: se recolectan para el proyecto.
- ▶ **Secundarios**: fueron creados con otro propósito.

Documentar cada fuente

Origen · licencia · cobertura · frecuencia · formato · calidad · sesgos · responsable

Big Data: más que tamaño

Dimensión	Pregunta de diagnóstico
Volumen	¿Cuánto se almacena y procesa?
Velocidad	¿Con qué rapidez llega y pierde vigencia?
Variedad	¿Cuántos formatos y significados se integran?
Veracidad	¿Qué tan confiable es la medición?
Valor	¿La información mejora una decisión?

Un dataset pequeño y preciso puede valer más que uno masivo pero irrelevante.

Herramientas: medios, no método

Python

pandas · NumPy · Matplotlib · scikit-learn

R

tidyverse · ggplot2 · tidymodels

Un proyecto reproducible registra:

- ▶ versiones, dependencias, parámetros y semillas;
- ▶ datos, particiones y transformaciones;
- ▶ métricas, resultados y decisiones.

La elección depende del equipo, el ecosistema y la tarea.

Caso transversal: movilidad urbana

Necesidad inicial

Una empresa que administra una flota quiere reducir demoras.

- ▶ **Unidad:** viaje.
- ▶ **Usuario:** responsable de operaciones.
- ▶ **Horizonte:** próxima franja horaria.
- ▶ **Resultado:** demora por zona.
- ▶ **Acción:** reasignar vehículos.
- ▶ **Restricciones:** capacidad y distancia.
- ▶ **Valor:** reducir demoras sin aumentar cancelaciones.

Del caso amplio a tareas concretas

Etapas	Tarea	Producto
Describir	Resumir viajes y demoras por zona y hora	Tabla o visualización
Predecir	Estimar demora del siguiente intervalo	Predicción y evaluación
Prescribir	Comparar reasignaciones factibles	Recomendación operativa
Monitorear	Detectar degradación del servicio	Indicadores y alertas

Campos posibles

`id_viaje · origen · destino · hora_programada · hora_real · zona · vehículo`

Cuidado: `hora_real` no está disponible antes de terminar el viaje.

Actividad guiada: ficha del problema

En equipos, completar para el caso de movilidad:

- 1 problema observable y beneficio esperado;
- 2 usuario del resultado y personas afectadas;
- 3 unidad de análisis y periodo;
- 4 decisión y acciones posibles;
- 5 datos disponibles antes de decidir;
- 6 resultado de interés;
- 7 restricciones y supuestos;
- 8 baseline y métrica de valor.

Tiempo sugerido

25 minutos de trabajo + 10 minutos de contraste.

Criteria de revisión de la ficha

La evidencia es adecuada si:

- ▶ la unidad corresponde con la pregunta;
- ▶ el usuario puede ejecutar la acción declarada;
- ▶ las entradas existen antes de la decisión;
- ▶ la métrica representa valor y no solo desempeño técnico;
- ▶ el baseline permite comparar la propuesta;
- ▶ los supuestos y límites son observables;
- ▶ se reconocen personas o procesos afectados.

Entregable de semana 1

Ficha de una página, versión inicial.

Puesta en común

Cada equipo presenta en un minuto:

- 1 su decisión principal;
- 2 la unidad de análisis elegida;
- 3 la métrica de valor;
- 4 el supuesto más riesgoso.

Preguntas para contrastar

- ▶ ¿Hay datos suficientes para representar el fenómeno?
- ▶ ¿Se requiere descripción, predicción o prescripción?
- ▶ ¿Qué cambia si la unidad es zona en vez de viaje?

Síntesis

- ▶ La Ciencia de Datos produce evidencia a partir de observaciones.
- ▶ Los datos son representaciones parciales y situadas.
- ▶ Describir, predecir y prescribir responden preguntas diferentes.
- ▶ Un modelo no es una decisión.
- ▶ El workflow conecta necesidad, datos, análisis, uso y evaluación.
- ▶ Formular unidad, usuario, acción y valor precede a elegir herramientas.

Idea de cierre

Primero se diseña la pregunta; después se decide qué datos y métodos necesita.

Autoevaluación

- 1 ¿Por qué los datos no equivalen al fenómeno observado?
- 2 ¿Qué diferencia existe entre una predicción y una decisión?
- 3 ¿Cómo cambia el problema al cambiar la unidad de análisis?
- 4 ¿Por qué CRISP-DM debe entenderse como un ciclo?
- 5 ¿Qué dimensión de Big Data se relaciona con la confiabilidad?
- 6 ¿Qué información produciría fuga al anticipar una demora?

Lecturas y recursos

Lectura principal

- ▶ **Capítulo 1:** secciones 1.1.1, 1.1.4, 1.1.5 y 1.1.6.
- ▶ **Capítulo 2:** secciones 2.1 a 2.4.

Para continuar

- ▶ Revisar el glosario y la autoevaluación del capítulo 1.
- ▶ Completar y entregar la ficha inicial del problema de movilidad.