

Introducción a la Ciencia de Datos

De una necesidad a evidencia útil para decidir

Curso de Data Science

Semana 1 · Clase 1

Propósito de la clase

Comprender la Ciencia de Datos como un proceso interdisciplinario que transforma observaciones en evidencia para apoyar decisiones responsables.

Al finalizar, podremos

- ▶ distinguir dato, representación, modelo, evidencia y decisión;
- ▶ diferenciar descripción, predicción y prescripción;
- ▶ formular unidad, población, alcance y horizonte antes de modelar;
- ▶ explicar workflow, KDD, CRISP-DM, procedencia y reproducibilidad;
- ▶ especificar un problema de movilidad con unidad **zona-franja**.

Pregunta de apertura

Situación

Una empresa de movilidad quiere “mejorar el servicio”.

Pregunta clave

¿Qué debemos precisar antes de abrir un dataset?

- ▶ ¿Qué situación se desea modificar?
- ▶ ¿Quién utilizará el resultado?
- ▶ ¿Sobre qué unidad se decidirá?
- ▶ ¿Qué acción está disponible?
- ▶ ¿Qué datos existirán a tiempo?
- ▶ ¿Cómo se medirá el valor?

¿Qué es la Ciencia de Datos?

Campo interdisciplinario que desarrolla métodos para:

- ① obtener conocimiento a partir de datos;
- ② comunicar evidencia sobre un fenómeno;
- ③ apoyar decisiones bajo objetivos y restricciones.

No se reduce a


Programar, graficar, entrenar modelos o acumular datos.

Producto apropiado

Puede ser un inventario, auditoría, análisis, estimación, visualización o recomendación.

La pregunta y la decisión determinan el producto.

Los datos representan, no reproducen




Un dato es un registro producido por un proceso situado.

Preguntas mínimas

- ¿Qué representa?
- ¿Cómo se obtuvo?
- ¿Qué no observa?
- ¿Cuándo estuvo disponible?

De datos a conocimiento



Trazabilidad

Cada transición agrega contexto, pero también supuestos, pérdidas y posibles sesgos. Debemos poder reconstruirla.

De la necesidad a la decisión



Correspondencia hacia adelante


La tarea debe producir evidencia utilizable por una acción real.

Correspondencia hacia atrás

La decisión define unidad, oportunidad, evaluación y datos necesarios.

Un modelo es un componente de la cadena, no la decisión.

El ciclo aprende y vuelve atrás



- Explorar puede revelar que la pregunta no es medible.
- Evaluar puede mostrar que no se supera el baseline.
- Usar puede cambiar el proceso que genera datos.

Autoridad

La organización define quién aprueba, ejecuta, revisa y puede detener el sistema.

Taxonomía de preguntas analíticas

Objetivo	Pregunta	Ejemplo en movilidad
Describir	¿Qué ocurrió?	¿Dónde y cuándo hubo demoras?
Diagnosticar	¿Qué se asocia?	¿Qué acompaña demoras mayores?
Predecir	¿Qué valor no conocemos?	¿Qué demanda tendrá cada zona-franja?
Prescribir	¿Qué acción conviene?	¿Cómo reasignar vehículos factibles?
Monitorear	¿Qué está cambiando?	¿Se degradó la cobertura o el modelo?

Pueden conectarse, pero requieren evidencia y evaluación diferentes.

Describir: resumir lo observado

Una descripción estima propiedades de observaciones y grupos:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \hat{p} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i = 1)$$

Productos

Frecuencias, medias, cuantiles, distribuciones, segmentos y visualizaciones.

Movilidad

Viajes, demora mediana y espera extrema por zona y franja observada.

Asociación descriptiva no demuestra causa ni anticipa por sí sola.

Predecir: estimar lo no observado

Una predicción estima un resultado desconocido, futuro o costoso de medir:


$$\hat{P}(Y | X) \quad \text{o} \quad \hat{\mathbb{E}}[Y | X]$$

- ▶ Las entradas deben existir en el momento real de uso.
- ▶ La evaluación utiliza casos no usados para ajustar.
- ▶ La partición debe respetar tiempo, grupos y duplicados.
- ▶ El desempeño se compara con un baseline pertinente.

Pregunta clave

¿Qué demanda tendrá cada zona durante la próxima franja?

Describir no es predecir



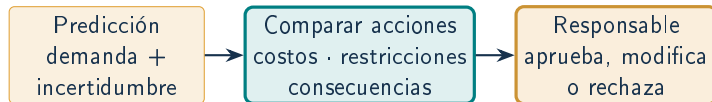
¿Dónde ocurrieron demoras?

¿Qué zona-franja tendrá demanda alta?

Prueba decisiva

Una buena explicación del pasado no implica bajo error sobre periodos posteriores.

Predecir no es decidir



$$a^* = \arg \max_{a \in A} \mathbb{E}[U(a, S) \mid X]$$

- ▶ El modelo informa.
- ▶ La política compara.
- ▶ La persona autorizada decide.

Autoridad humana efectiva


Requiere tiempo, información y poder real para contradecir o detener la recomendación.

Una disciplina interdisciplinaria



Una perspectiva aislada puede optimizar la parte equivocada.

Formular antes de modelar



Prueba sin algoritmos

Si no podemos explicar quién decide, sobre qué unidad, con qué información, para cuándo y con qué propósito, la formulación aún no está completa.

Especificación compacta del problema

$$\mathcal{P} = (U, \mathcal{R}, O, X, Y, A, H, C)$$

- ▶ U : unidad de análisis.
- ▶ $\mathcal{R}$: población objetivo.
- ▶ O : objetivo del proyecto.
- ▶ X : entradas disponibles.
- ▶ Y : resultado de interés.
- ▶ A : acciones posibles.
- ▶ H : horizonte temporal.
- ▶ C : restricciones.
- ▶ Usuario, valor y responsables completan la ficha.

Cuatro pruebas

Observabilidad · accionabilidad · disponibilidad temporal · contrafactual: “¿qué haríamos si la respuesta fuera distinta?”

Unidad, población y alcance

Unidad U

Entidad elemental descrita, predicha o decidida. Define el significado de una fila.

Población $\mathcal{R}$

Unidades sobre las que se desea generalizar o actuar; no equivale a la muestra observada.

Alcance


Periodos, lugares, casos, usuarios, acciones y exclusiones autorizadas.

Coherencia de granularidad

Si la acción reasigna recursos entre zonas por franja, la evidencia final debe conservar la unidad **zona-franja**; predicciones por viaje requieren una agregación explícita.

Población objetivo $\neq$ muestra disponible $\neq$ población futura de uso.

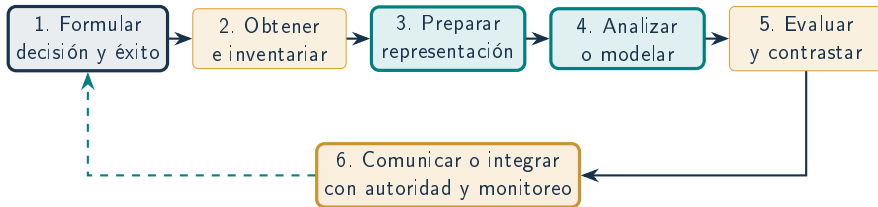
Horizonte y disponibilidad: reconstruir el reloj



Regla temporal

Evaluar con la información disponible retrospectivamente puede sobrestimar lo que el sistema sabía al decidir.

Workflow de un proyecto de datos



Principio

Baseline, criterios de éxito y protocolo de evaluación se fijan antes de comparar resultados finales.

Puertas y artefactos: aprender antes de escalar

Puerta	Evidencia mínima	Artefacto vivo
Formular → datos	Unidad, alcance, autoridad y valor acordados	Ficha del problema
Datos → análisis	Cobertura, licencia, calidad y tiempo conocidos	Inventario + diccionario
Análisis → uso	Baseline superado y riesgos aceptables	Registro de experimento
Uso → escala	Utilidad, carga y fallos observados	Plan de monitoreo y retirada

Producto mínimo evaluable

El artefacto más pequeño que permite probar la incertidumbre capaz de invalidar el proyecto.

Continuar, modificar, escalar o detener son resultados legítimos.

KDD: del dato al conocimiento validado




Distinción

La minería es una etapa dentro de KDD, no un sinónimo del proceso completo.

Salto que debe evitarse

Resultado → patrón → hallazgo validado → regla aprobada.

CRISP-DM: organizar el proyecto completo



- ▶ Comienza por el problema, no por el modelo.
- ▶ Evalúa técnica y correspondencia con el objetivo.
- ▶ Despliegue puede ser informe, tablero, API o regla operativa.

No termina al publicar

Operación, monitoreo, incidentes y retirada retroalimentan el ciclo.


Estructura de los datos

Tipo	Organización	Ejemplo y decisión de representación
Estructurados	Esquema explícito, filas, columnas y claves	Viajes SQL; validar unidad, tipos y cardinalidad
Semiestructurados	Claves o marcas con esquema flexible	Eventos JSON; distinguir ausente, nulo y lista vacía
No estructurados	Sin variables tabulares inmediatas	Texto, audio o imagen; construir una representación

Advertencia semántica

Un esquema válido no garantiza significado correcto; y “no estructurado” no significa carente de estructura interna.

De fuentes heterogéneas a una tabla analítica



- ▶ La tabla analítica deriva de fuentes: no las reemplaza.
- ▶ Cada unión declara claves, cardinalidad, cobertura y fecha de corte.
- ▶ Cambiar la cantidad de filas puede cambiar la población o la unidad.

Fuentes: inventariar antes de integrar

Fuente	Unidad original	Acceso	Riesgo principal
Viajes	viaje	base o archivo	operadores no cubiertos
GPS	dispositivo-evento	flujo o API	latencia, deriva y pérdida
Clima	estación-hora	API	desfase horario y distancia
Zonas	polígono-versión	archivo geográfico	límites modificados
Calendario	día	archivo o tabla	definición local

Ficha mínima por fuente

Propietario · propósito original · unidad · cobertura · captura · formato · frecuencia · licencia · sensibilidad · calidad · cambios

Procedencia: ejes distintos, preguntas distintas

Mecanismo de generación observacional | experimental | simulado

Propósito de recolección primario para el proyecto | secundario, otro propósito

Acceso y gobernanza abierto | privado | restringido

Linaje origen → extracción → transformación → producto

No son categorías excluyentes entre ejes

Un dato puede ser observacional, secundario y privado a la vez. Cada eje implica límites de inferencia, uso y auditoría diferentes.

Big Data: seis V, seis diagnósticos



Escala no corrige semántica: más datos del concepto equivocado siguen siendo equivocados.

Herramientas y reproducibilidad

Entornos

Python · R · SQL · Jupyter ·
Quarto

Artefactos

Código · datos · configuración
· resultados · documentación

Controles

Versiones · checksums ·
pruebas · semillas · registro
de decisiones

Cadena reproducible

Fuente identificada → transformación versionada → experimento registrado → resultado
reconstruible

- ▶ Una semilla ayuda, pero no sustituye datos, entorno y partición versionados.
- ▶ Un notebook debe ejecutarse de principio a fin en un entorno limpio.
- ▶ La herramienta se elige por el ciclo de vida y el equipo, no por preferencia personal.


Caso movilidad: formulación coherente

Decisión operativa

Antes de cada franja, el responsable decide si reasigna vehículos entre zonas.

- ▶ **Unidad:** zona-franja.
 - ▶ **Población:** zonas operadas en condiciones normales.
 - ▶ **Horizonte:** próxima franja de 30 minutos.
 - ▶ **Resultado:** demanda y espera por zona-franja.
 - ▶ **Acciones:** mantener o proponer traslados factibles.
 - ▶ **Restricciones:** capacidad, distancia, seguridad y cobertura.
 - ▶ **Valor:** reducir espera extrema sin aumentar cancelaciones.
 - ▶ **Autoridad:** responsable de operaciones.
- La unidad coincide con el nivel de predicción y de reasignación.

Movilidad: evidencia, recomendación y autoridad



Límite de automatización

El sistema recomienda y puede abstenerse; no ejecuta traslados ni reemplaza protocolos de seguridad.


Del caso amplio a tareas concretas

Objetivo	Tarea sobre zona-franja	Producto y evaluación
Describir	Agregar viajes, espera y oferta observada	Perfil por zona-franja
Predecir	Estimar demanda o espera de la próxima franja	Pronóstico vs. baseline temporal
Prescribir	Comparar reasignaciones factibles	Opciones, utilidad y restricciones
Monitorear	Detectar cambio en datos, error e impacto	Alertas, revisión o retirada

Granularidad

Los eventos de viaje se agregan a zona-franja; el resultado no se presenta como una decisión por viaje individual.

Fuga temporal: saber hoy lo que mañana ocurrió



Prueba

Reconstruir para cada fila qué eventos habían sido recibidos, no solo cuáles ocurrieron antes. Tiempo de evento, recepción y decisión son relojes distintos.

Actividad guiada: ficha del problema

En equipos, completar para movilidad:

- 1 necesidad, usuario, responsable y personas afectadas;
- 2 unidad zona-franja, población, alcance y exclusiones;
- 3 decisión, acciones permitidas y autoridad final;
- 4 fecha de corte, horizonte, entradas disponibles y resultado;
- 5 pregunta descriptiva, predictiva y prescriptiva;
- 6 fuentes, procedencia y regla de integración;
- 7 baseline, valor, restricciones y condición de detención;
- 8 un riesgo de fuga temporal y su control.

Tiempo sugerido

30 minutos de trabajo + 10 minutos de contraste.

Crterios de revisi3n

La ficha es adecuada si:

- ▶ la unidad **zona-franja** coincide con pregunta, tabla y acci3n;
- ▶ poblaci3n, alcance, horizonte y exclusiones son verificables;
- ▶ cada entrada existe y puede recibirse antes de decidir;
- ▶ descripci3n, predicci3n y prescripci3n no se confunden;
- ▶ las fuentes conservan procedencia y reglas de integraci3n;
- ▶ el baseline representa una alternativa realista;
- ▶ valor, riesgos y criterios de detenci3n est3n expl3citos;
- ▶ una persona con autoridad aprueba, modifica o rechaza la acci3n.

Entregable de semana 1

Ficha de una p3gina + diagrama necesidad → evidencia → decisi3n → impacto.

Puesta en común

Cada equipo presenta en un minuto:

- 1 la decisión y quién conserva autoridad;
- 2 la unidad, el corte temporal y el horizonte;
- 3 el baseline y la métrica de valor;
- 4 el supuesto que podría invalidar el proyecto.

Preguntas para contrastar

- ▶ ¿La evidencia llega antes y a la misma granularidad que la decisión?
- ▶ ¿Qué representa la muestra y qué zonas quedan fuera?
- ▶ ¿Qué resultado justificaría modificar o detener el proyecto?


Síntesis: siete ideas para conservar

- 1 Los datos son representaciones parciales producidas por procesos.
- 2 La Ciencia de Datos construye evidencia, no solo modelos.
- 3 Describir, predecir y decidir son problemas distintos.
- 4 Unidad, población, alcance y horizonte preceden al algoritmo.
- 5 Workflow, KDD y CRISP-DM son iterativos y trazables.
- 6 Procedencia y reproducibilidad sostienen lo que podemos afirmar.
- 7 La autoridad y responsabilidad pertenecen a personas y organizaciones.

Idea de cierre

Primero se diseña la decisión y la evidencia necesaria; después se eligen datos, métodos y herramientas.

Síntesis visual: la cadena completa



Cada flecha es una decisión documentable; cada retorno es una oportunidad de aprender.

Lecturas y recursos

Lectura principal

- ▶ **Capítulo 1:** secciones 1.1.1, 1.1.4, 1.1.5 y 1.1.6.
- ▶ **Capítulo 2:** secciones 2.1 a 2.4, con énfasis en 2.1.3, 2.2.1, 2.2.2, 2.3 y 2.4.

Para continuar

- ▶ Revisar los glosarios de ambos capítulos.
- ▶ Completar la ficha inicial del caso de movilidad.
- ▶ Dibujar el linaje de una fuente hasta la unidad zona-franja.