

Adquisición, comprensión y preparación inicial de datos

De fuentes heterogéneas a una tabla analítica defendible

Curso de Data Science

Semana 2 · Clase 2

Propósito y resultados de aprendizaje

Propósito: adquirir, comprender y preparar datos sin separar decisiones técnicas de su significado y uso.

Al finalizar, podremos

- ▶ distinguir fuente, archivo, tabla, dataset y producto;
- ▶ documentar procedencia, unidad, granularidad y regla de una fila;
- ▶ evaluar calidad, faltantes, duplicados, claves y cardinalidad;
- ▶ integrar viajes, zonas y clima en una tabla **zona-hora**;
- ▶ explicar pérdidas de agregación y límites del análisis.

Correspondencia: capítulos **2, 3 y 4** del libro.

La preparación comienza con una pregunta

Punto de partida

“Tenemos muchos archivos” no define un problema de datos.

Para describir entregas tardías por sucursal-día debemos precisar:

- ▶ producto esperado: tabla, gráfico o decisión;
- ▶ unidad final: sucursal-día;
- ▶ población, periodo y exclusiones;
- ▶ variables necesarias y momento de disponibilidad.

La pregunta determina qué adquirir y cómo representarlo.

Fuente, archivo, tabla, dataset y producto

Concepto	Función	Ejemplo breve
Fuente	Sistema o institución de origen	portal municipal
Archivo	Objeto de intercambio	enero.parquet
Tabla	Estructura de filas y columnas	viajes
Dataset	Colección delimitada y documentada	viajes + diccionario
Producto	Evidencia destinada a un uso	perfil zona-hora

Distinción

Un dataset puede usar varios archivos; el producto es una transformación, no otro nombre para la fuente.

Procedencia y linaje



- ▶ Registrar responsable, propósito, URL, acceso, versión y licencia.
- ▶ Conservar filtros, conversiones, uniones y artefactos resultantes.

Dos preguntas

Procedencia: ¿de dónde viene? Linaje: ¿qué le hicimos?

Unidad y granularidad

Unidad de análisis

Entidad elemental sobre la que se describe o compara.

Granularidad

Nivel de detalle temporal, espacial y de entidad.

Representación	Unidad	Granularidad
ventas	transacción	producto-instante
resumen	tienda-día	tienda $\times$ día

Cambiar granularidad cambia preguntas válidas, dependencias y filas.

La regla de una fila

Completar antes de limpiar

Una fila representa _____.

Ejemplo: “una medición de un sensor en un instante”, no “un sensor”.

- ▶ ¿Qué columnas identifican esa unidad?
- ▶ ¿Una clave repetida es repetición, corrección o duplicado?
- ▶ ¿Listas, intervalos o medidas repetidas rompen la regla?

Riesgo

Sin esta regla, `drop_duplicates()` puede borrar observaciones legítimas.

Tipos físicos y tipos semánticos

Valor	Tipo físico	Tipo semántico correcto
00123	texto	identificador nominal
2024-01-05	texto	fecha
1, 2, 3	entero	categoría ordinal
-73.98	decimal	longitud geográfica

Principio

El tipo físico permite operaciones; el semántico determina cuáles tienen sentido.

Promediar códigos postales es computable, pero inválido.

Calidad apta al propósito

Dimensión	Pregunta de control
Compleitud	¿Faltan campos o unidades necesarias?
Validez	¿Cumple dominio, formato y rango?
Consistencia	¿Concuerdan campos y fuentes?
Unicidad	¿La clave identifica una fila?
Oportunidad	¿Llega antes de usarla?
Cobertura	¿Representa población, lugar y periodo?

Un dato puede ser correcto y aun así no ser apto.

Faltantes: ausencia con significado

Un nulo puede significar:

- ▶ no medido, no aplicable o desconocido;
- ▶ fallo de captura o unión sin correspondencia;
- ▶ valor censurado o todavía no disponible.

Diagnóstico mínimo

Proporción por variable, patrón por grupo y periodo, y relación con el proceso de captura.

No imputar hasta explicar el mecanismo y el costo de equivocarse.

Duplicados: definir antes de eliminar

Exacto

Todas las columnas coinciden.

De clave

Coincide la clave; difieren atributos.

De entidad

Mismo objeto sin clave común.

Ejemplo: dos lecturas del mismo paciente-hora pueden ser duplicados, reintentos o mediciones válidas.

Decisión documentada

Conservar, consolidar, versionar o excluir según la regla de una fila y el proceso generador.

Claves y cardinalidad

- ▶ **Clave primaria:** identifica filas en una tabla.
- ▶ **Clave foránea:** referencia otra tabla.
- ▶ **Cardinalidad:** one_to_one, many_to_one, one_to_many o many_to_many.

Ejemplo

Muchas ventas pertenecen a una tienda: ventas → tiendas es **many-to-one**.

Una unión many-to-many accidental multiplica filas y totales.


Integración segura

- 1 Declarar unidad y clave de cada tabla.
- 2 Verificar unicidad del lado que debe ser “uno”.
- 3 Validar cardinalidad en el código.
- 4 Medir coincidencias y no coincidencias.
- 5 Comprobar filas, unidades y totales antes y después.

Principio

Toda unión es una hipótesis sobre correspondencia.

Integración temporal



- ▶ Interpretar zona horaria de origen y convertir a una común.
- ▶ Definir intervalos, bordes y horario de verano.
- ▶ Agregar fuentes a granularidad compatible.

No equivalencia

10:00 UTC $\neq$ 10:00 America/New_York

Integración espacial

Una relación espacial puede usar:

- ▶ identificador administrativo estable;
- ▶ punto dentro de polígono;
- ▶ zona más cercana o intersección.

Registrar siempre

Sistema de referencia de coordenadas (CRS), versión de límites y casos sin zona.

Un centroide resume geometría; no reemplaza el polígono.

Agregación y pérdida de información

$$n_g = \sum_i \mathbb{I}(G_i = g), \quad \bar{x}_g = \frac{1}{n_g} \sum_{i: G_i = g} x_i$$

Ganamos

Comparabilidad, menor volumen y unidad útil para la pregunta.

Perdemos

Orden intra-grupo, detalle individual y reconstrucción de casos.

Conservar conteo, dispersión, cobertura y regla junto a la media.

Reproducibilidad desde la adquisición

Una ejecución reconstruible registra:

- ▶ URL, fecha de acceso, periodo y parámetros;
- ▶ versiones de librerías y formato;
- ▶ código ordenado de inicio a fin;
- ▶ validaciones y decisiones de exclusión;
- ▶ salida con esquema, clave y procedencia.


Notebook de la clase

Taller_Clase_02_Movilidad.ipynb

Del concepto al taller

Pregunta descriptiva

¿Cómo varían los viajes Yellow Taxi reportados por zona de origen y hora, y qué asociación muestran con el clima?



Viajes reportados por TLC $\neq$ demanda total de movilidad.

Taller 1: fuentes y contrato analítico

Notebook: Taller_Clase_02_Movilidad.ipynb

Fuente	Archivo / tabla	Unidad original
NYC TLC	Yellow Taxi enero 2024, Parquet	viaje reportado
NYC TLC	taxi_zone_lookup.csv	zona-ID
NYC TLC	taxi_zones.zip, shapefile	polígono-zona
NOAA GHCNh	estación USW00094728, PSV	estación-observación

Producto

Una fila = **zona de origen-hora local**; clave: PULocationID, hora.

Taller 2: construir la URL TLC

```
def construir_url_tlc(tipo, anio, mes):  
    prefijos = {  
        "yellow": "yellow_tripdata",  
        "green": "green_tripdata",  
        "fhv": "fhv_tripdata",  
        "fhvhv": "fhvhv_tripdata",  
    }  
    return ("https://d37ci6vzurychx.cloudfront.net/trip-data/"  
           f"{prefijos[tipo]}_{anio}-{mes:02d}.parquet")
```

Parámetros explícitos hacen visible el periodo y evitan editar URL manualmente.

Taller 3: cargar Parquet con proyección

```
cols = ["tpep_pickup_datetime", "tpep_dropoff_datetime",  
        "PULocationID", "DOLocationID", "passenger_count",  
        "trip_distance", "fare_amount", "total_amount"]  
url = construir_url_tlc("yellow", 2024, 1)  
viajes = pd.read_parquet(url, columns=cols)  
print(viajes.shape)
```

Procedencia

Fuente pública y secundaria, generada con propósito operativo/administrativo.

Taller 4: inspeccionar antes de transformar

```
viajes.info()  
display(viajes.head(3))  
display(viajes.describe(include="all").T)  
print(viajes.dtypes)
```

- ▶ ¿Qué representa una fila y qué rango temporal aparece?
- ▶ ¿Los ID son medidas o categorías?
- ▶ ¿Hay importes o duraciones imposibles?

La inspección genera hipótesis; los controles las verifican.

Taller 5: controles de calidad básicos

```
clave = ["tpep_pickup_datetime", "tpep_dropoff_datetime",  
         "PULocationID", "DOLocationID", "total_amount"]  
  
qc = {  
    "nulos_pct": viajes.isna().mean().mul(100),  
    "duplicados_clave": viajes.duplicated(clave).sum(),  
    "duracion_no_positiva": (viajes.tpep_dropoff_datetime <=  
                             viajes.tpep_pickup_datetime).sum(),  
}
```

La clave es una aproximación operativa, no un ID oficial de viaje.

Taller 6: validez y filtros explícitos

```
validos = (  
    viajes["PULocationID"].notna()  
    & (viajes["trip_distance"] >= 0)  
    & (viajes["total_amount"] >= 0)  
    & (viajes["tpep_dropoff_datetime"] >  
        viajes["tpep_pickup_datetime"])  
)  
viajes_limpios = viajes.loc[validos].copy()
```

El catálogo TLC validará los ID al unir. Plausibilidad no equivale a verdad.

Taller 7: zonas y unión many-to-one

```
zones_url = ("https://d37ci6vzurychx.cloudfront.net/"
             "misc/taxi_zone_lookup.csv")
zonas = pd.read_csv(zones_url)
assert zonas["LocationID"].is_unique
viajes_z = viajes_limpios.merge(
    zonas, left_on="PULocationID", right_on="LocationID",
    how="left", validate="many_to_one", indicator=True)
```

Auditar `_merge`: cada viaje encuentra como máximo una zona.

Taller 8: cobertura y pérdidas de la unión

```
cobertura = viajes_z["_merge"].value_counts(dropna=False)
sin_zona = viajes_z.loc[
    viajes_z["_merge"] == "left_only", "PULocationID"
].value_counts()
assert len(viajes_z) == len(viajes_limpios)
print(cobertura, sin_zona.head())
```

Interpretación

Una unión izquierda conserva viajes, pero puede dejar atributos nulos.

Taller 9: shapefile y geometría

```
geo_url = ("https://d37ci6vzurychx.cloudfront.net/"  
          "misc/taxi_zones.zip")  
zonas_geo = gpd.read_file(f"zip://{geo_url}")  
zonas_geo["LocationID"] = zonas_geo["LocationID"].astype(int)  
zonas_geo = zonas_geo.to_crs(4326)  
assert zonas_geo["LocationID"].is_unique
```

El lookup aporta nombres; el shapefile, polígonos. Registrar CRS y versión.

Taller 10: construir zona-hora

```
viajes_z["hora"] = (  
    viajes_z["tpep_pickup_datetime"]  
    .dt.tz_localize("America/New_York", ambiguous="NaT",  
                    nonexistent="shift_forward")  
    .dt.floor("h")  
)  
zona_hora = (viajes_z.groupby(["PULocationID", "hora"])  
    .agg(viajes_reportados=("PULocationID", "size"),  
         distancia_medio=("trip_distance", "mean")).reset_index())
```

Cambia la unidad de viaje a zona-hora y elimina detalle individual.

Taller 11: NOAA e interpretación UTC

```
meteo_url = ("https://www.ncei.noaa.gov/oa/global-historical-"  
            "climatology-network/hourly/access/by-year/2024/psv/"  
            "GHCNh_USW00094728_2024.psv")  
clima = pd.read_csv(meteo_url, sep="|", low_memory=False)  
clima["DATE.UTC"] = pd.to_datetime(clima["DATE"], utc=True)  
clima["DATE_NY"] = clima["DATE.UTC"].dt.tz_convert(  
    "America/New_York")
```

Convertimos un instante UTC; no solo la etiqueta de una hora ingenua.

Taller 12: clima horario de enero

```
inicio = pd.Timestamp("2024-01-01", tz="America/New_York")
fin = pd.Timestamp("2024-02-01", tz="America/New_York")
clima_mes = clima[clima["DATE_NY"].between(
    inicio, fin, inclusive="left")].copy()
clima_mes["hora"] = clima_mes["DATE_NY"].dt.floor("h")
vars_num = ["temperature", "relative_humidity",
            "wind_speed", "precipitation"]
clima_h = clima_mes.groupby("hora")[vars_num].mean().reset_index()
```

Promediar muestras subhorarias pierde extremos y secuencia.

Taller 13: unir zona-hora con clima

```
assert clima_h["hora"].is_unique
analitica = zona_hora.merge(
    clima_h, on="hora", how="left",
    validate="many_to_one", indicator="union_clima")
print(analitica["union_clima"].value_counts())
print(analitica.isna().mean()
      .sort_values(ascending=False).head())
```

Una estación para muchas zonas supone representatividad espacial.

Taller 14: perfil horario de viajes reportados

```
perfil_hora = (analitica.assign(
    hora_dia=analitica["hora"].dt.hour)
    .groupby("hora_dia", as_index=False)
    ["viajes_reportados"].sum())
plt.plot(perfil_hora["hora_dia"],
         perfil_hora["viajes_reportados"], marker="o")
plt.ylabel("Viajes Yellow Taxi reportados")
plt.xlabel("Hora local")
```

Describe registros TLC de enero de 2024, no demanda total.

Taller 15: mapa por zona

```
por_zona = (analitica.groupby("PULocationID", as_index=False)
            ["viajes_reportados"].sum())
mapa = zonas_geo.merge(
    por_zona, left_on="LocationID", right_on="PULocationID",
    how="left", validate="one_to_one")
mapa.plot(column="viajes_reportados", cmap="YlGnBu",
          legend=True, missing_kwds={"color": "lightgrey"})
```

Los conteos mezclan actividad, tamaño, cobertura y registro.

Taller 16: clima y asociación descriptiva

```
por_hora = (analitica.groupby("hora", as_index=False)
            .agg(viajes_reportados=("viajes_reportados", "sum"),
                 temperatura=("temperature", "first"),
                 precipitacion=("precipitation", "first")))
plt.scatter(por_hora["temperatura"], por_hora["viajes_reportados"],
            c=por_hora["precipitacion"], cmap="Blues")
r = por_hora[
    ["temperatura", "viajes_reportados"]
].corr().iloc[0, 1]
```

Hora y calendario pueden confundir. **Correlación no implica causalidad.**

Taller 17: guardar un producto reproducible

```
analitica = analitica.sort_values(["hora", "PULocationID"])
assert not analitica.duplicated(
    ["PULocationID", "hora"]).any()
alcance = "semana_1_enero_2024" if MODO_CLASE else "enero_2024"
ruta = Path(tempfile.gettempdir()) / f"zona_hora_{alcance}.parquet"
analitica.to_parquet(ruta, index=False)
metadatos = {"unidad": "zona de origen-hora local",
             "zona_horaria": "America/New_York",
             "fuentes": [url, zones_url, geo_url, meteo_url]}
```

Entregar controles, exclusiones, versiones y fecha de ejecución.

Producto y evidencia de aprendizaje

Entregable: Taller_Clase_02_Movilidad.ipynb ejecutado de inicio a fin.

- ▶ inventario de cuatro fuentes y procedencia;
- ▶ regla de una fila y diccionario semántico mínimo;
- ▶ reporte de faltantes, duplicados, validez, cobertura y cardinalidad;
- ▶ tabla zona-hora temporal con alcance explícito y clave única;
- ▶ perfil horario, mapa y gráfico clima-viajes;
- ▶ cinco hallazgos con evidencia y tres límites.

Criterio

Otra persona puede ejecutar, auditar y explicar cada transformación.

Límites y afirmaciones permitidas

Podemos describir **viajes Yellow Taxi reportados** y asociaciones en el periodo y cobertura analizados. **No podemos afirmar directamente:**

- ▶ demanda total de movilidad o solicitudes no atendidas;
- ▶ comportamiento de todas las plataformas, personas o meses;
- ▶ causalidad del clima sobre los viajes;
- ▶ clima idéntico en toda zona por usar una estación;
- ▶ exactitud de cada registro por superar controles de plausibilidad.

Cierre: de datos disponibles a evidencia defendible

- 1 Formular propósito y producto antes de descargar.
- 2 Declarar fuente, procedencia, unidad y regla de una fila.
- 3 Tratar tipos, faltantes y duplicados según significado.
- 4 Validar claves, cardinalidad y cobertura al integrar.
- 5 Alinear tiempo y espacio antes de agregar.
- 6 Documentar pérdidas, límites y cadena reproducible.

Para continuar

Capítulos 2, 3 y 4. Próximo paso: exploración estadística sin exceder lo que los datos representan.