

Guía docente: Adquisición, comprensión y preparación inicial de datos

Curso: Data Science

Semana y clase: semana 2, clase 2

Presentación asociada: *Adquisición, comprensión y preparación inicial de datos: de fuentes heterogéneas a una tabla analítica defendible* (38 diapositivas)

Notebook asociado: [Taller_Clase_02_Movilidad.ipynb](#)

Fuentes principales: capítulos 2, 3 y 4 del libro *Ciencia de Datos e Inteligencia Artificial*

Propósito y forma de uso

Esta guía sincroniza la exposición conceptual con un taller de datos públicos sobre viajes de NYC TLC Yellow Taxi, zonas de taxi y clima NOAA. La meta no es obtener una cifra predeterminada, sino construir y auditar una tabla cuya fila representa una **zona de origen-hora local**. Los conteos, porcentajes, asociaciones y gráficos dependen de la disponibilidad de las fuentes, de **MODO_CLASE** y de los filtros ejecutados; por ello se comprueba la lógica y no se anticipan resultados numéricos.

La sesión debe conservar una distinción central: los registros son **viajes reportados**, no demanda total de movilidad. La tabla analítica permite descripción y asociación exploratoria; no identifica causalidad ni representa por sí sola toda la ciudad, todos los servicios o todo el clima urbano.

Recorrido por bloques

Bloque	Diapositivas	Resultado esperado
Bloque conceptual	1-17	Delimitar producto, procedencia, unidad, calidad, integración, agregación y reproducibilidad
Transición	18	Convertir los conceptos en pregunta, flujo y límites del caso
Taller guiado	19-35	Adquirir, inspeccionar, auditar, integrar, agregar, visualizar y guardar el producto
Producto	36	Presentar evidencias y artefactos verificables
Límites	37	Formular únicamente afirmaciones compatibles con cobertura y diseño
Cierre	38	Recuperar el proceso completo y enlazar con exploración estadística

Tesis de la clase: preparar datos no es aplicar una secuencia automática de limpieza. Es justificar qué representa cada fila, de dónde proviene, qué reglas soporta, qué se pierde al transformar y para qué afirmaciones sigue siendo apta.

Agenda temporal sugerida: 150 minutos

Tiempo	Actividad	Diapositivas
0-8 min	Apertura, propósito y pregunta rectora	1-3
8-30 min	Objetos de datos, procedencia, unidad y regla de una fila	4-7
30-52 min	Tipos, calidad, faltantes, duplicados y claves	8-12
52-68 min	Integración temporal/espacial, agregación y reproducibilidad	13-17
68-73 min	Transición y contrato del taller	18-19
73-81 min	Pausa breve	--
81-111 min	Adquisición, inspección, auditoría y zonas	20-27
111-132 min	Zona-hora, clima e integración	28-31
132-143 min	Visualizaciones, asociación y guardado	32-35
143-150 min	Producto, límites y cierre	36-38

Los tiempos son orientativos. Si las descargas se retrasan, priorizar los controles de unidad, calidad, cardinalidad y cobertura; la extensión espacial puede demostrarse sin esperar su renderizado.

Preparación previa del docente

1. Confirmar internet estable y acceso desde el entorno de clase a las cuatro URL definidas en [URL_VIAJES](#), [URL_ZONAS](#), [URL_GEOMETRIAS](#) y [URL_CLIMA](#).
2. Verificar dependencias base: [pandas](#), [numpy](#), [matplotlib](#), [pyarrow](#) e IPython. Para la extensión opcional, verificar [geopandas](#), [folium](#) y [requests](#).
3. Abrir una copia de trabajo del notebook y mantener `MODO_CLASE = True`; esta opción procesa la primera semana consecutiva y reduce tiempo sin convertirla en muestra aleatoria.
4. Ejecutar el notebook de inicio a fin antes de la sesión, incluidas las comprobaciones y, si el entorno lo permite, la extensión espacial. Revisar mensajes de error, cambios de esquema y nombres de columnas NOAA.
5. Comprobar que el entorno permite leer Parquet remoto con filtros mediante [pyarrow](#) y que las fechas quedan con zona [America/New_York](#) después de la conversión.
6. No guardar datasets descargados en el repositorio. Si se necesita conservar el producto para evaluación, usar almacenamiento temporal del entorno, una carpeta externa o la descarga local del artefacto generado.

Plan B offline, sin añadir datasets al repositorio

Antes de clase, ejecutar el notebook conectado y conservar **fuera del repositorio** una copia temporal de los recursos requeridos, por ejemplo en el almacenamiento local privado del docente, una unidad institucional o el directorio temporal del entorno. Registrar junto a esa copia URL, fecha de acceso y nombre original. En clase, si falla internet, sustituir únicamente las cuatro variables URL por rutas locales externas y mantener intactas las

celdas de validación, filtrado, unión y análisis. Para Parquet se conserva `columns` y, si el motor local admite el filtro, `filters`; CSV/PSV se leen desde la ruta externa; el ZIP espacial se pasa a `geopandas` desde esa ubicación.

Si no existe una copia externa autorizada, usar la ejecución previa ya visible para discutir esquema, auditorías y gráficos, y realizar en vivo ejercicios de lectura de código y predicción de invariantes. No fabricar cifras, no presentar capturas como una nueva fuente y no incorporar datos ni salidas al control de versiones. Explicar que este plan preserva la enseñanza del flujo, pero no demuestra reproducibilidad de red en ese momento; registrar la incidencia y repetir la ejecución conectada después.

Evaluación del producto

Criterio	Evidencia observable	Peso sugerido
Contrato y procedencia	Cuatro fuentes, periodo, unidad, clave, zona horaria y propósito declarados	20 %
Calidad y decisiones	Faltantes, duplicados o aproximación de clave, reglas de validez, exclusiones y sensibilidad justificadas	20 %
Integración verificable	Unicidad del lado “uno”, <code>validate</code> , conservación de filas y cobertura de zonas/clima	20 %
Producto reproducible	Notebook ejecutable, tabla zona-hora con clave única, orden, metadatos y procedencia	20 %
Comunicación responsable	Perfil, mapa o extensión espacial, gráficos clima-viajes, hallazgos con evidencia y al menos tres límites	20 %

Una falla crítica de cardinalidad no resuelta, una unidad ambigua o una afirmación causal invalida la defensa aunque los gráficos se rendericen. No calificar por obtener conteos idénticos entre fechas de ejecución; calificar reglas, trazabilidad e interpretación.

Pautas para los ejercicios del notebook

Pregunta breve sobre ventana consecutiva. Una semana consecutiva conserva orden, ciclos diarios, horas contiguas y denominador temporal. Una muestra aleatoria puede fragmentar horas y alterar conteos; la ventana tampoco garantiza representar el mes completo.

Ejercicio 1, sensibilidad de distancia. Construir una máscara independiente, sin modificar `viajes_validos: fuera_con_umbral_50 = (~calidad["trip_distance"].between(0, 50)).sum()`. Comparar conceptualmente con `ok_distancia` y explicar que el cambio mide sensibilidad a una decisión de dominio; el total debe leerse de la ejecución.

Ejercicio 2, cobertura temporal. Crear `horas_esperadas = pd.date_range(inicio_local, fin_local, freq="h", inclusive="left")` y obtener `horas_sin_clima = horas_esperadas.difference(clima_horario["hora"])`. Interpretar los huecos reales sin presuponer cuántos existen; verificar también que ambas series sean conscientes de zona horaria.

Ejercicio 3, interpretar sin exagerar. Aceptar observaciones que nombren variable, dirección o franja, ventana analizada y evidencia gráfica. Exigir una explicación alternativa como hora del día, día de semana, aeropuerto, feriado, oferta o selección. Rechazar lenguaje causal y generalizaciones desde `MODO_CLASE=True` al mes completo.

Diapositiva 1. Adquisición, comprensión y preparación inicial de datos

- Correspondencia con el libro.** Capítulos 2, ciclo y fuentes; 3, preparación e integración; 4, exploración y visualización.
- Propósito.** Presentar la preparación como construcción de una tabla analítica defendible, no como limpieza mecánica.
- Guion sugerido.** Abrir con: “Hoy partiremos de fuentes heterogéneas y terminaremos en una fila cuyo significado, clave y límites podemos explicar”. Anticipar viajes, zonas y clima.
- Conceptos y términos.** *Adquisición*: obtención documentada; *comprensión*: interpretación de estructura y significado; *preparación*: transformaciones justificadas; *defendible*: reconstruible y limitada a afirmaciones permitidas.
- Ejemplo o acción en notebook.** Mostrar el título, la pregunta guía y la ficha de fuentes, sin ejecutar todavía.
- Error frecuente o límite.** Prometer “datos limpios” como ausencia universal de errores o confundir tabla preparada con verdad completa.
- Comprobación.** Preguntar cuál será la unidad final. Respuesta esperada: zona de origen-hora local.
- Conclusión que debe quedar.** La calidad del producto depende de decisiones semánticas y técnicas trazables.
- Transición sugerida.** “Convirtamos esa meta general en resultados que podamos comprobar al final”.

Diapositiva 2. Propósito y resultados de aprendizaje

- Correspondencia con el libro.** Capítulo 2, §§2.2-2.4; capítulo 3, §§3.1-3.3; capítulo 4, exploración descriptiva.
- Propósito.** Fijar el contrato de aprendizaje de la sesión.
- Guion sugerido.** Recorrer los cinco resultados en orden: distinguir objetos, documentar representación, evaluar calidad, integrar a zona-hora y declarar pérdida y límites. Subrayar que cada resultado tendrá evidencia en el notebook.
- Conceptos y términos.** *Procedencia*, *granularidad*, *regla de una fila*, *cardinalidad*, *reproducibilidad* y *tabla analítica*.
- Ejemplo o acción en notebook.** Vincular los objetivos del notebook con los resultados; aclarar que “pickups” es el conteo de viajes reportados con origen registrado.
- Error frecuente o límite.** Reducir el objetivo a descargar archivos o producir gráficos.
- Comprobación.** Pedir dos controles indispensables al integrar. Respuestas válidas: cardinalidad y cobertura, además de filas, claves o totales pertinentes.
- Conclusión que debe quedar.** El producto deberá ser interpretable, verificable y reproducible.
- Transición sugerida.** “Para decidir qué datos sirven, primero hace falta una pregunta suficientemente precisa”.

Diapositiva 3. La preparación comienza con una pregunta

- Correspondencia con el libro.** Capítulo 2, formulación del problema, comprensión del negocio y de los datos.
- Propósito.** Mostrar que pregunta y producto determinan adquisición y representación.
- Guion sugerido.** Usar el ejemplo sucursal-día: precisar producto, unidad, población, periodo, exclusiones y disponibilidad. Contrastar “tenemos archivos” con una necesidad analítica delimitada.
- Conceptos y términos.** *Producto esperado*, *población*, *periodo*, *exclusión*, *momento de disponibilidad*.
- Ejemplo o acción en notebook.** Leer la pregunta guía y pedir que identifiquen producto, periodo y unidad antes de ejecutar. La unidad final se completa con el contrato de la diapositiva 19.

Error frecuente o límite. Elegir columnas disponibles y después inventar una pregunta que las justifique.

Comprobación. “¿Cambiaría la adquisición si el producto fuera viaje individual en vez de zona-hora?”. Sí: cambiarían unidad, clave, integración y afirmaciones.

Conclusión que debe quedar. La pregunta restringe qué adquirir, conservar, transformar y comunicar.

Transición sugerida. “Antes de descargar, distinguamos los objetos que solemos llamar indistintamente datos”.

Diapositiva 4. Fuente, archivo, tabla, dataset y producto

Correspondencia con el libro. Capítulo 2, §2.3 sobre fuentes, tipos y arquitectura; §2.4 sobre artefactos reproducibles.

Propósito. Evitar que origen, contenedor, estructura, colección y resultado se usen como sinónimos.

Guion sugerido. Leer cada fila de la tabla y encadenar un ejemplo: portal TLC, Parquet mensual, tabla de viajes, conjunto documentado y perfil zona-hora. El producto siempre implica transformación y propósito.

Conceptos y términos. *Fuente*: sistema de origen; *archivo*: objeto intercambiable; *tabla*: filas y columnas; *dataset*: colección delimitada y documentada; *producto*: evidencia preparada para uso.

Descripción visual relevante. La tabla tiene tres columnas: concepto, función y ejemplo. Leer horizontalmente cada fila y después verticalmente la primera columna; no interpretar los cinco objetos como etapas obligatorias ni relación uno a uno.

Ejemplo o acción en notebook. Identificar TLC y NOAA como fuentes, Parquet/CSV/ZIP/PSV como archivos, DataFrames como tablas y `zona_hora_clima` como producto analítico intermedio/final.

Error frecuente o límite. Llamar “fuente” a una copia descargada o “dataset” a cualquier DataFrame sin alcance ni documentación.

Comprobación. Preguntar si un ZIP espacial es ya la tabla zona-hora. No: es un archivo con recursos geométricos.

Conclusión que debe quedar. Saber qué objeto se nombra aclara procedencia y responsabilidad.

Transición sugerida. “Ahora reconstruyamos el camino desde el fenómeno hasta el producto”.

Diapositiva 5. Procedencia y linaje

Correspondencia con el libro. Capítulo 2, adquisición, procedencia, documentación y reproducibilidad.

Propósito. Diferenciar origen documentado y cadena de transformaciones.

Guion sugerido. Recorrer fenómeno, captura, fuente, extracción, transformaciones y producto. Para cada fuente registrar responsable, propósito original, URL, acceso, versión, licencia, filtros y uniones.

Conceptos y términos. *Procedencia*: de dónde viene; *linaje*: qué transformaciones y decisiones condujeron al artefacto.

Descripción visual relevante. El diagrama es una cadena lineal `fenómeno → captura → fuente → extracción → transformaciones → producto`. Las flechas significan dependencia trazable, no copia exacta ni garantía de calidad; leer también hacia atrás desde el producto para preguntar qué debe reconstruirse.

Ejemplo o acción en notebook. Revisar “Ficha de fuentes” y las constantes `URL_*`; pedir anotar fecha de acceso y `MODULO_CLASE` en la entrega.

Error frecuente o límite. Registrar solo la URL final o suponer que una licencia corrige problemas de cobertura y significado.

Comprobación. “¿Dónde queda documentado que solo se leyó la primera semana?”. En parámetros/filtros y metadatos de ejecución, no en el nombre del archivo original.

Conclusión que debe quedar. Procedencia y linaje permiten explicar y regenerar el producto.

Transición sugerida. “Para reconstruir una tabla también debemos saber qué representa cada observación”.

Diapositiva 6. Unidad y granularidad

Correspondencia con el libro. Capítulo 2, unidad y alcance; capítulo 3, estructura tabular y transformación.

Propósito. Separar entidad elemental y nivel de detalle.

Guion sugerido. Contrastar transacción producto-instante con resumen tienda-día. Explicar que cambiar granularidad modifica preguntas, dependencias y número de filas.

Conceptos y términos. *Unidad de análisis*: entidad elemental descrita; *granularidad*: detalle temporal, espacial y de entidad.

Ejemplo o acción en notebook. Señalar el cambio de viaje en `viajes_originales` a zona-hora en `pickups_zona_hora`.

Error frecuente o límite. Decir que una tabla es “por zona” omitiendo hora, o comparar medias sin reconocer unidades distintas.

Comprobación. Pedir la unidad antes y después de `groupby`: viaje reportado y zona de pickup-hora local.

Conclusión que debe quedar. Toda transformación debe declarar si conserva o cambia la unidad.

Transición sugerida. “Hagamos esa declaración operativa con una frase que pueda comprobarse”.

Diapositiva 7. La regla de una fila

Correspondencia con el libro. Capítulo 3, §3.1 sobre estructura, claves, perfiles y diccionarios.

Propósito. Establecer una frase verificable antes de limpiar o deduplicar.

Guion sugerido. Completar “una fila representa...”, identificar columnas candidatas a clave y discutir si coincidencias significan repetición, corrección o evento válido.

Conceptos y términos. *Regla de una fila*, *clave candidata*, *medida repetida*, *duplicado legítimo* o *problemático*.

Ejemplo o acción en notebook. Para `viajes_originales`, una fila es un viaje Yellow Taxi reportado sin identificador oficial expuesto; para `pickups_zona_hora`, una fila es una combinación única `pickup_hora`, `PULocationID`.

Error frecuente o límite. Ejecutar `drop_duplicates()` sin definir unidad; la aproximación de columnas de viaje puede colisionar con eventos distintos.

Comprobación. Verificar el `assert` de no duplicidad en `pickups_zona_hora` y pedir que expliquen qué garantiza y qué no.

Conclusión que debe quedar. La regla de una fila precede a claves, duplicados y agregaciones.

Transición sugerida. “Con la unidad clara, distinguamos cómo está almacenado un valor de lo que significa”.

Diapositiva 8. Tipos físicos y tipos semánticos

- Correspondencia con el libro.** Capítulo 2, tipos de datos; capítulo 3, comprensión, diccionario y conversiones.
- Propósito.** Evitar operaciones computables pero conceptualmente inválidas.
- Guion sugerido.** Leer los cuatro ejemplos de la tabla. Señalar que formato físico habilita operaciones, mientras significado determina si son válidas.
- Conceptos y términos.** *Tipo físico, tipo semántico, identificador nominal, categoría ordinal, fecha, coordenada.*
- Ejemplo o acción en notebook.** Inspeccionar `dtypes`; tratar `PULocationID` como identificador aunque sea numérico y `tpep_pickup_datetime` como tiempo local ingenuo hasta localizarlo.
- Error frecuente o límite.** Promediar IDs de zona o asumir que toda columna numérica es una medida continua.
- Comprobación.** “¿Qué significa la media de `PULocationID`?”. Ninguna cantidad geográfica interpretable.
- Conclusión que debe quedar.** El diccionario semántico gobierna transformaciones válidas.
- Transición sugerida.** “Tipos correctos no bastan: la calidad siempre debe juzgarse contra un propósito”.

Diapositiva 9. Calidad apta al propósito

- Correspondencia con el libro.** Capítulo 3, §3.1 sobre evaluación y perfiles de calidad.
- Propósito.** Definir calidad como suficiencia para un uso declarado.
- Guion sugerido.** Recorrer completitud, validez, consistencia, unicidad, oportunidad y cobertura. Dar un contraejemplo: un valor correcto que llega después de decidir no es apto.
- Conceptos y términos.** Las seis dimensiones de la tabla y *apto al propósito*.
- Descripción visual relevante.** La tabla empareja cada dimensión con una pregunta de control. Leer cada par como prueba distinta; ninguna fila resume por sí sola “calidad total” y las dimensiones pueden entrar en tensión.
- Ejemplo o acción en notebook.** Relacionar `faltantes`, columnas `ok_*`, unicidad de claves y `auditoria_union` con dimensiones distintas.
- Error frecuente o límite.** Convertir dimensiones en una puntuación única que oculte una falla crítica.
- Comprobación.** Pedir qué dimensión evalúa una zona válida ausente del lookup: cobertura/consistencia de integración, no solo completitud de la tabla original.
- Conclusión que debe quedar.** Cada control necesita una pregunta de uso y una consecuencia.
- Transición sugerida.** “Comencemos por una señal visible cuya causa no puede inferirse solo desde la celda: el faltante”.

Diapositiva 10. Faltantes: ausencia con significado

- Correspondencia con el libro.** Capítulo 3, limpieza y tratamiento de valores ausentes; capítulo 4, omisión de datos.
- Propósito.** Interpretar nulos según mecanismo y costo antes de imputar o excluir.
- Guion sugerido.** Distinguir no medido, no aplicable, desconocido, fallo de captura, no correspondencia, censura y demora. Pedir proporciones por variable, grupo y periodo.
- Conceptos y términos.** *Mecanismo de ausencia, imputación, no aplicable, fallo de unión.*
- Ejemplo o acción en notebook.** Mostrar `faltantes`; explicar por qué `passenger_count` ausente se conserva y solo valores presentes fuera del intervalo se marcan problemáticos.
- Error frecuente o límite.** Rellenar nulos con cero o media sin distinguir ausencia, o eliminar toda fila con algún nulo.
- Comprobación.** “¿Un `passenger_count` nulo invalida automáticamente el viaje?”. No bajo la regla explícita del taller.
- Conclusión que debe quedar.** Un nulo es evidencia sobre captura o integración, no una instrucción automática.
- Transición sugerida.** “La misma precaución se aplica a filas aparentemente repetidas”.

Diapositiva 11. Duplicados: definir antes de eliminar

- Correspondencia con el libro.** Capítulo 3, limpieza, duplicados, claves y consistencia.
- Propósito.** Distinguir coincidencia exacta, de clave y de entidad.
- Guion sugerido.** Usar el ejemplo paciente-hora para mostrar que dos filas pueden ser reintentos, correcciones o mediciones válidas. Exigir regla documentada: conservar, consolidar, versionar o excluir.
- Conceptos y términos.** *Duplicado exacto, de clave, de entidad, resolución de entidades.*
- Ejemplo o acción en notebook.** Discutir la clave operativa propuesta en la presentación; el notebook evita borrar silenciosamente y mantiene rechazados separados.
- Error frecuente o límite.** Tratar una combinación operativa como identificador oficial de viaje.
- Comprobación.** Pedir una razón válida para conservar dos filas con tiempos iguales: pueden ser viajes distintos que coinciden en variables observadas.
- Conclusión que debe quedar.** El significado de repetición depende de unidad, clave y proceso generador.
- Transición sugerida.** “Para controlar repeticiones e integración necesitamos declarar claves y relaciones”.

Diapositiva 12. Claves y cardinalidad

- Correspondencia con el libro.** Capítulo 3, estructura tabular e integración de tablas.
- Propósito.** Prevenir multiplicaciones silenciosas en uniones.
- Guion sugerido.** Definir clave primaria y foránea; recorrer `one_to_one`, `many_to_one`, `one_to_many` y `many_to_many`. Ejemplificar muchas ventas hacia una tienda.
- Conceptos y términos.** *Clave primaria, clave foránea, cardinalidad esperada, multiplicación de filas.*
- Ejemplo o acción en notebook.** `LocationID` debe ser único; muchos viajes referencian una zona. Mostrar `validate="many_to_one"` en ambas uniones del catálogo.

Error frecuente o límite. Confiar en que `merge` avisará por sí solo una relación many-to-many accidental.

Comprobación. Preguntar qué falla si `LocationID` aparece dos veces: deja de ser lado “uno” y puede duplicar viajes.

Conclusión que debe quedar. La cardinalidad es una hipótesis comprobable, no un detalle sintáctico.

Transición sugerida. “Convirtamos esa hipótesis en un protocolo antes y después de cada unión”.

Diapositiva 13. Integración segura

Correspondencia con el libro. Capítulo 3, §3.3 sobre integración y ejemplo guiado.

Propósito. Establecer cinco controles mínimos para unir tablas.

Guion sugerido. Declarar unidad/clave, comprobar unicidad, validar cardinalidad, medir coincidencias y revisar filas/unidades/totales. Repetir que toda unión afirma correspondencia.

Conceptos y términos. *Cobertura de unión, lado uno, coincidencia, invariante.*

Ejemplo o acción en notebook. Señalar `validate`, el `assert len(viajes_zonas) == len(viajes_validos)` y los conteos sin nombre de pickup/dropoff.

Error frecuente o límite. Considerar exitosa una unión solo porque no lanzó excepción; conservar filas no garantiza atributos completos.

Comprobación. Pedir dos preguntas posteriores: ¿cambió el número de viajes?, ¿cuántos quedaron sin zona?

Conclusión que debe quedar. Una unión se acepta por invariantes y cobertura, no por ejecución técnica.

Transición sugerida. “Cuando la clave incluye tiempo, primero hay que reconciliar relojes”.

Diapositiva 14. Integración temporal

Correspondencia con el libro. Capítulos 2 y 3, disponibilidad temporal, transformación e integración.

Propósito. Separar tiempo de evento, registro y disponibilidad, y alinear zonas horarias e intervalos.

Guion sugerido. Explicar que `10:00 UTC` y `10:00 America/New_York` no son el mismo instante. Definir origen, conversión común, bordes, horario de verano y agregación compatible.

Conceptos y términos. *UTC, hora local, timestamp ingenuo/con zona, intervalo semiabierto, horario de verano.*

Ejemplo o acción en notebook. TLC se localiza en `America/New_York`; NOAA se interpreta con `utc=True` y luego usa `tz_convert`. Enero no contiene transición, pero la regla queda explícita.

Error frecuente o límite. Usar `tz_localize` para un instante ya UTC o quitar zona horaria para hacer coincidir etiquetas.

Comprobación. Preguntar por qué NOAA usa conversión y TLC localización: una serie representa instantes UTC; la otra, etiquetas locales ingenuas.

Conclusión que debe quedar. Integrar por hora exige igualdad de instantes y definición de bordes, no parecido textual.

Transición sugerida. “La correspondencia espacial también requiere una regla y metadatos”.

Diapositiva 15. Integración espacial

Correspondencia con el libro. Capítulo 3, integración; capítulo 4, visualización espacial y sus límites.

Propósito. Distinguir unión por identificador y relaciones geométricas.

Guion sugerido. Enumerar ID administrativo, punto en polígono, zona cercana e intersección. Registrar CRS, versión de límites y casos sin zona; advertir sobre centroides.

Conceptos y términos. *Sistema de referencia de coordenadas (CRS), polígono, centroide, intersección espacial.*

Ejemplo o acción en notebook. El taller une viajes por `LocationID`; la extensión lee polígonos y convierte a EPSG:4326 para el mapa Folium.

Error frecuente o límite. Reemplazar cobertura por distancia a centroides o calcular centroides en coordenadas geográficas como medida precisa.

Comprobación. “¿El centroide usado para centrar el mapa redefine la zona?”. No; solo ayuda a la vista y genera una advertencia geométrica posible.

Conclusión que debe quedar. Una relación espacial debe declarar geometría, CRS, versión y casos no asignados.

Transición sugerida. “Después de alinear espacio y tiempo, agregaremos y haremos explícita la pérdida”.

Diapositiva 16. Agregación y pérdida de información

Correspondencia con el libro. Capítulo 3, agregación y transformación; capítulo 4, resúmenes descriptivos.

Propósito. Explicar ganancias y pérdidas al pasar de eventos a grupos.

Guion sugerido. Leer conteo y media por grupo. Ganamos comparabilidad y volumen manejable; perdemos orden intra-grupo, variabilidad individual y reconstrucción de casos. Conservar conteos, dispersión, cobertura y regla.

Conceptos y términos. *Grupo, conteo, media, dispersión, pérdida irreversible.*

Lectura de fórmulas. En $\sum_i \mathbb{1}(G_i=g)$, la indicadora cuenta observaciones del grupo g . En $\bar{x}_g = \frac{1}{n_g} \sum_{i:G_i=g} x_i$, se promedian valores incluidos. Ambas expresiones dependen de reglas de inclusión y no recuperan eventos descartados ni prueban representatividad.

Ejemplo o acción en notebook. `groupby(...).size()` crea `pickups`; NOAA resume medias y suma precipitación con `min_count=1`, conservando `observaciones`.

Error frecuente o límite. Promediar precipitación cuando el significado requiere acumulación o convertir una hora enteramente ausente en cero.

Comprobación. Pedir qué ya no contiene `pickups_zona_hora`: importes, destinos y secuencia de viajes individuales.

Conclusión que debe quedar. Agregar es una decisión semántica con pérdidas documentables.

Transición sugerida. “Para defender esas decisiones, la adquisición y cada transformación deben poder repetirse”.

Diapositiva 17. Reproducibilidad desde la adquisición

Correspondencia con el libro. Capítulo 2, §2.4 sobre reproducibilidad, organización y versionado; capítulo 3, controles documentados.

Propósito. Fijar los elementos que permiten reconstruir una ejecución.

Guion sugerido. Enumerar URL, acceso, periodo, parámetros, versiones, orden, validaciones, exclusiones, esquema, clave y procedencia. Presentar el notebook como registro ejecutable, no como garantía automática.

Conceptos y términos. *Reproducibilidad, parámetro, versión, artefacto, ejecución de inicio a fin.*

Ejemplo o acción en notebook. Mostrar `MODO_CLASE`, fechas, `ZONA_HORARIA`, funciones y aserciones. Pedir registrar fecha y entorno junto al producto.

Error frecuente o límite. Entregar un notebook con celdas fuera de orden o resultados sin código que los genere.

Comprobación. Reiniciar kernel y ejecutar todo; cada variable debe originarse antes de usarse y cada aserción debe pasar.

Conclusión que debe quedar. La reproducibilidad comienza al adquirir, no al guardar el gráfico final.

Transición sugerida. “Apliquemos ahora estas reglas a una pregunta concreta de movilidad y clima”.

Diapositiva 18. Del concepto al taller

Correspondencia con el libro. Capítulos 2-4: formulación, preparación/integración y exploración descriptiva.

Propósito. Conectar el marco conceptual con la pregunta, las fuentes y la meta práctica.

Guion sugerido. Leer la pregunta exacta y el flujo `TLC-zonas-zona-hora-clima`. Aclarar que se construirá una tabla auditada, no un modelo predictivo, y que viajes reportados no equivalen a demanda.

Conceptos y términos. *Tabla analítica auditada, asociación descriptiva, viajes reportados, demanda no observada.*

Descripción visual relevante. El flujo `TLC viajes → zonas + shapefile → zona-hora ← NOAA clima` converge en zona-hora. La flecha desde NOAA indica enriquecimiento temporal; `zonas + shapefile` reúne atributos y geometría, no afirma que todo viaje tenga correspondencia ni que una estación represente cada zona.

Ejemplo o acción en notebook. Mostrar la pregunta guía y anticipar `zona_hora_clima`; pedir una hipótesis descriptiva sin cifras ni causalidad.

Error frecuente o límite. Convertir “asociación con clima” en “efecto del clima” o usar pickups como solicitudes totales.

Comprobación. “¿Entrenaremos un predictor?”. No; construiremos evidencia descriptiva y una tabla reproducible.

Conclusión que debe quedar. El taller prueba preparación e integración bajo límites explícitos.

Transición sugerida. “Definamos formalmente fuentes, unidades originales y contrato del producto”.

Diapositiva 19. Taller 1: fuentes y contrato analítico

Correspondencia con el libro. Capítulo 2, inventario de fuentes; capítulo 3, unidad, clave e integración.

Propósito. Declarar cuatro fuentes, unidades originales y producto antes de cargar.

Guion sugerido. Leer `TLC viajes`, `lookup`, `shapefile` y NOAA. Fijar una fila igual a zona de origen-hora local y clave `PULocationID`, `hora`.

Conceptos y términos. *Contrato analítico, unidad original, clave compuesta, estación-observación.*

Descripción visual relevante. La tabla organiza fuente, archivo/tabla y unidad original; leer por filas y luego contrastar todas con la unidad final inferior. El cambio de unidad ocurre por transformación, no porque los archivos ya compartan granularidad.

Ejemplo o acción en notebook. Revisar “Ficha de fuentes” y completar metadatos. En el código, `pickup_hora` corresponde a `hora` y `pickups_zona_hora` materializa el contrato.

Error frecuente o límite. Confundir zona-ID del `lookup` con una observación de viaje o clima horario con clima zonal.

Comprobación. Pedir la cardinalidad esperada de viajes a zona: many-to-one.

Conclusión que debe quedar. Las fuentes heterogéneas solo se integran después de declarar unidades y clave final.

Transición sugerida. “Hagamos visible el periodo construyendo la URL en lugar de editar texto manualmente”.

Diapositiva 20. Taller 2: construir la URL TLC

Correspondencia con el libro. Capítulo 2, adquisición parametrizada y reproducibilidad.

Propósito. Hacer explícitos tipo de servicio, año y mes.

Guion sugerido. Recorrer el diccionario de prefijos y el formato `anio-mes`. Explicar que parametrizar reduce errores manuales y registra intención.

Conceptos y términos. *Parámetro, plantilla de URL, validación de entrada.*

Ejemplo o acción en notebook. Ejecutar `construir_url_tlc("yellow", 2024, 1)`; destacar que el notebook además valida tipo, rango de año, rango de mes y excluye booleanos.

Error frecuente o límite. Aceptar cualquier texto como tipo o asumir que una URL bien formada garantiza disponibilidad y esquema.

Comprobación. Probar conceptualmente un mes fuera de rango: debe producir `ValueError`, no una URL silenciosa.

Conclusión que debe quedar. Parámetros validados hacen auditable qué recurso se solicitó.

Transición sugerida. “Con la dirección construida, leeremos solo periodo y columnas necesarios”.

Diapositiva 21. Taller 3: cargar Parquet con proyección

Correspondencia con el libro. Capítulo 2, archivos, eficiencia y adquisición; capítulo 3, esquema.

Propósito. Cargar columnas y ventana explícitas sin leer indiscriminadamente.

Guion sugerido. Explicar proyección de columnas y filtro temporal. Parquet conserva tipos y `pyarrow` puede reducir lectura; la fuente sigue siendo secundaria y operativa.

Conceptos y términos. *Parquet, proyección, predicate pushdown/filtro de lectura, fuente secundaria.*

Ejemplo o acción en notebook. Ejecutar `COLUMNAS_VIAJES`, `filtros` y `pd.read_parquet`; observar el total real sin memorizarlo. `MODO_CLASE=True` fija una semana consecutiva.

Error frecuente o límite. Llamar muestra aleatoria a la primera semana o inferir representatividad mensual por menor volumen.

Comprobación. Resolver la pregunta breve: una ventana contigua conserva ciclos y denominador temporal, pero no garantiza representar el mes.

Conclusión que debe quedar. La adquisición eficiente debe preservar significado de selección y periodo.

Transición sugerida. “Antes de imponer reglas, inspeccionemos qué llegó realmente”.

Diapositiva 22. Taller 4: inspeccionar antes de transformar

Correspondencia con el libro. Capítulo 3, perfilado, estructura y diccionario; capítulo 4, exploración inicial.

Propósito. Generar hipótesis sobre esquema, tipos, rangos y faltantes.

Guion sugerido. Revisar forma, primeras filas, `info`, tipos y tabla de faltantes. Preguntar qué representa una fila y qué columnas son IDs, tiempos o medidas.

Conceptos y términos. *Perfilado, esquema, rango observado, hipótesis de calidad.*

Ejemplo o acción en notebook. Ejecutar la sección 3; sustituye `describe(include="all")` de la lámina por un perfil explícito de tipos y ausencias adecuado al taller.

Error frecuente o límite. Convertir valores o eliminar filas durante la misma inspección y perder el estado original.

Comprobación. Pedir una hipótesis y su control: por ejemplo, duración no positiva se prueba calculando diferencia temporal.

Conclusión que debe quedar. Inspección propone preguntas; reglas booleanas las vuelven auditables.

Transición sugerida. “Materialicemos ahora esos controles sin borrar información”.

Diapositiva 23. Taller 5: controles de calidad básicos

Correspondencia con el libro. Capítulo 3, perfiles, faltantes, duplicados y validez.

Propósito. Convertir dimensiones de calidad en métricas y señales verificables.

Guion sugerido. Presentar nulos, aproximación de duplicados y duración. Aclarar que la combinación de clave no es ID oficial y que los resultados dependen de datos/filtros.

Conceptos y términos. *Control de calidad (QC), máscara booleana, clave operativa, duración no positiva.*

Ejemplo o acción en notebook. El notebook amplía la lámina: calcula `duracion_min`, crea columnas `ok_*` y una `auditoria` con cumplen/incumplen.

Error frecuente o límite. Interpretar `duplicados_clave` como número cierto de viajes repetidos o sumar incumplimientos como si fueran filas distintas.

Comprobación. Verificar que cada regla pueda señalarse por separado y que una fila puede incumplir más de una.

Conclusión que debe quedar. Un control útil hace visible su definición y no exagera lo que detecta.

Transición sugerida. “Pasemos de diagnosticar a decidir qué registros cumplen el contrato operativo”.

Diapositiva 24. Taller 6: validez y filtros explícitos

Correspondencia con el libro. Capítulo 3, limpieza, rangos, consistencia y documentación de exclusiones.

Propósito. Aplicar reglas explícitas conservando rechazados y sensibilidad.

Guion sugerido. Explicar cada máscara y sus umbrales como criterios analíticos. Separar válidos y rechazados; no borrar en sitio. Reportar exclusiones por regla desde la ejecución.

Conceptos y términos. *Validez, plausibilidad, umbral, sensibilidad, exclusión documentada.*

Ejemplo o acción en notebook. Ejecutar `registro_valido`, `viajes_rechazados` y `viajes_validos`. Resolver Ejercicio 1 con una máscara de 50 millas sin modificar el producto.

Error frecuente o límite. Llamar falso a todo valor extremo o escoger umbrales después de mirar el resultado deseado.

Comprobación. Confirmar que `viajes_rechazados` conserva filas y columnas `ok_*`; comparar definiciones, no anticipar totales.

Conclusión que debe quedar. Filtrar requiere regla, justificación, conteo y conservación de evidencia excluida.

Transición sugerida. “La pertenencia de los IDs al catálogo se comprobará mediante una unión validada”.

Diapositiva 25. Taller 7: zonas y unión many-to-one

Correspondencia con el libro. Capítulo 3, claves, cardinalidad e integración.

Propósito. Enriquecer pickup y dropoff sin multiplicar viajes.

Guion sugerido. Comprobar unicidad del catálogo, renombrar por rol y unir dos veces con `many_to_one`. Explicar por qué pickup y dropoff no son intercambiables.

Conceptos y términos. *Tabla de referencia, rol de clave, many-to-one, enriquecimiento.*

Ejemplo o acción en notebook. Ejecutar `zonas_pickup`, `zonas_dropoff` y `viajes_zonas`; revisar el `assert` de longitud.

Error frecuente o límite. Unir dos veces sin renombrar y confundir columnas, o no verificar unicidad antes de `merge`.

Comprobación. Si la longitud cambia, detener la clase y diagnosticar cardinalidad; no continuar hacia gráficos.

Conclusión que debe quedar. La misma dimensión puede cumplir roles distintos y cada unión necesita contrato.

Transición sugerida. “Conservar filas no implica que todas hayan encontrado nombre de zona; midamos cobertura”.

Diapositiva 26. Taller 8: cobertura y pérdidas de la unión

Correspondencia con el libro. Capítulo 3, auditoría de integración y faltantes derivados.

Propósito. Separar conservación de filas y cobertura semántica.

Guion sugerido. Una unión izquierda conserva viajes, pero puede dejar atributos nulos. Medir coincidencias/no coincidencias y revisar IDs sin zona.

Conceptos y términos. *Left join, left-only, cobertura semántica, multiplicación.*

Ejemplo o acción en notebook. El notebook mide `sin_nombre_pickup` y `sin_nombre_dropoff`; el `assert` controla filas. Explicar que podría usarse `indicator=True` para la auditoría mostrada en la lámina.

Error frecuente o límite. Concluir cobertura completa solo porque el número de filas no cambió.

Comprobación. Pedir interpretar por separado longitud estable y nombres ausentes; responden a riesgos distintos.

Conclusión que debe quedar. La auditoría de unión requiere cardinalidad y cobertura.

Transición sugerida. “El catálogo aporta nombres; para representar límites necesitamos geometría”.

Diapositiva 27. Taller 9: shapefile y geometría

Correspondencia con el libro. Capítulo 3, integración espacial; capítulo 4, mapas.

Propósito. Incorporar polígonos de zonas como extensión espacial separada del lookup.

Guion sugerido. Distinguir nombres y geometría; convertir `LocationID`, fijar CRS y comprobar unicidad. La geometría no debe sustituirse por centroides para cobertura.

Conceptos y términos. *Shapefile, ZIP, GeoDataFrame, EPSG:4326, mapa coroplético.*

Ejemplo o acción en notebook. Ejecutar la extensión opcional si están `geopandas`, `folium` y `requests`; el ZIP vive en `TemporaryDirectory` y no se añade al repo.

Error frecuente o límite. Hacer obligatoria la extensión cuando faltan dependencias o interpretar el centro visual como ubicación exacta de actividad.

Comprobación. Verificar mensaje explícito si faltan dependencias y, si se ejecuta, unicidad implícita mediante `validate="one_to_one"` al unir conteos.

Conclusión que debe quedar. Geometría y atributos cumplen funciones complementarias y tienen metadatos propios.

Transición sugerida. “Volvamos al eje central: cambiar la unidad desde viaje a zona-hora”.

Diapositiva 28. Taller 10: construir zona-hora

Correspondencia con el libro. Capítulo 3, transformación y agregación; capítulo 4, series y resúmenes.

Propósito. Localizar tiempo, redondear por hora y agregar pickups con clave única.

Guion sugerido. Mostrar localización TLC, `floor("h")` y agrupación. Explicar que una fila nueva resume muchos viajes y elimina detalle individual.

Conceptos y términos. *Localización temporal, hora local, floor, groupby, clave compuesta.*

Ejemplo o acción en notebook. Ejecutar `pickup_hora` y `pickups_zona_hora`; el notebook conserva borough y nombre además de ID, y comprueba duplicados de `pickup_hora`, `PULocationID`.

Error frecuente o límite. Sumar una tabla que ya está agregada como si cada fila siguiera siendo viaje, o localizar dos veces una serie.

Comprobación. La aserción de clave debe pasar; pedir explicar por qué `pickups` es conteo de reportes, no demanda.

Conclusión que debe quedar. La tabla zona-hora tiene nueva unidad, clave y alcance.

Transición sugerida. “Para enriquecer cada hora, primero interpretaremos correctamente el reloj NOAA”.

Diapositiva 29. Taller 11: NOAA e interpretación UTC

Correspondencia con el libro. Capítulos 2 y 3, adquisición, tipos temporales e integración.

Propósito. Cargar clima y convertir instantes UTC a hora local.

Guion sugerido. Leer el PSV, verificar estación, parsear `DATE` con `utc=True` y convertir a Nueva York. Repetir que convertir un instante no es cambiar una etiqueta.

Conceptos y términos. *PSV, estación meteorológica, UTC, tz_convert.*

Ejemplo o acción en notebook. Ejecutar `urlopen`, `clima_bruto`, `fecha_utc` y `fecha_ny`; observar errores de conversión como faltantes mediante `errors="coerce"`.

Error frecuente o límite. Tratar `DATE` como hora local o asumir que una estación representa espacialmente todas las zonas.

Comprobación. Revisar que `fecha_utc` y `fecha_ny` expresan los mismos instantes con zonas distintas.

Conclusión que debe quedar. La semántica temporal debe resolverse antes de agrupar y unir.

Transición sugerida. “Resumamos las observaciones subhorarias con reglas específicas por variable”.

Diapositiva 30. Taller 12: clima horario de enero

Correspondencia con el libro. Capítulo 3, tipos, faltantes y agregación; capítulo 4, resúmenes temporales.

Propósito. Filtrar la ventana local y producir una fila meteorológica por hora.

Guion sugerido. Convertir variables a numéricas, agrupar por hora, usar medias donde corresponde y suma para precipitación con `min_count=1`; conservar número de observaciones.

Conceptos y términos. *Observación subhoraria, agregación variable-específica, cobertura temporal, intervalo semiabierto.*

Ejemplo o acción en notebook. Ejecutar `clima_horario` y resolver Ejercicio 2 comparando `horas_esperadas` con horas observadas.

Error frecuente o límite. Convertir ausencia total de precipitación en cero o suponer frecuencia constante sin consultar documentación NOAA.

Comprobación. Verificar unicidad de `hora` y leer los huecos que realmente arroje la ejecución, sin anticiparlos.

Conclusión que debe quedar. El resumen horario debe conservar regla y cobertura, no solo medias.

Transición sugerida. “Con ambos lados a la misma granularidad temporal, validemos su integración”.

Diapositiva 31. Taller 13: unir zona-hora con clima

Correspondencia con el libro. Capítulo 3, integración, cardinalidad y cobertura.

Propósito. Enriquecer muchas zonas-hora con como máximo una observación climática por hora.

Guion sugerido. Comprobar unicidad climática, unir a izquierda con `many_to_one`, conservar filas y medir `_merge`/faltantes. Explicitar el supuesto espacial de una estación.

Conceptos y términos. *Many-to-one temporal, indicador de unión, representatividad espacial.*

Ejemplo o acción en notebook. Ejecutar `zona_hora_clima` y `auditoria_union`; el notebook elimina `_merge` solo después de mostrar la auditoría.

Error frecuente o límite. Correlacionar directamente la tabla sin recordar que el clima se repite por zona o imputar huecos sin justificarlos.

Comprobación. Confirmar longitud izquierda estable y revisar categorías reales de la auditoría.

Conclusión que debe quedar. La unión es técnicamente many-to-one y conceptualmente depende de un supuesto espacial fuerte.

Transición sugerida. “Leamos ahora el patrón temporal como descripción de reportes”.

Diapositiva 32. Taller 14: perfil horario de viajes reportados

Correspondencia con el libro. Capítulo 4, series, perfiles y visualización descriptiva.

Propósito. Describir variación temporal sin convertirla en demanda o pronóstico.

Guion sugerido. Leer ejes, unidad, ventana y filtros antes del patrón. Comparar serie por hora y mapa de calor día-hora disponibles en el notebook.

Conceptos y términos. *Perfil horario, serie temporal, ciclo diario, mapa de calor.*

Ejemplo o acción en notebook. Ejecutar `viajes_por_hora` y `patron`; describir picos y valles solo según lo visible en la ejecución.

Descripción visual relevante. La línea ordena conteos por hora local; el mapa de calor organiza días en filas y horas en columnas, con color como cantidad. Ninguno muestra solicitudes no atendidas ni controla por oferta.

Error frecuente o límite. Generalizar una semana a todo enero o atribuir un pico a una causa no observada.

Comprobación. Pedir una frase completa: variable, unidad, periodo y carácter descriptivo.

Conclusión que debe quedar. El perfil caracteriza viajes Yellow Taxi reportados dentro de la ventana filtrada.

Transición sugerida. “La dimensión temporal puede complementarse con la distribución espacial”.

Diapositiva 33. Taller 15: mapa por zona

Correspondencia con el libro. Capítulo 4, visualización espacial; capítulo 3, integración geométrica.

Propósito. Comparar conteos por zona conservando cautelas de cobertura y escala.

Guion sugerido. Agregar por `PULocationID`, unir one-to-one con polígonos y representar ausencias. Explicar que conteos mezclan tamaño, actividad, cobertura y registro.

Conceptos y términos. *Coropleta, conteo zonal, geometría sin dato, comparabilidad espacial.*

Ejemplo o acción en notebook. Usar barras `top_zonas` como vista base y Folium como extensión opcional. Leer valores reales del entorno, no una lista fija de zonas.

Descripción visual relevante. En barras, longitud representa pickups y solo aparece el subconjunto superior; en el mapa, color rellena polígonos según conteo y no densidad. Áreas grandes captan más atención visual sin implicar más viajes por superficie.

Error frecuente o límite. Interpretar color como preferencia individual o comparar conteos brutos como tasas.

Comprobación. Preguntar qué denominador faltaría para una tasa: población, superficie, oferta u otro, según la pregunta; ninguno se incorpora automáticamente.

Conclusión que debe quedar. Un mapa de conteos localiza registros, no explica por sí solo su distribución.

Transición sugerida. “Finalmente, exploremos clima y pickups sin saltar de asociación a causalidad”.

Diapositiva 34. Taller 16: clima y asociación descriptiva

Correspondencia con el libro. Capítulo 4, dispersión, correlación, exploración y comunicación de límites.

Propósito. Explorar asociación horaria evitando repetición del clima por zona y lenguaje causal.

Guion sugerido. Volver primero a una fila por hora, sumar pickups y tomar una sola observación climática. Leer dispersión y correlación como asociación lineal condicionada por selección y calendario.

Conceptos y términos. *Diagrama de dispersión, correlación, factor de confusión, unidad horaria.*

Ejemplo o acción en notebook. Ejecutar `comparacion_horaria`, los dos gráficos y la matriz de correlación; resolver Ejercicio 3 con dos observaciones y una explicación alternativa.

Descripción visual relevante. Cada punto representa una hora, no una zona ni un viaje. Los paneles comparan pickups con temperatura y precipitación; cercanía o pendiente aparente no identifica mecanismo causal.

Error frecuente o límite. Calcular correlación sobre clima replicado por zona o afirmar “la lluvia provoca” a partir de puntos observacionales.

Comprobación. Exigir mencionar al menos un confusor: hora, día, aeropuerto, feriado, oferta, eventos o selección.

Conclusión que debe quedar. Correlación resume asociación en la ventana; no demuestra causalidad ni transportabilidad.

Transición sugerida. “Guardemos el producto junto con la información necesaria para reconstruirlo”.

Diapositiva 35. Taller 17: guardar un producto reproducible

Correspondencia con el libro. Capítulo 2, organización, metadatos y versionado; capítulo 3, producto preparado.

Propósito. Materializar tabla ordenada, clave única y metadatos mínimos.

Guion sugerido. Ordenar por hora e ID, comprobar clave, exportar Parquet y registrar unidad, zona horaria y fuentes. Adjuntar controles, exclusiones, versiones y fecha.

Conceptos y términos. *Artefacto reproducible, metadatos, esquema, clave única, fecha de ejecución.*

Ejemplo o acción en notebook. Adaptar la lámina a nombres reales: ordenar `zona_hora_clima` por `pickup_hora`, `PULocationID`, comprobar no duplicidad y exportar al directorio temporal. Verificar que el nombre indique `primera_semana_enero_2024` con `MODO_CLASE=True` o `enero_2024` en modo completo.

Error frecuente o límite. Escribir el dataset generado dentro del repositorio, omitir el modo de ejecución o guardar una tabla con resultados de celdas fuera de orden.

Comprobación. Recargar el Parquet desde su ubicación externa y comprobar esquema, clave y rango temporal contra los parámetros, sin exigir un conteo fijo.

Conclusión que debe quedar. Un archivo solo es producto reproducible si viaja con contrato, controles y procedencia.

Transición sugerida. “Reunamos ahora los artefactos que demostrarán el aprendizaje”.

Diapositiva 36. Producto y evidencia de aprendizaje

Correspondencia con el libro. Capítulo 2, productos y reproducibilidad; capítulo 3, auditoría; capítulo 4, evidencia visual.

Propósito. Definir un entregable verificable y defendible.

Guion sugerido. Recorrer inventario, regla de fila, diccionario, controles, tabla, visualizaciones, cinco hallazgos y tres límites. Aplicar la rúbrica de esta guía y exigir ejecución ordenada.

Conceptos y términos. *Entregable, evidencia de aprendizaje, diccionario semántico, hallazgo con evidencia.*

Ejemplo o acción en notebook. Entregar el notebook ejecutado de inicio a fin y el Parquet fuera del repo o como descarga separada. Los hallazgos deben citar tabla/gráfico y ventana real.

Descripción visual relevante. La composición es una lista de seis evidencias complementarias; no es una secuencia ni permite sustituir auditoría por gráficos. La tabla y el notebook sostienen los hallazgos, mientras los límites acotan su lectura.

Error frecuente o límite. Entregar capturas sin código, cinco opiniones sin evidencia o un mapa como sustituto de controles de cardinalidad.

Comprobación. Seleccionar una fila del producto y reconstruir fuentes, filtros, uniones y agregación que la originaron.

Conclusión que debe quedar. El aprendizaje se demuestra mediante trazabilidad, controles e interpretación, no por una cifra particular.

Transición sugerida. “Antes de cerrar, fijemos qué afirmaciones permite y cuáles prohíbe este diseño”.

Diapositiva 37. Límites y afirmaciones permitidas

Correspondencia con el libro. Capítulo 2, alcance y riesgo; capítulo 3, cobertura; capítulo 4, interpretación descriptiva.

Propósito. Restringir conclusiones a población, periodo, fuentes y diseño observacional.

Guion sugerido. Afirmar únicamente descripción de viajes reportados y asociaciones en la cobertura analizada. Negar demanda total, generalización universal, causalidad, clima zonal idéntico y exactitud individual garantizada.

Conceptos y términos. *Alcance, cobertura, validez descriptiva, causalidad, representatividad.*

Ejemplo o acción en notebook. Revisar “Conclusiones y límites”; añadir explícitamente el alcance de `MOD0_CLASE` usado y cualquier hueco observado de NOAA o zona.

Error frecuente o límite. Redactar el límite como fórmula vacía después de una conclusión exagerada, o usar “podría causar” para insinuar causalidad no identificada.

Comprobación. Reformular “la lluvia reduce/aumenta la demanda” como “en las horas observadas, pickups reportados y precipitación muestran la asociación visible, confundida por...”. La dirección se completa solo desde el resultado real.

Conclusión que debe quedar. Los límites forman parte de la evidencia y determinan el lenguaje permitido.

Transición sugerida. “Cerramos reconstruyendo las seis decisiones que convierten datos disponibles en evidencia defendible”.

Diapositiva 38. Cierre: de datos disponibles a evidencia defendible

Correspondencia con el libro. Síntesis de capítulos 2, 3 y 4.

Propósito. Consolidar formulación, representación, calidad, integración, agregación y reproducibilidad.

Guion sugerido. Recuperar las seis ideas en el orden de la lámina: propósito/producto; fuente/unidad/fila; tipos/faltantes/duplicados; claves/cardinalidad/cobertura; tiempo/espacio/agregación; pérdidas/límites/cadena reproducible. Conectar cada una con un objeto del notebook.

Conceptos y términos. No introducir vocabulario nuevo; integrar contrato, procedencia, calidad apta, cardinalidad, granularidad y límites.

Ejemplo o acción en notebook. Cerrar con la pregunta final: qué dato permitiría distinguir mejor demanda, oferta y viajes realizados. Aceptar propuestas justificadas por unidad, disponibilidad y procedencia.

Descripción visual relevante. La lista numerada es una secuencia de controles acumulativos, no una receta rígida. La línea final enlaza capítulos 2-4 y anticipa exploración estadística sin ampliar lo que representan los datos.

Error frecuente o límite. Terminar mostrando solo gráficos o presentar preparación como fase acabada que ya no requiere revisión.

Comprobación. Pedir a cada estudiante una decisión del flujo, su comprobación y el límite que permanece.

Conclusión que debe quedar. La evidencia defendible conserva significado, controles, pérdidas, procedencia y alcance desde la adquisición hasta el producto.

Transición sugerida. “La próxima etapa profundizará la exploración estadística sin exceder la representación construida hoy”.

Referencias

- [../.../Libro/Capitulo_02_Ciclo_de_vida_de_un_proyecto_de_datos.md](#)
- [../.../Libro/Capitulo_03_Preparacion_calidad_y_transformacion_de_datos.md](#)
- [../.../Libro/Capitulo_04_Estadistica_descriptiva_exploracion_y_visualizacion.md](#)
- [Clase_02_Adquisicion_comprension_y_preparacion_inicial_de_datos.md](#)
- [Taller_Clase_02_Movilidad.ipynb](#)