

Exploración, diagnóstico y visualización de datos

De una tabla analítica a hallazgos defendibles

Tabla analítica

Vistas y
resúmenes

Controles

Hallazgo
defendible

Curso de Data Science

Semana 3 · Clase 3

Diagnóstico descriptivo: no identificación causal.

Propósito y resultados

Propósito: explorar una tabla analítica mediante preguntas coordinadas sobre representación, distribución, relación y cobertura.


Al finalizar, podremos

- ▶ delimitar población, unidad, estimando y denominador;
- ▶ describir posición, dispersión, forma y extremos;
- ▶ elegir gráficos según la comparación requerida;
- ▶ estudiar asociaciones y estratos sin convertirlos en causas;
- ▶ redactar hallazgos trazables, limitados y comprobables.

Clase teórica y conceptual: sin programación ni resultados empíricos.

Continuidad semanas 1–3

Semana	Pregunta central	Producto
1. Formulación	¿Qué necesidad, población y decisión importan?	problema analítico
2. Preparación	¿Qué representa cada fila y cómo se construyó?	tabla analítica defendible
3. Exploración	¿Cómo se distribuyen y relacionan los registros?	hallazgos limitados



Explorar audita decisiones previas; no autoriza redefinirlas para obtener un patrón atractivo.

Alcance del cronograma

Bloque conceptual	Diapositivas
Contrato y fundamentos	1–10
Descripción univariada	11–19
Codificación visual	20–25
Relaciones	26–34
Tiempo, espacio y multivariado	35–37
Hallazgos y cierre	38–40

Fuera del alcance de hoy

Pruebas confirmatorias, identificación causal, predicción y despliegue. La práctica se realizará después en un notebook que todavía no forma parte de esta entrega.

Pregunta de apertura

Caso transversal

Tenemos una tabla **zona-hora** con pickups reportados, atributos de zona y clima de una estación: ¿qué miraríamos primero y qué podríamos afirmar?

Dimensión	Pregunta inicial
Representación	¿Qué significa una fila y qué quedó fuera?
Distribución	¿Qué valores, frecuencias, ceros y faltantes existen?
Relación	¿Qué variables varían juntas y bajo qué estratos?
Límite	¿A qué población y periodo alcanza la evidencia?

TLC: viajes realizados/reportados, **no demanda total**. NOAA: una estación, **no clima zonal**.

Qué es y qué no es EDA

El **análisis exploratorio de datos (EDA)** combina revisión semántica, controles de calidad, resúmenes y visualizaciones complementarias.

EDA sí

- examina distribuciones y cobertura
- contrasta representaciones
- localiza casos que requieren explicación
- genera hipótesis y controles


EDA no

- repara automáticamente los datos
- confirma historias descubiertas al mirar
- sustituye inferencia o diseño causal
- garantiza representatividad

Límite

Diagnóstico exploratorio es comprensión provisional, no un veredicto causal.

Ciclo exploratorio




Iteración disciplinada

Cada cambio responde a evidencia y deja trazados filtros, transformaciones, descartes y explicaciones alternativas.

Población, muestra y población registrada

Concepto	Delimitación
Población objetivo	unidades sobre las que interesa afirmar
Muestra observada	subconjunto obtenido por un mecanismo de selección
Población registrada	eventos materializados por el sistema en el alcance



Cobertura

Un archivo completo de TLC aún excluye solicitudes no atendidas, otros operadores y viajes no reportados. Más filas no corrigen esa frontera.

Unidad, estimando, ponderación y denominador

El **estimando** es la cantidad precisa que se desea describir. Cambia si cada zona, zona-hora o viaje reportado recibe el mismo peso.

$$\hat{p} = \frac{n_A}{n_{\text{val}}}$$

Frase profesional

Este estadístico describe _____ para _____ durante _____, dando a cada _____ un peso de _____ y usando como denominador _____.

Cada zona pesa igual

Cada viaje reportado pesa igual

Una tasa de pickups por hora observada describe registros y exposición temporal, no demanda total.

Tipos semánticos y preguntas válidas

Tipo	Operaciones conceptualmente válidas	Ejemplo del caso
Nominal	igualdad, conteo, agrupación	ID de zona
Ordinal	igualdad y orden	categoría ordenada
Intervalo	diferencias	temperatura Celsius
Razón	diferencias y razones	conteo de pickups
Temporal	orden, intervalo, ciclo	hora local
Espacial	ubicación, vecindad, área	zona de origen

Principio

La semántica, no el tipo físico, gobierna el resumen y el gráfico.

Un ID numérico no tiene una media significativa; una hora codificada como entero sigue teniendo dependencia cíclica.

Distribuciones de frecuencia


Para una categoría o intervalo j :

$$f_j = \sum_{i=1}^n \mathbb{I}(x_i \in j), \quad h_j = \frac{f_j}{n_{\text{val}}}, \quad H_j = \sum_{k \leq j} h_k$$

Medida	Lectura
f_j	frecuencia absoluta
$h_j / 100h_j$	frecuencia relativa / porcentaje
H_j	frecuencia acumulada, solo si existe orden

La distribución debe informar válidos, faltantes, exclusiones y denominador.

Cero, faltante y ausencia de fila



Situación	Pregunta de control
Cero	¿se observó realmente ausencia del evento?
Faltante	¿falló medición, unión o disponibilidad?
Sin fila	¿el marco debía contener esa unidad?

NOAA faltante no equivale a precipitación cero.

Media, mediana y moda

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Centro	Interpretación	Sensibilidad
Media	punto de balance de magnitudes	alta ante extremos
Mediana	posición que divide datos ordenados	menor ante extremos
Moda	valor o categoría más frecuente	depende de resolución

Lectura conjunta

Para pickups por zona-hora, cada centro responde una pregunta diferente dentro de los viajes realizados/reportados. Ninguno describe por sí solo colas o cobertura.

Cuantiles y percentiles

$$Q(p) = \inf\{x : F(x) \geq p\}, \quad 0 < p < 1$$



- ▶ $Q_1 = Q(0.25)$, mediana = $Q(0.50)$ y $Q_3 = Q(0.75)$.
- ▶ Un P90 describe una posición en la población y periodo declarados, no la probabilidad del próximo caso.
- ▶ Las convenciones muestrales pueden interpolar de modo distinto.

Rango, varianza y desviación estándar

$$R = x_{\text{máx}} - x_{\text{mín}}$$

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}$$

- ▶ El rango usa solo extremos; la varianza queda en unidades al cuadrado.
- ▶ La desviación estándar recupera la unidad original.
- ▶ N describe una población finita; $n - 1$ corrige sesgo muestral bajo supuestos.

Condición

La regla 68–95 requiere una forma aproximadamente normal; no es universal.

IQR, MAD y robustez

$$IQR = Q_3 - Q_1, \quad MAD = \text{mediana}_i |x_i - \text{mediana}(x)|$$


Medida robusta	Qué resume
IQR	extensión del 50 % central
MAD	distancia absoluta típica respecto de la mediana

Son menos sensibles a extremos que rango, varianza y desviación estándar.

Robustez $\neq$ representatividad

Mediana e IQR no recuperan viajes no registrados ni corrigen faltantes sistemáticos.

Asimetría, colas y multimodalidad



Rasgo	Pregunta que abre
Asimetría / cola	¿qué lado concentra extremos, censura o mezcla?
Multimodalidad	¿coexisten grupos, ciclos o resoluciones?
Acumulación	¿hay redondeo, umbral o saturación?

Una segunda moda genera hipótesis; no prueba una causa.

Atípico no equivale a error

La regla de Tukey marca valores fuera de:

$$[Q_1 - 1.5\ IQR,\ Q_3 + 1.5\ IQR]$$

Caso señalado	Acción responsable
plausible y relevante	conservar y contextualizar
compatible pero influyente	evaluar sensibilidad
incompatible con unidad o dominio	revisar captura y transformación
significado desconocido	investigar antes de decidir

Una zona-hora extrema puede ser aeropuerto, evento o error de agregación. La distancia estadística no justifica eliminarla.

Perfil estadístico coherente

Componente	Control mínimo	Componente	Control mínimo
Contrato	población, unidad, periodo, estimando	Cobertura	válidos, faltantes, ceros, filas ausentes
Distribución	frecuencias y forma	Posición	centro y cuantiles
Dispersión	clásica y robusta	Extremos	plausibilidad e influencia
Sensibilidad	filtros, resolución, denominador	Conclusión	afirmación permitida y límite

Coherencia interna

Todas las piezas comparten reglas de inclusión o declaran sus diferencias. Un perfil no es una colección de cifras desconectadas.

Cobertura y unidad gobiernan todo el perfil.

Visualización como codificación



Marcas

Puntos, líneas y áreas.

Canales

Posición, longitud, color, forma y tamaño.

Decisiones

Escala, agregación, orden, denominador y exclusiones.

Un gráfico decide qué comparación será fácil y qué quedará menos visible.

Posición, longitud, área y color

Canal	Precisión comparativa	Uso apropiado
Posición común	alta	diferencias y orden
Longitud	alta a media	magnitudes desde una base
Área	media a baja	tamaño aproximado
Color	media a baja	patrón, categoría o intensidad

- ▶ Paleta secuencial: magnitud; divergente: distancia a un centro significativo; cualitativa: categorías.
- ▶ El faltante necesita apariencia propia.
- ▶ El área debe ser proporcional al dato, no su radio.

La codificación debe apoyar la tarea sin exagerar diferencias.


Matriz de selección de gráficos

Objetivo	Vistas posibles	Control principal
Comparar magnitudes	puntos, barras	base y orden
Mostrar distribución	histograma, caja, violín	resolución y tamaño
Relacionar variables	dispersión, tabla	unidad conjunta
Mostrar tiempo	línea, mapa día-hora	orden, huecos y frecuencia
Mostrar composición	barras apiladas	denominador y volumen
Mostrar espacio	mapa	medida, cobertura y proyección

Criterio

La pregunta y la tarea perceptiva determinan la vista, no el nombre de la variable. Una tabla es preferible si se necesitan valores exactos.

Histogramas, intervalos y densidad



- ▶ Anchura, origen y límites de bins alteran la apariencia.
- ▶ Con intervalos desiguales, el **área** representa proporción.
- ▶ La densidad depende del ancho de banda; grupos comparados requieren límites y escalas comunes.


No elegir la resolución que produzca la historia más llamativa.

Caja y violín

Vista	Aporta
Caja	mediana, cuartiles, IQR, bigotes y puntos externos
Violín	forma y modos aproximados

Caja: depende de la convención de bigotes.

Violín: depende del suavizado y ancho de banda.



Comparación responsable

Conservar periodo, unidad, reglas, escala y tamaño de cada grupo. Estas vistas describen diferencias; no las prueban ni convierten puntos externos en errores.

Barras, conteos, proporciones y tasas

$$\text{proporción} = \frac{\text{casos de interés}}{\text{total definido}}, \quad \text{tasa} = \frac{\text{eventos}}{\text{exposición}}$$

Cantidad	Pregunta
Conteo	¿cuántos eventos registrados?
Proporción	¿qué parte del total declarado?
Tasa	¿cuántos por unidad de exposición?

Caso

Pickups por zona son conteos; pickups por hora observada son una tasa descriptiva. Ninguno equivale a demanda total sin otro mecanismo y denominador.

Las barras de magnitud suelen comenzar en cero.

Secuencia para estudiar relaciones



Candado 1

Forma, escala y pares válidos antes del coeficiente.

Candado 2

Estratos, dependencia y alternativas antes del hallazgo.

Para relacionar NOAA con pickups, una vista horaria evita repetir una observación de estación entre zonas como si fueran observaciones independientes.

Tablas de contingencia

	Categoría B1	Categoría B2	Total de fila
Categoría A1	n_{11}	n_{12}	$n_{1.}$
Categoría A2	n_{21}	n_{22}	$n_{2.}$
Total de columna	$n_{.1}$	$n_{.2}$	n

- ▶ Cada celda contiene un conteo conjunto; los márgenes describen volumen.
- ▶ Bajo independencia, el esperado conceptual es

$$e_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}.$$

- ▶ Los conteos no establecen comparabilidad: primero debe elegirse el condicionamiento.

Proporciones condicionadas

$$P(B_j | A_i) \approx \frac{n_{ij}}{n_{i.}}, \quad P(A_i | B_j) \approx \frac{n_{ij}}{n_{.j}}$$

Normalización	Suma 100 % dentro de	Pregunta
Por fila	cada fila	¿cómo se distribuye B entre unidades A?
Por columna	cada columna	¿cómo se distribuye A entre unidades B?

El sentido importa

“Proporción de zona-horas de volumen alto dentro de cada franja” no equivale a su frase inversa.

Nombrar siempre **dentro de qué** se calcula y mostrar el tamaño del grupo.

Comparación numérica entre grupos

Control común	Pregunta
Unidad	¿cada observación representa lo mismo?
Periodo y marco	¿hubo oportunidades comparables?
Inclusión	¿ceros y faltantes siguen la misma regla?
Cobertura y tamaño	¿cuántas unidades válidas aporta cada grupo?
Distribución	¿cómo cambian centro, dispersión, forma y colas?




Segmentar aquí es comparar estratos reproducibles, no hacer clustering formal.

Diagrama de dispersión

Cada punto necesita una unidad explícita. Observar:

- ▶ rango y dirección;
- ▶ curvatura y límites;
- ▶ grupos y heterogeneidad;
- ▶ sobreposición y densidad;
- ▶ casos influyentes.



En el caso transversal, un punto podría ser una **hora** con pickups agregados y una observación NOAA, no una zona-hora con clima replicado.

Covarianza y correlación

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad r = \frac{s_{xy}}{s_x s_y}, \quad -1 \leq r \leq 1$$

Medida	Resume	Escala
Covarianza	variación lineal conjunta	producto de unidades
Pearson	asociación lineal estandarizada	sin unidades
Spearman / Kendall	asociación de orden monotónica	rangos u orden

No sustituye la forma

Correlación cero no implica independencia. Ningún coeficiente demuestra causalidad ni reemplaza la nube, la unidad y los estratos.

Trampas de correlación

Trampa	Qué puede ocultar
No linealidad	dependencia fuerte con r cercano a cero
Punto influyente	coeficiente dominado por un caso
Rango restringido	relación atenuada por selección
Mezcla de grupos	patrón global distinto de patrones internos
Pseudorreplicación	tamaño aparente mayor que la información independiente
Multiplicidad	asociaciones casuales entre muchas búsquedas


Caso NOAA

Replicar una observación de estación en todas las zonas no crea nuevas observaciones meteorológicas.

Elegir el coeficiente que mejor respalda una historia es una decisión exploratoria sesgada.

Asociación, causalidad, confusión y Simpson

Concepto	Afirmación permitida
Asociación	la conjunta no factoriza como producto de marginales
Causalidad	una intervención cambiaría un resultado bajo diseño y supuestos
Confusión	una causa común previa puede distorsionar la asociación
Simpson	el patrón agregado cambia o se invierte dentro de estratos



Lenguaje no autorizado

“La lluvia causa más demanda”. Sí puede estudiarse la coincidencia entre precipitación de estación y pickups reportados, considerando hora, día, oferta, cobertura y alternativas.

Asociarse con X e Y no basta para clasificar Z como confusor.

Segmentación y estratificación

Segmentar

Describir subconjuntos sustantivos.

Estratificar

Comparar una distribución o relación dentro de niveles de una tercera variable.

Estrato útil

relevante para el dominio
definido de forma reproducible
tamaño y cobertura visibles
escalas comunes

Riesgo a controlar


partición oportunista
regla modificada después de mirar
celdas escasas
exageración visual

Franja, borough o tipo de zona son estratos posibles. Estratificar revela heterogeneidad; no identifica causas ni implica clustering.

Exploración temporal

Declarar:

- ▶ evento temporal y zona horaria;
- ▶ intervalo y regularidad;
- ▶ huecos y cobertura;
- ▶ ciclos y calendario;
- ▶ cambios de definición o captura.




Límites


Una serie TLC describe viajes reportados; NOAA describe una estación. Temporal no significa pronóstico y precedencia no demuestra causa.

Exploración espacial


Vista espacial	Uso	Control
Coropleta	tasa o proporción por área	denominador y cortes
Símbolos o puntos	localización y magnitud	sobreposición y privacidad
Mapa de cobertura	presencia, ausencia y calidad	cero distinto de sin dato



Conteo



Tasa



Cobertura

Interpretación

El mapa TLC localiza pickups realizados/reportados, no demanda total. Una estación NOAA no se vuelve clima de cada zona. Un mapa describe dónde aparece una medida; no explica por qué.

Exploración multivariada y riesgo exploratorio

Matrices de pares, mapas de calor y facetas pueden revelar redundancia, grupos y casos extraños en combinación.

Decisión	Control necesario
Elegir variables	justificación sustantiva
Estandarizar	escala común no implica igual importancia
Filtrar y facetar	registrar el universo de decisiones
Seleccionar patrón	conservar resultados discordantes y alternativas



Cuantas más variables, filtros y cortes se prueben, mayor transparencia se necesita ante hallazgos casuales.

Anatomía de un hallazgo defendible

Campo	Contenido
Contrato	pregunta, población, unidad y periodo
Observación	patrón y magnitud obtenidos de evidencia
Soporte	tabla o figura trazable
Cobertura	válidos, faltantes, exclusiones y denominador
Interpretación	lenguaje proporcional al diseño
Defensa	alternativa, sensibilidad, límite y siguiente control

Plantilla sin resultado

“En [periodo y unidades], los pickups TLC realizados/reportados muestran [patrón por completar], bajo [cobertura]. Coincide con [variable], pero puede reflejar [alternativas]. NOAA representa una estación, no clima zonal”.

Usar “se observa” o “se asocia”, no “produce” o “causa”.

Contrato de cinco hallazgos y continuidad

El **futuro notebook**, aún no creado ni incluido, materializará cinco hallazgos complementarios:

Hallazgo requerido	Pregunta que deberá resolver
1. Distribución univariada	¿cómo se distribuye una variable bajo cobertura declarada?
2. Comparación de grupos	¿qué cambia entre estratos comparables?
3. Relación entre variables	¿qué asociación aparece y qué alternativas existen?
4. Patrón temporal	¿qué orden, ciclos, huecos o cambios se observan, sin pronosticar?
5. Patrón espacial o multivariado	¿qué heterogeneidad aparece con medida y denominador explícitos?

Contrato reproducible

Cada hallazgo incluirá contrato, evidencia, cobertura, ceros/faltantes, extremos, sensibilidad, límite y próximo paso. No hay resultados predeterminados.

Síntesis y lecturas

- 1 Población no es archivo; estimando, peso y denominador fijan la pregunta.
- 2 Cero, faltante y ausencia de fila son estados diferentes.
- 3 Distribución, forma y cobertura preceden a cualquier resumen.
- 4 Robustez no corrige sesgo; atípico no equivale a error.
- 5 Un gráfico es una codificación y un coeficiente no reemplaza la forma.
- 6 Asociación no implica causalidad; el diagnóstico genera hipótesis.
- 7 Estratos, tiempo y espacio describen estructura, no explicación automática.
- 8 Todo hallazgo necesita alcance, alternativas, sensibilidad y próxima comprobación.

Lectura principal

Capítulo 4, *Estadística descriptiva, exploración y visualización*, del libro *Ciencia de Datos e Inteligencia Artificial*.
Como continuidad, revisar los capítulos 2 y 3.

Explorar responsablemente es describir con precisión, comparar con honestidad y mantener visibles los límites.