

Probabilidad, incertidumbre y decisiones

De una muestra observada a una acción defendible

Muestra

Estimación

Incertidumbre

Decisión

La muestra aporta evidencia parcial; la estimación resume lo observado; la incertidumbre reconoce lo que puede variar; la decisión incorpora consecuencias.

Curso de Data Science

Semana 4 · Clase 4

De los hallazgos a las decisiones

En la Semana 3 aprendimos a describir distribuciones y asociaciones. Ahora preguntaremos cuánto podemos generalizar y cómo actuar cuando el resultado todavía es incierto.

Etapas	Preguntas	Productos
Explorar	¿Qué patrón aparece?	Hallazgo descriptivo
Estimar	¿Qué cantidad desconocida aproximamos?	Estimación
Cuantificar	¿Cuánto podría cambiar?	Medida de incertidumbre
Decidir	¿Qué acción conviene?	Regla explícita

Las etapas se conectan, pero no son equivalentes: observar un patrón no determina automáticamente una acción.

Propósito y resultados de aprendizaje

Propósito: comprender cómo la probabilidad representa incertidumbre y cómo una decisión agrega objetivos, costos y restricciones a la evidencia disponible.


Al finalizar, podremos

- ▶ definir población, muestra, parámetro y estimación;
- ▶ calcular probabilidades marginales, conjuntas y condicionales;
- ▶ interpretar independencia y actualización bayesiana;
- ▶ reconocer variabilidad muestral y evaluar estabilidad;
- ▶ distinguir descripción, predicción y prescripción;
- ▶ comparar acciones mediante consecuencias esperadas.

La clase desarrolla razonamiento conceptual y ejemplos numéricos breves; no entrena todavía un modelo predictivo.

Continuidad de las semanas 1 a 4

Semana	Pregunta central	Producto
1. Formulación	¿Qué necesidad y decisión importan?	Problema analítico
2. Preparación	¿Qué representa cada fila?	Tabla defendible
3. Exploración	¿Qué patrones aparecen?	Hallazgos limitados
4. Incertidumbre	¿Qué puede variar y cómo decidimos?	Regla de decisión



Los retornos indican que una estimación inestable puede exigir más datos y que una decisión inviable puede obligar a reformular la pregunta.

Pregunta de apertura: ¿qué tan probable es?

Caso transversal

Una organización dispone de muestras históricas de calidad del agua y solo puede revisar algunos sitios. Desea priorizar aquellos con mayor posibilidad de detectar coliformes.

Antes de responder necesita precisar:

- ▶ qué evento contará como detección y qué población desea representar;
- ▶ qué evidencia estaba disponible antes de decidir;
- ▶ qué costo tiene revisar y qué costo tiene omitir;
- ▶ cuántas revisiones puede realizar.

Describir no es predecir


Afirmación	Tipo	Referencia
“El 3 % de las muestras registradas tuvo detección”	Descriptiva	Datos observados
“Una nueva muestra tiene 3 % de probabilidad de detección”	Predictiva	Caso no observado
“Conviene revisar este sitio”	Prescriptiva	Acción y consecuencias

La primera frase resume un archivo; la segunda generaliza bajo supuestos; la tercera agrega una comparación entre acciones.

El cambio de verbo revela un cambio de pregunta: frecuencia observada, incertidumbre futura y elección no son sinónimos.

Población, muestra y unidad de análisis

- ▶ **Población objetivo:** conjunto sobre el cual interesa afirmar o decidir.
- ▶ **Muestra:** subconjunto observado mediante un mecanismo de selección.
- ▶ **Unidad de análisis:** objeto representado por cada observación utilizada.
- ▶ **Población registrada:** eventos capturados por el sistema en el alcance declarado.



Las inclusiones representan reducciones conceptuales: cada frontera puede excluir unidades y modificar qué generalizaciones son razonables.

En el caso del agua, una fila es una muestra en un sitio, fecha y hora; no representa automáticamente a todos los hogares.

Parámetro, estadístico y estimación

Un **parámetro** es una cantidad fija pero desconocida de la población. Un **estadístico** es una función de los datos y puede usarse como estimación:

$$\hat{p} = \frac{x}{n}$$


donde x es el número de detecciones válidas y n el total de muestras válidas.

Objeto	Se refiere a	Estado
p	Población definida	Desconocido
$\hat{p}$	Muestra observada	Calculable

Usamos el estadístico como estimación del parámetro; la igualdad entre ambos no está garantizada.

¿Por qué cambia una estimación?

Si repitiéramos el muestreo, las unidades seleccionadas y los resultados podrían ser diferentes, aun cuando la población permanezca estable.




Las ramas representan repeticiones hipotéticas del mismo diseño. La dispersión entre resultados expresa variabilidad muestral, no un error de programación.

Cuanto menor sea la muestra o más raro sea el evento, más visibles pueden ser esas diferencias relativas.

Sesgo y variabilidad: dos problemas distintos

Propiedad	Pregunta	Ejemplo
Sesgo	¿El procedimiento apunta sistemáticamente fuera del objetivo?	Solo se visitan sitios accesibles
Variabilidad	¿Cuánto cambia el resultado entre muestras?	Hay pocos resultados por sitio



Baja variabilidad, alto sesgo



Bajo sesgo, alta variabilidad

La posición media representa sesgo; la separación entre puntos representa variabilidad. Son dimensiones diferentes.

Advertencia crítica

Una muestra enorme puede producir una cifra muy estable y, al mismo tiempo, estar sistemáticamente sesgada.

Cobertura, selección y representatividad

La **cobertura** indica qué parte de la población pudo entrar en el registro. La **selección** describe cómo unas unidades terminaron observadas y otras no.

Mecanismo	Posible efecto
Horarios operativos limitados	Algunas franjas quedan subrepresentadas
Remuestreo tras una detección	Los positivos reciben más observaciones
Sitios de acceso sencillo	Cambia la composición espacial
Valores inválidos excluidos	Quedan menos casos válidos y la proporción puede cambiar

Excluir un registro no solo reduce el denominador. Si los inválidos se concentran en ciertos sitios, periodos o condiciones, la proporción calculada también puede quedar sesgada.

La representatividad depende del proceso que produjo los datos, no únicamente del número de filas disponibles.

Tipos de muestreo

Diseño	Regla básica ampliada
Aleatorio simple	Construir un marco completo y sortear n unidades; cada conjunto posible de tamaño n debe tener la misma probabilidad de selección.
Estratificado	Dividir la población en grupos exhaustivos y mutuamente excluyentes; sortear dentro de cada grupo y combinar los resultados respetando sus pesos.


En ambos diseños la selección se realiza al azar y parte de un marco definido. La diferencia es que el aleatorio simple realiza un único sorteo sobre toda la población, mientras que el estratificado realiza sorteos separados para asegurar representación de cada grupo.

El diseño no consiste en tomar filas al azar de una tabla ya disponible: define las probabilidades de inclusión y las ponderaciones necesarias para representar la población.

Muestreo aleatorio simple

En un muestreo aleatorio simple de tamaño n , cada conjunto posible de n unidades tiene la misma probabilidad de ser elegido.

- 1 definir un marco con todas las unidades elegibles;
- 2 aplicar una selección aleatoria reproducible;
- 3 observar las unidades seleccionadas;
- 4 registrar no respuesta o imposibilidad de medición.



El marco es anterior al sorteo: si una unidad no figura en él, la aleatoriedad no corrige esa ausencia.

Muestreo estratificado

La población se divide en estratos mutuamente excluyentes, como sitio, estación o tipo de muestra, y se seleccionan unidades dentro de cada uno.



La separación asegura presencia de grupos; la combinación recupera sus pesos poblacionales cuando las fracciones de muestreo difieren. Puede mejorar precisión si los estratos son internamente homogéneos y facilita comparaciones con tamaños suficientes.

La muestra como proceso de medición

Una fila observada es el resultado de varias etapas, no una lectura neutral de la realidad.




Cada bloque puede excluir unidades o alterar valores. Las flechas describen cómo se produce la evidencia que finalmente analizamos.

Etapa	Pregunta concreta
Selección	¿Por qué se observó esta unidad?
Medición	¿Qué instrumento y límite se usaron?
Registro	¿Cómo se codificaron censura y faltantes?
Validación	¿Qué reglas determinaron un resultado válido?

Evento, resultado y espacio muestral

Un **experimento aleatorio** produce uno de varios resultados posibles. El **espacio muestral** Ω los reúne y un **evento** es un subconjunto.

$$\Omega = \{\text{no detectado, detectado, resultado inválido}\}$$



El rectángulo contiene todos los resultados previstos; la región D agrupa solo aquellos que cumplen la definición del evento.
Definir el evento antes de contar evita modificarlo para acomodar los datos obtenidos.

Probabilidad como proporción de largo plazo

Si un procedimiento se repitiera en condiciones comparables, la frecuencia relativa puede aproximarse a una probabilidad:

$$P(D) \approx \frac{\text{detecciones válidas}}{\text{muestras válidas}}$$

Valor	Lectura
0	Evento imposible bajo el modelo
entre 0 y 1	Distintos grados de posibilidad
1	Evento seguro bajo el modelo


La probabilidad se interpreta dentro de un modelo, una población y una información definidos; no es una propiedad aislada de una etiqueta.

Probabilidad marginal y complemento

La probabilidad **marginal** considera un evento sin fijar otra condición. Su complemento reúne los resultados en los que no ocurre:

$$P(D^c) = 1 - P(D)$$

Si $P(D) = 0,04$, entonces $P(D^c) = 0,96$.




Las dos regiones no se superponen y cubren todos los resultados posibles; aumentar una reduce necesariamente la otra.
La categoría “inválido” debe resolverse en el universo antes de tratar “no detectado” como complemento de “detectado”.

Probabilidad conjunta

La intersección $A \cap B$ contiene resultados donde ocurren ambos eventos. Ejemplo: A = verano y B = detección.

Cantidad	Pregunta
$P(A)$	¿Qué proporción pertenece al verano?
$P(B)$	¿Qué proporción presenta detección?
$P(A \cap B)$	¿Qué proporción cumple ambas?



La zona superpuesta representa casos compartidos; no expresa todavía una probabilidad condicionada.

Probabilidad condicional

La probabilidad condicional restringe el universo a los casos donde ocurrió B :

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Para $P(D \mid V)$, primero conservamos las muestras de verano V y luego calculamos qué proporción tuvo detección D .



La barra vertical se lee “dado que”: modifica el denominador y, por tanto, la pregunta respondida.

Independencia y asociación

Dos eventos son independientes cuando conocer uno no cambia la probabilidad del otro:

$$P(A \mid B) = P(A) \quad \Longleftrightarrow \quad P(A \cap B) = P(A)P(B)$$

Para estudiar si la detección D se relaciona con el verano V , comparamos la proporción de detecciones entre todas las muestras, $P(D)$, con la proporción únicamente entre las muestras de verano, $P(D \mid V)$.

Si ambas probabilidades son iguales, saber que una muestra pertenece al verano no modifica la probabilidad de detección. En datos muestrales esperamos valores aproximados: una diferencia pequeña puede deberse a variabilidad del muestreo.

Si $P(D \mid V)$ se aparta claramente de $P(D)$, la probabilidad cambia al restringirnos al verano. Esto indica asociación dentro de la población y el periodo definidos.

La independencia es una propiedad de la distribución conjunta definida; no significa que las variables carezcan de toda relación física o causal.

Un error frecuente: invertir la condición

$$P(\text{alerta} \mid \text{detección}) \neq P(\text{detección} \mid \text{alerta})$$

Expresión	Pregunta
$P(A \mid D)$	Entre las detecciones, ¿cuántas generan alerta?
$P(D \mid A)$	Entre las alertas, ¿cuántas son detecciones?

Cambiar el orden cambia el grupo usado como denominador; por eso las probabilidades no son intercambiables.

Advertencia crítica

Una alerta sensible puede aparecer en casi todas las detecciones y aun así producir muchas falsas alarmas cuando la detección es rara.

Estimaciones y tamaño de muestra

Una estimación basada en pocos casos suele cambiar más entre muestras que otra basada en muchos casos comparables.

Sitio	Detecciones	Muestras	Proporción observada
A	1	2	50 %
B	40	100	40 %

La proporción de A es mayor, pero está sostenida por solo dos observaciones. Una observación adicional podría modificarla drásticamente.


La proporción comunica la estimación puntual; el denominador comunica cuánta evidencia la sostiene. Ambas piezas deben leerse juntas.

Variabilidad muestral de una proporción

Bajo ensayos aproximadamente independientes con probabilidad constante:

$$SE(\hat{p}) \approx \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

El error estándar disminuye con n , pero lo hace con su raíz cuadrada: cuadruplicar la muestra reduce aproximadamente a la mitad esta variabilidad.



Las curvas representan tamaños pequeño, medio y grande: su ancho muestra cuánto cambiaría la estimación entre repeticiones comparables.

Variabilidad muestral de una media

Para observaciones independientes con dispersión finita:

$$SE(\bar{x}) \approx \frac{s}{\sqrt{n}}$$

Componente	Significado
s	Cuánto difieren las observaciones entre sí
n	Cuántas observaciones independientes sostienen la media
$SE(\bar{x})$	Cuánto variaría la media entre muestras


La desviación estándar describe datos individuales; el error estándar describe la estabilidad del estimador.

Si varias mediciones pertenecen al mismo sitio o episodio, el número de filas puede exagerar la información independiente.

Bootstrap: evaluar estabilidad

El **bootstrap** aproxima la variabilidad de un estadístico mediante remuestreo con reemplazo.

- 1 tomar una remuestra del mismo tamaño;
- 2 calcular el estadístico de interés;
- 3 repetir muchas veces;
- 4 estudiar la distribución de resultados.




Cada remuestra reutiliza filas y omite otras; la colección aproxima cómo cambiaría el resultado bajo el esquema elegido.

El remuestreo debe respetar grupos, tiempo o dependencia cuando la estructura lo requiera.

Precisión no es ausencia de sesgo

Un intervalo estrecho expresa poca variabilidad bajo un procedimiento; no demuestra que el procedimiento esté centrado en la cantidad correcta.



El ancho de la curva representa precisión y el desplazamiento representa sesgo. Más datos reducen el ancho, no el desplazamiento.

Advertencia crítica

Aumentar el tamaño de una muestra mal seleccionada puede aumentar la confianza aparente en una respuesta equivocada.

Del análisis descriptivo al predictivo


Dimensión	Descriptivo	Predictivo
Objetivo	Resumir casos observados	Estimar casos no observados
Referencia	Archivo y periodo analizados	Población y horizonte futuros
Validación	Coherencia y cobertura	Desempeño fuera del ajuste
Salida	Tabla, gráfico o estadístico	Valor, clase o probabilidad



El patrón se construye con el pasado y se aplica a una unidad no usada para producir esa predicción; la evaluación debe imitar ese uso.

Del análisis predictivo al prescriptivo

Una predicción estima qué podría ocurrir. Una prescripción compara qué conviene hacer frente a esa incertidumbre.



La probabilidad resume creencias sobre estados; el bloque de decisión agrega valores y límites operativos para elegir una acción.
Dos organizaciones pueden usar la misma probabilidad y elegir acciones distintas si enfrentan costos, capacidades o responsabilidades diferentes.

Estados inciertos y acciones posibles

- ▶ **Estados:** condiciones desconocidas al decidir.
- ▶ **Acciones:** alternativas bajo control del decisor.
- ▶ **Consecuencias:** resultados de combinar una acción con un estado.
- ▶ **Información:** evidencia disponible antes de elegir.

	Detección	No detección
Revisar	Detección atendida	Revisión innecesaria
No revisar	Omisión	Recurso conservado

Las filas son acciones controlables y las columnas estados inciertos; cada celda describe una consecuencia.

Costos de aciertos y errores

Cuando decidimos revisar o no un sitio, el resultado puede ser acertado o equivocado. Revisar una muestra que efectivamente presenta detección es un acierto, pero revisar una muestra sin detección consume un recurso que pudo destinarse a otro caso.

No revisar una muestra sin detección es otro acierto, mientras que no revisar una detección real implica una demora o una omisión con consecuencias posibles.

Los costos de estos resultados no son todos iguales. Pueden representar dinero, tiempo, riesgo, equidad y capacidad perdida para atender otros casos.


Un falso positivo y un falso negativo pueden ocurrir con la misma frecuencia y aun así tener importancias muy distintas. Conviene valorar cada error por separado.

Matriz de decisión

Supongamos estos costos didácticos:

Acción	Detección	No detección
Revisar	2	2
No revisar	20	0

Revisar cuesta 2 unidades cualquiera sea el estado. No revisar cuesta 20 si existía una detección y 0 en caso contrario.



La probabilidad pondera cada consecuencia; la suma permite comparar acciones en una unidad común.

Valor esperado de una acción

Para una acción a , estados s y evidencia E :

$$EC(a) = \sum_s P(s | E)C(a, s)$$

Si $P(D | E) = 0,15$:

$$EC(\text{revisar}) = 2$$

$$EC(\text{no revisar}) = 0,15(20) + 0,85(0) = 3$$

Resultado

Con estos supuestos, revisar tiene menor costo esperado.

El cálculo no predice qué ocurrirá en un caso concreto; compara consecuencias promedio bajo probabilidades y costos explícitos.