

Diseño experimental de Machine Learning

Cómo formular, evaluar y comparar modelos de manera confiable

Problema

Tarea

Partición

Evaluación

Evidencia

Un resultado es confiable cuando el experimento representa el uso futuro y evita información indebida.

Curso de Data Science

Semana 5 · Clase 5

De la incertidumbre al aprendizaje

En la Semana 4 estudiamos estimaciones, variabilidad y decisiones. Ahora usaremos datos históricos para construir una función que produzca estimaciones en casos nuevos.

Antes	Ahora
Estimar una proporción o una media	Aprender una relación entre variables
Cuantificar variabilidad muestral	Medir desempeño fuera del ajuste
Comparar acciones y costos	Elegir métricas vinculadas con esos costos

Continuidad

Una métrica también es una estimación obtenida sobre una muestra y bajo supuestos determinados.

Propósito y resultados de aprendizaje

Propósito: diseñar una evaluación de Machine Learning que produzca evidencia relevante, reproducible y libre de fuga de información.

Al finalizar, podremos

- ▶ distinguir paradigma, tarea, modelo, predicción y decisión;
- ▶ formular clasificación, regresión, clustering y series temporales;
- ▶ elegir particiones coherentes con la población de uso;
- ▶ establecer baselines y métricas pertinentes;
- ▶ aplicar validación cruzada sin contaminar la evaluación;
- ▶ reconocer subajuste, sobreajuste y comparaciones injustas;
- ▶ documentar un protocolo experimental reproducible.

Pregunta de apertura

Una organización desea anticipar problemas de calidad del agua para priorizar inspecciones.

- ▶ ¿Qué debe predecirse exactamente?
- ▶ ¿Qué información estará disponible al predecir?
- ▶ ¿Se evaluarán nuevas mediciones, nuevos sitios o meses futuros?
- ▶ ¿Qué error tiene mayor costo?
- ▶ ¿Cómo sabremos que un modelo mejora la práctica actual?

Idea

Antes de elegir un algoritmo debemos definir qué evidencia demostraría que su resultado es útil fuera de los datos usados para construirlo.

¿Qué significa aprender de los datos?

Aprender es ajustar una función a partir de ejemplos:

$$f : \mathcal{X} \rightarrow \mathcal{Y}, \quad \hat{y} = f(x).$$

- ▶ x : variables disponibles para un caso.
- ▶ y : resultado real que se desea estimar.
- ▶ $\hat{y}$: predicción producida por el modelo.
- ▶ El ajuste utiliza casos históricos.
- ▶ La evaluación debe usar casos que no participaron del ajuste.

Resultado

Memorizar el pasado no demuestra que el modelo generalice.

Paradigma, tarea y algoritmo

Nivel	Pregunta	Ejemplo
Paradigma	¿De dónde proviene la señal de aprendizaje?	supervisado o no supervisado
Tarea	¿Qué salida necesitamos?	clase, valor, grupo o pronóstico
Algoritmo	¿Qué procedimiento ajustará la relación?	regresión, árbol o K-means

Una misma tarea admite varios algoritmos y un algoritmo puede resolver tareas diferentes.

Elegir “un árbol” no define todavía la población, la etiqueta, la partición ni la métrica.

Aprendizaje supervisado

El conjunto de entrenamiento contiene pares con respuesta conocida:

$$\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}.$$

- ▶ La respuesta y guía el ajuste.
- ▶ En **clasificación**, y representa una categoría.
- ▶ En **regresión**, y representa una cantidad.
- ▶ El desempeño se mide comparando $\hat{y}$ con respuestas reservadas.

Ejemplo

Variables fisicoquímicas y antecedentes permiten estimar si una futura medición excederá un límite.

Aprendizaje no supervisado y semisupervisado

No supervisado: trabaja con entradas x sin una respuesta objetivo conocida.

- ▶ Busca estructura, similitudes o representaciones.
- ▶ El clustering agrupa sitios con perfiles semejantes.
- ▶ Los grupos requieren interpretación y validación.

Semisupervisado: combina pocos casos etiquetados con muchos casos sin etiqueta.

- ▶ Puede ser útil cuando medir es barato y confirmar el resultado es costoso.
- ▶ La evaluación final sigue necesitando etiquetas confiables.

Cuatro tareas de análisis

Tarea	Salida	Pregunta de evaluación
Clasificación	categoría o probabilidad	¿detecta correctamente las clases?
Regresión	valor numérico	¿cuánto se aleja del valor real?
Clustering	grupo o pertenencia	¿los grupos son estables e interpretables?
Serie temporal	valor futuro	¿supera un pronóstico ingenuo respetando el tiempo?

Control

La codificación numérica de una categoría no la convierte en regresión.

Un dominio, cuatro formulaciones

Con datos de calidad del agua podemos formular problemas distintos:

Necesidad	Tarea	Objetivo
Activar una inspección	clasificación	excede/no excede un límite
Estimar concentración	regresión	concentración en mg/L
Comparar perfiles de sitios	clustering	agrupación por similitud
Anticipar el próximo mes	serie temporal	concentración futura

Resultado

Cada formulación cambia la unidad, la salida, la partición y el criterio de evaluación.

Definición del problema predictivo

Antes de modelar debemos establecer:

- 1 decisión o uso de la predicción;
- 2 unidad de análisis y población objetivo;
- 3 instante en que se predice y horizonte del resultado;
- 4 variables disponibles;
- 5 objetivo y fuente de confirmación;
- 6 criterio de evaluación.

Pregunta de control

¿Qué cambiará operativamente cuando el modelo produzca una predicción?

Unidad, población y muestra

- ▶ **Unidad:** entidad sobre la que se produce una predicción; por ejemplo, (sitio, fecha).
- ▶ **Población objetivo:** conjunto de unidades donde se pretende utilizar el modelo.
- ▶ **Muestra histórica:** unidades observadas disponibles para ajustar y evaluar.

Dependencia

La misma estación en dos fechas produce dos filas, pero esas filas pueden estar relacionadas.

Consecuencia

El número de filas no siempre coincide con el número de unidades independientes.

Instante y horizonte

- ▶ t_0 : instante en que debe emitirse la predicción.
- ▶ Ventana de observación: información disponible hasta t_0 .
- ▶ Horizonte H : periodo futuro donde se define el resultado.
- ▶ Confirmación: momento en que la etiqueta puede conocerse.



Cambiar t_0 o H cambia el problema, aunque las columnas tengan los mismos nombres.

Generalización

Generalizar es mantener un desempeño útil en casos nuevos de la población objetivo.

$$R(f) = \mathbb{E}_{(X,Y) \sim P_{\text{uso}}} [L(Y, f(X))].$$

La evaluación aproxima ese error esperado con datos no utilizados para ajustar el procedimiento.

- ▶ Casos representativos del uso esperado.
- ▶ Separación compatible con tiempo y entidades.
- ▶ Métrica alineada con el error relevante.

Alcance

El resultado vale para el escenario evaluado, no para cualquier población futura.

Entrenamiento, validación y prueba

Partición	Uso permitido
Entrenamiento	ajustar parámetros y transformaciones
Validación	elegir variables, configuración y umbral
Prueba	medir una vez el procedimiento congelado

Control

Consultar repetidamente la prueba y modificar el procedimiento convierte la prueba en validación.

Los porcentajes 60/20/20 u 80/10/10 son opciones, no reglas universales.

Partición aleatoria y estratificada

- ▶ **Aleatoria:** asigna unidades al azar.
- ▶ **Estratificada:** conserva aproximadamente la proporción de clases.
- ▶ Son adecuadas cuando las unidades pueden tratarse como intercambiables e independientes.
- ▶ La estratificación estabiliza la medición de clases poco frecuentes.

Limitación

Ninguna evita que mediciones del mismo sitio o del mismo episodio aparezcan a ambos lados.

Partición por grupos

Todos los registros de un grupo permanecen en una sola partición.

Ejemplo

Sitios A–F → entrenamiento | G–H → validación | I–J → prueba.

- ▶ Grupo posible: sitio, sensor, paciente, cliente, vehículo o evento.
- ▶ Evita compartir patrones propios de una entidad.
- ▶ Evalúa transferencia hacia grupos no observados.

Pregunta: ¿el uso real predice nuevas fechas de sitios conocidos o sitios completamente nuevos?

Partición temporal

El pasado entrena y el futuro evalúa:

Orden

enero–junio: entrenamiento → julio–agosto: validación → septiembre: prueba.

- ▶ Respetar el orden causal y simular un despliegue prospectivo.
- ▶ Revela cambios de estación, sensores o procesos.
- ▶ Cada transformación se ajusta solo con datos anteriores al periodo evaluado.

Riesgo

Barajar observaciones temporales puede permitir que el futuro ayude a predecir el pasado.

¿Qué partición reproduce el uso real?

La prueba debe parecerse a los casos que recibirá el modelo después del despliegue.

Cómo llegará el caso nuevo	Partición recomendada
otra fila independiente de la misma población	aleatoria o estratificada
una fecha posterior de un grupo conocido	temporal dentro de cada grupo
un sitio, paciente o vehículo nunca visto	por grupos
un periodo futuro	temporal
un grupo nuevo en un periodo futuro	combinación de grupos y tiempo

Pregunta guía

Cuando el modelo se use, ¿deberá predecir otra fila, una fecha futura o una entidad nueva?

Regla: la partición de prueba debe imitar esa situación.

Fuga de información

Existe **fuga** cuando el ajuste o la evaluación utilizan información que no estaría disponible al producir una predicción real.

- ▶ Produce resultados demasiado optimistas.
- ▶ Puede aparecer en variables, particiones o transformaciones.
- ▶ También ocurre cuando unidades relacionadas cruzan la frontera experimental.

Prueba operativa

Para cada variable registrar quién la genera, cuándo existe y qué datos intervinieron en su cálculo.

Tres fugas frecuentes

Tipo	Ejemplo	Control
Temporal Entidad Preprocesamiento	usar la medición que confirma el evento mismo sitio en entrenamiento y prueba imputar con la media de todos los datos	cortar variables en t_0 separar por grupo ajustar solo con entrenamiento

Resultado

Eliminar una columna sospechosa no basta: toda la frontera experimental debe preservar la separación.

Imputación: separar antes de calcular

Queremos predecir alertas de calidad del agua usando la turbidez.

Conjunto	Turbidez
Entrenamiento, datos pasados	[2, 4, NA, 6]
Prueba, periodo futuro	[20]

Correcto: separar primero

$\bar{x}_{train} = (2 + 4 + 6)/3 = 4$.
El faltante se completa con 4.

Problema: el valor futuro de prueba modifica los datos con los que aprende el modelo.

Regla: separar primero; ajustar el imputador solo con entrenamiento y aplicarlo después a validación y prueba.

Contaminado: calcular antes

$\bar{x}_{todo} = (2 + 4 + 6 + 20)/4 = 8$.
El faltante se completa con 8.

Duplicados y selección de atributos

Duplicados o casos relacionados: copias, ventanas solapadas o mediciones del mismo episodio pueden inflar la muestra y aparecer en particiones distintas.

Selección de atributos: elegir variables mediante correlaciones, rankings o desempeño también aprende de los datos.

- ▶ Los duplicados relacionados deben permanecer juntos.
- ▶ La selección basada en datos debe realizarse dentro de entrenamiento o de cada fold.
- ▶ La prueba no interviene en ninguna selección.

Ejemplo: el mismo evento a ambos lados

La muestra M-104 se exportó dos veces y las copias terminaron en particiones distintas:

Registro	Partición	Sitio y hora	Turbidez	Alerta
M-104	entrenamiento	A, 10:00	18	sí
M-104-copia	prueba	A, 10:00	18	sí

Problema

El modelo puede reconocer un evento ya observado. Un acierto sobre la copia no demuestra que generalice a una muestra nueva.

Control

Identificar duplicados o agrupar por evento antes de particionar; todas las versiones del mismo episodio deben permanecer juntas.

Selección contaminada: la prueba elige la variable

El equipo compara modelos de una sola variable. Resultados ilustrativos:

Variable utilizada	Accuracy en validación	Accuracy en prueba
pH	70 %	68 %
turbidez	62 %	91 %
temperatura	66 %	65 %

Correcto

Elegir pH por validación, congelar la elección y consultar la prueba una sola vez.

¿Qué ocurrió? La prueba decidió qué variable conservar: pasó a funcionar como validación y el 91 % dejó de ser una evaluación independiente.

Regla: con muchas variables, alguna puede sobresalir en prueba por azar. La selección se realiza con entrenamiento y validación, nunca con prueba.

Contaminado

Elegir turbidez por su 91 % en prueba y publicar ese mismo valor como evaluación final.

Baseline: referencia mínima

Un baseline es una referencia simple, reproducible y disponible con la misma información que el modelo.

- ▶ Determina qué mejora debe justificar la complejidad.
- ▶ Detecta errores del pipeline y métricas mal interpretadas.
- ▶ Puede ser una regla operativa existente, no solo una constante.
- ▶ Debe evaluarse en exactamente los mismos casos.

Resultado

Superar un baseline débil no demuestra utilidad; la referencia debe ser pertinente.

Baselines por tipo de tarea

Tarea	Baseline posible
Clasificación	clase mayoritaria o frecuencia histórica
Regresión	media o mediana del entrenamiento
Serie temporal	último valor o mismo periodo anterior
Clustering	partición trivial y estabilidad frente a remuestreo

Referencia operativa

En calidad del agua también puede compararse contra la regla de inspección vigente.

Ejemplo: accuracy engañosa

En 100 mediciones hay 20 excedencias y 80 casos normales. El baseline siempre predice “normal”.

	Excedencia real	Normal real
Predice excedencia	VP = 0	FP = 0
Predice normal	FN = 20	VN = 80

$\text{accuracy} = 80/100 = 80 \%$, $\text{recall} = 0/20 = 0 \%$.

Lectura

Tiene accuracy alta, pero no detecta ninguna excedencia.

Matriz de confusión

	Real positiva	Real negativa
Predicción positiva	verdadero positivo (VP)	falso positivo (FP)
Predicción negativa	falso negativo (FN)	verdadero negativo (VN)

- ▶ VP y VN son aciertos respecto de la clase definida como positiva.
- ▶ FP es una falsa alarma; FN es un positivo omitido.
- ▶ La clase positiva debe declararse antes de interpretar las métricas.

Métricas de clasificación

Supongamos $VP = 16$, $FP = 8$, $FN = 4$ y $VN = 72$:

$$\text{accuracy} = \frac{16 + 72}{100} = 0,88,$$

$$\text{Prec} = \frac{16}{16 + 8} = 0,67, \quad \text{recall} = \frac{16}{16 + 4} = 0,80,$$

$$F_1 = \frac{2VP}{2VP + FP + FN} = \frac{32}{44} = 0,73.$$

Resultado

Cada métrica responde una pregunta diferente.

Métrica, prevalencia y costo

- ▶ **Accuracy:** fracción total de aciertos; puede ocultar una clase rara.
- ▶ **Precisión:** de las alertas emitidas, cuántas eran correctas.
- ▶ **Recall:** de los eventos reales, cuántos se detectaron.
- ▶ F_1 : equilibra precisión y recall, pero no incorpora verdaderos negativos.

Si omitir una excedencia es más costoso que realizar una inspección innecesaria, recall merece especial atención.

Control

Ninguna métrica sustituye la declaración de costos y capacidad operativa.

Métricas de regresión

Para errores $e_i = y_i - \hat{y}_i$:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |e_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}.$$

- ▶ Ambas conservan la unidad de y .
- ▶ MAE pondera linealmente la magnitud del error.
- ▶ RMSE penaliza más los errores grandes.
- ▶ La elección depende de las consecuencias de los errores extremos.

Ejemplo numérico: MAE y RMSE

Valores reales: [10, 12, 18, 20]. Predicciones: [11, 10, 17, 26].

Errores absolutos: [1, 2, 1, 6].

$$\text{MAE} = \frac{1 + 2 + 1 + 6}{4} = 2,5.$$

$$\text{RMSE} = \sqrt{\frac{1^2 + 2^2 + 1^2 + 6^2}{4}} = \sqrt{10,5} \approx 3,24.$$

Lectura

RMSE aumenta más por el error de 6 unidades.

R^2 y sus límites

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

- ▶ Compara el error del modelo con predecir la media.
- ▶ Puede ser negativo fuera de muestra.
- ▶ No conserva la unidad del objetivo.
- ▶ Un valor alto no garantiza errores operativamente pequeños.
- ▶ En series con tendencia puede resultar engañoso.

Recomendación

Informar R^2 junto con MAE o RMSE y un baseline pertinente.

Evaluar clustering

Sin etiquetas objetivo no existe una accuracy predictiva convencional.

- ▶ **Cohesión:** observaciones próximas dentro de cada grupo.
- ▶ **Separación:** grupos alejados entre sí.
- ▶ **Silhouette:** combina cohesión y separación en una escala aproximada de -1 a 1 .
- ▶ **Estabilidad:** grupos similares ante remuestreo o cambios razonables.
- ▶ **Utilidad:** perfiles interpretables que apoyan una decisión.

Control

Un valor interno alto no demuestra que los grupos sean relevantes para el dominio.

Evaluar series temporales

- ▶ Entrenar con pasado y validar sobre periodos posteriores.
- ▶ Comparar contra persistencia y estacionalidad simple.
- ▶ Medir varios orígenes y horizontes, no un único corte conveniente.
- ▶ Ajustar transformaciones nuevamente en cada ventana.

Ventana expansiva

enero-marzo → abril | enero-abril → mayo | enero-mayo → junio.

El promedio resume desempeño; la variación entre periodos revela estabilidad temporal.

Validación cruzada

En K-fold, el conjunto de desarrollo se divide en K bloques. Cada bloque actúa una vez como validación:

$$\bar{m} = \frac{1}{K} \sum_{k=1}^K m_k.$$

- ▶ Estratificada para conservar clases.
- ▶ Por grupos para mantener entidades juntas.
- ▶ Temporal con ventanas ordenadas.
- ▶ La prueba final permanece fuera del ciclo.

Resultado

Reportar promedio y dispersión entre folds evita depender de una única partición favorable.

El pipeline se ajusta dentro de cada fold


En cada iteración:

- 1 ajustar imputación, escalado y codificación con los folds de entrenamiento;
- 2 seleccionar atributos usando solo esos folds;
- 3 transformar entrenamiento y validación;
- 4 ajustar el modelo;
- 5 medir sobre el fold reservado.



El objeto evaluado es el procedimiento completo, no solo el algoritmo final.

Curvas de pérdida: subajuste y sobreajuste



Subajuste

Ambas pérdidas son altas: el modelo todavía no aprendió suficiente.

Mejor punto

La pérdida de validación alcanza su mínimo; allí conviene conservar el modelo.

Sobreajuste

Entrenamiento sigue mejorando, pero validación deja de hacerlo y la separación aumenta.

Criterio: la selección se realiza con validación. La prueba permanece fuera de esta decisión.

Actividad: protocolo experimental

Cada equipo definirá, antes de entrenar:

Sección	Evidencia mínima
Problema	unidad, población, t_0 , horizonte, x e y
Partición	entrenamiento, validación y prueba justificadas
Controles	riesgos de fuga y cómo se comprobarán
Referencia	baseline reproducible
Evaluación	métrica principal, auxiliares y costo relevante
Reproducción	versión de datos, semilla y reglas congeladas

Hito

Otro equipo debe poder reconstruir y auditar la evaluación propuesta.

Síntesis y próximo paso

Flujo: definición → tarea → partición → baseline → pipeline → validación → prueba.

- ▶ La tarea determina la salida, no el algoritmo.
- ▶ La partición debe representar qué significa un caso nuevo.
- ▶ La fuga invalida la evidencia de generalización.
- ▶ Cada tarea necesita baselines y métricas pertinentes.
- ▶ La validación evalúa todo el procedimiento.
- ▶ La prueba mide una vez una configuración congelada.

Próximo paso

Implementar transformaciones y atributos ajustados únicamente con entrenamiento.