

GUÍA DE EJERCICIOS

Diseño experimental de Machine Learning

Formulación, evaluación y comparación confiable de modelos

Curso: Data Science

Alcance: clasificación, regresión y clustering.

Extensión opcional: evaluación de transferencia mediante particiones por isla y por año.

Conjunto de datos común: Palmer Penguins.

Entorno de trabajo: Jupyter Notebook con Python.

Modalidad sugerida: resolución individual, discusión en pequeños grupos y entrega individual verificable.

Índice

Propósitos de aprendizaje	2
Datos y entorno de trabajo	2
Conjunto Palmer Penguins	2
Escenario de uso y criterio de partición establecidos	2
Protocolo temprano para reservar la prueba	3
Entorno de trabajo obligatorio	3
Estructura del notebook único	4
Reglas experimentales comunes	5
Producto de entrega	5
Bloque A. Formulación del problema	6
Ejercicio 1. Paradigma, tarea, algoritmo, predicción y decisión	6
Ejercicio 2. Tres formulaciones sobre el mismo conjunto de datos	6
Bloque B. Auditoría y partición de los datos	7
Ejercicio 3. Auditoría estructural y reserva temprana de la prueba	7
Ejercicio 4. Papeles de desarrollo, validación y prueba	9
Bloque C. Fuga de información y pipelines	10
Ejercicio 5. Detectives de fuga de información	10
Ejercicio 6. Imputación y escalado: procedimiento incorrecto y procedimiento válido	11
Bloque D. Baselines y métricas	12
Ejercicio 7. Baselines pertinentes	12
Ejercicio 8. Matriz de confusión y métricas de clasificación	12
Ejercicio 9. Métricas de regresión	14
Ejercicio 10. Evaluación de clustering	15
Bloque E. Validación cruzada y comparación de modelos	16
Ejercicio 11. Validación cruzada del procedimiento completo	16
Ejercicio 12. Subajuste, equilibrio y sobreajuste	17
Ejercicio 13. Evaluación final sobre la prueba reservada	17
Extensión opcional: transferencia entre contextos	18

Propósitos de aprendizaje

Al completar la guía, el estudiante deberá ser capaz de:

1. Distinguir paradigma, tarea, algoritmo, modelo, predicción y decisión.
2. Formular problemas de clasificación, regresión y clustering a partir de un mismo dominio.
3. Definir unidad de análisis, población objetivo, muestra, variables predictoras y resultado esperado.
4. Relacionar escenarios de uso con criterios de partición adecuados.
5. Separar correctamente entrenamiento, validación y prueba.
6. Reconocer fugas de información producidas por variables, entidades, duplicados o transformaciones.
7. Construir baselines pertinentes para cada tarea.
8. Seleccionar métricas compatibles con el objetivo y los costos de error.
9. Aplicar validación cruzada preservando la independencia de la evaluación.
10. Comparar modelos en condiciones justas y reconocer subajuste y sobreajuste.
11. Documentar un protocolo experimental reproducible y auditable.

Datos y entorno de trabajo

Conjunto Palmer Penguins

El conjunto contiene observaciones de 344 pingüinos pertenecientes a tres especies y registrados en tres islas del archipiélago Palmer, en la Antártida.

Descarga directa en CSV:

<https://raw.githubusercontent.com/allisonhorst/palmerpenguins/master/inst/extdata/penguins.csv>

Documentación:

<https://allisonhorst.github.io/palmerpenguins/>

Licencia: CC0.

Variable	Tipo	Descripción
species	Categórica	Especie: Adelie, Chinstrap o Gentoo
island	Categórica	Isla de observación
bill_length_mm	Númerica	Longitud del pico en milímetros
bill_depth_mm	Númerica	Profundidad del pico en milímetros
flipper_length_mm	Númerica	Longitud de la aleta en milímetros
body_mass_g	Númerica	Masa corporal en gramos
sex	Categórica	Sexo registrado
year	Categórica u ordinal	Año de observación

Escenario de uso y criterio de partición establecidos

La tarea principal consiste en clasificar la especie de nuevos pingüinos pertenecientes a la misma población de referencia que representa el conjunto Palmer Penguins: individuos observados bajo el mismo procedimiento general, en las islas Biscoe, Dream y Torgersen y en los años incluidos en los datos. Cada fila representa un pingüino diferente y la predicción se realiza a partir de sus características registradas. El resultado estimará el desempeño esperado sobre nuevos individuos de ese mismo contexto.

La fuente utilizada carece de un identificador explícito del animal y su documentación describe una observación por individuo. La versión indicada contiene cero filas idénticas; la auditoría verificará este resultado y tratará cada fila como una unidad distinta. Este escenario permite considerar las filas intercambiables y establece una partición aleatoria estratificada por **species**: 80 % para desarrollo y 20 % para prueba.

Protocolo temprano para reservar la prueba

Después de descargar y conservar una copia inalterada, se realizará una auditoría estructural mínima sobre el archivo completo: dimensiones, nombres, tipos, disponibilidad del objetivo, identificadores, orden temporal y posibles relaciones entre filas. Los análisis sustantivos —asociaciones con el objetivo, rankings de variables, imputaciones, escalas y resultados de modelos— comenzarán sobre el conjunto de desarrollo después de la separación.

Antes de iniciar el análisis exploratorio se deberá:

1. verificar que cada fila represente un pingüino diferente mediante la documentación y el conteo de filas idénticas;
2. registrar como unidad de análisis al pingüino individual y como caso nuevo a otro individuo de la misma población de referencia;
3. aplicar una partición aleatoria estratificada por `species`;
4. reservar la prueba, registrar semilla e índices y conservar el resto como conjunto de desarrollo;
5. continuar la exploración, selección y ajuste sobre el conjunto de desarrollo.

El porcentaje establecido responde al tamaño del conjunto, la cantidad de casos por especie y el escenario de uso definido para esta guía. En otros problemas, esas características pueden conducir a una partición diferente.

```
import pandas as pd
from sklearn.model_selection import train_test_split

RANDOM_STATE = 42
DATA_URL = (
    "https://raw.githubusercontent.com/allisonhorst/"
    "palmerpenguins/master/inst/extdata/penguins.csv"
)

datos = pd.read_csv(DATA_URL)
datos_originales = datos.copy(deep=True)

idx_desarrollo, idx_prueba = train_test_split(
    datos.index,
    test_size=0.20,
    stratify=datos["species"],
    random_state=RANDOM_STATE
)

desarrollo = datos.loc[idx_desarrollo].copy()
prueba = datos.loc[idx_prueba].copy()

# Guardar los indices permite reconstruir exactamente la separacion.
pd.Series(idx_desarrollo, name="indice").to_csv("indices_desarrollo.csv", index=False)
pd.Series(idx_prueba, name="indice").to_csv("indices_prueba.csv", index=False)
```

La prueba se utilizará una sola vez, después de fijar variables, preprocesamiento, modelo, hiperparámetros y métricas. La semilla registrada se conservará durante todo el experimento. Un eventual hallazgo que cambie el escenario de uso se documentará como inicio de un nuevo ciclo experimental con una nueva muestra de evaluación.

Entorno de trabajo obligatorio

Todos los ejercicios se resolverán en un único notebook de Jupyter con Python.

Bibliotecas principales:

- `pandas` para carga, inspección y transformación de datos;
- `numpy` para operaciones numéricas;
- `matplotlib` y `seaborn` para visualización;
- `scikit-learn` para particiones, pipelines, modelos, validación y métricas.

Cuando sea necesario preparar las dependencias del entorno, puede utilizarse una celda inicial como:

```
%pip install pandas numpy matplotlib seaborn scikit-learn
```

Una vez preparado el entorno, la celda de instalación se conservará comentada o se marcará como configuración inicial.

Estructura del notebook único

El archivo `.ipynb` reunirá todos los ejercicios y deberá organizarse mediante celdas Markdown y celdas de código en este orden:

1. **Portada y metadatos:** título del práctico, estudiante, fecha y versión.
2. **Índice del notebook:** bloques y ejercicios incluidos, con enlaces internos a sus encabezados Markdown.
3. **Entorno:** importaciones, versiones de bibliotecas y semilla.
4. **Carga y auditoría inicial:** fuente, fecha de descarga, copia original y revisión estructural.
5. **Protocolo experimental común:** unidad de análisis, escenario de uso, variables, partición y funciones de desarrollo, validación y prueba.
6. **Resolución de los ejercicios:** bloques y ejercicios en el orden de la guía. Cada ejercicio tendrá un encabezado Markdown e integrará su objetivo o pregunta, desarrollo, resultados, interpretación, evidencia solicitada y conclusión.
7. **Evaluación final:** configuración congelada, ejecución del ejercicio 13 y resultados sobre la prueba reservada.
8. **Extensión opcional:** evaluación de transferencia por isla y por período, cuando se realice.
9. **Cierre y reproducibilidad:** limitaciones, decisiones tomadas, parámetros y condiciones necesarias para ejecutar nuevamente el notebook.

Convención sugerida para los bloques iniciales:

```
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns

RANDOM_STATE = 42
DATA_URL = (
    "https://raw.githubusercontent.com/allisonhorst/"
    "palmerpenguins/master/inst/extdata/penguins.csv"
)
```

Reglas experimentales comunes

Estas reglas se aplican a todos los ejercicios:

1. Fijar y registrar una semilla aleatoria.
2. Conservar una copia inalterada de los datos originales.
3. Definir la partición sobre la copia inalterada y tratar observaciones y faltantes dentro de la partición correspondiente.
4. Realizar antes de la separación la revisión de estructura, identificadores, dependencias entre filas y disponibilidad del objetivo.
5. Reservar el conjunto de prueba para la evaluación final de variables, modelo e hiperparámetros ya fijados.
6. Ajustar imputación, codificación y escalado con los datos de entrenamiento de cada iteración.
7. Realizar análisis descriptivos, asociaciones con el objetivo y decisiones de modelado sobre el conjunto de desarrollo.
8. Conservar la misma semilla, los mismos índices y el mismo criterio de partición durante el experimento.
9. Informar las decisiones junto con los resultados numéricos.
10. Diferenciar claramente resultados de entrenamiento, validación y prueba.
11. Utilizar `Pipeline` y `ColumnTransformer` de `scikit-learn` cuando existan transformaciones aprendidas de los datos.
12. Declarar las variables de configuración en celdas visibles y ejecutar las celdas en orden.
13. Antes de entregar, reiniciar el kernel y ejecutar todas las celdas desde el comienzo.
14. El notebook debe finalizar sin errores y conservar las salidas necesarias para revisar los resultados.

Producto de entrega

Cada estudiante deberá entregar:

- Un único archivo `.ipynb` ejecutable y comentado que contenga todos los ejercicios.
- El informe breve integrado en las celdas Markdown del notebook.
- Una ficha final de protocolo experimental.
- Las tablas y figuras solicitadas con títulos, unidades y explicación.
- Una declaración de qué decisiones se tomaron antes y después de observar resultados.
- El archivo debe abrirse con Jupyter Notebook o JupyterLab y ejecutarse de principio a fin con **Restart Kernel and Run All**.

Bloque A. Formulación del problema

Ejercicio 1. Paradigma, tarea, algoritmo, predicción y decisión

Objetivo

Distinguir los niveles que intervienen en un sistema de Machine Learning.

Consignas

Para cada situación, completar la tabla solicitada:

1. Estimar la especie de un pingüino a partir de sus medidas corporales.
2. Estimar la masa corporal de un pingüino.
3. Formar grupos de pingüinos con perfiles morfológicos semejantes.
4. Usar una pequeña cantidad de especies verificadas y muchas observaciones sin especie confirmada.

Situación	Paradigma	Tarea	Salida esperada	Algoritmos posibles	Decisión apoyada
1					
2					
3					
4					

Luego responder:

1. ¿Qué elementos adicionales al algoritmo definen el problema experimental?
2. ¿En qué se diferencian una predicción y una decisión?
3. ¿Puede un mismo algoritmo resolver más de una tarea? Proponer un ejemplo.
4. ¿Puede una misma tarea resolverse con distintos algoritmos? Proponer dos alternativas.
5. ¿Por qué la codificación de las especies como 0, 1 y 2 conserva la naturaleza clasificatoria de la tarea?

Evidencia requerida

- Tabla completa.
- Respuestas justificadas en un máximo de 300 palabras.

Ejercicio 2. Tres formulaciones sobre el mismo conjunto de datos

Objetivo

Distinguir diferentes tareas que pueden formularse sobre un mismo dominio.

Consignas

Formular los siguientes problemas usando Palmer Penguins:

1. **Clasificación:** predecir `species`.
2. **Regresión:** predecir `body_mass_g`.

3. **Clustering:** descubrir perfiles a partir de las variables morfológicas y reservar **species** para la interpretación posterior de los grupos.

Completar una única tabla comparativa. Cada columna deberá contener la definición propuesta para el tipo de problema correspondiente:

Elemento	Definición propuesta: clasificación	Definición propuesta: regresión	Definición propuesta: clustering
Uso o decisión que se desea apoyar			
Unidad de análisis			
Variables de entrada candidatas			
Variable objetivo, si corresponde			
Salida producida por el modelo			
Error o fracaso relevante			

Preguntas de análisis

1. ¿Qué cambia entre las tres formulaciones aunque las filas sean las mismas?
2. ¿Qué variable debe ocultarse durante el clustering? ¿Para qué podría utilizarse después?
3. En regresión, ¿qué función debe asignarse a **body_mass_g** y qué riesgo produciría incluirla entre los predictores?
4. ¿Qué limitaciones de alcance tendrían las conclusiones obtenidas con estos datos?

Evidencia requerida

- Una tabla comparativa completa con las tres definiciones propuestas.
- Un párrafo que compare sus diferencias experimentales.

Bloque B. Auditoría y partición de los datos

Ejercicio 3. Auditoría estructural y reserva temprana de la prueba

Objetivo

Definir una separación reproducible antes de explorar relaciones con el objetivo o tomar decisiones de modelado.

Consignas

1. Descargar el CSV, conservar una copia inalterada y verificar dimensiones, nombres, tipos y disponibilidad de **species**.
2. Registrar la unidad de análisis y el caso nuevo establecidos en el escenario de uso de esta guía; comprobar la cantidad de filas idénticas y documentar el resultado.
3. Reservar 20 % como prueba mediante la partición aleatoria estratificada por **species** y con semilla registrada; conservar 80 % como desarrollo.

4. Guardar los índices de ambas particiones, comprobar que su intersección esté vacía y que su unión reconstruya el conjunto original.
5. Mantener cerrada la prueba hasta la evaluación final y realizar los análisis siguientes sobre desarrollo.
6. Completar el siguiente diccionario usando documentación y estadísticas del conjunto de desarrollo. Los nombres de las variables ya están precargados.

Variable	Descripción	Tipo conceptual	Tipo en pandas	Unidad o categorías	Cantidad de faltantes	Valores o rango observados	Rol posible	Tratamiento, controles y riesgos
species								
island								
bill_length_mm								
bill_depth_mm								
flipper_length_mm								
body_mass_g								
sex								
year								

Para completar la tabla se deberá indicar, calculando cantidades y rangos sobre desarrollo:

- **Descripción:** significado de la variable.
- **Tipo conceptual:** numérica continua, numérica discreta, categórica nominal o categórica ordinal.
- **Tipo en pandas:** tipo detectado al cargar el CSV, por ejemplo `object`, `float64` o `int64`.
- **Unidad o categorías:** unidad de medición o conjunto de categorías observadas.
- **Cantidad de faltantes:** número de valores ausentes calculado desde el `DataFrame`.
- **Valores o rango observados:** categorías presentes o valores mínimo y máximo.
- **Rol posible:** predictor, variable objetivo, variable contextual o variable reservada para análisis posterior, según la tarea.
- **Tratamiento, controles y riesgos:** imputación, codificación, escalado, controles de calidad y posibles fugas o atajos.

7. Contar faltantes por variable en desarrollo.
8. Buscar filas exactamente duplicadas y posibles duplicados lógicos dentro de desarrollo.
9. Describir en desarrollo la distribución de `species`, `island` y `sex`.
10. Obtener resúmenes de las cuatro medidas corporales usando solo desarrollo.
11. Identificar unidades y valores físicamente improbables en desarrollo, conservarlos durante la auditoría y proponer un tratamiento justificado.

Preguntas de análisis

1. ¿Qué tratamiento requieren los faltantes antes de entrenar?
2. ¿En qué datos debe calcularse la media dentro de cada fold de validación y qué fuga produciría calcularla sobre desarrollo completo?

3. ¿**island** podría actuar como atajo para predecir **species**? Investigar la relación mediante una tabla cruzada.
4. ¿El año debería tratarse como número continuo o categoría? Justificar según el uso propuesto.
5. ¿Qué información fue admisible para elegir la partición y qué análisis debió esperar hasta reservar la prueba?

Evidencia requerida

- Diccionario de datos completo según la tabla proporcionada.
- Criterio de partición, semilla e índices guardados.
- Comprobación de ausencia de superposición entre desarrollo y prueba.
- Tabla de calidad.
- Tabla cruzada **island** por **species**.
- Lista razonada de variables candidatas y variables que requieren cautela.

Ejercicio 4. Papeles de desarrollo, validación y prueba

Objetivo

Asignar a cada partición un único papel experimental.

Consignas

Para la clasificación de **species**, utilizar exactamente la separación fijada en el ejercicio anterior:

1. Confirmar que desarrollo contiene 80 % y prueba 20 % mediante los índices ya guardados.
2. Dentro del conjunto de desarrollo, establecer cómo se realizará la validación y qué decisiones podrán tomarse con ella.
3. Verificar una sola vez que la estratificación mantuvo proporciones razonables de especies en:
 - datos completos;
 - desarrollo;
 - prueba.
4. Registrar cantidades, proporciones, semilla e índices en un manifiesto de partición reproducible.
5. Crear una tabla que asigne una función y un momento de uso a cada partición:

Partición	Función asignada	Momento de uso
Entrenamiento		
Validación		
Prueba		

Preguntas de análisis

1. ¿Por qué la estratificación es apropiada para este objetivo?
2. ¿Qué ocurriría si una clase poco frecuente quedara casi ausente de validación?
3. ¿Por qué consultar la prueba después de cada modificación invalida su papel?

4. ¿Los porcentajes elegidos constituyen una regla universal? ¿Qué otros factores deberían considerarse?
5. Si se descubre una dependencia entre filas que vuelve incorrecta la separación, ¿por qué debe redefinirse el experimento antes de seguir comparando modelos?

Evidencia requerida

- Código reproducible de la partición.
- Manifiesto con criterio, semilla, índices, cantidades y proporciones.
- Tabla con cantidades y proporciones.
- Tabla de funciones y momentos de uso de las particiones.

Bloque C. Fuga de información y pipelines

Ejercicio 5. Detectives de fuga de información

Objetivo

Identificar procedimientos que producen evaluaciones demasiado optimistas.

Consignas

Clasificar cada situación como correcta o contaminada y explicar el motivo:

1. Imputar faltantes con la media de todas las filas y luego separar entrenamiento y prueba.
2. Separar primero y ajustar el imputador con entrenamiento.
3. Estandarizar las cuatro variables corporales usando todos los datos antes de validación cruzada.
4. Elegir las dos variables con mayor correlación con el objetivo usando entrenamiento y prueba juntos.
5. Probar veinte configuraciones y seleccionar la que logra mayor accuracy en prueba.
6. Mantener fotografías del mismo pingüino en una única partición.
7. Incluir una variable creada después de confirmar la especie.
8. Eliminar duplicados después de repartir sus copias entre entrenamiento y prueba.
9. Ajustar el escalador dentro de cada fold de validación cruzada.
10. Usar `island` sin analizar que puede actuar como atajo para `species`.

Para los casos contaminados:

- identificar qué información cruza la frontera;
- explicar en qué momento se genera esa información y compararlo con el momento de la predicción real;
- proponer una corrección.

Evidencia requerida

- Tabla con diagnóstico, explicación y corrección de los diez casos.

Ejercicio 6. Imputación y escalado: procedimiento incorrecto y procedimiento válido

Objetivo

Demostrar que las transformaciones también aprenden de los datos.

Consignas

Utilizar como predictores:

- `bill_length_mm`;
- `bill_depth_mm`;
- `flipper_length_mm`;
- `body_mass_g`.

Utilizar `species` como variable objetivo. Para clasificar las tres especies se puede emplear una regresión logística multiclase. El ejercicio se centra en observar dónde se ajustan la imputación y el escalado.

Importar como mínimo los siguientes módulos:

```
import pandas as pd

from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import StratifiedKFold, cross_validate
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
```

Usar los mismos folds y la misma configuración de `LogisticRegression` en ambos diseños para que la comparación sea justa.

Realizar dos diseños:

Diseño A, contaminado para fines de diagnóstico

1. Imputar y escalar usando todos los datos.
2. Aplicar después validación cruzada.

Diseño B, válido

1. Construir un pipeline con imputación y escalado.
2. Ajustar esas transformaciones dentro de cada fold.
3. Aplicar exactamente los parámetros aprendidos al fold reservado.

Comparar ambos resultados, aunque la diferencia sea pequeña.

Preguntas de análisis

1. ¿Por qué el Diseño A está conceptualmente invalidado aunque produzca una métrica similar?
2. ¿Qué parámetros aprende el imputador?
3. ¿Qué parámetros aprende el escalador?
4. ¿Qué objeto se evalúa realmente: el algoritmo final o el procedimiento completo?

Evidencia requerida

- Diagrama o lista de pasos de ambos diseños.
- Código de un pipeline reproducible.
- Comparación y explicación conceptual.

Bloque D. Baselines y métricas

Ejercicio 7. Baselines pertinentes

Objetivo

Establecer referencias mínimas antes de comparar modelos complejos.

Consignas

Construir los siguientes baselines usando solo información de entrenamiento:

1. **Clasificación:** predecir siempre la especie mayoritaria.
2. **Clasificación probabilística:** utilizar las frecuencias de especies observadas en entrenamiento.
3. **Regresión:** predecir siempre la media de `body_mass_g`.
4. **Regresión robusta:** predecir siempre la mediana de `body_mass_g`.
5. **Clustering:** considerar una partición trivial de un único grupo como referencia conceptual y evaluar si soluciones con más grupos aportan estructura estable e interpretable.

Evaluar cada baseline sobre los mismos casos que se utilizarán para evaluar los modelos correspondientes.

Preguntas de análisis

1. ¿Por qué el baseline debe usar la misma información disponible que el modelo?
2. ¿Qué condiciones debe cumplir una referencia para que la comparación aporte evidencia de utilidad?
3. ¿Qué regla humana sencilla podría utilizarse como baseline operativo para estimar la masa de un pingüino?
4. ¿Qué cantidad mínima de grupos requiere silhouette y qué elementos compara esa métrica?

Evidencia requerida

- Tabla de baselines, reglas y métricas.
- Justificación de cuál será la referencia principal para cada tarea.

Ejercicio 8. Matriz de confusión y métricas de clasificación

Objetivo

Interpretar accuracy, precisión, recall y F1 según el error relevante.

Parte A. Cálculo manual

En un problema binario se obtuvieron:

- $VP = 16$
- $FP = 8$

- $FN = 4$
- $VN = 72$

Calcular, mostrando las operaciones:

1. Accuracy.
2. Precisión.
3. Recall.
4. F1.
5. Proporción real de positivos.

Luego interpretar cada resultado en una oración.

Parte B. Accuracy engañosa

En 100 casos existen 20 positivos y 80 negativos. Un sistema siempre predice la clase negativa.

1. Construir la matriz de confusión.
2. Calcular accuracy y recall.
3. Explicar por qué una accuracy del 80 % puede ser inútil.
4. Proponer una situación donde los falsos negativos sean más costosos.
5. Proponer otra donde los falsos positivos sean más costosos.

Parte C. Clasificación multiclase con Palmer Penguins

1. Ajustar un modelo sencillo de clasificación.
2. Obtener la matriz de confusión de validación.
3. Calcular accuracy, precisión, recall y F1 por especie.
4. Calcular un promedio macro para asignar el mismo peso a cada clase en la interpretación.
5. Identificar qué par de especies se confunde con mayor frecuencia.
6. Comparar contra el baseline de clase mayoritaria.

Evidencia requerida

- Cálculos manuales.
- Matriz de confusión correctamente rotulada.
- Tabla de métricas por clase.
- Interpretación vinculada con tipos de error.

Ejercicio 9. Métricas de regresión

Objetivo

Comparar MAE, RMSE y R cuadrado fuera de muestra.

Parte A. Cálculo manual

Valores reales: [10, 12, 18, 20]

Predicciones: [11, 10, 17, 26]

1. Calcular los errores con signo.
2. Calcular los errores absolutos.
3. Calcular los errores cuadrados.
4. Obtener MAE y RMSE.
5. Explicar por qué RMSE aumenta más ante el error de 6 unidades.

Parte B. Predicción de masa corporal

Predecir `body_mass_g` a partir de:

- `bill_length_mm`;
- `bill_depth_mm`;
- `flipper_length_mm`.

Realizar lo siguiente:

1. Evaluar los baselines de media y mediana.
2. Ajustar una regresión lineal mediante un pipeline.
3. Medir MAE, RMSE y R cuadrado en validación.
4. Comparar las métricas con las de los baselines.
5. Expresar MAE y RMSE en gramos.
6. Interpretar qué significa un R cuadrado negativo si apareciera fuera de muestra.
7. Decidir qué métrica sería principal si los errores grandes fueran especialmente costosos.

Extensión

Incorporar `species` como predictor mediante codificación ajustada dentro del pipeline y comparar. Explicar qué pregunta distinta responde el nuevo modelo.

Evidencia requerida

- Cálculos manuales.
- Tabla comparativa de modelos y baselines.
- Interpretación en unidades del problema.

Ejercicio 10. Evaluación de clustering

Objetivo

Evaluar grupos sin confundir calidad geométrica con utilidad sustantiva.

Consignas

Usar las cuatro variables morfológicas:

- `bill_length_mm`;
- `bill_depth_mm`;
- `flipper_length_mm`;
- `body_mass_g`.

Construir los clusters con esas cuatro variables y reservar **species**, **island** y **sex** para la interpretación posterior.

1. Imputar faltantes y estandarizar las variables.
2. Aplicar K-means para valores de K entre 2 y 6.
3. Repetir cada configuración con varias inicializaciones o semillas.
4. Calcular silhouette para cada K.
5. Examinar la variabilidad de silhouette entre repeticiones.
6. Seleccionar una solución considerando:
 - cohesión;
 - separación;
 - estabilidad;
 - simplicidad;
 - interpretabilidad.
7. Describir cada cluster mediante valores centrales de las variables en sus unidades originales.
8. Después de finalizar el agrupamiento, comparar los clusters con **species** mediante una tabla cruzada e interpretar esta comparación como evaluación externa del agrupamiento.
9. Analizar casos con silhouette baja o negativa.
10. Explicar si los grupos podrían apoyar alguna decisión concreta.

Preguntas de análisis

1. ¿Por qué es imprescindible escalar antes de usar distancias con estas variables?
2. ¿Un silhouette alto demuestra que los grupos tienen significado biológico?
3. ¿Por qué distintas semillas pueden producir soluciones diferentes?
4. ¿Qué significa que un cluster contenga varias especies?
5. ¿Qué información adicional aporta la estabilidad frente al resultado de una única ejecución?

Evidencia requerida

- Curva o tabla de silhouette para $K = 2, \dots, 6$.
- Resumen de estabilidad entre repeticiones.
- Perfiles de clusters en unidades originales.
- Tabla cruzada final con **species**.
- Interpretación que separe evidencia geométrica de significado de dominio.

Bloque E. Validación cruzada y comparación de modelos

Ejercicio 11. Validación cruzada del procedimiento completo

Objetivo

Estimar desempeño y variabilidad mediante validación cruzada sobre el conjunto de desarrollo.

Consignas

Sobre el conjunto de desarrollo de la tarea de clasificación:

1. Definir una validación cruzada estratificada de K folds.
2. Construir un pipeline con:
 - imputación;
 - escalado, cuando el algoritmo lo requiera;
 - modelo.
3. Evaluar al menos:
 - regresión logística multinomial;
 - árbol de decisión.
4. Usar exactamente los mismos folds para ambos modelos.
5. Registrar accuracy y F1 macro en cada fold.
6. Informar promedio, desvío estándar, mínimo y máximo.
7. Mantener el conjunto de prueba cerrado durante todo el ejercicio.

Preguntas de análisis

1. ¿Por qué informar solamente el promedio oculta información?
2. ¿Qué indicaría una dispersión grande entre folds?
3. ¿Por qué los modelos deben utilizar los mismos folds?
4. ¿Dónde deben aprenderse imputación, escalado y cualquier selección de atributos?
5. ¿Qué parte del proceso permanece completamente fuera del ciclo?

Evidencia requerida

- Descripción de folds, semilla y métricas.
- Tabla con resultados por fold.
- Tabla resumida de comparación.
- Selección provisional de un modelo obtenida mediante validación sobre desarrollo.

Ejercicio 12. Subajuste, equilibrio y sobreajuste

Objetivo

Relacionar capacidad del modelo con desempeño de entrenamiento y validación.

Consignas

Entrenar árboles de clasificación con diferentes valores de profundidad máxima, por ejemplo:

1, 2, 3, 5, 8, sin límite

Para cada configuración:

1. Medir desempeño de entrenamiento.
2. Medir desempeño mediante los mismos folds de validación.
3. Registrar promedio y dispersión.
4. Construir una figura con complejidad en el eje horizontal y desempeño en el vertical.
5. Clasificar cada región como posible subajuste, equilibrio o sobreajuste.
6. Seleccionar una configuración considerando desempeño, estabilidad y simplicidad.

Preguntas de análisis

1. ¿Qué patrón se espera bajo subajuste?
2. ¿Qué brecha entre entrenamiento y validación sugiere sobreajuste?
3. ¿Qué riesgo presenta elegir la configuración mediante el mejor resultado de entrenamiento?
4. ¿Qué papel cumple la simplicidad cuando dos configuraciones rinden de forma semejante?

Evidencia requerida

- Tabla por configuración.
- Curva de desempeño.
- Selección justificada a partir de los resultados de validación.

Ejercicio 13. Evaluación final sobre la prueba reservada

Objetivo

Obtener una estimación final sobre datos independientes de las decisiones del procedimiento.

Consignas

Antes de acceder a la prueba, dejar por escrito y congelar:

- variables seleccionadas y función asignada a cada variable disponible;
- imputación, codificación, escalado y cualquier selección de atributos;
- familia de modelo e hiperparámetros;
- semilla, métricas y definición de clase positiva cuando corresponda;
- criterio utilizado para elegir la configuración final.

Luego:

1. Reajustar el pipeline completo con todo el conjunto de desarrollo.
2. Aplicar a la prueba reservada las transformaciones aprendidas en desarrollo.
3. Calcular una sola vez las métricas finales y la matriz de confusión.
4. Comparar el resultado con la estimación de validación y analizar las diferencias conservando la configuración congelada.
5. Registrar cualquier problema como limitación del experimento finalizado o como inicio de un nuevo ciclo experimental con una nueva muestra de evaluación.

Preguntas de análisis

1. ¿La diferencia entre validación y prueba es compatible con la variabilidad observada entre folds?
2. ¿Qué conclusiones están respaldadas por esta prueba y cuáles exceden la población evaluada?
3. ¿Qué nuevo conjunto independiente sería necesario si el resultado de prueba motiva cambios en el procedimiento?

Evidencia requerida

- Configuración final congelada antes de abrir la prueba.
- Métricas y matriz de confusión de prueba.
- Comparación entre validación y prueba.
- Declaración explícita del momento en que se consultó la prueba y de las decisiones que quedaron congeladas previamente.

Extensión opcional: transferencia entre contextos

En esta guía, **transferencia** significa aplicar un modelo en un contexto que estuvo ausente durante su ajuste. La separación por contexto cambia la pregunta experimental: en lugar de estimar el desempeño sobre nuevos individuos de la misma población combinada, se estudia cuánto se conservan las relaciones aprendidas al cambiar de isla o avanzar en el tiempo.

Ejemplo temporal. Ajustar con observaciones de 2007 y 2008 y evaluar con las de 2009 representa el uso de un modelo en un período posterior. La pregunta concreta es: *¿las relaciones entre las medidas corporales y la especie aprendidas en 2007–2008 conservan su utilidad para clasificar pingüinos observados en 2009?*

Ejemplo por isla. Ajustar con Biscoe y Dream y evaluar con Torgersen representa el uso del modelo en una isla ausente durante el ajuste. La pregunta concreta es: *¿las relaciones morfológicas aprendidas en Biscoe y Dream permiten reconocer los pingüinos de Torgersen?* En Palmer Penguins, isla y especie están fuertemente relacionadas: Torgersen contiene Adelie, Dream contiene Adelie y Chinstrap, y Biscoe contiene Adelie y Gentoo. Por ello, reservar una isla también puede cambiar las especies disponibles en cada partición. Esa cobertura forma parte del fenómeno que debe analizarse.

La extensión se realizará después de completar la evaluación principal y se informará como un experimento separado:

1. Construir una tabla cruzada de **island** por **species** y otra de **year** por **species**.
2. Para la transferencia temporal, usar 2007–2008 como desarrollo y 2009 como evaluación.

3. Para la transferencia por isla, repetir tres veces el análisis, reservando en cada repetición una isla completa para evaluación y usando las otras dos para desarrollo.
4. Registrar qué especies aparecen en desarrollo y evaluación en cada repetición.
5. Informar métricas por especie, cobertura de clases y matriz de confusión.
6. Interpretar por separado el cambio de contexto y la disponibilidad de cada especie durante el ajuste.
7. Comparar cada resultado con la partición aleatoria estratificada del experimento principal.

Por ejemplo, al reservar Dream, Chinstrap aparece en evaluación y está ausente de las otras islas usadas para desarrollo. Ese resultado muestra una falta de cobertura de la clase durante el aprendizaje. Al reservar Torgersen, Adelie está representada también en desarrollo, pero la evaluación contiene una sola especie; las métricas por especie describen entonces la transferencia de Adelie hacia esa isla. Estos ejemplos permiten distinguir entre *cambio de contexto* y *cobertura de clases*.