Ingeniería de atributos y clustering

De la representación de datos a segmentos interpretables



Curso de Data Science

Semana 6 · Clase 6

Propósito de la clase

Construir representaciones útiles para analizar datos y formar grupos sin una etiqueta objetivo conocida.

Al finalizar, podremos

- transformar atributos numéricos, categóricos, temporales y espaciales;
- distinguir selección y reducción dimensional;
- explicar K-means, jerárquico y DBSCAN;
- calcular métricas de agrupamiento;
- describir grupos con prudencia.

Punto de partida

La Semana 05 estableció cómo formular una tarea y evaluar procedimientos. Ahora el foco es anterior al modelo:

datos brutos $\rightarrow$ representación $\rightarrow$ estructura analizable.

Idea

Las decisiones de representación determinan qué diferencias, semejanzas y patrones pueden aparecer.

Caso conductor: Palmer Penguins

Elemento	Decisión
Unidad	un pingüino registrado
Formación	cuatro medidas morfológicas
Variables reservadas	`species`, `island`, `sex`
Pregunta	¿qué perfiles aparecen sin usar especie?
Uso posterior	describir patrones y contrastarlos con información externa

Atributos: representación con propósito

Dato	Representación	Supuesto
masa corporal	valor, logaritmo o nivel	importa escala absoluta o relativa
isla	categoría indicadora	no existe orden entre islas
fecha	año, estación o ciclo	hay estructura temporal relevante
ubicación	zona, distancia o conectividad	la cercanía está bien definida

Criterio

Una representación útil conserva significado y responde a la pregunta de análisis.

Outliers: error, evento o población distinta

Un valor extremo puede ser error de captura, medición válida inusual, señal de otra población o resultado de una transformación incorrecta.

Criterio

Antes de recortar, revisar fuente, unidad, cobertura y contexto. Eliminar extremos sin investigar puede borrar justamente el patrón relevante.

Transformaciones numéricas

Operación	Uso	Riesgo
estandarizar	relacionar escalas	asumir comparabilidad sin justificación
logaritmo	comprimir colas	usar ceros o negativos
razón	normalizar exposición	denominador pequeño o nulo
recorte	limitar influencia extrema	ocultar eventos reales

Ejemplo

Masa en gramos y aleta en milímetros requieren una decisión de escala antes de usar distancias.

Categorías, discretización y binarización

- Las categorías nominales no poseen orden ni distancia intrínsecos.
- La codificación indicadora crea una columna binaria por nivel.
- Discretizar convierte una escala continua en intervalos.
- Binarizar expresa una condición, por ejemplo masa > 4500 g.

Control

La codificación debe preservar significado y declarar cómo trata niveles nuevos.

Tiempo, espacio e interacciones

Para una posición temporal t dentro de un periodo P:

$$x_{\sin} = \sin(2\pi t/P), \qquad x_{\cos} = \cos(2\pi t/P).$$

Las interacciones expresan que el efecto de una variable depende de otra. Las distancias espaciales deben representar el mecanismo relevante: kilómetros, conectividad y tiempo de viaje no son equivalentes.

Selección y reducción no son lo mismo

Operación	Resultado
Selección	conserva un subconjunto de columnas originales
Reducción dimensional	construye coordenadas combinando columnas

Ejemplo

La selección conserva una medida corporal directa; PCA puede resumir medidas correlacionadas en componentes menos interpretables.

Familias de selección de atributos

Familia	Estrategia	Límite
Filtro	puntuar antes del modelo	puede ignorar interacciones
Envolvente	comparar subconjuntos	costo y sobreajuste de búsqueda
Embebida	seleccionar durante el ajuste	depende de modelo y escala

Precaución

Relevancia no equivale a causalidad; atributos correlacionados pueden sustituirse entre muestras.

Reducir dimensión: por qué

$$Z = g(X), \qquad q < p.$$

- Puede comprimir, disminuir ruido o facilitar visualización.
- En alta dimensión, las distancias entre vecinos pierden contraste.
- Variables irrelevantes degradan la noción de semejanza.

PCA: componentes principales

PCA busca direcciones ortogonales de máxima varianza:

1. centrar variables;
2. decidir si las unidades justifican estandarizar;
3. proyectar observaciones en componentes ordenadas por varianza.

Lectura

Las cargas indican contribución de variables; las puntuaciones ubican observaciones en la nueva representación.

Varianza explicada y límites de PCA

$$\mathrm{PVE}_j = \frac{\lambda_j}{\sum_r \lambda_r}.$$

- Alta varianza explicada no garantiza relevancia para una tarea.
- Una señal rara puede quedar en componentes de baja varianza.
- Un plano PCA explora; no prueba grupos separados.

Aprendizaje no supervisado

No hay etiqueta que indique la respuesta correcta. El análisis busca resumir perfiles, explorar estructura local, detectar casos para revisión y generar hipótesis.

Pregunta central

¿Qué significa semejanza para las variables y el uso previsto?

Distancia euclídea

$$d_2(x, z) = \sqrt{\sum_{j=1}^{p} (x_j - z_j)^2}.$$

Es coherente con K-means y centroides definidos por medias. Las diferencias grandes pesan más y las escalas deben ser comparables.

Manhattan y coseno

$$d_1(\mathrm{x}, \mathrm{z}) = \sum_{j=1}^{p} |x_j - z_j|.$$

$$s_{\cos}(\mathrm{x}, \mathrm{z}) = \frac{\mathrm{x}^{\mathsf{T}}\mathrm{z}}{\|\mathrm{x}\|_2 \|\mathrm{z}\|_2}.$$

Manhattan reduce el peso relativo de extremos. El coseno compara forma relativa y puede ignorar magnitud.

Escalado y ponderación

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \qquad d_w(x, z) = \sqrt{\sum_{j=1}^{p} w_j (x_j - z_j)^2}.$$

Criterio

Ponderar debe responder a confiabilidad o significado, no a producir grupos visualmente atractivos.

K-means: objetivo

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2.$$

El centroide μ_k es la media del grupo: un perfil promedio, no necesariamente una observación real.

K-means: procedimiento

1. Inicializar K centroides.
2. Asignar cada observación al centroide más cercano.
3. Recalcular cada centroide como media del grupo.
4. Repetir hasta estabilizar asignaciones u objetivo.

Control

K-means++ y varios reinicios reducen el riesgo de resultados locales deficientes.

Cuándo sirve K-means

Adecuado

- grupos compactos;
- dispersión semejante;
- variables numéricas escaladas.

Problemático

- grupos curvos;
- densidades diferentes;
- casos que deberían quedar aislados.

Límite

K-means siempre asigna cada observación a un grupo.

Elegir K

$$W_K = \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \boldsymbol{\mu}_k\|_2^2.$$

La inercia disminuye siempre al crecer K. El codo busca rendimientos decrecientes, pero no determina una respuesta única.

Decisión

Combinar inercia, métricas, tamaños, estabilidad, simplicidad y utilidad de perfiles.

Clustering jerárquico

Estrategia	Inicio	Operación
Aglomerativa	una observación por grupo	fusiona grupos cercanos
Divisiva	un conjunto	divide grupos sucesivamente

Resultado

El dendrograma permite examinar varias granularidades; una fusión aglomerativa temprana no se deshace.

Enlaces y dendrogramas

- **Simple**: par más cercano; puede encadenar regiones mediante puntos puente.
- **Completo**: par más lejano; favorece compactación, es sensible a extremos.
- **Promedio**: resume todas las distancias entre pares.
- **Ward**: minimiza aumento de dispersión con geometría euclídea coherente.

El orden horizontal de hojas no representa otra distancia. El corte se justifica con perfiles, estabilidad y propósito.

Alternativas de enlace: una lectura visual

Enlace simple



par más cercano

Enlace completo



par más lejano

Enlace promedio



todas las distancias

Enlace de Ward



centroides y dispersión

Lectura

La misma matriz de datos puede producir jerarquías distintas porque cada enlace define distancia entre grupos de otra manera.

DBSCAN: densidad y ruido

DBSCAN usa radio ε y `min_samples`.

Tipo	Condición
núcleo	suficientes vecinos en radio ε
frontera	cerca de un núcleo, pero no es núcleo
ruido	fuera de regiones densas bajo esa configuración

Puede encontrar formas arbitrarias y no requiere fijar K.

Sensibilidad de DBSCAN

- Radio grande fusiona regiones; radio pequeño las fragmenta.
- `min_samples` grande exige más evidencia local.
- El escalado cambia el significado de ε.
- Ruido no significa error ni irrelevancia.

Control

Explorar una grilla de parámetros y buscar configuraciones estables, no una cifra aislada favorable.

Métricas internas

Métrica	Qué resume	Dirección
Inercia	dispersión de K-means	menor
Silhouette	cohesión y separación	mayor
Calinski–Harabasz	separación relativa	mayor
Davies–Bouldin	grupos rivales	menor

Límite

Las métricas dependen de representación y geometría; ninguna identifica sola una segmentación útil.

Silhouette

Para i, $a(i)$ es distancia media a su grupo y $b(i)$ la menor distancia media a otro grupo:

$$s(i) = \frac{b(i) - a(i)}{\text{máx}\{a(i), b(i)\}}.$$

- Cercano a 1: cohesión y separación altas.
- Cercano a 0: caso fronterizo.
- Negativo: más cercano, en promedio, a otro grupo.

Calinski–Harabasz y Davies–Bouldin

Calinski–Harabasz compara dispersión entre grupos con dispersión interna; valores mayores indican separación relativa mayor.

$$DB = \frac{1}{K} \sum_{k=1}^{K} \max_{l \neq k} \frac{S_k + S_l}{M_{kl}}.$$

Davies–Bouldin menor es preferible. Ambas métricas favorecen geometrías particulares y se interpretan junto con perfiles y estabilidad.

Estabilidad y casos frontera

Diagnóstico	Pregunta
reinicios	¿la optimización llega a particiones parecidas?
submuestras	¿los perfiles sobreviven a cambios de muestra?
silhouette baja	¿son fronteras, errores o transiciones?
tamaños	¿hay segmentos diminutos o dominantes?

Describir grupos con prudencia

Una ficha de grupo debe indicar cantidad, perfiles centrales y dispersión en unidades originales, casos representativos y frontera, sensibilidad y población cubierta.

Lenguaje

Usar nombres descriptivos, no etiquetas valorativas. Un grupo encontrado no demuestra una clase natural ni una causa.

Comparación externa posterior

Después de formar grupos con las cuatro medidas, podemos cruzar `cluster` con `species`.

Uso legítimo	Uso incorrecto
describir coincidencias y desacuerdos **evaluar una referencia externa**	declarar que el algoritmo predijo especie usar especie para elegir retrospectivamente el mejor resultado

Notebook: qué exploraremos

1. Imputación y estandarización de medidas morfológicas.
2. K-means, jerárquico y DBSCAN.
3. Inercia, silhouette, Calinski–Harabasz, Davies–Bouldin y estabilidad.
4. PCA 2D solo para visualizar.
5. Perfiles en unidades originales y tabla cruzada final con especie.

Síntesis

- Atributos, escalas y agregaciones definen el espacio donde se buscan patrones.
- Selección conserva columnas; PCA crea representaciones nuevas.
- K-means, jerárquico y DBSCAN responden a geometrías distintas.
- Métricas comparan estructura geométrica, no significado automático.
- Estabilidad, perfiles e información externa completan la evaluación.

Lecturas

Ingeniería y reducción de atributos

- Capítulo 10, §§10.1–10.4.

Clustering y evaluación

- Capítulo 13, §§13.1–13.4.

Práctica

- Guía de ejercicios de Diseño experimental de Machine Learning, ejercicio 10: Palmer Penguins.