


Diseño experimental de Machine Learning

De datos históricos a decisiones confiables



El valor de una predicción depende del experimento que permite confiar en ella.

Curso de Inteligencia Artificial

Semana 5 · Clase 5

Continuidad: de incertidumbre a aprendizaje

Un agente decide con información parcial y costos distintos para cada error.

- ▶ La probabilidad representó la creencia sobre un estado oculto.
- ▶ El costo esperado conectó esa creencia con una acción.
- ▶ En sistemas reales, las probabilidades y reglas se estiman con datos históricos.

Continuidad

Diseñar el experimento determina si una estimación aprendida puede sostener una decisión fuera de los datos usados para construirla.

Propósito y resultados de aprendizaje

Propósito: diseñar una evaluación de Machine Learning alineada con la decisión y libre de información indebida.

Al finalizar, podremos

- ▶ distinguir tarea, modelo, regla de decisión y agente;
- ▶ definir unidad, población, instante, horizonte, variables y etiqueta;
- ▶ elegir particiones coherentes con la forma de uso;
- ▶ construir baselines y métricas vinculadas con costos;
- ▶ aplicar validación cruzada sin fuga de información;
- ▶ reconocer subajuste, sobreajuste y comparaciones injustas;
- ▶ documentar un procedimiento reproducible y congelado.

Pregunta de apertura

Pregunta clave

Un vehículo debe decidir si ingresa a un tramo. ¿Cómo demostramos que su estimación de bloqueo funcionará con tramos futuros?

- ▶ ¿Qué señales existen antes de ingresar? ¿Cuándo se confirma el estado real?
- ▶ ¿Qué error es más costoso: ingresar con bloqueo o desviarse sin necesidad?
- ▶ ¿Qué datos representan el uso real?

Idea

El experimento debe reproducir la información y las restricciones disponibles al decidir.

De probabilidades dadas a estimaciones aprendidas

Probabilidad especificada	Estimación aprendida
Se entrega $P(B)$ y $P(A B)$ La tabla define la relación Bayes actualiza la creencia	Se observan ejemplos históricos (x_i, y_i) Una función f aproxima la relación $\hat{y} = f(x)$ estima el objetivo

Puente

Los datos reemplazan parámetros dados por estimaciones; el diseño experimental controla si esas estimaciones generalizan.

¿Qué significa aprender?

Aprender es ajustar, a partir de ejemplos, una función que transforma información disponible en una salida útil:


$$f : \mathcal{X} \rightarrow \mathcal{Y}, \quad \hat{y} = f(x).$$

- ▶ x : variables observadas antes de decidir.
- ▶ y : resultado real definido por el problema.
- ▶ $\hat{y}$: estimación producida por la función aprendida.
- ▶ El ajuste busca buen desempeño en casos no usados para aprender.

Resultado

Memorizar ejemplos no equivale a aprender una relación generalizable.

Modelo, regla de decisión y agente



Modelo

estima una clase, valor o puntaje

Regla de decisión

convierte salida y costos en una acción

Agente

observa, aplica la regla, actúa y recibe consecuencias

Control

Una predicción de bloqueo no ordena desviarse; la acción depende del umbral, los costos y las restricciones.

Anatomía de un ejemplo

Para un tramo observado a las 08:00:

Elemento	Ejemplo
x	lluvia reciente, velocidad aguas arriba, alertas previas, tipo de vía
y	1 si queda confirmado como bloqueado en 15 min; 0 si queda libre
$\hat{y}$	puntaje de bloqueo estimado antes de ingresar

Unidad temporal

Una fila representa una unidad en un instante. La etiqueta se conoce después; la predicción usa únicamente el pasado disponible a las 08:00.

Aprendizaje supervisado

El conjunto de entrenamiento contiene pares (x_i, y_i) con respuesta conocida:

$$\{(x_1, y_1), \dots, (x_n, y_n)\} \longrightarrow \hat{f}.$$

- ▶ La etiqueta guía el ajuste de la función.
- ▶ La salida se compara con respuestas reales no usadas en el ajuste.
- ▶ Ejemplos: bloqueo de un tramo, demanda de agua y tiempo de resolución de un reclamo.

Idea

Supervisado describe la disponibilidad de etiquetas, no un algoritmo particular.

Clasificación y regresión

Tarea	Salida	Ejemplo de transferencia
Clasificación	categoría o puntaje	tramo bloqueado/libre; reclamo urgente/no urgente
Regresión	valor numérico	demanda de agua; minutos para resolver un reclamo

- ▶ En clasificación, un puntaje puede convertirse en clase mediante un umbral.
- ▶ En regresión, la salida conserva escala y unidad.

Control

La forma de y define la tarea; la acción pertenece al sistema de decisión.

Aprendizaje no supervisado

Los datos contienen variables x_i , pero no una etiqueta objetivo y_i .

- ▶ Busca estructura, similitudes o representaciones en los datos.
- ▶ El **clustering** agrupa observaciones según un criterio de similitud.
- ▶ Ejemplo: agrupar patrones de consumo de agua sin categorías previas.
- ▶ Los grupos obtenidos requieren interpretación y validación respecto del propósito.

Resultado

Descubrir estructura no demuestra por sí mismo capacidad predictiva ni prescribe una acción.

Aprendizaje semisupervisado

Combina pocos ejemplos etiquetados con muchos sin etiqueta:

$$\mathcal{D}_L = \{(x_i, y_i)\}, \quad \mathcal{D}_U = \{x_j\}, \quad |\mathcal{D}_L| \ll |\mathcal{D}_U|.$$

- ▶ Es útil cuando medir señales es barato y confirmar el resultado es costoso.
- ▶ En movilidad abundan trazas, pero confirmar cada bloqueo exige verificación.
- ▶ La evaluación final necesita etiquetas confiables y una partición representativa.

Control

Datos sin etiqueta amplían información sobre x ; no reemplazan una definición precisa de y .

Comparación de paradigmas

Paradigma	Evidencia disponible	Pregunta central
Supervisado	ejemplos (x, y)	¿qué salida corresponde a un caso nuevo?
No supervisado	ejemplos x	¿qué estructura aparece en los datos?
Semisupervisado	pocos (x, y) y muchos x	¿cómo aprovechar ambos conjuntos?
Refuerzo	interacción, acciones y recompensas	¿qué acciones acumulan mejores consecuencias?

Idea

El paradigma surge del tipo de retroalimentación disponible y del objetivo de la tarea.

Partir de la decisión

El diseño comienza en el uso, no en el archivo de datos:

- 1 decisión que debe tomar el sistema;
- 2 consecuencias de cada error;
- 3 salida predictiva que informa la decisión;
- 4 instante exacto en que se requiere;
- 5 evidencia disponible en ese instante;
- 6 evaluación que reproduce esas condiciones.

Pregunta clave

¿Qué cambiará operativamente cuando el modelo produzca $\hat{y}$?

Definición del caso conductor

Elemento	Definición
Decisión	ingresar al tramo o tomar un desvío
Salida predictiva	puntaje de bloqueo en los próximos 15 min
Regla	desviar si el puntaje supera el umbral operativo
Evidencia	señales registradas antes de ingresar
Confirmación	reporte verificado del estado del tramo
Costo principal	seguridad, demora y consumo del recorrido

Criterio de consistencia

Cada ejemplo debe respetar estas definiciones para representar la misma tarea.

Unidad y población

- ▶ **Unidad de análisis:** un par (tramo, instante de decisión).
- ▶ **Población objetivo:** decisiones de ingreso de la flota en la red y condiciones operativas definidas.
- ▶ **Muestra:** unidades históricas observadas y recuperadas por el sistema de datos.

La misma vía en dos instantes produce dos unidades distintas. Dos registros de la misma unidad no son evidencia independiente.

Control

Evaluar sobre otra población responde otra pregunta, aunque las columnas coincidan.

Objetivo, etiqueta, predicción y acción

Objetivo	anticipar bloqueo antes de ingresar
Etiqueta y	estado confirmado dentro del horizonte: 1/0
Predicción $\hat{y}$	puntaje o clase estimada
Acción	ingresar, desviar o solicitar verificación


$$x \xrightarrow{f} \hat{y} \xrightarrow{\text{regla} + \text{costos}} a.$$

Resultado

Evaluar $\hat{y}$ mide predicción; evaluar consecuencias de a mide el sistema de decisión.

Instante y horizonte

- ▶ t_0 : instante en que el vehículo debe decidir.
- ▶ Ventana de observación: datos con marca temporal $t \leq t_0$.
- ▶ Horizonte $H = 15$ min; etiqueta: bloqueo confirmado en $(t_0, t_0 + H]$.



Control

Cambiar t_0 o H cambia la tarea, la etiqueta y la utilidad operativa.

Variables disponibles al decidir

Admitidas en t_0	No admitidas en t_0
lluvia acumulada hasta t_0 velocidad aguas arriba hasta t_0 reportes recibidos antes de t_0 atributos estables del tramo	lluvia registrada después de t_0 velocidad medida tras ingresar confirmación final del bloqueo duración total del incidente

Control

Una columna es válida por su momento real de disponibilidad, no por aparecer en la tabla histórica.

Fuga de información

Existe **fuga** cuando el entrenamiento o la evaluación reciben información que no estaría disponible al producir la predicción real.

- ▶ Infla el resultado medido sin mejorar el uso futuro.
- ▶ Puede ocurrir en variables, transformaciones o particiones.
- ▶ También aparece cuando una misma entidad aporta registros casi idénticos a entrenamiento y evaluación.

Prueba operativa

Para cada valor usado, registrar quién lo genera, cuándo existe y qué datos intervinieron en su cálculo.

Tres fugas frecuentes

Tipo	Ejemplo	Control
Temporal	usar la duración final del bloqueo	cortar variables en t_0
Preprocesamiento	normalizar con media de todo el conjunto	ajustar solo con entrenamiento
Duplicados o entidad	misma ventana o vehículo en ambos lados	deduplicar y separar por unidad o grupo

Resultado

Quitar una columna sospechosa no basta; la frontera experimental debe aislar toda información futura o compartida.

Generalización

Generalizar es mantener desempeño en unidades nuevas de la población objetivo.

$$R(f) = \mathbb{E}_{(X,Y) \sim P_{\text{uso}}} [L(Y, f(X))].$$

La evaluación estima ese riesgo con datos no usados para ajustar el procedimiento.

- ▶ Muestra representativa del uso esperado.
- ▶ Separación compatible con dependencias temporales y de entidad.
- ▶ Métrica alineada con el error relevante.

Idea

Un valor fuera de muestra es evidencia bajo un escenario de uso definido, no una garantía universal.

Entrenamiento, validación y prueba

Entrenamiento	ajustar parámetros y transformaciones
Validación	elegir variables, configuraciones y umbral con la métrica principal ya definida
Prueba	medir una vez el procedimiento congelado

Consultar repetidamente la prueba la convierte en validación.

Control

La prueba se reserva para la medición final; cualquier cambio motivado por ella exige una nueva prueba independiente.

Partición aleatoria y estratificada

- ▶ **Aleatoria**: asigna unidades al azar; corresponde cuando son intercambiables e independientes.
- ▶ **Estratificada**: conserva aproximadamente la proporción de clases en cada partición.
- ▶ La estratificación estabiliza la medición cuando el bloqueo es poco frecuente.
- ▶ Ninguna resuelve dependencias entre registros de una entidad ni anticipación temporal.

Control

Primero se define qué observaciones pueden separarse; después se conserva la distribución relevante.

Partición por grupos

Todos los registros de un mismo grupo quedan en una sola partición.

Entrenamiento
A, B, C

Validación
D

Prueba
E

- ▶ Grupo posible: vehículo, corredor, sensor, cliente o evento.
- ▶ Evalúa transferencia hacia grupos no observados durante el ajuste.
- ▶ Evita que patrones propios de una entidad aparezcan a ambos lados.

Pregunta clave

¿El uso real predice nuevos instantes de entidades conocidas o entidades completamente nuevas?

Partición temporal

El pasado entrena y el futuro evalúa:



- ▶ Respeta causalidad y simula despliegue prospectivo.
- ▶ Conserva juntas las ventanas de un mismo incidente cuando corresponde.
- ▶ Puede revelar cambios de estación, sensores, rutas o comportamiento.

Control

Toda variable y transformación se calcula únicamente con información anterior al período evaluado.

Baseline: el mínimo que debe superarse

Un baseline es una referencia simple, reproducible y disponible con la misma información.

- ▶ Clasificación: clase mayoritaria o regla operativa vigente.
- ▶ Regresión: media o mediana del entrenamiento.
- ▶ Series temporales: último valor observado o patrón estacional simple.

Resultado

Un modelo complejo aporta valor solo si mejora una referencia pertinente en la métrica y el escenario elegidos.

Baseline de clasificación: accuracy engañosa

En 100 registros hay 20 bloqueos y 80 libres. El baseline siempre predice libre.

	Real bloqueado	Real libre
Predice bloqueado	VP = 0	FP = 0
Predice libre	FN = 20	VN = 80

$$\text{accuracy} = \frac{0 + 80}{100} = 80 \%, \quad \text{recall} = \frac{0}{0 + 20} = 0 \%.$$

Lectura

Acierta la clase frecuente, pero no detecta ningún bloqueo; accuracy sola no representa el objetivo.

Baselines de regresión y temporales

Problema	Baseline	Qué controla
demanda diaria de agua	mediana del entrenamiento	nivel constante robusto
tiempo de resolución	media del entrenamiento	promedio histórico
velocidad del tramo	último valor observado	persistencia temporal
demanda semanal	valor del mismo día previo	estacionalidad simple

Control

Los baselines fijos se estiman con entrenamiento. Un baseline temporal actualiza su estado en cada origen usando solo información disponible hasta ese instante.

Métrica y costo

La métrica resume errores predictivos; el costo expresa sus consecuencias.

FN	predecir libre con bloqueo: ingreso inseguro, detención y demora alta
FP	predecir bloqueado con tramo libre: desvío innecesario

- ▶ Un umbral cambia el equilibrio entre FP y FN.
- ▶ La métrica elegida debe visibilizar el error costoso.
- ▶ La decisión puede minimizar costo esperado sujeto a restricciones de seguridad.

Idea

Ninguna métrica reemplaza la declaración explícita de costos y límites operativos.

Matriz de confusión

	Real positivo: bloqueado	Real negativo: libre
Predicción positiva	VP	FP
Predicción negativa	FN	VN

- ▶ VP y VN son aciertos; FP es una falsa alarma; FN es un bloqueo omitido.
- ▶ Total $N = VP + VN + FP + FN$.
- ▶ Positivos reales $P = VP + FN$; positivos predichos $\hat{P} = VP + FP$.

Control

Definir la clase positiva antes de interpretar cualquier métrica.

Accuracy, precisión, recall y F1

$$\begin{aligned} \text{accuracy} &= \frac{VP + VN}{VP + VN + FP + FN}, & \text{precisión} &= \frac{VP}{VP + FP}, \\ \text{recall} &= \frac{VP}{VP + FN}, & F_1 &= 2 \frac{\text{precisión} \times \text{recall}}{\text{precisión} + \text{recall}} = \frac{2VP}{2VP + FP + FN}. \end{aligned}$$

- Precisión: de las alertas emitidas, qué fracción era bloqueo.
- Recall: de los bloqueos reales, qué fracción fue detectada.
- F_1 : media armónica de precisión y recall; no incorpora VN.

Denominadores

Los cocientes requieren denominador mayor que cero; si no hay positivos reales o predichos, se reporta esa condición.

MAE y RMSE

Para errores $e_i = y_i - \hat{y}_i$ en n observaciones:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |e_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}.$$

- ▶ Ambos se expresan en la unidad de y .
- ▶ MAE pondera linealmente cada magnitud de error.
- ▶ RMSE penaliza con mayor fuerza los errores grandes.

Control

Comparar ambas métricas sobre las mismas observaciones y declarar si los errores extremos tienen un costo especial.

Validación cruzada K-fold

Para unidades intercambiables, se divide el conjunto de desarrollo en K folds. Cada fold actúa una vez como validación y los $K - 1$ restantes como entrenamiento.

$$\bar{m} = \frac{1}{K} \sum_{k=1}^K m_k.$$

- ▶ Con grupos, cada entidad completa se asigna a un fold.
- ▶ Con tiempo, se usan ventanas expansivas o deslizantes: solo el pasado entrena y el futuro valida.
- ▶ La prueba permanece fuera del ciclo completo.

Resultado

La estrategia de remuestreo debe reproducir las dependencias y el orden del uso real.

Transformaciones dentro de cada fold

En cada iteración:

- 1 ajustar imputación, escalado y codificación con folds de entrenamiento;
- 2 transformar entrenamiento y validación con esos valores;
- 3 ajustar el modelo en entrenamiento transformado;
- 4 medir en validación transformada.



Control

Ajustar el preprocesamiento con todos los datos filtra información entre folds.

Selección de características


Elegir variables también aprende de los datos y forma parte del procedimiento.

- ▶ **Disponibilidad:** cada variable debe existir en t_0 .
- ▶ **Pertinencia:** representa una señal compatible con el objetivo.
- ▶ **Estabilidad:** significado y medición se sostienen en uso.
- ▶ **Selección:** cualquier ranking o descarte basado en datos se ajusta dentro de cada fold.

Resultado

Una lista fijada por disponibilidad o conocimiento del dominio puede preespecificarse; usar información de validación o prueba para elegir variables produce optimismo.

Subajuste y sobreajuste



- ▶ **Subajuste:** errores altos en entrenamiento y validación; mejorar representación o capacidad.
- ▶ **Equilibrio:** validación mínima y brecha controlada; conservar el procedimiento.
- ▶ **Sobreajuste:** error de entrenamiento bajo y validación peor; reducir búsqueda, regularizar o reunir datos relevantes.

Idea

Se elige por desempeño de validación, no por el mejor ajuste al entrenamiento.

Comparación justa y protocolo congelado

Dos alternativas se comparan con las mismas:

- ▶ unidades, folds y período de prueba;
- ▶ variables disponibles y tratamiento de faltantes;
- ▶ métrica, clase positiva y regla de agregación;
- ▶ presupuesto de búsqueda y semillas registradas.

Protocolo congelado

Código, versión de datos, particiones, transformaciones, variables, configuración, umbral y métricas quedan fijados antes de abrir la prueba.

Resultado: reproducibilidad es reconstruir el procedimiento y obtener resultados compatibles bajo las mismas condiciones.



- ▶ Aprender estima $\hat{y} = f(x)$; decidir convierte la salida en acción.
- ▶ Unidad, población, instante y horizonte definen un ejemplo; la fuga invalida generalización.
- ▶ La partición representa dependencias y uso; baselines y métricas se conectan con costos.
- ▶ Preprocesamiento y selección se ajustan dentro de cada fold.
- ▶ La prueba mide una vez un protocolo reproducible y congelado.

Resultado

Un buen experimento hace creíble la conexión entre datos históricos y decisiones futuras.