

Ingeniería de características

De datos brutos a representaciones útiles

Dato bruto

Característica

Pipeline

Modelo

El modelo solo puede aprender diferencias que su representación vuelve visibles.

Curso de Inteligencia Artificial

Semana 6 · Clase 6

La representación define qué puede aprenderse

Una **característica** o **atributo** es una magnitud utilizada como entrada de un modelo.

Dato disponible	Representación posible	Supuesto incorporado
fecha y hora	hora, día, feriado	existe un patrón de calendario
lluvia acumulada	valor, nivel o indicador	importa la magnitud o un umbral
ubicación	zona, distancia o conectividad	la cercanía relevante está bien definida

Criterios

Una característica útil tiene significado, está disponible al predecir, se calcula igual durante entrenamiento e inferencia y mantiene estabilidad operativa.

Características numéricas

Operación	Uso	Riesgo
Estandarizar	comparar escalas	aprender media y dispersión con todos los datos
Logaritmo	representar cambios relativos	aplicarlo a ceros o negativos
Razón	normalizar por exposición	denominadores pequeños o nulos
Recorte	limitar extremos	ocultar eventos reales

Si una zona registra 120 viajes con capacidad 150:

$$\text{presión} = 120/150 = 0,80.$$

Control

La razón facilita comparar zonas de tamaños distintos, pero necesita una regla para capacidad cero.

Características categóricas

- ▶ Una categoría nominal no tiene distancia ni orden intrínsecos.
- ▶ Codificar `norte`, `centro`, `sur` como 1, 2, 3 crea una geometría artificial.
- ▶ La codificación indicadora crea una columna binaria por nivel.
- ▶ Las categorías ordinales admiten orden, pero no necesariamente intervalos iguales.
- ▶ Los niveles raros y desconocidos necesitan una política explícita.

Categoría desconocida: ejemplo y cuidados

Caso

El modelo se entrenó con $\text{zona} \in \{\text{norte}, \text{centro}, \text{sur}\}$ y durante el uso aparece oeste.

Tratamiento riesgoso

Un pipeline configurado para sustituir valores no reconocidos por la categoría más frecuente podría codificar oeste como norte. Esto evita un error técnico, pero no demuestra que ambas zonas se comporten igual y oculta una posible diferencia entre entrenamiento y uso.

Cuidados necesarios

- ▶ distinguir una categoría nueva de un dato faltante;
- ▶ comprobar si proviene de un error, una fuente nueva o una ampliación de la población;
- ▶ representarla como desconocida u otra con un codificador preparado;
- ▶ registrar su frecuencia y revisar el desempeño del modelo en esos casos;
- ▶ actualizar y reevaluar el modelo si la categoría se vuelve habitual.

Tiempo y espacio

Para una posición temporal t dentro de un periodo P :

$$x_{\sin} = \sin(2\pi t/P), \quad x_{\cos} = \cos(2\pi t/P).$$

El par conserva que las 23:00 y las 00:00 son horas cercanas. Los rezagos y medias móviles deben usar únicamente valores anteriores al instante de predicción.

En espacio pueden utilizarse distancias, pertenencia a zonas, accesibilidad o conectividad. La distancia geométrica no siempre representa tiempo de viaje ni transferencia del fenómeno.

Interacciones y conocimiento del dominio

Una interacción representa que el efecto de una variable depende de otra:

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2.$$

Ejemplo: lluvia $\times$ hora pico puede representar que la lluvia afecta más la circulación cuando la red está congestionada.

- ▶ Priorizar combinaciones con una explicación operativa.
- ▶ Verificar que existan suficientes observaciones de la combinación.
- ▶ Comparar su aporte fuera de muestra.

Escala del problema

Con 100 variables existen 4950 interacciones por pares: generar todas aumenta capacidad y riesgo de sobreajuste.

Selección de atributos

Seleccionar atributos conserva un subconjunto de las variables disponibles.

Familia	Estrategia	Limitación principal
Filtro	puntuar antes del modelo final	puede ignorar interacciones
Envolvente	comparar subconjuntos con el modelo	costo y sobreajuste de la búsqueda
Embebida	seleccionar durante el ajuste	depende del modelo y la escala

Relevancia no equivale a causalidad. Dos variables correlacionadas pueden sustituirse y cambiar de posición entre muestras.

Regla

Cualquier selección basada en datos se ajusta dentro de cada fold.

Métodos de filtro

Los filtros puntúan atributos sin entrenar repetidamente el modelo final.

Criterio	Qué busca	Ejemplo
Varianza Asociación	columnas constantes o casi constantes correlación lineal, relación monótona o asociación categórica con y	retirar un sensor que siempre informa 1 ordenar velocidad por su asociación con bloqueo
Información mutua	dependencia lineal o no lineal con y	detectar señal aportada por lluvia

Ejemplo ilustrativo

Información mutua con bloqueo: velocidad = 0,31, lluvia = 0,18, hora = 0,05 e identificador = 0,01. Un selector *top-2* conservaría velocidad y lluvia.

Cuidados

El número de atributos se valida; un filtro univariado puede perder interacciones y todo filtro que usa y se ajusta dentro de cada fold.

Métodos envolventes

Evalúan subconjuntos entrenando el modelo que finalmente se utilizará.

Método	Procedimiento
Selección hacia adelante	comienza sin atributos y agrega el que más mejora validación
Eliminación hacia atrás	comienza con todos y retira el menos útil
RFE	ajusta, ordena, elimina los menos importantes y repite

Ejemplo

Con selección hacia adelante, velocidad obtiene $F_1 = 0,71$; al agregar lluvia, $F_1 = 0,78$; agregar hora mantiene $F_1 = 0,78$. Si la regla exige una mejora mínima de 0,01, se conservan dos atributos.

Cuidados

Son costosos, no garantizan el mejor subconjunto y pueden sobreajustar la validación. La búsqueda se realiza en el ciclo interno de validación.

Métodos embebidos

La selección ocurre durante el ajuste del modelo.

Método	Mecanismo	Ejemplo de selección
Lasso o L1	produce algunos coeficientes iguales a cero	descarta entradas con coeficiente cero
Elastic Net	combina L1 y L2	estabiliza grupos correlacionados
Árbol	utiliza atributos para construir divisiones	conserva variables presentes en ramas válidas

Ejemplo ilustrativo

Tras estandarizar, una regresión logística con L1 produce: velocidad = $-1,20$, lluvia = $0,70$, hora = 0 e identificador = 0 . Bajo la regla definida, conserva velocidad y lluvia.

Cuidados

Penalización y escala se ajustan dentro de cada fold. Variables correlacionadas pueden sustituirse de forma inestable y un cero no demuestra irrelevancia causal.

Reducción dimensional y PCA

La selección conserva columnas originales; la reducción construye nuevas coordenadas $Z = g(X)$ con $q < p$. En PCA, los componentes son direcciones ortogonales ordenadas por varianza. Si los autovalores son $(4,2; 2,1; 0,7)$:

$$\text{PVE}_1 = 4,2/7 = 60 \%, \quad \text{PVE}_{1:2} = 6,3/7 = 90 \%.$$

Límite

Conservar 90 % de la varianza no garantiza conservar 90 % de la capacidad predictiva. Una señal rara puede encontrarse en una dirección de baja varianza.

El pipeline completo es la unidad evaluada



En cada partición:

- 1 ajustar transformaciones únicamente con entrenamiento;
- 2 aplicar esos parámetros a validación;
- 3 ajustar el modelo con la representación transformada;
- 4 medir sobre los casos reservados.

Inferencia

Se reutilizan medias, categorías, columnas seleccionadas y componentes aprendidos; no se vuelven a ajustar.

Caso integrado: anticipar un bloqueo

Un vehículo debe estimar, antes de ingresar, si un tramo quedará bloqueado en los próximos 15 minutos.

Datos brutos	Características candidatas	Control necesario
fecha y hora lluvia reciente velocidades previas tramo y red	seno/coseno de hora; día hábil acumulado causal; indicador intenso media y tendencia anteriores tipo de vía; centralidad; desvío	calendario disponible corte en el instante de decisión excluir mediciones futuras política para tramos nuevos

Actividad

Proponer una interacción útil, una variable que causaría fuga y una prueba para detectar una diferencia entre entrenamiento e inferencia.