Modelos supervisados fundamentales

De funciones aprendidas a decisiones



Curso de Inteligencia Artificial

Semana 7 · Clase 7

Propósito de la clase

Comprender qué aprende un modelo supervisado y cómo su salida puede informar la acción de un agente.

Al finalizar, podremos

- formular regresión y clasificación;
- explicar el ajuste lineal y la probabilidad logística;
- distinguir probabilidad, clase y acción;
- explicar cómo aprende un árbol;
- comparar modelos lineales, árboles y ensambles.

Punto de partida

Ya estudiamos un agente que decide con una creencia conocida:

$$\textbf{evidencia} \rightarrow \textbf{probabilidad} \rightarrow \textbf{costo esperado} \rightarrow \textbf{acción}$$

Ahora la probabilidad o el valor esperado se estima desde ejemplos:

$$(x_i, y_i) \rightarrow \textbf{modelo ajustado} \rightarrow \textbf{predicción nueva}$$

Pregunta clave

¿Qué relación aprende cada familia de modelos?

Caso conductor: movilidad

Treinta minutos antes de una salida, un agente debe anticipar el estado de un trayecto.

Elemento	Ejemplo
Entradas x	duración planificada, congestión, lluvia y franja horaria
Objetivo continuo	minutos de demora
Objetivo binario	demora mayor que 10 minutos: sí/no
Acción posterior	mantener, reasignar o solicitar revisión

Idea

El mismo dominio admite modelos distintos según la salida necesaria.

Aprendizaje supervisado

Disponemos de ejemplos con entrada y respuesta observada:

$$\mathcal{D} = \{(x_1, y_1), \ldots, (x_n, y_n)\}.$$

El algoritmo selecciona una función dentro de una familia:

$$\widehat{f} = \arg\min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(x_i)).$$

- $\mathcal{F}$: funciones que el modelo puede representar.
- L: penalización por una predicción incorrecta.
- Aprender significa ajustar una función, no almacenar respuestas.

Tarea, modelo y decisión

Nivel	Pregunta
Tarea	¿Qué salida necesitamos estimar?
Modelo	¿Qué familia de funciones utilizaremos?
Ajuste	¿Qué criterio determina sus parámetros?
Decisión	¿Cómo convertimos la salida en una acción?

Distinción central

Un modelo predice; la regla de decisión incorpora costos, capacidad y restricciones.

Regresión o clasificación

Tarea	y	Salida	Movilidad
Regresión	real	$\widehat{y}$	demora: 14,2 min
Clasificación binaria	0 o 1	$\widehat{p} = P(Y = 1 \mid x)$	probabilidad de demora crítica

Control

El puntaje probabilístico contiene más información que una clase rígida obtenida con un umbral.

Regresión lineal: hipótesis

La media del objetivo se aproxima mediante una función afín:

$$\widehat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

- β_0: valor de referencia.
- β_j: cambio asociado con una unidad de x_j, manteniendo las demás entradas fijas.
- "Lineal" se refiere a los parámetros; pueden incluirse transformaciones e interacciones.

Ejemplo de una recta

Horas de operación: $x = (2, 4, 6, 8, 10)$.
Consumo en MWh: $y = (18, 25, 29, 36, 42)$.

$$\widehat{y} = 12{,}3 + 2{,}95x.$$

Para siete horas:

$$\widehat{y} = 12{,}3 + 2{,}95(7) = 32{,}95 \text{ MWh}.$$

Lectura

La recta resume una tendencia dentro del rango observado.

¿Qué significa ajustar la recta?

El residuo del caso i es $e_i = y_i - \widehat{y}_i$.
Mínimos cuadrados elige los parámetros que minimizan:

$$S(\beta) = \sum_{i=1}^{n} (y_i - \widehat{y}_i)^2.$$

- Los errores grandes pesan más porque se elevan al cuadrado.
- La pérdida define qué ajuste considera preferible el modelo.
- Ajustar no garantiza desempeño fuera de los ejemplos usados.

La solución en regresión simple

$$\widehat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \qquad \widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}.$$

La pendiente es covarianza dividida por varianza de x.

Lectura del ejemplo

2,95 MWh adicionales por cada hora de operación dentro del rango estudiado.

Interpretar sin exagerar

Un coeficiente describe una asociación condicionada al modelo. No demuestra por sí solo que:

- modificar x_j causará el cambio predicho;
- la relación continuará fuera del rango observado;
- las entradas omitidas son irrelevantes;
- el mismo coeficiente vale en otra población o período.

Límite

Asociación predictiva no equivale a efecto causal.

Residuos: qué no explicó el modelo

Revisar residuos permite detectar límites de la forma elegida:

- curvatura: falta una relación no lineal;
- dispersión creciente: cambia la variabilidad;
- grupos separados: falta una diferencia relevante;
- observaciones extremas: pueden dominar el ajuste;
- patrón temporal: los errores no son independientes.

Idea

Un error sistemático no se corrige agregando decimales.

Regresión lineal en movilidad

$$\widehat{\text{demora}} = -4 + 0{,}18\,\text{duración} + 6{,}2\,\text{congestión} + 3{,}1\,\text{lluvia}.$$

Para duración 40 min, congestión 0,7 y lluvia 1:

$$\widehat{\text{demora}} = -4 + 0{,}18(40) + 6{,}2(0{,}7) + 3{,}1 = 10{,}64.$$

Término	Lectura condicionada
0,18 **duración**	0,18 minutos por minuto planificado
6,2 **congestión**	diferencia asociada con la escala de congestión
3,1 **lluvia**	diferencia lluvia frente a no lluvia

¿Por qué no usar una recta para probabilidades?

Si $Y \in \{0, 1\}$, una recta puede producir valores menores que 0 o mayores que 1.

Necesitamos

1. un puntaje que combine las entradas;
2. una transformación que lo lleve al intervalo $[0, 1]$.

La regresión logística utiliza un puntaje lineal y una función sigmoide.

Regresión logística

Primero calcula un puntaje:

$$\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

Luego lo transforma:

$$\widehat{p} = \sigma(\eta) = \frac{1}{1 + e^{-\eta}}.$$

- η puede tomar cualquier valor real.
- $\widehat{p}$ siempre pertenece a $(0, 1)$.
- $\sigma(0) = 0{,}5$ y $\sigma(-\eta) = 1 - \sigma(\eta)$.

Puntaje, probabilidad, clase y acción

Objeto	Ejemplo	Función
Puntaje η	0,8	evidencia combinada
Probabilidad $\widehat{p}$	0,69	riesgo estimado
Clase	crítica	salida de un umbral
Acción	reasignar	decisión con costos y restricciones

Control

Confundir estos objetos oculta dónde se produce el error.

Ejemplo numérico de la sigmoide

Supongamos $\eta = -3 + 0{,}8x$. Para $x = 4$:

$$\eta = 0{,}2, \qquad \widehat{p} = \frac{1}{1 + e^{-0{,}2}} \approx 0{,}55.$$

Para $x = 5$:

$$\eta = 1, \qquad \widehat{p} \approx 0{,}731.$$

Resultado

El incremento de probabilidad no es constante: depende del punto de partida.

Odds y coeficientes

La regresión logística es lineal en los log-odds:

$$\log \frac{p}{1-p} = \beta_0 + \sum_j \beta_j x_j .$$

Si x_j aumenta una unidad, los odds se multiplican por e^{β_j}, manteniendo las demás entradas fijas.

Ejemplo

Si $\beta_j = 0{,}40$, $e^{0{,}40} \approx 1{,}49$: los odds aumentan 49 %, no la probabilidad en 49 puntos.

¿Cómo se ajusta la logística?

Para cada caso, $Y_i \sim \text{Bernoulli}(p_i)$.
El ajuste minimiza la log-loss:

$$-\ell(\beta) = -\sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

- Una probabilidad alta asignada a la clase equivocada recibe una penalización grande.
- El ajuste es iterativo: no existe la fórmula cerrada de mínimos cuadrados.
- La regularización puede limitar coeficientes inestables.

Probabilidad no significa certeza

Una salida $\widehat{p} = 0{,}8$ significa 80 % de probabilidad bajo los datos y supuestos del modelo. No significa que:

- el evento ocurrirá;
- el modelo acierta 80 % en cualquier población;
- la probabilidad está bien calibrada;
- deba ejecutarse automáticamente una acción.

Control

La calidad probabilística se comprueba con casos no usados para ajustar.

De probabilidad a acción

Decidir si actuar tiene dos errores posibles:

- actuar y que el evento no ocurra (falso positivo): costo C_{FP};
- no actuar y que el evento ocurra (falso negativo): costo C_{FN}.

Se actúa cuando actuar es más barato que no actuar en valor esperado:

$$(1-\widehat{p})\,C_{FP} < \widehat{p}\,C_{FN} \qquad \Longleftrightarrow \qquad \widehat{p} > \frac{C_{FP}}{C_{FP}+C_{FN}}.$$

Con $C_{FP}=8$ y $C_{FN}=40$: $t=\frac{8}{48}\approx 0{,}167$.

Lectura

Si un falso negativo cuesta más que un falso positivo ($40>8$), conviene actuar incluso con probabilidades bajas: el umbral desciende por debajo de 0,5.

Conclusión

El umbral 0,5 no es universal: depende de consecuencias, capacidad y restricciones.

Caso conductor: probabilidad de demora

$$\eta = -3 + 0{,}04\,\text{duración} + 2{,}2\,\text{congestión} + 0{,}8\,\text{lluvia}.$$

Para duración 40, congestión 0,7 y lluvia 1:

$$\eta = -3 + 1{,}6 + 1{,}54 + 0{,}8 = 0{,}94,$$

$$\widehat{p} = \sigma(0{,}94) \approx 0{,}719.$$

Paso posterior

La regla de decisión determina si ese riesgo justifica intervenir.

Límite compartido de los modelos lineales

Regresión lineal y logística combinan entradas mediante una suma ponderada.

Fortalezas

- interpretación;
- cálculo eficiente;
- estabilidad con pocos datos.

Límite

- frontera lineal;
- curvaturas explícitas;
- interacciones explícitas.

Árbol de decisión

Un árbol aprende una secuencia de preguntas:

```
¿congestión > 0,65?
|-- sí: ¿llueve?
|   |-- sí  -> riesgo alto
|   `-- no  -> riesgo medio
`-- no      -> riesgo bajo
```

Cada hoja contiene una predicción basada en los ejemplos que llegan a ella.

¿Cómo elige una división?

El árbol prueba atributos y umbrales y mide la impureza de cada nodo con el índice de Gini:

$$G = 1 - p^2 - (1 - p)^2 = 2p(1 - p),$$

donde p es la proporción de una de las clases en el nodo.

- $G = 0$: nodo puro (una sola clase).
- $G = 0{,}5$: clases equilibradas (máxima mezcla).

Se elige la división que más reduce la impureza, comparando la del padre con la suma ponderada de la de las hijas.

Lectura

G es la probabilidad de que dos ejemplos tomados al azar del nodo tengan etiquetas distintas. Un padre 50/50 ($G = 0{,}5$) dividido en hijas 80/20 y 20/80 ($G = 0{,}32$) deja la impureza ponderada en 0,32, menor que la del padre.

Capacidad e inestabilidad del árbol

Un árbol profundo puede:

- representar relaciones no lineales e interacciones;
- aislar pocos ejemplos y memorizar ruido;
- cambiar ante pequeñas variaciones de los datos;
- producir probabilidades extremas en hojas pequeñas.

Control

Profundidad, tamaño mínimo de hoja y poda regulan la complejidad.

Por qué combinar árboles

Los ensambles aprovechan que modelos distintos cometen errores diferentes.

Método	Mecanismo	Efecto
Bagging	árboles sobre remuestras	reducir varianza
Random Forest	remuestras y atributos aleatorios	aumentar diversidad
Boosting	correcciones secuenciales	reducir error progresivamente

Límite

Más modelos no reparan etiquetas incorrectas, información indebida o cambios de población.

Random Forest

Un bosque aleatorio:

1. obtiene varias remuestras de los ejemplos;
2. crece un árbol en cada remuestra;
3. considera solo algunos atributos en cada división;
4. promedia probabilidades o predicciones.

Intuición

El promedio estabiliza; la aleatoriedad evita que todos los árboles repitan las mismas primeras divisiones.

Boosting

Boosting construye un modelo aditivo:

$$F_M(x) = F_0(x) + \sum_{m=1}^{M} \nu h_m(x).$$

Cada árbol nuevo intenta corregir parte del error actual.

- ν: tasa de aprendizaje.
- Árboles pequeños: correcciones acotadas.
- Muchas iteraciones: mayor capacidad y necesidad de control.

Diferencia

No es votación independiente: el aprendizaje es secuencial.

Comparación de familias

Aspecto	Lineal / logística	Árbol	Ensamble
Relación	suma ponderada	reglas por regiones	combinación de regiones
Interacciones	explícitas	automáticas	automáticas
Interpretación	coeficientes	reglas si es pequeño	más difícil
Extrapolación	posible, con riesgo	pobre	pobre
Estabilidad	generalmente alta	baja	mayor que un árbol

Resultado

Ninguna familia domina en todos los problemas.

Cómo elegir un punto de partida

- Salida numérica y relación aproximadamente suave: **regresión lineal**.
- Probabilidad binaria interpretable: **regresión logística**.
- Reglas no lineales e interacciones: **árbol controlado**.
- Datos tabulares con prioridad predictiva: **Random Forest o boosting**.

Comparación justa

Mantener la misma tarea, información disponible y criterio de uso.

Lecturas

Lectura principal

- Capítulo 11, 11.1.1–11.1.5: regresión lineal.
- Capítulo 11, 11.4.1–11.4.5: regresión logística.
- Capítulo 12, 12.1.1–12.1.5: árboles.

Para ampliar

Capítulo 12, 12.3.1–12.3.5: ensambles, Random Forest y boosting.