Aprendizaje no supervisado

De la semejanza a segmentos e hipótesis

Representación | **Semejanza** | Estructura | Interpretación

Curso de Inteligencia Artificial

Semana 8 · Clase 8

Propósito de la clase

Comprender cómo los métodos no supervisados organizan observaciones sin una etiqueta objetivo y cómo evaluar si esa organización es útil.

Al finalizar, podremos

- formular una pregunta no supervisada;
- justificar una distancia y una representación;
- explicar K-means, jerárquico, DBSCAN y SOM;
- usar PCA para resumir y visualizar datos;
- interpretar segmentos sin convertirlos en categorías esenciales.

Punto de partida

En aprendizaje supervisado disponíamos de pares con respuesta observada:

$$(x_i, y_i) \rightarrow \textbf{modelo ajustado} \rightarrow \textbf{predicción}$$

Ahora solo observamos perfiles:

$$x_1, \ldots, x_n \rightarrow \textbf{representación} \rightarrow \textbf{estructura candidata}$$

Pregunta clave

¿Qué significa que dos observaciones sean semejantes para nuestro problema?

Caso conductor: movilidad

Una ciudad quiere resumir perfiles de zonas para planificar observación y servicio.

Elemento	Ejemplo
Unidad	zona de movilidad durante una semana
Formación	proporciones por franja, duración típica, variabilidad y congestión
Sin etiqueta	no existe un tipo verdadero de zona
Uso posterior	describir perfiles, revisar cobertura, proponer acciones exploratorias

Idea

Un grupo resume una estructura bajo decisiones explícitas; no descubre una categoría natural.

¿Qué cambia sin etiquetas?

	Supervisado	No supervisado
Información	objetivo y observado	sin respuesta correcta conocida
Calidad	error frente a y	cohesión, separación, estabilidad y utilidad
Resultado	predicción para casos nuevos	segmentos, prototipos o vecindades
Revisión	validación con etiquetas	evidencia interna, externa y contextual

Consecuencia

Muchas particiones pueden ser válidas matemáticamente. Ninguna métrica única decide cuál sirve mejor.

Cuatro objetivos posibles

- **Descubrimiento de grupos**: semejanza interna y diferencia entre segmentos.
- **Representación**: resumir con prototipos, componentes o mapas.
- **Estructura local**: identificar vecindades, regiones densas y puntos aislados.
- **Generación de hipótesis**: proponer preguntas para contrastar después.

Control

Elegir un algoritmo sin declarar el objetivo confunde una figura atractiva con un resultado útil.

Formular antes de agrupar

Antes del ajuste debemos responder:

1. ¿Cuál es la unidad de análisis?
2. ¿Qué periodo y población cubren los datos?
3. ¿Qué diferencias importan para el dominio?
4. ¿Se admite ruido sin asignar a un grupo?
5. ¿Cómo se usará y revisará el resultado?

Idea

La distancia es una hipótesis de dominio expresada matemáticamente.

Distancia euclídea

Para perfiles numéricos x y z:

$$d_2(\mathrm{x},\mathrm{z}) = \sqrt{\sum_{j=1}^{p}(x_j - z_j)^2}.$$

Para $A = (2,3)$ y $B = (5,7)$:

$$d_2(A,B) = \sqrt{3^2 + 4^2} = 5.$$

- Las diferencias grandes pesan más al elevarse al cuadrado.
- Es coherente con K-means y centroides definidos por medias.
- Supone variables cuantitativas y escalas comparables.

Distancia Manhattan

La distancia Manhattan suma diferencias absolutas:

$$d_1(\mathrm{x}, \mathrm{z}) = \sum_{j=1}^{p} |x_j - z_j|.$$

Para los mismos perfiles:

$$d_1(A, B) = |2 - 5| + |3 - 7| = 7.$$

Lectura

No elimina la necesidad de escalar variables, pero reduce el peso relativo de diferencias extremas frente a d_2.

La métrica puede cambiar el vecino

Para $O = (0, 0)$, $P = (3, 0)$ y $Q = (2, 2)$:

Métrica	$d(O, P)$	$d(O, Q)$	Vecino más cercano
Euclídea	3	$\sqrt{8} \approx 2{,}83$	Q
Manhattan	3	4	P

Conclusión

No hay una métrica universalmente correcta: cada una expresa una noción distinta de diferencia.

Similitud coseno: forma y nivel

La similitud coseno compara orientación:

$$s_{\cos}(x, z) = \frac{x^{\top} z}{\|x\|_2 \|z\|_2}.$$

Los perfiles $A = (2, 4, 2)$ y $B = (20, 40, 20)$ tienen coseno 1: misma composición relativa, distinta magnitud.

Decisión

Usar proporciones para la forma y conservar el volumen como una variable adicional si importa operacionalmente.

Escalar también es decidir

Una duración entre 0 y 120 puede dominar a una proporción entre 0 y 1. Dos opciones frecuentes:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \qquad r_{ij} = \frac{x_{ij} - \text{mediana}(X_j)}{Q_{0.75}(X_j) - Q_{0.25}(X_j)}.$$

- z: centra y asigna varianza unitaria.
- r: alternativa robusta basada en mediana y rango intercuartílico.
- Los logaritmos pueden comprimir colas derechas.

Ponderar bloques de variables

Una distancia ponderada explicita prioridades:

$$d_w(\mathrm{x}, \mathrm{z}) = \sqrt{\sum_{j=1}^{p} w_j (x_j - z_j)^2}, \qquad w_j \geq 0.$$

En movilidad, doce proporciones horarias pueden dominar por cantidad de columnas a dos variables de diversidad, incluso estandarizadas.

Criterio

Ponderar por confiabilidad, relevancia operativa o equilibrio entre bloques; no para producir grupos más vistosos.

Datos mixtos y variables reservadas

- K-means requiere variables numéricas y una media interpretable.
- Las categorías necesitan una codificación y una disimilitud coherentes.
- Las variables de **formación** determinan los grupos.
- Las variables de **caracterización** se reservan para comprenderlos después.

Control

Separar ambos conjuntos evita introducir previamente la conclusión que se busca describir.

K-means: idea y objetivo

K-means divide observaciones numéricas en K grupos $C_1, \dots, C_K$ minimizando:

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \boldsymbol{\mu}_k\|_2^2, \qquad \boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

Lectura

El centroide es un perfil promedio; no tiene por qué coincidir con una zona real.

K-means: dos pasos alternados

1. Inicializar K centroides.
2. Asignar cada observación al centroide más cercano.
3. Recalcular cada centroide como media de su grupo.
4. Repetir hasta que no cambien asignaciones o la mejora sea pequeña.

- Cada paso no aumenta J.
- Converge a una solución local, no garantiza el óptimo global.
- Un grupo vacío requiere una regla documentada.

Qué estructura busca K-means

Funciona mejor con grupos:

Adecuados

- compactos;
- aproximadamente esféricos;
- de dispersión y tamaño semejantes.

Problemáticos

- alargados;
- densidades muy distintas;
- observaciones que deberían quedar sin grupo.

Límite

Su eficiencia no corrige una geometría inadecuada.

Inicialización, reinicios y estabilidad

- Distintas semillas pueden producir soluciones diferentes.
- K-means++ favorece centros iniciales separados.
- Varios reinicios reducen el riesgo de una mala solución local.
- Comparar solo la menor inercia puede ocultar asignaciones muy distintas.

Control

Además de cambiar semillas, repetir con submuestras, periodos y transformaciones plausibles.

Elegir el número de grupos

La inercia disminuye siempre al aumentar K. El codo busca rendimientos decrecientes, pero puede no ser claro.

1. Definir un rango de K útil para el problema.
2. Ejecutar varios reinicios por cada K.
3. Comparar inercia, silhouette, Davies–Bouldin y tamaños.
4. Revisar estabilidad y perfiles.
5. Elegir la solución más simple que sea estable y accionable.

Clustering jerárquico

Construye relaciones anidadas entre observaciones.

Estrategia	Inicio	Operación
Aglomerativa	una observación por grupo	fusiona los grupos más próximos
Divisiva	todas las observaciones juntas	divide grupos sucesivamente

Resultado

El dendrograma permite examinar varios niveles de granularidad sin fijar K al inicio.

Reglas de enlace

La distancia entre grupos A y B depende de la regla elegida:

$$D_{\text{simple}}(A,B) = \min_{i\in A,\, l\in B} d(i,l), \qquad D_{\text{completo}}(A,B) = \max_{i\in A,\, l\in B} d(i,l).$$

$$D_{\text{promedio}}(A,B) = \frac{1}{|A||B|} \sum_{i\in A} \sum_{l\in B} d(i,l).$$

- Simple: descubre cadenas, pero puede unir regiones por puntos puente.
- Completo: favorece grupos compactos; es sensible a extremos.
- Promedio: usa toda la información entre pares.
- Ward: minimiza aumento de dispersión y requiere geometría euclídea coherente.

Leer un dendrograma

- Cada hoja es una observación o grupo inicial.
- La altura de unión indica la disimilitud de enlace.
- Un corte horizontal induce una partición.

Tres errores frecuentes

Leer la posición horizontal como distancia; elegir un corte solo por cantidad deseada; tratar ramas como categorías reales sin perfiles ni estabilidad.

Idea

El dendrograma explora granularidades; no cuenta grupos automáticamente.

Densidad y vecindades

Una vecindad de radio ε alrededor de x es:

$$N_\varepsilon(x) = \{z : d(x, z) \leq \varepsilon\}.$$

El tamaño $|N_\varepsilon(x)|$ aproxima densidad local.

- Los métodos por densidad encuentran regiones conectadas y densas.
- Pueden describir formas no convexas.
- Pueden dejar casos sin grupo.

DBSCAN: núcleo, frontera y ruido

DBSCAN usa radio ε y `minPts`:

Tipo	Condición
Núcleo	su vecindad contiene al menos `minPts` casos
Frontera	no es núcleo, pero está cerca de uno
Ruido	no cumple ninguna de las condiciones anteriores

Mecanismo

Expande grupos mediante cadenas de puntos núcleo conectados por densidad.

DBSCAN frente a K-means

	K-means	DBSCAN
Parámetros	K	ε y `minPts`
Asignación	todos los casos	puede dejar ruido
Geometría	grupos convexos	formas arbitrarias
Resumen	centroide promedio	regiones densas conectadas

Precaución

Ruido es aislamiento geométrico bajo una configuración; no equivale a error, fraude ni evento irrelevante.

Sensibilidad de DBSCAN

- `minPts` pequeño acepta cadenas frágiles; uno grande convierte más casos en ruido.
- La distancia al vecino k puede sugerir un rango para ε, no decidirlo por sí sola.
- El escalado cambia el significado efectivo de ε.

Control

Explorar una rejilla de parámetros y buscar mesetas donde cantidad, tamaño y composición de grupos cambien poco.

Mapas autoorganizados (SOM)

Un SOM es una rejilla de prototipos. Cada nodo m tiene pesos w_m. Para una observación x, la unidad de mejor coincidencia es:

$$c = \arg\min_m \|\mathrm{x} - \mathrm{w}_m\|_2.$$

Durante el ajuste se acercan a x la unidad ganadora y sus vecinas de rejilla:

$$\mathrm{w}_m(t+1) = \mathrm{w}_m(t) + \alpha(t) h_{cm}(t)[\mathrm{x}(t) - \mathrm{w}_m(t)].$$

Qué muestra un SOM

- **Mapa de componentes**: valor de una variable en cada prototipo.
- **Matriz U**: distancia entre prototipos vecinos; sugiere fronteras o continuidad.
- **Mapa de conteos**: cantidad de observaciones por nodo.

Límite

Un SOM preserva vecindades de forma aproximada; no produce grupos automáticamente. Agrupar prototipos es una etapa adicional.

Reducir dimensión: por qué

Con muchas variables, las distancias tienden a parecerse y las vecindades pierden contraste.

$$Z = g(X), \qquad q < p.$$

- Puede comprimir, disminuir ruido o facilitar visualización.
- Puede ocultar señales raras o distorsionar proximidades.
- No debe justificarse solo porque produce una figura más clara.

Control

No agrupar solo una proyección 2D sin revisar la estructura en el espacio de formación.

PCA: componentes principales

PCA construye nuevas coordenadas lineales que resumen variación de X.

1. Centrar las variables.
2. Decidir si estandarizar según las unidades.
3. Buscar direcciones ortogonales de máxima varianza.
4. Proyectar cada observación en esas direcciones.

Lectura

La primera componente explica la mayor varianza disponible; las siguientes explican varianza restante y son ortogonales a las anteriores.

Varianza explicada e interpretación

Si λ_j es la varianza de la componente j:

$$\text{varianza explicada}_j = \frac{\lambda_j}{\sum_r \lambda_r}.$$

- Una componente combina variables originales mediante cargas.
- Alta varianza no implica utilidad para todas las decisiones.
- PCA optimiza reconstrucción lineal, no clasificación, causalidad ni calidad de grupos.

Resultado

Elegir q combina pérdida aceptable, estabilidad e interpretación.

Inercia: compactación de K-means

La inercia es la función objetivo:

$$W_K = \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \boldsymbol{\mu}_k\|_2^2.$$

- Menor valor: menor dispersión bajo esa representación.
- Solo compara soluciones sobre los mismos datos y preprocesamiento.
- Siempre disminuye al crecer K; no basta para elegirlo.

Silhouette: cohesión y separación

Para i, $a(i)$ es distancia media a su grupo y $b(i)$ la menor distancia media a otro grupo:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

Valor	Lectura
cercano a 1	buena cohesión y separación
cercano a 0	punto de frontera
negativo	más cercano, en promedio, a otro grupo

Control

Revisar la distribución por grupo, no solo su promedio.

Davies–Bouldin: grupos rivales

Compara dispersión interna y distancia entre centroides:

$$DB = \frac{1}{K}\sum_{k=1}^{K} \max_{l \neq k} \frac{S_k + S_l}{M_{kl}}.$$

Valores menores indican grupos compactos respecto de su rival más cercano.

Límite

Supone grupos descritos por centroides; puede valorar mal formas arbitrarias y resultados de DBSCAN.

Caracterizar sin esencializar

Una ficha de segmento debe indicar:

- tamaño, perfiles centrales y dispersión;
- variables que lo distinguen y casos fronterizos;
- estabilidad ante muestras, periodos y decisiones de representación;
- qué casos no representa;
- para qué pregunta o acción exploratoria podría servir.

Lenguaje

Usar nombres descriptivos, como “actividad nocturna alta y variabilidad baja”, en lugar de etiquetas valorativas.

Anomalías y sobreinterpretación

Una observación atípica puede ser global, contextual o colectiva. Primero se revisan integridad, cobertura, unidades y periodo.

No debemos concluir que

- un cluster es una clase natural;
- una separación visual prueba causalidad;
- ruido de DBSCAN es error;
- una métrica alta vuelve estable o útil la segmentación.

Control

Triangular métricas internas, estabilidad, evidencia externa y utilidad contextual.

Del segmento a la decisión

En movilidad, los segmentos pueden guiar preguntas como:

Hallazgo descriptivo	Pregunta posterior
patrón nocturno concentrado	¿la cobertura de observación es suficiente?
zona frontera entre segmentos	¿cambia por periodo o por medición?
perfil aislado	¿es un evento raro, una falla o una zona subobservada?

Idea

El grupo informa una investigación o una regla revisable; no reemplaza el juicio ni demuestra por qué ocurre el patrón.

Síntesis

- El aprendizaje no supervisado organiza perfiles sin una respuesta conocida.
- Representación, distancia y escalado definen qué estructura puede aparecer.
- K-means, jerárquico, DBSCAN y SOM responden a geometrías diferentes.
- PCA resume variación, pero no certifica utilidad ni conserva toda la estructura.
- La evaluación combina compactación, separación, estabilidad, evidencia externa y propósito.
- Un segmento es una descripción condicionada por método y datos, no una identidad fija.

Lecturas

Lectura principal

- Capítulo 13, §§13.1–13.4: distancias, clustering, DBSCAN, SOM y evaluación.

Para ampliar

- Capítulo 10, §10.3: reducción de dimensionalidad, PCA y visualización.

Actividad sugerida

- Capítulo 13, actividad EMO [MOV-03]: segmentar zonas por patrón de movilidad.