

Ciencia de Datos e Inteligencia Artificial

Índice general

Índice del libro	1
Parte I. Fundamentos y trabajo con datos	1
Parte II. Probabilidad, agentes y resolución de problemas	1
Parte III. Fundamentos del aprendizaje automático	1
Parte IV. Aprendizaje profundo y datos no estructurados	1
Apéndices	1
Capítulo 1. Ciencia de Datos e Inteligencia Artificial: conceptos, historia y aplicaciones	2
Propósito	2
1.1. Ciencia de Datos, Inteligencia Artificial y aprendizaje automático	2
1.2. Enfoques y fundamentos de la Inteligencia Artificial	9
1.3. Evolución histórica de la Ciencia de Datos y la IA	12
1.4. Aplicaciones, alcances y riesgos	15
Síntesis	17
Glosario esencial	18
Preguntas de autoevaluación	18
Actividad de reflexión	18
Capítulo 2. Ciclo de vida de un proyecto basado en datos	19
Propósito y objetivos de aprendizaje	19
2.1. Formulación del problema	19
2.2. Metodologías para proyectos de datos	31
2.3. Fuentes, tipos y arquitectura básica de datos	41
2.4. Entornos, herramientas y reproducibilidad	50
Síntesis del capítulo	57
Glosario esencial	58
Preguntas de autoevaluación	58
Actividad integradora de cierre	59
Capítulo 3. Preparación, calidad y transformación de datos	60
Propósito y objetivos de aprendizaje	60
3.1. Comprensión y evaluación de la calidad de los datos	60
3.2. Limpieza de datos	68
3.3. Integración y transformación	77
3.4. Pipelines y prevención de fugas de información	84
Síntesis del capítulo	89
Glosario esencial	90
Preguntas de autoevaluación	90
Actividad integradora de cierre	90

Capítulo 4. Estadística descriptiva, exploración y visualización	92
Propósito y objetivos de aprendizaje	92
4.1. Descripción de una variable	92
4.2. Relaciones entre variables	103
4.3. Visualización exploratoria	112
4.4. Comunicación de resultados	121
Síntesis del capítulo	127
Glosario esencial	127
Preguntas de autoevaluación	127
Actividad integradora de cierre	128
Capítulo 5. Probabilidad, incertidumbre e inferencia bayesiana	129
Propósito y objetivos de aprendizaje	129
5.1. Fundamentos de probabilidad	130
5.2. Variables aleatorias y distribuciones	136
5.3. Teorema de Bayes e inferencia probabilística	144
5.4. Incertidumbre y comunicación probabilística	153
Síntesis del capítulo	160
Glosario esencial	161
Preguntas de autoevaluación	161
Actividad integradora de cierre	161
Capítulo 6. Agentes inteligentes y representación de problemas	163
Propósito y objetivos de aprendizaje	163
6.1. Agentes y racionalidad	164
6.2. Entornos de tarea	170
6.3. Arquitecturas de agentes	176
6.4. Representación computacional de problemas	181
Síntesis integradora	187
Errores comunes y criterios de revisión	188
Glosario	189
Preguntas de autoevaluación	189
Actividad integradora de cierre	190
Capítulo 7. Búsqueda y resolución algorítmica de problemas	192
7.1. Espacios de estados y procesos de búsqueda	193
7.2. Búsqueda no informada	198
7.3. Búsqueda informada y heurísticas	202
7.4. Búsqueda local y problemas con restricciones	209
Errores comunes y límites del capítulo	214
Síntesis	215
Glosario	215
Preguntas de revisión y discusión	216
Actividad integradora del capítulo	217
Capítulo 8. Decisiones secuenciales y aprendizaje por refuerzo	219
8.1. Decisiones bajo incertidumbre	220
8.2. Procesos de decisión de Markov	226
8.3. Resolución de procesos de decisión	232
8.4. Aprendizaje por refuerzo	237
Síntesis del capítulo	244
Errores de razonamiento que deben evitarse	245

Glosario esencial	245
Autoevaluación	246
Actividad integradora de cierre	247
Capítulo 9. Formulación y evaluación de problemas de aprendizaje automático	249
9.1. Paradigmas de aprendizaje	249
9.2. Ajuste, error y generalización	254
9.3. Diseño de la evaluación	258
9.4. Métricas de desempeño	262
Síntesis del capítulo	271
Glosario esencial	271
Preguntas de autoevaluación	272
Actividad integradora de cierre	272
Capítulo 10. Ingeniería, selección y reducción de atributos	274
10.1. Ingeniería de características	274
10.2. Selección de atributos	285
10.3. Reducción de dimensionalidad	293
10.4. Pipelines de representación y modelado	299
Errores frecuentes y cómo evitarlos	305
Glosario	306
Preguntas de revisión	307
Actividad integradora: representación auditable para demanda urbana . .	307
Síntesis	308
Capítulo 11. Regresión y clasificación: modelos fundamentales	309
11.1. Regresión lineal	309
11.2. Supuestos y diagnóstico del modelo lineal	317
11.3. Modelos lineales regularizados	323
11.4. Regresión logística y clasificación	328
Síntesis	335
Glosario	335
Preguntas de revisión	336
Actividad integradora	337
Capítulo 12. Métodos supervisados avanzados y ensambles	339
12.1. Árboles de decisión	339
12.2. Máquinas de soporte vectorial	346
12.3. Métodos de ensamble	351
12.4. Explicabilidad y aprendizaje distribuido	357
Síntesis	363
Glosario	364
Preguntas de revisión y discusión	364
Actividad integradora	365
Capítulo 13. Aprendizaje no supervisado y descubrimiento de estructura	367
13.1. Distancias, similitudes y representación	367
13.2. Agrupamiento particional y jerárquico	373
13.3. Métodos basados en densidad y representaciones neuronales	379
13.4. Evaluación, interpretación y anomalías	386
Síntesis	392

Glosario	393
Preguntas de revisión	394
Actividad integradora del capítulo	394
Capítulo 14. Análisis y pronóstico de series temporales	396
14.1. Estructura de las series temporales	397
14.2. Dependencia temporal y estacionariedad	402
14.3. Modelos ARIMA	407
14.4. Evaluación de pronósticos	412
Glosario	419
Preguntas de revisión y discusión	420
Actividad integradora de razonamiento	420
Síntesis	421
Capítulo 15. Redes neuronales, aprendizaje profundo y visión artificial	422
15.1. Fundamentos de redes neuronales	422
15.2. Entrenamiento de redes profundas	428
15.3. Imágenes digitales y redes convolucionales	435
15.4. Transferencia, evaluación y tareas avanzadas de visión	439
Diseño experimental, incertidumbre y documentación	445
Diagnóstico sistemático de fallos	447
Riesgos, ética y uso responsable	448
Síntesis	448
Glosario esencial	448
Preguntas de revisión y discusión	449
Actividad integradora de cierre	450
Capítulo 16. Procesamiento del lenguaje natural y grandes modelos de lenguaje	451
16.1. Preparación y representación clásica de textos	452
16.2. Modelado y evaluación de textos	459
16.3. Embeddings, atención y Transformers	465
16.4. Grandes modelos de lenguaje y aplicaciones generativas	471
Síntesis	477
Glosario esencial	477
Preguntas de revisión	478
Actividad integradora de cierre	479
Apendices	480
A. Fundamentos matematicos	480
B. Guia de programacion cientifica	480
C. Etica, gobernanza y documentacion	480

Indice del libro

La secuencia sigue el indice detallado de `Indice_detallado_libro_Ciencia_de_Datos_IA.md`.

Parte I. Fundamentos y trabajo con datos

1. [Ciencia de Datos e Inteligencia Artificial](#)
2. [Ciclo de vida de un proyecto basado en datos](#)
3. [Preparacion, calidad y transformacion de datos](#)
4. [Estadistica descriptiva, exploracion y visualizacion](#)

Parte II. Probabilidad, agentes y resolucion de problemas

5. [Probabilidad, incertidumbre e inferencia bayesiana](#)
6. [Agentes inteligentes y representacion de problemas](#)
7. [Busqueda y resolucion algoritmica](#)
8. [Decisiones secuenciales y aprendizaje por refuerzo](#)

Parte III. Fundamentos del aprendizaje automatico

9. [Formulacion y evaluacion](#)
10. [Ingenieria, seleccion y reduccion de atributos](#)
11. [Regresion y clasificacion](#)
12. [Metodos supervisados avanzados y ensambles](#)
13. [Aprendizaje no supervisado](#)
14. [Series temporales](#)

Parte IV. Aprendizaje profundo y datos no estructurados

15. [Redes neuronales y vision](#)
16. [Lenguaje natural y modelos de lenguaje](#)

Apéndices

- [Apéndices](#)

Capítulo 1. Ciencia de Datos e Inteligencia Artificial: conceptos, historia y aplicaciones

Propósito

La Ciencia de Datos y la Inteligencia Artificial suelen presentarse como campos nuevos, pero sus preguntas fundamentales tienen una historia mucho más larga: ¿cómo representar un fenómeno?, ¿cómo razonar con información incompleta?, ¿cómo aprender a partir de observaciones? y ¿cómo actuar cuando las consecuencias de una decisión son inciertas? Este capítulo introduce esos campos, delimita sus conceptos centrales y muestra cómo se relacionan sin convertirlos en sinónimos.

El objetivo no es aprender todavía a implementar un algoritmo particular. Es construir un mapa conceptual que permita reconocer qué problema se está resolviendo, qué tipo de evidencia se necesita, qué modelo resulta pertinente y qué riesgos aparecen cuando una predicción se transforma en una acción. Los capítulos siguientes desarrollarán las técnicas matemáticas, estadísticas y computacionales que aquí se presentan de manera introductoria.

Una idea orienta todo el capítulo: un modelo no es una decisión. Un modelo representa, resume o estima algún aspecto de la realidad; una decisión utiliza ese resultado dentro de un contexto, con objetivos, restricciones, costos y responsabilidades. Por eso, evaluar un sistema exige considerar tanto su desempeño técnico como la utilidad y las consecuencias de su uso.

1.1. Ciencia de Datos, Inteligencia Artificial y aprendizaje automático

1.1.1. Definición y objetivos de la Ciencia de Datos

La Ciencia de Datos es un campo interdisciplinario que desarrolla métodos para obtener conocimiento y apoyar decisiones a partir de datos. La definición contiene tres elementos importantes.

En primer lugar, los datos son representaciones parciales de fenómenos. Una medición de temperatura no es la temperatura en sí misma; es un registro

producido por un sensor, en una ubicación, con una unidad, una precisión y un procedimiento de observación determinados. Un reclamo escrito no es el evento financiero completo; es una expresión textual condicionada por el canal, el lenguaje y la información que el usuario decidió proporcionar. La Ciencia de Datos comienza, por tanto, preguntando qué representan los datos y qué aspectos del fenómeno quedan fuera de ellos.

En segundo lugar, la disciplina es interdisciplinaria. La estadística permite describir variabilidad e inferir a partir de muestras; la informática proporciona estructuras, algoritmos y sistemas; la matemática formaliza relaciones, incertidumbre y optimización; el conocimiento del dominio permite interpretar si un resultado es plausible; y la comunicación convierte la evidencia en una explicación útil para otras personas. Ninguna de esas dimensiones, por sí sola, constituye todo el trabajo de datos.

En tercer lugar, el resultado no es necesariamente un modelo predictivo. Un proyecto puede producir un inventario de fuentes, una medición de calidad, un análisis descriptivo, una estimación causal, una segmentación, una visualización o una recomendación. La pregunta y la decisión determinan qué producto es apropiado.

El ciclo general puede representarse como:

problema -> datos -> representación -> análisis -> evidencia -> decisión
-> evaluación




Figura 1: Ciclo de vida de un proyecto de datos

El ciclo es iterativo. La exploración puede mostrar que la pregunta original no es medible; una auditoría puede revelar que la variable objetivo se registró de manera inconsistente; una evaluación puede demostrar que un modelo no supera una regla simple. En esos casos, volver a formular el problema no significa fracasar, sino aprender algo relevante sobre el sistema estudiado.

Los objetivos de la Ciencia de Datos pueden clasificarse de la siguiente manera:

- **Describir:** resumir qué ocurrió, con qué frecuencia, en qué grupos y durante

qué periodos.

- **Diagnosticar:** investigar factores asociados con un resultado o posibles explicaciones de un comportamiento.
- **Predecir:** estimar un valor o una categoría no observada, futura o costosa de medir.
- **Prescribir o recomendar:** comparar acciones posibles considerando consecuencias, restricciones y preferencias.
- **Monitorear:** detectar cambios, anomalías o degradación en datos, procesos y modelos.

Estas categorías pueden combinarse, pero no deben confundirse. Describir que dos variables se mueven juntas no demuestra que una cause la otra. Predecir que ocurrirá un evento no indica automáticamente qué acción es conveniente. Recomendar una acción requiere una función de utilidad o una regla de decisión, no solo una probabilidad.

Una especificación inicial de un problema puede expresarse como:

$$P = (U, O, X, Y, A, H, C)$$

donde U es la unidad de análisis, O el objetivo, X las variables disponibles, Y el resultado de interés, A el conjunto de acciones posibles, H el horizonte temporal y C las restricciones. Esta notación obliga a preguntar qué representa cada observación y en qué momento se conocerá cada dato.

Por ejemplo, si una empresa desea reducir retrasos de transporte, una fila podría representar un viaje, una parada, una zona o un intervalo de quince minutos. Cada elección conduce a una pregunta diferente. Predecir el retraso de un viaje requiere variables disponibles antes de iniciarlo; analizar la congestión de una zona puede requerir agregar muchos viajes; asignar vehículos necesita además conocer recursos y restricciones operativas.

La Ciencia de Datos también debe distinguir entre datos, información y conocimiento. Los datos son observaciones codificadas; la información surge al organizarlos en un contexto; el conocimiento combina patrones y explicaciones con experiencia y reglas de uso; una decisión selecciona una acción. El paso de un nivel a otro puede introducir errores, supuestos y sesgos, por lo que la trazabilidad es parte del resultado científico.

1.1.2. Definición y objetivos de la Inteligencia Artificial

La Inteligencia Artificial estudia la construcción de sistemas capaces de realizar tareas que asociamos con capacidades inteligentes: percibir, representar estados, razonar, aprender, planificar, comunicarse y actuar. La expresión “inteligente” no implica que el sistema posea conciencia, comprensión humana general o intenciones propias. En un sentido técnico, significa que el sistema transforma información en comportamiento dirigido a un objetivo bajo determinadas condiciones.

Una forma clásica de describir un sistema inteligente es mediante el concepto de agente. Un agente recibe una secuencia de percepciones y selecciona acciones:

$$a_t = \pi(h_t)$$

donde h_t es la historia de percepciones hasta el instante t , a_t es la acción y π es la política o función de decisión. En un sistema sencillo, π puede ser una tabla de reglas. En otro, puede ser un modelo aprendido a partir de datos. La complejidad de la implementación no determina por sí sola la inteligencia del comportamiento.

El agente actúa en un entorno. El entorno puede ser físico, como una red de agua o un vehículo, o informacional, como un sistema de reclamos. Las acciones producen consecuencias que pueden medirse mediante una función de desempeño U . Un agente racional intenta seleccionar acciones con buen desempeño esperado, dadas sus percepciones, su conocimiento y sus recursos.

La formulación general de una decisión bajo incertidumbre es:

$$a^* = \arg \max_a \mathbb{E}[U(a, S) \mid \text{evidencia disponible}]$$

El valor de la expresión depende de cómo se definan los estados posibles S , sus probabilidades, la utilidad y las restricciones. Esto es importante porque un sistema puede optimizar perfectamente una función mal elegida. Si se recompensa únicamente la rapidez de respuesta, un asistente puede producir respuestas rápidas pero incorrectas; si se penalizan demasiado los falsos negativos, un detector puede generar demasiadas alertas innecesarias.

La IA incluye enfoques basados en reglas, búsqueda, lógica, probabilidades, planificación, aprendizaje automático, visión artificial, procesamiento del lenguaje y agentes autónomos. El aprendizaje automático es una parte de la IA, no su totalidad. Un sistema experto construido con reglas puede ser IA aunque no aprenda automáticamente. Del mismo modo, una regresión usada para describir una relación puede pertenecer a Ciencia de Datos sin constituir un agente inteligente.

La distinción entre capacidad y autonomía también es fundamental. Un sistema puede realizar una tarea compleja y, sin embargo, operar dentro de un procedimiento muy acotado. Un clasificador de imágenes que asigna una etiqueta no decide necesariamente qué debe hacer una persona. La autonomía aparece cuando el sistema puede seleccionar y ejecutar acciones con poca intervención humana. A mayor autonomía, mayor importancia tienen la seguridad, la supervisión, la posibilidad de reversión y la responsabilidad institucional.

1.1.3. Aprendizaje automático y aprendizaje profundo

El aprendizaje automático construye una función a partir de ejemplos o experiencia. En el aprendizaje supervisado se dispone de observaciones $D = \{(x_i, y_i)\}_{i=1}^n$, donde x_i representa entradas y y_i el resultado asociado. El objetivo es estimar una función f_θ cuyos parámetros θ produzcan resultados útiles en observaciones nuevas.

Una formulación frecuente es:

$$\theta^* = \arg \min_{\theta} \left[\frac{1}{n} \sum_{i=1}^n L(y_i, f_\theta(x_i)) + \lambda \Omega(\theta) \right]$$

La primera parte mide el error sobre los ejemplos disponibles. L puede ser una pérdida cuadrática para regresión, una pérdida logarítmica para clasificación

u otra función apropiada. El término $\Omega(\theta)$ penaliza complejidad; λ controla la intensidad de la regularización. La optimización encuentra parámetros, pero no garantiza que la tarea esté bien formulada ni que el modelo generalice.

La generalización es la capacidad de funcionar sobre datos que no se utilizaron para ajustar el modelo. Si un algoritmo memoriza peculiaridades del conjunto de entrenamiento, puede presentar bajo error interno y fallar en producción. Por eso se separan entrenamiento, validación y prueba, y se diseñan protocolos que respetan tiempo, grupos, duplicados y disponibilidad de información.

En el aprendizaje no supervisado no se dispone necesariamente de una variable objetivo. El propósito puede ser encontrar grupos, representaciones, componentes o anomalías. En el aprendizaje por refuerzo, un agente interactúa con un entorno, recibe recompensas y aprende una política. Cada paradigma responde a una pregunta diferente y exige una evaluación diferente.

El aprendizaje profundo utiliza redes neuronales con múltiples capas de transformaciones. Una capa puede calcular:

$$h^{(\ell)} = \phi(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)})$$

donde W son pesos, b sesgos y ϕ una función no lineal. Al apilar capas, el sistema aprende representaciones intermedias: en una imagen pueden aparecer bordes, texturas y formas; en un texto, relaciones entre tokens y contexto. La profundidad aumenta la capacidad representacional, pero también la necesidad de datos, cómputo, regularización, diagnóstico y explicabilidad.

“Aprender” no significa comprender en el sentido humano. Un modelo estadístico identifica regularidades útiles para su objetivo de entrenamiento. Puede explotar correlaciones espurias, señales de fondo o artefactos de captura. Por eso la inspección de ejemplos, la evaluación por subgrupos y el análisis fuera de distribución son tan importantes como la métrica global.

1.1.4. Relación con la estadística, la optimización y la ingeniería de software

La estadística aporta conceptos para describir variabilidad, estimar parámetros, construir intervalos, contrastar hipótesis y distinguir señal de ruido. Un dataset suele ser una muestra de una población más amplia. La pregunta estadística es qué puede inferirse de esa muestra y bajo qué supuestos. La pregunta de aprendizaje automático suele ser qué tan bien puede predecirse un resultado en datos futuros. Ambas preguntas se relacionan, pero no son idénticas.

La optimización formaliza la selección de parámetros o acciones. En un modelo supervisado, se minimiza una función de pérdida; en un problema de planificación, se minimiza un costo; en un agente, se maximiza una utilidad. Las funciones objetivo expresan prioridades. Cambiar la función objetivo cambia el comportamiento que se considera correcto.

La ingeniería de software transforma un método en un sistema mantenible. Incluye diseño modular, pruebas, control de versiones, gestión de dependencias, seguridad, observabilidad y despliegue. Un notebook que produce una métrica una vez no equivale a un sistema reproducible. Un modelo que funciona en una evaluación

controlada puede fallar si el sistema de producción cambia el formato, la frecuencia o la población de los datos.

Puede resumirse la relación así:

Disciplina	Pregunta principal	Contribución al proyecto
Estadística	¿Qué evidencia permiten los datos y cuál es la incertidumbre?	Descripción, inferencia y evaluación
Optimización	¿Qué parámetros o acciones maximizan el objetivo?	Ajuste y decisión
Computación	¿Cómo se representa y calcula el procedimiento?	Algoritmos y eficiencia
Ingeniería de software	¿Cómo se mantiene y opera el sistema?	Reproducibilidad y confiabilidad
Conocimiento del dominio	¿Qué significa el resultado en el contexto real?	Interpretación y restricciones

Un proyecto sólido necesita que estas perspectivas sean compatibles. Un modelo estadísticamente adecuado puede ser demasiado lento para una decisión en tiempo real; un algoritmo rápido puede optimizar una variable que no representa el objetivo institucional; una solución técnicamente correcta puede ser imposible de operar porque no existe un proceso de supervisión.

1.1.5. Diferencias entre modelos descriptivos, predictivos y prescriptivos

Un modelo descriptivo resume observaciones. Puede calcular frecuencias, medias, cuantiles, distribuciones, asociaciones o segmentos. Su propósito es responder qué ocurrió o qué estructuras aparecen. Un modelo descriptivo no necesita predecir el futuro para ser valioso; por ejemplo, identificar horarios con mayor demanda puede orientar una investigación operativa.

Un modelo predictivo estima un resultado desconocido. La predicción puede referirse al futuro, a una observación cuyo valor aún no se midió o a una etiqueta que requiere evaluación costosa. Formalmente, se busca estimar $P(Y | X)$ o una cantidad condicional como $\mathbb{E}[Y | X]$. La calidad se mide comparando predicciones con resultados observados mediante un protocolo que represente el uso real.

Un modelo prescriptivo compara acciones. Puede usar predicciones, pero agrega una función de utilidad, costos, restricciones y consecuencias. Si p es la probabilidad de una falla, C_i el costo de inspección y C_f el costo de no detectar la falla, una regla simple puede seleccionar inspección cuando:

$$p C_f > C_i$$

La desigualdad no es una ley universal. Es una consecuencia de un modelo de costos determinado. Si existen beneficios de inspeccionar, restricciones de capacidad o daños irreversibles, la regla debe ampliarse.

Los tres tipos se conectan en una cadena, pero no se sustituyen:

descripción -> predicción -> evaluación de acciones -> decisión

Una predicción precisa puede ser inútil si no cambia ninguna acción. Una recomendación puede ser razonable aun cuando la predicción sea incierta, si la acción es barata y reversible. Del mismo modo, un análisis descriptivo puede ser preferible a automatizar una decisión cuando faltan datos confiables o las consecuencias son graves.

1.1.6. Ejemplo práctico guiado: identificación de componentes de Ciencia de Datos e IA en un problema real

Considérese una empresa que administra una flota de vehículos y desea reducir demoras. El problema inicial es amplio: “mejorar el servicio”. Para volverlo analizable se define la unidad de análisis como un viaje, el horizonte como la próxima franja horaria y la decisión como reasignar vehículos entre zonas.

La captura registra identificador del viaje, origen, destino, hora programada, hora real, zona, vehículo y eventualmente condiciones climáticas. Antes de modelar es necesario verificar qué significa cada campo, cuándo queda disponible y si la hora real, que se conoce después del viaje, estaría disponible al momento de predecir.

El análisis descriptivo calcula cantidad de viajes, demora media y cuantiles por zona y franja horaria. Su resultado puede ser una tabla o visualización que muestre dónde y cuándo se concentran los retrasos. Todavía no predice un viaje futuro ni recomienda una acción.

La predicción estima, por ejemplo, la demora esperada del siguiente intervalo. La variable objetivo puede ser continua, como minutos de retraso, o categórica, como “a tiempo”, “demorado” y “crítico”. La evaluación debe utilizar datos posteriores a los usados para ajustar, respetar el orden temporal y comparar el modelo con un baseline.

La prescripción utiliza la predicción junto con vehículos disponibles, capacidad, tiempos de traslado, prioridades y costos. Una regla puede asignar un vehículo a la zona donde el beneficio esperado de reducir retrasos sea mayor. Esa regla es un componente de decisión y debe evaluarse con una métrica operativa, no solo con el error predictivo.

El procedimiento conceptual es:

- definir unidad, horizonte y acción
- auditar campos, disponibilidad temporal y calidad
- describir demanda y demoras por zona y periodo
- definir objetivo predictivo y baseline
- separar datos respetando el tiempo
- ajustar modelo y evaluar generalización
- estimar consecuencias de cada acción posible
- seleccionar acción factible con utilidad esperada
- monitorear resultados y revisar supuestos

El ejemplo muestra que la Ciencia de Datos aparece en la definición, preparación, análisis y evaluación. La IA puede aparecer en la predicción, en la búsqueda de una asignación o en un agente que actúe sobre la flota. La captura de datos no es todavía inteligencia; es una condición para producir evidencia.

1.2. Enfoques y fundamentos de la Inteligencia Artificial

Una misma aplicación puede considerarse inteligente según criterios diferentes. La clasificación clásica distingue sistemas que actúan como seres humanos, sistemas que piensan como seres humanos, sistemas que piensan racionalmente y sistemas que actúan racionalmente. Los enfoques no describen necesariamente cuatro tecnologías separadas; son cuatro preguntas sobre qué significa inteligencia.

1.2.1. Sistemas que actúan como seres humanos

Este enfoque evalúa la conducta observable. Un sistema se considera exitoso si su comportamiento resulta indistinguible o comparable al de una persona en una tarea definida. Incluye conversación, percepción, movimiento, uso de herramientas y respuesta a situaciones.

La ventaja del criterio conductual es que permite evaluar resultados sin resolver el problema filosófico de qué ocurre dentro del sistema. Sin embargo, una conducta similar puede producirse mediante mecanismos muy distintos. Un sistema puede dar respuestas apropiadas usando reglas específicas sin poseer una representación general del mundo. También puede imitar el estilo humano y cometer errores que una persona no cometería, o producir una respuesta convincente sin contar con evidencia suficiente.

El criterio debe especificar tarea, contexto y población de evaluación. “Actuar como una persona” no es una propiedad única: una persona puede ser rápida en conversación, pero no necesariamente precisa en diagnóstico; puede reconocer un objeto en condiciones normales y fallar en una imagen degradada.

1.2.2. Sistemas que piensan como seres humanos

Este enfoque intenta modelar procesos cognitivos humanos: percepción, memoria, aprendizaje, lenguaje, razonamiento y resolución de problemas. La evaluación no se limita a la respuesta final, sino que considera tiempos, errores, secuencias de pasos y cambios frente a nueva información.

El modelado cognitivo puede apoyarse en experimentos psicológicos, neurociencia, modelos simbólicos y modelos conexionistas. Su objetivo no siempre es construir la solución más eficaz, sino formular hipótesis sobre cómo funciona la cognición.

Un sistema que resuelve un problema correctamente no necesariamente piensa como una persona. Puede explorar miles de alternativas de manera impracticable para un humano, utilizar una memoria completa del conjunto de datos o aprovechar una regularidad que no está disponible para la percepción humana. La similitud de resultados y la similitud del proceso son criterios distintos.

Este enfoque es útil cuando se diseñan interfaces, tutores o herramientas de asistencia que deben adaptarse a capacidades humanas. También permite

estudiar qué tipos de explicaciones, alertas o representaciones son comprensibles para sus usuarios.

1.2.3. Sistemas que piensan racionalmente

Pensar racionalmente significa derivar conclusiones válidas a partir de premisas y reglas de inferencia. La lógica proposicional y la lógica de predicados ofrecen lenguajes formales para representar hechos y relaciones. Si se tiene $A \rightarrow B$ y se observa A , el modus ponens permite inferir B .

La ventaja de la lógica es la claridad: las premisas, reglas y conclusiones pueden inspeccionarse. Sus limitaciones aparecen cuando el conocimiento es incompleto, ambiguo o incierto. Un sistema médico raramente dispone de premisas absolutas; una observación puede ser ruidosa y una regla puede tener excepciones.

La probabilidad amplía este enfoque al permitir grados de creencia. En lugar de afirmar únicamente que una hipótesis es verdadera o falsa, se puede calcular $P(H | E)$, la probabilidad de una hipótesis H dada la evidencia E . La lógica difusa, los modelos gráficos y otras formalizaciones representan incertidumbre o vaguedad de maneras diferentes.

Pensar racionalmente tampoco garantiza actuar bien. Una inferencia puede ser válida y conducir a una acción perjudicial si las premisas son incorrectas o si no se consideraron costos y consecuencias.

1.2.4. Sistemas que actúan racionalmente

Un sistema actúa racionalmente cuando selecciona, entre las acciones disponibles, aquella que maximiza el desempeño esperado según sus objetivos, información y limitaciones. Este enfoque es central para los agentes inteligentes.

Sea S el estado del entorno, E la evidencia, A una acción y U la utilidad. La elección ideal puede escribirse como:

$$a^* = \arg \max_a \sum_s P(s | E) U(a, s)$$

El agente no necesita conocer el estado verdadero con certeza. Necesita representar creencias sobre estados posibles, evaluar consecuencias y reconocer el costo de obtener más información. La racionalidad es, por tanto, relativa a la información disponible. Un agente no es irracional por no elegir una acción que solo sería óptima con información que no podía observar.

La racionalidad también incluye acciones de recolección de información. Si una medición puede cambiar significativamente la decisión, su valor esperado puede justificar el costo de obtenerla. Esta idea anticipa el valor de la información y la planificación bajo incertidumbre.

El enfoque racional es especialmente adecuado para sistemas de recomendación, control, asignación y asistencia a decisiones. Su desafío principal es definir correctamente la utilidad y las restricciones. Optimizar una función simplificada puede producir un comportamiento eficiente en términos numéricos pero inaceptable en términos sociales, ambientales o de seguridad.

1.2.5. Test de Turing y modelado cognitivo

El test de Turing propone evaluar si un interlocutor humano puede distinguir, mediante una conversación, entre una persona y una máquina. Su importancia histórica está en desplazar la discusión desde una definición abstracta de inteligencia hacia una prueba de comportamiento.

El test tiene límites. Una conversación no evalúa necesariamente percepción física, planificación prolongada, comprensión causal o desempeño en situaciones nuevas. Además, un sistema puede utilizar estrategias de evasión, imitación o generación de respuestas plausibles. Superar una prueba particular no demuestra inteligencia general ni confiabilidad en dominios sensibles.

El modelado cognitivo plantea una pregunta diferente: ¿qué mecanismos internos podrían explicar el comportamiento? Dos sistemas pueden aprobar una prueba con respuestas similares, pero uno puede utilizar memoria, reglas y búsqueda, mientras que otro utiliza representaciones distribuidas y estimación estadística. Para diferenciarlos se estudian patrones de error, tiempos de respuesta, generalización y reacción a cambios controlados.

Los dos enfoques son complementarios. La evaluación conductual pregunta si el sistema cumple la tarea; el modelado cognitivo pregunta qué proceso explica ese cumplimiento. En aplicaciones reales conviene agregar un tercer nivel: si el sistema es seguro, trazable y apropiado para la decisión que se pretende apoyar.

1.2.6. Fundamentos filosóficos, matemáticos y computacionales

La IA se apoya en varias tradiciones filosóficas. El racionalismo destaca la razón y las estructuras formales; el empirismo destaca la experiencia y la observación; el pragmatismo evalúa ideas por sus consecuencias prácticas. Estas tradiciones reaparecen en el contraste entre sistemas basados en conocimiento explícito y sistemas que aprenden regularidades de datos.

La lógica aporta representación y deducción. La probabilidad permite razonar ante incertidumbre. La teoría de la decisión relaciona creencias con acciones mediante utilidad. La optimización permite elegir parámetros o políticas. El álgebra lineal representa datos, transformaciones y redes; el cálculo proporciona gradientes; la teoría de la información cuantifica incertidumbre y contenido informativo.

Desde la computación, un sistema de IA requiere una representación de estados, una forma de producir transiciones, un algoritmo de búsqueda o aprendizaje y recursos de memoria y tiempo. La complejidad computacional importa porque un método exacto puede ser impracticable a gran escala. La aproximación, la heurística y la paralelización intercambian garantías, velocidad y calidad.

Una arquitectura completa suele incluir:

1. percepción o entrada de datos;
2. representación interna;
3. memoria o estado;
4. inferencia, búsqueda o aprendizaje;
5. evaluación de acciones;
6. ejecución, comunicación y retroalimentación.

La separación ayuda a localizar fallos. Una predicción incorrecta puede deberse a una representación inadecuada; una acción incorrecta puede deberse a una

función de utilidad mal definida aunque la predicción sea buena; un sistema inestable puede deberse a la interacción entre modelo y entorno.

1.2.7. Ejemplo práctico guiado: análisis de un asistente inteligente desde los cuatro enfoques de la IA

Considérese un asistente que recibe el texto de un reclamo, consulta antecedentes y propone una respuesta. Desde el enfoque de actuar como humano se evalúa si conversa con fluidez, identifica la intención y mantiene el contexto. La prueba debe incluir preguntas ambiguas, errores de escritura, cambios de tema y solicitudes fuera de alcance.

Desde el enfoque de pensar como humano se estudia si separa hechos, interpreta referencias y utiliza una secuencia de razonamiento comparable a la de un agente de atención. No es suficiente observar una respuesta correcta; también interesa cómo reacciona cuando falta información y si puede explicar qué dato necesita.

Desde el enfoque de pensar racionalmente se inspeccionan las reglas de inferencia, las fuentes consultadas y la coherencia entre evidencia y conclusión. Una respuesta debe poder justificarse mediante antecedentes verificables y no solamente por su plausibilidad lingüística.

Desde el enfoque de actuar racionalmente se analiza si la recomendación maximiza el objetivo del servicio bajo restricciones de política, privacidad, tiempos y costos. El asistente podría decidir responder, pedir información, derivar el caso o abstenerse. La abstención es una acción racional cuando la incertidumbre o el riesgo son altos.

La evaluación debe registrar entradas, fuentes usadas, respuesta, nivel de confianza, acción sugerida y revisión humana. Así se distingue capacidad conversacional de confiabilidad operativa.

1.3. Evolución histórica de la Ciencia de Datos y la IA

La historia de estos campos no es una sucesión lineal de inventos cada vez mejores. Es una alternancia entre representaciones, expectativas y recursos disponibles. Un método puede ser conceptualmente correcto y fracasar porque no existen datos, memoria o capacidad de cómputo suficientes. También puede ser técnicamente eficaz y resultar limitado cuando cambia el problema.

1.3.1. Antecedentes lógicos y matemáticos

La lógica formal permitió expresar proposiciones y reglas de inferencia. El cálculo y el álgebra proporcionaron herramientas para modelar cambio, geometría y transformaciones. La probabilidad formalizó la incertidumbre y la estadística desarrolló procedimientos para aprender sobre poblaciones a partir de muestras.

La teoría de la información introdujo formas de cuantificar incertidumbre y transmisión de señales. La teoría de la decisión relacionó probabilidades con preferencias y costos. Estos desarrollos no fueron inicialmente “IA”, pero constituyen la base de métodos contemporáneos de clasificación, compresión, estimación y control.

La computación agregó una condición práctica: que los procedimientos pudieran ejecutarse mecánicamente. La idea de algoritmo precede al computador moderno, pero la máquina programable permitió automatizar secuencias generales de operaciones. El límite entre un cálculo explícito y un sistema que aprende aparece cuando el procedimiento no especifica directamente todas las respuestas, sino que ajusta una representación a partir de ejemplos.

1.3.2. Nacimiento formal de la Inteligencia Artificial

Durante la década de 1950 se consolidó la idea de estudiar inteligencia mediante programas. La conferencia de Dartmouth de 1956 suele considerarse un hito nominal para el campo. Los primeros proyectos exploraron demostración de teoremas, juegos, resolución de problemas y manipulación simbólica.

La expectativa inicial era que muchas tareas inteligentes pudieran expresarse como búsqueda en espacios de estados y manipulación de símbolos. La computadora recibiría una representación del problema, aplicaría reglas y encontraría una solución. Este enfoque fue exitoso en mundos acotados, donde las reglas y estados eran relativamente claros.

Pronto aparecieron dificultades: la cantidad de estados crecía rápidamente, el lenguaje natural era ambiguo, el conocimiento del mundo era enorme y la percepción contenía ruido. La diferencia entre resolver un rompecabezas formal y actuar en un entorno abierto obligó a incorporar heurísticas, conocimiento de dominio, probabilidades y aprendizaje.

1.3.3. Sistemas expertos y representación simbólica

Los sistemas expertos separaron una base de conocimiento de un motor de inferencia. La base podía contener reglas como “si se observa A y B, considerar C”; el motor aplicaba esas reglas a hechos disponibles. Este diseño permitía explicar una conclusión mediante una cadena de reglas, una característica valiosa en dominios profesionales.

La representación simbólica ofrece conceptos legibles: entidades, relaciones, categorías, causas y restricciones. También permite incorporar conocimiento que no sería fácil aprender de pocos ejemplos. Sus dificultades son el costo de adquirir y mantener reglas, la ambigüedad de las excepciones y la fragilidad ante situaciones no contempladas.

Un sistema experto no es automáticamente objetivo. Las reglas reflejan decisiones de quienes las diseñan, datos históricos y políticas institucionales. Si la base de conocimiento omite una población o utiliza una definición inadecuada, el razonamiento será coherente con premisas problemáticas.

La representación simbólica y el aprendizaje estadístico pueden combinarse. Un sistema puede usar un modelo aprendido para percibir una imagen y reglas explícitas para controlar una decisión. Esta combinación conserva conocimiento verificable sin exigir que toda la tarea se resuelva con reglas.

1.3.4. Invierno de la IA y resurgimiento estadístico

Los inviernos de la IA fueron periodos de reducción de financiamiento y entusiasmo. Las causas incluyeron promesas desproporcionadas, resultados difíciles de

generalizar, limitaciones de cómputo, falta de datos y sistemas demasiado frágiles fuera de entornos controlados.

La experiencia mostró que una demostración en un problema pequeño no equivalía a inteligencia general. También mostró que una tarea podía ser difícil por razones de representación y no solo por falta de potencia. En reconocimiento visual, por ejemplo, especificar manualmente todas las formas posibles era poco viable; en lenguaje, las reglas no podían cubrir todas las expresiones.

El resurgimiento estadístico dio mayor importancia a modelos que estiman regularidades a partir de datos. La disponibilidad de bases más grandes, mejores sensores, almacenamiento barato, redes de comunicación y procesadores especializados permitió entrenar modelos más complejos. Los avances no eliminaron los problemas de sesgo, cambio de distribución y evaluación; simplemente desplazaron el centro de gravedad hacia los datos y el aprendizaje.

1.3.5. Big Data, aprendizaje profundo e IA generativa

Big Data no significa solamente “muchos datos”. Suele describirse mediante volumen, velocidad, variedad, veracidad y valor. Un flujo de sensores puede tener gran velocidad y volumen, pero mediciones incompletas; un corpus textual puede tener variedad, pero etiquetas ambiguas; un dataset pequeño puede tener alto valor si representa con precisión una tarea crítica.

El aprendizaje profundo se benefició de datasets extensos, GPU, arquitecturas diferenciables y técnicas de entrenamiento más estables. Las redes convolucionales mejoraron tareas visuales; los modelos secuenciales y Transformers ampliaron el procesamiento del lenguaje y de otras secuencias.

Los modelos fundacionales se preentrenan sobre grandes colecciones y luego se adaptan a tareas o dominios. La IA generativa produce nuevas instancias condicionadas por una entrada: texto, imágenes, audio, código u otros contenidos. En un modelo autoregresivo, una secuencia puede factorizarse como:

$$P(x_1, \dots, x_T) = P(x_1) \prod_{t=2}^T P(x_t | x_1, \dots, x_{t-1})$$

Esta formulación permite generar paso a paso, pero no garantiza que el contenido sea verdadero. La fluidez lingüística es una propiedad de generación, no una prueba de conocimiento. Por eso los modelos generativos deben combinarse con recuperación de fuentes, validación, límites de uso y supervisión.

1.3.6. Ejemplo práctico guiado: construcción de una línea de tiempo tecnológica

Construir una línea de tiempo con cinco columnas: hito, representación dominante, datos disponibles, capacidad de cómputo y limitación principal. Incluir, por ejemplo, antecedentes lógicos, nacimiento de la IA simbólica, sistemas expertos, resurgimiento estadístico, aprendizaje profundo y modelos generativos.

La tarea no consiste en memorizar fechas. Para cada hito se debe responder: ¿qué problema podía resolverse?, ¿qué supuesto se utilizaba?, ¿qué recurso faltante

limitaba la expansión? Una línea de tiempo útil conecta la aparición de un método con las condiciones que lo hicieron posible.

1.4. Aplicaciones, alcances y riesgos

Una aplicación de datos o IA transforma observaciones en una salida que puede influir en personas, recursos o procesos. La utilidad depende del contexto de uso. El mismo clasificador puede ser aceptable como herramienta exploratoria y no serlo como mecanismo automático de rechazo de solicitudes.

1.4.1. Aplicaciones en ingeniería e industria

En ingeniería, los modelos pueden estimar vida útil, detectar fallas, optimizar consumo, programar mantenimiento y controlar procesos. En industria, los sensores permiten construir series de temperatura, vibración, presión o producción. La predicción de mantenimiento puede reducir interrupciones, pero requiere que las mediciones estén disponibles antes de la falla y que exista capacidad de intervenir.

La confiabilidad técnica exige distinguir entre detección y diagnóstico. Detectar una señal anómala indica que el comportamiento difiere del patrón esperado; diagnosticar implica asociarla con una causa; prescribir requiere elegir una intervención. Cada paso tiene un nivel distinto de evidencia.

1.4.2. Aplicaciones en salud, ambiente y agricultura

En salud, la IA puede apoyar clasificación de imágenes, priorización, búsqueda bibliográfica y estimación de riesgos. El modelo no reemplaza automáticamente la evaluación clínica: las consecuencias de un error, la prevalencia de la condición y la calidad de la población de validación son determinantes.

En ambiente, los datos pueden provenir de sensores, satélites, estaciones y registros comunitarios. La cobertura espacial y temporal rara vez es uniforme. Un mapa de riesgo puede reflejar tanto el fenómeno como la distribución de sensores. En agricultura, la visión artificial puede identificar síntomas en hojas, pero la generalización desde imágenes controladas a condiciones de campo debe probarse explícitamente.

1.4.3. Aplicaciones en finanzas y sistemas de información

En finanzas y servicios, los modelos se usan para detectar transacciones anómalas, clasificar reclamos, estimar riesgo y recomendar productos. Los datos históricos pueden contener decisiones previas, por lo que un modelo puede aprender patrones institucionales en lugar de medir directamente el comportamiento que interesa.

En sistemas de información, la IA puede mejorar búsqueda, recomendación, extracción de datos y asistencia al usuario. Los objetivos de interacción, retención o rapidez pueden entrar en tensión con precisión, privacidad y bienestar. Por eso la métrica de negocio no debe ser la única medida de éxito.

1.4.4. Automatización, asistencia y apoyo a decisiones

La automatización ejecuta una acción con intervención humana reducida. La asistencia presenta información, predicciones o alternativas para que una persona decida. El apoyo a decisiones puede incluir una recomendación, pero mantiene responsabilidad y control humanos.

Una clasificación útil considera cuatro niveles:

1. **Observación:** el sistema resume o visualiza datos.
2. **Sugerencia:** propone una interpretación o acción.
3. **Ejecución supervisada:** actúa después de una aprobación.
4. **Ejecución autónoma:** actúa sin aprobación caso por caso.

El nivel apropiado depende de reversibilidad, velocidad, consecuencias, posibilidad de auditoría y capacidad de supervisión. En una tarea de bajo riesgo puede ser eficiente automatizar; en una decisión sensible puede ser preferible que el sistema se abstenga y derive el caso.

1.4.5. Limitaciones técnicas y organizacionales

Las limitaciones técnicas incluyen datos incompletos, etiquetas ruidosas, variables mal definidas, fuga de información, sobreajuste, deriva, cambios de distribución, errores de medición y vulnerabilidades adversariales. El desempeño promedio puede ocultar fallos sistemáticos en subgrupos o situaciones poco frecuentes.

Las limitaciones organizacionales incluyen falta de responsables, procesos de revisión inexistentes, infraestructura insuficiente, incentivos mal alineados, resistencia de usuarios y ausencia de un mecanismo para corregir decisiones. Un modelo no se despliega en el vacío: entra en un proceso que puede amplificar o neutralizar sus errores.

La validez debe considerarse en varias dimensiones:

- **Validez de constructo:** las variables representan el concepto que se quiere medir.
- **Validez interna:** el resultado está respaldado dentro de los datos y diseño utilizados.
- **Validez externa:** generaliza a la población y condiciones de uso.
- **Validez operativa:** puede integrarse en un proceso que ejecuta la decisión.

1.4.6. Sesgos, privacidad, seguridad y uso responsable

El sesgo no es una propiedad única de un algoritmo. Puede aparecer durante la definición del problema, la medición, la selección de datos, el etiquetado, el entrenamiento, el umbral, la interfaz o el uso posterior. Un dataset puede representar de manera desigual a una población; una etiqueta puede reflejar decisiones históricas; una métrica puede favorecer un grupo y perjudicar otro.

La privacidad exige limitar recolección, acceso, retención y reutilización. Anonimizar identificadores no garantiza que una persona no pueda ser reidentificada si se combinan atributos. La seguridad incluye proteger datos, modelos y canales de inferencia, así como prevenir manipulación de entradas y filtración de información.

El uso responsable requiere, como mínimo, propósito definido, base legal o legitimidad, documentación de datos y modelo, evaluación de impacto, controles de acceso, supervisión, posibilidad de apelación y monitoreo posterior. La explicabilidad debe adaptarse al usuario y a la decisión: una explicación técnica de pesos no necesariamente permite cuestionar una decisión concreta.

Una cadena de análisis de riesgo puede escribirse como:

dato o supuesto -> mecanismo de error -> impacto -> control -> responsable
-> evidencia de control

Este esquema evita declaraciones generales como “el sistema es ético” y obliga a especificar qué puede fallar, quién debe detectarlo y qué se hará cuando ocurra.

1.4.7. Ejemplo práctico guiado: evaluación inicial de oportunidades y riesgos

Elegir una aplicación concreta, por ejemplo, un sistema que prioriza reclamos financieros. Elaborar una ficha con:

- problema y beneficio esperado;
- usuarios, personas afectadas y responsables;
- datos utilizados y datos excluidos;
- salida del modelo y acción asociada;
- falsos positivos y falsos negativos;
- grupos o condiciones con posible desempeño desigual;
- riesgos de privacidad y seguridad;
- controles, revisión humana y mecanismo de apelación;
- condición para suspender o retirar el sistema.

La evaluación debe distinguir el riesgo del modelo del riesgo de la decisión. Un clasificador puede tener una métrica aceptable, pero ser inadecuado si la organización convierte automáticamente una prioridad en un rechazo. También debe distinguir posibilidad y severidad: un error raro puede requerir controles estrictos si sus consecuencias son graves.

Síntesis

La Ciencia de Datos organiza un proceso para producir evidencia a partir de observaciones; la Inteligencia Artificial construye sistemas que perciben, razonan, aprenden o actúan. El aprendizaje automático estima funciones desde datos y el aprendizaje profundo utiliza representaciones compuestas, pero ninguno reemplaza la formulación del problema ni el juicio sobre el uso.

Los cuatro enfoques de la IA muestran que “inteligencia” puede referirse a conducta, proceso cognitivo, razonamiento o acción racional. La historia del campo evidencia que los métodos dependen de representaciones, datos, cómputo y expectativas. Las aplicaciones actuales amplían capacidades, pero también hacen visibles riesgos de sesgo, privacidad, seguridad y automatización.

En los capítulos siguientes, estos conceptos se convertirán en procedimientos: el Capítulo 2 formalizará el ciclo de vida; los Capítulos 3 y 4 tratarán calidad, exploración y comunicación; los Capítulos 5 a 8 desarrollarán incertidumbre,

agentes, búsqueda y decisión; y los Capítulos 9 a 16 estudiarán aprendizaje automático, visión y lenguaje.

Glosario esencial

- **Agente:** sistema que recibe percepciones y selecciona acciones en un entorno.
- **Aprendizaje automático:** métodos que ajustan una función o política a partir de datos o experiencia.
- **Aprendizaje profundo:** aprendizaje basado en redes con múltiples transformaciones parametrizadas.
- **Baseline:** regla o modelo simple usado como referencia.
- **Dato:** representación registrada de una observación, evento o entidad.
- **Generalización:** capacidad de funcionar sobre casos no utilizados durante el ajuste.
- **Modelo descriptivo:** representación que resume estructuras o patrones observados.
- **Modelo predictivo:** función que estima resultados no observados o futuros.
- **Modelo prescriptivo:** método que compara acciones considerando utilidad y restricciones.
- **Racionalidad:** selección de acciones con mejor desempeño esperado dada la información disponible.
- **Sesgo:** desviación sistemática producida por datos, mediciones, procedimientos o decisiones.

Preguntas de autoevaluación

1. ¿Por qué Ciencia de Datos e Inteligencia Artificial no son sinónimos?
2. ¿Qué diferencia existe entre describir, predecir y prescribir?
3. ¿Por qué una predicción precisa no garantiza una decisión útil?
4. ¿Qué papel cumplen la estadística, la optimización y la ingeniería de software?
5. ¿Qué diferencia existe entre actuar como humano y actuar racionalmente?
6. ¿Qué limitaciones tiene el test de Turing?
7. ¿Por qué los sistemas expertos pueden ser útiles y frágiles al mismo tiempo?
8. ¿Qué relación existe entre datos, cómputo y resurgimiento del aprendizaje profundo?
9. ¿Cómo puede aparecer un sesgo antes de entrenar un modelo?
10. ¿Qué condiciones justificarían abstenerse de automatizar una decisión?

Actividad de reflexión

Seleccione una aplicación de su entorno y descríbalas sin utilizar todavía un algoritmo. Identifique el fenómeno, la unidad de análisis, las observaciones disponibles, el resultado que se desea conocer, las acciones posibles, los costos de error y las personas afectadas. Finalmente, determine si la aplicación requiere descripción, predicción, prescripción o una combinación de ellas, y justifique qué nivel de automatización sería aceptable.

Capítulo 2. Ciclo de vida de un proyecto basado en datos

Propósito y objetivos de aprendizaje

Un proyecto basado en datos no comienza cuando se abre un archivo ni cuando se elige un algoritmo. Comienza cuando una organización, una comunidad o un equipo identifica una situación que necesita comprender o modificar. Entre esa necesidad inicial y una solución operativa existe una cadena de decisiones: definir qué se quiere lograr, determinar qué puede observarse, obtener y preparar los datos, construir evidencia, evaluar alternativas e integrar el resultado en un proceso real.

Este capítulo estudia esa cadena como un **ciclo de vida**. La palabra *ciclo* es importante: aunque las etapas se presentan en un orden pedagógico, el trabajo real rara vez avanza en línea recta. La exploración de los datos puede mostrar que la pregunta no era medible; el modelado puede revelar que la variable objetivo está mal definida; una prueba de uso puede demostrar que una predicción técnicamente correcta llega demasiado tarde para modificar la decisión. En esos casos, regresar a una etapa anterior no es un fracaso, sino el mecanismo normal mediante el cual el proyecto aprende.

Al finalizar el capítulo, el lector podrá:

- distinguir una necesidad real, una pregunta analítica y una tarea computacional;
- formular objetivos técnicos vinculados con objetivos operativos;
- definir unidad de análisis, población, alcance, variables y restricciones;
- establecer criterios de éxito y líneas de base antes de modelar;
- comparar KDD, CRISP-DM y formas iterativas de organizar el trabajo;
- reconocer tipos de datos, fuentes y arquitecturas básicas;
- diseñar una estructura de proyecto reproducible y trazable.

La figura resume una secuencia general. Sin embargo, las flechas deben imaginarse en ambas direcciones. Cada resultado intermedio puede aportar información que obligue a revisar una decisión previa.

2.1. Formulación del problema

La formulación es la etapa en la que una necesidad amplia se convierte en un problema que puede observarse, analizarse y evaluarse. Es también la etapa en la que suelen producirse los errores más costosos. Un algoritmo deficiente puede reemplazarse; un proyecto construido durante meses para responder la pregunta equivocada habrá consumido datos, tiempo y confianza sin producir valor.




Figura 2: Ciclo de vida de un proyecto de datos

Una formulación completa debe responder, al menos, las siguientes preguntas:

1. ¿Qué situación se desea comprender o modificar?
2. ¿Quién utilizará el resultado y qué acción podrá realizar?
3. ¿Cuál es la unidad sobre la que se observará y decidirá?
4. ¿Qué información estará disponible en ese momento?
5. ¿Qué resultado se considera deseable?
6. ¿Qué restricciones técnicas, legales, económicas o éticas existen?
7. ¿Cómo se sabrá si la solución aporta valor?

2.1.1. Problema real, pregunta analítica y tarea computacional

Un **problema real** describe una situación del dominio. Por ejemplo: una empresa distribuidora pierde agua en algunos sectores de su red; una ciudad experimenta demoras en el transporte; una entidad financiera acumula reclamos sin priorizar; un servicio agronómico necesita reconocer síntomas en hojas. Estas formulaciones expresan necesidades legítimas, pero todavía no indican qué datos deben utilizarse ni qué cálculo debe realizarse.

La **pregunta analítica** delimita un aspecto observable del problema. Para la pérdida de agua podrían formularse preguntas diferentes:

- ¿En qué zonas y horarios se registran caídas inusuales de presión?
- ¿Qué variables se asocian con las fugas confirmadas?
- ¿Cuál es la probabilidad de que una zona presente una fuga durante las próximas 24 horas?
- ¿Qué sectores conviene inspeccionar primero con una cuadrilla limitada?

Cada pregunta produce un tipo distinto de evidencia. La primera es descriptiva; la segunda es asociativa o diagnóstica; la tercera es predictiva; la cuarta es prescriptiva. Aunque puedan formar parte del mismo proyecto, no son intercambiables.

La **tarea computacional** especifica la operación formal que se ejecutará sobre los

datos. Puede ser agregación, estimación, clasificación, regresión, agrupamiento, detección de anomalías, búsqueda, optimización o simulación. La pregunta “¿qué zonas conviene inspeccionar?” no se resuelve solamente con un clasificador. El clasificador podría estimar riesgo, pero la selección final debe considerar distancia, costo, disponibilidad de cuadrillas y gravedad esperada.

La relación entre los tres niveles puede representarse así:

necesidad $\rightarrow$ pregunta analítica $\rightarrow$ tarea computacional $\rightarrow$ evidencia $\rightarrow$ decisión.

La correspondencia debe verificarse en ambos sentidos. Si la tarea produce una probabilidad, debe existir una decisión capaz de utilizarla. Si la decisión exige actuar sobre una zona, los datos y la evaluación deben conservar esa unidad geográfica. Si el problema requiere una explicación causal, una tarea puramente predictiva no basta, aunque obtenga buen desempeño.

Preguntas descriptivas, predictivas y prescriptivas

Una pregunta descriptiva resume lo observado: “¿cuántos incidentes hubo por mes?”. Una pregunta predictiva estima algo desconocido: “¿cuántos incidentes habrá el próximo mes?”. Una pregunta prescriptiva compara acciones: “¿cómo distribuir recursos para reducir su impacto?”. La transición entre ellas incorpora supuestos adicionales.

En términos formales, una descripción estima propiedades de una distribución observada, como una media $E[X]$ o una proporción $P(Y = 1)$. Una predicción busca una cantidad condicional, por ejemplo $P(Y = 1 \mid X = x)$. Una prescripción introduce acciones $a \in \mathcal{A}$ y una utilidad $U(a, s)$ para cada posible estado s :

$$a^* = \arg \max_{a \in \mathcal{A}} \sum_s P(s \mid x) U(a, s).$$

El paso desde probabilidad a decisión requiere costos y preferencias. Dos organizaciones pueden utilizar la misma predicción y elegir acciones distintas porque tienen capacidades, responsabilidades o tolerancias al riesgo diferentes.

Errores frecuentes de formulación

Un error habitual es comenzar por una técnica: “queremos aplicar redes neuronales”. La técnica no define el problema y puede no ser pertinente. Otro error consiste en formular una pregunta con una variable que solo se conoce después de decidir. También es frecuente confundir un indicador disponible con el fenómeno de interés: utilizar cantidad de reclamos como medida directa de calidad ignora que reclamar depende del acceso al canal, del conocimiento del usuario y de la confianza en la institución.

Una prueba útil consiste en explicar el proyecto sin nombrar ningún algoritmo. Si no puede describirse quién decide, sobre qué unidad, con qué información y para lograr qué resultado, la formulación todavía no está completa.

Un método de revisión de la pregunta

En la práctica conviene someter la pregunta a cuatro pruebas. La **prueba de observabilidad** pregunta si sus conceptos pueden vincularse con mediciones. La **prueba de accionabilidad** verifica si el resultado permite elegir entre acciones. La **prueba temporal** reconstruye qué información existe antes de decidir. La **prueba contrafactual** pregunta qué se haría si la respuesta analítica fuera distinta.

La última prueba es especialmente reveladora. Si una organización afirma que desea predecir demanda, pero asignará la misma cantidad de vehículos cualquiera sea el pronóstico, el proyecto no tiene todavía una decisión asociada. Puede ser valioso como descripción, pero no debe prometer impacto operativo.

También es útil construir una tabla de trazabilidad:

Elemento	Formulación	Evidencia requerida
Necesidad	Reducir interrupciones	Duración y alcance de incidentes
Pregunta	Riesgo en 24 horas	Historial con cortes temporales
Tarea	Estimar probabilidad	Etiquetas y variables previas
Acción	Inspeccionar o esperar	Capacidad y costo de error
Impacto	Daño evitado	Seguimiento posterior

Si una fila no puede completarse, existe un salto lógico. Detectarlo al comienzo es mucho más barato que descubrirlo después del despliegue.

2.1.2. Objetivos técnicos y objetivos de negocio

El término **objetivo de negocio** se utiliza de manera amplia para referirse al resultado organizacional, público, social o científico que se desea alcanzar. Puede ser reducir pérdidas, mejorar cobertura, disminuir tiempos, asignar recursos con equidad o aumentar la capacidad de vigilancia. No necesariamente implica una empresa ni un beneficio económico.

El **objetivo técnico** describe el comportamiento esperado del sistema analítico: estimar probabilidades calibradas, reducir error de pronóstico, detectar cierta proporción de eventos, procesar datos con una latencia máxima o producir explicaciones auditables.

Ambos objetivos deben conectarse mediante una teoría de cambio:

salida técnica → interpretación → acción → consecuencia operativa → impacto.

Supóngase que un modelo identifica fugas con alta sensibilidad. Esa propiedad solo reduce pérdidas si las alertas llegan a tiempo, las cuadrillas pueden inspeccionarlas, las falsas alarmas no saturan el proceso y la reparación efectivamente evita desperdicio. El desempeño del modelo es una condición de la cadena, no su resultado final.

Indicadores de modelo e indicadores de impacto

Un indicador de modelo compara salidas con referencias: error absoluto, sensibilidad, precisión, calibración o tiempo de respuesta. Un indicador de impacto mide consecuencias: litros ahorrados, horas de interrupción evitadas, tiempo de resolución o cobertura territorial.

La relación no siempre es monótonica. Aumentar sensibilidad puede elevar las inspecciones innecesarias; disminuir el error promedio puede no mejorar los casos extremos; responder más rápido puede reducir la calidad de la revisión. Por ello, los objetivos suelen ser múltiples y parcialmente conflictivos.

Una formulación multicriterio puede representar el valor de una solución m como:

$$J(m) = w_1 Q(m) - w_2 C(m) - w_3 R(m),$$

donde Q mide calidad, C costo y R riesgo. Los pesos w_j no son propiedades matemáticas naturales: expresan prioridades que deben acordarse y documentarse.

Criterios SMART y límites de su aplicación

Los objetivos suelen formularse como específicos, medibles, alcanzables, relevantes y acotados en el tiempo. “Reducir en seis meses el tiempo mediano de atención de reclamos prioritarios” es más evaluable que “mejorar la atención”. Sin embargo, medir no garantiza que el indicador represente bien el objetivo. Si solo se mide rapidez, el sistema puede cerrar casos sin resolverlos. Toda métrica puede convertirse en un objetivo imperfecto y alterar el comportamiento de quienes la optimizan.

Por eso conviene acompañar cada objetivo con métricas de control. Si se busca velocidad, se controla calidad; si se busca cobertura, se controla tasa de errores; si se busca ahorro, se controla seguridad y equidad.

Objetivos de actores diferentes

Un proyecto rara vez tiene un único interesado. La dirección puede buscar reducir costos; los operadores, recibir pocas alertas y bien justificadas; los usuarios, continuidad del servicio; el área legal, cumplimiento; el equipo técnico, estabilidad. Estos objetivos pueden entrar en conflicto.

El trabajo de formulación no consiste en ocultar el conflicto dentro de una media ponderada. Primero se identifican condiciones no negociables y luego se comparan compromisos. Una reducción de costo que aumenta riesgo de seguridad por encima del límite no es una alternativa válida, aunque maximice un índice global.

Una matriz de objetivos ayuda a explicitar la gobernanza:

Actor	Objetivo	Indicador	Restricción o temor
Operaciones	Priorizar trabajo útil	Intervenciones confirmadas	Saturación de alertas
Dirección	Reducir pérdidas	Volumen evitado	Costo total

Actor	Objetivo	Indicador	Restricción o temor
Comunidad	Mantener servicio	Horas sin interrupción	Distribución desigual
Auditoría	Justificar decisiones	Casos trazables	Opacidad

El criterio final debe ser aprobado por quienes poseen autoridad y responsabilidad, no inferido por el equipo a partir de la disponibilidad de métricas.

2.1.3. Unidad de análisis, población y alcance

La **unidad de análisis** es la entidad elemental sobre la cual se realizan descripciones, predicciones o decisiones. En una tabla suele corresponder al significado de una fila, aunque una unidad puede necesitar varias tablas. En movilidad puede ser un viaje, una parada, una zona por hora o un vehículo por día. En agua puede ser una lectura de sensor, un tramo de tubería o una zona por intervalo.

Elegir la unidad determina:

- qué constituye una observación;
- cuáles son las claves válidas;
- cómo se agregan los datos;
- qué dependencias existen entre filas;
- cómo deben realizarse las particiones de evaluación;
- a qué nivel se ejecutará la decisión.

Si la decisión asigna recursos a zonas, pero el modelo produce predicciones por sensor, debe definirse cómo se combinan sensores en una prioridad zonal. Si varias mediciones pertenecen a la misma tubería, tratarlas como independientes puede producir intervalos demasiado estrechos y particiones contaminadas.

Población, muestra y población de despliegue

La **población objetivo** contiene las unidades sobre las que se desea generalizar. La **muestra observada** contiene las unidades disponibles para el análisis. La **población de despliegue** contiene las unidades que encontrará el sistema cuando se utilice. Idealmente coinciden en sus propiedades relevantes, pero en la práctica pueden diferir.

Sea $P_T(X, Y)$ la distribución de la población de entrenamiento y $P_D(X, Y)$ la de despliegue. Si $P_T \neq P_D$, el desempeño estimado puede no transferirse. La diferencia puede surgir por cobertura geográfica, selección de usuarios, cambios estacionales, nuevas políticas o modificaciones en sensores.

La representatividad no depende solo del tamaño. Un millón de registros de un único tipo de zona puede representar peor a la ciudad que una muestra más pequeña diseñada para cubrir su diversidad. Deben documentarse mecanismos de inclusión y exclusión.

Alcance y fronteras del sistema

El alcance define periodos, lugares, tipos de casos, usuarios y acciones incluidas. También establece exclusiones. Un sistema puede diseñarse para alertas operativas y no para sanciones; para condiciones normales y no para emergencias; para zonas instrumentadas y no para toda la red.

Declarar el alcance evita que una herramienta sea reutilizada en decisiones para las que no fue evaluada. La ampliación posterior requiere nueva evidencia, no solo una modificación de interfaz.

Muestreo, cobertura y dependencia

Cuando no se observa toda la población, debe entenderse cómo se produjo la muestra. Un muestreo probabilístico permite estimar probabilidades de inclusión; una muestra por conveniencia refleja accesibilidad. Los registros administrativos suelen ser censos del sistema, pero no de la realidad: contienen todos los eventos registrados, no todos los eventos ocurridos.

Si cada unidad i tiene probabilidad de inclusión π_i , una muestra con probabilidades desiguales puede requerir ponderaciones $w_i = 1/\pi_i$. Sin embargo, ponderar no corrige variables ausentes ni poblaciones sin posibilidad de inclusión. La documentación del mecanismo sigue siendo indispensable.

La dependencia entre unidades también define la evaluación. Varias filas de una persona, planta, vehículo o zona comparten factores. Separarlas aleatoriamente puede colocar información casi idéntica en entrenamiento y prueba. El protocolo debe agrupar por la entidad cuya generalización interesa. Si el sistema se usará en zonas nuevas, la prueba debe contener zonas no vistas; si se usará en días futuros de las mismas zonas, la separación debe ser temporal.

Una práctica recomendable es redactar una **declaración de generalización**: “el resultado pretende aplicarse a , **bajo las condiciones** , durante ; **no se ha evaluado en** ”. Esta frase obliga a convertir la palabra “generaliza” en una afirmación verificable.

2.1.4. Variables de entrada, resultados y restricciones

Una variable es una representación de una propiedad. Para utilizarla deben conocerse significado, unidad, procedencia, instante de disponibilidad y relación con la unidad de análisis.

Las **variables de entrada** X contienen información disponible antes de producir la salida. La **variable resultado** Y representa lo que se intenta estimar. Una **acción** A es una intervención posible. Las **restricciones** C delimitan el conjunto de soluciones factibles.

Una especificación compacta es:

$$\mathcal{P} = (U, \mathcal{R}, X, Y, A, H, C),$$

donde U es la unidad, $\mathcal{R}$ la población, H el horizonte y los demás símbolos conservan el significado anterior.

Disponibilidad y legitimidad de las entradas

Que una variable exista en la base no significa que pueda usarse. Puede conocerse después de la decisión, contener información sensible, derivarse de la etiqueta o no estar disponible en producción. Para cada entrada conviene preguntar:

1. ¿cuándo se genera?;
2. ¿quién la registra?;
3. ¿estará disponible con la misma calidad?;
4. ¿es legítimo utilizarla para este propósito?;
5. ¿puede cambiar como consecuencia del propio sistema?

La última pregunta es importante. Si un modelo prioriza zonas y las inspecciones generan más registros allí, los datos futuros reflejarán la política del modelo. La observación deja de ser pasiva y aparece un ciclo de retroalimentación.

Resultado observado y constructo

El **constructo** es el concepto que interesa; la **etiqueta** es su representación observada. “Riesgo”, “calidad”, “urgencia” o “satisfacción” no se observan directamente. Se aproximan mediante reglas, mediciones o decisiones humanas.

Una etiqueta de fuga confirmada puede depender de que una zona haya sido inspeccionada. Las zonas nunca visitadas no tienen necesariamente ausencia de fuga; tienen ausencia de confirmación. Confundir ambos estados introduce sesgo de selección.

Restricciones duras y blandas

Una restricción dura no puede violarse: capacidad física, presupuesto máximo, normativa o seguridad. Una restricción blanda representa una preferencia cuyo incumplimiento tiene costo. En optimización puede formularse:

$$\min_a \text{Costo}(a) + \lambda \text{ Penalización}(a)$$

sujeto a restricciones obligatorias. La separación ayuda a evitar recomendaciones matemáticamente atractivas pero imposibles de ejecutar.

Protocolo de construcción de la etiqueta

La variable objetivo merece un documento propio. Debe establecer quién asigna la etiqueta, con qué evidencia, en qué momento, qué opciones existen, cómo se resuelven desacuerdos y qué significa un caso sin etiqueta. Si participan expertos, conviene medir acuerdo y revisar ejemplos ambiguos.

Una etiqueta puede cambiar después de una apelación o una prueba adicional. En ese caso se necesita versión y fecha de vigencia. Entrenar con la versión final puede ser correcto para aprender el estado real, pero una característica construida durante la revisión podría no estar disponible al inicio.

La calidad de la etiqueta impone un techo práctico. Si expertos coinciden solo en 80 % de los casos porque el concepto es ambiguo, exigir al modelo una exactitud casi perfecta puede indicar fuga o una evaluación que no representa la dificultad

real. El desacuerdo no siempre debe eliminarse: puede definir una clase incierta o una regla de derivación humana.

En problemas prescriptivos, las acciones también necesitan representación. No basta con predecir Y ; debe conocerse qué acciones son factibles para cada unidad y cómo modifican costos o resultados. Esta información suele estar en sistemas operativos distintos del dataset analítico.

2.1.5. Criterios de éxito y línea de base

Los criterios de éxito deben fijarse antes de observar los resultados finales. De lo contrario, existe el riesgo de seleccionar retrospectivamente la métrica que favorece al modelo. Un criterio completo combina cuatro dimensiones:

- desempeño técnico;
- utilidad operativa;
- viabilidad de implementación;
- seguridad y uso responsable.

Para un sistema de alertas puede exigirse sensibilidad mínima, límite de falsas alarmas por día, latencia inferior a una hora y ausencia de degradación grave entre zonas. Ninguna métrica aislada resume esas condiciones.

Línea de base

La **línea de base** o *baseline* es el procedimiento de referencia contra el que se evalúa una propuesta. Puede ser:

- una regla institucional vigente;
- la clase mayoritaria;
- el promedio histórico;
- el último valor observado;
- un pronóstico estacional ingenuo;
- una asignación aleatoria o proporcional;
- un modelo sencillo e interpretable.

El baseline cumple funciones científicas y organizacionales. Permite saber si la complejidad aporta valor, detectar errores de implementación y comunicar la magnitud real de la mejora. Superar una línea de base débil no es suficiente si existe una regla simple más pertinente.

Costos de error y umbrales

En clasificación, los falsos positivos y falsos negativos rara vez tienen el mismo costo. Si C_{FP} y C_{FN} son esos costos, el costo esperado puede expresarse como:

$$EC = C_{FP} P(FP) + C_{FN} P(FN).$$

El umbral debe elegirse considerando esta función y la capacidad operativa. Un sistema que produce mil alertas correctas por día puede ser inútil si solo pueden revisarse veinte.

Criterios de detención

No todo proyecto debe llegar al despliegue. Se debe detener o reformular cuando los datos no representan el objetivo, el desempeño no supera el baseline, el impacto esperado no compensa costos, no existe proceso de uso o los riesgos no pueden controlarse. Detener temprano es una conclusión válida y valiosa.

Diseño de una tabla de aceptación

Los criterios se vuelven operativos cuando se expresan como condiciones verificables. Por ejemplo:

Dimensión	Condición de aceptación	Evidencia
Predicción	Mejora al baseline en validación temporal	Intervalo de métricas
Capacidad	No más de 20 alertas diarias	Simulación histórica
Equidad	Diferencias justificadas y controladas	Evaluación por zona
Latencia	Resultado antes de las 7:00	Prueba de extremo a extremo
Trazabilidad	Toda alerta conserva entradas y versión	Auditoría de casos

Las condiciones deben incluir tolerancias. Una diferencia de una centésima puede ser ruido, no mejora. Cuando es posible, se reporta incertidumbre mediante repeticiones, intervalos o análisis de sensibilidad.

También conviene distinguir **criterio de selección** y **criterio de aceptación**. El primero elige el mejor candidato entre los estudiados; el segundo determina si ese candidato es suficientemente bueno para avanzar. Siempre existe un “mejor” modelo dentro de una lista, aunque todos sean inadecuados.

2.1.6. Ejemplo práctico guiado: formulación de un problema de mantenimiento ferroviario

Situación inicial

Una operadora ferroviaria desea reducir fallas que obligan a limitar la velocidad o interrumpir el servicio. Dispone de mediciones de vibración tomadas por vehículos instrumentados, temperatura de componentes próximos a la vía, inspecciones visuales, historial de intervenciones y características de cada tramo. Solo cuenta con tres cuadrillas y cada una puede revisar como máximo cuatro tramos durante el turno nocturno.

La necesidad inicial, “mejorar el mantenimiento”, es demasiado amplia. Después de entrevistar a responsables de infraestructura y planificación, el equipo fija una decisión concreta: al cierre de cada jornada, ordenar los tramos candidatos y asignar hasta doce inspecciones para la noche siguiente.

Formulación paso a paso

Unidad de análisis: tramo de vía de 500 metros por día. Esta unidad conserva una referencia espacial estable y coincide con el nivel al que se emite la orden de trabajo. Las mediciones obtenidas dentro del tramo se agregan sin perder su instante de captura ni el vehículo de origen.

Población y alcance: tramos activos de las líneas instrumentadas durante los últimos tres años. Se excluyen playas de maniobras y sectores en renovación, cuyos regímenes de operación y registro no son comparables. La evaluación debe informar por separado líneas urbanas, interurbanas y tramos con cobertura sensorica incompleta.

Horizonte de decisión y predicción: se emplea información disponible hasta las 18:00 para decidir inspecciones del turno nocturno y estimar si se confirmará un defecto que requiera intervención en los siete días siguientes. El horizonte permite coordinar recursos, pero obliga a distinguir una alerta preventiva de una incidencia que exige actuación inmediata por protocolo.

Pregunta descriptiva: ¿cómo varían la vibración, la temperatura, la frecuencia de inspecciones y los defectos registrados según tramo, carga acumulada, tipo de infraestructura y época del año?

Pregunta predictiva: ¿cuál es la probabilidad de confirmar en cada tramo un defecto relevante durante los próximos siete días, utilizando solo datos conocidos a las 18:00?

Pregunta prescriptiva: ¿qué conjunto de hasta doce tramos conviene inspeccionar para maximizar el riesgo esperado cubierto, respetando tiempos de traslado, ventanas de acceso y competencias de las cuadrillas?

Resultado y etiqueta: el resultado positivo es un defecto confirmado por inspección que exige reparación, restricción temporal o seguimiento reforzado. La etiqueta está sesgada: los tramos con señales llamativas, acceso sencillo o antecedentes reciben más inspecciones y, por tanto, más oportunidades de confirmación. Los tramos no inspeccionados no deben codificarse automáticamente como negativos; constituyen resultados no observados.

Entradas disponibles: estadísticas de vibración por bandas de frecuencia, cambios respecto del patrón histórico del tramo, máximos y persistencia de temperatura, tonelaje acumulado, velocidad de paso, geometría, antigüedad de componentes, inspecciones e intervenciones previas y tiempo desde la última revisión. Se excluyen el informe de la inspección futura, la orden de reparación y cualquier variable actualizada después de la fecha de corte.

Baselines: el primero reproduce la regla vigente, que prioriza los tramos con más días desde la última inspección. El segundo ordena por el mayor incremento normalizado de vibración durante las últimas 72 horas. Un tercero combina reglas de seguridad definidas por especialistas, sin aprendizaje estadístico. Estos referentes representan alternativas realmente disponibles, no modelos deliberadamente débiles.

Métricas: se evaluarán calibración y sensibilidad, además de precisión entre los primeros doce tramos del ranking (Precision@12) y proporción de defectos confirmados cubierta (Recall@12). En el plano operativo se medirán horas de cuadrilla, kilómetros de traslado, inspecciones sin hallazgo, estabilidad diaria del ranking y tiempo entre alerta e intervención. En seguridad se informarán por separado los defectos críticos omitidos y el desempeño por línea y nivel de cobertura sensorica.

Restricciones y aceptación: ninguna recomendación puede reemplazar una regla obligatoria de seguridad. El plan debe limitarse a tres cuadrillas, doce inspecciones, las ventanas nocturnas autorizadas y las competencias disponibles;

también debe entregar resultados antes de las 19:00 y conservar las mediciones y la versión que originaron cada prioridad. Se aceptará avanzar solo si la validación temporal supera la regla vigente en defectos relevantes cubiertos sin aumentar horas de trabajo ni concentrar sistemáticamente la atención en los tramos mejor instrumentados.

Pseudocódigo de la formulación

```
identificar usuario, decisión y protocolos que prevalecen  
definir tramo, fecha de corte y horizonte de siete días  
inventariar señales disponibles antes de las 18:00  
documentar cómo la inspección produce etiquetas sesgadas  
separar negativos confirmados de resultados no observados  
enumerar cuadrillas, accesos y planes factibles  
comparar reglas vigentes con candidatos bajo cortes temporales  
medir desempeño predictivo, carga operativa y riesgo de seguridad  
registrar exclusiones, supuestos y criterios de detención
```

El ejemplo muestra que formular no equivale a solicitar “un modelo de fallas”. La unidad determina la tabla analítica; la fecha de corte evita conocimiento futuro; el horizonte define qué resultado es útil; y la capacidad de las cuadrillas convierte un puntaje de riesgo en una decisión de asignación.

Análisis de sensibilidad de la formulación

Antes de modelar, el equipo estudia otras unidades y horizontes. Una unidad vehículo-tramo produciría varias observaciones para el mismo lugar y podría sobrerrepresentar los recorridos más frecuentes. Un tramo de cinco kilómetros facilitaría la planificación, pero ocultaría señales localizadas. Un horizonte de 24 horas favorecería incidencias inminentes; uno de treinta días admitiría programación preventiva, aunque con mayor incertidumbre. Cada alternativa cambia el significado de la predicción y debe evaluarse contra la acción prevista.

También se analiza el mecanismo de confirmación. Entrenar solo con tramos inspeccionados estima riesgo dentro de una población seleccionada, no necesariamente en toda la red ferroviaria. Para reducir esa limitación se puede reservar una pequeña cuota de inspecciones aleatorias entre tramos elegibles, registrar por qué se inspeccionó cada caso y comparar la cobertura entre observados y no observados. La exploración debe ser compatible con las normas de seguridad y nunca desplazar revisiones obligatorias.

Por último, se simulan rutas y capacidad con datos históricos. Si una clasificación de alta calidad exige más visitas de las que pueden realizarse, el objetivo no será “detectar todos los defectos”, sino cubrir la mayor cantidad de riesgo bajo restricciones explícitas. Si ningún candidato mejora los baselines de manera estable o si la evaluación revela brechas no controlables entre líneas, el proyecto debe regresar a la obtención de datos o detener el despliegue.

Actividad EMO [AGUA-01]: formular el problema y la decisión operativa

Capacidad mínima: convertir una necesidad de gestión del agua en una tarea analítica verificable y conectarla con una decisión concreta.

Consigna: seleccionar una necesidad del caso de agua y elaborar una ficha que contenga usuario, decisión, unidad, población, alcance, preguntas descriptiva, predictiva y prescriptiva, variable objetivo, entradas disponibles, restricciones, baseline y criterios de éxito.

Modalidad de trabajo: preparación individual y contraste breve entre pares. El intercambio debe buscar inconsistencias, no uniformar respuestas.

Evidencia individual: documento de una página más un anexo con diccionario preliminar de variables y diagrama necesidad -> evidencia -> acción -> impacto.

Criterios de aprobación:

- la tarea computacional responde a la pregunta y la decisión;
- la unidad de análisis coincide con el nivel de acción;
- la etiqueta y su proceso de producción están definidos;
- las entradas estarán disponibles al decidir;
- el baseline representa una alternativa realista;
- los supuestos, exclusiones, afectados y límites están explícitos.

Preguntas para la defensa: ¿qué ocurriría si faltaran sensores en las zonas de mayor riesgo?, ¿qué variable produciría fuga de información?, ¿qué resultado haría abandonar el proyecto?, ¿quién es responsable de la decisión final?

2.2. Metodologías para proyectos de datos

Las metodologías ofrecen un vocabulario para organizar actividades, entregables y revisiones. No sustituyen el razonamiento ni garantizan calidad por sí mismas. Su valor reside en hacer visibles tareas que podrían omitirse si el equipo se concentrara exclusivamente en modelar.

2.2.1. Proceso KDD

KDD significa *Knowledge Discovery in Databases*, descubrimiento de conocimiento en bases de datos. Surgió para describir el proceso más amplio dentro del cual la minería de datos es solo una etapa. Sus componentes habituales son selección, preprocesamiento, transformación, minería e interpretación/evaluación.

Selección

Se identifican fuentes, variables, periodos y unidades relevantes. Seleccionar no es copiar todo lo disponible: implica justificar qué datos pueden aportar evidencia y qué restricciones de acceso o uso existen.

Preprocesamiento

Se estudian calidad, faltantes, errores, duplicados y consistencia. Las decisiones deben conservar trazabilidad. La limpieza no persigue una tabla estéticamente perfecta, sino una representación válida para el objetivo.

Transformación

Se cambia la representación mediante agregación, codificación, escalado, extracción de características o reducción de dimensionalidad. Cada transformación introduce supuestos sobre qué información conservar.

Minería de datos

Se aplican métodos para encontrar patrones: reglas, grupos, asociaciones, predicciones o anomalías. El patrón es un resultado computacional, no todavía conocimiento.

Interpretación y evaluación

Se determina si el patrón es válido, novedoso, comprensible y útil. Una asociación frecuente puede ser trivial; un cluster bien separado puede no tener significado operativo; una predicción precisa puede no modificar ninguna acción.

KDD destaca que el conocimiento emerge de la interacción entre datos, método y contexto. También enfatiza la iteración: una regla inesperada puede revelar un error de codificación y obligar a volver al preprocesamiento.

Del patrón al conocimiento

En proyectos reales conviene clasificar el estado epistemológico de cada hallazgo. Un **resultado** es una salida calculada; un **patrón** es una regularidad observada; una **hipótesis** propone una explicación o expectativa; un **hallazgo validado** ha resistido controles definidos; una **regla operativa** ha sido aprobada para orientar acciones. Saltar directamente de patrón a regla es una fuente frecuente de daño.

Supóngase que los reclamos aumentan antes de las fugas confirmadas. El patrón puede reflejar una señal temprana, pero también mayor propensión a inspeccionar zonas con reclamos. Para utilizarlo se necesita comprobar temporalidad, cobertura y estabilidad. KDD obliga a interpretar la regularidad dentro de su proceso de generación.

La novedad también es contextual. Un algoritmo puede descubrir que la demanda aumenta en hora pico, un patrón estadísticamente fuerte pero conocido por cualquier operador. El proyecto debe valorar si confirma conocimiento, lo cuantifica mejor o revela una estructura capaz de modificar decisiones.

Una revisión KDD debería preguntar: ¿el patrón aparece en particiones independientes?, ¿puede explicarse por calidad o selección?, ¿es comprensible para el dominio?, ¿permite una acción?, ¿qué evidencia podría refutarlo? Estas preguntas transforman minería en aprendizaje institucional.

2.2.2. Metodología CRISP-DM

CRISP-DM, *Cross-Industry Standard Process for Data Mining*, organiza el proyecto en seis fases: comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue.

Comprensión del negocio

Define necesidad, usuarios, decisiones, riesgos, criterios de éxito, recursos y plan. Su entregable principal no es un modelo, sino una especificación compartida del problema.

Comprensión de los datos

Construye inventario, descripción, perfil de calidad y primeras hipótesis. El equipo verifica si la información necesaria existe y si representa la población objetivo.

Preparación de los datos

Selecciona, integra, limpia y transforma. Suele consumir gran parte del esfuerzo porque debe reconciliar fuentes creadas para fines distintos. El producto es un dataset analítico versionado junto con su procedimiento de construcción.

Modelado

Define protocolo de evaluación, baseline, familias de modelos e hiperparámetros. El protocolo debe preceder a la comparación para evitar que la prueba se convierta en herramienta de selección.

Evaluación

Verifica desempeño técnico y correspondencia con el objetivo. Incluye análisis de errores, sensibilidad, subgrupos, costos y condiciones de uso. La pregunta no es solo “¿funciona el modelo?”, sino “¿resuelve el problema formulado con riesgo aceptable?”.

Despliegue

Integra el resultado en un proceso, establece responsables, monitoreo, actualización y retirada. El despliegue puede ser un informe periódico, un tablero, una API o una regla incorporada a una operación; no implica necesariamente automatización en tiempo real.

CRISP-DM es cíclico. La evaluación puede mostrar que se necesita otra variable; el despliegue puede cambiar la distribución de datos; una nueva normativa puede modificar el objetivo. Cada retorno debe registrar qué evidencia motivó la revisión.

Puertas de decisión entre fases

CRISP-DM funciona mejor cuando cada transición posee una puerta de decisión. No se avanza a preparación porque “ya se exploró bastante”, sino porque existe evidencia mínima: unidad definida, cobertura conocida, fuentes autorizadas y problemas críticos identificados. No se avanza a despliegue porque un modelo obtuvo la mejor métrica, sino porque cumple criterios operativos y de riesgo.

Las puertas evitan dos extremos. El primero es avanzar con incertidumbres que invalidarán el trabajo posterior. El segundo es buscar certeza imposible y no experimentar nunca. La evidencia requerida debe ser proporcional al costo de la siguiente fase y al riesgo de equivocarse.

Documentos vivos

Los entregables no son informes congelados. La ficha del problema, el diccionario, la tarjeta del modelo y el plan de monitoreo evolucionan con versiones. Cuando cambia una definición, se registra qué artefactos quedan afectados. Esta disciplina permite distinguir una iteración legítima de una inconsistencia.

Relación con operación y MLOps

CRISP-DM suele describirse hasta “despliegue”, pero un sistema operativo necesita monitoreo, gestión de incidentes, reentrenamiento y retirada. Estas prácticas se asocian con MLOps, aunque sus principios son más generales: automatizar lo repetible, verificar contratos, versionar artefactos y observar comportamiento. No deben agregarse al final; los requisitos de operación influyen desde la formulación.

2.2.3. Ciclos iterativos y enfoques ágiles

Un enfoque iterativo divide una iniciativa incierta en ciclos pequeños. Cada ciclo formula una hipótesis, produce un artefacto verificable y obtiene retroalimentación. En proyectos de datos, los artefactos tempranos pueden ser un mapa de fuentes, una auditoría, un baseline o una simulación de la decisión.

La iteración reduce el riesgo de invertir meses en una solución técnicamente sofisticada que nadie puede usar. Sin embargo, “ágil” no significa improvisado. Para aprender entre iteraciones deben mantenerse versiones, criterios y registros.

Una iteración puede expresarse como:

- seleccionar la incertidumbre más importante
- formular una hipótesis verificable
- definir evidencia y criterio de decisión
- construir el artefacto mínimo necesario
- evaluar y registrar resultados
- decidir: continuar, modificar, escalar o detener

Producto mínimo viable y producto mínimo evaluable

En software se habla de producto mínimo viable. En datos conviene distinguir un **producto mínimo evaluable**: la implementación más pequeña que permite probar un supuesto crítico. Si se desconoce si los sensores cubren suficientes eventos, el primer producto no debe ser un clasificador, sino un análisis de cobertura.

La prioridad se asigna por riesgo de conocimiento. Las preguntas que podrían invalidar el proyecto deben estudiarse antes que las mejoras de interfaz o rendimiento.

Deuda técnica y deuda analítica

La velocidad puede generar deuda técnica: código duplicado, dependencias no registradas o procesos manuales frágiles. También existe deuda analítica: definiciones ambiguas, métricas elegidas después de observar resultados,

datasets sin versión o supuestos no documentados. Ambas deudas encarecen cada iteración posterior.

Organizar un backlog de incertidumbres

En software, un backlog suele contener funcionalidades. En datos debe contener también incertidumbres. Cada elemento puede formularse como: “No sabemos si ; **lo comprobaremos mediante** ; decidiremos ___ si observamos ___”. Esta estructura evita tareas genéricas como “mejorar el modelo”.

Las incertidumbres pueden priorizarse por:

Prioridad $\approx$ Probabilidad de fallo $\times$ Impacto $\times$ Costo de descubrirlo tarde.

Por ejemplo, desconocer la licencia de una fuente tiene alta prioridad porque puede impedir su uso completo. Ajustar el color de un tablero tiene menor prioridad antes de demostrar que los datos llegan a tiempo.

Criterio de terminado

Cada incremento necesita una definición de terminado. Para un perfil puede ser: fuente versionada, reglas ejecutadas, hallazgos revisados por dominio y limitaciones registradas. Para un baseline: pipeline reproducible, partición correcta, métricas y análisis de errores. “El notebook corre en mi equipo” no es suficiente.

La revisión de iteración debe separar lo construido, lo aprendido y lo decidido. Un ciclo puede producir poco código y mucho aprendizaje útil. Medir avance solo por cantidad de funcionalidades incentiva construir antes de entender.

2.2.4. Hipótesis, experimentación y retroalimentación

Una hipótesis es una afirmación que puede contrastarse con evidencia. Debe especificar población, variables, comparación y resultado esperado. “La presión influye en las fugas” es ambigua. “En zonas instrumentadas, una caída de presión superior al patrón horario se asocia con mayor proporción de fugas confirmadas durante las siguientes 24 horas” es más precisa.

No todas las hipótesis son causales. Una hipótesis predictiva puede afirmar que una variable mejora generalización sin sostener que causa el resultado. Separar asociación, predicción y causalidad evita interpretaciones excesivas.

Diseño de un experimento analítico

Un registro de experimento debe contener:

- pregunta e hipótesis;
- versión de datos y población;
- partición y unidad de separación;
- procedimiento y parámetros;
- métricas principales y auxiliares;
- resultado con incertidumbre;

- errores observados;
- conclusión y decisión siguiente.

La comparación justa mantiene constantes los factores no estudiados. Si se comparan dos modelos, deben usar las mismas particiones y reglas de preprocesamiento pertinentes. Si se comparan dos representaciones, debe controlarse el modelo o declarar que se compara el pipeline completo.

Retroalimentación

La retroalimentación puede provenir de métricas, usuarios, errores, monitoreo o cambios del entorno. Debe traducirse en una decisión verificable. “A los usuarios no les gusta” necesita descomponerse: ¿la salida llega tarde?, ¿no se entiende?, ¿genera trabajo adicional?, ¿contradice conocimiento local?

Los resultados negativos son información. Si un modelo no supera el baseline, puede indicar falta de señal, etiqueta inadecuada o pregunta mal formulada. Ocultarlos conduce a repetir experimentos y sobreestimar evidencia.

Hipótesis operativas y analíticas

Una hipótesis analítica afirma algo sobre datos o desempeño. Una hipótesis operativa afirma algo sobre uso: “si la alerta se presenta con evidencia y antes de las 7:00, el operador modificará la ruta”. Ambas deben probarse. Un sistema puede superar validación y fracasar porque la salida no encaja en el flujo de trabajo.

Las pruebas operativas incluyen prototipos, modo sombra, simulaciones y estudios con usuarios. No necesitan esperar al modelo final. Una maqueta con prioridades históricas puede revelar que el operador necesita ver tendencia y procedencia antes de confiar.

Incertidumbre experimental

Una única métrica es una realización. Deben considerarse variación por muestra, semilla, periodo y subgrupo. Si dos alternativas difieren menos que esa variación, declarar un ganador definitivo es excesivo. Se pueden reportar distribuciones, intervalos y estabilidad de ranking.

También se debe controlar la multiplicidad informal. Probar decenas de configuraciones y comunicar solo la mejor sobreestima el desempeño esperado. El registro completo y una prueba reservada limitan este sesgo de selección.

Aprender de los errores

El análisis de errores agrupa fallos por mecanismo: información insuficiente, etiqueta dudosa, población nueva, transformación incorrecta o decisión de umbral. Esta taxonomía orienta acciones. No todos los errores se corrigen con un modelo más complejo; algunos requieren mejores datos o abstención.

2.2.5. Roles dentro de un equipo de datos

Un proyecto interdisciplinario necesita competencias distintas. Los nombres varían entre organizaciones, pero las responsabilidades principales permanecen.

Rol o responsabilidad	Pregunta principal	Entregables habituales
Responsable del dominio	¿Qué significa el problema y qué restricciones existen?	Definiciones, reglas y validación contextual
Responsable del producto o decisión	¿Quién usará el resultado y qué valor debe producir?	Prioridades, criterios y proceso de uso
Analista de datos	¿Qué muestran los datos y cómo comunicarlo?	Perfiles, análisis y visualizaciones
Ingeniería de datos	¿Cómo obtener datos confiables y repetibles?	Pipelines, esquemas y controles
Ciencia de datos	¿Qué representación y modelo responden la pregunta?	Experimentos, modelos y evaluación
Ingeniería de ML/software	¿Cómo operar el sistema de forma confiable?	Servicios, pruebas, despliegue y monitoreo
Seguridad, privacidad y legal	¿Qué usos y controles son aceptables?	Evaluaciones, permisos y salvaguardas
Usuarios y afectados	¿Cómo funciona la solución en la práctica?	Retroalimentación y criterios de aceptación

En equipos pequeños una persona puede cubrir varios roles, pero las preguntas no deben omitirse. Debe existir una asignación explícita de quién aprueba datos, métricas, despliegue y cambios.

Responsabilidad y decisión final

El modelo no es responsable. La organización debe definir quién interpreta, quién autoriza acciones, quién atiende incidentes y quién puede detener el sistema. La participación humana no garantiza supervisión efectiva si la persona no tiene tiempo, información o autoridad para contradecir la recomendación.

Lenguaje compartido

Los equipos suelen utilizar la misma palabra con significados distintos. “Cliente activo”, “fuga”, “resuelto” o “zona crítica” deben registrarse en un glosario. Una definición operacional debe indicar cómo se observa y no solo su interpretación intuitiva.

Matriz de responsabilidades

Una práctica útil es asignar para cada decisión quién es responsable de ejecutar, quién aprueba, quién debe ser consultado y quién informado. La matriz evita que una decisión crítica quede implícitamente en manos de quien escribió el último código.

Por ejemplo, ingeniería de datos puede ejecutar un cambio de esquema; ciencia de datos evalúa su efecto; dominio valida significado; producto aprueba el uso; seguridad revisa acceso. Una persona puede ocupar varias posiciones, pero la secuencia de revisión queda visible.

Tensiones saludables

Los desacuerdos entre roles no son un obstáculo a eliminar. El experto de dominio puede detectar una simplificación inválida; el ingeniero puede advertir que una variable no estará disponible; el usuario puede mostrar que una explicación no sirve bajo presión. Un proceso maduro convierte estas tensiones en criterios verificables.

La colaboración requiere artefactos compartidos: ficha del problema, diccionario, ejemplos de casos, tablero de experimentos y registro de decisiones. Las reuniones sin artefactos producen acuerdos difíciles de auditar.

Competencia y revisión

Los resultados sensibles deben contar con revisión independiente. Quien diseña una regla tiende a conocer sus casos favorables. Una revisión por pares intenta reproducir, desafiar supuestos y buscar escenarios de fallo. La revisión no transfiere responsabilidad; mejora la evidencia con la que se decide.

2.2.6. Ejemplo práctico guiado: diseño de un ciclo CRISP-DM

Una empresa de servicios técnicos quiere priorizar el mantenimiento de ascensores en cientos de edificios. Dispone de sensores instalados en parte de los equipos, avisos de servicio enviados por administradores y usuarios, e historiales de mantenimiento. CRISP-DM permite organizar el proyecto sin tratar el modelado como una actividad aislada.

Comprensión del problema

El equipo define una decisión diaria: seleccionar los ascensores que recibirán mantenimiento preventivo durante los próximos siete días, además de las atenciones urgentes exigidas por contrato o seguridad. La unidad de decisión es ascensor-semana y la salida será una lista priorizada con motivo, nivel de riesgo y fecha sugerida. Los usuarios directos son planificadores y técnicos; residentes, visitantes y personal de los edificios son actores afectados.

Se documentan capacidad, competencias, repuestos, horarios de acceso, tiempos de traslado y acuerdos de nivel de servicio. El éxito no se formula como “predecir averías”, sino como reducir inmovilizaciones y rescates sin aumentar horas extraordinarias ni demorar avisos urgentes. La regla vigente, basada en periodicidad y antigüedad, queda registrada como baseline operativo.

Comprensión de los datos

Se inventarían tres fuentes principales. Los sensores registran ciclos de puerta, vibración del motor, temperatura, consumo eléctrico y códigos de error; los avisos de servicio contienen fecha, canal, texto libre, equipo asociado y urgencia declarada; los historiales describen visitas, diagnósticos, piezas sustituidas, duración y resultado. Se verifican propietarios, cobertura temporal, identificadores y disponibilidad de cada campo antes de planificar.

El perfil revela que no todos los ascensores tienen los mismos sensores, algunos identificadores cambiaron después de modernizaciones y un mismo aviso puede

duplicarse por varios canales. También muestra que las averías se confirman con mayor frecuencia en equipos que recibieron una visita. Por ello, ausencia de diagnóstico no se interpreta automáticamente como ausencia de problema, y se conserva el motivo que originó cada intervención.

Preparación

Se construye una tabla ascensor-semana con fecha de corte reproducible. Las señales se resumen mediante niveles, tendencias, variabilidad y frecuencia de códigos; los avisos se deduplican y se representan con categorías verificables; los historiales producen variables como días desde la última visita, reincidencias y vida útil estimada de componentes. Las modernizaciones se tratan como cambios de configuración, no como continuidad silenciosa de la serie.

La integración valida cardinalidades para evitar que varios avisos multipliquen artificialmente los ciclos sensóricos. Los parámetros de imputación, vocabularios y escalas se ajustan solo con el periodo de entrenamiento. El pipeline conserva indicadores de dato ausente y de cobertura, porque la falta de señal puede significar ausencia de dispositivo, desconexión o error de transmisión.

Modelado

Se comparan la regla vigente, una puntuación experta transparente y modelos que estiman la probabilidad de una avería con inmovilización durante los siguientes siete días. La división es temporal y mantiene cada ascensor en un único lado de cada corte cuando se ajustan transformaciones. Los candidatos producen probabilidades calibrables, no una asignación automática de técnicos.

Una segunda etapa convierte el riesgo estimado en un plan factible. Selecciona visitas considerando duración esperada, ubicación, especialidad, disponibilidad de repuestos y compromisos contractuales. Separar predicción y asignación permite comprobar si un fallo proviene de la estimación de riesgo o de las restricciones del planificador.

Evaluación

La evaluación técnica incluye calibración, sensibilidad para averías graves, precisión en las primeras prioridades y desempeño por modelo, antigüedad, fabricante, edificio y cobertura de sensores. La evaluación operativa simula semanas históricas y compara inmovilizaciones cubiertas, rescates, horas de técnicos, traslados, cumplimiento de visitas reglamentarias y estabilidad del plan frente a cambios pequeños.

Especialistas revisan falsos negativos graves, falsos positivos costosos y desacuerdos entre la recomendación y la regla experta. El candidato solo avanza si mejora el baseline en periodos no usados para ajuste, respeta la capacidad y no degrada de forma injustificada los equipos con menor instrumentación. Una métrica global alta no compensa fallos sistemáticos en un grupo relevante.

Despliegue

El primer despliegue funciona en modo sombra: genera un plan, pero los coordinadores continúan usando el procedimiento vigente y registran por qué

aceptarían o rechazarían cada sugerencia. Después se prueba de forma asistida en una región y con aprobación humana. Toda prioridad muestra fecha de corte, señales principales, restricciones aplicadas y versión del pipeline.

Se monitorean disponibilidad y retraso de sensores, volumen y duplicación de avisos, distribución de puntuaciones, tasa de aceptación, averías posteriores, carga por técnico y cambios de cobertura. Los avisos urgentes y las obligaciones reglamentarias mantienen rutas independientes. Existe un procedimiento para retirar el sistema y volver a la regla vigente si faltan datos críticos, se excede la capacidad o empeoran los indicadores de seguridad y servicio.

Matriz de entregables

Fase	Entregable	Pregunta de aprobación
Comprensión del problema	Ficha de decisión y capacidad	¿La prioridad puede convertirse en una visita factible?
Comprensión de datos	Inventario, perfil y mapa de cobertura	¿Sensores, avisos e historiales representan los equipos objetivo?
Preparación	Dataset y pipeline versionados	¿Puede reconstruirse cada fila con datos previos al corte?
Modelado	Baselines, candidatos y asignador	¿Se distinguen estimación de riesgo y planificación?
Evaluación	Informe técnico-operativo	¿Mejora el servicio con riesgo y carga aceptables?
Despliegue	Procedimiento, monitoreo y reversión	¿Hay responsables y una alternativa segura?

La matriz convierte las fases en puntos de control. La existencia de un archivo no basta para aprobar una fase: el entregable debe resolver su pregunta y conservar evidencia para una revisión posterior.

Qué ocurre cuando una fase falla

Durante la comprensión de datos, el equipo descubre que un fabricante registra códigos de error solo cuando el técnico conecta una herramienta durante la visita. Como esa variable no existe al decidir, regresa a preparación y la excluye; además, revisa otras marcas temporales para evitar información futura.

En la evaluación, el candidato parece mejorar globalmente, pero asigna casi todas las visitas a edificios con sensores completos. El equipo vuelve a comprensión de datos para caracterizar la cobertura, a modelado para comparar estrategias compatibles con datos heterogéneos y a comprensión del problema para acordar una cuota de revisión de equipos poco observados. El ciclo evita convertir una limitación de medición en abandono operativo.

Despliegue gradual

El modo sombra permite comparar sin intervenir. La fase asistida presenta prioridades y explicaciones al coordinador; la fase limitada modifica una parte de la agenda en una región; una ampliación solo ocurre después de comprobar desempeño, carga y respuesta ante incidentes. Cada paso tiene duración, población, responsable y criterio de salida definidos de antemano.

La reversión también se ensaya. Si una actualización cambia identificadores, si la latencia impide producir el plan a tiempo o si aumentan las omisiones graves, se suspende la recomendación y se recupera la regla de periodicidad. Operar con seguridad incluye saber cuándo no utilizar el resultado analítico.

Cierre de aprendizaje

Al terminar cada iteración se registran supuestos confirmados, hipótesis rechazadas, cambios de datos, discrepancias con técnicos y decisiones pendientes. También se actualizan el diccionario, los umbrales y los criterios de monitoreo. Así, CRISP-DM funciona como un ciclo de aprendizaje institucional y no como una secuencia que termina al publicar un modelo.

2.3. Fuentes, tipos y arquitectura básica de datos

Los datos no existen de manera independiente al proceso que los produce. Una temperatura proviene de un sensor con rango y calibración; un reclamo existe porque una persona eligió un canal y completó un formulario; una etiqueta de enfermedad puede reflejar el juicio de un experto o una prueba de laboratorio. Conocer la fuente es indispensable para interpretar el contenido.

El inventario de datos debe preceder a su integración. Para cada fuente se documentan propietario, propósito original, unidad, cobertura, método de captura, formato, frecuencia, licencia, sensibilidad, controles de calidad y cambios históricos. Esta información constituye la **procedencia** o *provenance*.

2.3.1. Datos estructurados

Los datos estructurados siguen un esquema explícito. En el modelo relacional, una tabla contiene filas y columnas; una clave primaria identifica registros y una clave foránea relaciona tablas. El esquema define tipos y puede imponer restricciones: valores no nulos, unicidad, dominios e integridad referencial.

Por ejemplo, una tabla viajes puede contener un identificador, origen, destino y horario, mientras una tabla zonas describe geometría y población. La relación se realiza mediante un identificador de zona, no mediante similitud textual del nombre.

La estructura facilita consultas y validación, pero no garantiza calidad semántica. Una columna numérica puede mezclar unidades; una fecha válida puede corresponder al huso horario equivocado; una clave formalmente única puede identificar cargas y no eventos. El esquema físico responde “cómo está almacenado”; el diccionario responde “qué significa”.

Normalización y tablas analíticas

Las bases operativas suelen normalizar entidades para reducir redundancia y conservar integridad. Un análisis puede necesitar desnormalizar temporalmente y construir una tabla analítica. Esa tabla no debe reemplazar la fuente ni perder procedencia. Su construcción debe especificar claves, cardinalidades, filtros y fecha de corte.

Los datos estructurados son apropiados para transacciones y mediciones regulares, pero no todos los fenómenos pueden representarse sin pérdida en una tabla plana. Las relaciones, secuencias e imágenes requieren estructuras adicionales.

Del sistema operativo al dataset analítico

Una base operativa está diseñada para registrar transacciones con consistencia y velocidad. Un dataset analítico está diseñado para responder una pregunta en una fecha de corte. Copiar tablas operativas sin reconstruir el estado histórico puede introducir conocimiento futuro. Por ejemplo, una tabla de clientes que conserva solo la dirección actual no permite saber qué dirección se conocía cuando ocurrió una transacción pasada.

Por eso, las dimensiones que cambian necesitan vigencia o historial. El analista debe decidir si utiliza el valor actual, el valor al momento del evento o ambos. La respuesta depende de la pregunta y debe quedar en la procedencia.

Contratos y evolución de esquema

Un contrato de datos especifica nombres, tipos, unidades, claves, nulabilidad y semántica. Cuando el esquema cambia, se determina si el cambio es compatible. Agregar una columna opcional puede serlo; cambiar la unidad sin cambiar el nombre no lo es.

Las migraciones deben probarse sobre consumidores. Un pipeline que tolera cualquier columna faltante puede continuar ejecutándose y producir resultados incompletos. Fallar temprano ante una ruptura crítica suele ser más seguro que completar silenciosamente con nulos.

2.3.2. Datos semiestructurados

Los datos semiestructurados poseen marcas o claves, pero no siempre un esquema uniforme. JSON, XML, mensajes de eventos y registros de aplicaciones pueden contener objetos anidados, listas y campos opcionales.

Un evento JSON puede incluir fecha, usuario, acción y un objeto detalles cuyo contenido depende del tipo de acción. Dos registros válidos pueden tener campos diferentes. Antes del análisis se debe decidir:

- qué constituye una observación;
- cómo expandir objetos y listas;
- qué diferencia existe entre campo ausente y valor nulo;
- cómo versionar cambios de esquema;
- qué identificadores permiten reconstruir secuencias.

La flexibilidad favorece la captura, pero traslada complejidad a la validación. Un proveedor puede agregar o renombrar una clave sin que el archivo deje de

ser JSON. Si el pipeline ignora campos desconocidos, el cambio puede pasar inadvertido y alterar resultados.

Una práctica robusta conserva el documento original, valida contra un esquema esperado y produce una tabla derivada. Los errores se registran, no se descartan silenciosamente.

Aplanar sin perder significado

Convertir objetos anidados en columnas requiere definir qué hacer con listas. Si un reclamo contiene varias categorías, expandirlo puede producir varias filas y cambiar la unidad. Concatenar categorías conserva una fila, pero crea un campo complejo. Crear una tabla relacional separada suele preservar mejor la relación muchos-a-muchos.

El valor null, una clave ausente y una lista vacía no son necesariamente equivalentes. null puede indicar que se conocía el campo pero no el valor; ausencia puede corresponder a una versión anterior; lista vacía puede significar que se evaluó y no hubo elementos. Homogeneizarlos sin consultar el contrato destruye información.

Eventos y reconstrucción de estado

Los logs suelen registrar cambios, no estados completos. Para conocer el estado en t se debe ordenar eventos, resolver duplicados y aplicar transiciones. El orden de llegada puede diferir del orden de ocurrencia. Se conservan ambos tiempos y un identificador idempotente para que un reintento no duplique el evento.

Esta reconstrucción es una transformación analítica importante. Debe probarse con secuencias incompletas, tardías y fuera de orden.

2.3.3. Datos no estructurados

Texto, imagen, audio y video se denominan no estructurados porque su contenido no se organiza directamente en variables tabulares. No carecen de estructura interna: una imagen posee posiciones y canales; un texto posee secuencia y sintaxis; un audio es una señal temporal. Lo que falta es una representación analítica inmediata.

Para utilizar estos datos se construyen características o representaciones:

- texto: tokens, n-gramas, frecuencias o embeddings;
- imagen: píxeles, descriptores, mapas de características;
- audio: forma de onda, espectrograma, coeficientes;
- video: secuencias de cuadros, movimiento y audio.

Cada representación establece invariancias. Reducir una imagen puede eliminar detalle; normalizar texto puede borrar información de estilo; recortar audio puede excluir contexto. La preparación debe alinearse con la señal relevante para el problema.

Los metadatos también son datos. Fecha, dispositivo, ubicación y condiciones de captura pueden explicar variación, detectar duplicados o producir fuga. Una fotografía tomada siempre sobre un fondo distinto por clase puede permitir que un modelo reconozca el fondo en lugar de la enfermedad.

Muestreo y etiquetado de contenido

En datos no estructurados, la selección de ejemplos suele ser tan importante como la arquitectura. Un corpus puede contener muchos documentos repetidos; una colección visual puede representar una enfermedad solo bajo iluminación controlada. El inventario debe describir diversidad de contenido y condiciones de captura.

El etiquetado requiere una guía con definiciones, ejemplos positivos, negativos y ambiguos. Se realiza una prueba piloto para medir desacuerdo y refinar criterios. Forzar consenso sin registrar incertidumbre produce etiquetas aparentemente limpias que ocultan límites del concepto.

Separación por procedencia

Fragmentos de un mismo documento, cuadros de un video o imágenes de una misma sesión deben mantenerse juntos al dividir datos. De lo contrario, el modelo ve variaciones casi idénticas durante entrenamiento y evaluación. La clave de partición debe representar la fuente independiente, no el archivo individual.

También conviene construir pruebas “fuera de condición”: otro dispositivo, región, temporada o estilo de redacción. Esas pruebas no reemplazan la evaluación principal, pero muestran qué invariancias aprendió realmente el sistema.

2.3.4. Datos observacionales, experimentales y simulados

Esta clasificación no describe formato, sino mecanismo de generación.

Datos observacionales

Se registran fenómenos sin asignar deliberadamente las condiciones. Transacciones, sensores, historias clínicas y reclamos suelen ser observacionales. Son esenciales para describir y predecir, pero las asociaciones pueden resultar de confusión, selección o causalidad inversa.

Si las zonas con más fugas reciben más sensores, la cantidad de alertas estará asociada con fugas y con intensidad de observación. Un modelo predictivo puede aprovechar la asociación; una interpretación causal necesitará considerar el mecanismo de asignación de sensores.

Datos experimentales

En un experimento se manipula una condición y se asignan unidades a alternativas mediante un diseño. La aleatorización busca equilibrar factores no observados. Un experimento controlado permite estimar efectos bajo sus supuestos, pero puede tener restricciones éticas, económicas o de generalización.

No todo cambio histórico es un experimento. Comparar antes y después de una política sin grupo de referencia confunde su efecto con tendencias, estacionalidad y otros eventos.

Datos simulados

Una simulación genera observaciones desde un modelo conocido. Permite estudiar escenarios raros, evaluar algoritmos y analizar sensibilidad. Su ventaja es el control; su límite es que reproduce los supuestos del simulador. Un sistema que funciona con datos sintéticos puede fallar frente a ruido, comportamiento humano y condiciones no representadas.

Las tres fuentes pueden combinarse: observaciones para estimar parámetros, experimentos para validar intervenciones y simulaciones para explorar escenarios. Deben mantenerse distinguidas para no presentar evidencia simulada como observación real.

Dibujar el proceso generador

Antes de interpretar una asociación, resulta útil dibujar un diagrama causal cualitativo. En el caso de fugas, daño físico puede afectar presión y reclamos; cobertura de sensores afecta mediciones; reclamos afectan inspección; inspección afecta confirmación. La etiqueta observada depende tanto de la fuga como de la política de inspección.

El diagrama no demuestra causalidad, pero obliga a identificar variables de confusión, mediación y selección. También señala qué preguntas sí pueden responderse. Un modelo puede predecir confirmación bajo la política histórica sin estimar probabilidad real de fuga en zonas nunca inspeccionadas.

Triangulación

Cuando ninguna fuente es completa, se combinan evidencias con mecanismos distintos. Sensores, reclamos e inspecciones pueden coincidir o discrepar. La discrepancia no debe resolverse siempre eligiendo una fuente “verdadera”; puede revelar fallos de cobertura.

Los datos simulados son útiles para comprobar que un método recupera relaciones conocidas. Los experimentos o pilotos ayudan a validar que una intervención produce el efecto esperado. Los observacionales muestran escala y diversidad reales. La triangulación fortalece una conclusión cuando fuentes con sesgos diferentes apuntan en la misma dirección.

2.3.5. Datasets abiertos y fuentes privadas

Los datasets abiertos favorecen aprendizaje, transparencia y replicación. Sin embargo, “descargable” no significa que pueda utilizarse para cualquier propósito. Deben revisarse licencia, términos, atribución, restricciones comerciales, privacidad y condiciones de redistribución.

Una ficha de dataset abierto debe incluir:

- institución y enlace estable;
- versión o fecha de descarga;
- licencia;
- método de recolección;
- población y cobertura;
- unidad y esquema;

- cambios conocidos;
- limitaciones declaradas;
- suma de comprobación del archivo cuando sea posible.

Las fuentes privadas pueden representar mejor el proceso local y contener atributos más detallados. También plantean riesgos de acceso, dependencia y uso secundario. Los permisos deben aplicar el principio de mínimo privilegio: cada persona o servicio accede solo a lo necesario.

Datos personales y sensibles

Eliminar nombre o documento no siempre anonimiza. Combinaciones de ubicación, fecha y atributos pueden reidentificar individuos. Se debe evaluar minimización, seudonimización, agregación, retención y control de acceso. La pregunta no es solo “¿podemos obtener el dato?”, sino “¿es necesario y legítimo utilizarlo?”.

Sesgo de disponibilidad

Los datos disponibles no son necesariamente los adecuados. La facilidad de acceso puede orientar la pregunta hacia lo medible y excluir fenómenos importantes. Utilizar reclamos porque están digitalizados puede invisibilizar a quienes no reclaman. El inventario debe registrar ausencias sistemáticas, no solo fuentes existentes.

Evaluar una fuente antes de adoptarla

Una fuente puede puntuarse cualitativamente en pertinencia, cobertura, estabilidad, oportunidad, calidad, legalidad y costo. La puntuación no sustituye revisión, pero permite comparar alternativas y mostrar por qué una fuente atractiva fue descartada.

La estabilidad contractual importa tanto como la técnica. Un proveedor puede retirar acceso, cambiar términos o imponer costos. Si la operación depende de esa fuente, se necesita una estrategia de continuidad y una degradación segura.

Gobernanza del acceso

El acceso debe registrarse y revisarse. Se separan permisos de lectura, escritura y administración; se limitan copias locales; se establece retención y eliminación. Los entornos de desarrollo pueden utilizar datos minimizados o seudonimizados.

Cuando un proyecto termina, la conservación “por si acaso” contradice minimización. Debe existir un responsable que determine qué artefactos pueden retenerse y cuáles deben eliminarse, incluyendo copias, modelos y resultados que puedan contener información sensible.

2.3.6. Bases de datos, archivos, APIs y flujos de sensores

Cada mecanismo de acceso requiere controles diferentes.

Bases de datos

Las bases relacionales permiten consultas, transacciones e integridad. Los almacenes columnares favorecen análisis de grandes volúmenes; los sistemas documentales almacenan estructuras flexibles; las bases de grafos representan relaciones. La elección depende de patrón de acceso, consistencia, escala y mantenimiento.

Una consulta debe registrar fecha de corte, filtros y versión del esquema. Ejecutar la misma consulta meses después puede producir resultados distintos porque la base cambió. Para reproducir un experimento se necesita una instantánea o una estrategia de versionado.

Archivos

CSV es simple, pero no conserva tipos ni esquema; Parquet almacena columnas, tipos y compresión; formatos geoespaciales agregan sistemas de coordenadas; archivos de imagen y audio contienen metadatos. Extensión y formato no garantizan contenido correcto.

Los archivos deben acompañarse con tamaño, suma de comprobación, codificación, separador, zona horaria y reglas para valores faltantes. Sobrescribir el archivo original impide reconstruir el proceso.

APIs

Una API expone datos mediante solicitudes. Puede aplicar autenticación, paginación, límites, filtros y versiones. La extracción debe manejar respuestas incompletas, reintentos, errores, duplicados y cambios de contrato.

El hecho de recibir una respuesta correcta no garantiza que se obtuvo todo el universo. Se debe verificar paginación, cobertura y hora de actualización. También se debe respetar la licencia y los límites del servicio.

Flujos de sensores

Los sensores producen eventos continuos con latencia, pérdida de paquetes, desorden, calibración y deriva. Una medición necesita identificador de dispositivo, instante de evento e instante de recepción. La diferencia entre ambos permite detectar retrasos.

Los flujos suelen procesarse mediante ventanas. Una ventana de diez minutos puede resumir media, máximo y cantidad de lecturas. La elección de ventana modifica qué patrones son visibles. Además, el sistema debe definir cómo manejar eventos tardíos y periodos sin señal.

Diseñar según el modo de fallo

Cada medio falla de manera distinta. Una base puede devolver una vista cambiante; un archivo puede quedar truncado; una API puede responder parcialmente con estado exitoso; un sensor puede quedar congelado en un valor plausible. Los controles deben diseñarse para esos fallos, no limitarse a verificar que “hay datos”.

Una extracción robusta registra cantidad esperada, páginas, rango temporal, esquema y checksum. Los reintentos son idempotentes: repetir no duplica. Los errores transitorios se distinguen de rupturas de contrato. El sistema conserva un punto de control para continuar sin perder ni repetir periodos.

Tiempo de evento, procesamiento y decisión

En sistemas en flujo existen al menos tres relojes: cuándo ocurrió el fenómeno, cuándo se recibió y cuándo se utilizó. Una alerta debe construirse con eventos conocidos antes del tiempo de decisión, aunque luego lleguen datos tardíos que corrijan el histórico.

Esto obliga a mantener dos perspectivas: la verdad retrospectiva y la información disponible en línea. Evaluar con la primera un sistema que operó con la segunda puede introducir fuga temporal. Los datos deben permitir reconstruir qué sabía el sistema en cada instante.

2.3.7. Introducción a las características de Big Data

Big Data describe problemas en los que escala, velocidad o diversidad exceden las capacidades de un procedimiento convencional. Las “V” ayudan a caracterizar el desafío:

- **volumen:** cantidad de observaciones y atributos;
- **velocidad:** ritmo de generación y necesidad de respuesta;
- **variedad:** diversidad de formatos, fuentes y estructuras;
- **veracidad:** confiabilidad, incertidumbre y calidad;
- **valor:** utilidad potencial para una decisión;
- **variabilidad:** cambios de significado y distribución.

Estas dimensiones interactúan. Un flujo rápido exige validaciones en línea; múltiples fuentes necesitan reconciliar identidades; alto volumen puede impedir algoritmos exactos. Sin embargo, la arquitectura distribuida no corrige problemas semánticos. Procesar mil millones de observaciones mal definidas produce una estimación precisa del dato equivocado.

Procesamiento por lotes y en flujo

En lotes se procesan conjuntos delimitados periódicamente. En flujo se procesan eventos conforme llegan. La elección depende de latencia necesaria, costo, tolerancia a errores y posibilidad de reprocesar.

Una arquitectura moderna puede distinguir:

1. fuentes;
2. zona de datos originales;
3. validación y estandarización;
4. datos curados;
5. productos analíticos;
6. servicios y monitoreo.

La separación conserva el original y permite reconstruir derivados. Los nombres tecnológicos cambian; el principio de capas y procedencia permanece.

Escala como propiedad de la arquitectura

No se adopta una plataforma distribuida solo porque el dataset “parece grande”. Se mide volumen, tiempo de proceso, memoria, frecuencia y crecimiento. Una solución simple que cabe en una máquina suele ser más fácil de probar y reproducir. La distribución agrega coordinación, particiones, consistencia y costos operativos.

Cuando la escala exige distribuir, se decide la clave de partición. Una mala clave concentra carga o separa eventos que deben procesarse juntos. También se diseñan operaciones asociativas o incrementales para evitar mover todos los datos.

Calidad a escala

La validación completa puede ser costosa. Se combinan contratos deterministas, métricas agregadas, muestreo y controles por partición. Los resultados de calidad son productos de primera clase: deben consultarse por fecha y fuente.

El linaje permite responder qué salidas dependen de una fuente defectuosa. Sin linaje, corregir un archivo obliga a adivinar qué tablas, modelos e informes deben regenerarse. A gran escala, la trazabilidad deja de ser documentación opcional y se convierte en requisito operativo.

2.3.8. Ejemplo práctico guiado: inventario de fuentes para movilidad urbana

Pregunta

Una autoridad desea describir demanda y anticipar viajes por zona y franja horaria. Antes de modelar, el equipo inventaría fuentes.

Fuente	Unidad original	Frecuencia	Clave posible	Riesgo principal
Viajes	Un viaje	Evento	viaje, zona, fecha	Cobertura parcial de opera
Clima	Estación-hora	Horaria	estación y hora	Distancia a la zona
Calendario	Día	Diaria	fecha	Definiciones locales
Obras	Tramo-periodo	Irregular	geometría y fechas	Cambios no actualizados
Zonas	Polígono	Versionada	identificador espacial	Límites modificados

Comprobaciones

Los viajes usan hora local, mientras el clima puede llegar en UTC. Las zonas pueden cambiar entre versiones. Una estación meteorológica puede representar varias zonas, pero esa asignación requiere una regla espacial. Las obras tienen inicio y fin, por lo que unir solo por fecha de inicio sería incorrecto.

El equipo define una unidad analítica zona-hora y documenta cómo se agrega cada fuente. Los conteos de viajes se suman; el clima se asigna por estación más cercana o interpolación; las obras se marcan cuando su intervalo y geometría intersectan la unidad. También registra qué operadores no están incluidos.

Producto

El inventario no es una lista de enlaces. Es una especificación de integración con claves, granularidades, cobertura, licencia y riesgos. Su aprobación precede a

la descarga masiva porque puede demostrar que una variable importante no es integrable o no está disponible a tiempo.

Decisión sobre cada fuente

El equipo clasifica las fuentes como obligatorias, opcionales o descartadas. Viajes y zonas son obligatorias para construir la unidad. Calendario es opcional pero estable. Clima se incorpora si la asignación espacial supera un umbral de cobertura. Obras se pospone porque su actualización es irregular y podría producir una falsa sensación de precisión.

Esta decisión evita que “más variables” sea el objetivo. Cada fuente agrega costo de integración, mantenimiento y riesgo de fuga. Debe justificar su valor esperado.

Prueba de integración mínima

Antes de procesar todo el histórico se toma un periodo pequeño y se ejecutan uniones. Se comprueba cardinalidad, zonas sin correspondencia, eventos en límites y desfases horarios. La prueba no estima todavía desempeño; intenta refutar la hipótesis de que las fuentes pueden formar una tabla coherente.

El inventario concluye con preguntas abiertas y responsables. Por ejemplo, cartografía debe confirmar la versión de zonas; movilidad, la cobertura de operadores; infraestructura, la frecuencia de obras. Una celda vacía no se interpreta como aprobación tácita.

2.4. Entornos, herramientas y reproducibilidad

Un resultado es reproducible cuando otra persona, o el mismo equipo en otro momento, puede reconstruirlo a partir de entradas identificadas y un procedimiento documentado. La reproducibilidad no exige que todo resultado aleatorio sea idéntico bit a bit, pero sí que las condiciones, variaciones y tolerancias estén controladas.

La reproducibilidad tiene niveles:

- **computacional:** volver a ejecutar el mismo código con los mismos datos;
- **analítica:** obtener conclusiones compatibles siguiendo el mismo método;
- **operativa:** ejecutar el proceso de manera confiable en el entorno de uso;
- **científica:** contrastar el hallazgo con nuevos datos o estudios.

2.4.1. Python y R como entornos de análisis

Python y R son lenguajes y ecosistemas, no metodologías. Python integra análisis, aprendizaje automático, automatización y servicios. R posee una tradición fuerte en estadística, visualización y publicación reproducible. Ambos pueden resolver gran parte de las tareas del libro.

La elección debe considerar:

- experiencia del equipo;
- bibliotecas pertinentes;
- integración con sistemas existentes;
- rendimiento y escala;

- facilidad de despliegue;
- soporte y mantenimiento;
- requisitos de auditoría.

Una organización puede utilizar ambos mediante formatos interoperables y contratos claros. El riesgo no es la diversidad por sí misma, sino la falta de definición de entradas, salidas y versiones.

Los conceptos deben permanecer agnósticos del lenguaje. Una partición temporal, una imputación ajustada en entrenamiento o una matriz de confusión tienen la misma lógica en cualquier implementación.

Elegir por ciclo de vida, no por preferencia personal

La productividad inicial es solo un criterio. Debe considerarse quién mantendrá el proyecto, cómo se probará, dónde se desplegará y qué competencias existen. Un prototipo excelente en un lenguaje que nadie puede operar genera dependencia de su autor.

Conviene realizar una prueba vertical: leer una muestra, aplicar una transformación, generar un resultado y ejecutarlo en el entorno previsto. Esta prueba revela temprano problemas de controladores, memoria, serialización y permisos.

La interoperabilidad se construye mediante formatos y contratos, no traduciendo manualmente notebooks. Parquet, CSV controlado, bases o APIs pueden ser fronteras; cada una debe especificar esquema, unidades y valores faltantes.

Rendimiento y claridad

La optimización prematura suele oscurecer el método. Primero se construye una referencia correcta y medible; luego se perfila tiempo y memoria. La vectorización, procesamiento por lotes o distribución se aplican donde existe evidencia de cuello de botella. El código más rápido no compensa una transformación imposible de auditar.

2.4.2. Cuadernos Jupyter y documentos reproducibles

Un cuaderno combina narrativa, código, fórmulas y resultados. Es adecuado para exploración y enseñanza porque permite mostrar el razonamiento junto con evidencia. También puede presentar problemas:

- celdas ejecutadas fuera de orden;
- variables ocultas en memoria;
- salidas que no corresponden al código visible;
- rutas absolutas;
- descarga manual no documentada;
- mezcla de exploración y funciones productivas.

Un cuaderno reproducible debe ejecutarse de principio a fin en un entorno limpio. Las celdas iniciales describen propósito, entradas, versión y configuración. Las transformaciones reutilizables se trasladan a módulos probados; el cuaderno conserva análisis y comunicación.

Los documentos reproducibles en R Markdown, Quarto u otros sistemas aplican el mismo principio: texto y resultados se generan desde fuentes y código versionados.

Una tabla pegada manualmente rompe la cadena de procedencia.

El cuaderno como registro narrativo

Un buen cuaderno explica pregunta, datos, método, resultado e interpretación. No debe convertirse en una secuencia de intentos sin jerarquía. Durante exploración pueden existir celdas provisionales; antes de entregar se elimina estado accidental, se ordena la narrativa y se comprueba ejecución completa.

Las salidas pesadas no deberían ocultar advertencias ni inflar el repositorio. Se guardan artefactos relevantes en directorios versionados o identificados y el cuaderno los referencia. Las decisiones importantes se escriben en texto, no se dejan implícitas en una gráfica.

De exploración a proceso

Cuando una transformación se reutiliza, se mueve a una función o módulo con prueba. Esto reduce diferencias entre cuaderno y producción. El cuaderno llama al mismo código que el pipeline, en lugar de mantener una copia simplificada.

Una revisión útil consiste en reiniciar el kernel, ejecutar todo y comparar artefactos. Si el resultado depende de una celda ejecutada manualmente o un archivo local no declarado, la reproducción falla aunque la salida visible parezca correcta.

2.4.3. Bibliotecas esenciales de Python

La selección de bibliotecas depende del proyecto. Algunas categorías comunes son:

Propósito	Bibliotecas habituales
Arreglos y cálculo numérico	NumPy
Datos tabulares	pandas
Métodos científicos	SciPy
Aprendizaje automático	scikit-learn
Visualización	matplotlib
Imágenes	Pillow
Cuadernos	Jupyter

Una biblioteca reduce trabajo de implementación, pero introduce una dependencia. Deben fijarse versiones compatibles, revisar licencias y registrar cambios que puedan alterar resultados. Las funciones por defecto no son decisiones neutrales: una métrica, un tratamiento de faltantes o un método de optimización puede cambiar entre versiones.

El entorno virtual `.venv` del proyecto aísla dependencias. La instalación reproducible se describe en `requirements.txt`. Para una publicación o despliegue crítico puede requerirse un archivo con versiones exactas y hashes.

Dependencias directas y transitivas

El proyecto utiliza bibliotecas directas, pero estas dependen de otras. Un cambio transitivo puede modificar comportamiento o romper instalación. Los entornos

importantes se prueban desde cero y se conserva una resolución concreta de versiones.

Actualizar dependencias es una actividad controlada. Se ejecutan pruebas, se regeneran resultados de referencia y se revisan cambios numéricos. Mantener versiones antiguas indefinidamente también tiene costo y riesgo de seguridad; la reproducibilidad no significa congelar sin mantenimiento.

Criterio de adopción

Antes de agregar una biblioteca se considera necesidad, madurez, licencia, documentación, comunidad y posibilidad de sustituirla. Una dependencia grande para una operación trivial puede complicar instalación. Implementar manualmente un algoritmo complejo y crítico puede ser peor. La decisión equilibra confiabilidad y carga de mantenimiento.

2.4.4. Ecosistema tidyverse en R

El ecosistema tidyverse propone una gramática coherente para manipulación y visualización. `readr` importa datos, `dplyr` selecciona y transforma, `tidyr` reorganiza, `ggplot2` visualiza y `purrr` ayuda a aplicar funciones.

El principio de datos ordenados establece que cada variable ocupa una columna, cada observación una fila y cada tipo de unidad una tabla. Este principio facilita muchas operaciones, aunque no obliga a convertir todo fenómeno en una tabla plana. Series, grafos, imágenes y modelos conservan estructuras especializadas.

R también permite documentos reproducibles y gestión de entornos. La sección se incluye para reconocer que el método no depende de Python y que la colaboración puede requerir equivalencias conceptuales entre ecosistemas.

Gramáticas consistentes y revisión

El valor pedagógico de tidyverse no reside solo en funciones, sino en una gramática que hace visibles verbos de transformación. Seleccionar, filtrar, agrupar y resumir pueden leerse como pasos. Esa claridad facilita revisar si cambió la unidad.

Sin embargo, una cadena larga puede ocultar resultados intermedios y cardinalidades. En un proceso crítico se agregan comprobaciones después de uniones y agregaciones. La elegancia sintáctica no reemplaza contratos ni pruebas.

En equipos mixtos, una especificación agnóstica describe la operación antes de implementarla: “conservar todos los viajes y unir clima por estación y hora” es más estable que una función particular. Python y R deben producir tablas compatibles bajo el mismo contrato.

2.4.5. Organización de código, datos y resultados

Una estructura clara reduce errores y facilita automatización. Una organización posible es:

proyecto/

```
datos/  
  originales/  
  intermedios/  
  procesados/  
src/  
notebooks/  
configuracion/  
modelos/  
resultados/  
pruebas/  
documentacion/
```

Los datos originales son inmutables. Los intermedios permiten inspeccionar etapas costosas; los procesados representan productos analíticos versionados. `src` contiene funciones reutilizables; los notebooks comunican análisis; configuración separa parámetros del código; resultados y modelos se vinculan con experimentos.

Convenciones

Los nombres deben ser descriptivos y estables. Las rutas relativas parten de la raíz del proyecto. Los secretos no se almacenan en el repositorio; se suministran mediante mecanismos seguros. Los archivos generados deben distinguirse de las fuentes para saber qué puede eliminarse y reconstruirse.

Una regla útil es que cada resultado responda tres preguntas: ¿qué proceso lo produjo?, ¿con qué entradas y configuración?, ¿puede regenerarse sin pasos manuales ocultos?

Datos como entradas o productos

Cada archivo debe clasificarse como fuente, intermedio, producto o artefacto temporal. Las fuentes son inmutables; los productos tienen propietario y contrato; los intermedios se regeneran; los temporales pueden eliminarse. Sin esta clasificación, el equipo no sabe qué respaldo necesita ni qué archivo es autoridad.

Los directorios no sustituyen una interfaz. El código no debería depender de que una persona coloque manualmente “el archivo más nuevo”. La configuración identifica versión y ubicación; la validación confirma checksum y esquema.

Configuración y secretos

Los parámetros que cambian entre entornos —rutas, fechas, umbrales operativos— se separan del código. Los secretos se suministran mediante almacenes o variables seguras y nunca se imprimen en logs o notebooks.

Debe distinguirse parámetro científico de configuración operativa. Cambiar una semilla o umbral de clasificación modifica el experimento y requiere registro; cambiar una ruta sin alterar contenido no debería cambiar resultados.

2.4.6. Versionado de código, datos y modelos

El control de versiones registra cambios en archivos de texto y permite asociar una ejecución con un estado del proyecto. Cada cambio debe ser pequeño y explicable. Las ramas y revisiones facilitan colaboración, pero no sustituyen pruebas.

Los datos grandes no siempre deben almacenarse en Git. Pueden versionarse mediante identificadores, catálogos, almacenamiento de objetos, herramientas especializadas o sumas de comprobación. Una versión debe ser inmutable: “los datos de julio” no es suficiente si el archivo puede actualizarse.

Un modelo guardado necesita más que sus parámetros. Debe asociarse con:

- versión de código;
- versión y esquema de datos;
- pipeline de preprocesamiento;
- hiperparámetros;
- biblioteca y entorno;
- métricas y población de evaluación;
- fecha, responsable y condiciones de uso.

Esta asociación permite reproducir, comparar y retirar modelos. Sin ella, un archivo de modelo es un artefacto opaco.

Versionado semántico de productos de datos

Un producto puede cambiar filas sin cambiar contrato, agregar una columna compatible o modificar significado. Conviene diferenciar versiones de datos, esquema y lógica. Un cambio de definición necesita una versión mayor y una migración para consumidores.

Las sumas de comprobación identifican contenido exacto, pero no explican semántica. Se combinan con catálogo y notas de cambio. Un consumidor debe poder saber si necesita recalcular, adaptar o rechazar una versión.

Reproducir frente a reconstruir

Reproducir usa los mismos datos y procedimiento. Reconstruir puede requerir consultar sistemas mutables. Si no existe instantánea, la misma consulta no garantiza el mismo conjunto. Por eso los experimentos importantes conservan una versión inmutable o una consulta con corte transaccional verificable.

La política de retención debe equilibrar reproducibilidad, costo y privacidad. No todo dato puede conservarse indefinidamente; en ese caso se guardan metadatos, agregados o evidencia suficiente para auditar sin retener información prohibida.

2.4.7. Semillas aleatorias y registro de experimentos

La aleatoriedad aparece en muestreo, particiones, inicialización y optimización. Una semilla inicializa un generador pseudoaleatorio y permite repetir una secuencia bajo condiciones compatibles.

Fijar una semilla no garantiza reproducibilidad total. Diferencias de hardware, paralelismo, versiones y operaciones no deterministas pueden producir resultados distintos. Por eso se deben reportar variabilidad y tolerancias, no confiar únicamente en una ejecución.

Un registro de experimento incluye:

Elemento	Ejemplo de contenido
Identificador	fecha y nombre estable
Pregunta	hipótesis evaluada
Código	commit o versión
Datos	versión y checksum
Partición	método, grupos y semilla
Pipeline	transformaciones y parámetros
Modelo	familia e hiperparámetros
Métricas	valores y variabilidad
Artefactos	gráficos, tablas y modelo
Conclusión	decisión y próximo paso

El registro evita comparar resultados obtenidos bajo condiciones incompatibles. También impide que solo se conserven las ejecuciones favorables.

Repetibilidad y robustez

Una ejecución repetible responde “¿puedo obtener el mismo resultado?”. La robustez responde “¿la conclusión se mantiene ante variaciones razonables?”. Se evalúan varias semillas, particiones, periodos o parámetros. Un modelo cuya ventaja desaparece con otra semilla no ofrece evidencia sólida.

Las fuentes de aleatoriedad deben enumerarse. Algunas bibliotecas usan generadores separados; procesos paralelos pueden cambiar el orden; GPU puede ejecutar operaciones no deterministas. Cuando no se puede garantizar identidad, se fijan tolerancias y se reportan distribuciones.

Registro de decisiones, no solo métricas

Un sistema de seguimiento puede almacenar cientos de números y aun así no explicar por qué se eligió un modelo. Cada experimento necesita conclusión escrita: qué se aprendió, qué limitación se observó y qué decisión se tomó.

También deben registrarse ejecuciones fallidas relevantes. Un error de memoria, una configuración inestable o una fuente sin cobertura es conocimiento sobre viabilidad. Borrarlo sesga la historia hacia los éxitos.

2.4.8. Ejemplo práctico guiado: creación de la estructura reproducible de un proyecto

Objetivo

Preparar la estructura inicial del proyecto de agua antes de analizar datos. La evidencia esperada no es un modelo, sino la posibilidad de reconstruir un perfil inicial desde una fuente identificada.

Procedimiento

1. Crear directorios para originales, procesados, código, notebooks, resultados, pruebas y documentación.
2. Registrar fuente, licencia, fecha, versión y suma de comprobación.

3. Definir el entorno y las dependencias.
4. Crear un archivo de configuración con rutas relativas y parámetros no sensibles.
5. Implementar una validación de existencia y esquema.
6. Generar un perfil de calidad en resultados.
7. Ejecutar desde cero y comprobar que el resultado se reproduce.

Un esquema de ejecución es:

```
cargar configuración
verificar entorno y entradas
validar esquema y versión de datos
construir dataset intermedio
generar perfil y controles
guardar resultados con identificador de ejecución
registrar estado, métricas y errores
```

Criterios de revisión

El proyecto debe fallar de manera explícita si falta una entrada o cambia el esquema. No debe descargar silenciosamente una versión nueva. El original permanece intacto; el procesado se regenera. Otra persona debe poder seguir la documentación sin conocer las decisiones informales del autor.

Prueba de entrega

La revisión se realiza desde un entorno nuevo, no desde la máquina del autor. Se instala a partir del archivo de dependencias, se obtienen entradas según la documentación y se ejecuta el comando o cuaderno principal. Se comparan esquema, conteos y artefactos con referencias.

La prueba incluye fallos deliberados: retirar una columna, cambiar el tipo, omitir un archivo y usar una versión no reconocida. El proyecto debe emitir mensajes que permitan diagnosticar la causa sin exponer secretos.

Manifiesto de ejecución

Cada corrida produce un manifiesto con hora, entorno, código, datos, configuración y artefactos. Este pequeño documento conecta todos los elementos de procedencia. Si un gráfico llega a un informe, su manifiesto permite reconstruirlo.

Al finalizar, una persona ajena al desarrollo intenta responder: “¿de dónde salió este número?”. Si debe preguntar al autor o buscar en mensajes privados, la estructura todavía no es reproducible en sentido organizacional.

Síntesis del capítulo

Un proyecto basado en datos es un sistema de producción de evidencia para una decisión. La formulación conecta necesidad, pregunta, unidad, variables, acción y criterios. Las metodologías organizan iteraciones y responsabilidades. Las fuentes determinan qué puede afirmarse y con qué sesgos. La arquitectura y la reproducibilidad conservan la cadena que une datos con resultados.

El modelo ocupa una parte del ciclo. Antes de él se encuentran la definición, la procedencia y la preparación; después se encuentran evaluación, integración, monitoreo y responsabilidad. Una mejora técnica solo tiene sentido si puede traducirse en una acción viable y si sus riesgos son aceptables.

El Capítulo 3 profundiza la comprensión, validación, limpieza e integración de datos. Las decisiones tomadas aquí —unidad, población, horizonte, fuentes y particiones— determinarán cómo debe realizarse esa preparación.

Glosario esencial

- **Alcance:** fronteras de población, tiempo, lugar, usos y casos cubiertos.
- **Baseline:** procedimiento de referencia contra el cual se compara una propuesta.
- **CRISP-DM:** metodología cíclica para organizar proyectos de datos.
- **Dato semiestructurado:** dato con marcas o claves, pero esquema variable o parcial.
- **Despliegue:** integración de un resultado analítico en un proceso de uso.
- **KDD:** proceso de descubrimiento de conocimiento que incluye preparación, minería e interpretación.
- **Población objetivo:** conjunto sobre el que se desea generalizar o actuar.
- **Procedencia:** registro del origen y transformaciones de un dato.
- **Reproducibilidad:** capacidad de reconstruir un resultado bajo condiciones documentadas.
- **Tarea computacional:** operación formal mediante la cual se produce evidencia.
- **Unidad de análisis:** entidad elemental representada por una observación.

Preguntas de autoevaluación

1. ¿Por qué una necesidad real no constituye todavía una tarea computacional?
2. ¿Qué supuestos adicionales se incorporan al pasar de descripción a prescripción?
3. ¿Cómo se conecta un objetivo técnico con un objetivo operativo?
4. ¿Por qué la unidad de análisis condiciona la partición de datos?
5. ¿Qué diferencia existe entre etiqueta observada y constructo?
6. ¿Qué criterios pueden justificar detener un proyecto antes del despliegue?
7. ¿Por qué la minería de datos es solo una etapa de KDD?
8. ¿Qué pregunta de aprobación corresponde a cada fase de CRISP-DM?
9. ¿Qué diferencia existe entre producto mínimo viable y producto mínimo evaluable?
10. ¿Por qué los resultados negativos deben registrarse?
11. ¿Qué diferencia existe entre datos observacionales, experimentales y simulados?
12. ¿Qué controles requiere una API que no requiere un archivo estático?
13. ¿Por qué Big Data no resuelve problemas de validez semántica?
14. ¿Qué niveles de reproducibilidad pueden distinguirse?
15. ¿Por qué una semilla no garantiza por sí sola resultados idénticos?

Actividad integradora de cierre

Seleccione uno de los cuatro casos transversales del libro. Elabore un documento de inicio de proyecto que incluya:

1. necesidad y usuario;
2. decisión y teoría de cambio;
3. unidad, población, alcance y horizonte;
4. preguntas descriptiva, predictiva y prescriptiva;
5. entradas, etiqueta, acciones y restricciones;
6. baseline y criterios técnicos, operativos y de riesgo;
7. inventario de al menos tres fuentes;
8. ciclo CRISP-DM con entregables y responsables;
9. estructura reproducible y registro de experimento;
10. tres motivos que justificarían reformular o detener el proyecto.

La entrega se evalúa por coherencia entre componentes, no por complejidad algorítmica. Una formulación simple y verificable es preferible a una propuesta sofisticada cuyos datos, decisión o criterios no estén definidos.

Capítulo 3. Preparación, calidad y transformación de datos

Propósito y objetivos de aprendizaje

En un proyecto real, los datos casi nunca llegan en una tabla ordenada, completa y lista para modelar. Llegan como archivos producidos por sistemas diferentes, lecturas de sensores que perdieron conexión, categorías que cambiaron de nombre, fechas almacenadas en distintas zonas horarias, formularios incompletos y registros que reflejan decisiones organizacionales previas. Preparar esos datos no es una tarea secundaria ni un trámite anterior al análisis: es el proceso mediante el cual se decide qué representa cada observación y qué evidencia puede obtenerse de ella.

La experiencia muestra que muchos errores atribuidos al modelo se originan antes del modelado. Una unión muchos-a-muchos puede multiplicar observaciones; una imputación global puede revelar información del conjunto de prueba; un cambio de unidad puede parecer una anomalía; una etiqueta creada después de resolver un caso puede anticipar artificialmente el resultado. Ningún algoritmo compensa una representación incoherente.

Este capítulo desarrolla una forma disciplinada de trabajar. El objetivo no es “limpiar todo”, sino construir datos **aptos para el propósito**, conservando procedencia, significado e incertidumbre. Al finalizar, el lector podrá:

- interpretar la estructura y granularidad de una tabla;
- distinguir tipos de variables y escalas de medición;
- evaluar dimensiones de calidad con reglas explícitas;
- analizar mecanismos de ausencia y elegir estrategias de tratamiento;
- distinguir duplicados, errores y eventos reales;
- integrar y transformar datos sin alterar inadvertidamente la unidad de análisis;
- construir pipelines reproducibles que eviten fugas de información.

3.1. Comprensión y evaluación de la calidad de los datos

La calidad de datos no puede evaluarse sin conocer el uso previsto. Una ubicación aproximada puede ser suficiente para un mapa regional e inaceptable para localizar una tubería. Una actualización semanal puede servir para un informe histórico y llegar demasiado tarde para una alerta operativa. Por eso, antes de contar faltantes o calcular rangos, se debe recuperar la relación entre el dataset y la formulación del Capítulo 2.

La pregunta central es: **¿estos datos representan, con suficiente fidelidad y oportunidad, las unidades y variables necesarias para la decisión?**

La calidad se evalúa respecto del propósito y se controla de forma continua




Figura 3: Ciclo de evaluación de la calidad de datos

3.1.1. Estructura de una tabla de datos

Una tabla posee filas y columnas, pero esa descripción física es insuficiente. Para interpretarla se necesitan cuatro conceptos: unidad de observación, granularidad, claves y relaciones.

La **unidad de observación** indica qué representa una fila. En una tabla de movilidad puede ser un viaje; en una tabla de agua, una medición de sensor; en un corpus, un reclamo. La **granularidad** añade el nivel de detalle: una medición por sensor y minuto no equivale a un promedio por zona y día.

La **clave primaria** identifica de manera única una fila dentro de su unidad. Puede ser simple, como `id_reclamo`, o compuesta, como `(id_sensor, instante)`. Una **clave foránea** vincula una tabla con otra. La existencia de una columna llamada `id` no demuestra que sea una clave: debe comprobarse unicidad, estabilidad y significado.

La regla de una fila

Antes de cualquier transformación, el analista debería completar la frase:

Cada fila representa _____, observada durante _____, en _____.

Si la frase no tiene una respuesta única, probablemente la tabla mezcle unidades. Es frecuente encontrar filas que a veces representan clientes y otras transacciones, o columnas que combinan mediciones instantáneas con resúmenes mensuales. Esa mezcla dificulta toda operación posterior.

Cardinalidad y dependencias

La cardinalidad expresa cuántas instancias de una entidad se relacionan con otra:

- uno a uno: un reclamo tiene una ficha principal;

- uno a muchos: una zona contiene muchos sensores;
- muchos a muchos: varios reclamos pueden referirse a varios productos.

La cardinalidad determina qué uniones son válidas y qué agregaciones se necesitan. También revela dependencias. Diez mediciones consecutivas del mismo sensor no equivalen a diez sensores independientes. Si se ignora esa estructura, una evaluación puede repartir observaciones relacionadas entre entrenamiento y prueba.

Datos ordenados y tablas relacionales

En una tabla analítica ordenada, cada variable ocupa una columna, cada observación una fila y cada tipo de unidad una tabla. Este principio simplifica análisis y visualización, pero no obliga a desnormalizar todo. Las bases operativas suelen separar entidades para preservar integridad. La tabla analítica es un producto derivado que debe conservar las claves y la procedencia de esas entidades.

Una buena práctica consiste en registrar, para cada tabla:

Elemento	Pregunta
Unidad	¿Qué representa una fila?
Clave	¿Qué identifica una fila de manera única?
Granularidad	¿Cuál es el nivel temporal, espacial o conceptual?
Cobertura	¿Qué población y periodo están incluidos?
Relaciones	¿Cómo se vincula con otras tablas?
Actualización	¿Se agregan filas, se corrigen o se reemplazan?

Este registro parece elemental, pero evita una parte considerable de los errores de integración.

3.1.2. Tipos de variables

El tipo de una variable describe qué clase de información representa y qué operaciones son legítimas. Debe distinguirse el **tipo de almacenamiento** del **tipo semántico**. Un código postal puede almacenarse como entero, pero no es una cantidad; una fecha puede almacenarse como texto, pero posee orden temporal; una etiqueta 1, 2, 3 puede ser nominal u ordinal.

Variables categóricas

Las variables **nominales** distinguen categorías sin orden intrínseco: zona, material, canal o especie. Solo tienen sentido igualdad, diferencia, frecuencias y proporciones. Asignarles números no crea una distancia.

Las variables **ordinales** poseen orden, como severidad baja, media y alta. Sin embargo, la distancia entre niveles no está necesariamente definida. No puede suponerse que la diferencia entre baja y media sea igual a la diferencia entre media y alta.

Una categoría puede ser binaria, pero no siempre representa presencia/ausencia. sí/no, aprobado/rechazado y antes/después contienen significados diferentes.

También debe existir una política para categorías desconocidas, nuevas o poco frecuentes.

Variables numéricas

Las variables **discretas** toman valores contables, como cantidad de reclamos. Las **continuas** representan magnitudes que, en principio, pueden tomar cualquier valor en un intervalo, como presión o temperatura. En la práctica, toda medición tiene resolución finita.

El hecho de que una variable sea numérica no implica que una media sea siempre representativa. Conteos con muchos ceros, distribuciones fuertemente asimétricas o límites físicos requieren descripciones específicas.

Variables temporales y espaciales

Una fecha no es solo una cadena ordenable. Incluye calendario, zona horaria, resolución y, a veces, intervalo de validez. Una marca temporal puede referirse al momento del evento, al de registro o al de procesamiento. Confundirlos afecta secuencias y disponibilidad.

Una coordenada necesita un sistema de referencia. Latitud y longitud no deben tratarse como distancias euclídeas sin considerar geometría. Las zonas son polígonos con versiones; un mismo identificador puede cambiar de límites.

Variables de texto, imagen y relaciones

Texto e imagen son objetos complejos que requieren representaciones. Sus metadatos también son variables: idioma, dispositivo, resolución, origen o autor. Las relaciones entre entidades pueden representarse como grafos. Forzar esos datos a una tabla plana puede perder estructura.

Inferencia automática de tipos

Las herramientas intentan inferir tipos a partir de valores. Esa inferencia debe considerarse una hipótesis. Una columna numérica puede convertirse en texto porque una fila contiene N/D; una fecha ambigua puede interpretarse con día y mes invertidos; valores como NA pueden confundirse con abreviaturas legítimas.

El tipo esperado debe declararse y validarse. Permitir que cambie silenciosamente entre archivos convierte un problema de calidad en un cambio de comportamiento del pipeline.

3.1.3. Escalas de medición

La escala de medición indica qué transformaciones conservan significado y qué comparaciones son válidas.

Escala nominal

Permite afirmar igualdad o diferencia. Las categorías pueden renombrarse sin alterar información, siempre que la correspondencia sea uno a uno. Calcular una media de códigos nominales carece de interpretación.

Escala ordinal

Permite ordenar. Una transformación que preserve el orden conserva la escala. La mediana y los cuantiles pueden ser pertinentes, mientras que la media exige justificar distancias entre niveles.

Escala de intervalo

Las diferencias son interpretables, pero el cero es convencional. En grados Celsius, pasar de 10 a 20 representa un aumento de 10 grados, pero 20 no es “el doble de temperatura” que 10.

Escala de razón

Posee un cero que representa ausencia de magnitud y permite interpretar cocientes. Longitud, duración, masa y volumen suelen pertenecer a esta escala bajo condiciones adecuadas.

Por qué importa en el análisis

La escala condiciona estadísticas, visualizaciones y modelos. Una correlación lineal entre códigos nominales no tiene significado; una transformación logarítmica requiere una magnitud positiva; una diferencia temporal necesita unidades consistentes.

También condiciona la integración. Si una fuente mide caudal en litros por segundo y otra en metros cúbicos por hora, ambas representan la misma magnitud en escala de razón, pero deben convertirse antes de comparar. Si dos encuestas usan escalas ordinales distintas, la armonización no se resuelve con una conversión numérica automática.

Una pregunta útil es: **¿qué operaciones seguirían teniendo sentido si se cambiaran las etiquetas o unidades de manera válida?** La respuesta ayuda a identificar la escala y a evitar cálculos engañosos.

3.1.4. Exactitud, completitud, consistencia y actualidad

La calidad es multidimensional. Una tabla puede ser completa y, sin embargo, inexacta; consistente internamente y desactualizada; válida según su esquema y sesgada respecto de la población.

Exactitud

La exactitud describe proximidad entre el registro y el valor o estado real. Evaluarla requiere una referencia: calibración, inspección, fuente oficial o doble captura. Sin referencia, solo puede evaluarse plausibilidad, no exactitud estricta.

Para una variable numérica con referencia r_i , el error puede medirse como $e_i = x_i - r_i$. Sin embargo, una media de error cercana a cero puede ocultar errores positivos y negativos grandes. Deben revisarse magnitud, sesgo y distribución.

Compleitud

La completitud mide presencia de datos esperados. Para una variable j :

$$Compleitud_j = \frac{n_j^{observado}}{n_j^{esperado}}.$$

El denominador debe definirse. Si un campo solo aplica a cierto tipo de evento, su ausencia en otros no es un faltante. También existe completitud de filas, periodos y cobertura poblacional. Un archivo sin celdas vacías puede omitir por completo una zona.

Consistencia

La consistencia verifica relaciones internas y externas. Una fecha de cierre no debe preceder a la apertura; el código de zona debe existir en el catálogo; el total debe coincidir con sus componentes dentro de una tolerancia.

Dos fuentes pueden ser internamente consistentes y discrepar entre sí porque utilizan definiciones diferentes. Resolver la discrepancia requiere conocer autoridad, fecha y propósito, no elegir automáticamente el valor más frecuente.

Actualidad y oportunidad

La actualidad describe qué tan reciente es el dato. La oportunidad indica si llega antes de la decisión. Puede definirse latencia como:

$$L_i = t_i^{disponible} - t_i^{evento}.$$

Una medición exacta que llega después de asignar recursos no sirve como entrada predictiva, aunque pueda utilizarse para evaluación posterior.

Otras dimensiones

La unicidad evalúa duplicación; la validez, cumplimiento de dominios y formatos; la integridad, relaciones entre entidades; la trazabilidad, capacidad de reconstruir origen; la representatividad, cobertura de la población.

No conviene combinar todas las dimensiones en una puntuación sin contexto. Un promedio puede ocultar una falla crítica. Es preferible construir un tablero con métricas, umbrales y severidades vinculados al uso.

3.1.5. Perfiles y diccionarios de datos

Un **perfil de datos** resume lo observado en un dataset. Un **diccionario de datos** documenta lo que debería significar. Compararlos permite detectar discrepancias entre diseño y realidad.

Contenido de un perfil

Para cada variable suelen calcularse:

- tipo observado y tipo esperado;
- cantidad y proporción de faltantes;
- cardinalidad y valores únicos;
- frecuencias de categorías;
- mínimo, máximo, cuantiles y dispersión;
- patrones de formato;
- fechas mínima y máxima;
- ejemplos de valores;
- cambios por periodo o fuente.

A nivel de tabla se revisan filas, claves, duplicados, relaciones y cobertura. A nivel multivariado se buscan combinaciones imposibles y asociaciones inesperadas.

Un perfil no debe reducirse a una salida automática. El analista interpreta por qué una variable tiene 99 % de un único valor, por qué los faltantes aumentan después de una fecha o por qué aparece una categoría nueva. La herramienta encuentra síntomas; el conocimiento del sistema propone causas.

Diccionario de datos

Un diccionario robusto contiene:

Campo	Descripción
Nombre	Identificador técnico estable
Definición	Significado operacional
Unidad y escala	Cómo se mide
Dominio	Valores permitidos
Fuente	Sistema y responsable
Disponibilidad	Momento en que puede usarse
Sensibilidad	Clasificación y acceso
Faltantes	Significados y códigos
Versión	Cambios de definición

El diccionario es un contrato. Si el sistema cambia de metros a centímetros, no basta con modificar los datos: se actualiza la versión, se fija una fecha efectiva y se adapta la validación.

Perfilado continuo

El perfil inicial sirve como referencia para monitorear. Si la distribución, cardinalidad o tasa de faltantes cambia, puede haber deriva real o un problema de captura. Comparar perfiles entre entrenamiento y producción es una forma temprana de detectar degradación.

3.1.6. Reglas de validación

Una regla de validación convierte conocimiento del dominio en una comprobación ejecutable. Debe formularse de manera que dos personas obtengan el mismo resultado sobre la misma entrada.

Una especificación de regla incluye:

- identificador y descripción;
- columnas y unidad afectadas;
- condición de aceptación;
- severidad;
- tratamiento ante incumplimiento;
- responsable y fuente de autoridad;
- fecha de vigencia.

Tipos de reglas

Las reglas de **esquema** verifican columnas, tipos y nulabilidad. Las de **dominio** comprueban rangos y categorías. Las de **integridad** revisan claves y referencias. Las **temporales** verifican orden y frecuencia. Las **multivariadas** relacionan campos. Las **estadísticas** detectan cambios respecto de una referencia.

Una regla exacta, como `fecha_cierre >= fecha_apertura`, puede bloquear un registro. Una regla estadística, como “la media diaria se aparta tres desviaciones del histórico”, debería generar una advertencia y revisión, no una corrección automática.

Severidad y tratamiento

No todos los incumplimientos son iguales:

- **informativo**: se registra para análisis;
- **advertencia**: permite continuar, pero requiere revisión;
- **error**: excluye el registro del producto analítico;
- **crítico**: detiene el pipeline porque compromete todo el resultado.

La validación debe producir un informe, no solo un booleano. Debe indicar cantidad, proporción, ejemplos y evolución. Conservar el registro inválido en una zona de cuarentena permite investigar sin contaminar el producto final.

Validar antes y después

Las reglas se aplican al ingreso y después de las transformaciones. Una unión puede introducir duplicados; una conversión puede producir infinitos; un filtro puede eliminar una población completa. La salida también necesita contrato.

3.1.7. Ejemplo práctico guiado: auditoría inicial de un dataset abierto

Supóngase un archivo abierto de viajes urbanos. Antes de graficar o modelar, se realiza una auditoría reproducible.

Paso 1. Registrar la fuente

Se documentan URL, licencia, fecha de descarga, versión, tamaño y suma de comprobación. Se conserva el archivo original sin modificar. Si existe documentación oficial, se guarda su versión o enlace.

Paso 2. Definir la unidad esperada

Cada fila debería representar un viaje completado. Se identifican claves, periodo y cobertura de operadores. Se verifica si un viaje puede aparecer más de una vez por actualizaciones.

Paso 3. Contrastar esquema

Se comparan columnas y tipos con el diccionario. Una duración almacenada como texto, una zona inexistente o una columna faltante son desviaciones de esquema.

Paso 4. Construir el perfil

Se calculan faltantes, cardinalidades, rangos temporales, duración, distancia y frecuencias por zona. Los resultados se estratifican por mes para detectar cambios.

Paso 5. Aplicar reglas

Se comprueba que inicio preceda a fin, duración y distancia no sean negativas, zonas existan en el catálogo y claves respeten su cardinalidad. Los casos problemáticos se cuentan y aíslan.

Paso 6. Interpretar

Una duración de cero puede representar cancelación, error o viaje muy corto. La auditoría no decide sin evidencia. Registra hipótesis, consulta documentación y define si el caso pertenece al alcance.

Producto esperado

La auditoría entrega un informe con descripción de fuente, unidad, perfil, tabla de reglas, ejemplos, riesgos y recomendación. El resultado no es todavía “datos limpios”, sino conocimiento suficiente para diseñar la preparación.

3.2. Limpieza de datos

La limpieza es el conjunto de decisiones que transforma registros problemáticos en una representación apropiada para el análisis. La palabra puede sugerir que existe suciedad evidente y una versión correcta fácil de recuperar. En la práctica, muchos casos son ambiguos. El deber del analista es distinguir lo que puede corregirse de lo que solo puede marcarse o modelarse con incertidumbre.

Una limpieza profesional cumple cuatro principios:

1. conserva el original;
2. registra la regla aplicada;
3. evita utilizar información futura o de prueba;
4. evalúa cómo cambia la población y los resultados.

3.2.1. Datos faltantes y mecanismos de ausencia

Un valor faltante no es una categoría única. Puede significar que no se midió, que no aplica, que se perdió, que fue censurado, que el usuario no respondió o que la fuente todavía no actualizó. Los códigos NA, vacío, -999, sin dato y cero pueden representar ausencia, pero también valores legítimos según el campo.

Sea R_j un indicador que vale 1 si X_j se observa y 0 si falta. La relación entre R , los datos observados y los no observados define mecanismos clásicos.

MCAR: ausencia completamente aleatoria

La probabilidad de ausencia no depende de variables observadas ni del valor faltante:

$$P(R | X_{obs}, X_{mis}) = P(R).$$

Es una condición fuerte. Podría aproximarse si una pérdida de paquetes ocurre al azar y no se relaciona con la señal. Bajo MCAR, eliminar casos reduce precisión, pero no necesariamente introduce sesgo.

MAR: ausencia aleatoria condicionada

La ausencia depende de variables observadas:

$$P(R | X_{obs}, X_{mis}) = P(R | X_{obs}).$$

Por ejemplo, ciertos sensores pueden perder más datos durante tormentas registradas. Modelar la ausencia mediante variables observadas puede permitir imputación razonable.

MNAR: ausencia no aleatoria

La ausencia depende del propio valor faltante incluso después de considerar lo observado. Un sensor puede saturarse precisamente ante presiones extremas; una persona puede omitir una respuesta sensible por su contenido. La imputación convencional no elimina el sesgo sin supuestos adicionales.

Diagnóstico práctico

El mecanismo no puede demostrarse solo mirando el dataset, porque los valores faltantes no se observan. Se combinan conocimiento del proceso, comparación de tasas por grupos, patrones temporales y pruebas de sensibilidad.

Conviene construir una matriz de ausencia, agrupar patrones y preguntar si la falta anticipa el objetivo. Un indicador de ausencia puede ser predictivo, pero también representar una inequidad de acceso o un defecto que debería corregirse en origen.

3.2.2. Eliminación e imputación de observaciones

Eliminar o imputar no son respuestas automáticas. La decisión depende del mecanismo, proporción, variable, modelo y costo de distorsión.

Eliminación

La eliminación por caso completo conserva solo filas sin faltantes en las variables utilizadas. Es simple, pero puede reducir mucho la muestra y cambiar su composición. La eliminación por pares utiliza los datos disponibles para cada cálculo, lo que puede producir estadísticas basadas en poblaciones distintas.

Se justifica excluir una observación cuando está fuera del alcance, no puede identificarse su unidad o carece de información indispensable. Debe informarse cuántas filas se excluyen y cómo difieren de las conservadas.

Imputación simple

Media, mediana y moda son fáciles de aplicar. La mediana resiste extremos; la moda sirve para categorías; un valor constante puede distinguir ausencia. Sin embargo, repetir un único valor reduce variabilidad y altera relaciones.

Para una variable j , la mediana se estima únicamente en entrenamiento:

$$m_j = \text{mediana}\{x_{ij} : i \in \text{entrenamiento}, x_{ij} \text{ observado}\}.$$

Luego se aplica el mismo m_j a validación, prueba y producción hasta reentrenar el pipeline.

Imputación condicionada y múltiple

Métodos por vecinos, regresión o modelos iterativos utilizan otras variables. Pueden preservar mejor relaciones, pero introducen supuestos y riesgo de sobreajuste. La imputación múltiple genera varios datasets plausibles y combina resultados para reflejar incertidumbre. Es especialmente relevante para inferencia estadística.

Series temporales

Interpolar entre observaciones futuras y pasadas puede ser válido para reconstruir una serie histórica, pero no para una predicción en tiempo real si el futuro aún no existe. El propósito determina qué información está permitida.

Evaluación

Una estrategia se evalúa en tres niveles: plausibilidad de valores, preservación de distribuciones y efecto sobre el objetivo final. También se realiza sensibilidad: si conclusiones cambian radicalmente entre estrategias razonables, la incertidumbre debe reportarse.

3.2.3. Registros duplicados

Dos filas idénticas no son necesariamente un duplicado, y dos filas diferentes pueden representar el mismo evento. La deduplicación exige comprender identidad y versionado.

Duplicados exactos

Pueden surgir al concatenar archivos, repetir una carga o reintentar una API. Antes de eliminar se verifica si cada fila debía representar un evento único. En una tabla de lecturas, dos valores iguales en momentos distintos son observaciones legítimas.

Duplicados por clave

Si dos filas comparten clave primaria, puede existir una corrección, una actualización o una colisión. La regla de precedencia podría usar versión, fecha de actualización o fuente autorizada. Elegir “la última fila” solo es válido si el orden representa realmente vigencia.

Duplicados aproximados

Nombres, direcciones, textos e imágenes pueden corresponder a la misma entidad sin coincidir exactamente. La vinculación probabilística utiliza similitudes y reglas. Toda fusión tiene riesgo de unir entidades distintas o separar la misma entidad.

Consecuencias analíticas

Los duplicados alteran frecuencias y pesos. Si copias relacionadas se distribuyen entre entrenamiento y prueba, el modelo puede memorizar y aparentar generalización. La partición debe agrupar entidades, capturas o fuentes relacionadas.

Una tabla de deduplicación debe conservar identificador canónico, identificadores originales, regla, puntaje de similitud y decisión. Así puede auditarse y revertirse.

3.2.4. Errores de codificación y unidades

Los errores de codificación aparecen cuando el mismo concepto se representa de formas distintas o la misma representación se usa para conceptos diferentes.

Categorías y texto

Mayúsculas, espacios, acentos y abreviaturas producen categorías artificiales. Normalizar texto puede corregir diferencias superficiales, pero no resuelve equivalencia semántica. Norte, N y Zona Norte solo deben unificarse con un catálogo autorizado.

Los códigos pueden reutilizarse después de una reorganización. Una categoría 3 en 2022 puede no significar lo mismo en 2025. La armonización necesita fecha y versión.

Fechas y horas

03/04/2026 es ambiguo sin convención. Los cambios de horario, zonas y formatos ISO deben manejarse explícitamente. Se recomienda conservar instante original, zona y versión normalizada. Convertir todo a UTC facilita cálculo, pero la hora local sigue siendo necesaria para interpretar patrones sociales.

Unidades

Una conversión tiene forma:

$$x_{destino} = a x_{origen} + b.$$

Las conversiones de escala de razón suelen tener $b = 0$; temperatura puede requerir desplazamiento. El pipeline conserva valor y unidad originales, valor convertido y regla. Inferir la unidad solo por magnitud es riesgoso; debe apoyarse en metadatos o periodos documentados.

Codificación de caracteres

Problemas UTF-8, separadores decimales y miles pueden alterar texto y números. 1,234 puede significar decimal o millar. El formato debe fijarse al importar y validarse con ejemplos conocidos.

3.2.5. Valores imposibles e inconsistencias lógicas

Un valor imposible viola una regla necesaria del dominio. Una inconsistencia lógica surge de la combinación de valores, aunque cada uno sea válido por separado.

Ejemplos univariados incluyen porcentajes fuera de $[0, 100]$, duraciones negativas o categorías inexistentes. Ejemplos multivariados incluyen fecha de resolución anterior a apertura, caudal positivo con estado “sensor apagado” o coordenada fuera de la zona declarada.

Imposible no significa corregible

Detectar un valor imposible no revela el valor correcto. Una presión negativa puede representar error de signo, calibración, código de falla o fenómeno definido respecto de una referencia. Reemplazarla por su valor absoluto sería una conjetura.

Las acciones posibles son:

- corregir desde una fuente autorizada;
- recodificar un valor especial documentado;
- marcar como inválido;
- excluir del producto analítico;
- conservar en cuarentena para investigar el sistema.

Reglas duras y tolerancias

Las mediciones físicas tienen precisión. Una igualdad teórica puede necesitar tolerancia. Si un total debe coincidir con componentes, se valida:

$$|total - \sum_j componente_j| \leq \epsilon.$$

El valor de ϵ depende de redondeo e instrumento, no de conveniencia analítica.

Inconsistencias como señal del proceso

Un aumento de valores imposibles puede indicar falla de software, cambio de formulario o capacitación insuficiente. Corregir filas sin informar la causa permite que el defecto continúe. La calidad de datos también es observabilidad del proceso que los genera.

3.2.6. Detección y tratamiento de valores atípicos

Un valor atípico se aparta de un patrón de referencia. Puede ser error, evento raro genuino, cambio de régimen o miembro de una subpoblación. En detección de fallas, los extremos suelen ser precisamente el objeto de interés.

Métodos univariados

El rango intercuartílico define límites:

$$L_i = Q_1 - 1.5 IQR, \quad L_s = Q_3 + 1.5 IQR.$$

El puntaje estandarizado es:

$$z_i = \frac{x_i - \mu}{\sigma}.$$

El criterio $|z| > 3$ supone una referencia aproximadamente simétrica y es sensible a los mismos extremos que intenta detectar. La mediana y la desviación absoluta mediana ofrecen alternativas robustas.

Atípicos contextuales y multivariados

Una demanda alta puede ser normal en hora pico y anómala de madrugada. Un par presión-caudal puede ser extraño aunque cada variable aislada parezca normal. Deben incorporarse grupo, tiempo, estación, espacio y relaciones físicas.

Tratamientos

Conservar es apropiado si el valor es plausible. Transformar puede reducir influencia sin eliminar. Winsorizar limita extremos a cuantiles, pero cambia la distribución. Usar modelos robustos puede ser preferible. Excluir exige evidencia de error y análisis de sensibilidad.

Cada tratamiento responde a una pregunta: ¿se busca estimar comportamiento típico, detectar eventos raros o predecir bajo todo el rango? No existe una regla universal.

Evitar el círculo de limpieza

Definir atípicos a partir de todo el dataset antes de separar puede introducir información de prueba. Los umbrales aprendidos se estiman en entrenamiento o se fijan desde el dominio. Además, no se debe eliminar un caso simplemente porque el modelo lo predice mal; eso adapta los datos al modelo y oculta fallos.

3.2.7. Ejemplo práctico guiado: limpieza de mediciones de temperatura y vibración

Contexto

Una línea de manufactura registra la temperatura de los rodamientos y la vibración de motores y husillos. El sistema anterior enviaba temperatura cada minuto y vibración eficaz cada diez segundos; tras el recambio gradual de sensores, algunos equipos comenzaron a transmitir ambas variables cada cinco segundos. Durante la transición también hubo cortes de comunicación. El objetivo es obtener características por turno para anticipar mantenimiento sin confundir fallas de adquisición con señales de deterioro.

Inventario, procedencia y reglas

Primero se construye un inventario por `sensor_id` y activo: modelo, número de serie, variable medida, unidad, frecuencia nominal, resolución, rango certificado, fecha de calibración y periodo de instalación. La orden de recambio permite determinar qué dispositivo debía estar activo en cada instante. Así se evita interpretar como duplicado el breve solapamiento de dos sensores durante una prueba de aceptación.

Las fuentes se conservan separadas en una capa cruda e inmutable. Cada lectura mantiene archivo o mensaje de origen, instante de recepción, identificador del dispositivo y versión del firmware. Sobre esa base se definen reglas con distinto efecto:

- el esquema y los tipos incorrectos impiden procesar el registro;
- los límites instrumentales y físicos marcan valores inválidos;
- la frecuencia, la continuidad y los cambios abruptos generan alertas que requieren contexto;
- la correspondencia entre sensor, activo y periodo de instalación determina si la lectura pertenece al proceso analizado.

Armonización de frecuencias y unidades

La temperatura se lleva a grados Celsius y la vibración a milímetros por segundo, pero se preservan `valor_original` y `unidad_original`. Por ejemplo, las lecturas térmicas recibidas en grados Fahrenheit se convierten mediante

$$T_C = (T_F - 32) \frac{5}{9},$$

y la vibración recibida en pulgadas por segundo se transforma con el factor documentado por el fabricante. No se infiere una unidad solo por la magnitud: si el metadato falta o contradice la configuración vigente, el registro queda en cuarentena.

Para combinar frecuencias se define una rejilla de un minuto. La temperatura se resume con mediana, mínimo y máximo; para vibración se calculan mediana, percentil 95 y máximo a partir de las muestras disponibles. No se replica una lectura lenta para simular observaciones más frecuentes. Cada ventana conserva cantidad esperada, cantidad observada y cobertura, calculadas según el sensor que estaba instalado en ese periodo.

Duplicados y valores imposibles

Los reintentos de transmisión pueden producir mensajes idénticos. Se eliminan duplicados exactos por identificador de mensaje, conservando el primero recibido. Si coinciden sensor e instante pero difieren los valores, no se promedian automáticamente: se selecciona la versión válida según la secuencia de adquisición y las demás quedan registradas como conflicto.

Se marcan como inválidas las temperaturas por debajo del mínimo físicamente alcanzable en la planta, las que exceden el rango certificado y las vibraciones negativas. Una serie clavada exactamente en el máximo digital se identifica como saturación, no como una medición extrema confiable. El valor cero de vibración solo es admisible cuando el estado de máquina indica detención; durante producción se trata como posible desconexión o fallo instrumental.

Anomalías contextuales

Un aumento de vibración puede ser anómalo durante operación estable y esperable en el arranque, al cambiar de producto o después de una intervención. Del mismo modo, una temperatura alta puede ser coherente con una carga elevada, pero sospechosa con la máquina detenida. Por ello se unen, respetando su disponibilidad temporal, las señales de estado, velocidad, carga, producto, turno y registro de mantenimiento.

Las reglas contextuales conservan el evento y agregan una etiqueta en lugar de borrarlo. Un salto que coincide con el recambio de sensor se marca como posible cambio de nivel instrumental; un incremento gradual presente en sensores asociados al mismo activo se conserva como señal operativa plausible. Los umbrales estadísticos se estiman por modelo de sensor y régimen de operación usando solo el conjunto de entrenamiento.

Faltantes e imputación

La ausencia se clasifica antes de imputar. Se distinguen cortes de comunicación, mantenimiento programado, equipo detenido, sensor todavía no instalado y pérdida aislada de mensajes. Los intervalos esperados se derivan del historial de instalación y de la frecuencia nominal; de este modo, una máquina apagada o un dispositivo retirado no genera falsos faltantes.

Una brecha breve de temperatura durante operación estable puede interpolarse si no atraviesa un cambio de turno, estado o producto. La vibración no se interpola a través de arranques, paradas o intervenciones, porque se suavizaría precisamente el evento relevante. Las ventanas con cobertura inferior al umbral acordado no reciben un resumen imputado: mantienen el faltante, su causa y la cobertura observada. Todo valor imputado incluye método, parámetros y distancia respecto de la última observación real.

Trazabilidad y validación

La tabla analítica contiene:

- activo, sensor y periodo de instalación;
- instante original, instante normalizado y ventana de agregación;
- valor y unidad originales;

- valor armonizado y estadísticos de la ventana;
- frecuencia nominal, observaciones esperadas y cobertura;
- estado de validación e identificadores de reglas incumplidas;
- causa del faltante e indicador de imputación;
- referencias al mensaje de origen, calibración y orden de recambio;
- versión del diccionario, de las reglas y del pipeline.

La validación se ejecuta antes y después de limpiar. Se comprueba que las conversiones conserven valores conocidos, que no queden unidades mezcladas, que la clave definida sea única y que cada sensor se asocie únicamente con el activo y periodo autorizados. También se reconcilian conteos: registros de entrada, duplicados descartados, conflictos, inválidos, agregados e imputados deben explicar la salida sin pérdidas silenciosas.

Finalmente se comparan distribuciones, faltantes y cobertura por activo, turno, modelo de sensor y periodos anterior y posterior al recambio. Se revisan manualmente ejemplos de cada regla y se contrastan arranques e intervenciones conocidas con las etiquetas obtenidas. Si la limpieza elimina de forma desproporcionada un modelo o un turno, o borra los eventos que mantenimiento considera reales, el producto no se aprueba aunque supere las validaciones de esquema.

Actividad EMO [AGUA-02]: auditar y limpiar mediciones de agua

Capacidad mínima: distinguir datos ausentes, errores de registro, limitaciones instrumentales y posibles eventos físicos reales.

Consigna: seleccionar un subconjunto de mediciones; definir unidad y diccionario; construir un perfil; identificar faltantes, duplicados, cambios de unidad, imposibles e indicios atípicos; aplicar una estrategia de limpieza e imputación justificada.

Modalidad: el equipo puede acordar límites y documentación comunes. Cada estudiante implementa, evalúa y defiende sus decisiones sobre una zona o periodo diferente.

Evidencia individual: notebook reproducible, tabla de reglas, reporte de calidad antes/después, listado de transformaciones y análisis de al menos tres casos ambiguos.

Criterios de aprobación:

- las reglas provienen del diccionario, documentación instrumental o evidencia explícita;
- se diferencia detección de corrección;
- la imputación se ajusta sin futuro ni datos de prueba;
- se conserva indicador de cambios relevantes;
- los posibles eventos reales no se eliminan automáticamente;
- se analiza si la limpieza cambia la cobertura de la población.

Preguntas para la defensa: ¿qué supuesto permite imputar?, ¿qué extremo se conservó y por qué?, ¿qué error no pudo corregirse?, ¿cómo afectaría otra estrategia a la decisión operativa?

3.3. Integración y transformación

Después de comprender y limpiar las fuentes, el proyecto debe convertirlas en una representación analítica. Esta etapa parece mecánica —filtrar, unir, agrupar, codificar—, pero cada operación modifica la población, la granularidad o la geometría de los datos. La pregunta profesional no es solo “¿cómo ejecutar la operación?”, sino “¿qué significado tendrá la tabla resultante?”.

La integración debe conservar una cadena de procedencia. Cada columna derivada necesita fuente, regla, parámetros y momento de disponibilidad. Cada cambio de cantidad de filas necesita explicación. Una tabla final sin esa información puede ser cómoda para modelar e imposible de auditar.

3.3.1. Selección y filtrado de observaciones

La **selección** elige variables; el **filtrado** elige observaciones. Ambas operaciones definen qué información y población estarán disponibles para el análisis.

Filtrado por alcance

Es válido excluir periodos, zonas o tipos de evento que están fuera del alcance formulado. Por ejemplo, si se estudian viajes completados, las cancelaciones pueden quedar fuera, pero deben contabilizarse porque su exclusión modifica la interpretación del servicio.

El criterio debe definirse antes de observar resultados. Excluir casos difíciles porque empeoran la métrica crea una población artificial. Si una regla se modifica, se registra su versión y se compara la composición antes/después.

Sesgo de selección

Una muestra filtrada puede depender del resultado. Si solo se conservan pacientes con prueba confirmatoria, se estudia la política de prueba además de la enfermedad. Si solo se analizan reclamos cerrados, se excluyen los casos que permanecen abiertos y quizá son los más complejos.

Sea $S = 1$ el evento de inclusión. Las conclusiones describen $P(Y | X, S = 1)$, que no necesariamente coincide con $P(Y | X)$. Esa diferencia debe considerarse al generalizar.

Selección de columnas

Una variable puede excluirse por indisponibilidad, sensibilidad, redundancia o fuga. El criterio no debe basarse únicamente en correlación con el objetivo. Identificadores, campos administrativos posteriores y textos con la respuesta explícita pueden tener alto poder predictivo y ser inválidos.

Auditoría del filtro

Cada filtro debe producir un reporte con filas antes, filas después, proporción eliminada y distribución por grupos relevantes. Si una regla elimina 2 % global, pero 40 % de una zona, existe un impacto de cobertura que no puede ocultarse en el promedio.

3.3.2. Combinación de tablas y tipos de unión

Una unión relaciona filas mediante claves. Antes de ejecutarla se debe declarar cardinalidad esperada y decidir qué población debe conservarse.

Tipos de unión

- **Interna:** conserva claves presentes en ambas tablas.
- **Izquierda:** conserva todas las filas de la tabla principal y agrega coincidencias.
- **Derecha:** operación simétrica respecto de la anterior.
- **Completa:** conserva claves de ambas fuentes.
- **Semiunión:** conserva filas de una tabla que tienen coincidencia.
- **Antiunión:** conserva filas sin coincidencia, útil para diagnosticar cobertura.

La elección expresa una decisión de población. Una unión interna entre viajes y clima elimina viajes sin estación asignada. Si esas ausencias se concentran en zonas periféricas, el dataset resultante cambia de alcance.

Cardinalidad

Para claves k , conviene calcular conteos $n_A(k)$ y $n_B(k)$. La cantidad de filas producida por una unión para esa clave es:

$$n_{A \bowtie B}(k) = n_A(k) n_B(k).$$

Si ambas tablas tienen varias filas por clave, aparece una relación muchos-a-muchos que multiplica registros. A veces es correcta; con frecuencia indica que falta una clave o una agregación previa.

Uniones temporales y espaciales

No todas las relaciones usan igualdad exacta. Una medición puede vincularse con la calibración vigente en ese instante; un viaje, con la zona que contiene su coordenada; un reclamo, con el contrato activo durante su fecha.

Una unión temporal necesita intervalos de validez y una regla para superposiciones. Una unión espacial necesita sistema de coordenadas y política para puntos en límites. Aproximar por fecha o nombre sin documentar puede producir correspondencias silenciosamente erróneas.

Controles posteriores

Después de unir se revisan cantidad de filas, unicidad de clave, tasa de coincidencia, campos faltantes y distribución de casos no emparejados. También se inspeccionan ejemplos. Una tasa de coincidencia alta no descarta emparejamientos incorrectos.

3.3.3. Agregación y cambio de granularidad

Agregar combina observaciones para representar una unidad más amplia. Un conjunto de lecturas por minuto puede convertirse en sensor-hora; varios sensores, en zona-día. La operación debe declarar función, ventana, denominador y cobertura.

Estadísticos de agregación

La suma es apropiada para cantidades aditivas; la media para magnitudes comparables; mediana y cuantiles para distribuciones robustas; máximo y mínimo para extremos; conteo para frecuencia. Promediar promedios sin ponderar puede ser incorrecto si los grupos tienen tamaños distintos:

$$\bar{x} = \frac{\sum_g n_g \bar{x}_g}{\sum_g n_g}.$$

Tasas y denominadores

Una tasa necesita numerador y población en riesgo. “Reclamos por zona” no permite comparar zonas con distinta cantidad de usuarios. Una tasa por mil contratos puede ser más pertinente, pero depende de que contratos y reclamos correspondan al mismo periodo y cobertura.

Ventanas temporales

Las ventanas pueden ser fijas, móviles o basadas en eventos. Deben definirse extremos inclusivos, zona horaria y tratamiento de eventos tardíos. Para predecir en t , una característica histórica solo puede usar información anterior a t :

$$f_t = g(X_{t-h}, \dots, X_{t-1}).$$

Incluir X_t es válido únicamente si ya está disponible cuando se decide.

Pérdida de información y falacia ecológica

La agregación reduce ruido y volumen, pero oculta heterogeneidad. Una relación observada entre zonas no implica la misma relación entre individuos. Comparar resultados a varias granularidades ayuda a detectar conclusiones dependientes de la agregación.

Cobertura

Un promedio horario calculado con una lectura no equivale a otro calculado con doce. Junto al estadístico se conserva cantidad esperada, observada y proporción de cobertura. El modelo puede entonces distinguir valor normal de información insuficiente.

3.3.4. Reformateo entre estructuras anchas y largas

En formato **ancho**, varias mediciones ocupan columnas; en formato **largo**, una columna identifica la variable y otra contiene el valor. Por ejemplo, `presion_enero`, `presion_febrero` y `presion_marzo` pueden convertirse en filas con columnas `mes` y `presion`.

El formato largo facilita agrupar, visualizar y aplicar operaciones uniformes. El ancho puede ser conveniente para ciertos modelos y reportes. Reformatear no debería cambiar información si los identificadores son completos.

Riesgos

Si varias filas comparten el mismo identificador y nombre de variable, pivotar a ancho exige una agregación. Aplicar la primera observación oculta duplicados. Antes de reformatear se comprueba unicidad de la clave resultante.

Los nombres de columnas pueden contener varias dimensiones, como `presion_zonaA_2025`. Separarlas requiere una convención confiable. Si el separador también aparece en nombres, el análisis puede romperse.

Reversibilidad

Una prueba útil consiste en transformar de ancho a largo y volver. Si el resultado no coincide, hubo pérdida, agregación o ambigüedad. La reversibilidad es una propiedad verificable del pipeline.

3.3.5. Codificación de variables categóricas

Los modelos numéricos necesitan representar categorías. La codificación elegida introduce una noción de similitud y puede afectar dimensionalidad, interpretación y fuga.

Codificación ordinal

Asigna números respetando un orden. Es apropiada para niveles realmente ordenados, pero puede imponer distancias artificiales. Si `bajo=1`, `medio=2` y `alto=3`, un modelo lineal interpreta incrementos constantes salvo que se diseñe otra representación.

One-hot

Crea un indicador por categoría. No impone orden y es interpretable, pero aumenta dimensionalidad. Debe existir tratamiento para categorías desconocidas. Agrupar las raras puede mejorar estabilidad, siempre que el umbral se aprenda en entrenamiento.

Codificaciones basadas en frecuencia u objetivo

La frecuencia reemplaza categoría por prevalencia. La codificación por objetivo utiliza relación con Y y puede ser potente, pero tiene alto riesgo de fuga y sobreajuste. Debe calcularse dentro de cada partición de entrenamiento, con regularización y estrategia para categorías nuevas.

Alta cardinalidad

Identificadores, direcciones y productos pueden tener miles de valores. One-hot puede ser impracticable; hashing o embeddings reducen dimensión, pero dificultan interpretación. Antes de codificar se pregunta si la variable representa señal generalizable o memoriza entidades.

Equidad y categorías

Eliminar una variable sensible no elimina necesariamente su información, porque otras variables pueden actuar como proxies. La decisión de incluir o excluir debe responder al propósito, legalidad y evaluación de impacto, no a una regla automática.

3.3.6. Normalización y estandarización

El escalado modifica la magnitud numérica sin cambiar el orden de los valores.

Estandarización

Transforma mediante:

$$z_i = \frac{x_i - \mu_{train}}{\sigma_{train}}.$$

Produce media aproximada cero y desviación uno en entrenamiento. Es útil para modelos regularizados, métodos basados en distancia y optimización por gradiente. La media y desviación son sensibles a extremos.

Escalado min-max

Transforma a un intervalo:

$$x'_i = \frac{x_i - x_{min}}{x_{max} - x_{min}}.$$

Los nuevos valores pueden quedar fuera de $[0, 1]$ si producción excede los límites de entrenamiento. Eso no es necesariamente un error; es una señal de cambio que debe monitorearse.

Escalado robusto y normalización por fila

Mediana e IQR reducen sensibilidad a extremos. La normalización por norma convierte cada vector en dirección comparable y es útil para similitud coseno. No debe confundirse con normalización de una variable.

Cuándo no escalar

Los árboles suelen ser invariantes a transformaciones monótonas. Escalar puede ser innecesario y dificultar interpretación. Tampoco debe aplicarse automáticamente a variables binarias. El pipeline debe justificar cada operación según modelo y objetivo.

3.3.7. Transformaciones matemáticas

Las transformaciones buscan estabilizar varianza, reducir asimetría, linealizar relaciones o representar mejor el fenómeno. No son cosméticas: cambian la escala de interpretación.

Logaritmos

Para $x > 0$, $z = \log(x)$ comprime valores grandes. Una diferencia en escala logarítmica representa una razón en la escala original. Usar $\log(1 + x)$ permite ceros, pero debe justificarse y no admite valores menores que -1.

Potencias y raíces

Raíz cuadrada puede estabilizar conteos; Box-Cox y Yeo-Johnson estiman familias de potencias. Sus parámetros deben aprenderse en entrenamiento. Una transformación que hace la distribución más simétrica no garantiza mejor predicción ni validez del modelo.

Interacciones

Una interacción representa que el efecto de una variable depende de otra. Si x_1 es presión y x_2 tipo de tubería, el producto $x_1 x_2$ puede permitir pendientes diferentes. La interacción debe responder a una hipótesis o evaluarse dentro del protocolo.

Transformaciones temporales y cíclicas

Hora y día de semana son cíclicos. Codificar hora como 0 a 23 hace que 23 y 0 parezcan distantes. Una representación usa:

$$\sin(2\pi h/24), \quad \cos(2\pi h/24).$$

Estas variables conservan proximidad circular, pero no sustituyen patrones específicos de calendario.

Interpretación inversa

Si se predice en escala transformada, la vuelta a escala original puede introducir sesgo. En particular, $E[\exp(Z)] \neq \exp(E[Z])$. La comunicación debe aclarar en qué escala se optimiza y se informa.

3.3.8. Discretización y binarización

La discretización convierte una variable continua en intervalos. La binarización crea un indicador a partir de una condición.

Cortes por dominio

Umrales físicos, clínicos o normativos tienen interpretación directa. Debe conservarse también el valor continuo si es legítimo, porque dos mediciones cercanas a lados distintos del corte son muy similares aunque reciban categorías distintas.

Cortes por distribución

Intervalos de igual amplitud o cuantiles se adaptan a los datos. Los cuantiles producen grupos de tamaño parecido en entrenamiento, pero sus límites pueden cambiar entre versiones y no tener significado de dominio. Se estiman solo con entrenamiento.

Pérdida de información

Discretizar simplifica reglas y puede capturar no linealidad, pero pierde orden fino y crea discontinuidades. Un cambio mínimo alrededor del umbral puede cambiar la categoría. Se debe evaluar estabilidad y sensibilidad.

Binarización de resultados

Convertir un resultado continuo en “normal/anormal” cambia la tarea y los costos. El umbral debe corresponder a una decisión, no elegirse para equilibrar clases o mejorar métricas sin fundamento.

3.3.9. Ejemplo práctico guiado: integración de reclamos y datos contextuales**Objetivo y unidad**

Se desea construir un corpus para clasificar la temática de cada reclamo. La unidad es un reclamo inicial, no cada interacción posterior. La etiqueta proviene de una revisión validada, y la predicción se realizará al momento de recepción.

Fuentes

La tabla principal contiene texto, fecha y canal. Un catálogo define productos y categorías. Una tabla de interacciones contiene respuestas posteriores. Otra fuente contiene contexto regional agregado.

Decisiones de integración

Se conserva un único registro por reclamo inicial. Las interacciones posteriores no se incluyen como entradas porque contienen pistas sobre la resolución. El catálogo se une por código y periodo de vigencia. El contexto regional se agrega al mes anterior para asegurar disponibilidad.

Controles

Antes de unir se verifica cardinalidad. Después se mide tasa de coincidencia y se inspeccionan códigos sin catálogo. Se armonizan categorías sin modificar el texto original. Se marca texto ausente y se excluyen plantillas automáticas identificadas mediante reglas documentadas.

Procedencia

Cada columna del corpus registra fuente, regla, momento de disponibilidad y condición de uso. La etiqueta se mantiene separada de los atributos hasta la

partición. El producto contiene identificador, texto inicial, etiqueta, contexto permitido y grupo para evitar que reclamos relacionados se repartan entre particiones.

Actividad EMO [REC-01]: construir el corpus analítico de reclamos

Capacidad mínima: transformar registros heterogéneos en un corpus reproducible sin contaminar la variable objetivo.

Consigna: definir unidad, seleccionar texto, armonizar categorías, resolver duplicados, documentar faltantes e integrar variables contextuales disponibles al recibir el reclamo.

Evidencia individual: notebook de preparación, diccionario, reporte de cardinalidades, diagrama de procedencia, lista de campos excluidos y prueba de reconstrucción.

Criterios de aprobación:

- cada fila y etiqueta tienen interpretación inequívoca;
- las uniones conservan la unidad y verifican cardinalidad;
- se identifican campos que revelan directa o indirectamente la respuesta;
- las reglas de deduplicación y exclusión son auditables;
- el mismo corpus puede regenerarse desde datos originales versionados.

Preguntas para la defensa: ¿qué información posterior fue excluida?, ¿qué unión podía multiplicar filas?, ¿cómo se tratará una categoría nueva?, ¿qué población queda fuera del corpus?

3.4. Pipelines y prevención de fugas de información

Un pipeline convierte decisiones de preparación en un procedimiento repetible. Su función no es solo ahorrar código: establece el límite entre lo que se aprende del entrenamiento y lo que se aplica a datos nuevos.

La fuga de información es una de las causas más comunes de evaluaciones engañosas. Ocurre cuando el procedimiento utiliza información que no estaría disponible en el momento real de predicción. Puede aparecer en una columna obvia, en una estadística global, en una partición incorrecta o en una decisión humana tomada después de ver la prueba.

3.4.1. Concepto de pipeline

Un pipeline es una composición ordenada de transformaciones $T_1, \dots, T_k$ y un estimador M :

$$\hat{y} = M(T_k(\dots T_2(T_1(x)) \dots)).$$

Cada paso declara entrada, salida, parámetros, validaciones y errores. Algunos pasos son deterministas y fijos, como convertir unidades mediante una regla conocida. Otros aprenden parámetros: media de imputación, categorías, vocabulario, escalas, componentes o selección de variables.


Incorrecto: la prueba influye en el ajuste**Correcto: separar antes de aprender transformaciones**

Figura 4: Pipeline con fuga y pipeline correcto

Propiedades deseables

Un pipeline debe ser reproducible, idempotente cuando corresponda, observable y consistente entre entrenamiento e inferencia. **Idempotencia** significa que repetir una operación sobre la misma entrada no cambia de nuevo el resultado. Convertir unidades sin marcar el estado puede aplicar el factor dos veces y violar esta propiedad.

La observabilidad exige registrar cantidad de filas, esquema, advertencias, tiempos y distribuciones. Un pipeline que termina sin error pero produce una tabla vacía no es exitoso.

3.4.2. Ajuste y aplicación de transformaciones

Se debe distinguir ajustar de transformar.

- **Ajustar:** estimar parámetros usando un conjunto de datos.
- **Transformar:** aplicar parámetros ya estimados.

Un escalador ajusta μ y σ en entrenamiento; luego transforma todos los conjuntos con esos valores. Un codificador ajusta el vocabulario de categorías; una PCA ajusta componentes; un selector ajusta qué variables conservar.

El procedimiento correcto es:

```

separar datos según el protocolo
ajustar el pipeline solo con entrenamiento
transformar entrenamiento con parámetros aprendidos
transformar validación y prueba sin reajustar
ajustar el modelo con entrenamiento transformado
evaluar sobre datos no utilizados para ajustar
  
```

En validación cruzada, este proceso se repite dentro de cada fold. Preprocesar una vez antes de la validación ya expone información entre particiones.

Estado del pipeline

Los parámetros aprendidos forman parte del modelo. Persistir solo el estimador final produce incompatibilidad en producción. Deben guardarse orden de columnas, categorías, estadísticas, versión y política para entradas desconocidas.

3.4.3. Fuga de información o data leakage

La fuga puede clasificarse por origen.

Fuga de objetivo

Una variable contiene el resultado o un proxy creado después. Fecha de cierre para predecir resolución, tratamiento administrado para predecir diagnóstico o texto de respuesta para clasificar reclamo son ejemplos.

Fuga entre particiones

Duplicados, entidades o periodos relacionados aparecen en entrenamiento y prueba. Un modelo reconoce la entidad en lugar de generalizar. La solución es particionar por grupo, origen o tiempo según la unidad real.

Fuga de preprocesamiento

Imputación, escalado, selección o vocabulario se ajustan con toda la tabla. Aunque no usen explícitamente Y , incorporan la distribución de evaluación.

Fuga temporal

Se usan datos futuros, revisiones posteriores o agregados que no respetan el corte. Una media “del día” puede incluir horas posteriores a la predicción de la mañana.

Fuga por selección humana

El equipo consulta repetidamente la prueba y adapta decisiones. La prueba deja de ser independiente aunque el código sea correcto. Debe reservarse y utilizarse solo al final.

Señales de advertencia

Desempeño sorprendentemente alto, caída extrema en producción, variables administrativas muy importantes o gran diferencia al eliminar duplicados sugieren fuga. La mejor defensa es reconstruir cronológicamente qué información existe para cada caso.

3.4.4. Transformaciones dependientes del conjunto de entrenamiento

Toda transformación cuyos parámetros dependen de los datos debe tratarse como parte del ajuste. Esto incluye operaciones que suelen parecer “exploratorias”:

- decidir umbrales por cuantiles;
- agrupar categorías raras;

- elegir variables por correlación;
- eliminar columnas con demasiados faltantes;
- detectar atípicos mediante distribución;
- construir vocabulario;
- estimar componentes principales.

Incluso el perfilado puede influir en decisiones. Durante desarrollo se puede explorar entrenamiento. La prueba se limita a controles de esquema y evaluación final, no a decisiones sobre representación.

Validación anidada

Si se seleccionan hiperparámetros y se estima desempeño con validación cruzada, puede requerirse un ciclo interno para selección y otro externo para estimación. La lógica es separar toda decisión adaptativa de los datos usados para evaluar esa decisión.

Transformaciones fijas

Una conversión física documentada no necesita aprenderse y puede aplicarse a todos los conjuntos. Sin embargo, si la unidad se infiere por distribución, esa inferencia sí depende de datos y debe incorporarse al ajuste o, preferiblemente, resolverse mediante metadatos.

3.4.5. Tratamiento conjunto del preprocesamiento y el modelo

La unidad que se compara no es solo el algoritmo, sino el pipeline completo. Un modelo lineal con codificación y escalado es un sistema distinto de un árbol con imputación y categorías nativas.

Comparación justa

Todos los candidatos deben usar las mismas particiones y objetivo. Las transformaciones específicas pueden variar, pero se ajustan dentro del mismo protocolo. Si una representación fue elegida observando validación, esa elección forma parte de la búsqueda.

Búsqueda de hiperparámetros

Los parámetros de imputación, cantidad de componentes, umbrales y complejidad del modelo pueden buscarse conjuntamente. Cada configuración se evalúa sin tocar prueba. El costo computacional también es una métrica: una mejora marginal puede no justificar un pipeline mucho más lento.

Inferencia y entrenamiento

Debe existir paridad: la misma lógica se utiliza al entrenar y al predecir. Reimplementar transformaciones en otro sistema puede introducir diferencias. Los contratos de características especifican nombre, tipo, orden, unidad y política de faltantes.

Persistencia y versión

El artefacto desplegable incluye transformaciones, estimador y metadatos. Cambiar una categoría o una media de imputación sin cambiar versión equivale a modificar el modelo.

3.4.6. Pruebas y documentación del proceso

Los pipelines de datos necesitan pruebas igual que cualquier software, pero además deben comprobar propiedades estadísticas y semánticas.

Pruebas de esquema

Verifican columnas, tipos, rangos, categorías y nulabilidad. Detectan cambios de contrato antes de producir resultados.

Pruebas de unidad

Comprueban una transformación con ejemplos conocidos: conversiones, reglas de fechas, agregaciones y tratamiento de desconocidos. Incluyen casos límite.

Pruebas de integración

Ejecutan varias etapas y verifican cardinalidad, claves, filas y artefactos. Una unión debe demostrar que no multiplica la unidad inesperadamente.

Pruebas de invariantes

Una transformación puede conservar suma, orden o número de entidades. Estas propiedades se expresan como invariantes. Por ejemplo, reformatear de ancho a largo y volver debería recuperar la tabla cuando la clave es única.

Pruebas contra fuga

Se comprueba que ninguna fecha de entrada sea posterior al corte, que grupos no se solapen y que los parámetros del pipeline procedan del entrenamiento. También pueden introducirse datos de prueba artificialmente extremos y verificar que no cambien parámetros ajustados.

Documentación

El documento del pipeline incluye propósito, diagrama, entradas, salidas, reglas, parámetros aprendidos, orden de ejecución, errores, versión y responsables. Debe explicar por qué se tomó cada decisión importante, no solo qué función se llamó.

3.4.7. Ejemplo práctico guiado: construcción de un pipeline sin fuga de información**Procedimiento incorrecto**

Se carga toda la tabla, se imputan faltantes con la media global, se estandariza, se seleccionan variables correlacionadas con Y y recién entonces se divide en entrenamiento y prueba. La prueba influyó en todas las decisiones.

Procedimiento correcto

Primero se separan entidades y periodos según el uso. Dentro de entrenamiento se ajustan imputación, escalado y selección. Validación recibe solamente transform. Tras fijar el pipeline, la prueba se evalúa una vez.

```
definir grupos, tiempo y conjunto de prueba
separar antes de toda transformación aprendida
para cada partición de validación:
    ajustar imputación con entrenamiento interno
    ajustar codificación y escalado con entrenamiento interno
    ajustar selección y modelo con entrenamiento interno
    evaluar en validación interna
seleccionar configuración
reajustar pipeline con todo el entrenamiento permitido
evaluar una vez en prueba
persistir pipeline completo y metadatos
```

Demostración conceptual

Si la prueba contiene valores muy altos, la media global aumenta y modifica también los valores transformados de entrenamiento. El modelo ha recibido información sobre la distribución futura. Puede parecer un efecto pequeño, pero la lógica de independencia ya se rompió.

Lista de revisión

- ¿La división ocurrió antes de calcular estadísticas?
- ¿Las entidades relacionadas permanecen juntas?
- ¿Las características respetan el tiempo de decisión?
- ¿La selección de variables ocurre dentro de validación?
- ¿El conjunto de prueba se consultó una sola vez?
- ¿Se guardó el mismo pipeline que se desplegará?

Síntesis del capítulo

Preparar datos es construir una representación defendible del fenómeno. La estructura de una tabla define unidad y relaciones; los tipos y escalas delimitan operaciones; las dimensiones de calidad relacionan registros con su propósito. Limpiar requiere comprender mecanismos de ausencia, identidad, unidades y contexto, no aplicar recetas universales.

La integración puede cambiar población y granularidad. Las transformaciones incorporan supuestos y parámetros. Por eso, el preprocesamiento y el modelo forman una unidad experimental. Separar datos antes de ajustar, conservar procedencia y probar invariantes son condiciones para una evaluación honesta.

La principal lección práctica es que toda modificación debe responder cuatro preguntas: ¿qué problema corrige?, ¿qué evidencia autoriza la corrección?, ¿qué información puede perder?, ¿cómo se reproducirá y auditará? Si no pueden responderse, la transformación necesita revisión.

Glosario esencial

- **Ajuste:** estimación de parámetros a partir de un conjunto de datos.
- **Cardinalidad:** cantidad de instancias relacionadas entre claves o entidades.
- **Compleitud:** proporción de datos esperados que están presentes.
- **Dato faltante:** valor no observado cuyo significado depende del mecanismo de ausencia.
- **Diccionario de datos:** contrato que documenta significado, tipo, unidad, dominio y procedencia.
- **Fuga de información:** uso durante desarrollo de información no disponible en el uso real.
- **Granularidad:** nivel temporal, espacial o conceptual de una observación.
- **Imputación:** sustitución de un valor ausente por una estimación.
- **Pipeline:** composición reproducible de transformaciones y estimación.
- **Procedencia:** historia del origen y transformaciones de un dato.
- **Transformación:** aplicación de parámetros o reglas a observaciones.
- **Valor atípico:** observación que se aparta de un patrón de referencia y requiere interpretación.

Preguntas de autoevaluación

1. ¿Por qué una fila no puede interpretarse sin conocer granularidad y clave?
2. ¿Qué diferencia existe entre tipo de almacenamiento y tipo semántico?
3. ¿Cómo condiciona la escala las operaciones válidas?
4. ¿Por qué completitud no equivale a cobertura poblacional?
5. ¿Qué diferencia existe entre un perfil y un diccionario?
6. ¿Cuándo una regla debe advertir y cuándo debe detener el pipeline?
7. ¿Qué supuestos distinguen MCAR, MAR y MNAR?
8. ¿Por qué la imputación simple reduce variabilidad?
9. ¿Cómo pueden los duplicados contaminar una evaluación?
10. ¿Por qué un valor imposible no revela automáticamente su corrección?
11. ¿Qué diferencia existe entre un atípico global y uno contextual?
12. ¿Cómo cambia una unión interna la población?
13. ¿Por qué una unión muchos-a-muchos multiplica filas?
14. ¿Qué información debe acompañar una agregación?
15. ¿Cuándo es apropiada una codificación ordinal?
16. ¿Por qué el escalado se ajusta solo con entrenamiento?
17. ¿Qué tipos de fuga pueden aparecer sin utilizar explícitamente la etiqueta?
18. ¿Qué significa tratar preprocesamiento y modelo como una unidad?

Actividad integradora de cierre

Seleccione una fuente de uno de los casos transversales. Produzca una especificación de preparación que incluya:

1. unidad, granularidad, claves y población;
2. diccionario de diez variables relevantes;
3. perfil inicial y seis reglas de validación;
4. análisis de faltantes y mecanismo plausible;
5. estrategia para duplicados, unidades, imposibles y atípicos;
6. diseño de integración con otra fuente y control de cardinalidad;

7. transformaciones con distinción entre fijas y aprendidas;
8. protocolo de partición anterior al ajuste;
9. diagrama del pipeline y pruebas de invariantes;
10. comparación antes/después y riesgos residuales.

La calidad de la entrega se evalúa por la coherencia entre problema, datos y reglas. No se premia eliminar más filas ni producir una tabla sin faltantes. Se premia conservar significado, justificar incertidumbre y hacer reproducible cada decisión.

Capítulo 4. Estadística descriptiva, exploración y visualización

Propósito y objetivos de aprendizaje

Explorar datos no consiste en producir una colección de gráficos hasta encontrar algo llamativo. Consiste en construir una descripción disciplinada del fenómeno, comprobar si los datos representan la unidad formulada, identificar patrones que merecen explicación y comunicar qué evidencia existe sin atribuirle más alcance del que posee.

La estadística descriptiva proporciona un lenguaje para hablar de posición, dispersión, forma y asociación. La visualización permite percibir estructuras que una tabla de números puede ocultar. Ambas se necesitan mutuamente: una medida sin distribución puede ser engañosa y un gráfico sin cuantificación puede depender demasiado de la impresión visual.

Este capítulo sigue una secuencia deliberada. Primero se aprende a describir una variable. Después se estudian relaciones entre variables y los límites de su interpretación. Luego se presentan recursos visuales adecuados para diferentes preguntas. Finalmente se transforma la exploración en comunicación para públicos y decisiones concretas.

Al finalizar, el lector podrá:

- distinguir población, muestra, parámetro, estimando y estadístico;
- construir e interpretar distribuciones de frecuencias;
- elegir medidas de posición y dispersión apropiadas;
- analizar tablas de contingencia, covarianzas y correlaciones;
- separar asociación, predicción y causalidad;
- seleccionar gráficos según variable, pregunta y audiencia;
- reconocer escalas engañosas, sobrecarga y otras manipulaciones;
- comunicar hallazgos con incertidumbre, contexto y trazabilidad.

4.1. Descripción de una variable

La exploración comienza con una variable porque toda relación multivariada hereda los problemas de sus componentes. Antes de correlacionar presión y caudal, se debe saber si comparten unidad temporal, si tienen faltantes, qué

rango ocupan y si contienen cambios de escala. Una correlación calculada sobre variables mal comprendidas solo resume un error con precisión numérica.

Describir una variable requiere al menos cuatro preguntas: ¿qué representa?, ¿sobre qué población se observa?, ¿cómo se distribuye? y ¿qué medida resume el aspecto relevante sin ocultar su forma?

4.1.1. Población, muestra, parámetro y estadístico

La **población** es el conjunto de unidades sobre el cual se desea afirmar algo. Puede ser finita —todos los viajes registrados durante un mes— o conceptual —todos los viajes que podrían ocurrir bajo determinadas condiciones—. La población debe definirse mediante unidades, espacio, periodo y criterios de inclusión.

Una **muestra** es el subconjunto observado. Puede provenir de un diseño probabilístico, de una selección por conveniencia o de un proceso administrativo. Disponer de muchos registros no convierte una muestra de conveniencia en representativa. Un sistema puede registrar todos los viajes de un operador y ninguno de los restantes.

Un **parámetro** es una característica de la población: media μ , varianza σ^2 , proporción p o cuantil. Un **estadístico** es una función de la muestra: media $\bar{x}$, varianza s^2 o proporción $\hat{p}$. El estadístico se observa; el parámetro suele estimarse.

Para una muestra $X_1, \dots, X_n$, la media muestral es:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Si el muestreo es aleatorio e independiente bajo condiciones apropiadas, $\bar{X}$ estima μ . Esa frase contiene supuestos. Si las unidades con valores altos tienen menor probabilidad de inclusión, el promedio muestral puede ser sistemáticamente bajo.

Estimando y unidad de análisis

El **estimando** expresa con precisión qué cantidad se pretende conocer. “Consumo promedio” es ambiguo: puede ser promedio por conexión, por hogar, por día o por zona. También puede ponderar cada unidad de manera distinta.

Supóngase que una zona tiene diez conexiones y otra mil. El promedio de los dos promedios zonales otorga igual peso a ambas zonas; el promedio de todas las conexiones otorga igual peso a cada conexión. Ninguno es universalmente correcto. Responden preguntas diferentes.

Variabilidad muestral

Si se tomaran muestras distintas, el estadístico cambiaría. Esa variabilidad no es un error de programación, sino una propiedad del muestreo. La estadística inferencial, que se desarrollará más adelante, cuantifica esa incertidumbre. En este capítulo, incluso una descripción debe declarar si resume toda la población registrada o una muestra.

Ponderaciones

Cuando las unidades tienen probabilidades de inclusión diferentes, puede utilizarse una media ponderada:

$$\bar{x}_w = \frac{\sum_i w_i x_i}{\sum_i w_i}.$$

Los pesos deben tener significado: expansión poblacional, duración, importancia o confiabilidad. Elegirlos modifica el estimando. Una media ponderada sin explicación es menos interpretable que una media simple explícitamente limitada.

Práctica profesional

Antes de calcular, redacte: “Este estadístico describe ___ para ___ durante , **dando a cada** un peso de ___”. Si la frase resulta difícil, la unidad o el estimando no están definidos.

4.1.2. Distribuciones de frecuencias

Una distribución de frecuencias muestra cuántas observaciones adoptan cada valor o intervalo. Es la descripción más directa de una variable categórica y una aproximación fundamental para variables numéricas.

Para categorías $c_1, \dots, c_k$, la frecuencia absoluta es:

$$n_j = \sum_{i=1}^n \mathbb{I}(x_i = c_j),$$

donde $\mathbb{I}$ vale 1 cuando se cumple la condición. La frecuencia relativa es $f_j = n_j/n$ y la porcentual es $100f_j$.

Las frecuencias deben sumar n solo si cada observación pertenece exactamente a una categoría. En preguntas de selección múltiple, una unidad puede aportar a varias categorías y los porcentajes pueden superar 100 %. El denominador debe explicarse.

Variables ordinales y acumulación

En variables ordinales, la frecuencia acumulada:

$$F_j = \sum_{h \leq j} f_h$$

permite responder qué proporción está en o por debajo de un nivel. Acumular categorías nominales no tiene significado salvo que se imponga un orden externo.

Agrupación de variables numéricas

Para una variable continua se construyen intervalos. La anchura y los límites modifican la percepción. Intervalos demasiado amplios ocultan multimodalidad; demasiado estrechos muestran ruido. Reglas como Sturges o Freedman-Diaconis ofrecen puntos de partida, no decisiones definitivas.

La regla de Freedman-Diaconis propone anchura:

$$h = 2 \text{ IQR}(x) n^{-1/3}.$$

Es robusta frente a extremos, pero puede fallar con muestras pequeñas o distribuciones discretas. Conviene observar varias resoluciones y mantener límites comparables entre grupos.

Ceros y faltantes

Un cero puede ser valor real, ausencia de evento o código de faltante. Las celdas faltantes no deben desaparecer del denominador sin explicación. Una tabla profesional informa frecuencias válidas y cantidad excluida.

Comparación entre grupos

Los conteos absolutos reflejan tamaño del grupo. Para comparar zonas con distinta población se utilizan proporciones o tasas con denominador relevante. Aun así, una proporción basada en diez observaciones es más inestable que otra basada en diez mil; el tamaño debe acompañar al porcentaje.

4.1.3. Media, mediana y moda

Las medidas de tendencia central resumen dónde se concentra una distribución. No existe una medida “correcta” independientemente de la forma, la escala y la pregunta.

Media

La media es el punto de equilibrio aritmético. Utiliza todos los valores y posee propiedades algebraicas útiles. También minimiza la suma de errores cuadrados:

$$\bar{x} = \arg \min_a \sum_i (x_i - a)^2.$$

Esta propiedad explica su relación con regresión y MSE. Sin embargo, un valor extremo influye proporcionalmente a su distancia. En consumos muy asimétricos, la media puede describir carga total por unidad, pero no una experiencia típica.

Mediana

La mediana divide las observaciones ordenadas de modo que al menos la mitad queda a cada lado. Minimiza la suma de desviaciones absolutas:

$$\tilde{x} = \arg \min_a \sum_i |x_i - a|.$$

Es robusta a extremos y adecuada para distribuciones asimétricas. No utiliza la magnitud completa de las colas: dos distribuciones con la misma mediana pueden tener riesgos extremos muy diferentes.

Moda

La moda es el valor o categoría más frecuente. Es la única medida de tendencia central directamente aplicable a variables nominales. Puede haber varias modas o ninguna claramente dominante. En variables continuas, depende de la resolución o del método de estimación de densidad.

Elegir según la pregunta

Si se planifica volumen total, la media multiplicada por cantidad puede ser relevante. Si se describe un usuario típico ante una cola larga, la mediana suele ser más estable. Si se decide qué categoría abastecer, la moda puede ser útil. A menudo deben reportarse juntas.

Media recortada y estimadores robustos

La media recortada elimina una proporción simétrica de extremos antes de promediar. Ofrece un compromiso entre eficiencia de la media y robustez de la mediana. Su uso debe declarar porcentaje y propósito; no es una licencia para eliminar observaciones incómodas.

Error frecuente

Decir “el promedio es 40” sin especificar cuál convierte una decisión estadística en ambigüedad lingüística. En este libro, *media*, *mediana* y *moda* se nombran explícitamente.

4.1.4. Cuantiles y medidas de posición

El cuantil de orden p es un valor q_p tal que una proporción p de la distribución se encuentra, aproximadamente, por debajo. Los percentiles son cuantiles expresados en cien partes; los cuartiles corresponden a 25 %, 50 % y 75 %.

Los cuantiles describen posiciones sin suponer simetría. El percentil 90 del tiempo de viaje indica que 90 % de los viajes observados tiene duración no mayor que ese valor, bajo la población y periodo definidos.

Definiciones muestrales

En una muestra finita, pn puede no coincidir con una posición entera. Existen varios métodos de interpolación. Las herramientas pueden devolver resultados ligeramente distintos. En informes reproducibles se registra el método cuando las diferencias importan, especialmente con muestras pequeñas o datos discretos.

Cuantiles frente a máximos

El máximo es muy sensible a tamaño de muestra y errores. Un percentil alto, como 95 o 99, suele describir mejor servicio extremo recurrente. Sin embargo, para seguridad el máximo real puede ser importante. La elección depende del uso.

Percentil no es porcentaje

Estar en percentil 80 no significa obtener 80 % de una escala. Significa superar aproximadamente a 80 % de las observaciones de referencia. Si cambia la población de referencia, cambia la posición aunque el valor permanezca igual.

Comparación de distribuciones

Una tabla de cuantiles permite comparar centro y colas. Si dos zonas tienen mediana similar, pero el percentil 95 difiere mucho, la diferencia operativa está en episodios extremos. Esta observación puede quedar oculta al comparar solo medias.

Cuantiles ponderados

Con pesos, el cuantil se define mediante frecuencia acumulada ponderada. Es pertinente cuando la muestra representa unidades con probabilidades distintas. Como siempre, el peso cambia la población implícita.

4.1.5. Rango, varianza y desviación estándar

La tendencia central no describe cuánto varían los datos. Dos variables pueden tener igual media y comportamientos completamente diferentes.

Rango

El rango es $\max(x) - \min(x)$. Es intuitivo y muestra extensión observada, pero depende de dos valores y del tamaño muestral. También confunde variabilidad típica con extremos o errores.

Varianza poblacional y muestral

La varianza poblacional es:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2.$$

Cuando una muestra estima la varianza de una población, se utiliza frecuentemente:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

El denominador $n - 1$ corrige el sesgo asociado con estimar la media usando la misma muestra bajo supuestos habituales. Si los datos son toda la población de

interés, dividir por N puede ser apropiado. La fórmula depende del estimando, no de una preferencia de software.

Desviación estándar

La desviación estándar $s = \sqrt{s^2}$ vuelve a la unidad original. En una distribución aproximadamente normal, cerca de 68 % de las observaciones cae dentro de una desviación de la media y cerca de 95 % dentro de dos. Estas reglas no deben aplicarse mecánicamente a distribuciones asimétricas o multimodales.

Sensibilidad y unidades

La elevación al cuadrado hace que extremos tengan gran influencia. Cambiar unidades multiplica la desviación por el factor y la varianza por su cuadrado. Comparar desviaciones de variables en escalas distintas no tiene sentido directo.

Coeficiente de variación

El coeficiente $CV = s/\bar{x}$ expresa dispersión relativa para escalas de razón con media positiva. No es apropiado cuando la media está cerca de cero o el cero es convencional, como en Celsius.

Interpretación operativa

La variabilidad puede ser el fenómeno, no ruido. Un servicio con tiempo medio aceptable y desviación alta es impredecible para el usuario. Reportar solo media puede ocultar esa inestabilidad.

4.1.6. Rango intercuartílico

El rango intercuartílico es:

$$IQR = Q_3 - Q_1.$$

Describe la amplitud del 50 % central. Como depende de cuantiles, es robusto frente a extremos. Se utiliza junto con la mediana para resumir distribuciones asimétricas.

Regla de los bigotes

Una convención identifica valores fuera de:

$$Q_1 - 1.5 IQR \quad \text{y} \quad Q_3 + 1.5 IQR.$$

Estos límites definen observaciones potencialmente atípicas para un diagrama de caja; no demuestran error ni rareza sustantiva. En una distribución muy asimétrica puede haber muchos puntos legítimos fuera.

Comparación entre grupos

Mediana e IQR permiten comparar posición y dispersión robustas. Pero grupos pequeños producen cuantiles inestables. Debe mostrarse tamaño y, cuando sea posible, datos individuales o intervalos.

IQR y cobertura

Si faltan sistemáticamente los valores extremos, el IQR puede parecer pequeño. La robustez estadística no corrige sesgo de observación. Toda interpretación necesita volver al mecanismo de captura.

Desviación absoluta mediana

Otra medida robusta es:

$$MAD = \text{mediana}(|x_i - \tilde{x}|).$$

Puede escalarse para comparar con desviación estándar bajo normalidad. IQR y MAD responden de manera diferente a la forma; ninguna reemplaza observar la distribución.

4.1.7. Asimetría y curtosis

La **asimetría** describe falta de simetría alrededor del centro. Una cola larga hacia valores altos produce asimetría positiva; hacia valores bajos, negativa. En una distribución simétrica, media y mediana suelen estar próximas, aunque esa coincidencia no demuestra simetría.

El coeficiente momental poblacional es:

$$\gamma_1 = \frac{E[(X - \mu)^3]}{\sigma^3}.$$

El tercer momento conserva signo y da gran peso a extremos. Las versiones muestrales varían en correcciones. Por eso conviene acompañar el número con histograma, cuantiles y conocimiento del dominio.

La **curtosis** estandarizada utiliza el cuarto momento:

$$\gamma_2 = \frac{E[(X - \mu)^4]}{\sigma^4}.$$

Con frecuencia se reporta exceso de curtosis $\gamma_2 - 3$, que vale cero para una normal. La curtosis se interpreta mejor como sensibilidad a colas y extremos que como simple “altura” del pico.

Fuentes de asimetría

La asimetría puede ser natural, como ingresos o duraciones; surgir de límites, como variables no negativas; o resultar de mezcla de poblaciones. Una cola larga puede sugerir transformación logarítmica, métricas robustas o análisis separado, pero la decisión depende de la tarea.

Multimodalidad

Una distribución con dos grupos puede tener asimetría cercana a cero y aun ser mal resumida por media y desviación. La forma no se reduce a dos coeficientes. Deben buscarse modos, huecos, truncamientos y acumulaciones en límites.

Efectos de redondeo y censura

Valores acumulados en números redondos pueden indicar resolución o declaración aproximada. Un pico en el máximo del sensor puede indicar saturación. Estas formas son información sobre captura, no características puramente matemáticas.

4.1.8. Ejemplo práctico guiado: perfil estadístico del consumo eléctrico

Contexto y pregunta descriptiva

Una empresa dispone de lecturas diarias de medidores residenciales durante 2025. Se desea caracterizar el consumo eléctrico observado, su variación estacional y las diferencias entre grupos de hogares. El estudio es descriptivo: permite reconocer patrones y priorizar verificaciones, pero no atribuir conductas, fraude ni efectos causales.

Paso 1. Definir población, unidad y variable

La población objetivo son los 1 200 hogares residenciales activos en el área de estudio durante todo 2025. La unidad analítica es el **hogar-día** y la variable principal es la energía diaria registrada, expresada en kWh. Por tanto, un hogar con 365 días potenciales aporta hasta 365 unidades; esas observaciones repetidas no son independientes y no deben interpretarse como 438 000 hogares distintos.

Se excluyen locales comerciales, medidores de áreas comunes y fechas anteriores al alta o posteriores a la baja del servicio. Los resultados describen hogares con medición disponible en el periodo y no se generalizan automáticamente a viviendas no instrumentadas, desocupadas o fuera del área.

Paso 2. Auditar cobertura y calidad

El marco contiene $1\,200 \times 365 = 438\,000$ hogares-día potenciales. Se reciben 426 840 registros, una cobertura global de 97,45 %. De ellos, 1 280 están duplicados y se resuelven conservando la versión validada más reciente; 2 190 tienen lectura ausente y 370 presentan unidad o sello temporal inconsistente. El conjunto analítico queda en 423 000 hogares-día, equivalente al 96,58 % del marco.

La cobertura se calcula también por hogar, mes y grupo, porque un porcentaje global alto puede ocultar vacíos concentrados. El mínimo mensual es 92,1 % en julio, frente a valores superiores a 96 % en los demás meses. Cuarenta y dos hogares tienen menos de 80 % de días válidos: se mantienen en el inventario de cobertura, pero se excluyen de comparaciones de consumo anual por hogar. Los ceros válidos se conservan y se distinguen de ausencias; ni unos ni otras se imputan para este perfil inicial.

Paso 3. Resumir centro, posición y dispersión

Para los 423 000 hogares-día válidos se obtiene el siguiente perfil:

Medida	Resultado
Media	10,8 kWh/día
Desviación estándar	7,9 kWh/día
Mediana	8,7 kWh/día
Q_1 ; Q_3	5,1; 13,9 kWh/día
IQR	8,8 kWh/día
MAD	4,1 kWh/día
P_{90} ; P_{95} ; P_{99}	20,6; 25,8; 39,7 kWh/día

La media y la desviación estándar ofrecen el resumen clásico y permiten comparaciones con informes que usan momentos. La mediana, el IQR y el MAD proporcionan el resumen robusto, menos sensible a días excepcionalmente altos. Como la media supera a la mediana y los percentiles superiores se separan progresivamente, un único promedio no representa bien toda la forma observada.

Paso 4. Examinar forma, estacionalidad y grupos

El histograma, representado en escala original y en escala logarítmica para valores positivos, muestra asimetría a la derecha y no justifica asumir normalidad. El 1,8 % de los registros válidos corresponde a cero kWh; estos casos se presentan por separado porque pueden reflejar ausencia de consumo, vivienda temporalmente vacía o una incidencia de medición, alternativas que este conjunto no permite distinguir.

Las medianas mensuales son 7,4 kWh/día en abril, 8,5 en octubre y 12,6 en enero. Un gráfico de líneas de medianas mensuales, acompañado por bandas entre Q_1 y Q_3 y por la cobertura de cada mes, permite observar la estacionalidad sin ocultar dispersión ni calidad de registro. La coincidencia temporal con meses cálidos es una descripción; demostrar qué factor produjo el cambio requeriría temperatura, ocupación, equipamiento y un diseño analítico adecuado.

Para comparar grupos se emplean el mismo periodo, reglas de validez y unidad. En hogares clasificados por número declarado de residentes, la mediana es 6,3 kWh/día para 1-2 residentes, 9,1 para 3-4 y 13,0 para 5 o más. Se reportan además tamaño, IQR y cobertura de cada grupo. Estas diferencias son asociaciones descriptivas: los grupos también pueden diferir en superficie, artefactos eléctricos, hábitos, ingresos o frecuencia de ocupación.

Paso 5. Revisar extremos sin confundirlos con errores

La regla de Tukey fija como umbral superior $Q_3 + 1,5 IQR = 27,1$ kWh/día y marca 17 965 registros (4,25 %). La cantidad relativamente alta es compatible con una cola derecha y muestra que la regla sirve para señalar observaciones, no para diagnosticar errores. No se eliminan ni se reemplazan automáticamente los extremos.

La revisión separa tres situaciones: valores físicamente plausibles y persistentes en un hogar; saltos aislados que requieren contraste con lecturas vecinas; y registros

incompatibles con la unidad o capacidad documentada. Se conserva una bitácora de cada decisión. También se analizan rachas de ceros y cambios abruptos, pero se describen como casos por verificar, sin inferir fraude, intención ni causa.

Paso 6. Integrar visualizaciones y hallazgos defendibles

El informe combina: histograma con mediana y percentiles; diagrama de caja por mes; serie mensual con IQR y cobertura; cajas o violines por número de residentes; y gráfico de cada hogar frente a su mediana e IQR para priorizar revisiones. Los ejes indican kWh/día, periodo, denominador y tratamiento de ausencias; cada figura muestra conteos para evitar comparar grupos de tamaño desconocido.

Son hallazgos defendibles que la distribución hogar-día presenta cola derecha, que enero tiene una mediana 5,2 kWh/día mayor que abril y que el grupo de 5 o más residentes posee mediana e IQR superiores al de 1-2 residentes dentro de los registros válidos. También es defendible señalar que julio tiene menor cobertura y, por ello, su comparación exige especial cautela.

No es defendible concluir que los hogares con valores altos cometen fraude, que el número de residentes causa por sí solo mayor consumo o que el patrón mensual se debe exclusivamente al clima. El perfil está limitado por faltantes no necesariamente aleatorios, mediciones repetidas por hogar, posibles cambios de ocupación, calidad de la clasificación y ausencia de variables contextuales. La entrega final incluye tabla descriptiva, auditoría de cobertura, figuras reproducibles, listado trazable de casos por verificar y una declaración explícita del alcance poblacional y de estas limitaciones.

Actividad EMO [AGUA-03]: explorar patrones y anomalías en datos de agua

Capacidad mínima: describir distribuciones y separar hallazgos estadísticos de conclusiones operativas no demostradas.

Consigna: seleccionar variables de consumo, presión, caudal o calidad; definir población y unidad; calcular medidas clásicas y robustas; comparar grupos o periodos; representar distribuciones; proponer tres hallazgos que orienten una hipótesis o muestreo posterior.

Modalidad: exploración en parejas para contrastar decisiones; interpretación y entrega individuales sobre una zona o periodo asignado.

Evidencia individual: notebook o informe reproducible con tabla descriptiva, al menos tres visualizaciones, interpretación de cada una y advertencia sobre causalidad, cobertura o sesgo.

Criterios de aprobación:

- denominadores, unidades, población y faltantes están explícitos;
- medidas y gráficos corresponden a escala y forma;
- cada hallazgo posee evidencia visible o cuantificada;
- se distinguen extremo estadístico, error y evento que requiere investigación;
- se propone qué dato o análisis permitiría avanzar.

Preguntas para la defensa: ¿por qué eligió media o mediana?, ¿qué cambia al usar otro periodo?, ¿qué extremo no eliminaría?, ¿qué conclusión causal sería inválida?

4.2. Relaciones entre variables

Después de comprender cada variable se estudia cómo cambian juntas. Una relación puede ser útil para descripción o predicción sin representar causalidad. También puede desaparecer al controlar un grupo, cambiar de signo al agregar o estar producida por el propio mecanismo de observación.

La práctica responsable combina tablas, medidas y gráficos, y formula siempre una explicación alternativa. La pregunta no es solo “¿hay relación?”, sino “¿en qué población, forma, dirección, intensidad y condiciones aparece?”.

4.2.1. Tablas de contingencia

Una tabla de contingencia cruza categorías de dos variables. Si n_{ij} es el conteo en fila i y columna j , los marginales son $n_{i+} = \sum_j n_{ij}$ y $n_{+j} = \sum_i n_{ij}$.

Los conteos muestran volumen, pero la asociación se interpreta con proporciones condicionadas. La proporción por fila es:

$$p_{j|i} = \frac{n_{ij}}{n_{i+}}.$$

Indica distribución de columnas dentro de cada fila. Invertir el condicionamiento responde otra pregunta. “Proporción de incidentes entre viajes nocturnos” no es igual a “proporción de viajes nocturnos entre incidentes”.

Independencia

Si dos variables fueran independientes, la frecuencia esperada sería:

$$e_{ij} = \frac{n_{i+}n_{+j}}{n}.$$

Comparar observados y esperados ayuda a localizar celdas responsables de asociación. Una prueba chi-cuadrado resume discrepancias, pero con muestras grandes puede detectar diferencias pequeñas sin importancia práctica. Deben reportarse magnitud y contexto.

Categorías raras y ceros

Celdas pequeñas vuelven inestables las proporciones. Agrupar categorías requiere criterio sustantivo y no debe ocultar grupos relevantes. Un cero puede ser ausencia real o falta de cobertura. La tabla debe mostrar denominadores.

Estratificación

Una asociación global puede diferir por zona, periodo o grupo. Construir tablas estratificadas permite observar heterogeneidad y detectar confusión. No se deben crear tantos estratos que todas las celdas queden vacías.

Medidas de asociación

Para tablas 2×2 pueden calcularse diferencia de riesgos, razón de riesgos u odds ratio. Cada una responde una escala distinta. No debe confundirse odds ratio con riesgo relativo cuando el evento es frecuente.

4.2.2. Covarianza

La covarianza mide variación lineal conjunta. Para población:

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])].$$

En muestra:

$$s_{xy} = \frac{1}{n-1} \sum_i (x_i - \bar{x})(y_i - \bar{y}).$$

Si ambas variables tienden a estar por encima de sus medias al mismo tiempo, la covarianza es positiva; si una sube cuando otra baja, negativa. Una covarianza cercana a cero indica ausencia de relación lineal promedio, no independencia.

Dependencia de unidades

La covarianza se expresa en producto de unidades. Cambiar metros a centímetros la multiplica por cien. Por eso su magnitud no permite comparar directamente pares de variables con escalas distintas.

Matriz de covarianzas

Para un vector $X \in \mathbb{R}^p$, la matriz Σ contiene varianzas en diagonal y covarianzas fuera. Es fundamental en PCA, modelos multivariados y distribuciones conjuntas. Debe ser simétrica y semidefinida positiva.

Interpretación geométrica

Una nube alargada con pendiente positiva produce covarianza positiva. Si la nube forma un círculo, puede ser cercana a cero. Si forma una U, también puede ser cero a pesar de una relación fuerte no lineal. El diagrama de dispersión es indispensable.

En el panel izquierdo, las desviaciones respecto de las medias tienden a compartir signo y sus productos son positivos. En la nube circular, los productos positivos y negativos se compensan sin una dirección dominante. En la relación en U también se compensan, pero existe una dependencia determinista aproximada entre X y Y . Los dos últimos casos muestran por qué un valor cercano a cero solo descarta una asociación lineal promedio, no toda dependencia.

Sensibilidad

Como utiliza productos de desviaciones, es sensible a extremos. Un único caso puede cambiar signo. Se deben revisar valores influyentes y considerar medidas robustas o transformaciones cuando corresponda.

La covarianza resume asociación lineal, no toda forma de dependencia




Figura 5: Interpretación geométrica de la covarianza

4.2.3. Correlación lineal

La correlación de Pearson estandariza la covarianza:

$$r = \frac{s_{xy}}{s_x s_y}, \quad -1 \leq r \leq 1.$$

Es invariante a cambios lineales positivos de escala. $r = 1$ indica que los puntos se encuentran sobre una recta creciente; $r = -1$, sobre una decreciente. $r = 0$ indica ausencia de asociación lineal muestral.

Magnitud y contexto

No existen umbrales universales para “débil” o “fuerte”. Una correlación pequeña puede ser importante en fenómenos complejos; una alta puede ser trivial o espuria. Debe interpretarse junto con rango, ruido, costo y propósito.

Restricción de rango

Si se observa solo una parte estrecha de X , la correlación puede disminuir. Comparar correlaciones entre poblaciones con rangos distintos puede ser engañoso. También mezclar grupos puede crear una relación que no existe dentro de ninguno.

La correlación depende del rango observado y de la composición de la población




Figura 6: Restricción de rango y mezcla de grupos

Los dos primeros paneles proceden de la misma relación subyacente. Al conservar únicamente una franja estrecha de X , la variación de la señal se reduce mientras el ruido conserva una magnitud semejante; como consecuencia, la correlación observada disminuye. En el tercer panel, cada grupo presenta una correlación interna cercana a cero, pero sus centros ocupan regiones diferentes y la mezcla produce una correlación global alta. El coeficiente siempre describe la población efectivamente observada, no una propiedad invariable de las variables.

Correlación y pendiente

La correlación no es pendiente. La pendiente de regresión de Y sobre X es $r(s_y/s_x)$ y depende de unidades. Una correlación alta no significa que un cambio unitario tenga efecto grande.

Incertidumbre

La correlación muestral varía entre muestras. Con pocos casos puede ser inestable. Deben informarse tamaño, gráfico e intervalo cuando se hace inferencia. Reportar varios decimales no agrega certeza.

Matrices de correlación

Una matriz facilita explorar muchas variables, pero genera numerosas comparaciones y oculta formas no lineales. Debe utilizarse como mapa para investigar, no como conclusión final. Las variables derivadas unas de otras producen correlaciones mecánicas.

4.2.4. Correlaciones no paramétricas

Las correlaciones de rango estudian relaciones monotónicas y reducen sensibilidad a escala y algunos extremos.

Spearman

La correlación de Spearman es la correlación de Pearson aplicada a rangos. Sin empates, puede expresarse como:

$$\rho_s = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)},$$

donde d_i es diferencia entre rangos. Detecta si al aumentar una variable la otra tiende a aumentar o disminuir, aunque la forma no sea lineal.

Kendall

La correlación de Kendall compara el orden relativo de todos los pares de observaciones. Sean dos observaciones (x_i, y_i) y (x_j, y_j) , con $i < j$. El par es **concordante** cuando ambas variables cambian en la misma dirección:

$$(x_i - x_j)(y_i - y_j) > 0.$$

Es **discordante** cuando cambian en direcciones opuestas:

$$(x_i - x_j)(y_i - y_j) < 0.$$

Si alguna diferencia es cero, existe un empate en la variable correspondiente. Cuando no hay empates, existen $n_0 = n(n-1)/2$ pares posibles. El coeficiente conocido como τ_a se define como:

$$\tau_a = \frac{C - D}{n_0} = \frac{C - D}{n(n-1)/2},$$

donde C es la cantidad de pares concordantes y D la cantidad de discordantes. El coeficiente está acotado entre -1 y 1 . Un valor de 1 significa que todos los pares conservan el orden; -1 , que todos lo invierten; y un valor cercano a cero, que concordancias y discordancias se compensan.

Una interpretación especialmente útil es:

$$\tau = P(\text{par concordante}) - P(\text{par discordante}).$$

Por tanto, Kendall mide la diferencia entre la probabilidad de que dos observaciones elegidas al azar aparezcan en el mismo orden en ambas variables y la probabilidad de que aparezcan en orden opuesto.

Corrección por empates: τ_b

En datos reales son frecuentes los empates, especialmente en escalas ordinales. La versión τ_a los incluye en el número total de pares y puede reducir artificialmente la magnitud. Kendall τ_b corrige el denominador:

$$\tau_b = \frac{C - D}{\sqrt{(n_0 - n_1)(n_0 - n_2)}},$$

donde:

$$n_1 = \sum_g \frac{t_g(t_g - 1)}{2}, \quad n_2 = \sum_h \frac{u_h(u_h - 1)}{2}.$$

t_g es el tamaño del grupo de observaciones empatadas en X y u_h el tamaño del grupo empatado en Y . Cuando no existen empates, $n_1 = n_2 = 0$ y $\tau_b = \tau_a$.

Ejemplo mínimo

Considérense cuatro observaciones cuyos rangos en X son $(1, 2, 3, 4)$ y en Y son $(1, 3, 2, 4)$. Hay seis pares posibles. Cinco son concordantes y uno —el formado por los rangos segundo y tercero— es discordante. Por tanto:

$$\tau_a = \frac{5 - 1}{6} = \frac{2}{3} \approx 0.67.$$

La asociación ordinal es positiva: 83,3 % de los pares conserva el orden y 16,7 % lo invierte. El valor 0.67 es la diferencia entre esas proporciones, no la proporción de pares concordantes por sí sola.

Kendall suele producir valores absolutos menores que Spearman porque ambos coeficientes usan escalas e interpretaciones distintas. No debe concluirse por ello que detecta una relación “más débil”. Resulta especialmente interpretable cuando interesa la concordancia entre rankings, hay muestras pequeñas o abundan empates, usando la variante adecuada.

Qué no resuelven

“No paramétrica” no significa sin supuestos. Las medidas requieren observaciones comparables y una relación monótonica para resumir bien. Una U puede producir correlación de rango cercana a cero. Tampoco corrigen confusión o causalidad.

Elección

Pearson responde por linealidad y es sensible a magnitudes; Spearman y Kendall responden por orden monótonico. La decisión debe basarse en pregunta, escala, forma y extremos, no en elegir el coeficiente que resulte más alto.

4.2.5. Asociación frente a causalidad

Una asociación describe cómo se distribuyen variables juntas. Una afirmación causal sostiene que intervenir sobre X modificaría Y , manteniendo un marco de comparación. La diferencia no es terminológica; determina qué decisión puede justificarse.

En lenguaje de resultados potenciales, el efecto para una unidad compara $Y(1)$ y $Y(0)$, resultados bajo dos acciones. Nunca se observan ambos simultáneamente para la misma unidad. La inferencia causal necesita construir un contrafactual mediante diseño o supuestos.

Causas de asociación no causal

- una tercera variable influye en ambas;
- Y causa X ;
- la selección depende de ambas;
- existe tendencia temporal común;
- se probaron muchas relaciones y se eligió una;
- las variables comparten parte de su definición.

Temporalidad

Que X ocurra antes de Y es necesario para una causa, pero no suficiente. La lluvia puede preceder reclamos y fugas sin que los reclamos causen fugas. El tiempo ayuda a descartar hipótesis, no a confirmar por sí solo.

Experimentos y evidencia observacional

La asignación aleatoria facilita interpretar diferencias como efectos bajo cumplimiento y medición adecuados. Cuando no es posible, se utilizan diseños

observacionales con ajuste, emparejamiento, discontinuidades o series interrumpidas, cada uno con supuestos. Una visualización exploratoria puede motivar esos diseños, no reemplazarlos.

Lenguaje responsable

“Se asocia”, “coincide” o “predice” describen evidencia distinta de “produce”, “reduce” o “causa”. El verbo debe corresponder al diseño, no a la fuerza visual del gráfico.

4.2.6. Variables de confusión

Una variable de confusión Z se relaciona con exposición X y resultado Y y puede crear o distorsionar su asociación. En movilidad, hora del día puede afectar demanda y retraso; comparar ambas sin controlar hora mezcla efectos.

La hora del día puede crear una asociación global entre demanda y retraso




Figura 7: Variable de confusión en movilidad

El panel central ignora la franja horaria y muestra una correlación positiva: los periodos con mayor demanda también parecen tener mayor retraso. El panel derecho revela el mecanismo oculto. Dentro de hora valle y hora pico, la demanda varía sin una asociación lineal apreciable con el retraso; la correlación global surge porque ambos grupos tienen centros diferentes. La hora del día actúa como causa común de la demanda observada y de las condiciones de circulación. Estratificar permite describir la relación dentro de niveles comparables, aunque no garantiza por sí solo una estimación causal si quedan otros confusores o si la franja fue definida de manera inadecuada.

Ejemplo de inversión

Dos rutas pueden mostrar dentro de cada franja que más demanda se asocia con menor retraso, pero globalmente lo contrario si las franjas de mayor demanda son también las más congestionadas. Esta inversión se relaciona con la paradoja de Simpson.

Identificar confusores

No se eligen solo por correlación estadística. Se utiliza conocimiento temporal y causal: el confusor precede a exposición y resultado y no debe ser consecuencia de

la exposición. Ajustar indiscriminadamente puede introducir sesgo, por ejemplo al controlar un mediador o un colisionador.

Estratificación y ajuste

La exploración puede comparar relaciones dentro de niveles de Z , estandarizar o usar modelos multivariados. Si las estimaciones cambian sustancialmente, la asociación cruda no era estable. Aun así, ajustar variables observadas no elimina confusión no medida.

Confusión frente a modificación de efecto

Si la relación cambia entre grupos porque el efecto realmente difiere, existe heterogeneidad o modificación de efecto, no solo confusión. Debe reportarse en lugar de forzar un único promedio.

Datos de observación

La intensidad de medición puede ser confusora. Zonas con más sensores producen más alertas y reciben más mantenimiento. Cobertura y política de observación deben incluirse en el razonamiento.

4.2.7. Análisis multivariado exploratorio

El análisis multivariado estudia varias variables conjuntamente para detectar estructura, redundancia, grupos, gradientes y casos atípicos. No consiste en calcular todas las correlaciones posibles, sino en formular vistas complementarias.

Matrices y pares

Una matriz de gráficos de dispersión combina distribuciones marginales y relaciones por pares. El color puede representar grupo, pero demasiadas variables producen sobrecarga. Se seleccionan variables según hipótesis y procedencia.

Estandarización

Cuando se comparan distancias o componentes, variables con mayor escala dominan. Estandarizar puede equilibrar, pero otorga igual importancia matemática, no necesariamente sustantiva. Variables redundantes pueden seguir pesando doble.

Componentes y representaciones

PCA proyecta combinaciones de máxima varianza y se desarrollará en el Capítulo 10. En exploración permite visualizar alta dimensión, pero los componentes son construcciones lineales y pueden estar dominados por calidad o escala.

Anomalías multivariadas

Una observación puede ser normal en cada variable y extraña en combinación. Presión y caudal individualmente plausibles pueden violar su relación física. Los casos deben investigarse en el espacio relevante y con contexto.

Estrategia de trabajo

Una secuencia eficaz es:

- comprender cada variable y su calidad
- seleccionar relaciones vinculadas con preguntas
- visualizar pares y estratos
- cuantificar asociaciones apropiadas
- buscar estructura multivariada y casos influyentes
- formular explicaciones alternativas
- registrar hipótesis para análisis confirmatorio

La exploración genera candidatos. Para conservar honestidad, las hipótesis descubiertas deben evaluarse después en datos independientes cuando se pretenda confirmarlas.

4.2.8. Ejemplo práctico guiado: análisis de factores asociados con retrasos de transporte**Pregunta y datos**

Se estudia la relación entre retraso, franja, clima, ruta y demanda. La unidad es viaje completado. Los datos no incluyen todos los operadores y el retraso se define respecto del horario planificado.

Análisis univariado previo

Se revisan distribuciones y faltantes. El retraso tiene cola derecha; demanda varía por hora; clima falta en zonas alejadas. Estas características condicionan medidas y comparaciones.

Relaciones categóricas

Una tabla cruza retraso crítico con franja. Se comparan proporciones dentro de cada franja, no solo conteos. Luego se estratifica por ruta para comprobar si la asociación persiste.

Relaciones numéricas

Se grafican demanda y retraso con transparencia y curvas descriptivas. Se calculan Pearson y Spearman. La diferencia entre ambos sugiere relación monotónica no lineal o influencia de extremos.

Confusión

Hora afecta demanda y tráfico. Clima afecta tiempo y puede cambiar demanda. Ruta determina distancia e infraestructura. Se construye un diagrama conceptual y se evita interpretar la correlación demanda-retraso como efecto causal directo.

Hallazgo

Una conclusión adecuada podría ser: "Dentro de la franja pico y en las rutas observadas, los viajes con mayor demanda presentan una mediana de retraso

superior, aunque la magnitud varía por ruta y la cobertura climática es desigual”. Esto justifica modelado o muestreo adicional, no una política causal inmediata.

4.3. Visualización exploratoria

Una visualización codifica datos mediante posición, longitud, área, color, forma o movimiento. Cada elección favorece ciertas comparaciones y dificulta otras. El objetivo de una gráfica exploratoria es permitir que el analista interroge la distribución, detecte errores, compare grupos y formule hipótesis. Su objetivo no es impresionar ni confirmar una historia elegida de antemano.

La visualización forma parte del método. Cambiar escala, agregación o denominador puede cambiar el patrón visible. Por ello, un gráfico debe ser reproducible y conservar las mismas definiciones que las estadísticas que acompaña.




Figura 8: Guía de selección de gráficos

4.3.1. Principios de percepción visual

La percepción humana compara algunas codificaciones con mayor precisión que otras. La posición sobre una escala común suele ser más precisa que longitud, ángulo, área o intensidad de color. Esta jerarquía explica por qué las barras alineadas facilitan comparar magnitudes y los gráficos de torta dificultan distinguir sectores similares.

Atención preatentiva

Ciertos rasgos —color distinto, orientación, tamaño— se detectan rápidamente. Deben utilizarse para destacar la evidencia principal, no para decorar cada elemento. Si todo está resaltado, nada guía la atención.

Agrupamiento

Proximidad, semejanza y conexión hacen que elementos se perciban como grupo. Un espacio mayor puede sugerir separación conceptual; líneas pueden sugerir continuidad. La estructura visual debe corresponder con la estructura de datos.

Posición y escalas

Comparar posiciones requiere escalas comunes. Paneles con ejes distintos pueden hacer que cambios pequeños parezcan iguales a grandes. A veces las escalas libres revelan forma interna; otras veces impiden comparación. La decisión debe declararse.

Color

Paletas secuenciales representan magnitud ordenada; divergentes, distancia a un centro significativo; cualitativas, categorías. El arcoíris crea fronteras perceptivas artificiales y no posee orden uniforme. Debe considerarse daltonismo y reproducción en escala de grises.

Carga cognitiva

Cada eje, símbolo, leyenda y anotación exige interpretación. Eliminar elementos innecesarios mejora claridad, pero eliminar contexto puede engañar. La simplicidad efectiva conserva todo lo necesario para responder la pregunta.

Diseño para comparación

La visualización funciona cuando el lector puede realizar la comparación relevante sin cálculos mentales excesivos. Si interesa diferencia entre periodos, deben alinearse; si interesa composición, debe verse denominador; si interesa incertidumbre, no debe ocultarse detrás de una línea única.

4.3.2. Histogramas y gráficos de densidad

El histograma divide el eje en intervalos y representa frecuencia o densidad. Revela centro, dispersión, asimetría, modos, huecos y acumulaciones.

Elección de intervalos

Los límites cambian la apariencia. Para comparar grupos se utilizan los mismos cortes. Probar varias anchuras ayuda a separar estructura estable de artefactos. Los intervalos deben respetar resolución: no tiene sentido crear cientos de bins para una variable registrada en enteros pequeños.

Si las alturas son conteos, el área depende de anchura. Con intervalos desiguales se utiliza densidad para que el área represente proporción. Etiquetar correctamente evita interpretar altura como frecuencia absoluta.

Gráficos de densidad

Una estimación kernel suaviza observaciones:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right).$$

El ancho de banda h controla suavizado. Un valor pequeño produce muchos picos; uno grande puede ocultar modos. La curva no son datos observados y puede asignar densidad fuera de límites naturales, como valores negativos de consumo.

Comparar grupos

Superponer demasiadas densidades produce confusión. Paneles pequeños, histogramas alineados o ridgelines pueden ser mejores. Además de forma, se reportan tamaños. Una densidad normalizada hace que un grupo de cien observaciones parezca tan prominente como otro de diez mil.

Faltantes y truncamiento

El histograma solo muestra valores observados. Debe acompañarse con cantidad de faltantes y explicar filtros. Los máximos administrativos o del sensor pueden generar picos que merecen anotación.

Lectura profesional

Antes de interpretar una “segunda moda”, cambie bins, revise grupos y confirme que no sea cambio de unidad o combinación de poblaciones. La forma visual genera una hipótesis, no una explicación automática.

4.3.3. Diagramas de caja y violín

El diagrama de caja resume mediana, cuartiles, IQR y observaciones fuera de bigotes. Es compacto y facilita comparar muchos grupos. Su principal fortaleza es también su límite: reduce la distribución a pocos elementos.

Qué muestra una caja

La caja se extiende de Q_1 a Q_3 ; una línea marca mediana; los bigotes suelen llegar hasta el valor más extremo dentro de $1.5IQR$. Los puntos restantes no son “errores”, sino observaciones fuera de esa convención.

Distintas herramientas pueden usar bigotes diferentes. El informe debe aclararlo si importa. El ancho de la caja puede representar tamaño, pero no debe suponerse sin leyenda.

Lo que puede ocultar

Distribuciones muy distintas pueden compartir caja. La multimodalidad desaparece. Con muestras pequeñas, los cuantiles son inestables y la caja da una apariencia de precisión excesiva. Añadir puntos individuales o un gráfico de violín ayuda.

Violines

El violín refleja densidad suavizada a ambos lados. Muestra modos y forma, pero depende del ancho de banda y puede parecer preciso donde hay pocos datos. Debe combinarse con mediana, cuantiles y tamaño.

Comparación ordenada

Ordenar grupos por mediana o criterio sustantivo facilita lectura. El orden alfabético rara vez responde la pregunta. Si se comparan periodos, se conserva orden temporal.

Interpretación

Una caja más alta indica mayor IQR, no necesariamente mayor varianza. Bigotes superpuestos no constituyen una prueba estadística. El gráfico orienta preguntas; la comparación inferencial necesita métodos apropiados.

4.3.4. Gráficos de barras y proporciones

Las barras codifican magnitud mediante longitud desde una línea base. Son adecuadas para conteos, tasas y valores agregados por categoría.

Eje en cero

Como se compara longitud, el eje cuantitativo debe comenzar en cero en la mayoría de los gráficos de barras. Truncarlo exagera diferencias. Si se necesita mostrar pequeñas variaciones, un punto con intervalo puede ser más honesto.

Conteos, proporciones y tasas

El título y eje deben indicar qué se representa. Conteos responden volumen; proporciones, composición; tasas, ocurrencia respecto de exposición. Una zona grande tendrá más reclamos aunque su tasa sea menor.

Barras agrupadas y apiladas

Las agrupadas facilitan comparar categorías dentro de grupos, pero muchas barras saturan. Las apiladas muestran composición total; solo el primer segmento comparte línea base. Las apiladas al 100 % comparan proporciones y ocultan volumen. A menudo conviene mostrar volumen y proporción en paneles separados.

Orden y categorías

Ordenar por valor facilita ranking; ordenar por nivel conserva ordinalidad; usar orden fijo permite comparar periodos. La categoría "otros" debe explicar qué agrupa. Excluir categorías pequeñas puede distorsionar total.

Intervalos

Si las barras representan estimaciones muestrales, deben incluir incertidumbre o tamaño. Las barras de error pueden representar desviación, error estándar o intervalo; la leyenda debe aclararlo.

4.3.5. Diagramas de dispersión

El diagrama de dispersión representa pares (x_i, y_i) y permite observar forma, dirección, fuerza, heterogeneidad y casos influyentes.

Forma antes que coeficiente

Se debe observar linealidad, curvatura, grupos y límites antes de calcular correlación o ajustar recta. Un coeficiente resume una forma asumida; el gráfico muestra si esa forma es plausible.

Sobreposición

Con muchos puntos, la sobreposición oculta densidad. Transparencia, puntos pequeños, muestreo, hexágonos o contornos ayudan. Muestrear debe conservar estructura y declararse; puede perder eventos raros.

Terceras variables

Color, forma o panel pueden representar un grupo. El tamaño de punto es menos preciso y puede dominar visualmente; debe usarse para magnitudes positivas con leyenda clara. Agregar demasiadas dimensiones dificulta comparar.

Curvas descriptivas

Una línea suavizada ayuda a observar tendencia no lineal, pero depende de parámetros y puede sugerir certeza. Debe acompañarse con datos e intervalo cuando corresponda. Una recta no demuestra causalidad.

Escalas logarítmicas

Son útiles para órdenes de magnitud y relaciones multiplicativas. El eje debe indicarlo y no admitir ceros sin tratamiento explícito. Una distancia visual igual representa razón, no diferencia absoluta.

Residuos y subgrupos

Los puntos alejados de una tendencia pueden revelar error o casos importantes. También se debe comprobar si la relación global está producida por grupos. Paneles por ruta o periodo pueden cambiar la interpretación.

4.3.6. Mapas de calor

Un mapa de calor codifica una matriz mediante color. Puede representar correlaciones, frecuencias, intensidad temporal o valores por combinación de categorías.

Orden de filas y columnas

El orden determina patrones visibles. Para tiempo se usa orden cronológico; para categorías, orden sustantivo o agrupamiento. Reordenar por clustering puede revelar bloques, pero debe indicarse porque altera la disposición original.

Escala de color

Una matriz de correlación necesita paleta divergente centrada en cero y límites simétricos. Una frecuencia usa paleta secuencial. Cambiar límites entre paneles impide comparar. Los faltantes deben tener color distinto, no confundirse con cero.

Anotaciones

Mostrar números en todas las celdas puede saturar. Se anotan valores relevantes o se ofrece interacción. El color sirve para patrones; la cifra, para precisión.

Matrices de correlación

La simetría duplica información. Se puede mostrar un triángulo. Debe revisarse tamaño muestral por par si hay faltantes y no interpretar color intenso como causalidad.

Calendarios y espacio-tiempo

Filas por día y columnas por hora revelan ciclos. La agregación debe ser comparable; una celda con poca cobertura necesita marca. Un patrón visual puede surgir de diferente cantidad de observaciones.

4.3.7. Visualización temporal y geográfica

El tiempo y el espacio introducen orden y dependencia. No son categorías ordinarias.

Series temporales

Una línea conecta observaciones en orden temporal y sugiere continuidad. Es adecuada cuando existe secuencia comparable. Los puntos irregulares no deben conectarse como si tuvieran intervalos iguales sin indicación.

La gráfica debe mostrar frecuencia, huecos y cambios de definición. Agregar bandas de variabilidad, eventos y referencias ayuda a interpretar. Suavizar revela tendencia, pero puede desplazar picos y ocultar cambios abruptos.

Comparar periodos requiere alinear calendario, días hábiles y estacionalidad. Un cambio respecto del mes anterior puede ser normal si ese mes es estacionalmente bajo.

Mapas geográficos

Un mapa coroplético colorea áreas por tasa o proporción, no habitualmente por conteo bruto. Las áreas grandes dominan visualmente aunque tengan poca población. El denominador debe corresponder a la población expuesta.

Los mapas de puntos muestran ubicaciones; densidad espacial resume concentración; flujos representan conexiones. La proyección cartográfica distorsiona distancia o área de distintas maneras y debe ser apropiada para la región.

Clasificación de colores

Intervalos iguales, cuantiles y cortes de dominio producen mapas diferentes. Cuantiles reparten zonas entre colores aunque diferencias sean pequeñas; cortes fijos permiten comparar fechas. La leyenda debe mostrar límites y casos sin datos.

Privacidad

Mapear ubicaciones exactas puede reidentificar personas o infraestructura sensible. Agregación, desplazamiento o acceso restringido deben evaluarse. La utilidad visual no justifica exposición innecesaria.


Dependencia espacial

Zonas vecinas suelen parecerse. Un patrón puede reflejar tamaño, cobertura o frontera administrativa. El mapa genera hipótesis; el análisis espacial formal necesita modelos y pruebas adicionales.

4.3.8. Errores y manipulaciones frecuentes

Una gráfica puede ser técnicamente correcta y retóricamente engañosa. La intención no siempre es manipular; muchos errores provienen de plantillas o desconocimiento. La responsabilidad consiste en revisar cómo podría interpretarla un lector razonable.

Los mismos valores producen impresiones visuales diferentes



La diferencia absoluta es 4 en ambos paneles; el segundo exagera su magnitud relativa.

Figura 9: Efecto de una escala truncada

Ejes truncados y escalas inconsistentes

En barras, truncar el eje exagera. En líneas puede ser útil para variación pequeña si se señala claramente y se ofrece contexto. Cambiar escalas entre paneles puede

hacer iguales tendencias de magnitud distinta.

Área y volumen

Si el valor controla radio, el área crece con el cuadrado y exagera diferencias. Los pictogramas tridimensionales son aún peores. Cuando se usa área, debe escalarse proporcionalmente al dato.

Selección de periodo

Elegir un inicio excepcional puede fabricar una tendencia. Se debe justificar ventana y, cuando sea pertinente, mostrar contexto histórico. Cambiar fecha de corte después de ver resultados es selección oportunista.

Doble eje

Dos ejes verticales permiten ajustar escalas para hacer coincidir curvas. Si se usan, deben tener relación justificable y señalización fuerte. Paneles alineados suelen ser más seguros.

Promedios sin distribución

Una barra de media oculta forma, extremos y tamaño. Debe complementarse con puntos, intervalos o distribuciones. El gráfico no debe sugerir que todos los casos se parecen al promedio.

Color y categorías

Colores intensos pueden atribuir gravedad sin criterio. Paletas divergentes necesitan centro significativo. Reordenar categorías entre gráficos obliga a reaprender la leyenda y facilita comparaciones erróneas.

Omisión de datos

Excluir faltantes, grupos o periodos sin indicarlo produce una narrativa incompleta. Toda figura debe poder responder cuántas observaciones representa y qué quedó fuera.

4.3.9. Ejemplo práctico guiado: panel exploratorio de movilidad

Pregunta y unidad

El panel busca identificar cuándo y dónde se concentra demanda y qué patrones requieren análisis. La unidad es zona-hora. No se presenta como tablero operativo hasta validar actualización y cobertura.

Vista temporal

Una línea muestra viajes por hora con bandas por día de semana. Se anotan feriados y faltantes. Un mapa de calor día-hora permite detectar ciclos. Ambas vistas usan el mismo denominador y zona horaria.

Vista espacial

Un mapa representa viajes por kilómetro cuadrado o por población, según pregunta, y muestra por separado el conteo. Las zonas sin cobertura tienen color propio. Los cortes se mantienen fijos entre periodos.

Distribución por zona

Diagramas de caja comparan demanda horaria y revelan heterogeneidad. Los puntos extremos se vinculan con eventos conocidos o se marcan para investigar.

Coordinación

Filtros de fecha y zona actualizan todas las vistas. El panel conserva título dinámico, unidad y fecha de actualización. Una tabla de calidad muestra cobertura y operadores incluidos.

Interpretación

El panel permite afirmar dónde hay registros y cómo varían; no demuestra demanda total si faltan operadores ni explica causalmente los picos. Cada hallazgo incluye limitación y próximo análisis.

Actividad EMO [MOV-01]: construir un diagnóstico geotemporal de movilidad

Capacidad mínima: preparar y representar correctamente datos con componentes espacial y temporal.

Consigna: construir unidades geotemporales comparables, mapear intensidad de viajes o demanda, elaborar una vista temporal y detectar al menos dos patrones y una observación atípica.

Modalidad: preparación de datos en equipo; visualizaciones, interpretación y defensa individuales sobre zonas o periodos distintos.

Evidencia individual: notebook con mapa, gráfico temporal, distribución complementaria, definición de granularidad, cobertura y tres conclusiones justificadas.

Criterios de aprobación:

- la agregación conserva una unidad clara;
- denominadores y escalas permiten comparar;
- faltantes y zonas sin cobertura son visibles;
- los gráficos responden preguntas específicas;
- las conclusiones reconocen estacionalidad, selección y sesgos de registro.

Preguntas para la defensa: ¿por qué eligió esa granularidad?, ¿qué cambia con otra clasificación del mapa?, ¿el atípico es error o evento?, ¿qué operador o población falta?

4.4. Comunicación de resultados

La exploración sirve al analista; la comunicación sirve a una audiencia. Transformar una en otra requiere seleccionar evidencia, ordenar argumentos y adaptar detalle sin alterar significado. Comunicar no es simplificar hasta eliminar incertidumbre, sino hacerla comprensible y relevante.

Una comunicación responsable distingue dato, interpretación y recomendación. El lector debe poder reconocer qué se observó, qué inferencia se propone y qué decisión se sugiere.

4.4.1. Pregunta, evidencia y mensaje principal

Una pieza eficaz responde una pregunta. El mensaje principal es una oración que expresa el hallazgo más importante para esa pregunta, con población, magnitud y contexto.

“Consumo de agua” es un tema, no un mensaje. “Durante verano, el percentil 95 de consumo en la zona B fue 30 % mayor que en invierno, con cobertura superior a 90 %” es una afirmación verificable.

Estructura de evidencia

Una comunicación puede organizarse como:

1. pregunta y por qué importa;
2. evidencia principal;
3. interpretación limitada;
4. incertidumbre y alternativas;
5. acción o siguiente paso.

La recomendación no debe aparecer antes de establecer evidencia. Tampoco debe presentarse como inevitable si depende de costos y preferencias no discutidos.

Título informativo

Un título descriptivo dice qué muestra; uno informativo resume el hallazgo. El segundo ayuda a orientar, pero debe evitar causalidad no demostrada. “Mayor demora coincide con hora pico en rutas observadas” es más prudente que “La demanda causa las demoras”.

Trazabilidad

Toda cifra importante debe poder rastrearse a fuente, definición y transformación. En un informe breve puede incluirse una nota metodológica o enlace. La concisión no justifica resultados imposibles de auditar.

4.4.2. Selección del gráfico según el objetivo

La variable no determina por sí sola el gráfico; también importa la tarea perceptiva.

Objetivo	Opciones frecuentes	Pregunta de control
Comparar magnitudes	Barras, puntos	¿Comparten línea base?

Objetivo	Opciones frecuentes	Pregunta de control
Mostrar distribución	Histograma, caja, violín	¿Se ve forma y tamaño?
Relacionar variables	Dispersión, hexágonos	¿Se observa sobreposición?
Mostrar evolución	Línea, puntos temporales	¿La frecuencia es regular?
Mostrar composición	Barras apiladas	¿Importa volumen o proporción?
Mostrar espacio	Mapa de puntos o coroplético	¿Existe denominador adecuado?

Una tabla puede ser mejor cuando el lector necesita valores exactos. Un gráfico es mejor para patrones y comparaciones. Combinarlos puede ofrecer visión y precisión.

Pregunta de lectura

Antes de diseñar, formule qué comparación debe hacer el lector: “comparar cada zona con la referencia”, “encontrar el máximo”, “observar tendencia” o “detectar dispersión”. Luego elija la codificación más directa.

Consistencia

Una serie de figuras debe conservar colores, categorías, unidades y escalas cuando representan lo mismo. La consistencia reduce carga cognitiva y evita asociaciones accidentales.

4.4.3. Storytelling con datos

El relato organiza atención mediante contexto, tensión y resolución. En datos, la tensión puede ser una brecha entre objetivo y observado; la resolución, una acción o una pregunta siguiente. La narrativa no autoriza seleccionar solo evidencia favorable.

Secuencia

Una secuencia útil va de panorama a detalle: situación general, patrón, segmento afectado, explicación posible y decisión. Otra va de expectativa a evidencia: se esperaba estabilidad, se observó cambio, se investigaron fuentes y se identificó una ruptura de medición.

Anotaciones

Las anotaciones señalan eventos, umbrales y valores relevantes. Deben explicar por qué mirar, no repetir el eje. Una línea de referencia puede mostrar objetivo o baseline.

Integridad narrativa

Una historia honesta incluye evidencia que limita su mensaje. Si el patrón desaparece en una zona, se informa. La comunicación no necesita enumerar cada análisis, pero sí aquellos que cambiarían la interpretación.

Evitar dramatización

Colores alarmistas, metáforas y ejes exagerados pueden producir emoción desproporcionada. En decisiones sensibles, claridad y proporcionalidad son más importantes que impacto visual.

4.4.4. Visualizaciones interactivas

La interacción permite filtrar, ampliar, consultar detalles y cambiar vistas. Es útil cuando distintas personas necesitan explorar subconjuntos o cuando la densidad impide mostrar todo a la vez.

Interacción con propósito

Cada control debe responder una necesidad. Agregar filtros por disponibilidad tecnológica produce complejidad. Los valores iniciales deben mostrar una vista válida y no seleccionar accidentalmente el caso más favorable.

Estado y reproducibilidad

Una vista interactiva necesita URL, parámetros o mecanismo para guardar estado. De otro modo, dos usuarios pueden discutir “el gráfico” viendo filtros distintos. Exportaciones deben incluir fecha y selección.

Detalle bajo demanda

Tooltips permiten precisión sin saturar. No deben contener información indispensable que usuarios de teclado o lectores de pantalla no puedan acceder. Una tabla alternativa mejora accesibilidad.

Rendimiento y agregación

Enviar millones de puntos al navegador no mejora evidencia. Se agregan datos o se muestrea con reglas visibles. La interacción debe mantener definiciones y no cambiar silenciosamente denominadores.

Riesgo exploratorio

Muchos filtros permiten encontrar patrones casuales. La herramienta debe distinguir exploración de resultados confirmados y evitar que una captura aislada se presente como conclusión general.

4.4.5. Dashboards y aplicaciones web

Un dashboard monitorea indicadores para una tarea recurrente. Una aplicación puede permitir análisis o acción. Ambos son productos operativos y requieren más que gráficos.

Diseño desde decisiones

Se comienza con usuarios y frecuencia: ¿qué revisan cada mañana?, ¿qué umbral exige acción?, ¿qué detalle necesitan para verificar? Cada componente debe apoyar una decisión o contexto necesario.

Jerarquía

La primera vista muestra estado, cambio y excepciones. Los detalles se ofrecen en niveles posteriores. Llenar la pantalla con KPI sin relación obliga al usuario a construir la historia mentalmente.

Definiciones y actualización

Cada indicador necesita definición, fuente, última actualización, periodo y comparación. Una cifra sin fecha puede parecer actual. Si una fuente falla, el tablero debe mostrar degradación en lugar de reutilizar silenciosamente el último valor.

Alertas

Un umbral visual no es una política completa. Debe existir responsable, canal, prioridad, posibilidad de reconocer y cierre. Demasiadas alertas producen fatiga. Se monitorea su utilidad y tasa de falsos positivos.

Pruebas

Además de exactitud de cálculos, se prueban permisos, filtros, dispositivos, accesibilidad, carga y fallos de fuente. Una aplicación analítica también necesita observabilidad y retirada.

4.4.6. Comunicación para públicos técnicos y no técnicos

Adaptar no significa ocultar. Significa elegir nivel de detalle, vocabulario y evidencia según las decisiones de la audiencia.

Público técnico

Necesita definiciones, método, supuestos, particiones, incertidumbre, sensibilidad y acceso a artefactos. Debe poder reproducir o desafiar el resultado. Una conclusión sin detalles metodológicos no es suficiente.

Público ejecutivo u operativo

Necesita implicación, magnitud, alternativas, costo, riesgo y próximo paso. Las métricas técnicas se traducen sin deformar: en lugar de solo sensibilidad, se informa cuántos eventos se detectarían y cuántas alertas innecesarias produciría el volumen real.

Público afectado

Necesita comprender propósito, datos utilizados, impacto, límites y mecanismo de consulta o apelación. Una explicación centrada en la organización puede omitir lo que importa a la persona.

Capas de comunicación

Un mismo resultado puede ofrecer resumen de una página, informe técnico y anexo reproducible. Las capas deben ser consistentes; el resumen no puede afirmar más de lo respaldado por el anexo.

Metáforas y probabilidades

Las analogías ayudan, pero pueden crear intuiciones incorrectas. Las probabilidades se acompañan con frecuencias naturales y periodo: “12 de cada 100 zonas similares durante una semana”, no “riesgo 12 %” sin referencia.

4.4.7. Accesibilidad y documentación

Una visualización accesible puede ser percibida, comprendida y operada por personas con capacidades y dispositivos diversos.

Color y contraste

El color no debe ser el único canal. Se agregan formas, etiquetas o patrones. El contraste debe permitir leer texto y distinguir elementos. Las paletas se prueban para deficiencias comunes de visión cromática.

Texto alternativo

El texto alternativo describe propósito, tendencia y dato relevante, no cada elemento visual. Por ejemplo: “La demanda aumenta entre 7 y 9, con máximo en zona centro; faltan datos de dos zonas periféricas”.

Estructura y navegación

Títulos, subtítulos y orden lógico ayudan a lectores de pantalla. Las interacciones deben operarse con teclado. Las tablas necesitan encabezados. Las animaciones deben poder detenerse.

Documentación mínima de una figura

Cada figura debe indicar:

- pregunta o mensaje;
- variables, unidades y denominador;
- población, periodo y tamaño;
- fuente y fecha;
- transformación o agregación;
- significado de color y símbolos;
- faltantes, exclusiones y limitaciones.

No todo debe ocupar el área gráfica; una nota o pie puede contener detalle. Lo importante es que viaje con la figura cuando se comparte.

Reproducibilidad

La figura se genera desde código o procedimiento versionado. El archivo exportado tiene nombre estable y metadatos. Editar manualmente una cifra después de generar rompe trazabilidad.

4.4.8. Ejemplo práctico guiado: presentación ejecutiva de un hallazgo

Hallazgo de partida

El análisis del consumo eléctrico encontró que el distrito B tiene una mediana semejante a la referencia, pero un percentil 95 y un IQR elevados durante las olas de calor. La cobertura supera el 90 %, aunque una parte de los hogares carece de medición horaria completa.

Mensaje

“Los episodios de consumo eléctrico alto aumentan durante las olas de calor en el distrito B, aunque el consumo típico permanece estable”. El título distingue la cola del comportamiento central y evita atribuir el patrón a una causa no observada.

Figura

Se utiliza un gráfico de cuantiles por periodo térmico, acompañado por el número de hogares observados y una distribución complementaria. Una línea muestra la referencia histórica y la escala se mantiene común entre distritos.

Contexto

El texto explica la unidad hogar-hora, el periodo, la cobertura y las exclusiones. Señala que los datos agregados no permiten distinguir entre climatización, equipamiento doméstico y cambios de ocupación.

Recomendación

En lugar de concluir una causa, se propone revisar la estabilidad de los medidores y obtener una muestra voluntaria con información de uso durante episodios de temperatura extrema. La recomendación es proporcional a la evidencia y respeta la privacidad de los hogares.

Versión técnica

El anexo incluye definiciones, cuantiles, sensibilidad a filtros, código y casos extremos. La presentación ejecutiva y el anexo comunican el mismo hallazgo a distintas profundidades.

Síntesis del capítulo

La estadística descriptiva convierte observaciones en una representación comprensible de posición, dispersión, forma y asociación. Cada medida responde a un estimando y posee sensibilidad específica. Media y desviación son informativas bajo ciertas formas; mediana, cuantiles e IQR ofrecen robustez; ninguna reemplaza la distribución.

Las relaciones entre variables requieren examinar condicionamiento, forma, grupos y mecanismo de generación. Covarianza y correlación resumen asociación, no causalidad. Confusión, selección, temporalidad y agregación pueden producir patrones convincentes y falsos para una decisión causal.

La visualización es una codificación con supuestos perceptivos. Elegir gráfico significa elegir qué comparación facilitar. La comunicación agrega audiencia, narrativa, accesibilidad y responsabilidad. Un hallazgo bien comunicado conserva población, denominador, incertidumbre, fuente y límites.

Glosario esencial

- **Asimetría:** falta de simetría de una distribución y orientación de sus colas.
- **Correlación:** medida estandarizada de asociación, lineal o por rangos según el coeficiente.
- **Covarianza:** medida de variación lineal conjunta dependiente de las unidades.
- **Cuantil:** valor de posición asociado con una proporción acumulada.
- **Curtosis:** medida basada en el cuarto momento, relacionada con colas y extremos.
- **Estimando:** cantidad de población definida como objetivo de estimación.
- **IQR:** diferencia entre tercer y primer cuartil.
- **Muestra:** subconjunto observado de una población.
- **Parámetro:** característica de una población.
- **Variable de confusión:** variable que distorsiona una asociación de interés.
- **Visualización exploratoria:** representación diseñada para investigar patrones y calidad.

Preguntas de autoevaluación

1. ¿Por qué un estadístico necesita declarar población y unidad?
2. ¿Qué diferencia existe entre conteo, proporción y tasa?
3. ¿Cuándo la media es preferible a la mediana?
4. ¿Qué información aporta un percentil que no aporta el máximo?
5. ¿Por qué la varianza muestral suele dividirse por $n - 1$?
6. ¿Qué significa que un valor quede fuera de $1.5IQR$?
7. ¿Por qué asimetría y curtosis no reemplazan un gráfico?
8. ¿Qué condicionamiento representa una proporción por fila?
9. ¿Cómo puede existir relación fuerte con correlación cero?
10. ¿Qué diferencia hay entre Pearson, Spearman y Kendall?
11. ¿Por qué precedencia temporal no demuestra causalidad?
12. ¿Cómo puede una variable de confusión invertir una asociación?
13. ¿Qué codificaciones visuales permiten comparaciones más precisas?

14. ¿Cómo afectan bins y ancho de banda a una distribución?
15. ¿Por qué un mapa de conteos puede confundir tamaño con riesgo?
16. ¿Cuándo es engañoso truncar un eje?
17. ¿Qué diferencia existe entre gráfico exploratorio y comunicación final?
18. ¿Qué información mínima debe acompañar una figura?

Actividad integradora de cierre

Seleccione un conjunto de datos de agua o movilidad y produzca un informe exploratorio con:

1. población, muestra, unidad, periodo y cobertura;
2. distribución de tres variables con medidas clásicas y robustas;
3. tabla de contingencia y proporciones condicionadas;
4. dos relaciones numéricas con gráfico y coeficiente justificado;
5. análisis de un posible confusor;
6. visualización temporal o geográfica con denominador explícito;
7. revisión de escalas, color, faltantes y accesibilidad;
8. tres hallazgos redactados con magnitud y límites;
9. una presentación ejecutiva de un hallazgo;
10. anexo reproducible con definiciones y decisiones gráficas.

La evaluación prioriza correspondencia entre pregunta, medida, gráfico e interpretación. Una figura visualmente atractiva que oculta población, escala o incertidumbre no se considera una buena comunicación estadística.

Capítulo 5. Probabilidad, incertidumbre e inferencia bayesiana

Propósito y objetivos de aprendizaje

Los datos no eliminan la incertidumbre. Una medición puede contener ruido, un evento futuro puede depender de factores no observados y una muestra puede diferir de la población. La probabilidad proporciona un lenguaje para representar esa incertidumbre, combinar evidencia y tomar decisiones sin fingir certeza.

Este capítulo comienza con experimentos y eventos porque toda probabilidad necesita especificar qué resultados son posibles. Luego introduce variables aleatorias y distribuciones, que permiten modelar cantidades como número de fallas o tiempo de espera. La inferencia bayesiana añade una regla coherente para actualizar creencias a medida que aparece evidencia. Finalmente se estudia cómo distinguir fuentes de incertidumbre y comunicarlas de manera útil para una decisión.

La probabilidad no debe tratarse como una colección de fórmulas. Cada cálculo expresa un modelo: qué se considera repetible, qué información condiciona, qué independencia se supone y qué población se representa. La experiencia técnica consiste tanto en realizar el cálculo como en reconocer cuándo sus supuestos no corresponden al problema.

Al finalizar, el lector podrá:

- definir experimentos, espacios muestrales y eventos;
- aplicar reglas de suma, producto y condicionamiento;
- distinguir independencia de exclusión mutua;
- interpretar funciones de masa, densidad y distribución;
- calcular esperanza, varianza y covarianza;
- seleccionar distribuciones frecuentes a partir de su mecanismo generador;
- diferenciar previa, verosimilitud, evidencia y posterior;
- actualizar probabilidades y vincularlas con costos de decisión;
- separar incertidumbre aleatoria y epistémica;
- evaluar calibración y comunicar riesgo sin crear falsa precisión.

5.1. Fundamentos de probabilidad

La probabilidad formaliza afirmaciones sobre resultados inciertos. Puede interpretarse como frecuencia de largo plazo, grado racional de creencia o medida matemática sobre conjuntos. En la práctica de Ciencia de Datos, estas interpretaciones conviven: se estiman frecuencias observadas, se construyen modelos y se expresan creencias condicionadas por información.

Antes de asignar un número se deben identificar resultado, población, horizonte y condiciones. “La probabilidad de una fuga es 10 %” está incompleta: ¿para qué zona, durante qué periodo, bajo qué definición de fuga y con qué información disponible?

5.1.1. Experimento aleatorio y espacio muestral

Un **experimento aleatorio** es un procedimiento cuyo resultado no se conoce con certeza antes de observarlo, aunque se conozcan resultados posibles. Lanzar un dado es el ejemplo clásico, pero en aplicaciones el experimento puede ser observar si una tubería falla durante una semana, registrar cantidad de reclamos en una hora o medir tiempo hasta que llegue un vehículo.

El **espacio muestral** Ω contiene todos los resultados elementales considerados por el modelo. Para una inspección binaria:

$$\Omega = \{fuga, no\ fuga\}.$$

Para dos sensores binarios, el espacio puede contener cuatro combinaciones. Para un tiempo de espera no negativo, $\Omega = [0, \infty)$.

El espacio es una decisión de modelado

El mundo real admite más estados que cualquier modelo. Una inspección puede ser inconclusa, detectar una falla distinta o no realizarse. Si se utiliza un espacio binario, se debe decidir dónde se ubican esos casos. Omitirlos no los elimina; los convierte en ambigüedad.

Un espacio debe ser **exhaustivo** respecto del alcance: incluir todos los resultados posibles. Sus resultados elementales deben ser mutuamente excluyentes: solo uno ocurre por realización. Estas condiciones dependen de la granularidad. “Lluvia” y “tráfico” no son resultados excluyentes; pueden coexistir.

Experimento, observación y repetición

La idea de repetición no siempre implica reproducir condiciones idénticas. Los viajes ocurren en rutas y horarios diferentes; las tuberías tienen edades distintas. La probabilidad suele condicionarse por esas características para construir unidades comparables.

En un modelo frecuentista, una probabilidad puede entenderse como frecuencia límite bajo repeticiones idealizadas. En una interpretación bayesiana, también puede representar incertidumbre sobre un evento único, dada la información disponible.

Resultados simples y trayectorias

En procesos temporales, un resultado puede ser una trayectoria completa $(X_1, \dots, X_T)$, no una sola medición. Definir el espacio como trayectorias permite formular secuencias, pero aumenta complejidad. El nivel debe responder a la pregunta.

Práctica profesional

Antes de calcular, redacte el experimento: unidad, instante de inicio, horizonte, resultado observable y casos inconclusos. Muchos desacuerdos probabilísticos son en realidad desacuerdos sobre esta definición.

5.1.2. Eventos y operaciones entre eventos

Un **evento** es un subconjunto de Ω . Ocurre si el resultado elemental pertenece a ese conjunto. En un dado, “obtener par” corresponde a $A = \{2, 4, 6\}$. En transporte, “incidente durante hora pico” reúne múltiples resultados con esa propiedad.

Las operaciones de conjuntos traducen expresiones del dominio.

- **Unión** $A \cup B$: ocurre A , ocurre B o ambos.
- **Intersección** $A \cap B$: ocurren ambos.
- **Complemento** A^c : no ocurre A .
- **Diferencia** $A \setminus B$: ocurre A y no B .

“O” inclusivo y exclusivo

En probabilidad, la unión suele ser inclusiva. “Lluvia o congestión” incluye días con ambas. Si se desea exactamente una, el evento es $(A \setminus B) \cup (B \setminus A)$.

Particiones

Una colección $B_1, \dots, B_k$ forma una partición si los eventos son mutuamente excluyentes y su unión es Ω . Las particiones permiten descomponer probabilidades por zona, turno o estado.

Por ejemplo, turnos mañana, tarde y noche pueden formar una partición si cada incidente pertenece exactamente a uno. Los límites horarios deben ser inequívocos.

Diagramas y tablas

Los diagramas de Venn ayudan con pocos eventos. Para muchas variables, tablas de contingencia y árboles resultan más claros. La representación debe impedir doble conteo.

Eventos compuestos en datos

Un evento se implementa mediante una regla. “Demora crítica” puede ser tiempo mayor a 20 minutos; “condición anómala”, combinación de presión y caudal. Cambiar umbral cambia el evento y su probabilidad. La definición debe versionarse.

5.1.3. Axiomas de probabilidad

Una función de probabilidad P asigna números a eventos y satisface los axiomas de Kolmogórov.

1. **No negatividad:** $P(A) \geq 0$.
2. **Normalización:** $P(\Omega) = 1$.
3. **Aditividad numerable:** para eventos disjuntos A_i ,

$$P\left(\bigcup_i A_i\right) = \sum_i P(A_i).$$

Los axiomas son pocos, pero de ellos se derivan reglas fundamentales.

Consecuencias

La probabilidad del evento imposible es $P(\emptyset) = 0$. El complemento cumple:

$$P(A^c) = 1 - P(A).$$

Si $A \subseteq B$, entonces $P(A) \leq P(B)$. Toda probabilidad está entre cero y uno.

Probabilidad cero no siempre significa imposibilidad

En una distribución continua, la probabilidad de un valor exacto puede ser cero aunque ese valor sea posible. La probabilidad se asigna a intervalos. Este punto evita interpretar densidad como probabilidad puntual.

Coherencia

Los axiomas impiden asignaciones contradictorias. Si una persona afirma $P(A) = 0.7$ y $P(A^c) = 0.5$, sus valores no forman una probabilidad coherente. En sistemas que combinan expertos o modelos se debe normalizar y revisar consistencia.

Probabilidad y datos

Una frecuencia relativa n_A/n estima una probabilidad bajo un mecanismo de muestreo. El axioma no garantiza que esa frecuencia represente otra población o periodo. La validez empírica depende del diseño estudiado en capítulos anteriores.

5.1.4. Reglas de suma y producto

La regla general de suma evita doble conteo:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Si A y B son mutuamente excluyentes, la intersección es vacía y las probabilidades se suman directamente.

Para múltiples eventos, el principio de inclusión-exclusión añade y resta intersecciones de distintos órdenes. En aplicaciones, una tabla bien definida suele ser menos propensa a errores que memorizar una fórmula extensa.

Regla del producto

La probabilidad conjunta se descompone mediante condicionamiento:

$$P(A \cap B) = P(A | B)P(B) = P(B | A)P(A).$$

Para una secuencia:

$$P(A_1, \dots, A_n) = P(A_1) \prod_{i=2}^n P(A_i | A_1, \dots, A_{i-1}).$$

Esta regla de cadena es siempre válida cuando los condicionamientos están definidos. Las simplificaciones aparecen al asumir independencia.

Árboles de probabilidad

Un árbol representa decisiones o secuencias. Cada rama lleva una probabilidad condicional; la probabilidad de un camino se obtiene multiplicando; caminos alternativos se suman. Es especialmente útil para pruebas diagnósticas y actualizaciones bayesianas.

Error frecuente: sumar intersecciones

Si se pregunta por “incidente o lluvia”, sumar probabilidades sin restar días con ambos sobrecuenta. Si se pregunta por “incidente y lluvia”, sumar no corresponde. Traducir primero la frase a conjuntos evita el error.

5.1.5. Probabilidad condicional

La probabilidad de A dada la información de que ocurrió B es:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0.$$

Condicionar restringe el universo a B y renormaliza. El denominador ya no es toda la población, sino las unidades que cumplen B .

El denominador como pregunta

“¿Qué proporción de incidentes ocurrió de noche?” estima $P(\text{Noche} | \text{Incidente})$.
 “¿Qué proporción de noches tuvo incidentes?” estima $P(\text{Incidente} | \text{Noche})$.
 Pueden diferir enormemente.

Una buena práctica es escribir numerador y denominador en palabras antes de calcular. Las tablas de contingencia deben presentar totales para que el lector pueda reconstruirlos.

Información y actualización

La probabilidad condicional representa cómo cambia una creencia al conocer B . Si $P(A | B) > P(A)$, B aumenta la probabilidad de A ; eso no demuestra que B cause A .

Ley de probabilidad total

Si $B_1, \dots, B_k$ forman una partición:

$$P(A) = \sum_{j=1}^k P(A | B_j)P(B_j).$$

La ley combina probabilidades condicionadas ponderadas por prevalencia de cada grupo. Es la base del denominador en Bayes y muestra por qué cambiar composición poblacional cambia la probabilidad global.

Condicionar en variables continuas

Para variables continuas se trabaja con densidades condicionales. El evento $X = x$ puede tener probabilidad cero, pero existe una densidad regular bajo condiciones matemáticas. La notación se conserva, aunque la interpretación requiere cuidado.

5.1.6. Independencia

Dos eventos son independientes si:

$$P(A \cap B) = P(A)P(B).$$

Cuando las probabilidades son positivas, equivale a $P(A | B) = P(A)$. Saber que ocurrió B no cambia la probabilidad de A dentro del modelo.

Independencia no es exclusión mutua

Eventos mutuamente excluyentes con probabilidad positiva no pueden ser independientes: si ocurre uno, el otro es imposible. Esta confusión es frecuente porque ambos conceptos suenan a “no relación”. Exclusión habla de coexistencia; independencia, de información.

Independencia por pares y conjunta

Varias variables pueden ser independientes por pares sin ser conjuntamente independientes. Para factorizar una distribución completa se necesita una condición más fuerte. Los modelos deben declarar qué tipo se supone.

Independencia condicional

A y B pueden ser dependientes globalmente e independientes dado C :

$$P(A, B | C) = P(A | C)P(B | C).$$

Por ejemplo, demanda y retraso pueden asociarse globalmente por hora; dentro de una franja y ruta, la relación puede reducirse. La independencia condicional es central en redes bayesianas.

No se demuestra con una muestra

Una asociación no significativa no prueba independencia. Puede faltar potencia o existir relación no medida. La independencia es un supuesto estructural que se contrasta con datos y conocimiento.

Consecuencias de asumirla

La independencia simplifica cálculos. Si se asume incorrectamente, se multiplican evidencias redundantes y se obtiene confianza excesiva. Dos sensores del mismo tipo pueden fallar juntos por una causa común.

5.1.7. Ejemplo práctico guiado: probabilidad de incidentes en una red de transporte**Datos**

Durante 1.000 turnos se registraron 120 con incidente. Hubo 300 turnos nocturnos; 60 tuvieron incidente. En 200 turnos llovió; 50 tuvieron incidente. De los turnos con lluvia, 80 fueron nocturnos y 30 combinaron noche e incidente.

Probabilidad simple

La frecuencia de incidentes estima:

$$\hat{P}(I) = 120/1000 = 0.12.$$

Esta estimación describe turnos registrados, bajo la definición y cobertura disponibles.

Probabilidad condicional

Entre turnos nocturnos:

$$\hat{P}(I | N) = 60/300 = 0.20.$$

Entre turnos con incidente, la proporción nocturna es $P(N | I) = 60/120 = 0.50$. Los números responden preguntas distintas.

Intersección y producto

$P(I \cap N) = 60/1000 = 0.06$. Se comprueba:

$$P(I | N)P(N) = 0.20 \times 0.30 = 0.06.$$

Independencia

Si incidente y noche fueran independientes, $P(I \cap N)$ sería $0.12 \times 0.30 = 0.036$, diferente de 0.06 observado. Esto sugiere asociación en la muestra; no identifica causa.

Interpretación

La mayor frecuencia nocturna puede relacionarse con iluminación, dotación, rutas o clima. El análisis probabilístico cuantifica el patrón y orienta estratificación. No autoriza afirmar que la noche produce incidentes.

Sensibilidad

Se revisa si la definición cambió y si los turnos nocturnos tienen igual cobertura. Si los incidentes leves se registran menos durante el día, la diferencia refleja medición además de fenómeno.

5.2. Variables aleatorias y distribuciones

Una variable aleatoria convierte resultados de un experimento en números. Esta representación permite pasar de eventos aislados a modelos de cantidades: número de fallas, tiempo de espera, consumo o pérdida económica.

Una distribución no es una curva elegida por apariencia. Resume probabilidades bajo un mecanismo y parámetros. Seleccionarla requiere preguntar qué valores son posibles, cómo se generan y qué dependencias existen.

5.2.1. Variables aleatorias discretas y continuas

Una variable aleatoria es una función $X : \Omega \rightarrow \mathbb{R}$. A cada resultado elemental le asigna un número.

Una variable **discreta** toma un conjunto finito o numerable de valores: indicador de fuga, número de incidentes, cantidad de reclamos. Una variable **continua** se modela sobre intervalos: tiempo, presión o temperatura.

Discreto y continuo son modelos

Una medición digital de presión tiene resolución finita, pero suele modelarse continua porque los saltos son pequeños respecto de la pregunta. Un tiempo registrado en minutos puede modelarse discreto o continuo. La elección depende de resolución y uso.

Indicadores

Para un evento A , la variable indicadora I_A vale 1 si ocurre y 0 si no. Su esperanza es:

$$E[I_A] = P(A).$$

Esta identidad conecta proporciones, conteos y probabilidades y es útil para derivar resultados.

Soporte

El soporte es el conjunto de valores posibles con probabilidad o densidad positiva. Debe respetar el fenómeno. Una normal asigna probabilidad a negativos; puede ser inadecuada para tiempos cuando la masa negativa no es despreciable.

Transformaciones

Si $Y = g(X)$, su distribución se deriva de la de X . Transformar logaritmos, tasas o máximos cambia soporte y forma. No basta con transformar valores; la interpretación probabilística también cambia.

5.2.2. Función de probabilidad y función de densidad

Para una variable discreta, la función de masa es:

$$p_X(x) = P(X = x),$$

con $p_X(x) \geq 0$ y $\sum_x p_X(x) = 1$.

Para una variable continua, la densidad $f_X(x)$ satisface:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx,$$

y $\int_{-\infty}^{\infty} f_X(x) dx = 1$.

Densidad no es probabilidad

$f_X(x)$ puede ser mayor que uno; lo que debe estar entre cero y uno es el área sobre un intervalo. En una variable continua, $P(X = x) = 0$. La altura depende de unidades: cambiar segundos a minutos modifica densidad, no probabilidades de intervalos equivalentes.

Parámetros

Una familia $f(x | \theta)$ describe distribuciones posibles. θ puede ser tasa, media, varianza o forma. Estimar parámetros no demuestra que la familia sea correcta; se deben revisar mecanismo y ajuste.

Empírico frente a teórico

La distribución empírica asigna probabilidad según frecuencias observadas. Una distribución teórica suaviza y permite extrapolar bajo supuestos. El modelo debe compararse con datos mediante gráficos, cuantiles y residuos, no solo una prueba automática.

5.2.3. Función de distribución acumulada

La función acumulada es:

$$F_X(x) = P(X \leq x).$$

Existe para variables discretas y continuas, es no decreciente, tiende a cero en $-\infty$ y a uno en ∞ .

Interpretación

$F(10) = 0.8$ significa que 80 % de la probabilidad está en valores menores o iguales a 10. La probabilidad de intervalo es:

$$P(a < X \leq b) = F(b) - F(a).$$

Los detalles de inclusión importan en discretas; en continuas, los puntos tienen probabilidad cero.

Supervivencia

La función de supervivencia $S(x) = P(X > x) = 1 - F(x)$ resulta natural para tiempos hasta evento y probabilidades de excedencia. En riesgo operativo suele interesar más “superar un umbral” que “quedar por debajo”.

Cuantiles

El cuantil puede definirse como:

$$q_p = \inf\{x : F(x) \geq p\}.$$

Esta definición funciona con saltos y conecta el Capítulo 4 con modelos probabilísticos.

Función empírica

$\hat{F}_n(x) = n^{-1} \sum_i \mathbb{I}(X_i \leq x)$ estima la acumulada. Compararla con una CDF teórica revela discrepancias en centro y colas.

5.2.4. Esperanza, varianza y covarianza

La esperanza de una variable discreta es:

$$E[X] = \sum_x x p(x),$$

y para una continua:

$$E[X] = \int x f(x) dx,$$

si existe. Representa promedio de largo plazo o centro probabilístico, no necesariamente un valor posible ni típico.

Linealidad

Para constantes a, b :

$$E[aX + bY] = aE[X] + bE[Y],$$

sin requerir independencia. Esta propiedad permite calcular costos esperados sumando componentes.

Varianza

$$Var(X) = E[(X - E[X])^2] = E[X^2] - E[X]^2.$$

Para transformación lineal, $Var(aX + b) = a^2 Var(X)$. La varianza mide dispersión cuadrática y puede no existir en distribuciones de colas muy pesadas.

Covarianza

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Si son independientes y tienen momentos, la covarianza es cero; la inversa no es general. La varianza de una suma es:

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y).$$

Ignorar dependencia puede subestimar o sobreestimar riesgo agregado.

Esperanza de utilidad

Una decisión utiliza $E[U(A, S)]$, no necesariamente $U(E[S])$. Para funciones no lineales, $E[g(X)] \neq g(E[X])$. Sustituir incertidumbre por un promedio puede conducir a decisiones equivocadas.

5.2.5. Distribuciones discretas frecuentes**Bernoulli**

$X \sim \text{Bernoulli}(p)$ toma 1 con probabilidad p y 0 con $1 - p$. $E[X] = p$ y $Var(X) = p(1 - p)$. Modela un resultado binario bajo definición clara.

Binomial

$X \sim \text{Binomial}(n, p)$ cuenta éxitos en n ensayos Bernoulli independientes con igual p :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

Tiene media np y varianza $np(1 - p)$. Si la probabilidad cambia entre unidades o existe dependencia, puede aparecer sobredispersión respecto del modelo.

Geométrica y binomial negativa

La geométrica modela ensayos hasta el primer éxito y posee propiedad sin memoria. La binomial negativa puede modelar ensayos hasta cierta cantidad de éxitos o conteos sobredispersos según parametrización. Siempre debe indicarse convención.

Poisson

$X \sim \text{Poisson}(\lambda)$ modela conteos en un intervalo:

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!},$$

con media y varianza λ . Surge bajo eventos aproximadamente independientes, tasa estable y probabilidad pequeña en intervalos breves.

En datos reales, varianza mayor que media sugiere heterogeneidad, dependencia o exceso de ceros. No obliga automáticamente a usar otro modelo, pero exige investigar mecanismo.

Multinomial

Extiende binomial a varias categorías mutuamente excluyentes con probabilidades que suman uno. Modela conteos por clase bajo ensayos independientes y probabilidades comunes.

Elegir por mecanismo

No se elige Poisson porque el histograma “parece conteo”. Se pregunta si la exposición es comparable, la tasa estable y los eventos aproximadamente independientes. Para zonas con distinta duración o población se incorpora exposición.

5.2.6. Distribuciones continuas frecuentes**Uniforme**

Asigna densidad constante en $[a, b]$. Representa desconocimiento simétrico acotado o mecanismos uniformes, no una opción por defecto para cualquier rango.

Normal

$X \sim N(\mu, \sigma^2)$ tiene densidad:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right].$$

Es simétrica, no acotada y aparece como aproximación de sumas por el teorema central del límite. Que un promedio sea aproximadamente normal no implica que las observaciones lo sean.

Exponencial

Modela tiempos entre eventos de Poisson con tasa λ :

$$f(t) = \lambda e^{-\lambda t}, \quad t \geq 0.$$

Posee falta de memoria: la probabilidad futura no depende del tiempo ya transcurrido. Esta propiedad es fuerte e inadecuada para componentes que envejecen.

Gamma y Weibull

Gamma modela tiempos positivos y sumas de exponenciales. Weibull permite tasas de falla crecientes, constantes o decrecientes según parámetro de forma, por lo que es útil en confiabilidad.

Beta

Se define en $[0, 1]$ y adopta formas diversas. Es útil para proporciones y como previa de una probabilidad Bernoulli. Sus parámetros pueden interpretarse como evidencia previa en una parametrización común.

Lognormal

Si $\log X$ es normal, X es lognormal. Modela magnitudes positivas generadas por efectos multiplicativos y produce cola derecha. Media y mediana difieren.

Modelos y colas

En riesgo, el ajuste central puede ser bueno y las colas incorrectas. Comparar cuantiles extremos y consecuencias es más importante que una apariencia global. La distribución elegida debe respetar soporte y mecanismo.

5.2.7. Distribuciones conjuntas, marginales y condicionales

Una distribución conjunta describe probabilidades de varias variables. Para discretas, $p(x, y) = P(X = x, Y = y)$; para continuas, una densidad $f(x, y)$ integra sobre regiones.

Marginalización

La distribución marginal elimina una variable:

$$p_X(x) = \sum_y p(x, y)$$

o, en continuo,

$$f_X(x) = \int f(x, y) dy.$$

La marginal combina todos los estados de Y ponderados por su probabilidad.

La forma apropiada depende del soporte y del mecanismo generador




Figura 10: Ejemplos de distribuciones probabilísticas

Condicionamiento

Para discretas:

$$p(x | y) = \frac{p(x, y)}{p_Y(y)}.$$

La distribución condicional restringe a unidades con $Y = y$. Las marginales pueden ocultar relaciones heterogéneas entre grupos.

Independencia

Si X e Y son independientes:

$$p(x, y) = p_X(x)p_Y(y).$$

En una densidad conjunta, contornos elípticos inclinados sugieren dependencia lineal; formas complejas pueden tener covarianza cero.

Más de dos variables

La regla de cadena factoriza:

$$p(x_1, \dots, x_n) = \prod_i p(x_i | x_1, \dots, x_{i-1}).$$

Las independencias condicionales permiten simplificar y se representan mediante grafos probabilísticos.

Mezclas

Una marginal puede ser mezcla de distribuciones condicionadas:

$$p(x) = \sum_z p(x | z)p(z).$$

La multimodalidad puede surgir de subpoblaciones. Ajustar una distribución única sin reconocerlas produce parámetros difíciles de interpretar.

5.2.8. Ejemplo práctico guiado: modelado probabilístico de fallas y tiempos de espera

Unidad de análisis y exposición

Un centro de cómputo registra interrupciones no planificadas en 60 servidores durante 12 semanas. Los equipos pertenecen a tres clústeres: procesamiento general, bases de datos y cómputo intensivo. Para cada servidor-semana se registra el número de fallas y, mientras el equipo está bajo observación, el tiempo desde su recuperación hasta la siguiente falla. El conteo bruto no es comparable si un servidor estuvo activo menos horas; por ello se usa como exposición el tiempo efectivamente operativo.

Sea N_{cs} el número de fallas del clúster c durante la semana s y E_{cs} sus miles de horas-servidor operativas. Un punto de partida es:

$$N_{cs} | E_{cs} \sim \text{Poisson}(\lambda_c E_{cs}),$$

donde λ_c es la tasa de fallas por mil horas-servidor. Este modelo supone una tasa constante dentro de cada clúster y semana, incrementos independientes y eventos individuales. No basta observar que la variable es un conteo: reinicios masivos, versiones de software compartidas o picos térmicos pueden producir fallas simultáneas y violar esos supuestos.

Diagnóstico del modelo de conteos

En el clúster de procesamiento general, para semanas de exposición semejante, la media es 2,3 fallas y la varianza 2,5; Poisson resulta una aproximación inicial razonable. En bases de datos, la media es 1,8 y la varianza 6,1. Esta sobredispersión indica más variabilidad de la permitida por la igualdad $E(N) = \text{Var}(N)$ de Poisson. Además, se observan demasiadas semanas sin fallas y varias con cinco o más.

Antes de cambiar de familia se investiga el mecanismo. Al incorporar versión de sistema, antigüedad y temperatura de sala, parte de la heterogeneidad desaparece. La variación restante puede representarse con un modelo binomial negativo, equivalente a permitir que la tasa latente cambie entre semanas. Si persisten eventos agrupados por incidentes comunes, se añade un efecto aleatorio de semana o se modela cada incidente de infraestructura, pues tratar todas las fallas como independientes produciría intervalos demasiado estrechos.

El contraste incluye residuos por clúster, cociente varianza-media, frecuencia de ceros y probabilidades predictivas de semanas extremas. La elección final depende del uso: para dimensionar guardias importa reproducir $P(N_{cs} \geq 5)$, no solo la media.

Tiempos de espera por clúster

Si las fallas siguieran un proceso de Poisson homogéneo, el tiempo T_c hasta la siguiente falla tendría modelo exponencial:

$$P(T_c > t) = \exp(-\lambda_c t),$$

con tasa instantánea constante y propiedad de falta de memoria. Las curvas de supervivencia por clúster muestran, sin embargo, comportamientos distintos. En cómputo intensivo el riesgo aumenta con las horas continuas de carga, mientras que en bases de datos es elevado inmediatamente después de una actualización y luego disminuye. Una única exponencial mezclaría mecanismos y ocultaría estas diferencias. Se comparan entonces tasas por clúster y modelos Weibull o por tramos temporales; una forma Weibull menor que uno representa riesgo decreciente y una mayor que uno, riesgo creciente.

Censura y observación incompleta

Al cerrar el estudio, 41 servidores aún no habían presentado una nueva falla. Sus tiempos no son ceros ni deben eliminarse: están censurados a la derecha y solo se sabe que exceden el tiempo observado. También hay servidores incorporados después del inicio, con entrada tardía. La función de verosimilitud aporta una densidad para cada falla observada y una probabilidad de supervivencia para cada caso censurado, respetando el tiempo durante el cual cada equipo estuvo en riesgo.

Este tratamiento supone censura no informativa condicionada a las variables incluidas. Si los equipos más inestables se retiran antes o dejan de reportar telemetría, la censura depende del riesgo y debe modelarse o analizarse mediante escenarios de sensibilidad.

Resultado para la decisión

El reporte presenta tasas por mil horas-servidor, intervalos, probabilidades de conteos extremos y tiempos medianos hasta una nueva falla por clúster. Poisson y exponencial se conservan como referencias simples, no como propiedades automáticas de los datos. La recomendación operativa se basa en el modelo que reproduce heterogeneidad, agrupamiento y censura, y declara que sus predicciones solo son válidas para cargas, versiones y políticas de monitoreo comparables con las del estudio.

5.3. Teorema de Bayes e inferencia probabilística

El teorema de Bayes reorganiza probabilidades condicionadas. Su importancia práctica es que separa lo que se creía antes, cómo se comportaría la evidencia bajo cada hipótesis y qué debe creerse después de observarla.

Para hipótesis H y evidencia E :

$$P(H | E) = \frac{P(E | H)P(H)}{P(E)}.$$

La fórmula es sencilla; construir sus componentes es el verdadero trabajo. La previa debe representar una población pertinente, la verosimilitud debe modelar el mecanismo de observación y la evidencia debe integrar alternativas. Si alguno está mal definido, la posterior será coherente con un modelo equivocado.




Figura 11: Actualización bayesiana

5.3.1. Probabilidad previa

La **probabilidad previa** $P(H)$ representa incertidumbre sobre la hipótesis antes de incorporar la evidencia actual. No significa necesariamente ignorar datos: puede resumir prevalencia histórica, estudios anteriores, conocimiento experto o restricciones físicas.

La población de referencia

Una previa de fuga de 2 % puede ser adecuada para todas las zonas en un día normal e inadecuada para tuberías antiguas después de una tormenta. La previa debe corresponder a unidad, horizonte y condiciones del caso.

Usar una tasa global para grupos heterogéneos puede ocultar riesgo. Una previa jerárquica permite compartir información entre grupos sin tratarlos como idénticos.

Previas informativas y débiles

Una previa informativa concentra probabilidad según conocimiento sustantivo. Una previa débil distribuye más ampliamente. “No informativa” es un término problemático: una distribución uniforme en un parámetro deja de ser uniforme bajo transformación. Toda previa incorpora estructura.

Previas conjugadas

Para probabilidad Bernoulli p , una previa Beta:

$$p \sim \text{Beta}(\alpha, \beta)$$

se actualiza de forma simple. α y β pueden interpretarse como evidencia previa equivalente bajo una parametrización. La conjugación facilita cálculo, pero no debe imponerse si produce una forma inadecuada.

Elicitación experta

En lugar de pedir “una probabilidad”, se pueden preguntar cuantiles: valor más plausible, rango que contiene 90 % de creencia y escenarios extremos. Varios expertos deben aportar razonamiento y desacuerdos. Promediar números sin entender supuestos puede ocultar diferencias de definición.

Análisis de sensibilidad

Cuando la previa es discutible, se calculan posteriores bajo alternativas plausibles. Si la decisión cambia, se necesita más evidencia o una política robusta. Si no cambia, la conclusión es menos dependiente de la previa.

5.3.2. Verosimilitud

La **verosimilitud** describe cuán compatibles son los datos observados con distintos valores del parámetro o hipótesis:

$$L(\theta; y) = p(y | \theta).$$

Como función de y para θ fijo es una probabilidad o densidad. Como función de θ para datos fijos es verosimilitud y no necesita integrar uno sobre θ .

No es la probabilidad del parámetro

$L(\theta; y)$ no es $P(\theta | y)$. Para obtener una distribución posterior se combina con previa y se normaliza. Confundirlas lleva a interpretar un ajuste relativo como probabilidad.

Modelo de observación

La verosimilitud debe incluir ruido, censura, selección y dependencia. Si solo se inspeccionan zonas con alertas, las confirmaciones observadas no son una muestra aleatoria. El modelo necesita representar política de inspección o limitar el estimando.

Independencia condicional

Para datos condicionalmente independientes:

$$L(\theta; y_1, \dots, y_n) = \prod_i p(y_i | \theta).$$

Si mediciones comparten sensor o evento, multiplicarlas como independientes exagera evidencia. Puede utilizarse un modelo jerárquico o una estructura de correlación.

Log-verosimilitud

Los productos de probabilidades pequeñas causan problemas numéricos. Se utiliza:

$$\ell(\theta) = \sum_i \log p(y_i | \theta).$$

Maximizar log-verosimilitud equivale a maximizar verosimilitud. En Bayes, se suma log-previa y luego se normaliza o muestrea.

Verosimilitud de una prueba

Sensibilidad $P(+ | H)$ y tasa de falso positivo $P(+ | H^c)$ describen cómo se comporta una señal bajo estados. Su razón:

$$LR^+ = \frac{P(+ | H)}{P(+ | H^c)}$$

indica cuánto favorece un resultado positivo a H . No depende directamente de prevalencia; la posterior sí.

5.3.3. Probabilidad posterior

La posterior combina previa y verosimilitud:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

Representa incertidumbre sobre θ después de observar y , condicionada al modelo completo.

Ejemplo Beta-Binomial

Si $p \sim \text{Beta}(\alpha, \beta)$ y se observan s éxitos y f fracasos Bernoulli, entonces:

$$p | y \sim \text{Beta}(\alpha + s, \beta + f).$$

La actualización suma evidencia. Con pocos datos, la previa influye; con muchos, la verosimilitud suele dominar si el modelo es identificable.

Resúmenes posteriores

Se puede informar media, mediana, moda, intervalo creíble o probabilidad de superar un umbral. El resumen se elige según decisión. La media posterior minimiza pérdida cuadrática; la mediana, pérdida absoluta; otras pérdidas producen otras decisiones.

Distribución predictiva posterior

Para una nueva observación $\tilde{y}$:

$$p(\tilde{y} | y) = \int p(\tilde{y} | \theta) p(\theta | y) d\theta.$$

Integra incertidumbre del parámetro y variabilidad de observación. Es más pertinente para pronóstico que sustituir θ por una estimación puntual.

Posterior no equivale a verdad

Es condicional a familia, previa, datos y supuestos. Un modelo puede producir posterior estrecha y estar mal especificado. Se requieren comprobaciones predictivas y sensibilidad.

5.3.4. Evidencia y normalización

El denominador de Bayes es la **evidencia** o verosimilitud marginal:

$$p(y) = \int p(y | \theta) p(\theta) d\theta$$

o una suma en hipótesis discretas. Garantiza que la posterior integre uno.

Interpretación

La evidencia es la probabilidad de observar los datos bajo el modelo completo, promediada sobre la previa. En clasificación binaria:

$$P(E) = P(E | H)P(H) + P(E | H^c)P(H^c).$$

Comparación de modelos

La razón de evidencias entre modelos es un factor de Bayes. Integra ajuste y complejidad según previas. Es sensible a previas y puede ser difícil de calcular; no debe presentarse como criterio automático.

Normalización numérica

Con muchas hipótesis se trabaja en logaritmos y se usa la técnica log-sum-exp para evitar subdesbordamiento. En modelos complejos, la constante puede ser intratable y se utilizan aproximaciones o muestreo.

Clases múltiples

Para hipótesis $H_1, \dots, H_k$ mutuamente excluyentes y exhaustivas:

$$P(H_j | E) = \frac{P(E | H_j)P(H_j)}{\sum_h P(E | H_h)P(H_h)}.$$

Si falta una hipótesis plausible, las probabilidades se redistribuyen entre opciones incompletas y pueden crear falsa certeza. Un estado “otro” o “desconocido” puede ser necesario.

5.3.5. Actualización secuencial de creencias

La posterior de hoy puede ser previa de mañana. Para evidencias E_1, E_2 :

$$P(H | E_1, E_2) \propto P(E_2 | H, E_1)P(H | E_1).$$

El orden no cambia el resultado si se usa correctamente la distribución conjunta. Cambia la representación intermedia.

Evidencias condicionalmente independientes

Si E_1 y E_2 son independientes dado H :

$$P(E_1, E_2 | H) = P(E_1 | H)P(E_2 | H).$$

La simplificación permite multiplicar razones de verosimilitud. Si ambas provienen del mismo sensor o causa, asumir independencia cuenta dos veces la información.

Odds y razones de verosimilitud

Bayes puede expresarse:

$$Odds(H | E) = Odds(H) \times LR(E).$$

En una secuencia condicionalmente independiente, se multiplican LR . Esta forma muestra cómo cada evidencia aumenta o disminuye odds.

Olvido y cambio de régimen

En sistemas dinámicos, datos antiguos pueden no representar el presente. Una actualización acumulativa que nunca olvida se vuelve confiada en un régimen pasado. Se necesitan modelos temporales, ventanas o parámetros cambiantes.

Detener la observación

Obtener evidencia tiene costo. Puede detenerse cuando una acción es claramente preferible o continuar si el valor esperado de información supera el costo. Esto conecta Bayes con teoría de decisión.

5.3.6. Inferencia mediante distribuciones conjuntas

Una distribución conjunta contiene toda la información probabilística del conjunto de variables. La inferencia consiste en condicionar y marginalizar.

Supóngase F fuga, P baja presión y R reclamo. Para calcular:

$$P(F | P, R) = \frac{P(F, P, R)}{\sum_f P(f, P, R)}.$$

El numerador selecciona el estado; el denominador suma hipótesis compatibles.

Enumeración

Con pocas variables discretas se construye tabla completa y se suma. Es transparente, pero crece exponencialmente. Cuatro variables binarias tienen 16 estados; veinte, más de un millón.

Factorización

Las independencias condicionales permiten factorizar. Una red bayesiana representa un grafo dirigido y escribe:

$$P(X_1, \dots, X_n) = \prod_i P(X_i | Pa(X_i)),$$

donde Pa son padres. La estructura debe basarse en conocimiento y evidencia; no es solo comprensión.

Inferencia exacta y aproximada

Eliminación de variables y propagación de mensajes pueden ser exactas en ciertas estructuras. En modelos grandes se utilizan Monte Carlo, MCMC o métodos variacionales. La aproximación añade error computacional a la incertidumbre del modelo.

Evidencia faltante

La marginalización permite inferir sin observar todas las variables, siempre que el mecanismo esté modelado. No equivale a imputar un único valor; integra posibilidades.

Comprobación

Se revisa que distribuciones sumen uno, probabilidades estén en rango y marginales coincidan. También se realizan comprobaciones predictivas: simular desde el modelo y comparar patrones con datos.

5.3.7. Ejemplo práctico guiado: diagnóstico probabilístico de una transacción fraudulenta

Hipótesis, población y tasa base

Sea F el evento “la transacción es fraudulenta”. Para compras digitales del mismo país, comercio y franja horaria, el histórico auditado estima $P(F) = 0.004$: alrededor de 4 fraudes por cada 1000 transacciones. Esta población de referencia importa; emplear la tasa de un segmento ya alertado inflaría la previa.

Las probabilidades previas pueden expresarse como *odds*:

$$O(F) = \frac{P(F)}{1 - P(F)} = \frac{0.004}{0.996} \approx 0.004016.$$

La transacción analizada tiene importe superior a 1200 unidades monetarias (A), procede de un dispositivo no registrado para la cuenta (D) y se origina lejos del patrón geográfico habitual (L).

Actualización por importe

En datos de validación representativos se estima $P(A | F) = 0.48$ y $P(A | F^c) = 0.08$. La razón de verosimilitud es:

$$LR_A = \frac{0.48}{0.08} = 6.$$

Por tanto, $O(F | A) = 0.004016(6) = 0.02410$ y:

$$P(F | A) = \frac{0.02410}{1 + 0.02410} \approx 0.0235.$$

Aunque el importe multiplica por seis los *odds*, la probabilidad queda cerca de 2,4 % por la baja tasa base. Confundir $P(A | F) = 0.48$ con $P(F | A)$ produciría una alarma desproporcionada.

Dispositivo y localización

El dispositivo nuevo y la localización atípica no se tratan como señales independientes del importe. A partir de casos con el mismo criterio de importe se estima:

$$LR_{D|A} = \frac{P(D | F, A)}{P(D | F^c, A)} = \frac{0.50}{0.10} = 5.$$

La actualización da $O(F | A, D) = 0.02410(5) = 0.12048$, equivalente a $P(F | A, D) \approx 0.1075$. Para la localización, condicionando ahora por las dos señales anteriores:

$$LR_{L|A,D} = \frac{P(L | F, A, D)}{P(L | F^c, A, D)} = \frac{0.50}{0.20} = 2.5.$$

Así,

$$O(F | A, D, L) = 0.12048(2.5) = 0.30120,$$

$$P(F | A, D, L) = \frac{0.30120}{1 + 0.30120} \approx 0.2315.$$

La transacción tiene una probabilidad estimada de fraude de 23,2 %, no la suma de tres porcentajes. Las razones condicionadas reconocen parte de la dependencia: viajeros legítimos, por ejemplo, pueden usar simultáneamente un dispositivo nuevo y una localización inusual. Si esas probabilidades condicionadas se estimaron con pocos casos, conviene usar un modelo conjunto regularizado y validar calibración fuera de muestra. Multiplicar razones marginales como si fueran independientes sobrestimaría la evidencia.

Sensibilidad del diagnóstico

La tasa base puede variar entre 0,2 % y 0,8 % por retrasos de etiquetado y cambios estacionales. Además, el producto efectivo de las razones de verosimilitud puede estar entre 45 y 100, frente al valor central $6(5)(2.5) = 75$. Combinando los extremos relevantes:

$$P_{min} = \frac{(0.002/0.998)45}{1 + (0.002/0.998)45} \approx 0.083,$$

$$P_{max} = \frac{(0.008/0.992)100}{1 + (0.008/0.992)100} \approx 0.446.$$

El rango de 8,3 % a 44,6 % no es un intervalo formal si los extremos fueron elegidos como escenarios; comunica sensibilidad a entradas plausibles. La amplitud advierte que el valor central no debe presentarse con precisión excesiva.

Umbral de revisión basado en costos

Supóngase que una revisión manual cuesta $C_R = 12$ unidades entre tiempo del analista y fricción para el cliente, y que dejar pasar un fraude genera una pérdida esperada $C_F = 80$. En una simplificación donde la revisión evita esa pérdida y no hay restricción de capacidad, se revisa cuando:

$$C_R < pC_F \iff p > \frac{12}{80} = 0.15.$$

La estimación central de 23,2 % supera el umbral y recomienda revisión, pero el análisis de sensibilidad lo cruza: con los supuestos más conservadores no se revisaría. Por ello el reporte califica la decisión como sensible y propone obtener una autenticación adicional de bajo costo. En producción también deben incorporarse la eficacia imperfecta de la revisión, el costo de demoras, el presupuesto diario y los impactos desiguales sobre grupos de clientes; Bayes cuantifica el diagnóstico, mientras la política de decisión explicita sus consecuencias.

Actividad EMO [AGUA-04]: estimar riesgo y priorizar una acción

Capacidad mínima: actualizar una probabilidad con evidencia y convertirla en una decisión explícita.

Consigna: definir una condición anómala; estimar o justificar una previa; incorporar al menos dos evidencias mediante verosimilitudes; calcular posteriores; definir una regla con costos de falso positivo y falso negativo; analizar sensibilidad.

Modalidad: discusión grupal de supuestos y fuentes; cálculos, sensibilidad y decisión individuales para una zona o escenario.

Evidencia individual: notebook o planilla reproducible con árbol o tabla de probabilidades, previa, verosimilitudes, posteriores, matriz de costos, regla y análisis de escenarios.

Criterios de aprobación:

- hipótesis, eventos y población están definidos;
- previa, verosimilitud, evidencia y posterior se diferencian;
- no se confunden probabilidades inversas;
- las dependencias entre evidencias se discuten;
- la acción deriva de probabilidades, costos y restricciones;
- se muestra cómo cambian riesgo y decisión ante supuestos alternativos.

Preguntas para la defensa: ¿qué población sustenta la previa?, ¿qué evidencia podría estar duplicada?, ¿por qué la sensibilidad no es la posterior?, ¿qué medición tendría mayor valor?

5.4. Incertidumbre y comunicación probabilística

Una probabilidad no elimina incertidumbre: la representa dentro de un modelo. Además de la variabilidad del fenómeno, existe incertidumbre sobre parámetros, datos, estructura y condiciones futuras. Comunicar un único número sin esas capas puede producir una confianza que el análisis no respalda.

5.4.1. Incertidumbre aleatoria

La incertidumbre **aleatoria** o irreducible representa variabilidad inherente al fenómeno bajo el modelo. Incluso con parámetros conocidos, un resultado Bernoulli sigue siendo incierto y un tiempo de espera varía.

Variabilidad individual y promedio

El promedio de muchas observaciones suele ser más estable que una observación individual. Si X_i son independientes con varianza σ^2 :

$$Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Esto reduce incertidumbre sobre el promedio, no variabilidad de un nuevo individuo. Confundirlas produce intervalos predictivos demasiado estrechos.

Heterogeneidad

Parte de lo que parece aleatorio puede explicarse al incorporar variables. La demanda impredecible globalmente puede ser más estable por franja y zona. Después de condicionar persiste variabilidad residual.

Dependencia

La fórmula anterior falla con correlación. Eventos comunes hacen que aumentar cantidad no reduzca incertidumbre al ritmo esperado. En riesgo, muchas unidades pueden fallar juntas durante una tormenta.

Decisiones

La incertidumbre aleatoria no siempre puede reducirse con más datos históricos. Puede requerir reservas, redundancia, límites de seguridad o políticas robustas.

5.4.2. Incertidumbre epistémica

La incertidumbre **epistémica** proviene de conocimiento limitado: pocos datos, parámetros imprecisos, variables omitidas, etiquetas dudosas, cambio de distribución o modelos alternativos.

Parámetros y estructura

Una posterior amplia refleja incertidumbre paramétrica. Pero elegir una familia única puede ocultar incertidumbre estructural. Comparar modelos y supuestos revela cuánto depende la conclusión de esa elección.

Datos y medición

Errores de sensor, cobertura y selección agregan incertidumbre que no siempre aparece en la fórmula. Si se tratan datos como exactos, el intervalo será demasiado optimista.

Reducibilidad

La incertidumbre epistémica puede reducirse con mejores mediciones, más datos pertinentes, experimentos o conocimiento. La pregunta práctica es qué fuente conviene reducir. El valor de información prioriza mediciones capaces de cambiar la acción.

Frontera difusa

Aleatoria y epistémica dependen del modelo. Variación entre zonas puede parecer aleatoria hasta incluir material de tubería. La clasificación sirve para diseñar respuesta, no para afirmar una división metafísica absoluta.

Fuera de distribución

Un modelo puede ser confiado en casos alejados de entrenamiento. Detectar novedad, limitar extrapolación y abstenerse son controles de incertidumbre epistémica.

5.4.3. Estimaciones puntuales e intervalos

Una estimación puntual resume una distribución o muestra en un valor: media, mediana, máxima verosimilitud o media posterior. Es útil para decidir, pero oculta precisión.

Intervalo de confianza

En interpretación frecuentista, un procedimiento de 95 % produce intervalos que cubrirían el parámetro verdadero en 95 % de repeticiones bajo supuestos. Después de observar un intervalo concreto, el parámetro fijo no tiene una probabilidad frecuentista de 95 % de estar dentro.

Intervalo creíble

Un intervalo bayesiano de 95 % contiene 95 % de probabilidad posterior del parámetro, condicionado al modelo y previa. Puede ser central o de mayor densidad.

Intervalo predictivo

Describe una observación futura e incorpora variabilidad aleatoria y de parámetros. Suele ser más ancho que el intervalo para la media. Para operación, a menudo es el relevante.

Cobertura y calibración

Un intervalo nominal no garantiza cobertura si el modelo está mal especificado. Se evalúa en datos nuevos: aproximadamente 90 % de resultados debería caer en intervalos predictivos de 90 %, considerando dependencia.

Precisión numérica

Reportar 0.137426 no es más honesto si entradas son inciertas. Las cifras significativas deben reflejar precisión y uso. El redondeo no elimina la necesidad de intervalo.

5.4.4. Calibración de probabilidades

Un modelo está calibrado si, entre casos con probabilidad pronosticada cercana a p , el evento ocurre aproximadamente en proporción p .

Diagrama de confiabilidad

Se agrupan pronósticos y se compara media predicha con frecuencia observada. Los bins deben tener tamaño suficiente y pueden ocultar variación. También se utilizan métodos continuos o bandas.




Figura 12: Ejemplo de calibración probabilística

Brier score

Para resultados binarios:

$$BS = \frac{1}{n} \sum_i (p_i - y_i)^2.$$

Evalúa exactitud probabilística y es una regla de puntuación propia. Depende de prevalencia y combina calibración con resolución; debe compararse con baseline.

Calibración y discriminación

Un modelo puede ordenar bien riesgos y estar mal calibrado. AUC mide ranking, no correspondencia de probabilidades. Si la decisión usa costos y umbrales,

calibración es crucial.

Cambio de prevalencia

Una probabilidad calibrada en una población puede dejar de estarlo si cambia prevalencia o mecanismo. Se monitorea por periodo y grupo. Recalibrar no corrige ausencia de representatividad profunda.

Calibración por subgrupos

La calibración global puede ocultar desvíos por zona. Evaluarla en grupos pequeños es ruidoso, por lo que se combinan evidencia, intervalos y modelos jerárquicos.

5.4.5. Riesgos de interpretación

Inversión del condicional

Confundir $P(E | H)$ con $P(H | E)$ es el error diagnóstico clásico. Una prueba sensible no implica que un positivo tenga alta probabilidad de enfermedad si la prevalencia es baja.

Negligencia de tasa base

Ignorar la previa sobrevalora evidencia llamativa. Presentar frecuencias naturales ayuda: de 1.000 zonas, 20 tienen fuga; la señal detecta 16 y produce 98 falsos positivos; entre 114 alertas, solo 16 son fugas.

Riesgo relativo y absoluto

Duplicar riesgo de 0,01 % a 0,02 % es 100 % relativo y 0,01 puntos absoluto. Ambos son correctos, pero producen impresiones diferentes. Deben comunicarse juntos cuando sea pertinente.

Probabilidad y causalidad

Una posterior alta de evento no demuestra qué intervención lo evitará. Diagnóstico y tratamiento son preguntas diferentes.

Falsa precisión y certeza

Una salida de 87,3 % no incorpora automáticamente incertidumbre de modelo. Las etiquetas “bajo/alto” pueden ocultar gradación y umbrales arbitrarios. Se documentan supuestos y rango.

Riesgo individual y grupal

Una frecuencia de grupo aplicada a un individuo expresa incertidumbre condicionada, no destino. La comunicación debe evitar determinismo y estigmatización.

Colas

Eventos improbables con impacto enorme requieren atención. “Solo 1 %” no decide por sí solo; debe combinarse con consecuencia y reversibilidad.

5.4.6. Comunicación de resultados inciertos

Una comunicación probabilística debe permitir al receptor comprender magnitud, horizonte, referencia, incertidumbre y acción.

Frecuencias naturales

“15 de cada 100 zonas similares durante una semana” suele ser más comprensible que “0,15”. El denominador y periodo deben coincidir con la decisión.

Comparaciones

Se presenta baseline: riesgo habitual, con evidencia y después de acción. Sin referencia, “alto” es subjetivo. Riesgos relativos se acompañan con absolutos.

Rangos y escenarios

Un intervalo puede comunicarse como rango compatible con datos y supuestos. Si existen modelos alternativos, se presentan escenarios, no un promedio que oculte desacuerdo.

Lenguaje verbal

Palabras como “probable” tienen interpretaciones variadas. Si se usan, se vinculan con rangos definidos y se muestra número. No deben reemplazar probabilidades en decisiones críticas.

Decisión y sensibilidad

El informe indica si la acción cambia dentro del rango. “La probabilidad está entre 25 % y 40 %; inspeccionar sigue siendo preferible para costos considerados” es más útil que solo el intervalo.

Transparencia

Se explican fuente, población, fecha, actualización, supuestos y limitaciones. También qué evidencia podría cambiar la conclusión. Una comunicación madura reconoce lo desconocido sin paralizar la decisión.

5.4.7. Ejemplo práctico guiado: elaboración de un reporte de riesgo**Resumen ejecutivo**

“La máquina M-17 tiene una probabilidad estimada de falla funcional de 12 % durante los próximos 30 días, con un rango plausible de 7 % a 20 %. En maquinaria comparable, el riesgo es 4 %. Bajo los costos y la eficacia de mantenimiento

acordados, se recomienda intervenir; la recomendación es sensible al extremo inferior del rango.”

La frase define evento, unidad y horizonte. No afirma que 12 % de la máquina esté deteriorada ni que la falla sea inevitable.

Riesgo absoluto y relativo

Por cada 100 máquinas con señales semejantes a M-17 se esperarían aproximadamente 12 fallas en 30 días si el modelo permanece calibrado. La referencia histórica equivale a 4 por cada 100. La diferencia absoluta es:

$$RD = 0.12 - 0.04 = 0.08,$$

es decir, 8 fallas adicionales por cada 100 máquinas. El riesgo relativo es:

$$RR = \frac{0.12}{0.04} = 3.$$

M-17 presenta tres veces el riesgo de referencia, pero el aumento absoluto es de 8 puntos porcentuales. Informar ambas medidas evita que el cociente, más llamativo, oculte la magnitud operativa.

Evidencia e incertidumbre

La estimación integra antigüedad del rodamiento, horas desde el último mantenimiento, vibración espectral y temperatura del alojamiento. El rango de 7 % a 20 % combina incertidumbre de parámetros con escenarios sobre calibración del sensor y elección del modelo. No representa toda incertidumbre posible: un régimen de carga nuevo o una causa de falla ausente del histórico podría invalidarlo.

Como sensibilidad, al excluir temperatura por posible deriva del sensor el riesgo baja a 7 %; con una tendencia de vibración más pronunciada sube a 20 %. Frente a la referencia fija de 4 %, esos escenarios corresponden a diferencias absolutas de 3 a 16 puntos porcentuales y riesgos relativos de 1,75 a 5. Si también se estima la referencia, los intervalos de RD y RR deben obtenerse conjuntamente, no combinando extremos independientes.

Umbral de intervención

Una falla cuesta en promedio $C_F = 50$ unidades por reparación urgente y detención. El mantenimiento preventivo cuesta $C_M = 3$ y reduce el riesgo residual a $p_M = 0.02$. Bajo neutralidad al riesgo se interviene cuando:

$$C_M + p_M C_F < p C_F,$$

o, de forma equivalente,

$$p > p_M + \frac{C_M}{C_F} = 0.02 + \frac{3}{50} = 0.08.$$

El riesgo central de 12 % supera el umbral de 8 %. El costo esperado sin intervención es $0.12(50) = 6$ unidades y con mantenimiento es $3 + 0.02(50) = 4$. Sin embargo, el escenario de 7 % queda por debajo del umbral. La recomendación es, por tanto, favorable pero no robusta a todos los supuestos. Consecuencias de seguridad, paradas compartidas o aversión a pérdidas extremas justificarían una función de utilidad más rica que este cálculo esperado.

Valor de una medición adicional

Antes de detener M-17 puede realizarse una medición independiente de vibración durante un ciclo controlado. Según la validación disponible, hay 35 % de probabilidad de obtener una alarma que llevaría el riesgo a 25 %, y 65 % de obtener un resultado normal que lo reduciría a 5 %. El promedio $0.35(0.25) + 0.65(0.05) = 0.12$ es coherente con el riesgo actual.

Con la medición se intervendría ante alarma, con costo esperado de 4 unidades, y se continuaría operando ante resultado normal, con costo esperado $0.05(50) = 2.5$. El costo esperado de la estrategia informada, antes de pagar la medición, sería:

$$0.35(4) + 0.65(2.5) = 3.025.$$

Sin nueva información, la mejor acción cuesta 4 unidades en esperanza. El valor esperado de la información muestral es entonces $4 - 3.025 = 0.975$ unidades. La medición conviene si su costo total, incluida la demora y el riesgo de ejecutarla, es menor que ese valor. Este cálculo depende de que el ensayo esté calibrado, sea verdaderamente adicional y llegue antes de la decisión; si repite la misma señal del sensor actual, su valor sería menor.

Recomendación comunicada

El reporte recomienda realizar la medición controlada si cuesta menos de 0,975 unidades y, en caso contrario, ejecutar el mantenimiento preventivo con la evidencia actual. También solicita revisar el resultado si cambian la carga prevista, el costo de detención o la calibración. Así se separan con claridad la probabilidad estimada, su incertidumbre, las consecuencias y la regla que convierte el riesgo en acción.

Síntesis del capítulo

La probabilidad comienza por definir experimento, espacio y eventos. Sus reglas aseguran coherencia y obligan a controlar denominadores. El condicionamiento describe cómo cambia la incertidumbre con información; la independencia permite simplificar solo cuando el mecanismo la justifica.

Las variables aleatorias y distribuciones convierten resultados en modelos de conteos, magnitudes y tiempos. La elección de una familia depende de soporte, exposición, dependencia y proceso generador. El ajuste central no basta cuando la decisión depende de colas.

Bayes combina previa y verosimilitud para producir una posterior. La actualización es coherente, pero condicional al modelo. Convertir probabilidad en acción

requiere utilidad, costos y capacidad. Comunicar exige separar variabilidad, conocimiento limitado, calibración y supuestos.

Glosario esencial

- **Calibración:** correspondencia entre probabilidades pronosticadas y frecuencias observadas.
- **Densidad:** función cuya integral sobre un intervalo produce probabilidad.
- **Distribución conjunta:** modelo probabilístico de varias variables simultáneas.
- **Evidencia:** probabilidad marginal de los datos que normaliza Bayes.
- **Esperanza:** promedio probabilístico de una variable aleatoria.
- **Evento:** subconjunto del espacio muestral.
- **Independencia:** condición en que conocer un evento no cambia la probabilidad del otro.
- **Posterior:** distribución después de incorporar evidencia.
- **Previa:** distribución antes de la evidencia actual.
- **Verosimilitud:** compatibilidad de datos observados con hipótesis o parámetros.

Preguntas de autoevaluación

1. ¿Por qué el espacio muestral depende del nivel de modelado?
2. ¿Qué diferencia hay entre unión, intersección y exclusión mutua?
3. ¿Por qué probabilidad cero no implica siempre imposibilidad?
4. ¿Cómo evita la regla de suma el doble conteo?
5. ¿Qué cambia al condicionar una probabilidad?
6. ¿Por qué independencia y exclusión mutua no son sinónimos?
7. ¿Qué diferencia existe entre masa y densidad?
8. ¿Cómo se relacionan CDF, supervivencia y cuantiles?
9. ¿Por qué $E[g(X)]$ no suele ser $g(E[X])$?
10. ¿Qué supuestos justifican una distribución binomial o Poisson?
11. ¿Qué propiedad de la exponencial puede ser inadecuada para fallas?
12. ¿Cómo se obtienen marginales desde una conjunta?
13. ¿Qué representa una previa y cómo se evalúa su influencia?
14. ¿Por qué una verosimilitud no es una posterior?
15. ¿Qué función cumple la evidencia en Bayes?
16. ¿Cuándo no deben multiplicarse dos evidencias?
17. ¿Qué diferencia hay entre incertidumbre aleatoria y epistémica?
18. ¿Cómo difieren intervalo de confianza, creíble y predictivo?
19. ¿Por qué discriminación no garantiza calibración?
20. ¿Cómo ayuda una frecuencia natural a evitar negligencia de tasa base?

Actividad integradora de cierre

Construya un análisis probabilístico para un caso de agua o movilidad:

1. defina experimento, espacio, eventos y horizonte;
2. estime probabilidades simples, conjuntas y condicionales;
3. evalúe una independencia plausible;
4. seleccione una variable aleatoria y distribución justificando mecanismo;

5. compare propiedades teóricas con datos;
6. proponga previa y verosimilitudes para una hipótesis;
7. calcule una actualización secuencial;
8. convierta la posterior en decisión mediante costos;
9. analice sensibilidad y calibración;
10. redacte un reporte con frecuencia natural, rango y limitaciones.

La evaluación prioriza coherencia entre definición, modelo, evidencia y decisión. Un cálculo correcto sobre eventos ambiguos o supuestos no defendidos no constituye un análisis probabilístico sólido.

Capítulo 6. Agentes inteligentes y representación de problemas

Propósito y objetivos de aprendizaje

Un sistema de inteligencia artificial no actúa en el vacío. Recibe información incompleta, interviene sobre un entorno y es evaluado por las consecuencias de sus decisiones. La noción de **agente** reúne estos elementos en una unidad de análisis: permite preguntar qué observa el sistema, qué puede hacer, qué pretende lograr y bajo qué condiciones una acción puede considerarse racional. Esta perspectiva evita reducir la inteligencia artificial a un algoritmo aislado.

El capítulo avanza desde el concepto general de agente hasta la formulación computacional de problemas. Primero distingue racionalidad, autonomía y omnisciencia. Luego caracteriza los entornos mediante PEAS y seis dimensiones que condicionan el diseño. A continuación compara arquitecturas de agentes, desde reglas reactivas hasta sistemas que aprenden. Por último traduce situaciones del mundo real a estados, acciones, transiciones, objetivos, costos y restricciones. Esa traducción será la entrada de los métodos de búsqueda del capítulo 7 y de las decisiones secuenciales del capítulo 8.

Al finalizar, el lector podrá:

- definir un agente por su relación perceptiva y activa con un entorno;
- diferenciar secuencia de percepciones, función de agente y programa de agente;
- diseñar medidas de desempeño alineadas con resultados y restricciones;
- explicar racionalidad limitada, autonomía y diferencia respecto de omnisciencia;
- construir una descripción PEAS y justificar cada uno de sus componentes;
- caracterizar observabilidad, incertidumbre, secuencialidad, dinamismo, continuidad e interacción entre agentes;
- comparar arquitecturas reactivas, deliberativas, basadas en utilidad y con aprendizaje;
- formular un problema mediante estados, acciones, transiciones, objetivos, costos y restricciones;
- seleccionar un nivel de abstracción adecuado y reconocer sus pérdidas de información;
- documentar supuestos, errores posibles y criterios de validación de una representación.

6.1. Agentes y racionalidad

La perspectiva de agentes desplaza la pregunta «¿qué algoritmo es inteligente?» hacia una pregunta operacional: «¿qué entidad selecciona acciones a partir de lo que percibe y cómo se evalúa esa selección?». El mismo algoritmo puede ser apropiado en un entorno e inadecuado en otro. Por ello, antes de escoger técnicas se debe delimitar el sistema, su frontera, su información y su responsabilidad.

6.1.1. Concepto de agente

Un **agente** es una entidad que percibe un entorno mediante sensores y actúa sobre él mediante actuadores. La definición es deliberadamente amplia: incluye un termostato, un robot, una persona, un sistema de recomendación o un servicio que asigna cuadrillas. Lo decisivo no es que tenga forma física ni que aprenda, sino que exista un ciclo entre percepción y acción.

Se denomina **entorno** a aquello que queda fuera de la frontera del agente y que resulta relevante para su tarea. Esa frontera es una decisión de modelado. En un sistema de movilidad, puede considerarse agente a cada vehículo, al coordinador de toda la flota o al conjunto vehículo-conductor. Cada elección modifica sensores, acciones y objetivos. Si el conductor queda dentro del agente, sus decisiones forman parte del mecanismo interno; si queda fuera, son eventos del entorno que deben observarse o anticiparse.

Formalmente, en el instante t el entorno posee un estado e_t , genera una percepción p_t y recibe una acción a_t . Una representación general es:

$$p_t = O(e_t), \quad a_t = \pi(p_1, \dots, p_t), \quad e_{t+1} \sim T(e_t, a_t),$$

donde O es el proceso de observación, π la conducta del agente y T la dinámica del entorno. El símbolo $\sim$ admite que la transición sea incierta. No se presupone que $p_t = e_t$: una percepción es información acerca del entorno, no necesariamente una copia completa de este.

Conviene distinguir agente de herramienta. Una calculadora produce un resultado cuando una persona la invoca, pero no suele seleccionar por sí misma cuándo actuar ni mantener un ciclo propio de interacción. En cambio, un sistema que supervisa caudales, detecta riesgo y decide emitir una orden participa en ese ciclo. La distinción no siempre es absoluta; depende del grado de iniciativa y de la frontera adoptada.

Error frecuente. Llamar «agente» a cualquier modelo predictivo. Un predictor que estima probabilidad de falla produce información; solo constituye por sí solo un agente si esa salida participa en una política que selecciona acciones. De otro modo, es un componente perceptivo o inferencial dentro de un agente más amplio.

6.1.2. Percepciones, sensores, acciones y actuadores

Una **percepción** es el contenido informativo recibido por el agente en un instante. La **secuencia de percepciones** $p_{1:t} = (p_1, \dots, p_t)$ reúne toda su experiencia hasta t . Una observación puntual puede ser ambigua, mientras que la historia permite inferir tendencias: una presión baja aislada puede deberse a ruido; una caída persistente acompañada por aumento de caudal sugiere fuga.

Los **sensores** son mecanismos de adquisición. Pueden ser físicos, como manómetros y cámaras, o lógicos, como una interfaz de consulta, una cola de mensajes o un formulario. Sensor y variable observada no son sinónimos: un sensor posee rango, resolución, frecuencia, latencia, disponibilidad y error. Dos instrumentos que informan «presión» pueden ofrecer evidencias de calidad muy diferente.

Una **acción** es una decisión abstracta disponible para el agente; un **actuador** es el mecanismo que intenta ejecutarla. «Cerrar válvula V3» es una acción; el dispositivo motorizado y el canal de control son actuadores. La orden no garantiza el efecto: puede haber demora, rechazo o falla mecánica. Por eso se distingue entre acción emitida a_t y transición efectiva del entorno.

Elemento	Pregunta de diseño	Ejemplo en una red de agua	Riesgo habitual
Percepción	¿Qué información recibe el agente?	Presión 2,1 bar a las 10:05	Confundir dato con estado real
Sensor	¿Cómo y con qué calidad se obtiene?	Manómetro digital cada minuto	Ignorar calibración o latencia
Acción	¿Qué decisión puede seleccionar?	Reducir bombeo un 10 %	Definir acciones no ejecutables
Actuador	¿Cómo se materializa la acción?	Variador de frecuencia	Suponer ejecución perfecta
Efecto	¿Qué cambió realmente?	Caudal reducido tras 20 s	No verificar realimentación

Diseñar el ciclo exige unidades, marcas temporales y semántica explícitas. También requiere manejar percepciones ausentes, contradictorias o fuera de rango. «Sin lectura» no equivale a «valor cero». En sistemas críticos, una acción debe incluir confirmación, límites operativos y una alternativa segura si el actuador no responde.

6.1.3. Función y programa de agente

La **función de agente** describe matemáticamente qué acción corresponde a cada secuencia posible de percepciones:

$$f : P^* \rightarrow A,$$

donde P^* es el conjunto de secuencias finitas de percepciones y A el conjunto de acciones. Es una especificación abstracta de conducta. Aunque una tabla pudiera enumerar todas las correspondencias, sería inmensa o infinita en entornos reales.

El **programa de agente** es el procedimiento concreto que implementa esa función sobre una arquitectura computacional. Recibe la percepción actual, consulta o actualiza memoria y devuelve una acción. La **arquitectura** aporta recursos de cómputo, almacenamiento, comunicación, sensores y actuadores. En forma sintética:

$$\text{Agente} = \text{Arquitectura} + \text{Programa}.$$

No deben confundirse estos niveles. Una misma función puede implementarse con programas distintos; un mismo programa puede comportarse de manera diferente si cambia la precisión de los sensores o el tiempo disponible. Además, el programa no recibe literalmente toda la historia: suele condensarla en un estado interno m_t :

$$m_t = U(m_{t-1}, p_t), \quad a_t = D(m_t),$$

donde U actualiza memoria y D decide. La calidad de m_t depende de qué información retiene y cuál descarta.

Un esquema general, todavía independiente de lenguaje, es:

PROCEDIMIENTO AGENTE(percepción)

 actualizar estado interno con percepción y acción anterior
 estimar alternativas legalmente disponibles
 evaluar alternativas según objetivo y conocimiento actual
 seleccionar una acción, o abstenerse si ninguna es segura
 registrar decisión y razones
 devolver acción

FIN PROCEDIMIENTO

La función de agente es útil para razonar sobre conducta; el programa permite estudiar límites reales. Memoria finita, presupuesto, demora máxima y precisión numérica forman parte del diseño. Una especificación que solo funciona con tiempo ilimitado no define un agente operativo.

6.1.4. Medidas de desempeño

Una **medida de desempeño** evalúa la secuencia de estados y consecuencias producida por el agente. Debe expresar el resultado deseado en el entorno, no una preferencia por el mecanismo interno. Para un servicio de agua, «minimizar interrupciones y pérdidas respetando seguridad» es mejor criterio que «emitir muchas alertas», porque una cantidad elevada de alertas puede lograrse sin resolver ningún problema.

Sea una trayectoria $\tau = (e_0, a_0, e_1, \dots, e_H)$. Una medida general puede escribirse:

$$J(\tau) = \sum_{t=0}^H w_t r(e_t, a_t) - \sum_{t=0}^H q(e_t, a_t),$$

donde r representa beneficios, q costos o penalizaciones, y w_t pondera el tiempo. Sin embargo, no todo debe convertirse en una suma. Una restricción de seguridad puede ser no negociable: primero se excluyen acciones inseguras y luego se optimiza entre las restantes.

Una medida bien construida declara:

- **unidad de evaluación:** evento, usuario, zona o trayectoria;
- **horizonte:** minutos, jornada, año o vida útil;
- **resultados positivos:** continuidad, cobertura, calidad o tiempo ahorrado;

- **costos:** energía, desgaste, demora, falsa alarma o intervención;
- **restricciones:** legalidad, seguridad, equidad y capacidad;
- **agregación:** promedio, peor caso, percentil o combinación;
- **fuentes de verdad:** cómo y cuándo se verifica el resultado.

Medida defectuosa	Conducta oportunista posible	Reformulación preferible
Maximizar alertas atendidas	Generar alertas triviales	Reducir daño confirmado por unidad de recurso
Minimizar tiempo medio de viaje	Perjudicar sistemáticamente zonas remotas	Combinar media, percentil alto y cobertura territorial
Minimizar consumo energético	Interrumpir un servicio necesario	Minimizar energía sujeto a nivel mínimo de servicio
Maximizar precisión	Ignorar casos raros y graves	Incorporar costos asimétricos y calibración

La ley de Goodhart advierte que, cuando una medida se convierte en objetivo, puede dejar de ser una buena medida. Se requieren métricas complementarias, auditoría y revisión de efectos distributivos. El desempeño tampoco debe evaluarse solo con casos favorables: fallas de sensores, picos de demanda y cambios de régimen forman parte del entorno real.

6.1.5. Racionalidad y autonomía

Un agente es **racional** si selecciona la acción que maximiza el desempeño esperado dadas la secuencia de percepciones, el conocimiento previo, las acciones disponibles y sus recursos. En un instante t :

$$a_t^* \in \arg \max_{a \in A_t} \mathbb{E}[J \mid p_{1:t}, K, a],$$

donde K es el conocimiento disponible y A_t el conjunto de acciones factibles. Si varias acciones alcanzan el mismo máximo, cualquiera puede ser racional. La racionalidad se juzga con la información disponible al decidir, no únicamente por el resultado observado después.

La expectativa es esencial: una decisión razonable puede terminar mal por azar. Reparar una tubería con alto riesgo estimado puede revelar que estaba intacta; ello no demuestra irracionalidad si el diagnóstico era válido y el costo esperado justificaba inspeccionar. Inversamente, una decisión temeraria puede salir bien sin volverse racional.

La **racionalidad limitada** reconoce que obtener la acción ideal puede requerir más cómputo, datos o tiempo de los disponibles. Un agente operativo busca una buena decisión dentro de sus recursos. El costo de deliberar también importa: una planificación perfecta que llega después de una inundación carece de valor. Esto conduce a algoritmos interrumpibles, umbrales y políticas de respaldo.

La **autonomía** es el grado en que la conducta depende de la experiencia propia y no solo de conocimiento incorporado por el diseñador. No equivale a ausencia de supervisión. Un agente puede aprender patrones locales y, a la vez, requerir aprobación humana para cerrar una válvula principal. La autonomía responsable necesita límites de acción, trazabilidad, detección de situaciones desconocidas y capacidad de abstención.

Error frecuente. Presentar racionalidad como obediencia ciega a una métrica. Si la métrica omite seguridad o derechos, maximizarla no convierte la conducta en aceptable. La especificación normativa precede a la optimización.

6.1.6. Agentes omniscientes frente a agentes racionales

Un agente **omnisciente** conoce el estado real, los efectos exactos de cada acción y todos los eventos futuros. Un agente racional no dispone de ese privilegio: decide bien a partir de evidencia limitada. Confundir ambos conceptos lleva a evaluar decisiones retrospectivamente con información que no existía en el momento.

Supóngase que hay 30 % de probabilidad de una falla grave. Inspeccionar cuesta 10 unidades y evita una pérdida de 100 si la falla existe. Sin inspección, el costo esperado es $0,30 \times 100 = 30$; inspeccionar cuesta 10, por lo que es racional hacerlo bajo este modelo. Si luego se descubre que no había falla, el costo realizado fue 10, pero la decisión continúa siendo racional. Un agente omnisciente habría sabido que ese caso no requería inspección.

La diferencia puede formalizarse mediante valor de información. Sea I una observación perfecta antes de decidir. Su valor esperado es:

$$VEIP = \mathbb{E}_I \left[\max_a \mathbb{E}(J \mid I, a) \right] - \max_a \mathbb{E}(J \mid a).$$

El valor es no negativo si observar no tiene costo y no obliga a actuar, pero la información real puede ser imperfecta, tardía o costosa. Obtener más datos no siempre es racional; su mejora esperada debe superar adquisición y demora.

También debe evitarse el sesgo de resultado: juzgar solo por éxito o fracaso. Una auditoría correcta reconstruye percepciones, modelo, alternativas y restricciones disponibles en el instante de decisión. Esta distinción prepara el análisis de utilidad y decisiones bajo incertidumbre del capítulo 8.

6.1.7. Ejemplo práctico guiado: definición de un agente para supervisión de una cadena de frío

Se diseñará un agente que supervise lotes sensibles durante almacenamiento y transporte refrigerado. Su propósito es recomendar respuestas ante indicios de pérdida de condiciones térmicas, sin sustituir la decisión sanitaria ni accionar por sí mismo sobre los productos.

Paso 1. Delimitar frontera y autoridad. El agente recibe telemetría de cámaras y vehículos, consulta datos del lote y puede recomendar una medición adicional, priorizar una inspección o proponer el aislamiento preventivo de un lote. El responsable de calidad autoriza el aislamiento y decide la liberación o descarte posterior. Esta frontera distingue la recomendación del agente de la intervención ejecutada por personal habilitado.

Paso 2. Especificar PEAS. La tarea se describe antes de elegir el algoritmo:

Componente	Especificación
Desempeño	Reducir exposición térmica y tiempo de detección, evitar afectación de producto y limitar inspecciones, falsas alarmas y aislamientos innecesarios
Entorno	Cámaras refrigeradas, vehículos, lotes, turnos operativos, aperturas autorizadas, equipos de refrigeración y responsables de calidad
Actuadores	Emitir alertas; recomendar medición, inspección o aislamiento de lote; fijar prioridad e instante de reevaluación
Sensores	Temperatura, estado y duración de apertura de puerta, consumo y disponibilidad de energía, marcas temporales, autodiagnóstico del sensor e identificación del lote

Paso 3. Representar percepciones y calidad. Cada observación incluye unidad, ubicación, lote asociado, marca temporal, latencia, calibración y validez. La serie térmica permite distinguir un valor aislado de una desviación persistente; la señal de puerta aporta una causa operativa posible; la telemetría de energía ayuda a reconocer una interrupción o un equipo que consume sin recuperar el rango esperado. Un dato ausente se representa como desconocido, no como una condición normal.

Paso 4. Definir acciones y precondiciones. El conjunto de recomendaciones es:

$A = \{\text{vigilar, recomendar medición, recomendar inspección, recomendar aislamiento de lote}\}.$

Recomendar una medición es apropiado cuando la evidencia es insuficiente o contradictoria. La inspección requiere una anomalía plausible que pueda confirmarse en el equipo, el recinto o el registro operativo. Recomendar aislamiento exige identificar los lotes potencialmente expuestos y superar un umbral de riesgo acordado; si la trazabilidad es incompleta, el agente debe abstenerse de afirmar qué unidades están afectadas y escalar el caso.

Paso 5. Establecer desempeño. Una medida ilustrativa, aplicada sobre magnitudes normalizadas, es:

$$J = -(5E_T + 4D_P + 2T_D + C_I + 3F + 2A_I),$$

donde E_T es la exposición térmica acumulada, D_P el daño esperado al producto, T_D la demora de detección, C_I el costo de inspección, F las falsas alarmas y A_I los aislamientos innecesarios. La inocuidad y los límites normativos son restricciones duras: no deben intercambiarse por ahorro operativo. Los coeficientes son hipótesis sujetas a validación con calidad, logística y mantenimiento.

Paso 6. Explicitar conocimiento e incertidumbre. El agente conoce rangos admisibles por tipo de producto, tolerancias temporales, historial de calibración, asociación entre lotes y ubicaciones, aperturas planificadas y comportamiento esperado del equipo. No observa directamente la temperatura interna de cada unidad ni puede asegurar una causa única. Mantiene, por tanto, una creencia sobre exposición y riesgo en vez de convertir toda alerta en certeza.

Paso 7. Formular una política inicial auditable. El siguiente pseudocódigo ilustra el ciclo percepción-decisión, no una implementación productiva:

```
SI telemetría inválida, desactualizada O sin identificación confiable
    recomendar medición independiente y escalar la incertidumbre
SINO
    estimar exposición por lote con temperatura, puerta y energía
    SI desviación breve Y apertura autorizada Y recuperación normal
        vigilar y fijar instante de reevaluación
    SI desviación persistente O recuperación anómala
        recomendar inspección prioritaria
    SI riesgo del lote supera el umbral Y trazabilidad suficiente
        recomendar aislamiento para aprobación de calidad
```

Paso 8. Probar escenarios. Una lectura extrema aislada con autodiagnóstico defectuoso debe producir una solicitud de medición, no una conclusión sobre el producto. Una elevación sostenida tras una puerta abierta, acompañada de consumo energético alto y recuperación insuficiente, debe priorizar inspección. Una interrupción de energía con exposición prolongada y lotes bien identificados debe motivar la recomendación de aislamiento. Si no puede determinarse qué lotes estuvieron presentes, el agente debe comunicar esa incertidumbre y ampliar la revisión.

Resultado de la especificación. Se han declarado PEAS, percepciones, acciones, autoridad, conocimiento, restricciones, incertidumbre y desempeño. Quedan pendientes la calibración por producto, la validación retrospectiva con incidentes, las pruebas de sensores y trazabilidad, y los protocolos de ciberseguridad. La especificación define un agente racional respecto de información disponible; no promete diagnóstico omnisciente ni elimina la responsabilidad humana.

6.2. Entornos de tarea

El **entorno de tarea** es el problema externo para el cual se diseña el agente. Incluye condiciones físicas o informacionales, otros actores y reglas de evaluación. Caracterizarlo antes de elegir arquitectura evita, por ejemplo, aplicar reglas sin memoria cuando las observaciones son parciales o planificar sobre una dinámica que cambia más rápido que el cálculo.

6.2.1. Descripción PEAS

PEAS organiza la especificación en cuatro componentes: **medida de desempeño (P, performance)**, **entorno (E)**, **actuadores (A)** y **sensores (S)**. El orden comienza por desempeño para impedir que las capacidades tecnológicas definan por accidente el propósito.

Componente	Contenido	Preguntas de control
Desempeño	Criterios de éxito, costos y restricciones	¿Qué consecuencia se premia? ¿Para quién? ¿En qué horizonte?
Entorno	Objetos, procesos, actores y condiciones externas	¿Qué puede cambiar sin control del agente?
Actuadores	Canales por los que el agente interviene	¿Qué acciones son realmente ejecutables y reversibles?
Sensores	Fuentes de percepción y su calidad	¿Qué se observa, con qué demora, error y cobertura?

PEAS no es una lista de dispositivos. Debe capturar semántica y límites. «GPS» como sensor es insuficiente si no se especifican frecuencia, precisión y zonas sin cobertura. «Optimizar movilidad» como desempeño no indica si interesa tiempo total, regularidad, emisiones, accesibilidad o una combinación.

Un buen PEAS es consistente: cada criterio debe poder estimarse con alguna evidencia; cada acción debe corresponder a un actuador; cada supuesto sobre el entorno debe reflejarse en observaciones o incertidumbre. También debe señalar quién queda fuera de la frontera. En una flota, los pasajeros no son meros elementos físicos: poseen objetivos, reaccionan a recomendaciones y pueden alterar demanda.

PEAS es un documento vivo. Cambiar autoridad, incorporar un sensor o ampliar cobertura puede modificar la clase de entorno. Por ello se versiona junto con las políticas y pruebas del agente.

6.2.2. Entornos observables y parcialmente observables

Un entorno es **completamente observable** si la percepción contiene toda la información relevante para elegir racionalmente. Es **parcialmente observable** si sensores incompletos o ruidosos ocultan aspectos relevantes. La propiedad depende de la tarea y la representación, no de conocer cada detalle del universo.

En ajedrez, el tablero es observable: las piezas y posiciones están visibles, aunque no se conozca la futura jugada rival. En una red de agua subterránea, presión y caudal no revelan directamente ubicación y tamaño de una fuga. En movilidad, un mapa puede mostrar vehículos registrados, pero no intenciones de conductores ni demanda futura.

Cuando hay observabilidad parcial, el agente mantiene un **estado de creencia** $b_t(s)$, distribución sobre estados posibles:

$$b_t(s) = P(S_t = s \mid p_{1:t}, a_{1:t-1}).$$

Tras ejecutar a_t y observar p_{t+1} , combina modelo de transición y observación:

$$b_{t+1}(s') \propto P(p_{t+1} \mid s') \sum_s P(s' \mid s, a_t) b_t(s).$$

No siempre se requiere una distribución completa; pueden usarse intervalos, conjuntos de estados o resúmenes. Pero ocultar incertidumbre con una estimación puntual produce confianza falsa.

Errores frecuentes. Equiparar gran cantidad de datos con observabilidad completa; confundir variable no observada con inexistente; o usar información futura durante la evaluación. La observabilidad debe analizarse en el instante real de decisión y con sensores realmente disponibles.

6.2.3. Entornos deterministas y estocásticos

Un entorno es **determinista** si el estado siguiente queda fijado por estado actual y acción:

$$s_{t+1} = T(s_t, a_t).$$

Es **estocástico** si existen varios resultados con probabilidades:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = T(s' \mid s, a).$$

La incertidumbre puede provenir de variabilidad física, actores externos o una representación que omite variables. Si un modelo de tráfico no incluye clima ni eventos, la transición parecerá aleatoria incluso si parte de la variación posee causas. Por eso «estocástico» describe el modelo al nivel adoptado, no una propiedad metafísica.

En entornos estratégicos, el resultado también depende de acciones de otros agentes. A veces se utiliza «no determinista» cuando se conocen resultados posibles pero no probabilidades. Esta distinción es práctica: con probabilidades se optimiza utilidad esperada; sin ellas puede emplearse robustez, peor caso o planificación contingente.

La verificación exige repetir o simular una misma condición y observar variación, pero nunca se reproducen exactamente todos los factores. Conviene separar incertidumbre **aleatoria**, asociada a variación irreducible del modelo, de incertidumbre **epistémica**, asociada a conocimiento insuficiente. Más datos pueden reducir la segunda, no necesariamente la primera.

Un error común es transformar una predicción más probable en transición segura. Si una ruta demora 20 minutos con probabilidad 0,6 y 45 con probabilidad 0,4, planificar siempre con 20 puede incumplir compromisos críticos. La distribución y la tolerancia al riesgo son parte de la decisión.

6.2.4. Entornos episódicos y secuenciales

En un entorno **episódico**, la experiencia se divide en episodios independientes: la acción de uno no afecta decisiones futuras. Clasificar imágenes independientes se aproxima a este caso si cada predicción no modifica datos ni usuarios. En un entorno **secuencial**, la acción actual cambia estados, información disponible u oportunidades posteriores.

La diferencia se expresa en el horizonte. Si el desempeño total es

$$J = \sum_{t=0}^H r_t,$$

una elección secuencial debe considerar efectos sobre términos futuros, no solo r_t . Asignar hoy la única cuadrilla a una tarea moderada puede impedir atender una emergencia dentro de una hora. Recomendar una ruta redistribuye tráfico y modifica demoras posteriores.

Las decisiones secuenciales introducen compromisos entre beneficio inmediato y futuro, acciones reversibles e irreversibles y valor de conservar opciones. También requieren memoria o una representación de estado suficiente. Un sistema que trata cada instante como episodio independiente puede oscilar: abrir y cerrar una válvula repetidamente porque ignora su acción anterior.

La episodicidad depende de la ventana. Una inspección aislada parece episodio, pero forma parte de un programa anual con presupuesto limitado. Antes de declarar independencia, se debe preguntar si la acción consume recursos, cambia el entorno, produce aprendizaje o afecta a otros casos.

6.2.5. Entornos estáticos y dinámicos

Un entorno es **estático** si no cambia mientras el agente delibera. Es **dinámico** si evoluciona durante ese intervalo. En un entorno **semidinámico**, el estado externo permanece, pero la medida de desempeño cambia con el tiempo, como en una prueba cronometrada.

La clasificación depende de la relación entre escalas temporales. Un problema puede considerarse estático si calcular toma milisegundos y el entorno cambia cada hora; la misma técnica deja de ser adecuada si deliberar requiere veinte minutos. La razón

$$\rho = \frac{\text{tiempo de deliberación}}{\text{escala de cambio relevante}}$$

ofrece una guía: cuanto mayor es ρ , más necesario resulta actualizar, interrumpir o actuar con una política de respaldo.

Los entornos dinámicos exigen marcas temporales, detección de datos obsoletos y ciclos de realimentación. Un plan debe incluir condiciones de invalidez: «esta ruta es válida durante cinco minutos si no se cierra el corredor». También puede ser necesario decidir mientras continúa la percepción, en vez de alternar fases rígidas de observar y actuar.

Limitación. Aumentar frecuencia no resuelve todo. Sensores más rápidos generan ruido y carga; actuadores tienen latencia; cambios excesivos producen inestabilidad. El diseño debe equilibrar capacidad de respuesta y persistencia, por ejemplo mediante histéresis o tiempos mínimos entre maniobras.

6.2.6. Entornos discretos y continuos

Un entorno es **discreto** cuando estados, percepciones, acciones o tiempo se representan mediante conjuntos contables. Es **continuo** cuando alguna dimensión

relevante toma valores en intervalos. Un tablero de ajedrez es discreto; presión, velocidad y tiempo físico son continuos.

Las dimensiones pueden mezclarse. Un agente de bombeo observa presión continua, decide entre tres modos discretos y actúa en instantes cada cinco minutos. Por eso conviene caracterizar por separado:

Dimensión	Posible representación
Estado	Nivel continuo o categorías bajo/normal/alto
Acción	Caudal continuo o encender/apagar
Tiempo	Continuo o intervalos de cinco minutos
Observación	Señal continua muestreada y cuantizada

La discretización divide un continuo en regiones. Facilita búsqueda y verificación, pero introduce error. Si los intervalos son muy amplios, estados con riesgos distintos quedan unidos; si son muy finos, explota el número de combinaciones. Los umbrales cercanos a límites pueden causar cambios abruptos por ruido.

Una discretización defendible se basa en sensibilidad de la decisión: dos valores pueden compartir categoría si conducen a acciones equivalentes y cumplen las mismas restricciones. Deben documentarse resolución, tratamiento de fronteras y pérdida máxima tolerada. No basta con elegir intervalos «porque producen una tabla manejable».

6.2.7. Entornos monoagente y multiagente

En un entorno **monoagente**, el desempeño puede analizarse sin modelar decisiones de otras entidades como agentes. En uno **multiagente**, otros actores seleccionan acciones que afectan resultados. Pueden cooperar, competir o combinar ambas relaciones.

Una roca que bloquea una ruta pertenece al entorno, pero no es agente: no persigue una finalidad. Otro conductor sí puede serlo porque adapta su conducta. En movilidad, vehículos cooperan al respetar reglas y compiten por espacio. En mercados, participantes responden estratégicamente a precios. La política óptima depende entonces de expectativas sobre los demás.

Para agentes $i = 1, \dots, n$, la transición depende de una acción conjunta $\mathbf{a} = (a^1, \dots, a^n)$ y cada uno puede tener utilidad $U_i(s, \mathbf{a})$. Si todos comparten utilidad, hay cooperación; si la ganancia de uno es pérdida de otro, aparece un caso competitivo de suma cero; la mayoría de aplicaciones no encaja por completo en ninguno.

Un reto central es la **no estacionariedad**: mientras un agente aprende, los demás también cambian, de modo que el entorno aparente deja de tener dinámica fija. Surgen además coordinación, comunicación, confianza y asignación de responsabilidad.

Error frecuente. Modelar personas como obstáculos pasivos. Usuarios y operadores interpretan recomendaciones, pueden rechazarlas y cambian de conducta ante incentivos. Ignorar esa adaptación produce políticas frágiles y, a veces, injustas.

6.2.8. Ejemplo práctico guiado: caracterización PEAS de un sistema de movilidad

Se especificará un agente que recomienda rutas a una flota de transporte a demanda. La recomendación no controla directamente a conductores ni garantiza tiempos.

Paso 1. Definir desempeño. Se propone minimizar tiempo de espera y retraso, kilómetros vacíos y emisiones, sujeto a seguridad, capacidad y cobertura mínima por zona. Se añaden percentil 90 de espera y diferencia máxima entre zonas para evitar que un buen promedio oculte servicio deficiente.

Paso 2. Completar PEAS.

PEAS	Especificación del agente de movilidad
Desempeño	Espera media y P90, puntualidad, distancia vacía, cancelaciones, emisiones, cobertura territorial, cero violaciones de seguridad
Entorno	Red vial, vehículos, conductores, pasajeros, peatones, clima, obras, semáforos, regulación y eventos
Actuadores	Recomendar ruta, proponer reasignación, ajustar hora estimada, solicitar confirmación, abstenerse
Sensores	Posición y velocidad, solicitudes, ocupación, mapa, cierres, clima, aceptación del conductor y calidad de conexión

Paso 3. Clasificar con justificación. Es parcialmente observable porque no se conocen demanda futura, intención de otros conductores ni todos los incidentes. Es estocástico: una misma ruta y salida producen demoras diferentes. Es secuencial: asignar un vehículo modifica cobertura posterior. Es dinámico porque el tráfico cambia durante el cálculo. Combina variables continuas y discretas. Es multiagente, pues conductores y pasajeros responden a recomendaciones.

Paso 4. Identificar ambigüedades. Si el agente solo informa rutas y cada conductor decide, «seguir ruta» no es un actuador directo; es una acción recomendada cuyo cumplimiento debe observarse. Si la evaluación usa tiempos finales, estos no pueden introducirse retrospectivamente como percepción inicial.

Paso 5. Derivar requisitos. La observabilidad parcial requiere estimar estado e incertidumbre. El dinamismo exige caducidad y replanificación. La secuencialidad obliga a considerar disponibilidad futura. La interacción exige modelar aceptación y evitar concentrar vehículos en la misma ruta. Las restricciones de seguridad deben imponerse antes de optimizar tiempo.

Escenario de prueba. Dos rutas tienen estimaciones: A, 15 minutos con alta variabilidad; B, 19 minutos estable. Para un traslado con compromiso crítico, recomendar A solo por menor media puede ser inadecuado. El agente debe considerar la variabilidad de la demora y el costo de llegar tarde. Si 30 vehículos

reciben A simultáneamente, la recomendación modifica el entorno; una predicción que supone tráfico constante deja de ser válida.

El ejemplo muestra que PEAS y las seis dimensiones no son etiquetas decorativas. De ellas se desprenden memoria, actualización temporal, tratamiento probabilístico, coordinación y criterios de prueba.

6.3. Arquitecturas de agentes

Una arquitectura de agente organiza la transformación de percepciones en acciones. Las categorías siguientes no son productos excluyentes: un sistema real puede combinar reacción rápida, modelo interno, planificación, utilidad y aprendizaje. La elección depende del entorno, las garantías necesarias y el costo de construir y mantener cada componente.

6.3.1. Agentes reactivos simples

Un **agente reactivo simple** selecciona una acción a partir de la percepción actual mediante reglas condición-acción:

$$a_t = g(p_t).$$

Ejemplos son «si la temperatura supera el límite, apagar» o «si hay obstáculo inmediato, detener». No mantiene un modelo explícito del pasado. Su fortaleza es la respuesta rápida, trazable y de bajo costo computacional.

```
PARA CADA regla EN reglas ordenadas
  SI regla.condición coincide con percepción actual
    devolver regla.acción
devolver acción segura por defecto
```

La prioridad entre reglas debe ser explícita. Si «continuar servicio» y «detener por seguridad» se activan juntas, la segunda debe prevalecer. También se requiere una acción por defecto para condiciones no cubiertas.

Esta arquitectura es adecuada en entornos suficientemente observables, con relaciones estables y decisiones locales. Falla cuando la misma percepción corresponde a estados distintos. Una lectura normal puede significar «todo funciona» o «el sensor quedó congelado»; sin historia no se distingue. También puede oscilar cerca de un umbral. La histéresis reduce oscilación, pero ya introduce memoria mínima.

Error frecuente. Creer que más reglas solucionan cualquier caso. Una base creciente desarrolla conflictos, huecos y combinaciones difíciles de verificar. Si la decisión depende sistemáticamente del pasado o de consecuencias futuras, corresponde cambiar de arquitectura, no acumular excepciones.

6.3.2. Agentes reactivos basados en modelos

Un **agente reactivo basado en modelos** mantiene un estado interno que resume aspectos no observados directamente. Actualiza ese estado con percepción, acción anterior y conocimiento de cómo evoluciona el entorno:

$$m_t = U(m_{t-1}, a_{t-1}, p_t), \quad a_t = g(m_t).$$

El modelo posee al menos dos partes: un **modelo de transición**, que anticipa efectos de acciones y cambios externos, y un **modelo de observación**, que relaciona estados con percepciones. El estado interno puede ser simbólico («válvula probablemente cerrada»), numérico o probabilístico.

En inspección de tuberías, una caída gradual de presión y la acción previa de aumentar bombeo permiten inferir un estado distinto al sugerido por la lectura actual sola. Si falta una lectura, el modelo proyecta temporalmente el estado, pero su incertidumbre debe crecer.

La ventaja es operar bajo observabilidad parcial sin planificar extensamente. La limitación es que una reacción sobre estado estimado sigue siendo local: no compara necesariamente secuencias de acciones. Además, un modelo incorrecto acumula error. Por ello se necesitan sincronización temporal, detección de deriva y corrección con observaciones.

Conviene registrar no solo el valor estimado, sino su confianza y procedencia. Un estado interno opaco puede parecer conocimiento cierto cuando solo extrapola datos antiguos.

6.3.3. Agentes orientados a objetivos

Un **agente orientado a objetivos** selecciona acciones considerando estados deseados. Además de estimar el estado actual, pregunta qué secuencia puede alcanzar una condición objetivo G . Si $Goal(s)$ indica que s satisface el objetivo, el agente busca una sucesión:

$$s_0 \xrightarrow{a_0} s_1 \xrightarrow{a_1} \dots \xrightarrow{a_{k-1}} s_k, \quad Goal(s_k) = verdadero.$$

Esta arquitectura separa «qué se quiere» de «cómo lograrlo». Puede adaptarse a objetivos nuevos sin reescribir todas las reglas. En logística, el objetivo puede ser que tareas urgentes queden asignadas y todos los recursos regresen dentro del horario.

Sin embargo, alcanzar un objetivo no distingue caminos. Dos planes pueden ser factibles, pero uno consumir diez veces más recursos. Tampoco resuelve por sí solo objetivos incompatibles. «Llegar» y «llegar con seguridad» deben expresarse mediante restricciones y costos, no confiar en que el planificador los infiera.

La planificación requiere un modelo de acciones y puede ser costosa. En entornos dinámicos se combina con reacción: un plan proporciona dirección global y reglas de seguridad responden a eventos inmediatos. El capítulo 7 desarrollará algoritmos para explorar estos espacios y comparar estrategias de búsqueda.

6.3.4. Agentes basados en utilidad

Un **agente basado en utilidad** asigna valor a consecuencias y elige entre alternativas que alcanzan objetivos con diferente calidad. Una función $U(s)$ representa preferencia sobre estados; bajo incertidumbre se maximiza utilidad esperada:

$$a^* = \arg \max_a \sum_{s'} P(s' | s, a) U(s').$$

La utilidad permite intercambios entre tiempo, costo, riesgo y calidad. No es necesariamente dinero ni una medida objetiva. Debe reflejar preferencias coherentes de las partes responsables. Si hay múltiples criterios normalizados x_j , puede usarse provisionalmente:

$$U(s) = \sum_{j=1}^m w_j u_j(x_j(s)),$$

pero una suma ponderada admite compensaciones. Una gran mejora en tiempo podría compensar matemáticamente una violación de seguridad; por ello las restricciones duras se aplican fuera de la utilidad.

La forma de u_j expresa actitud ante riesgo y rendimientos decrecientes. Los pesos no deben escogerse solo por conveniencia: requieren consulta, análisis de sensibilidad y documentación. Si pequeños cambios alteran la acción, la decisión es frágil.

Los agentes de utilidad son apropiados con incertidumbre y objetivos graduados, pero plantean riesgos normativos. Agregar bienestar puede ocultar distribución: mejorar mucho a un grupo y empeorar poco a muchos quizá produzca igual suma. Se necesitan métricas de equidad, límites y mecanismos de impugnación.

6.3.5. Agentes que aprenden

Un **agente que aprende** modifica algún componente de su conducta a partir de experiencia. Puede aprender el modelo de observación, la transición, reglas, función de evaluación o política. Aprender no constituye una arquitectura completa por sí solo: especifica cómo cambia el agente.

Sea θ_t el conjunto de parámetros o conocimiento. Una actualización general es:

$$\theta_{t+1} = L(\theta_t, \text{experiencia}_t, \text{retroalimentación}_t).$$

La experiencia puede ser supervisada, cuando existe una respuesta de referencia; no supervisada, cuando se descubren estructuras; o basada en recompensas, cuando las consecuencias llegan después de actuar. Este último caso se estudiará en el capítulo 8.

Aprender aporta adaptación a condiciones locales y cambios difíciles de codificar. No garantiza mejora: datos sesgados, objetivos mal definidos o retroalimentación tardía pueden degradar conducta. La distribución cambia además porque las acciones del agente alteran qué datos se observan. Si solo se inspeccionan zonas que el modelo marca como riesgosas, faltará evidencia sobre las demás.

La operación segura exige separar entrenamiento y evaluación, comparar con una línea base, detectar deriva, conservar versiones y permitir reversión controlada. En ámbitos críticos, el aprendizaje puede proponer ajustes mientras reglas verificadas limitan acciones. Autonomía no significa actualización irrestricta en producción.

6.3.6. Componentes de aprendizaje, crítica y exploración

Una descomposición clásica incluye cuatro componentes:

- el **elemento de desempeño** selecciona acciones con el conocimiento actual;
- el **elemento de aprendizaje** modifica ese conocimiento;
- el **crítico** compara resultados con la medida de desempeño y produce retroalimentación;
- el **generador de problemas** propone acciones exploratorias que aportan información.

El crítico no es simplemente el entorno. El entorno produce consecuencias; el crítico las interpreta según objetivos. Una demora de cinco minutos puede ser aceptable o grave según contexto. Si la señal del crítico premia una aproximación incorrecta, el aprendizaje optimizará el sustituto.

La **exploración** sacrifica potencialmente desempeño inmediato para conocer alternativas; la **explotación** usa la mejor alternativa conocida. Explorar sin límites puede causar daño; no explorar consolida errores y desconoce cambios. Se puede restringir exploración a simulación, rangos seguros, periodos de baja demanda o acciones reversibles.

Componente	Pregunta de auditoría	Falla típica
Desempeño	¿Cómo se elige la acción ahora?	Política no alineada con restricciones
Aprendizaje	¿Qué se actualiza y con qué datos?	Aprender correlaciones espurias
Crítico	¿Quién define éxito y cuándo se observa?	Recompensa incompleta o tardía
Exploración	¿Qué incertidumbre intenta reducir?	Riesgo injustificado o exploración inútil

La retroalimentación puede estar demorada y confundida: tras cambiar una ruta, clima y demanda también cambian. Atribuir todo resultado a la acción genera aprendizaje causal incorrecto. Deben registrarse contexto, política activa y probabilidad con que se eligió la acción.

6.3.7. Ejemplo práctico guiado: comparación de arquitecturas

Se comparan cinco versiones de un agente que recomienda mantenimiento para aerogeneradores. Todas reciben vibración, temperatura de rodamientos, potencia producida, velocidad del viento, alarmas del controlador, historial de intervenciones y disponibilidad de técnicos. La acción puede ser continuar vigilancia, solicitar una prueba, programar mantenimiento o recomendar una parada segura.

Versión A, reactiva simple. Aplica reglas a la percepción actual: si la vibración supera un umbral, eleva la prioridad; si alcanza un límite de seguridad, recomienda parada. Responde con poca latencia y sus reglas son fáciles de auditar, pero no distingue un sensor defectuoso de un deterioro real ni integra señales débiles acumuladas.

Versión B, basada en modelo. Mantiene un estado interno con tendencia de vibración, régimen de operación, calidad de sensores, intervenciones recientes

y condición probable de componentes. Puede explicar una temperatura elevada por carga y ambiente, o considerar más preocupante una anomalía persistente en condiciones comparables. Tolera observación parcial, aunque introduce errores si el modelo de degradación está mal especificado.

Versión C, orientada a objetivos. Planifica acciones para alcanzar estados verificables, por ejemplo, diagnosticar todos los equipos de riesgo alto y completar el mantenimiento obligatorio antes de una fecha. Puede ordenar pruebas, ventanas de parada e intervenciones según precedencias y recursos. Satisface metas, pero dos planes que llegan al mismo objetivo parecen equivalentes si la representación no incorpora sus consecuencias económicas y operativas.

Versión D, basada en utilidad. Compara resultados graduados mediante su utilidad esperada. Pondera riesgo de falla, energía no producida, costo de movilización, demora y oportunidad de agrupar intervenciones, bajo restricciones no negociables de seguridad. Permite elegir entre mantenimiento inmediato y una prueba informativa, pero requiere probabilidades calibradas y acuerdos explícitos sobre intercambios entre criterios.

Versión E, con aprendizaje. Ajusta estimadores de degradación o políticas de prioridad usando inspecciones, reemplazos y fallas observadas. Puede reconocer patrones específicos de un modelo de aerogenerador y adaptarse al envejecimiento. Su calidad depende de etiquetas, cobertura y retroalimentación: si solo se inspeccionan los casos previamente priorizados, el conjunto de aprendizaje queda sesgado. Debe compararse con una línea base, vigilar deriva y conservar límites de seguridad no aprendidos.

Criterio	Reactiva	Basada en modelo	Orientada a objetivos	Basada en utilidad	Con aprendizaje
Respuesta inmediata	Alta	Alta	Media	Media	Depende de la política
Manejo de observación parcial	Bajo	Alto	Depende del estado	Alto si se modela	Alto con datos representativos
Planificación temporal	Nula	Baja	Alta	Alta	Depende del elemento de desempeño
Comparación de costos y riesgos	Implícita	Limitada	Limitada	Explícita	Aprendida o combinada
Adaptación a cambios	Baja	Media	Media	Media	Alta con control
Facilidad de auditoría	Alta	Media/alta	Media	Media	Variable

Prueba guiada. El aerogenerador A presenta un pico extremo de vibración, pero el sensor informa baja confiabilidad y las variables restantes son normales. El B muestra un aumento moderado y sostenido de vibración y temperatura bajo cargas comparables, con una ventana de bajo viento prevista para el día siguiente. El agente reactivo prioriza A por umbral. El basado en modelo reduce la certeza sobre A y eleva el riesgo estimado de B. El orientado a objetivos programa una prueba inmediata de A y reserva la ventana para diagnosticar B. El basado en utilidad compara el valor de la información, el riesgo de esperar y la pérdida de producción. El agente con aprendizaje puede refinar la probabilidad de degradación de B a partir de casos históricos semejantes, sin sobrepasar las reglas de seguridad.

Conclusión de diseño. Ninguna arquitectura domina en todos los criterios. Una solución híbrida puede usar reglas verificadas para protección inmediata, un modelo para mantener creencias sobre componentes, objetivos para construir el plan, utilidad para ordenar alternativas y aprendizaje para actualizar estimaciones. Cada capa debe aportar una mejora medible: añadir complejidad sin pruebas, trazabilidad ni datos adecuados solo agrega modos de falla.

6.4. Representación computacional de problemas

Diseñar un agente requiere transformar una situación abierta en una representación sobre la que sea posible razonar. Una formulación clásica de problema es:

$$\mathcal{P} = (S, A, T, s_0, G, C, R),$$

donde S es el espacio de estados, A las acciones, T el modelo de transición, s_0 el estado inicial, G la condición objetivo, C los costos y R las restricciones. Esta tupla no es la realidad: es un instrumento. Su validez depende de conservar las distinciones que cambian decisiones.

6.4.1. Estados y variables de estado

Un **estado** reúne la información necesaria para predecir las consecuencias relevantes de acciones futuras y evaluar objetivos. Las **variables de estado** son sus componentes. Si $X_1, \dots, X_n$ tienen dominios $D_1, \dots, D_n$, entonces:

$$s = (x_1, \dots, x_n) \in S \subseteq D_1 \times \dots \times D_n.$$

En asignación de cuadrillas, un estado puede incluir tareas pendientes, ubicación y disponibilidad de cada cuadrilla, tiempo actual y presupuesto restante. No necesita contener color de los vehículos si ese dato no afecta acciones, costos ni restricciones.

Un buen estado posee **suficiencia**: dado el estado actual y una acción, el pasado no aporta información adicional relevante para la transición. Esta es una propiedad de Markov respecto del modelo:

$$P(S_{t+1} \mid S_{0:t}, A_{0:t}) = P(S_{t+1} \mid S_t, A_t).$$

Si duración futura depende de desgaste acumulado y el estado solo guarda ubicación, no es suficiente. Se debe incorporar desgaste o una estadística que lo resuma.

También se distingue **estado del mundo**, que existe aunque no se observe; **percepción**, que aporta evidencia; **estado interno**, que estima o resume; y **nodo de búsqueda**, que además puede guardar padre, acción y costo. Confundirlos causa duplicación o uso indebido de información.

El tamaño del espacio crece multiplicativamente. Diez variables con diez valores producen hasta 10^{10} estados. Deben eliminarse combinaciones imposibles mediante restricciones y escoger variables relevantes, sin omitir aquellas que cambian factibilidad o costo.

6.4.2. Acciones y modelos de transición

Una **acción** transforma potencialmente un estado. Se especifica mediante nombre, parámetros, precondiciones y efectos. Para asignar una cuadrilla q a una tarea j :

ACCIÓN asignar(q , j)

PRECONDICIONES:

q está disponible

j está pendiente

q posee habilidades requeridas por j

el desplazamiento permite cumplir la ventana temporal

EFFECTOS:

j pasa a asignada

q pasa a ocupada y cambia su destino

se actualizan tiempo y presupuesto estimados

Las precondiciones determinan $A(s)$, acciones aplicables en s . Los efectos definen una transición determinista $T(s, a) = s'$ o una distribución $T(s' | s, a)$. En dominios inciertos, «inspeccionar» puede confirmar falla, descartar alerta o resultar inconcluso.

Debe distinguirse acción de evento exógeno. El agente asigna una cuadrilla; la lluvia o una nueva emergencia ocurren fuera de su control. Ambos cambian estado, pero atribuir eventos al agente distorsiona responsabilidad y planificación.

La transición debe conservar **invariantes**, propiedades verdaderas en todo estado legal: una cuadrilla no ocupa dos lugares simultáneamente; el presupuesto no es negativo; una tarea terminada no está pendiente. Las pruebas de modelo comprueban que toda acción aplicable produzca estados legales y que sus efectos correspondan al dominio.

Error frecuente. Especificar efectos favorables e ignorar efectos secundarios. Asignar consume tiempo, combustible y oportunidad. Si no se representan, el algoritmo puede reutilizar recursos ilimitadamente.

6.4.3. Estado inicial y estados objetivo

El **estado inicial** s_0 describe desde dónde comienza la resolución. Debe corresponder al instante de decisión y distinguir datos desconocidos. Si hay incertidumbre inicial, puede usarse un conjunto S_0 o una distribución $b_0(s)$, en vez de inventar valores.

Un **estado objetivo** satisface una prueba $Goal(s)$. Habitualmente hay un conjunto:

$$G = \{s \in S : Goal(s) = verdadero\}.$$

En asignación, «todas las tareas críticas cubiertas, ninguna restricción violada y cuadrillas dentro del turno» es condición; no exige una asignación única. Separar condición de un estado concreto permite descubrir soluciones alternativas.

Los objetivos pueden ser de logro («entregar suministro»), mantenimiento («presión siempre en rango») o evitación («nunca exceder capacidad»). Los de mantenimiento no se reducen fácilmente a alcanzar un estado final; se evalúan sobre trayectorias. También puede haber metas parciales y plazos.

Una formulación debe responder:

- ¿el estado inicial es legal y está fechado?;
- ¿el objetivo puede verificarse con variables representadas?;
- ¿existe al menos una solución en casos normales?;
- ¿qué ocurre si el objetivo es inalcanzable?;
- ¿terminar pronto tiene valor o solo importa llegar?;

Confundir objetivo con método restringe innecesariamente. «Usar la cuadrilla Q1» no es objetivo salvo que exista una razón de dominio; «resolver la tarea con personal habilitado» deja al algoritmo elegir.

6.4.4. Costos, restricciones y utilidad

El **costo de acción** $c(s, a, s')$ cuantifica recursos o consecuencias negativas. El costo de una trayectoria $\pi = (s_0, a_0, \dots, s_k)$ suele ser aditivo:

$$C(\pi) = \sum_{t=0}^{k-1} c(s_t, a_t, s_{t+1}).$$

Puede representar tiempo, distancia, dinero o riesgo esperado. La aditividad es un supuesto: fatiga o descuentos por volumen pueden depender de la trayectoria completa y exigir ampliar el estado o usar otra función.

Una **restricción** define qué estados, acciones o trayectorias son admisibles. Las restricciones duras no pueden violarse; las blandas admiten incumplimiento penalizado. Declarar una condición legal como «costo muy alto» es peligroso: si otras ganancias son mayores, el optimizador la violará.

La **utilidad** expresa preferencia por consecuencias, incluida incertidumbre. Costos y utilidad se relacionan, pero no son idénticos. Minimizar costo puede equivaler a maximizar $-C$ en un caso simple; utilidad permite no linealidad, riesgo y valor de resultados. En problemas deterministas de alcance, costo suele bastar. En decisiones inciertas, la utilidad esperada es más adecuada.

Concepto	Función	Ejemplo
Restricción dura	Excluir alternativas	Solo personal certificado atiende alta tensión

Concepto	Función	Ejemplo
Restricción blanda	Desalentar, pero permitir	Preferir equilibrio de carga
Costo	Comparar consumo acumulado	Kilómetros y horas extra
Utilidad	Valorar consecuencias y riesgo	Beneficio de reducir daño crítico

Las magnitudes deben compartir escala si se agregan. Los pesos requieren análisis de sensibilidad. Una precisión aparente como 0,37 para «equidad» no sustituye la discusión sobre su significado.

6.4.5. Nivel de abstracción

La **abstracción** conserva rasgos relevantes y omite detalles. Un mapa de rutas representa conexiones y costos, no cada centímetro del pavimento. Sin abstracción, el problema puede ser intratable; con demasiada, la solución puede ser imposible o insegura en el mundo real.

Una abstracción es adecuada para una decisión si estados considerados equivalentes admiten acciones equivalentes y consecuencias relevantes comparables. Si dos cuadrillas se agrupan como «disponibles» pero solo una posee certificación, la abstracción elimina una restricción decisiva.

Se puede trabajar en niveles:

1. estratégico: cuántos recursos reservar por zona;
2. táctico: qué cuadrilla asignar a cada tarea;
3. operativo: ruta exacta y secuencia de maniobras.

La planificación jerárquica resuelve primero decisiones gruesas y refina después. Cada nivel debe declarar interfaces: una asignación táctica debe ser realizable en el nivel operativo.

Para validar la abstracción se toman soluciones abstractas y se intenta ejecutarlas o refinarlas en casos representativos y extremos. Si muchas fallan por detalles omitidos, el nivel no es adecuado. También se compara sensibilidad: incorporar una variable supuestamente irrelevante no debería cambiar decisiones de manera sistemática.

Tensión fundamental. Agregar detalle aumenta fidelidad y costo; eliminarlo mejora tractabilidad y puede introducir sesgo. No existe representación «completa». La pregunta correcta es si es suficiente para el propósito, horizonte y riesgo.

6.4.6. Introducción a la representación del conocimiento

La representación de problemas describe configuraciones y transformaciones; la **representación del conocimiento** organiza hechos, conceptos, relaciones y reglas que permiten inferir información no explícita. Un agente necesita saber no solo dónde está, sino qué significa una entidad, qué propiedades hereda y qué condiciones se cumplen.

Formas frecuentes incluyen:

- **lógica proposicional:** hechos verdaderos o falsos, como *Sensor Activo*;
- **lógica de predicados:** objetos y relaciones, como *habilitado(q, t)*;
- **reglas de producción:** «si condición, entonces conclusión o acción»;
- **grafos semánticos y ontologías:** conceptos, relaciones y jerarquías;
- **representaciones probabilísticas:** creencias inciertas y dependencias;
- **vectores distribuidos:** similitud aprendida, con semántica menos explícita.

Una base de conocimiento puede contener:

$$\text{Certificado}(q, \text{agua}) \wedge \text{Requiere}(t, \text{agua}) \Rightarrow \text{Elegible}(q, t).$$

La inferencia deriva $\text{Elegible}(q, t)$ si se conocen ambas premisas. Debe distinguirse **mundo cerrado**, donde lo no registrado se asume falso, de **mundo abierto**, donde permanece desconocido. En seguridad, no encontrar una certificación no equivale a confirmar que no exista; pero tampoco autoriza a actuar. La política debe tratar explícitamente el desconocimiento.

Los criterios de calidad son expresividad, consistencia, eficiencia inferencial, explicabilidad y facilidad de actualización. Mayor expresividad puede hacer más costosa la inferencia. Las ontologías requieren gobernanza de términos; las reglas pueden entrar en conflicto; las representaciones aprendidas pueden reproducir sesgos y dificultar explicación.

Esta introducción no pretende cubrir todo el campo. Su propósito es mostrar que formular estados y acciones presupone vocabulario, relaciones y supuestos. Una mala semántica no se corrige con un algoritmo de búsqueda más potente.

6.4.7. Ejemplo práctico guiado: formulación de un problema de asignación de recursos

Un centro de datos debe asignar tres técnicos a cuatro intervenciones durante un turno. Las competencias relevantes son redes, energía y refrigeración. Cada intervención tiene duración, ubicación interna, ventana temporal, prioridad y habilidades requeridas; cada técnico posee competencias, certificaciones, horario y costo. Se busca completar las intervenciones críticas y minimizar demora, desplazamiento interno y horas extra sin vulnerar reglas de seguridad.

Paso 1. Declarar alcance y abstracción. El horizonte es un turno de ocho horas. Se decide quién atiende cada intervención y en qué orden, pero no se representan movimientos dentro de una sala ni pasos detallados del procedimiento técnico. Las duraciones se tratan inicialmente como deterministas. Esta abstracción es válida solo si la variabilidad no altera de forma sistemática la factibilidad de la agenda.

Paso 2. Definir variables. Sea $x_{ijt} = 1$ si el técnico i inicia la intervención j en el bloque temporal t , y 0 en otro caso. Para una formulación como búsqueda, un estado puede expresarse como:

$$s = (t, \text{pendientes}, \text{estado}_T, \text{ubicación}_T, \text{liberación}_T, \text{presupuesto}),$$

donde estado_T indica si cada técnico está disponible u ocupado y liberación_T conserva cuándo terminará su trabajo actual. La ubicación permite calcular el tiempo de acceso entre salas; omitir la liberación impediría decidir correctamente acciones posteriores.

Paso 3. Estado inicial y conocimiento. A las 08:00 los tres técnicos están disponibles, las cuatro intervenciones están pendientes y el presupuesto permanece completo. La base de conocimiento registra Posee(técnico, habilidad), Certificado(técnico, intervención) y Requiere(intervención, habilidad). Una competencia o certificación no registrada se considera desconocida y bloquea la asignación hasta su verificación; no se presume habilitación por ausencia de datos.

Paso 4. Acciones y transición. Las acciones son asignar(técnico, intervención, inicio), asignar_equipo(par, intervención, inicio), esperar(hasta) y solicitar_dato(elemento). Asignar exige disponibilidad, habilidades, certificación, acceso autorizado, tiempo suficiente y presupuesto. La transición ocupa al técnico durante la duración prevista, actualiza su futura ubicación, retira la intervención de pendientes al completarse y descuenta el costo. Una intervención que exige dos personas produce una transición conjunta, no dos decisiones independientes.

Paso 5. Formular restricciones duras. Sea n_j la cantidad de técnicos exigida por la intervención j , igual a dos para un trabajo en pareja y a uno en los demás casos. La cobertura válida requiere:

$$\sum_i \sum_t x_{ijt} = n_j.$$

Si $r_{jk} = 1$ indica que j requiere la habilidad k y $h_{ik} = 1$ que i la posee, entonces $x_{ijt} \leq h_{ik}$ para toda habilidad que deba poseer cada participante. En trabajos donde las competencias puedan complementarse, se exige $\sum_i h_{ik} x_{ijt} \geq r_{jk}$ para cada k . Además, un técnico no puede atender intervenciones solapadas; los participantes de un trabajo en pareja deben iniciar juntos y permanecer disponibles durante todo el intervalo. También se respetan ventanas, precedencias, descansos, certificaciones, aforo de sala y presupuesto. Estas condiciones no se sustituyen por penalizaciones, porque una solución barata pero insegura sigue siendo inadmisible.

Paso 6. Definir objetivo y costo. Primero se exige que todas las intervenciones críticas queden terminadas dentro de su ventana. Entre soluciones factibles se minimiza:

$$C = \sum_j (3D_j + 1,5M_j + 4H_j + 2R_j),$$

donde D_j es demora normalizada, M_j tiempo de desplazamiento interno, H_j horas extra y R_j costo de reasignar o interrumpir trabajo planificado. También puede añadirse el costo laboral específico de cada técnico. La prioridad crítica actúa como restricción temporal cuando existe un límite operativo, no solo como coeficiente alto.

Paso 7. Construir una instancia pequeña.

Intervención	Prioridad	Duración	Habilidad requerida	Condición	Límite
I1: reemplazo de conmutador	Crítica	1 h	Redes	Una persona	10:00
I2: revisión de UPS	Crítica	2 h	Energía	Dos personas; una certificada	13:00
I3: diagnóstico de unidad térmica	Alta	2 h	Refrigeración	Una persona	16:00
I4: verificación de enlaces y sensores	Media	1 h	Redes y refrigeración	Una persona con ambas	17:00

T1 posee redes y refrigeración; T2 posee energía y la certificación de UPS; T3 posee energía y refrigeración. Asignar temprano I3 a T3 y ocupar T1 en I4 puede dejar a T2 sin acompañante para I2 antes de las 13:00. Una solución candidata asigna I1 a T1 de 08:00 a 09:00, I2 a T2 y T3 de 09:00 a 11:00, I3 a T3 de 11:00 a 13:00 e I4 a T1 posteriormente. La secuencia conserva la competencia escasa de energía conjunta para la intervención crítica.

Paso 8. Validar la formulación. Tras cada transición se comprueban invariantes: nadie aparece en dos lugares a la vez, toda habilidad requerida está cubierta, las tareas en pareja comparten intervalo, el presupuesto no es negativo y ninguna intervención completada reaparece como pendiente. Se prueban ausencia de T2, demora de I1, llegada de una alarma crítica y una certificación desconocida. Si el modelo declara factible una agenda que viola acceso, simultaneidad o tiempos de traslado, falta una variable o restricción.

Paso 9. Reconocer límites. Las duraciones pueden variar, pueden surgir incidentes y la competencia nominal no refleja toda la experiencia. La formulación es apropiada como punto de partida para búsqueda y optimización; la operación real requerirá replanificación ante eventos y conservación del historial de decisiones. En el capítulo 7, los estados podrán tratarse como nodos y las asignaciones como aristas; en el capítulo 8, la incertidumbre y los costos esperados permitirán comparar políticas de reasignación.

Síntesis integradora

Un agente se define por el ciclo entre percepción y acción, pero su inteligencia solo puede evaluarse respecto de una tarea. La función de agente especifica conducta idealizada; el programa la implementa bajo límites. La racionalidad maximiza desempeño esperado con información disponible y no exige acertar

siempre. La autonomía indica cuánto se apoya el agente en experiencia propia, mientras que la omnisciencia es una referencia imposible.

PEAS obliga a comenzar por consecuencias y a conectar entorno, actuadores y sensores. Las dimensiones del entorno no son etiquetas absolutas: dependen de frontera, abstracción y escala temporal. De ellas se derivan requisitos arquitectónicos. Reglas simples son valiosas cuando bastan; modelos internos ayudan con observación parcial; objetivos permiten planificar; utilidad compara resultados graduados; aprendizaje adapta el comportamiento, pero añade riesgos de retroalimentación y deriva.

Representar un problema es decidir qué diferencias importan. Estados suficientes, acciones ejecutables, transiciones plausibles, objetivos verificables, restricciones explícitas y costos alineados forman el puente entre una necesidad real y un algoritmo. Una representación demasiado pobre produce soluciones inválidas; una excesiva puede impedir calcular. La calidad se demuestra mediante invariantes, escenarios adversos, sensibilidad y posibilidad de traducir la solución al mundo real.

Errores comunes y criterios de revisión

Error	Consecuencia	Pregunta correctiva
Confundir predicción con acción	No se define responsabilidad ni efecto	¿Quién decide y quién ejecuta?
Medir actividad en vez de resultado	El agente optimiza un indicador vacío	¿Qué mejora realmente en el entorno?
Evaluar con información futura	Se sobreestima racionalidad y desempeño	¿Estaba ese dato disponible al decidir?
Suponer observabilidad por tener muchos datos	Se oculta incertidumbre relevante	¿Qué estados distintos generan la misma percepción?
Tratar una transición probable como segura	Planes frágiles ante variabilidad	¿Qué otros resultados son plausibles y costosos?
Optimizar cada instante por separado	Se consumen opciones y recursos futuros	¿Cómo cambia esta acción decisiones posteriores?
Penalizar en vez de prohibir una ilegalidad	El optimizador puede aceptar la violación	¿Es preferencia o condición no negociable?
Omitir efectos secundarios	Se reutilizan recursos o se ignora desgaste	¿Qué cambia además del efecto principal?
Añadir reglas sin revisar arquitectura	Conflictos y huecos difíciles de auditar	¿La decisión requiere memoria o planificación?
Aprender sin un crítico válido	Se perfecciona un objetivo sustituto	¿La retroalimentación representa el resultado?

Glosario

- **Acción:** decisión disponible para un agente que puede modificar el entorno.
- **Actuador:** mecanismo físico o lógico que intenta ejecutar una acción.
- **Agente:** entidad que percibe un entorno y selecciona acciones sobre él.
- **Arquitectura:** soporte de cómputo, memoria, comunicación, sensores y actuadores donde opera el programa.
- **Autonomía:** grado en que la conducta depende de experiencia propia y no solo de conocimiento inicial.
- **Costo:** valoración de recursos o consecuencias negativas de una acción o trayectoria.
- **Crítico:** componente que convierte resultados observados en retroalimentación respecto del desempeño.
- **Entorno de tarea:** ámbito externo, actores y condiciones relevantes para evaluar y operar el agente.
- **Estado:** resumen de información suficiente para razonar sobre transiciones, objetivos y costos.
- **Estado de creencia:** distribución o conjunto que representa incertidumbre sobre el estado real.
- **Exploración:** selección de acciones para obtener información sobre alternativas inciertas.
- **Función de agente:** correspondencia abstracta entre secuencias de percepciones y acciones.
- **Medida de desempeño:** criterio que evalúa consecuencias de la conducta del agente.
- **Modelo de observación:** relación entre estados del entorno y percepciones posibles.
- **Modelo de transición:** descripción de cómo cambian los estados por acciones y eventos.
- **Objetivo:** condición sobre estados o trayectorias que define un resultado deseado.
- **Omnisciencia:** conocimiento perfecto del estado, consecuencias y futuro; no es requisito de racionalidad.
- **PEAS:** descripción mediante desempeño, entorno, actuadores y sensores.
- **Percepción:** contenido informativo recibido por el agente en un instante.
- **Política:** regla que selecciona acciones a partir del estado, creencia o historia disponible.
- **Programa de agente:** procedimiento concreto que implementa una función de agente.
- **Racionalidad:** elección que maximiza desempeño esperado dadas información, alternativas y recursos.
- **Restricción:** condición que limita estados, acciones o trayectorias admisibles.
- **Sensor:** mecanismo físico o lógico que adquiere información del entorno.
- **Utilidad:** representación numérica de preferencias sobre consecuencias.

Preguntas de autoevaluación

1. ¿Por qué un modelo que predice fallas no es necesariamente un agente? Identifique qué componentes faltarían.
2. Distinga percepción, sensor, acción y actuador mediante un ejemplo diferente

- de agua o movilidad.
3. ¿Por qué la función de agente tiene como entrada una secuencia y no solo la percepción actual?
 4. Formule una medida de desempeño para un agente de turnos médicos e identifique una métrica susceptible de manipulación.
 5. Una intervención racional produce un mal resultado. ¿Qué información se necesita para auditar la decisión sin sesgo retrospectivo?
 6. Explique por qué autonomía y ausencia de supervisión no son equivalentes.
 7. Construya un PEAS para un agente que administra consumo energético de un edificio.
 8. ¿Puede un entorno ser observable y estocástico? Proponga un ejemplo y justifique ambas propiedades.
 9. ¿Cómo puede un problema episódico convertirse en secuencial al ampliar el horizonte?
 10. Compare los requisitos temporales de un entorno estático y uno dinámico.
 11. ¿Qué se pierde al discretizar una variable continua? ¿Cómo validaría los intervalos?
 12. Explique por qué un entorno con personas suele requerir una perspectiva multiagente.
 13. ¿Cuándo elegiría un agente reactivo simple en lugar de uno basado en utilidad?
 14. Distinga elemento de aprendizaje, crítico y generador de problemas.
 15. ¿Qué significa que una representación de estado sea suficiente o markoviana?
 16. Redacte precondiciones y efectos para la acción «reservar recurso».
 17. ¿Por qué una restricción legal no debería representarse solo como costo elevado?
 18. Dé un ejemplo de abstracción excesiva que convierta una solución computacional en una acción inviable.
 19. Compare mundo abierto y mundo cerrado ante un dato de certificación ausente.
 20. En el ejemplo de asignación, ¿qué cambios requeriría representar tiempos de viaje estocásticos?

Actividad integradora de cierre

Diseño y defensa de un agente para respuesta operativa. Seleccione un dominio con impacto real, como gestión de residuos, mantenimiento de infraestructura, apoyo a emergencias o distribución de insumos. Elabore una especificación que pueda ser revisada por una persona técnica y por una responsable del dominio.

El producto debe incluir:

1. frontera del agente, actores y autoridad efectiva;
2. tabla PEAS con unidades, calidad de sensores y límites de actuadores;
3. clasificación razonada del entorno en las seis dimensiones estudiadas;
4. medida de desempeño con horizonte, restricciones y al menos un riesgo de desalineación;
5. comparación de dos arquitecturas y elección justificada;
6. formulación $\mathcal{P} = (S, A, T, s_0, G, C, R)$ con una instancia pequeña;
7. pseudocódigo de una decisión central y acción segura por defecto;
8. tres escenarios de prueba: normal, información faltante y evento adverso;

9. análisis de una variable omitida y de cómo podría invalidar la solución;
10. transición técnica hacia el capítulo 7 o el 8.

La defensa debe responder cuatro preguntas: ¿qué sabe realmente el agente?, ¿qué no sabe?, ¿qué puede ejecutar sin intervención? y ¿quién asume el costo de sus errores? Se valorará la coherencia entre PEAS, arquitectura y representación más que la complejidad del método.

Para enlazar con el **capítulo 7**, convierta la instancia en un grafo: cada estado será un nodo, cada acción aplicable una arista y cada costo una etiqueta. Anticipe si habrá ciclos, estados repetidos y qué información podría servir como heurística. Para enlazar con el **capítulo 8**, identifique al menos una transición incierta, una decisión que se repite y una consecuencia futura. Explique qué tendría que añadirse para definir una política bajo incertidumbre y cómo evitaría que el aprendizaje explore acciones inseguras.

Capítulo 7. Búsqueda y resolución algorítmica de problemas

Buscar es convertir una pregunta del tipo «¿qué secuencia de decisiones conduce desde esta situación hasta una situación aceptable?» en un procedimiento sistemático. Un planificador de recorridos, un rompecabezas, una asignación de turnos y una secuencia de inspecciones parecen problemas distintos; sin embargo, todos pueden describirse mediante estados, acciones, objetivos y costos. La representación establece qué soluciones existen. La estrategia de búsqueda establece cuáles se examinan primero y qué recursos se consumen para encontrarlas.

Este capítulo estudia problemas deliberativos, estáticos y conocidos durante la búsqueda. En ese marco, una acción tiene un resultado determinado y el algoritmo puede evaluar si alcanzó el objetivo. La incertidumbre, el cambio del entorno y las decisiones repetidas se abordarán en capítulos posteriores. Esta separación es importante: una ruta óptima en un modelo fijo no es necesariamente la mejor decisión cuando los tiempos cambian o se desconocen.

Al finalizar el capítulo, se espera que el lector pueda:

- formular un problema mediante un espacio de estados y distinguir estado, nodo y camino;
- implementar conceptualmente una búsqueda con frontera y conjunto explorado;
- seleccionar entre búsqueda en anchura, profundidad, profundidad limitada, profundización iterativa y costo uniforme;
- razonar sobre completitud, optimalidad, tiempo y memoria bajo supuestos explícitos;
- diseñar y evaluar heurísticas para búsqueda voraz y A*;
- reconocer cuándo conviene una búsqueda local o una formulación como problema de satisfacción de restricciones;
- interpretar correctamente un grafo de movilidad construido con pares origen-destino observados.

La exposición emplea pseudocódigo independiente del lenguaje. Una operación como INSERTAR no prescribe una biblioteca ni una estructura concreta: expresa el comportamiento que debe conservar cualquier implementación.

7.1. Espacios de estados y procesos de búsqueda

Un **problema de búsqueda** puede representarse formalmente como

$$P = (S, A, T, s_0, G, c),$$

donde S es el conjunto de estados; $A(s)$, las acciones aplicables en s ; $T(s, a)$, el estado resultante; s_0 , el estado inicial; $G(s)$, un predicado que reconoce objetivos; y $c(s, a, s')$, el costo de pasar de s a s' . Una solución es una secuencia de acciones aplicables que lleva desde s_0 hasta algún estado que satisface G . Su costo es la suma de los costos de sus transiciones.

Esta definición no obliga a enumerar S . En problemas reales, el espacio suele describirse de manera implícita mediante una función sucesora. La búsqueda genera solo la parte necesaria. Antes de elegir un algoritmo, por tanto, hay que decidir qué información integra un estado, qué acciones son legales y cuándo dos descripciones representan la misma situación.

7.1.1. Árboles y grafos

Un **grafo** es un par $G = (V, E)$, con un conjunto de vértices V y un conjunto de aristas E . En un grafo dirigido, cada arista es un par ordenado (u, v) : poder avanzar de u a v no implica poder volver de v a u . En un grafo no dirigido, una arista expresa una relación simétrica. Si a cada arista se le asocia un valor $w(u, v)$, se obtiene un grafo ponderado. El peso puede representar distancia, tiempo, dinero, riesgo o una combinación cuyo significado debe declararse.

Un **árbol** es un grafo conectado y sin ciclos. Si se elige una raíz, cada nodo salvo la raíz tiene un único padre y existe un único camino simple desde la raíz hasta cualquier nodo. El árbol es útil para visualizar el proceso de búsqueda, pero el dominio subyacente puede ser un grafo. Esta distinción evita una confusión frecuente:

- el **grafo de estados** contiene una vez cada estado y todas las transiciones legales;
- el **árbol de búsqueda** contiene las distintas maneras en que el algoritmo llega a estados, por lo que un mismo estado puede aparecer en varios nodos.

Considérese un espacio con transiciones $A \rightarrow B$, $A \rightarrow C$, $B \rightarrow D$, $C \rightarrow D$ y $D \rightarrow A$. El grafo tiene cuatro estados. El árbol de búsqueda puede incluir un nodo para D alcanzado por A, B, D , otro para D alcanzado por A, C, D y, si no se controlan ciclos, infinitas ramas como $A, B, D, A, B, D, \dots$. El dominio es finito, pero el árbol generado no tiene por qué serlo.

No todo grafo almacenado corresponde a un espacio de estados completo. Una tabla de conexiones observadas puede omitir transiciones posibles; un mapa agregado puede unir zonas sin describir el trayecto interior. Las propiedades del algoritmo se refieren al modelo proporcionado, no a una realidad que el modelo no representa.

7.1.2. Nodos, estados y caminos

Un **estado** describe una configuración relevante del problema. Un **nodo de búsqueda** es un registro creado por el algoritmo. Habitualmente contiene:

$n = (\text{estado}, \text{padre}, \text{acción}, g, \text{profundidad}),$

donde $g(n)$ es el costo acumulado desde la raíz. Dos nodos pueden contener el mismo estado y diferir en su padre, profundidad o costo. Identificar nodos por estado sin considerar el costo puede ser incorrecto cuando existen caminos alternativos.

Un **camino** es una secuencia $\langle s_0, s_1, \dots, s_k \rangle$ tal que cada par consecutivo está conectado por una transición legal. Su longitud es k , es decir, el número de aristas. Su costo es

$$g = \sum_{i=0}^{k-1} c(s_i, a_i, s_{i+1}).$$

Longitud y costo solo coinciden cuando todas las acciones cuestan una unidad. Un camino de dos aristas puede costar más que uno de cinco. Esta diferencia explica por qué la búsqueda en anchura minimiza cantidad de pasos, mientras que la búsqueda de costo uniforme minimiza costo acumulado.

La secuencia solución se recupera siguiendo punteros al padre desde el nodo objetivo hasta la raíz y luego invirtiendo el orden. Un algoritmo que devuelve únicamente el estado objetivo no ha reconstruido todavía el plan. También conviene separar tres magnitudes: **generar** un nodo es producirlo como sucesor; **insertarlo** es admitirlo en la frontera; **expandirlo** es retirarlo de la frontera y generar sus sucesores. Los informes experimentales deben indicar cuál se cuenta.

7.1.3. Frontera y conjunto explorado

La **frontera** reúne nodos generados pendientes de expansión. La política para extraer un nodo define la estrategia: una cola FIFO produce anchura; una pila LIFO, profundidad; una cola de prioridad por g , costo uniforme; y una cola por $g + h$, A^* . El **conjunto explorado** registra estados ya expandidos para evitar trabajo redundante y ciclos.

El siguiente esquema abstrae una búsqueda en grafo. CLAVE devuelve la representación canónica con la que se reconoce un estado repetido.

```
BUSQUEDA-EN-GRAFO(problema, frontera):
    raiz <- NODO(problema.estado_inicial)
    INSERTAR(frontera, raiz)
    mejor_costo[CLAVE(raiz.estado)] <- 0
    explorado <- conjunto vacio

    mientras frontera no este vacia:
        nodo <- EXTRAER(frontera)
        si la entrada de nodo es obsoleta respecto de mejor_costo:
            continuar
        si ES-OBJETIVO(nodo.estado):
            devolver RECONSTRUIR-CAMINO(nodo)
            agregar CLAVE(nodo.estado) a explorado

    para cada (accion, estado_hijo, costo_paso) en SUCESORES(nodo.estado):
```



```
nuevo_g <- nodo.g + costo_paso
clave <- CLAVE(estado_hijo)
si clave no fue descubierta o nuevo_g < mejor_costo[clave]:
    mejor_costo[clave] <- nuevo_g
    hijo <- NODO(estado_hijo, nodo, accion, nuevo_g)
    INSERTAR-0-ACTUALIZAR(frontera, hijo)
```

devolver fracaso

El esquema es deliberadamente general. Para anchura con costos unitarios basta recordar si un estado ya fue descubierto; para costo uniforme y A* hay que conservar el mejor g conocido. Marcar un estado como descubierto al generarlo evita duplicados en la frontera, pero no autoriza a descartar un camino posterior más barato en algoritmos sensibles al costo.

Una frontera bien definida también resuelve empates. Dos nodos pueden tener la misma prioridad; usar orden de inserción, menor heurística o una regla lexicográfica cambia el número y orden de expansiones, aunque no siempre las garantías. La regla debe ser estable y documentada para que un experimento sea reproducible.

7.1.4. Búsqueda en árbol y búsqueda en grafo

La **búsqueda en árbol** no recuerda estados previamente alcanzados. Cada sucesor crea un nodo nuevo, aunque su estado haya aparecido antes. Requiere menos mecanismos de control y puede ser adecuada cuando el espacio es realmente un árbol o cuando cada secuencia conduce a un estado único. En grafos con rutas convergentes desperdicia trabajo; con ciclos puede no terminar.

La **búsqueda en grafo** incorpora detección de repetidos. Su ventaja es reducir expansiones; su costo es almacenar claves de estados y decidir qué hacer cuando aparece una ruta mejor. Esa decisión depende de la estrategia:

- con anchura y costos unitarios, la primera profundidad a la que se descubre un estado es mínima;
- con costo uniforme, debe prevalecer el menor costo acumulado;
- con A* y heurística consistente, un estado retirado con prioridad mínima ya tiene su costo óptimo;
- con una heurística admisible pero inconsistente, puede ser necesario **reabrir** un estado explorado si se encuentra un g menor.

La igualdad entre estados debe corresponder a la semántica del problema. En un recorrido con ventanas horarias, «estar en la zona X a las 9:00» y «estar en X a las 11:00» no son necesariamente el mismo estado. Si la hora se omite de la clave, el algoritmo puede podar una solución válida. En cambio, guardar detalles irrelevantes como un identificador accidental puede impedir reconocer duplicados y aumentar drásticamente el espacio.

7.1.5. Ciclos y estados repetidos

Un **ciclo** es un camino no vacío que comienza y termina en el mismo estado. Un estado repetido también puede surgir sin ciclos: dos ramas distintas pueden converger. Ambos fenómenos exigen distinguir tres controles:

1. **Control de ancestros:** rechaza un sucesor si su estado aparece en el camino actual. Evita ciclos dentro de una rama y requiere memoria proporcional a su profundidad, pero no detecta convergencias entre ramas.
2. **Conjunto de descubiertos:** registra estados al insertarlos en la frontera. Evita múltiples copias, apropiado cuando la primera llegada ya es la mejor según la estrategia.
3. **Mejor costo y reapertura:** conserva el menor g por estado. Si aparece un camino mejor, actualiza la frontera o reabre el estado. Es la opción general para búsquedas por costo.

Los ciclos de costo cero merecen atención: aunque no reduzcan el costo, pueden generar infinitas secuencias equivalentes en búsqueda en árbol. Los ciclos de costo negativo son aún más problemáticos. Si un ciclo reduce el costo cada vez que se recorre, no existe un camino óptimo finito bien definido; costo uniforme y A* no ofrecen sus garantías habituales. En este capítulo se supondrán costos no negativos y, cuando se necesite una cota de terminación, un costo mínimo positivo ε .

Error habitual. Usar una lista de objetos nodo como conjunto explorado no detecta estados repetidos si cada objeto tiene identidad distinta. Debe utilizarse una clave canónica del estado. Otro error es cerrar un estado para siempre en A* sin haber demostrado consistencia de la heurística.

7.1.6. Complejidad temporal y espacial

El tamaño explícito de un grafo se expresa mediante $|V|$ y $|E|$. Si el algoritmo recorre cada vértice y arista una vez, su tiempo puede ser $O(|V| + |E|)$. En espacios implícitos, es más informativo usar:

- b : factor de ramificación máximo o efectivo;
- d : profundidad de la solución menos profunda;
- m : profundidad máxima del espacio, posiblemente infinita;
- C^* : costo de una solución óptima;
- ε : costo mínimo positivo de una acción.

Un árbol completo de ramificación b contiene $1 + b + \dots + b^d = O(b^d)$ nodos hasta profundidad d . La exponencial domina: reducir el factor de ramificación efectivo suele ser más valioso que acelerar una operación constante. Si $b = 10$, pasar de profundidad 5 a 6 multiplica aproximadamente por diez el último nivel.

La **complejidad temporal** puede medirse por nodos expandidos, nodos generados y costo de administrar la frontera. La **complejidad espacial** incluye frontera, explorados, nodos con punteros y representación de estados. Decir que una búsqueda «es rápida» sin declarar instancia, representación y métrica carece de valor comparativo.

Estructura o situación	Tiempo típico	Espacio típico	Observación
Recorrido explícito de grafo	$O(V + E)$	$O(V)$	Supone listas de adyacencia y control de visitados.

Estructura o situación	Tiempo típico	Espacio típico	Observación
Árbol hasta profundidad d	$O(b^d)$	depende de la estrategia	La mayoría de nodos está en el nivel más profundo.
Cola de prioridad con N operaciones	$O(N \log N)$	$O(N)$	Se suma al costo de generar y evaluar estados.
Estado con representación de tamaño k	al menos $O(k)$ por copia o clave	hasta $O(Nk)$	Una mala codificación puede dominar el cálculo.

Las cotas de peor caso no predicen por sí solas un caso concreto. Una heurística puede reducir enormemente el número de expansiones sin cambiar la clase exponencial. Por eso se combinan garantía teórica y evidencia experimental.

7.1.7. Ejemplo práctico guiado: representación de una red vial como grafo

Supóngase una red vial simplificada con intersecciones A, B, C, D, E, F . Las aristas dirigidas y sus tiempos estimados en minutos son: $A \rightarrow B : 4$, $A \rightarrow C : 2$, $C \rightarrow B : 1$, $B \rightarrow D : 5$, $C \rightarrow E : 7$, $B \rightarrow E : 2$, $E \rightarrow D : 1$, $D \rightarrow F : 3$ y $E \rightarrow F : 6$. El objetivo es ir de A a F minimizando tiempo.

La formulación es:

- **estado:** intersección actual;
- **estado inicial:** A ;
- **acciones:** recorrer una calle saliente habilitada;
- **transición:** llegar a la intersección destino de esa calle;
- **objetivo:** estado igual a F ;
- **costo:** tiempo de la arista; el costo del camino es su suma.

Existen, entre otros, los caminos $A - B - D - F$ de costo 12, $A - B - E - F$ de costo 12, $A - C - E - D - F$ de costo 13 y $A - C - B - E - D - F$ de costo 9. El camino con menos aristas no es el más barato. Una búsqueda en anchura podría devolver $A - B - D - F$; una búsqueda de costo uniforme debe devolver el camino de costo 9.

La representación es correcta solo para la pregunta planteada. Si se exige respetar combustible, calles cerradas por horario o una visita obligatoria, «intersección actual» deja de ser un estado suficiente. Habría que incorporar combustible restante, tiempo o tareas cumplidas. Asimismo, un tiempo estimado fijo abstrae congestión e incertidumbre: el resultado es óptimo en el modelo, no una promesa sobre el viaje real.

Comprobación guiada. Antes de buscar, conviene verificar: todas las aristas tienen dirección correcta; cada peso usa la misma unidad; no hay costos negativos;

el objetivo es alcanzable desde el origen; y el estado contiene la información necesaria para decidir legalidad y costo futuro. Este pequeño ejemplo será la base conceptual para comparar estrategias, pero no debe confundirse con MOV-02: aquella actividad utiliza un grafo agregado de zonas y viajes observados, no calles.

7.2. Búsqueda no informada

Una estrategia **no informada** emplea la definición del problema y el costo recorrido, pero no una estimación específica de la cercanía al objetivo. «No informada» no significa aleatoria: cada algoritmo impone un orden preciso. Sus garantías permiten establecer una línea base y entender qué aporta posteriormente una heurística.

7.2.1. Búsqueda en anchura

La **búsqueda en anchura** (BFS) expande primero todos los nodos de profundidad 0, luego los de profundidad 1 y así sucesivamente. Su frontera es una cola FIFO. En búsqueda en grafo, el estado suele marcarse al generarlo para evitar varias copias en la cola.

```
ANCHURA(problema):
    frontera <- cola FIFO con la raiz
    descubiertos <- {estado inicial}
    mientras frontera no este vacia:
        nodo <- DESENCOLAR(frontera)
        si nodo satisface el objetivo: devolver su camino
        para cada sucesor de nodo:
            si su estado no esta en descubiertos:
                agregar estado a descubiertos
                ENCOLAR(frontera, sucesor)
    devolver fracaso
```

Si b es finito y existe una solución a profundidad finita, BFS es completa. Es óptima cuando todos los pasos tienen igual costo, porque la primera solución extraída tiene longitud mínima. No es óptima con pesos diferentes. Su tiempo y memoria son $O(b^d)$: necesita conservar casi todo el último nivel. Esta exigencia de memoria suele ser su limitación práctica principal.

Un error común consiste en detenerse al generar cualquier objetivo sin analizar la estrategia. En BFS con costos unitarios es seguro porque los nodos se generan por niveles; en búsquedas de prioridad, generar un objetivo no demuestra que no exista otro camino pendiente más barato.

7.2.2. Búsqueda en profundidad

La **búsqueda en profundidad** (DFS) expande el nodo más profundo disponible. Puede implementarse con una pila LIFO o mediante recursión conceptual. Explora una rama hasta terminarla y luego retrocede.

Su atractivo es espacial: en búsqueda en árbol, si se guardan la rama actual y los hermanos pendientes, requiere $O(bm)$ memoria, muy inferior a la de anchura. Su tiempo de peor caso es $O(b^m)$. Si m es infinito o existen ciclos sin control, puede descender indefinidamente aun cuando haya una solución cercana en otra rama.

En un espacio finito con conjunto explorado termina, pero no garantiza el camino más corto ni el de menor costo.

El orden de sucesores tiene gran influencia. Si desde el origen se insertan primero acciones hacia una región improductiva, DFS puede recorrerla completa antes de probar una solución inmediata. Por ello, comparar DFS sin fijar orden de vecinos produce resultados no reproducibles. DFS es útil cuando la memoria es crítica, las soluciones pueden estar muy profundas y cualquier solución es aceptable; no debe elegirse solo porque su implementación parece sencilla.

7.2.3. Búsqueda con profundidad limitada

La **búsqueda con profundidad limitada** (DLS) impide expandir nodos más allá de un límite ℓ . Convierte un espacio de profundidad infinita en uno finito y evita que una rama consuma toda la búsqueda. Debe distinguir tres resultados: solución, fracaso verdadero y **corte**, que significa que el límite impidió saber si existe solución más abajo.

```

PROFUNDIDAD-LIMITADA(nodo, limite):
  si nodo satisface el objetivo: devolver solucion
  si limite = 0: devolver corte
  ocurrio_corte <- falso
  para cada sucesor que no repita un ancestro:
    resultado <- PROFUNDIDAD-LIMITADA(sucesor, limite - 1)
    si resultado es solucion: devolver resultado
    si resultado es corte: ocurrio_corte <- verdadero
  si ocurrio_corte: devolver corte
  devolver fracaso

```

El tiempo es $O(b^\ell)$ y el espacio $O(b\ell)$. DLS es completa solo si se elige $\ell \geq d$ y el espacio relevante cumple los supuestos de finitud. No es óptima en general. El desafío es fijar el límite: demasiado pequeño excluye todas las soluciones; demasiado grande recupera los problemas de DFS. Un conocimiento real del dominio, como un máximo operativo de trasbordos, puede justificarlo. Un número arbitrario no.

7.2.4. Profundización iterativa

La **profundización iterativa** (IDS) ejecuta DLS con límites $0, 1, 2, \dots$ hasta encontrar solución. Parece ineficiente porque regenera niveles superiores, pero en un árbol exponencial la mayor parte de los nodos está en el nivel final. Con $b = 10$ y $d = 5$, los pocos nodos cercanos a la raíz pueden repetirse varias veces sin dominar el total.

```

PROFUNDIZACION-ITERATIVA(problema):
  para limite <- 0, 1, 2, ...:
    resultado <- PROFUNDIDAD-LIMITADA(raiz, limite)
    si resultado es solucion: devolver resultado
    si resultado es fracaso: devolver fracaso

```

IDS combina completitud de BFS para factor de ramificación finito con memoria $O(bd)$ semejante a DFS. Es óptima cuando los costos son unitarios, pues encuentra primero una solución de profundidad mínima. Su tiempo es $O(b^d)$. Resulta especialmente adecuada cuando se desconoce d y almacenar la frontera

de BFS es inviable. Si generar un estado es extraordinariamente caro o si se dispone de mucha memoria, la regeneración puede desaconsejarla.

7.2.5. Búsqueda de costo uniforme

La **búsqueda de costo uniforme** (UCS) extrae de una cola de prioridad el nodo con menor $g(n)$. Es una generalización de BFS: si cada paso cuesta una unidad, el costo coincide con la profundidad. Con costos distintos, UCS explora contornos de costo acumulado creciente.

COSTO-UNIFORME(problema):

```

frontera <- cola de prioridad por g con la raiz
mejor_g[estado inicial] <- 0
mientras frontera no este vacia:
    nodo <- EXTRAER-MINIMO(frontera)
    si nodo.g no coincide con mejor_g[nodo.estado]: continuar
    si nodo satisface el objetivo: devolver su camino
    para cada sucesor:
        nuevo_g <- nodo.g + costo del paso
        si estado no visto o nuevo_g < mejor_g[estado]:
            mejor_g[estado] <- nuevo_g
            insertar sucesor con prioridad nuevo_g
devolver fracaso

```

Con factor de ramificación finito y costo de paso $c \geq \varepsilon > 0$, UCS es completa y óptima. Antes de extraer una solución de costo C^* solo puede expandir nodos con $g < C^*$ y quizá algunos con $g = C^*$ según los empates. Una cota habitual expresa tiempo y espacio como

$$O(b^{1+\lceil C^*/\varepsilon \rceil}),$$

que puede ser peor que una cota por profundidad cuando existen pasos muy baratos. En grafos explícitos con pesos no negativos, UCS corresponde conceptualmente al algoritmo de Dijkstra desde un origen hasta que se extrae el objetivo.

No se debe marcar irrevocablemente un estado al generarlo: el primer camino descubierto puede no ser el más barato. Tampoco se debe aceptar un objetivo cuando se inserta; la optimalidad se establece cuando se extrae como mínimo. Costos negativos invalidan este razonamiento.

7.2.6. Completitud y optimalidad

Una estrategia es **completa** si garantiza encontrar una solución cuando existe, bajo los supuestos declarados. Es **óptima** si garantiza devolver una solución de costo mínimo. Son propiedades diferentes: DFS puede encontrar alguna solución sin hallar la mejor; una estrategia teóricamente óptima puede no terminar si se violan sus condiciones.

Las garantías siempre llevan supuestos. BFS requiere ramificación finita para no tener infinitos hijos antes del siguiente nivel. UCS requiere una cota positiva de costo para evitar infinitos pasos de costo decreciente antes de alcanzar C^* . A* necesita condiciones sobre la heurística. En un grafo desconectado, ningún

algoritmo crea una ruta inexistente; completitud significa que reportará fracaso tras agotar el componente finito alcanzable.

También hay que precisar el objetivo de optimización. BFS es «óptima» respecto del número de pasos, no respecto de tiempo, distancia o dinero si esos costos difieren. Una suma ponderada de tiempo y distancia define un nuevo costo; ser óptimo para esa suma no significa ser simultáneamente óptimo para cada componente.

Lista de verificación de una afirmación de optimalidad: ¿qué costo se minimiza?, ¿los pesos tienen unidades coherentes?, ¿son no negativos?, ¿cuándo se comprueba el objetivo?, ¿cómo se tratan estados repetidos?, ¿qué propiedad tiene la heurística?, ¿la solución se refiere al modelo o al mundo real?

7.2.7. Comparación de estrategias

La tabla resume cotas clásicas de búsqueda en árbol. En búsqueda en grafo finito, las cotas pueden expresarse mediante $|V|$ y $|E|$, pero la frontera y la gestión de prioridades siguen influyendo.

Estrategia	Orden de extracción	Completa	Óptima	Tiempo de peor caso	Espacio de peor caso
Anchura	menor profundidad FIFO	Sí, si b es finito	Sí, con costos unitarios	$O(b^d)$	$O(b^d)$
Profundidad	mayor profundidad LIFO	No en espacios infinitos	No	$O(b^m)$	$O(bm)$
Profundidad limitada	mayor profundidad hasta ℓ	Solo si $\ell \geq d$	No	$O(b^\ell)$	$O(b\ell)$
Profundización iterativa	límites crecientes	Sí, si b es finito	Sí, con costos unitarios	$O(b^d)$	$O(bd)$
Costo uniforme	menor g	Sí, si $c \geq \varepsilon > 0$	Sí, con costos no negativos	exponencial en C^*/ε	igual orden que tiempo

La elección no se reduce a «mejor algoritmo». Si todos los pasos cuestan lo mismo y la solución es poco profunda, BFS ofrece una referencia clara. Si la memoria domina y una solución cualquiera sirve, DFS o DLS pueden ser razonables. Si se desconoce la profundidad, IDS evita escoger un límite arbitrario. Si los costos difieren y se exige mínimo costo, UCS es la línea base correcta.

En una comparación experimental justa se mantienen constantes el grafo, origen, objetivo, función de costo, criterio de objetivo y orden de sucesores. Se informan camino, costo, profundidad, nodos generados, nodos expandidos, máximo de frontera y tiempo bajo el mismo entorno. Comparar solo milisegundos mezcla estrategia, implementación y carga del sistema.

7.2.8. Ejemplo práctico guiado: comparación experimental de algoritmos no informados

Considérese el grafo dirigido con sucesores en el orden mostrado:

Estado	Sucesores y costos
<i>S</i>	<i>A</i> (1), <i>B</i> (4), <i>C</i> (2)
<i>A</i>	<i>D</i> (8), <i>E</i> (2)
<i>B</i>	<i>E</i> (1), <i>G</i> (7)
<i>C</i>	<i>B</i> (1), <i>F</i> (3)
<i>D</i>	<i>G</i> (1)
<i>E</i>	<i>G</i> (3)
<i>F</i>	<i>G</i> (2)

El objetivo es *G*. BFS organiza por profundidad. Tras *S*, genera *A*, *B*, *C*; en el nivel siguiente aparecen candidatos a través de *A*, *B* y *C*. El primer objetivo generado desde *B* forma *S* – *B* – *G*, de dos pasos y costo 11. Según se compruebe el objetivo al generar o al extraer, cambian algunos conteos, pero no la solución mínima en pasos.

DFS sigue primero *S* – *A* – *D* – *G* con el orden indicado y devuelve costo $1 + 8 + 1 = 10$. Ha encontrado rápidamente una solución, pero no la mejor. DLS con $\ell = 2$ encuentra *S* – *B* – *G*; con $\ell = 1$ devuelve corte. IDS repite raíz y primer nivel antes de hallar también una solución de dos pasos.

UCS compara costos acumulados. Extrae inicialmente *S*(0), *A*(1), *C*(2), *E*(3) y *B*(3); la llegada *S* – *C* – *B* mejora el costo inicial de *B*(4). Luego aparecen *F*(5) y alternativas a *E*. El objetivo óptimo puede alcanzarse por *S* – *A* – *E* – *G* con costo 6 o por *S* – *C* – *F* – *G* con costo 7; UCS extrae primero la solución de costo 6. El ejemplo demuestra tres hechos: menor profundidad no implica menor costo; una llegada posterior puede mejorar un estado; y la estrategia cambia tanto la solución como la memoria.

Un informe experimental completaría una tabla con los conteos reales de una convención fija. Antes de interpretar diferencias pequeñas, debería repetir el ensayo, explicar empates y verificar automáticamente que el costo reconstruido coincide con la suma de aristas. El propósito no es declarar un ganador universal, sino relacionar resultados con las garantías.

La búsqueda no informada ofrece referencias sólidas, pero ignora información obvia sobre el destino. La sección siguiente estudia cómo incorporar esa información sin confundir una estimación útil con una garantía.

7.3. Búsqueda informada y heurísticas

La búsqueda informada utiliza conocimiento adicional para ordenar la exploración. Una buena heurística dirige hacia regiones prometedoras; una mala puede añadir cálculo sin ahorrar expansiones o, si se emplea sin condiciones, comprometer la optimalidad. La pregunta central no es solo «¿qué valor estima?», sino «¿qué relación demostrable mantiene con el costo verdadero?».

7.3.1. Funciones heurísticas

Una **heurística** es una función $h : S \rightarrow \mathbb{R}$ que estima el costo mínimo restante desde un estado hasta un objetivo. Se adopta $h(g) = 0$ para estados objetivo. El costo verdadero restante se denota $h^*(n)$. Una heurística no modifica el costo real g ; aporta una señal para priorizar.

Ejemplos habituales son distancia en línea recta para rutas, cantidad de piezas fuera de lugar en un rompecabezas o suma de costos mínimos pendientes en una asignación. La escala debe coincidir con la función objetivo. Kilómetros no pueden sumarse directamente a minutos; si el costo es tiempo, una distancia puede transformarse en una cota temporal mediante una velocidad máxima válida.

Dos criterios empíricos son el costo de calcular h y su capacidad de discriminación. Una heurística perfecta, $h = h^*$, conduce directamente a una solución óptima, pero calcularla suele equivaler a resolver el problema. La heurística nula $h = 0$ no cuesta casi nada y convierte A^* en UCS. El diseño busca una aproximación barata y fundamentada.

7.3.2. Búsqueda voraz

La **búsqueda voraz por el mejor primero** ordena la frontera solo por $h(n)$. Elige el estado que parece más cercano al objetivo e ignora cuánto costó alcanzarlo. Puede avanzar con pocas expansiones cuando la estimación orienta bien, pero puede aceptar un desvío inicial muy caro o quedar atraída por una región engañosa.

En un grafo con dos opciones desde S , supóngase $S \rightarrow A$ de costo 100 con $h(A) = 1$ y $S \rightarrow B$ de costo 1 con $h(B) = 5$. Si desde A se llega al objetivo por costo 1 y desde B por costo 5, la voraz elige $S - A - G$ de costo 101, aunque existe $S - B - G$ de costo 6. La heurística describe cercanía restante, no costo total.

Con control de repetidos y un grafo finito, la búsqueda voraz termina; en espacios infinitos no es completa en general. Tampoco es óptima, incluso con una heurística admisible. Su utilidad está en obtener rápidamente soluciones plausibles cuando la optimalidad no es obligatoria o como componente de procedimientos más complejos. Debe evaluarse la calidad de solución, no solo la velocidad.

7.3.3. Algoritmo A^*

A^* combina costo recorrido y costo estimado:

$$f(n) = g(n) + h(n).$$

Interpreta f como una estimación del costo total de una solución que pasa por n . Extrae de la frontera el nodo con menor f . Su pseudocódigo es el de costo uniforme reemplazando la prioridad g por $g + h$, pero conserva `mejor_g` para decidir si una ruta nueva mejora el estado.

```
A-ESTRELLA(problema, h):
    frontera <- cola de prioridad por f
    mejor_g[inicial] <- 0
    insertar raiz con f = h(inicial)
    mientras frontera no este vacia:
        nodo <- EXTRAER-MINIMO(frontera)
```

```

    si nodo.g es una entrada obsoleta: continuar
    si nodo satisface el objetivo: devolver su camino
    para cada sucesor:
        nuevo_g <- nodo.g + costo_paso
        si nuevo_g mejora mejor_g[estado sucesor]:
            registrar padre y nuevo_g
            insertar con f = nuevo_g + h(sucesor)
    devolver fracaso

```

Con $h = 0$, A^* es UCS. A medida que una heurística informativa aumenta sin sobreestimar, A^* suele expandir menos estados. Sin embargo, guarda una frontera potencialmente exponencial; su limitación habitual es la memoria. Los empates entre valores f pueden resolverse prefiriendo mayor g o menor h para avanzar más profundo entre candidatos equivalentes, pero la regla debe declararse.

A^* no significa automáticamente «óptimo». La garantía depende de costos no negativos, prueba de objetivo al extraer, tratamiento correcto de mejores caminos y propiedades de h . Una implementación que mezcla unidades o descarta reaperturas necesarias deja de corresponder al algoritmo analizado.

7.3.4. Heurísticas admisibles

Una heurística es **admisible** si nunca sobreestima el costo óptimo restante:

$$0 \leq h(n) \leq h^*(n) \quad \text{para todo } n.$$

Es una cota inferior, no una predicción promedio. Que «casi siempre acierte» no basta: una sola sobreestimación puede hacer que A^* evite el camino óptimo. En búsqueda en árbol, con costos no negativos y una heurística admisible, A^* devuelve una solución óptima. La intuición es que todo nodo de un camino óptimo tiene $f(n) = g(n) + h(n) \leq C^*$; una solución subóptima tiene $f = C > C^*$. Por tanto, esta última no debería extraerse antes de que la frontera permita completar una óptima.

La admisibilidad puede derivarse de un problema relajado. Si se eliminan restricciones, el costo óptimo relajado no puede superar el original y sirve como h . Para un desplazamiento cuyo costo es distancia recorrida, la distancia recta entre posiciones es una cota inferior si las aristas representan trayectos físicos y sus pesos no son menores que esa separación. Para tiempo, distancia recta dividida por una velocidad máxima físicamente y operacionalmente válida puede ser cota inferior.

Multiplicar una heurística admisible por un factor mayor que uno suele perder admisibilidad, aunque reduzca expansiones. Esa variante puede ser útil como búsqueda ponderada si se acepta una solución aproximada, pero no debe presentarse como A^* óptimo sin una garantía específica.

7.3.5. Heurísticas consistentes

Una heurística es **consistente** o monótona si para toda transición $n \rightarrow n'$ de costo $c(n, n')$ cumple

$$h(n) \leq c(n, n') + h(n').$$

Es una desigualdad triangular: la estimación desde n no supera el costo de dar un paso más la estimación desde el sucesor. Si además $h(g) = 0$, la consistencia implica admisibilidad. A lo largo de cualquier camino,

$$f(n') = g(n) + c(n, n') + h(n') \geq g(n) + h(n) = f(n),$$

de modo que los valores f no disminuyen. En A* con búsqueda en grafo, esto permite cerrar un estado cuando se extrae con prioridad mínima: no aparecerá después un camino más barato.

Una heurística admisible puede ser inconsistente. En ese caso A* todavía puede ser óptimo si reabre estados cuyo g mejora. Prohibir reaperturas puede devolver una solución subóptima. La consistencia se verifica localmente sobre aristas, mientras que la admisibilidad se refiere al costo global desconocido; por eso la primera suele ser más fácil de auditar en un grafo finito.

Prueba práctica. Para cada arista almacenada, calcular la diferencia $h(u) - h(v)$ y comprobar que no excede $c(u, v)$, con tolerancia numérica documentada. Cero violaciones observadas en un grafo concreto demuestra consistencia en ese grafo si se revisaron todas sus aristas; no la demuestra para datos futuros o aristas omitidas.

7.3.6. Diseño y evaluación de heurísticas

Una heurística puede diseñarse mediante varios principios:

- **relajación:** resolver una versión con menos restricciones;
- **descomposición:** sumar costos mínimos de subproblemas independientes, evitando contar dos veces el mismo recurso;
- **abstracción:** buscar exactamente en un espacio más pequeño y usar ese costo;
- **geometría:** construir cotas a partir de distancias y límites físicos;
- **patrones precomputados:** almacenar costos exactos de configuraciones abstractas cuando la memoria lo permite.

Si h_1 y h_2 son admisibles, $\max(h_1, h_2)$ también lo es y domina a cada una: nunca es menor y sigue sin sobreestimar. La suma solo es admisible si los costos que estima son aditivos y no se superponen. Elegir el mínimo conserva admisibilidad, pero produce una guía más débil.

La evaluación debe incluir propiedades y desempeño. Primero se verifica unidad, objetivo cero, no negatividad, admisibilidad cuando sea posible y consistencia arista por arista. Después se compara con $h = 0$ sobre las mismas instancias. Métricas útiles son nodos expandidos, generados, reaperturas, máximo de frontera, tiempo de evaluación de h , costo de solución y, si se conoce h^* , error $h^* - h$. El **factor de ramificación efectivo** b^* puede estimarse resolviendo $N + 1 = 1 + b^* + \dots + (b^*)^d$ para N expansiones; valores menores indican mejor orientación.

Una correlación alta entre h y costo real no demuestra admisibilidad. Tampoco basta probar pocos pares cómodos. Deben incluirse distancias cortas y largas, componentes poco conectados, empates y casos sin solución. Si la heurística depende de datos estimados, se documentan periodo, filtros y posibles cambios.

7.3.7. Ejemplo práctico guiado: búsqueda de rutas con A*

Retómese una red física simplificada. Cada nodo tiene coordenadas y cada arista dirigida pesa su longitud de recorrido. Se define $h(n)$ como distancia euclidiana desde n al objetivo. Si cada longitud de arista es al menos la distancia euclidiana entre sus extremos, la desigualdad triangular garantiza consistencia:

$$h(n) \leq d(n, n') + h(n') \leq c(n, n') + h(n').$$

Supónganse los costos y heurísticas hacia G : desde S salen A con costo 2 y $h(A) = 4$, y B con costo 2 y $h(B) = 7$. A* asigna $f(A) = 6$ y $f(B) = 9$, por lo que explora primero A . Desde A llega a C con costo adicional 2 y $h(C) = 2$, luego $f(C) = 6$. Si $C \rightarrow G$ cuesta 3, alcanza una solución de costo 7. UCS habría considerado también varios nodos de costo acumulado inferior a 7 aunque se alejaran del objetivo. A* evita algunos porque su cota total ya es alta.

El procedimiento guiado es:

1. fijar origen, objetivo y costo de aristas;
2. proponer una heurística en la misma unidad;
3. justificar que es cota inferior y comprobar consistencia en todas las aristas;
4. ejecutar UCS y A* con idénticas reglas de repetición y desempate;
5. confirmar que ambos devuelven el mismo costo óptimo;
6. comparar expansiones y costo de calcular la heurística;
7. repetir sobre varios pares, incluidos casos donde la ventaja sea pequeña.

Si el peso cambia de distancia a tiempo observado, la distancia euclidiana ya no está en la misma unidad. Puede dividirse por una velocidad máxima documentada. Usar velocidad media sería riesgoso: un trayecto real puede ser más rápido que la media y la estimación sobreestimaría su tiempo. Además, coordenadas de centroides describen zonas, no puntos exactos de inicio y fin. Estas limitaciones serán centrales en la actividad aplicada.

Actividad EMO [MOV-02]: comparar rutas y heurísticas sobre una red

Capacidad mínima: representar una red de movilidad como grafo y justificar una estrategia de búsqueda.

Pregunta realizable: ¿qué caminos entre zonas pueden construirse sobre la red dirigida de conexiones origen-destino observadas en los viajes de taxi amarillo y cómo cambia la búsqueda según el costo?

Esta actividad se alinea con el Apéndice D. Su red **no es una red vial**: los nodos son zonas TLC y una arista $i \rightarrow j$ indica que la instantánea contiene suficiente cantidad de viajes válidos con ascenso en i y descenso en j . El camino $i \rightarrow j \rightarrow k$ significa que existen conexiones OD observadas entre esos pares; no significa que un vehículo haya realizado ese itinerario, que las zonas sean contiguas ni que la ruta cruce determinadas calles. Una recomendación calle por calle exigiría una red vial externa, fuera del caso mínimo.

Fuente y unidad. Se utilizan los archivos NYC TLC Yellow Taxi indicados en el Apéndice D para febrero, marzo y abril de 2026, junto con Taxi Zone Lookup y, si

se construye una heurística geográfica, Taxi Zone Shapefile. La unidad original es un viaje reportado. El nivel derivado para MOV-02 es el grafo OD.

Variables requeridas: PULocationID, DOLocationID, tpep_pickup_datetime, tpep_dropoff_datetime y trip_distance. Antes de agregar, se valida que el pickup pertenezca al periodo declarado, que el drop-off sea posterior, que duración y distancia sean plausibles en conjunto y que los identificadores existan en el lookup o queden marcados como desconocidos. Las exclusiones deben conservar conteos; no se eliminan registros silenciosamente.

Construcción formal del grafo. Sea Z el conjunto de zonas TLC válidas. Para cada par ordenado (i, j) se calcula el soporte q_{ij} , cantidad de viajes válidos observados. Dado un umbral mínimo $q_{\min}$ documentado,

$$V = Z, \quad E = \{(i, j) : q_{ij} \geq q_{\min}\}.$$

El umbral evita que una arista dependa de un único viaje y reduce conexiones inestables. No debe elegirse solo para obtener un camino deseado. Se informa cómo cambian cantidad de aristas, zonas aisladas y conectividad al variar razonablemente $q_{\min}$.

Cada arista conserva al menos soporte, duración mediana y distancia mediana. La mediana reduce la influencia de valores extremos, pero no elimina la necesidad de control de calidad. El costo elegido debe responder a una pregunta:

- $c_{ij} = \text{mediana}(\text{duracion}_{ij})$ para minimizar tiempo típico agregado;
- $c_{ij} = \text{mediana}(\text{distancia}_{ij})$ para minimizar distancia reportada típica;
- una combinación normalizada y justificada si existe una decisión multicriterio.

No se mezclan minutos y millas mediante una suma sin escala e interpretación. Tampoco se usa $1/q_{ij}$ como si fuera distancia: podría representar preferencia por conexiones frecuentes, pero resolvería otra pregunta. El costo agregado no garantiza el tiempo o distancia de un viaje futuro y la suma de medianas de varias aristas es un criterio analítico, no un itinerario observado completo.

Selección de instancias. El equipo propone varios pares origen-destino dentro del mismo componente alcanzable; cada estudiante analiza al menos un par asignado. Debe incluirse un par no trivial cuya solución tenga más de una arista y, cuando sea posible, un caso con alternativas de costos distintos. Si no hay camino dirigido, el resultado correcto es «inalcanzable en el grafo filtrado», no invertir aristas ni reducir el umbral después de ver el resultado sin reportarlo.

Comparación obligatoria: costo uniforme y A* se ejecutan sobre exactamente el mismo grafo, par OD, costo, control de repetidos y regla de desempate. Se registran camino de zonas, costo total, cantidad de aristas, nodos generados, nodos expandidos, máximo de frontera y tiempo de cálculo. Ambos deben devolver el mismo costo si A* cumple sus condiciones; una diferencia obliga a revisar heurística, cierres, unidades o reconstrucción.

Heurística para costo de distancia. Si se dispone de geometría, puede calcularse una separación geográfica entre centroides de zonas. Para sostener admisibilidad debe verificarse que, para cada arista, la heurística respete $h(i) \leq c_{ij} + h(j)$. Un centroide es un representante agregado: la distancia entre centroides podría superar una distancia mediana reportada en ciertos pares, por

lo que la frase «es línea recta» no constituye por sí sola una prueba. Una opción conservadora consiste en calibrar una escala $0 \leq \alpha \leq 1$ y definir $h(i) = \alpha d(i, g)$, eligiendo α sin usar la instancia de prueba y verificando consistencia en todo el grafo analizado. Si no puede justificarse una cota positiva, $h = 0$ es admisible y convierte A* en UCS.

Heurística para costo de tiempo. Una candidata es

$$h(i) = \frac{d(i, g)}{v_{\max}},$$

con unidades convertidas correctamente y una velocidad máxima documentada. $v_{\max}$ debe producir una cota inferior plausible, no ser la velocidad media de los viajes. Aun así, se comprueba la desigualdad de consistencia sobre todas las aristas porque centroides, agregación por medianas y errores de registro pueden quebrarla. Si existen violaciones, se reduce la escala, se usa reapertura con una discusión de admisibilidad o se adopta $h = 0$; no se ocultan las violaciones.

Protocolo de trabajo:

1. definir periodo, filtros y conteos de calidad;
2. agregar pares OD y fijar $q_{\min}$ antes de seleccionar resultados favorables;
3. describir $|V|$, $|E|$, dirección, componentes y distribución de soportes;
4. elegir una sola función de costo principal y declarar unidad;
5. seleccionar pares reproducibles mediante LocationID y nombre de zona;
6. obtener la referencia con costo uniforme;
7. diseñar la heurística usando solo información permitida;
8. evaluar objetivo cero, no negatividad y consistencia en todas las aristas;
9. ejecutar A* bajo las mismas condiciones;
10. interpretar diferencias y efectuar sensibilidad al umbral o a la escala heurística.

Modalidad de trabajo: construcción y auditoría del grafo en equipo; experimentos y análisis individuales. Compartir el grafo no implica compartir conclusiones: cada estudiante debe explicar su instancia, propiedades de la heurística y limitaciones.

Evidencia individual: notebook reproducible con representación del grafo, definición de estados, acciones, objetivo y costos; resumen de filtros y soporte; resultados comparativos; comprobaciones de la heurística; y discusión de admisibilidad o limitaciones. El capítulo no prescribe código de implementación: el notebook debe materializar los conceptos con las herramientas del curso.

Tabla mínima de resultados:

Campo	Costo uniforme	A*
Origen y destino	mismos	mismos
Costo y unidad	mismo	mismo
Camino de LocationID	reportar	reportar
Costo total	reportar	reportar
Nodos expandidos	reportar	reportar
Nodos generados	reportar	reportar
Máximo de frontera	reportar	reportar
Reaperturas	reportar	reportar

Criterios de aprobación:

- Estados, acciones, costos y objetivo quedan definidos sin ambigüedad.
- Los algoritmos se comparan sobre las mismas instancias.
- La heurística utiliza información disponible y sus propiedades se justifican.
- Las aristas exigen soporte mínimo y preservan su dirección OD.
- Se distinguen distancia reportada, separación entre centroides y distancia vial.
- El producto se presenta como camino en una red de zonas conectadas por viajes observados, nunca como ruta calle por calle.
- Se reconoce que TLC cubre taxis amarillos reportados y no toda la movilidad de Nueva York.

Errores que invalidan la evidencia: interpretar zonas como intersecciones; conectar centroides por cercanía sin viajes OD; usar el shapefile como red vial; comparar algoritmos con diferentes filtros; afirmar admisibilidad porque la heurística «parece menor» en un solo camino; seleccionar una velocidad promedio como cota máxima; o concluir que menos expansiones implica mejor ruta cuando ambos algoritmos deben coincidir en costo óptimo.

Aporte al laboratorio: incorpora la dimensión de decisión o desplazamiento sobre la estructura espacial. Su conectividad puede alimentar posteriormente una regla didáctica de prioridad de zonas, pero no constituye despacho óptimo: los datos no contienen ubicación ni disponibilidad de vehículos libres, demanda insatisfecha ni otros modos de transporte.

7.4. Búsqueda local y problemas con restricciones

Los algoritmos anteriores construyen caminos desde un estado inicial. En muchos problemas de optimización importa la configuración final y no la secuencia utilizada para obtenerla. La búsqueda local mantiene una o pocas soluciones completas y se mueve entre vecinas, con memoria reducida. Por otra parte, cuando el objetivo principal es satisfacer reglas combinatorias, una formulación de satisfacción de restricciones permite explotar la estructura de variables y dominios.

7.4.1. Búsqueda por ascenso de colinas

El **ascenso de colinas** parte de una solución candidata y reemplaza el estado actual por un vecino mejor según una función de valor. Si se minimiza un costo J , «mejor» significa menor J ; el nombre ascenso supone convencionalmente que se maximiza $F = -J$. No mantiene un camino hacia el origen ni una frontera global.

```

ASCENSO-DE-COLINAS(estado_inicial):
  actual <- estado_inicial
  repetir:
    vecinos <- VECINOS(actual)
    si vecinos esta vacio: devolver actual
    siguiente <- un vecino de mejor valor
    si VALOR(siguiente) <= VALOR(actual): devolver actual
    actual <- siguiente

```

En un recorrido, un estado puede ser una permutación de visitas y un vecino puede

intercambiar dos posiciones o invertir un segmento. La calidad del vecindario determina qué mejoras son accesibles en un paso. Un vecindario muy pequeño produce muchos óptimos locales; uno enorme encarece cada iteración.

El método usa poca memoria y suele obtener soluciones aceptables rápidamente en espacios grandes. No es completo ni garantiza óptimo global. Variantes útiles incluyen elegir la primera mejora en lugar de examinar todos los vecinos, permitir movimientos laterales limitados y ejecutar reinicios desde estados aleatorios. Los reinicios no prueban optimalidad, pero permiten estimar estabilidad: si muchas ejecuciones convergen al mismo valor, aumenta la confianza empírica.

7.4.2. Máximos locales, mesetas y crestas

Un **máximo local** tiene valor no menor que todos sus vecinos, aunque exista otro estado lejano con valor superior. Una **meseta** es una región de igual valor sin dirección local clara. Una **cresta** presenta una dirección de mejora que no puede seguirse con los movimientos disponibles, por ejemplo cuando requiere cambiar simultáneamente varias decisiones.

Las respuestas posibles tienen costos distintos:

- reinicios aleatorios exploran otras cuencas de atracción;
- movimientos laterales atraviesan mesetas, pero deben limitarse para evitar ciclos;
- vecindarios variables alternan tipos de movimiento;
- búsqueda tabú recuerda movimientos recientes y evita regresar inmediatamente;
- perturbaciones ocasionales abandonan una región antes de volver a mejorar.

El diagnóstico exige observar trayectorias, no solo el resultado final. Una curva completamente plana puede indicar meseta, pero también un error en la función objetivo. Resultados idénticos en todos los reinicios pueden señalar un óptimo dominante o una inicialización no realmente variable. Toda comparación debe fijar presupuesto de evaluaciones, no solo cantidad de iteraciones, porque examinar un vecindario grande cuesta más.

Limitación conceptual. La búsqueda local puede visitar temporalmente soluciones inviables si la representación lo permite. Penalizar violaciones mediante $J(x) = \text{costo}(x) + \lambda \text{violaciones}(x)$ no garantiza factibilidad: un λ pequeño tolera infracciones y uno enorme aplanar diferencias entre soluciones inviables. Cuando las restricciones son duras, es preferible generar solo vecinos factibles, reparar candidatos o usar un método específico de restricciones.

7.4.3. Recocido simulado

El **recocido simulado** incorpora la posibilidad de aceptar empeoramientos para escapar de óptimos locales. Al minimizar energía J , un movimiento con $\Delta = J(\text{nuevo}) - J(\text{actual}) \leq 0$ se acepta siempre. Si $\Delta > 0$, se acepta con probabilidad

$$p = \exp(-\Delta/T),$$

donde $T > 0$ es la temperatura. A temperatura alta se aceptan diversos movimientos; al enfriarse, el comportamiento se aproxima al ascenso de colinas.


```

RECOCIDO-SIMULADO(estado_inicial, calendario):
    actual <- estado_inicial
    mejor <- actual
    para t <- 1 hasta presupuesto:
        T <- calendario(t)
        si T <= 0: devolver mejor
        nuevo <- vecino elegido al azar de actual
        delta <- COSTO(nuevo) - COSTO(actual)
        si delta <= 0 o AZAR(0,1) < exp(-delta / T):
            actual <- nuevo
        si COSTO(actual) < COSTO(mejor): mejor <- actual
    devolver mejor

```

Debe devolverse el mejor estado observado, no necesariamente el último. La escala de T debe ser compatible con la de Δ ; cambiar unidades del costo sin ajustar temperatura altera el algoritmo. Un calendario geométrico usa $T_t = T_0 \alpha^t$, con $0 < \alpha < 1$. Un enfriamiento muy rápido reproduce el atrapamiento del ascenso; uno muy lento consume presupuesto explorando casi al azar.

Bajo condiciones matemáticas de enfriamiento extremadamente lento, existen resultados de convergencia al óptimo global, pero rara vez son prácticos. En uso real el recocido es estocástico y aproximado. Se reportan semilla, calendario, presupuesto y distribución de resultados de varias ejecuciones. Comparar solo la mejor ejecución de un método con la mediana de otro es una práctica sesgada.

7.4.4. Introducción a algoritmos evolutivos

Los **algoritmos evolutivos** mantienen una población de candidatos. Cada candidato posee una representación o genotipo; una función de aptitud evalúa su calidad; la selección favorece candidatos prometedores; el cruce combina material de progenitores; y la mutación introduce variación. El reemplazo forma la siguiente generación. No se trata de una copia literal de la evolución biológica, sino de una familia de heurísticas de optimización.

```

ALGORITMO-EVOLUTIVO(poblacion_inicial):
    poblacion <- poblacion_inicial
    mientras no se cumpla el criterio de parada:
        evaluar aptitud de cada individuo
        padres <- seleccionar segun aptitud y diversidad
        descendencia <- cruzar y mutar padres
        reparar o descartar descendencia invalida
        poblacion <- reemplazar con supervivientes y descendencia
    devolver el mejor individuo factible observado

```

La representación debe hacer probables las soluciones válidas. Para recorridos, un cruce ordinario de vectores puede duplicar visitas y omitir otras; se requieren operadores que preserven permutaciones o mecanismos de reparación. Una presión de selección excesiva elimina diversidad y causa convergencia prematura; una mutación demasiado alta transforma el proceso en búsqueda aleatoria.

Estos algoritmos son apropiados cuando el espacio es discontinuo, existen múltiples objetivos o no hay gradientes útiles. Consumen muchas evaluaciones y no garantizan el óptimo. Deben compararse bajo igual presupuesto, con varias semillas y baselines simples. Esta introducción aporta vocabulario y criterios; el

diseño avanzado de operadores y optimización multiobjetivo excede el alcance del capítulo.

7.4.5. Variables, dominios y restricciones

Un **problema de satisfacción de restricciones** (CSP) se define como

$$\mathcal{C} = (X, D, C),$$

donde $X = \{X_1, \dots, X_n\}$ es un conjunto de variables; cada D_i es el dominio de valores posibles para X_i ; y C es un conjunto de restricciones. Una asignación es **parcial** si solo fija algunas variables, **completa** si fija todas, **consistente** si no viola restricciones aplicables y **solución** si es completa y satisface todas las restricciones.

Las restricciones pueden ser unarias, binarias o globales. **TODO-DIFERENTE**($X_1, \dots, X_k$) es una restricción global más expresiva que enumerar pares, aunque ambas formulaciones compartan soluciones. También se distinguen restricciones duras, que deben cumplirse, y preferencias blandas, cuya violación tiene costo. Mezclarlas sin indicarlo transforma un CSP en un problema de optimización con restricciones.

Ejemplo: asignar cuatro inspecciones $I_1, \dots, I_4$ a franjas mañana y tarde y a dos equipos. Cada variable puede representar el par (franja, equipo). Las restricciones exigen que un equipo no realice dos inspecciones simultáneas, que I_1 ocurra por la mañana y que I_3 sea posterior a I_2 . Si además se minimiza desplazamiento, la factibilidad es el primer nivel y el costo, el segundo.

El **grafo de restricciones** coloca variables como nodos y une aquellas que participan en una restricción binaria. Su estructura explica parte de la dificultad: componentes independientes pueden resolverse por separado; un árbol admite algoritmos eficientes; redes densas propagan más información, pero también acoplan decisiones.

7.4.6. Satisfacción de restricciones

La búsqueda básica para CSP es el **retroceso** o backtracking: asigna una variable, prueba un valor consistente y retrocede cuando ninguna continuación es posible. A diferencia de una búsqueda genérica, el orden de asignación de variables no cambia la solución final y puede explotarse con heurísticas especializadas.

RETROCESO(asignacion, dominios):

```

    si asignacion es completa: devolver asignacion
    X <- variable no asignada elegida por MRV y grado
    para cada valor v de D[X] ordenado por valor menos restrictivo:
        si v es consistente con asignacion:
            asignar X <- v
            reducciones <- PROPAGAR(X, v, dominios)
            si ningun dominio queda vacio:
                resultado <- RETROCESO(asignacion, dominios reducidos)
                si resultado no es fracaso: devolver resultado
            deshacer asignacion y reducciones
    devolver fracaso
```

La heurística **MRV** elige la variable con menos valores restantes: intenta fallar pronto. En empate, la heurística de **grado** elige la variable que restringe más variables no asignadas. El **valor menos restrictivo** prueba primero el que elimina menos opciones ajenas. Estas heurísticas ordenan la búsqueda; no relajan restricciones.

La comprobación hacia adelante elimina de dominios vecinos los valores incompatibles con la asignación recién hecha. La **consistencia de arco** exige, para cada valor de X , algún valor compatible en cada variable vecina Y . El procedimiento AC-3 revisa arcos hasta que no haya cambios o un dominio quede vacío. Propagar detecta fracasos antes, pero tiene costo; conviene medir el equilibrio.

Un CSP finito resuelto por retroceso exhaustivo es completo. Encontrar una asignación factible no implica minimizar una preferencia. Para un problema de optimización con restricciones puede usarse ramificación y acotación: conservar la mejor solución y podar asignaciones cuya cota inferior ya no pueda mejorarla. La calidad de una cota determina la poda, del mismo modo que una heurística informa A^* .

Errores frecuentes: modelar como valor especial «sin asignar» y permitirlo en una solución; modificar dominios sin restaurarlos al retroceder; aplicar MRV sobre tamaños originales en vez de dominios actuales; considerar que consistencia de arco garantiza una solución global; y ocultar una restricción dura dentro de una penalización que el optimizador puede aceptar.

7.4.7. Ejemplo práctico guiado: planificación de recorridos de inspección

Una organización debe planificar un turno de 240 minutos para un equipo. Hay cuatro inspecciones: A requiere 35 minutos y prioridad 8; B , 50 y prioridad 10; C , 30 y prioridad 5; D , 45 y prioridad 7. Los tiempos de traslado dependen del orden. B solo está disponible durante los primeros 120 minutos; D debe realizarse después de A porque utiliza su diagnóstico; y toda inspección iniciada debe completarse dentro del turno.

Hay dos decisiones relacionadas pero distintas:

1. **Factibilidad y selección:** qué inspecciones se realizan y en qué condiciones.
2. **Secuenciación:** en qué orden se visitan para reducir traslado o maximizar prioridad atendida.

Una formulación CSP puede usar variables $seleccion_i$, $inicio_i$ y $posicion_i$. Sus dominios contienen valores booleanos, instantes discretizados y posiciones. Las restricciones imponen no solapamiento, disponibilidad de B , precedencia $A < D$ y duración total. Si todas las tareas deben realizarse y las restricciones son incompatibles, el sistema debe declarar que no existe solución; no puede prolongar implícitamente el turno.

Si algunas inspecciones son opcionales, el objetivo puede maximizar

$$F(x) = \sum_i prioridad_i seleccion_i - \lambda tiempoTraslado(x),$$

siempre que λ tenga interpretación y las restricciones de seguridad permanezcan

duras. El estado de una búsqueda local es una lista ordenada de inspecciones seleccionadas. Los vecinos pueden intercambiar dos visitas, invertir un segmento, insertar una omitida o retirar una visita. Cada vecino se reevalúa incluyendo traslado, servicio y ventanas.

Desarrollo guiado: primero se ejecuta propagación de restricciones. La ventana de B reduce sus posiciones posibles; la precedencia elimina órdenes con D antes de A ; el límite de turno descarta combinaciones demasiado largas. Sobre las secuencias factibles se aplica ascenso de colinas con varios reinicios. Se registra valor inicial, valor final, inspecciones cubiertas, tiempo total y razón de parada. Luego se aplica recocido con el mismo número de evaluaciones para observar si aceptar intercambios temporalmente peores permite mejorar el resultado.

Supóngase que el orden inicial $A - C - D - B$ incumple la ventana de B . No debe recibir simplemente una puntuación algo menor y competir como si fuera válido: se repara moviendo B o se rechaza. El orden $B - A - D - C$ respeta precedencia, pero puede superar 240 minutos según traslados. Solo después de confirmar factibilidad se compara su valor con $B - A - C - D$ u otras alternativas.

El informe final incluye la formulación, tabla de tiempos, restricciones, operador de vecindad, presupuesto de evaluación, semillas y distribución de resultados. Debe distinguir «mejor solución encontrada» de «solución óptima». Para demostrar optimalidad sería necesario enumerar todas las soluciones factibles o aplicar un método exacto con cota verificable. En operación real, además, tiempos inciertos, nuevas urgencias y varios equipos convertirían el problema en una decisión dinámica; el modelo estático constituye una aproximación inicial, no un plan inmune a cambios.

Errores comunes y límites del capítulo

Los errores siguientes atraviesan varias estrategias:

- confundir estado con nodo y eliminar una ruta mejor porque «el nodo ya apareció»;
- medir longitud cuando la pregunta exige costo, o sumar magnitudes con unidades incompatibles;
- afirmar completitud u optimalidad sin mencionar ramificación, signo de costos, condición de objetivo y propiedad heurística;
- comparar algoritmos sobre instancias, filtros u órdenes de sucesores diferentes;
- contar generados en un algoritmo y expandidos en otro;
- interpretar la salida como verdad del mundo en vez de óptimo del modelo;
- usar una heurística calculada con información futura o con el costo exacto que se pretende estimar;
- tratar una solución local estocástica como óptimo demostrado;
- convertir restricciones duras en penalizaciones sin analizar violaciones;
- inferir una ruta vial a partir de un grafo agregado de zonas OD.

Los métodos estudiados suponen que el modelo permanece fijo durante una ejecución. Si una calle se cierra, cambia el tiempo de viaje o llega una inspección urgente, puede ser necesario volver a planificar. Si las transiciones son inciertas o las acciones producen observaciones parciales, el espacio de estados debe ampliarse o reemplazarse por modelos de decisión bajo incertidumbre. Si la

función objetivo contiene consecuencias sociales, la optimización técnica no decide por sí sola qué pesos son legítimos. Una respuesta responsable documenta alcance, cobertura de datos y personas o fenómenos no representados.

Síntesis

Una búsqueda combina representación y estrategia. El grafo de estados expresa posibilidades; el árbol de búsqueda expresa caminos considerados. Frontera, conjunto explorado y mejor costo controlan el orden y la repetición. BFS privilegia profundidad; DFS, memoria; DLS impone un horizonte; IDS combina profundidad creciente y bajo espacio; UCS optimiza costos no negativos. A* añade una cota del costo restante y conserva optimalidad bajo condiciones precisas; la búsqueda voraz sacrifica esa garantía por dirección más agresiva.

La búsqueda local abandona la reconstrucción de caminos para mejorar configuraciones con poca memoria. Ascenso de colinas, recocido simulado y algoritmos evolutivos ofrecen soluciones aproximadas, por lo que necesitan múltiples ejecuciones y baselines. Los CSP hacen explícitas variables, dominios y restricciones y aprovechan propagación y órdenes de elección. En todos los casos, las garantías pertenecen a un modelo. En MOV-02, ese modelo es un grafo OD de zonas TLC sostenido por viajes observados, no una red de calles.

Glosario

Acción: operación aplicable a un estado que produce una transición.

Admisibilidad: propiedad $h(n) \leq h^*(n)$; la heurística no sobreestima el costo óptimo restante.

Aptitud: medida con la que un algoritmo evolutivo evalúa y selecciona candidatos.

Camino: secuencia de estados conectados por transiciones legales.

Compleitud: garantía de encontrar una solución cuando existe, bajo supuestos declarados.

Consistencia: propiedad heurística $h(n) \leq c(n, n') + h(n')$ para cada transición.

Costo acumulado $g(n)$: suma de costos desde el estado inicial hasta el nodo n .

Dominio: conjunto de valores permitidos para una variable de un CSP.

Estado: descripción suficiente de una configuración relevante del problema.

Estado repetido: estado alcanzado por más de un camino o más de una vez.

Expandir: retirar un nodo de la frontera y generar sus sucesores.

Factor de ramificación: cantidad de sucesores de un nodo; puede usarse un máximo o un valor efectivo.

Frontera: colección de nodos generados pendientes de expansión.

Función heurística $h(n)$: estimación del costo mínimo restante hasta un objetivo.

Grafo OD: grafo dirigido cuyas aristas representan pares origen-destino observados; no implica una red vial.

Meseta: región de estados vecinos con igual valor en búsqueda local.

Nodo de búsqueda: registro que contiene un estado y metadatos como padre, acción, profundidad y costo.

Optimalidad: garantía de devolver una solución de costo mínimo según la función declarada.

Reapertura: reinserción de un estado explorado cuando se descubre un camino de menor costo.

Restricción: relación que determina combinaciones permitidas de valores.

Solución: camino que alcanza un objetivo o asignación completa que satisface restricciones, según el problema.

Vecindario: conjunto de candidatos obtenibles mediante un movimiento local.

Preguntas de revisión y discusión

1. ¿Por qué un espacio con cuatro estados puede generar un árbol de búsqueda infinito? Construya un ejemplo.
2. Explique con sus palabras la diferencia entre generar, insertar y expandir un nodo. ¿Qué métrica informaría en un experimento?
3. ¿Qué información adicional debe contener un estado de ruta si existen ventanas horarias?
4. Demuestre por qué BFS no minimiza tiempo cuando las aristas tienen costos diferentes.
5. ¿En qué condiciones DFS es una elección razonable pese a no ser óptima?
6. ¿Por qué DLS debe distinguir corte de fracaso? Dé un caso donde confundirlos produzca una conclusión falsa.
7. Explique por qué la repetición de niveles en IDS no cambia su orden temporal $O(b^d)$.
8. ¿Por qué UCS comprueba el objetivo al extraer y no al generar?
9. Construya un grafo donde la búsqueda voraz encuentre una solución mucho más cara que UCS.
10. Demuestre que una heurística consistente con $h(g) = 0$ es admisible a lo largo de un camino óptimo.
11. ¿Qué debe hacer A* con una heurística admisible pero inconsistente?
12. ¿Por qué una alta correlación entre heurística y costo verdadero no demuestra admisibilidad?
13. Compare $\max(h_1, h_2)$ y $h_1 + h_2$ cuando ambas heurísticas son admisibles. ¿Qué condición adicional necesita la suma?
14. ¿Cómo afectan máximos locales, mesetas y crestas al ascenso de colinas?
15. ¿Qué sucede con recocido simulado si se cambia el costo de minutos a segundos y se conserva el mismo calendario de temperatura?
16. Distinga una restricción dura de una preferencia blanda en la planificación de inspecciones.
17. ¿Por qué consistencia de arco no garantiza por sí sola una solución completa de un CSP general?
18. Explique por qué una secuencia de zonas obtenida en MOV-02 no es una ruta de conducción.
19. Si el costo OD es tiempo mediano, ¿por qué la distancia entre centroides no puede sumarse directamente a g ?

20. ¿Qué análisis de sensibilidad haría antes de confiar en un camino obtenido tras filtrar aristas por soporte?

Actividad integradora del capítulo

Propósito. Comparar familias de búsqueda sobre una formulación común y defender una decisión metodológica con garantías, evidencia y límites.

Se propone un problema de planificación de cinco a ocho inspecciones con ubicaciones agregadas, duraciones, prioridades, precedencias y una ventana temporal. Cada equipo define un conjunto pequeño y completamente auditable. No se requieren datos de movilidad ni código vial; los tiempos de traslado pueden darse en una matriz didáctica.

Fase 1, formulación. Definir estados, acciones, transición, objetivo y costo para una búsqueda de caminos. Formular también variables, dominios y restricciones como CSP. Explicar qué detalles se omiten y presentar al menos un par de estados que parezcan iguales pero deban distinguirse por tiempo o tareas pendientes.

Fase 2, referencia exacta. Sobre una versión reducida, aplicar costo uniforme y obtener una solución de referencia. Informar orden de expansión, mejoras de costo, máximo de frontera y camino. Si se usa un límite o se poda, justificar que no elimina la solución óptima.

Fase 3, búsqueda informada. Diseñar una heurística mediante relajación, por ejemplo ignorar precedencias y usar la suma de mínimos costos pendientes. Probar objetivo cero, unidad, admisibilidad o, si no puede demostrarse, declarar la ausencia de garantía. Comparar A* con UCS sobre las mismas instancias.

Fase 4, optimización local y restricciones. Representar una solución completa como secuencia, definir al menos dos movimientos de vecindario y comparar ascenso de colinas con reinicios frente a recocido simulado bajo igual número de evaluaciones. Usar propagación del CSP para rechazar o reparar candidatos inviables. Ejecutar varias semillas y reportar mediana, mejor, peor y proporción de soluciones factibles.

Fase 5, argumentación. Recomendar una estrategia para tres escenarios: memoria muy limitada, exigencia de optimalidad y necesidad de una respuesta rápida aproximada. La recomendación debe citar supuestos y no basarse solo en el menor tiempo observado.

Producto esperado: informe breve con formulación formal, pseudocódigo adaptado en términos del dominio, tabla comparativa, trazas de una instancia, análisis de errores y una sección de límites. No se acepta una tabla de tiempos sin reconstrucción de caminos y validación de costos.

Rúbrica orientativa:

Dimensión	Evidencia esperada
Representación	Estado suficiente, acciones legales, objetivo y unidades inequívocas.
Corrección	Caminos válidos, costos recalculados y restricciones verificadas.

Dimensión	Evidencia esperada
Garantías	Complejidad y optimalidad asociadas a supuestos concretos.
Comparación	Mismas instancias, presupuesto y definiciones de métricas.
Heurística	Origen conceptual, propiedades comprobadas y costo de evaluación.
Búsqueda local	Varias semillas, factibilidad y distribución de calidad.
Comunicación	Conclusiones limitadas al modelo y errores discutidos.

La actividad cierra la transición entre representación y decisión. Un algoritmo no compensa una formulación incorrecta: únicamente explora con mayor o menor eficacia las alternativas que el modelo hizo visibles.

Capítulo 8. Decisiones secuenciales y aprendizaje por refuerzo

Decidir no consiste solamente en predecir qué ocurrirá. Una predicción estima resultados posibles; una decisión elige una acción teniendo en cuenta esos resultados, sus probabilidades, las preferencias del decisor y las restricciones existentes. La diferencia es sustantiva: dos organizaciones pueden compartir el mismo pronóstico de demanda y, sin embargo, tomar decisiones distintas porque afrontan costos, responsabilidades o tolerancias al riesgo diferentes.

La dificultad aumenta cuando las decisiones forman una secuencia. Bombear agua ahora modifica el nivel del depósito, ese nivel condiciona las acciones disponibles después y cada acción genera costos y riesgos futuros. En tales problemas no basta con optimizar el beneficio inmediato. Es preciso representar el estado del sistema, anticipar transiciones, acumular consecuencias a lo largo del tiempo y establecer una regla de actuación. Los procesos de decisión de Markov proporcionan el lenguaje matemático para hacerlo. Cuando el modelo de transición o de recompensa no se conoce, el aprendizaje por refuerzo estudia cómo aprender esa regla mediante interacción.

Este capítulo avanza desde decisiones únicas bajo incertidumbre hasta decisiones secuenciales y aprendizaje. El propósito no es presentar algoritmos como recetas aisladas, sino mostrar qué supuestos convierten una situación real en un problema formal, qué garantiza cada método y dónde puede fallar. Se empleará como caso conductor la operación simplificada de una red de agua. Las cantidades monetarias se expresan en unidades de costo (u.c.) para concentrar la atención en el razonamiento.

Al finalizar, el lector podrá distinguir alternativas, estados y consecuencias; justificar una función de utilidad; calcular utilidad esperada y valor de información; formular un proceso de decisión de Markov; interpretar funciones de valor y ecuaciones de Bellman; comparar iteración de políticas e iteración de valores; y explicar las diferencias entre Monte Carlo, diferencias temporales, Q-learning y SARSA. También podrá reconocer cuándo la recompensa no representa el objetivo social, cuándo explorar es inseguro y cuándo no corresponde desplegar aprendizaje por refuerzo.

8.1. Decisiones bajo incertidumbre

Una decisión bajo incertidumbre combina un conjunto de acciones controlables con hechos que el decisor no controla. Su tratamiento riguroso exige evitar tres confusiones frecuentes: una probabilidad no es una preferencia, el resultado más probable no tiene por qué ser la mejor base para actuar y una expectativa monetaria no siempre representa el valor que una persona u organización asigna a una consecuencia.

8.1.1. Alternativas, estados y consecuencias

Sea $A = \{a_1, \dots, a_m\}$ el conjunto de **alternativas** disponibles y $S = \{s_1, \dots, s_n\}$ el conjunto de **estados de la naturaleza** mutuamente excluyentes y exhaustivos. Una alternativa es controlable: inspeccionar una tubería, repararla de forma preventiva o esperar. Un estado no lo es: existe una fuga grave o no existe. La **consecuencia** $c(a, s)$ resulta de ejecutar a cuando ocurre s . Puede incluir costo, tiempo, continuidad del servicio, daño ambiental y reputación.

La tabla siguiente representa una decisión estática. Los valores son costos; por ello, cantidades menores son preferibles.

Alternativa	Fuga grave s_1	Sin fuga grave s_2
Reparar preventivamente a_1	32	28
Inspeccionar a_2	depende del resultado y de la acción posterior	depende del resultado y de la acción posterior
Esperar a_3	120	2

La consecuencia no debe confundirse con el estado. “Fuga grave” describe el mundo; “pérdida de 120 u.c. por esperar ante una fuga grave” describe la combinación de mundo y acción. Esta separación permite preguntar de dónde procede cada cantidad y someterla a análisis de sensibilidad.

Los estados deben cubrir las incertidumbres relevantes para la decisión, pero no todos los detalles imaginables. Si dos estados producen las mismas consecuencias para todas las alternativas, distinguirlos no modifica la elección. En cambio, agrupar “fuga leve” y “rotura inminente” puede ocultar una diferencia decisiva. La representación es, por tanto, un compromiso entre fidelidad y manejabilidad.

En ocasiones, la acción cambia la probabilidad del estado observado después. Entonces conviene escribir $P(s | a)$, no $P(s)$. Una intervención de mantenimiento puede reducir la probabilidad de falla; una prueba diagnóstica, en cambio, normalmente informa sobre una condición previa sin causarla. Confundir efectos causales con asociaciones observacionales genera decisiones incorrectas incluso si las probabilidades están bien calculadas.

Error frecuente. Elegir la alternativa asociada al estado más probable ignora los demás estados. Aunque la fuga grave tenga probabilidad baja, su daño puede justificar una reparación. La decisión debe considerar conjuntamente probabilidad y consecuencia.

8.1.2. Preferencias y teoría de utilidad

Una relación de preferencia $\geq$ expresa que una consecuencia o lotería se considera al menos tan deseable como otra. Se escribe $x > y$ si x se prefiere estrictamente a y , y $x \sim y$ si existe indiferencia. La teoría de utilidad representa numéricamente preferencias coherentes; no descubre por sí sola qué debería valorar una institución.

En contextos inciertos, una **lotería** asigna probabilidades a consecuencias. Bajo axiomas como completitud, transitividad, continuidad e independencia, existe una función U tal que las preferencias entre loterías se representan por su utilidad esperada. Completitud exige poder comparar alternativas; transitividad impide ciclos como $x > y$, $y > z$ y $z > x$; continuidad descarta saltos extremos; independencia establece una forma precisa de consistencia al mezclar loterías. Estos axiomas son modelos normativos y pueden no describir perfectamente el comportamiento humano.

La escala de utilidad de von Neumann-Morgenstern es única salvo transformaciones afines positivas. Si U representa las preferencias, $U'(x) = \alpha U(x) + \beta$, con $\alpha > 0$, representa las mismas. Por ello, el cero y la unidad son convencionales, y no es válido comparar diferencias de utilidad obtenidas con escalas construidas independientemente para personas distintas.

Cuando hay múltiples atributos, por ejemplo costo C , interrupción D y daño ambiental E , puede formularse $U(C, D, E)$. Una suma ponderada,

$$U(C, D, E) = w_C u_C(C) + w_D u_D(D) + w_E u_E(E),$$

solo es justificable bajo condiciones de independencia preferencial. Los pesos no son meramente “importancias”: dependen de las escalas de los atributos y de los intercambios aceptables. Las restricciones legales o de seguridad no deben convertirse sin reflexión en pequeñas penalizaciones. Si una consecuencia es inadmisibles, puede excluirse del conjunto factible antes de optimizar.

Para elicitar utilidad se pueden comparar consecuencias ciertas con loterías de referencia. Si el decisor es indiferente entre una consecuencia x y una lotería que entrega el mejor resultado con probabilidad p y el peor con probabilidad $1 - p$, normalizando sus utilidades a 1 y 0 se obtiene $U(x) = p$. El procedimiento debe documentar quién respondió, con qué información y bajo qué responsabilidad.

8.1.3. Utilidad esperada

Si la alternativa a induce probabilidades $P(s | a)$, su utilidad esperada es

$$EU(a) = \sum_{s \in S} P(s | a) U(c(a, s)).$$

La regla de utilidad esperada selecciona

$$a^* \in \arg \max_{a \in A} EU(a).$$

El símbolo $\arg \max$ devuelve una o varias alternativas; un empate requiere una regla adicional. Si se trabaja con costos y la utilidad es $U(c) = -c$, maximizar utilidad equivale a minimizar costo esperado.

Supóngase que la probabilidad de fuga grave es 0,20. Reparar cuesta 32 si hay fuga y 28 si no la hay; esperar cuesta 120 o 2, respectivamente. Los costos esperados son

$$EC(a_1) = 0,20(32) + 0,80(28) = 28,8,$$

$$EC(a_3) = 0,20(120) + 0,80(2) = 25,6.$$

Con utilidad lineal en dinero, esperar es preferible pese a que la pérdida posible sea mucho mayor. La comparación no afirma que esperar sea universalmente correcto: depende de 0,20, de los costos incluidos y de la linealidad. Si el costo de una falla excluye sanciones, daño ambiental o pérdida de vidas, el cálculo está incompleto.

El **análisis de sensibilidad** pregunta cuándo cambia la decisión. Si $p = P(s_1)$, reparar tiene costo $28 + 4p$, mientras esperar tiene $2 + 118p$. Son iguales cuando

$$28 + 4p = 2 + 118p \implies p^* = \frac{26}{114} \approx 0,228.$$

Por encima de ese umbral conviene reparar bajo los supuestos del modelo; por debajo conviene esperar. Informar el umbral suele ser más útil que comunicar una recomendación sin contexto. También permite apreciar si una pequeña imprecisión probabilística podría invertir la decisión.

La esperanza es una media de largo plazo o una valoración coherente de una lotería, no una promesa sobre un caso individual. Tampoco elimina la incertidumbre. Debe acompañarse de escenarios extremos, distribución de consecuencias y restricciones de tolerancia.

8.1.4. Actitudes frente al riesgo

Para riqueza final w , una utilidad lineal indica neutralidad al riesgo; una utilidad cóncava, $U''(w) < 0$, aversión; y una utilidad convexa, $U''(w) > 0$, propensión. Con utilidad cóncava y una lotería W , la desigualdad de Jensen establece

$$U(\mathbb{E}[W]) \geq \mathbb{E}[U(W)].$$

El **equivalente cierto** CE satisface $U(CE) = \mathbb{E}[U(W)]$. Para una persona adversa al riesgo, $CE < \mathbb{E}[W]$. La diferencia $\mathbb{E}[W] - CE$ es la prima máxima que estaría dispuesta a pagar para eliminar el riesgo.

Considérese una riqueza de 100 y $U(w) = \sqrt{w}$. Una lotería entrega riqueza 100 con probabilidad 0,8 y 0 con probabilidad 0,2. Su utilidad esperada es $0,8\sqrt{100} + 0,2\sqrt{0} = 8$, por lo que $CE = 8^2 = 64$. Aunque la riqueza esperada es 80, la lotería se valora como 64 bajo esa función.

La aversión al riesgo no equivale a pesimismo ni a asignar más probabilidad a eventos adversos. Las probabilidades describen creencias; la curvatura describe

preferencias. Tampoco toda organización debe usar una utilidad cóncava sobre costos agregados: una entidad grande puede diversificar pérdidas financieras, pero no “diversificar” muertes o daños irreversibles. En seguridad se combinan a menudo utilidad esperada, restricciones duras, medidas de riesgo de cola y criterios robustos.

Entre esas medidas se encuentra el valor en riesgo, VaR_α , un cuantil de pérdida, y el valor en riesgo condicional, $CVaR_\alpha$, que resume pérdidas en la cola más desfavorable. El primero puede ocultar la severidad más allá del cuantil; el segundo es más informativo sobre extremos, pero depende igualmente de un modelo probabilístico fiable.

Error frecuente. Modificar probabilidades “para reflejar prudencia” mezcla creencias con preferencias. Es más transparente conservar probabilidades calibradas y representar prudencia mediante utilidad, restricciones o una medida de riesgo explícita.

8.1.5. Árboles de decisión

Un árbol de decisión ordena cronológicamente elecciones e incertidumbres. Los nodos de decisión se representan convencionalmente con cuadrados, los nodos aleatorios con círculos y las hojas con consecuencias. Cada rama aleatoria lleva una probabilidad condicional; las ramas que parten del mismo nodo deben sumar uno.

La evaluación se realiza **de derecha a izquierda**. En un nodo aleatorio se calcula utilidad esperada. En un nodo de decisión se conserva la rama de mayor utilidad esperada. Este proceso, llamado repliegue o *rollback*, produce una estrategia contingente: no solo la primera acción, sino qué hacer después de cada observación posible.

Pseudocódigo: repliegue de un árbol

```

FUNCIÓN VALOR(nodo)
  SI nodo es una hoja
    DEVOLVER utilidad de su consecuencia
  SI nodo es aleatorio
    total <- 0
    PARA CADA rama del nodo
      total <- total + probabilidad(rama) * VALOR(hijo(rama))
    DEVOLVER total
  SI nodo es de decisión
    evaluar VALOR(hijo) para cada acción factible
    registrar una acción que alcance el valor máximo
    DEVOLVER el valor máximo
FIN FUNCIÓN

```

El orden importa. “Inspeccionar y luego reparar si el resultado es positivo” es diferente de “reparar y luego inspeccionar”: la segunda observación ya no puede mejorar la primera acción. Asimismo, las probabilidades posteriores a un resultado de prueba deben calcularse mediante Bayes, no confundirse con sensibilidad o especificidad.

Los árboles son especialmente claros para pocas etapas, pero crecen exponencialmente cuando aumentan observaciones y decisiones. Además, repetir el mismo estado

por caminos distintos duplica subproblemas. Los procesos de decisión de Markov compactan esa repetición al representar estados y reutilizar sus valores.

Antes de calcular, conviene auditar el árbol: ¿todas las acciones son realmente factibles?, ¿cada incertidumbre aparece después de la información que la condiciona?, ¿las hojas contienen todas las consecuencias relevantes?, ¿se han normalizado probabilidades?, ¿una misma cantidad se contó dos veces? Un diagrama visualmente impecable puede formalizar mal el problema.

8.1.6. Valor de la información

La información tiene valor instrumental: vale porque permite elegir mejor. El **valor esperado de la información perfecta** (VEIP) compara decidir después de observar exactamente el estado con decidir sin esa observación:

$$VEIP = \sum_s P(s) \max_a U(c(a, s)) - \max_a \sum_s P(s) U(c(a, s)).$$

En una formulación de costos,

$$VEIP = \min_a \mathbb{E}[C(a, S)] - \mathbb{E}[\min_a C(a, S)].$$

El VEIP es no negativo y constituye un límite superior para pagar por cualquier prueba imperfecta acerca del mismo estado. No es el valor de eliminar físicamente la incertidumbre, sino el de conocer su realización antes de actuar.

Para una prueba con resultado Y , el **valor esperado de la información muestral** (VEIM) es

$$VEIM = \sum_y P(y) \max_a \sum_s P(s | y) U(c(a, s)) - \max_a \sum_s P(s) U(c(a, s)).$$

La prueba conviene si su valor neto, $VEIM - C_{prueba}$, es positivo y si satisface restricciones de tiempo y seguridad. Una prueba gratuita puede tener valor cero si nunca cambia la acción. Del mismo modo, una prueba muy precisa puede llegar demasiado tarde.

Con los costos de la sección 8.1.3 y $p = 0,20$, sin información se espera y el costo es 25,6. Con información perfecta se repara ante fuga y se espera sin fuga: $0,2(32) + 0,8(2) = 8$. Por tanto, $VEIP = 25,6 - 8 = 17,6$ u.c. Ninguna inspección orientada únicamente a identificar ese estado debería pagarse por encima de 17,6 u.c. bajo este modelo.

Errores frecuentes. Restar el costo de la prueba dos veces; usar $P(y | s)$ como si fuera $P(s | y)$; y valorar información con una acción posterior fijada de antemano. La esencia del cálculo es volver a optimizar después de cada resultado.

8.1.7. Ejemplo práctico guiado: decisión de inspección y reemplazo de un transformador

Una empresa opera un transformador cuyo estado real no se observa directamente. Puede existir una falla interna relevante, F , con probabilidad previa $P(F) = 0,20$, o el equipo puede estar sano, $\neg F$. La decisión inmediata es reemplazarlo, esperar

y mantenerlo en servicio, o inspeccionarlo por 4 u.c. Si se inspecciona, el resultado es positivo o negativo y luego se elige entre reemplazar y esperar.

Los costos, expresados en unidades comparables, incorporan intervención, indisponibilidad y daño esperado:

Acción	Falla F	Sin falla $\neg F$
Reemplazar	32	28
Esperar	120	2

Tomando utilidad monetaria $U = -C$, maximizar utilidad esperada equivale a minimizar costo esperado. Sin inspección,

$$EC(\text{reemplazar}) = 0,2(32) + 0,8(28) = 28,80,$$

$$EC(\text{esperar}) = 0,2(120) + 0,8(2) = 25,60.$$

Por tanto, con la creencia previa conviene esperar. Si $p = P(F)$, reemplazar pasa a ser preferible cuando

$$28 + 4p < 2 + 118p, \quad p > \frac{26}{114} \approx 0,228.$$

La inspección tiene sensibilidad $P(+ | F) = 0,90$ y tasa de falsos positivos $P(+ | \neg F) = 0,10$. Las probabilidades de sus observaciones son

$$P(+) = 0,9(0,2) + 0,1(0,8) = 0,26, \quad P(-) = 0,74.$$

La regla de Bayes actualiza la creencia sobre la falla:

$$P(F | +) = \frac{0,9(0,2)}{0,26} \approx 0,6923,$$

$$P(F | -) = \frac{0,1(0,2)}{0,74} \approx 0,0270.$$

El resultado positivo supera el umbral de 0,228, mientras que el negativo queda por debajo. La regla posterior óptima es entonces reemplazar tras + y esperar tras -. Antes de sumar el precio de la prueba, los costos condicionales son

$$EC(\text{reemplazar} | +) = 28 + 4(0,6923) = 30,769,$$

$$EC(\text{esperar} | -) = 2 + 118(0,0270) = 5,189.$$

Así, el costo esperado de inspeccionar y actuar según el resultado es

$$EC(\text{inspeccionar}) = 4 + 0,26(30,769) + 0,74(5,189) = 15,84.$$

Estrategia inicial	Regla posterior	Costo esperado
Reemplazar ahora	no aplica	28,80
Esperar	no aplica	25,60
Inspeccionar	reemplazar si +; esperar si -	15,84

La información muestral vale, antes de pagarla, $25,60 - (15,84 - 4) = 13,76$ u.c. Su valor neto es $13,76 - 4 = 9,76$ u.c.; por eso la inspección es la mejor decisión inicial. Con información perfecta se reemplazaría ante falla y se esperaría en caso contrario, con costo $0,2(32) + 0,8(2) = 8$. El VEIP es $25,60 - 8 = 17,60$ u.c., mayor que el valor de la prueba imperfecta.

La recomendación depende de los supuestos. Si la prueba demora y el deterioro puede avanzar durante ese lapso, debe agregarse esa consecuencia. Si una falla plantea un riesgo no compensable, la utilidad monetaria esperada deja de ser el único criterio. También deben verificarse la validez de sensibilidad y especificidad para este tipo de equipo, la disponibilidad del repuesto y la capacidad de ejecutar el reemplazo indicado por cada observación.

8.2. Procesos de decisión de Markov

En una decisión secuencial, la acción actual altera las situaciones futuras. Un proceso de decisión de Markov (MDP, por sus siglas en inglés) finito puede definirse mediante la tupla

$$\mathcal{M} = (S, \mathcal{A}, P, R, \gamma, \rho_0),$$

donde S es el espacio de estados, $\mathcal{A}$ el de acciones, P el modelo de transición, R el de recompensa, γ el factor de descuento y ρ_0 la distribución inicial. En horizonte finito también se especifica el número de etapas H . Algunas convenciones incorporan estados terminales o acciones dependientes del estado.

8.2.1. Propiedad de Markov

Sea la historia hasta el tiempo t , $H_t = (S_0, A_0, R_1, \dots, S_t)$. La propiedad de Markov afirma que, condicionado al estado y la acción actuales, el siguiente resultado no depende de la historia completa:

$$P(S_{t+1}, R_{t+1} | H_t, A_t) = P(S_{t+1}, R_{t+1} | S_t, A_t).$$

No significa que el pasado sea irrelevante. Significa que toda información del pasado necesaria para predecir el futuro y valorar decisiones ha sido resumida en S_t . Por ejemplo, “nivel actual del depósito” quizá no sea suficiente si el desgaste acumulado de una bomba cambia su probabilidad de falla. Incorporar una categoría de desgaste puede restaurar aproximadamente la propiedad.

El carácter markoviano depende de la representación, no solo del sistema físico. Una observación parcial puede no ser un estado. Si el operador ve presión pero no el daño oculto de la tubería, dos historias con igual presión pueden tener futuros distintos. El marco apropiado sería entonces un MDP parcialmente observable,

donde se decide a partir de una creencia sobre estados ocultos, o bien un MDP aproximado cuya limitación debe declararse.

La propiedad también suele acompañarse de **estacionariedad**: P y R no cambian con t . Son supuestos diferentes. Un proceso puede ser markoviano y tener demanda estacional. Agregar hora, día o estación al estado puede representar esa variación; si las dinámicas cambian por envejecimiento o clima no observado, el entorno es no estacionario.

Una prueba empírica de Markov perfecta rara vez es posible. Se examina si variables históricas aportan predicción residual una vez condicionado el estado, se consulta conocimiento del dominio y se analiza el desempeño fuera de muestra. Un estado demasiado pequeño pierde información; uno excesivamente detallado agrava el costo computacional y la escasez de experiencia en cada combinación.

8.2.2. Estados, acciones y transiciones

El estado $s \in \mathcal{S}$ debe ser suficiente para decidir. En un depósito simplificado podría ser nivel bajo (B), medio (M) o alto (A). Las acciones podrían ser apagar (0) o encender (1) una bomba. No todas las acciones tienen que ser factibles en todos los estados; $\mathcal{A}(s)$ representa las disponibles.

La dinámica se expresa mediante

$$P(s' | s, a) = P(S_{t+1} = s' | S_t = s, A_t = a),$$

con $P(s' | s, a) \geq 0$ y $\sum_{s'} P(s' | s, a) = 1$. Para espacios finitos, cada acción puede asociarse con una matriz de transición. La fila corresponde al estado actual y la columna al siguiente.

Estado y acción	Próximo B	Próximo M	Próximo A
B, apagar	0,8	0,2	0,0
B, encender	0,2	0,7	0,1
M, apagar	0,6	0,4	0,0
M, encender	0,1	0,6	0,3
A, apagar	0,1	0,7	0,2
A, encender	0,0	0,2	0,8

La incertidumbre puede provenir de demanda, clima, medición o fallas. Una transición determinista es el caso especial en que una probabilidad vale uno. La tabla debe reflejar el intervalo temporal elegido: las probabilidades por hora no se usan directamente como probabilidades diarias.

Estimar P a partir de datos históricos requiere atender al sesgo de política. Si la organización siempre enciende la bomba cuando el nivel es bajo, habrá poca evidencia sobre “B, apagar”. Además, los registros observacionales pueden mezclar acciones con condiciones no incluidas en el estado. Una transición aprendida describe asociaciones condicionadas; interpretarla como efecto de intervenir exige supuestos causales.

Error frecuente. Definir como estado la identificación única de cada registro. Eso permite memorizar, pero no generalizar ni reutilizar valores. El estado debe

agrupar situaciones equivalentes para la decisión sin borrar diferencias predictivas relevantes.

8.2.3. Recompensas

La recompensa R_{t+1} es la señal numérica recibida tras actuar. El modelo puede especificar su esperanza como

$$r(s, a, s') = \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a, S_{t+1} = s']$$

o como $r(s, a)$ cuando no se necesita distinguir s' . Una recompensa positiva no es necesariamente dinero y una penalización puede representarse como recompensa negativa. Cambiar todos los signos transforma maximización de recompensa en minimización de costo, pero mezclar ambas convenciones dentro del cálculo produce errores.

En el depósito, una recompensa posible es “servicio menos energía y desgaste”:

$$r(s, a, s') = -c_{\text{energía}}(a) - c_{\text{desgaste}}(s, a) - c_{\text{servicio}}(s').$$

Una penalización alta por llegar a B expresa la importancia de evitar desabastecimiento. Sin embargo, la recompensa es una **representación** del objetivo, no el objetivo mismo. Debe distinguir indicadores sustitutivos, como nivel del depósito, de resultados finales, como continuidad segura y equitativa del servicio.

Las recompensas densas aparecen con frecuencia y facilitan atribuir mérito; las escasas ocurren solo al alcanzar un objetivo o terminar un episodio. Una señal densa mal construida puede incentivar mantener el indicador sin resolver el problema. Una señal escasa dificulta aprender qué acciones tempranas contribuyeron al resultado.

En tareas continuas, sumar una constante a cada recompensa puede cambiar preferencias si los episodios tienen longitudes distintas, aunque en un problema continuo descontado con longitud fija no cambie la política óptima bajo ciertos supuestos. Escalar recompensas tampoco es inocuo para la estabilidad numérica de algoritmos de aprendizaje. La unidad, el rango y la frecuencia deben documentarse.

No deben ocultarse restricciones críticas mediante penalizaciones arbitrarias. Si está prohibido superar una presión, el conjunto de acciones o un mecanismo de seguridad puede excluir esa conducta. Una penalización finita podría ser compensada por otras recompensas y permitir una violación.

8.2.4. Políticas

Una **política** especifica cómo actuar. Una política determinista estacionaria es una función $\pi : \mathcal{S} \rightarrow \mathcal{A}$. Una política estocástica asigna una distribución:

$$\pi(a \mid s) = P(A_t = a \mid S_t = s), \quad \sum_a \pi(a \mid s) = 1.$$

Por ejemplo, una política determinista puede encender en B y M, y apagar en A. Una política estocástica podría encender en M con probabilidad 0,7. La

aleatorización es útil para explorar, resolver ciertos problemas con restricciones o evitar predictibilidad frente a otros agentes; no es sinónimo de indecisión.

Una política abierta fija una secuencia de acciones sin observar estados. Una política de realimentación condiciona cada acción al estado observado y suele ser más robusta frente a perturbaciones. En horizonte finito, la política óptima puede depender del tiempo restante, $\pi_t(a | s)$: con una etapa pendiente puede no valer la pena encender una bomba, aunque sí con muchas etapas.

El objetivo habitual es hallar π^* que maximice el retorno esperado desde todos los estados o desde una distribución inicial. Puede haber varias políticas óptimas. La política calculada solo tiene sentido para las acciones, estados, recompensas y horizonte modelados. Si en operación se impone una regla externa que modifica acciones, la política ejecutada difiere de la evaluada.

Evaluar una política exige especificar también su **cobertura**: en qué estados es válida y qué hace ante estados desconocidos. Una tabla incompleta no es una política desplegable. En sistemas reales se añaden reglas de abstención, intervención humana y retorno a un modo seguro.

8.2.5. Horizonte y factor de descuento

El retorno desde el tiempo t acumula recompensas futuras. Para horizonte finito H ,

$$G_t = \sum_{k=0}^{H-t-1} \gamma^k R_{t+k+1}.$$

Para horizonte infinito descontado,

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}, \quad 0 \leq \gamma < 1.$$

El factor γ reduce el peso matemático de recompensas lejanas y, con recompensas acotadas, garantiza que la suma infinita sea finita. También puede modelar preferencia temporal o probabilidad de que el proceso continúe. No debe elegirse solo porque “el algoritmo converge”: su interpretación afecta la política.

El horizonte puede ser episódico, con un estado terminal, o continuo, como la operación permanente de una red. En tareas episódicas con terminación segura se puede usar $\gamma = 1$. En procesos continuos también existe el criterio de recompensa promedio a largo plazo, que no equivale siempre al criterio descontado.

La escala temporal importa. Si γ_d es descuento diario, un descuento horario coherente satisface aproximadamente $\gamma_h^{24} = \gamma_d$. Usar el mismo número al cambiar el paso temporal altera el horizonte efectivo. Una interpretación práctica es que el peso cae a la mitad después de

$$h_{1/2} = \frac{\log(0,5)}{\log(\gamma)}$$

etapas. Con $\gamma = 0,9$, la semivida es unas 6,58 etapas; con 0,99, unas 68,97.

Un descuento pequeño favorece resultados inmediatos y puede inducir miopía; uno cercano a uno propaga efectos lejanos, pero aumenta sensibilidad a errores del modelo y suele ralentizar convergencia. Los impactos intergeneracionales o irreversibles no deberían devaluarse automáticamente mediante un parámetro técnico sin deliberación ética.

8.2.6. Funciones de valor

La función de valor de estado bajo una política π es el retorno esperado al comenzar en s y seguir π :

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s].$$

La función de valor de acción es

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a],$$

donde la primera acción se fija en a y luego se sigue π . Se relacionan mediante

$$V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s, a).$$

Las funciones óptimas son $V^*(s) = \max_\pi V^\pi(s)$ y $Q^*(s, a) = \max_\pi Q^\pi(s, a)$. Una política codiciosa respecto de Q^* elige una acción en $\arg \max_a Q^*(s, a)$.

El valor no es una propiedad intrínseca del estado. Depende de recompensa, horizonte, descuento y política. Un depósito bajo puede tener valor moderado si existe una bomba fiable y energía barata, o muy negativo si la recuperación es lenta. Comparar valores de modelos con escalas de recompensa distintas carece de significado directo.

El **valor de ventaja**,

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s),$$

indica cuánto mejora o empeora una acción respecto del promedio de la política en ese estado. Esta descomposición es importante en métodos más avanzados, pero también ofrece una lectura operacional: identifica dónde cambiar la acción tendría mayor efecto.

Una estimación de valor puede ser precisa en estados frecuentes y deficiente en estados raros. Reportar solo el promedio bajo ρ_0 puede esconder fallas críticas. Es necesario examinar valores, incertidumbre y acciones por subgrupos de estados relevantes.

8.2.7. Ecuaciones de Bellman

La idea central de Bellman es descomponer el retorno en recompensa inmediata más valor del futuro. Para una política π ,

$$V^\pi(s) = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^\pi(s')].$$

En términos de valores de acción,

$$Q^\pi(s, a) = \sum_{s'} P(s' | s, a) \left[r(s, a, s') + \gamma \sum_{a'} \pi(a' | s') Q^\pi(s', a') \right].$$

Las ecuaciones de optimalidad sustituyen el promedio de acciones futuras por la mejor elección:

$$V^*(s) = \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V^*(s')],$$

$$Q^*(s, a) = \sum_{s'} P(s' | s, a) \left[r(s, a, s') + \gamma \max_{a'} Q^*(s', a') \right].$$

Estas expresiones son ecuaciones de punto fijo, no simples definiciones circulares. El operador óptimo de Bellman T , definido por el lado derecho, es una contracción en norma suprema cuando $\gamma < 1$:

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty.$$

Por ello existe un único punto fijo V^* y aplicar repetidamente T converge hacia él en el caso tabular finito.

Errores frecuentes. Maximizar por separado para cada estado siguiente, como si se pudiera elegir la acción antes de conocer s' ; omitir la probabilidad de transición; usar recompensa de s cuando fue definida sobre s' ; y descontar también la recompensa inmediata. La cronología debe estar explícita.

8.2.8. Ejemplo práctico guiado: control secuencial de un sistema simplificado

Considérese una batería que se revisa al comienzo de cada período. Su estado de carga se resume como bajo B o suficiente S , y el controlador elige cargar C o esperar E . El estado siguiente depende del consumo incierto y de la eficacia de la carga. La siguiente tabla especifica el modelo:

Estado	Acción	$P(B s, a)$	$P(S s, a)$	$r(s, a)$
B	E	0,8	0,2	-8
B	C	0,2	0,8	-4
S	E	0,3	0,7	0
S	C	0,1	0,9	-3

Las recompensas son negativas porque representan costos. Cargar cuesta electricidad: 4 u.c. en B y 3 u.c. en S , por diferencias en duración y tarifa esperada. Esperar en B genera una penalización esperada de 8 u.c. por indisponibilidad; esperar en S no tiene costo inmediato. Las probabilidades ya resumen consumo y pérdidas durante el período.

Sea $\gamma = 0,9$ y considérese la política π que carga en B y espera en S . Sus ecuaciones de Bellman son

$$V^{\pi}(B) = -4 + 0,9[0,2V^{\pi}(B) + 0,8V^{\pi}(S)],$$

$$V^{\pi}(S) = 0 + 0,9[0,3V^{\pi}(B) + 0,7V^{\pi}(S)].$$

Reordenando,

$$0,82V^{\pi}(B) - 0,72V^{\pi}(S) = -4,$$

$$-0,27V^{\pi}(B) + 0,37V^{\pi}(S) = 0.$$

La solución es aproximadamente $V^{\pi}(B) = -28,92$ y $V^{\pi}(S) = -21,10$. Aunque esperar en S tiene recompensa inmediata cero, su valor es negativo porque el consumo puede llevar la batería a B en un período posterior.

Para evaluar una desviación puntual en S ,

$$Q^{\pi}(S, C) = -3 + 0,9[0,1(-28,92) + 0,9(-21,10)] \approx -22,70.$$

Como $Q^{\pi}(S, E) = V^{\pi}(S) \approx -21,10$, esperar es mejor en S . En B , la alternativa de esperar produce

$$Q^{\pi}(B, E) = -8 + 0,9[0,8(-28,92) + 0,2(-21,10)] \approx -32,61,$$

valor inferior al de cargar, $-28,92$. Ninguna desviación de una etapa mejora la política, de modo que, para este MDP, cargar en B y esperar en S es óptimo.

El ejemplo muestra por qué no basta comparar costos inmediatos: cargar en S reduce la probabilidad de llegar a B , pero ese beneficio futuro no compensa 3 u.c. de electricidad. Una penalización mayor por indisponibilidad, una tarifa más barata o una dinámica distinta podrían cambiar la acción. Antes de aplicar el modelo deben comprobarse degradación de la batería, límites térmicos, potencia disponible y variación horaria de precios; las restricciones críticas deben representarse como acciones no factibles y no solo como costos.

8.3. Resolución de procesos de decisión

Cuando P y R son conocidos, la programación dinámica aprovecha la estructura recursiva de Bellman. Evaluar una política responde “¿qué rendimiento tendrá esta regla?”. Mejorarla responde “¿qué acción sería preferible según esos valores?”. Iteración de políticas alterna ambas tareas; iteración de valores las combina mediante actualizaciones óptimas.

8.3.1. Evaluación de políticas

Para una política fija, la ecuación de Bellman puede escribirse matricialmente:

$$\mathbf{v}_\pi = \mathbf{r}_\pi + \gamma P_\pi \mathbf{v}_\pi, \quad \mathbf{v}_\pi = (I - \gamma P_\pi)^{-1} \mathbf{r}_\pi.$$

La solución directa requiere almacenar y resolver un sistema lineal. Para muchos estados se usa evaluación iterativa:

$$V_{k+1}(s) = \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V_k(s')].$$

Pseudocódigo: evaluación iterativa de una política

inicializar $V(s)$ arbitrariamente para estados no terminales

REPETIR

 cambio_máximo $\leftarrow$ 0

 PARA CADA estado s

 anterior $\leftarrow V(s)$

$V(s) \leftarrow$ promedio de recompensa inmediata más valor descontado
 según la política y las transiciones desde s

 cambio_máximo $\leftarrow$ máximo(cambio_máximo, $|$ anterior - $V(s)|$)

HASTA QUE cambio_máximo sea menor que la tolerancia

DEVOLVER V

Las actualizaciones pueden ser síncronas, usando una copia de V_k , o en el lugar, reutilizando valores recién calculados. Ambas convergen bajo condiciones estándar, aunque con velocidades diferentes. El orden de barrido puede importar para eficiencia, no para el punto fijo.

Detenerse cuando $\|V_{k+1} - V_k\|_\infty < \varepsilon$ controla el residuo entre iteraciones. No debe confundirse con error exacto, aunque la contracción permite establecer cotas. Una tolerancia excesivamente estricta desperdicia cómputo si P , R y los datos ya contienen mayor incertidumbre.

Evaluar también puede hacerse mediante simulación cuando el modelo es generativo, pero entonces aparece error muestral. La programación dinámica exacta realiza expectativas sobre todos los sucesores y presupone acceso al modelo completo.

8.3.2. Mejora de políticas

El teorema de mejora de políticas establece que, si para todo estado se elige una acción codiciosa respecto de V^π , la nueva política π' no es peor:

$$\pi'(s) \in \arg \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V^\pi(s')].$$

Entonces $V^{\pi'}(s) \geq V^\pi(s)$ para todo s . Si la acción actual ya maximiza en todos los estados, π satisface la ecuación de optimalidad y es óptima.

La mejora considera una desviación de una etapa seguida por la política anterior. Aunque parezca local, el valor $V^\pi(s')$ resume todas las consecuencias futuras, por

lo que la comparación no es miope. Después de cambiar acciones, se evalúa la nueva política para propagar los efectos.

Los empates requieren cuidado. Cambiar repetidamente entre acciones de igual valor puede dificultar detectar estabilidad. Una regla determinista, por ejemplo conservar la acción previa cuando está entre las máximas, evita oscilaciones artificiales. En problemas con restricciones, el máximo solo se toma sobre $\mathcal{A}(s)$.

Error frecuente. Mejorar con respecto a recompensas inmediatas $r(s, a)$ en lugar de $Q^\pi(s, a)$. Esa estrategia codiciosa de una etapa puede agotar recursos o desplazar costos al futuro. Otro error es usar valores aproximados como si garantizaran mejora exacta; con error de aproximación, una diferencia pequeña entre acciones puede no ser significativa.

8.3.3. Iteración de políticas

La iteración de políticas alterna evaluación y mejora hasta que la política no cambia.

```

inicializar una política factible pi
REPETIR
    evaluar pi para obtener V_pi
    estable <- verdadero
    PARA CADA estado s
        acción_anterior <- pi(s)
        pi(s) <- una acción factible que maximice
            la recompensa esperada más el valor futuro descontado
        SI pi(s) difiere de acción_anterior
            estable <- falso
HASTA QUE estable
DEVOLVER pi y V_pi

```

En un MDP finito descontado hay un número finito de políticas deterministas estacionarias. Cada mejora estricta produce una política mejor; por ello el procedimiento termina en una política óptima, suponiendo evaluación exacta y tratamiento consistente de empates.

La **iteración de políticas modificada** no evalúa cada política hasta convergencia. Ejecuta pocos barridos y vuelve a mejorar. Así interpola entre iteración de políticas e iteración de valores. Puede reducir trabajo cuando una evaluación muy precisa es innecesaria en etapas tempranas.

El costo por iteración de una evaluación exacta puede ser alto, pero el número de cambios de política suele ser pequeño en muchos problemas. No existe una superioridad universal frente a iteración de valores. Importan la dispersión de transiciones, la facilidad de resolver sistemas, el descuento y la precisión requerida.

Una política estable dentro del modelo no implica estabilidad operacional. Si pequeñas variaciones de costos cambian muchas acciones, la recomendación es frágil. Debe repetirse el cálculo sobre escenarios plausibles y reportar estados donde la acción depende de supuestos inciertos.

8.3.4. Iteración de valores

La iteración de valores aplica directamente el operador óptimo:

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V_k(s')].$$

inicializar $V(s)$ arbitrariamente para estados no terminales

REPETIR

cambio_máximo <- 0

PARA CADA estado s

anterior <- $V(s)$

$V(s)$ <- máximo, sobre acciones factibles, de
recompensa esperada más valor futuro descontado

actualizar cambio_máximo con $|\text{anterior} - V(s)|$

HASTA QUE se satisfaga el criterio de parada

PARA CADA estado s

$\pi(s)$ <- una acción codiciosa respecto de V

DEVOLVER π y V

Puede interpretarse como evaluación truncada y mejora en cada barrido. Si $V_0 = 0$, las primeras iteraciones incorporan consecuencias progresivamente más lejanas, aunque con descuento y ciclos la interpretación exacta requiere cuidado.

La política debe extraerse usando un barrido codicioso coherente con el valor final. Detenerse porque la política no cambia puede ser suficiente para la decisión, aun si los valores continúan ajustándose. A la inversa, un residuo pequeño no garantiza que acciones casi empatadas sean robustas frente a error del modelo.

Para estados terminales se fija normalmente $V = 0$ después de incorporar la recompensa de entrada. Contar además una recompensa terminal en cada permanencia dentro del estado absorbente duplica beneficios o costos. La convención temporal debe declararse.

La iteración de valores requiere conocer las transiciones de todas las acciones. No es aprendizaje por refuerzo libre de modelos. Puede usarse sobre un modelo estimado, pero entonces su exactitud numérica no elimina el error de estimación.

8.3.5. Convergencia y costo computacional

En MDP finitos con $\gamma < 1$, la contracción de Bellman garantiza

$$\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty.$$

Si las recompensas están acotadas por $|R| \leq R_{\max}$ y $V_0 = 0$, entonces $\|V^*\|_\infty \leq R_{\max}/(1 - \gamma)$. Cuando γ se aproxima a uno, la cota empeora y se necesitan más iteraciones.

Para una representación densa, un barrido de Bellman cuesta aproximadamente $O(|S|^2|\mathcal{A}|)$, porque cada par estado-acción suma sobre todos los sucesores. Si cada par tiene a lo sumo d sucesores, el costo baja a $O(|S||\mathcal{A}|d)$. Almacenar transiciones densas requiere $O(|S|^2|\mathcal{A}|)$. La estructura dispersa es decisiva.

La “maldición de la dimensionalidad” surge cuando el estado combina variables. Diez variables con diez niveles producen 10^{10} estados. Discretizar más finamente

aumenta fidelidad local, pero hace inviable enumerar y reduce datos por celda. La aproximación de funciones aborda parte del problema, a costa de perder garantías tabulares simples y de introducir generalización potencialmente errónea.

Convergencia numérica no es validez. Un algoritmo puede converger exactamente a la política óptima de un modelo equivocado. Deben distinguirse al menos cuatro fuentes de error: especificación de objetivo, representación del estado, estimación de P y R , y aproximación computacional. La última suele ser la más fácil de medir y no necesariamente la más importante.

Otras limitaciones son memoria, comunicación en sistemas distribuidos, latencia de decisión y cambios del entorno. La política óptima calculada fuera de línea puede quedar obsoleta. La revisión periódica debe basarse en indicadores de cambio y no solo en un calendario.

8.3.6. Ejemplo práctico guiado: selección de una política operativa

Una empresa debe fijar una regla operativa para cargar su flota eléctrica. Al inicio de cada franja horaria, el estado agregado es bajo B si pocos vehículos tienen autonomía suficiente para los próximos servicios, y suficiente S en caso contrario. Las acciones son cargar C o esperar E . Para concentrar el análisis en la resolución, se usan las transiciones y recompensas de la sección 8.2.8: la penalización de -8 representa indisponibilidad esperada y los valores -4 y -3 representan electricidad.

Se aplica iteración de valores con $\gamma = 0,9$ y $V_0(B) = V_0(S) = 0$. En el primer barrido solo influyen las recompensas inmediatas:

$$V_1(B) = \max\{-8, -4\} = -4, \quad V_1(S) = \max\{0, -3\} = 0.$$

En el segundo barrido ya se incorpora el efecto sobre la franja siguiente:

$$V_2(B) = \max\{-8 + 0,9[0,8(-4) + 0,2(0)], -4 + 0,9[0,2(-4) + 0,8(0)]\} = -4,72,$$

$$V_2(S) = \max\{0 + 0,9[0,3(-4) + 0,7(0)], -3 + 0,9[0,1(-4) + 0,9(0)]\} = -1,08.$$

Las acciones codiciosas son cargar en B y esperar en S . Los valores continúan bajando a medida que se incorporan costos futuros y convergen aproximadamente a $V^*(B) = -28,92$ y $V^*(S) = -21,10$. La política seleccionada es, por tanto,

$$\pi^*(B) = C, \quad \pi^*(S) = E.$$

La evaluación tiene una interpretación operativa: cuando la autonomía agregada es baja, pagar electricidad evita una probabilidad alta de indisponibilidad; cuando es suficiente, la carga adicional no justifica su costo. Los valores no son el costo de una única franja, sino el retorno descontado de ejecutar la regla repetidamente.

Conviene comprobar si la política es sensible al precio de cargar en S . Sea c ese costo. Manteniendo por el momento el futuro de la política calculada,

$$Q(S, C) = -c + 0,9[0,1V(B) + 0,9V(S)].$$

El punto de indiferencia frente a esperar satisface

$$-c + 0,9[0,1(-28,92) + 0,9(-21,10)] = -21,10,$$

de donde $c \approx 1,40$. Con costo 3 se espera; si una tarifa reducida llevara el costo por debajo de aproximadamente 1,40, cargar en S podría ser preferible. Este cálculo identifica una frontera local: si la acción cambia de forma permanente, hay que resolver otra vez las ecuaciones porque también cambia el valor futuro.

La sensibilidad debe extenderse a la penalización por vehículos no disponibles y a las probabilidades estimadas. Si pequeñas variaciones alteran la acción, la recomendación es frágil y requiere mejor estimación o una regla conservadora. La entrega técnica debe declarar franja temporal, criterio de parada, valores residuales y acciones casi empatadas. Antes del despliegue se prueban picos de demanda, errores del estado de carga, límites de potencia, degradación y vehículos fuera de servicio; cualquier acción físicamente inadmisibles se elimina del conjunto factible antes de volver a resolver el MDP.

8.4. Aprendizaje por refuerzo

El aprendizaje por refuerzo (RL) estudia agentes que aprenden a actuar a partir de interacción y recompensas. A diferencia del aprendizaje supervisado, no recibe para cada estado una etiqueta con la acción correcta. Las acciones influyen en datos futuros, las recompensas pueden demorarse y explorar una opción modifica tanto el conocimiento como el desempeño.

El bucle básico es: el agente observa S_t , elige A_t , el entorno produce R_{t+1} y S_{t+1} , y el agente actualiza su conocimiento. El problema formal puede ser un MDP, pero los algoritmos difieren en si conocen el modelo, esperan al final del episodio, aprenden sobre la conducta ejecutada o sobre una política objetivo distinta.

8.4.1. Aprendizaje basado en modelos y libre de modelos

Un método **basado en modelos** dispone de, estima o aprende $P(s' | s, a)$ y $r(s, a, s')$. Luego planifica con ese modelo, por ejemplo mediante iteración de valores. También puede combinar experiencia real con transiciones simuladas. Su ventaja es reutilizar cada observación para considerar varias políticas y anticipar resultados; su riesgo es explotar errores del modelo.

Un método **libre de modelos** aprende valores o políticas sin construir explícitamente toda la dinámica. Q-learning estima Q^* ; SARSA estima el valor de la política de conducta mientras esta evoluciona. “Libre de modelos” no significa libre de supuestos: sigue suponiendo estados adecuados, recompensa representativa, cierta estabilidad y experiencia suficiente.

Otra distinción es entre métodos **basados en valor**, que derivan la política de valores; **basados en política**, que optimizan parámetros de la política directamente; y actor-crítico, que combina un actor con un estimador de valor. Este capítulo desarrolla los primeros en espacios discretos.

Enfoque	Qué aprende	Uso de experiencia	Riesgo característico
Modelo conocido + planificación	valores/política	expectativas del modelo	modelo mal especificado
Modelo aprendido + planificación	dinámica y política	datos reales y simulación	sesgo acumulado al simular
Libre de modelos	valores o política	transiciones observadas	baja eficiencia muestral

La elección depende del costo de interacción. Si existe un simulador físico fiable, un enfoque basado en modelos puede ser eficiente. Si las dinámicas son difíciles pero se dispone de abundante interacción segura, uno libre de modelos puede ser práctico. En sistemas críticos, aprender directamente en operación suele ser inaceptable; se combinan datos históricos, simulación, límites y validación humana.

8.4.2. Exploración frente a explotación

Explotar es elegir la acción con mayor valor estimado; **explorar** es probar acciones para reducir incertidumbre o descubrir mejores resultados. Explotación prematura consolida una estimación posiblemente errónea. Exploración excesiva incurre en costo y puede impedir un desempeño estable.

Una regla ε -codiciosa elige una acción codiciosa con probabilidad $1 - \varepsilon$ y una acción al azar con probabilidad ε . Si la selección aleatoria incluye la acción codiciosa, su probabilidad total es $1 - \varepsilon + \varepsilon/|\mathcal{A}(s)|$. Reducir ε con el tiempo favorece explotación; reducirlo demasiado rápido puede dejar acciones sin aprender.

Otras estrategias asignan probabilidades suaves según valores, añaden bonos por incertidumbre o mantienen intervalos de confianza. La exploración dirigida es más eficiente que el azar cuando se puede cuantificar incertidumbre. En cualquier caso, “probar todo” no es una obligación moral ni técnica: las acciones inseguras deben excluirse.

Para convergencia tabular de muchos métodos se requiere que cada par estado-acción relevante se visite repetidamente y que las tasas de aprendizaje disminuyan de forma apropiada. Esta condición asintótica rara vez se cumple literalmente en una operación finita y cambiante. Por eso, la cobertura debe medirse: conteos de visitas, distribución de estados y desempeño por regiones.

Existe además aprendizaje fuera de línea, que intenta aprender de un conjunto fijo. Allí no se puede explorar y aparece el problema de extrapolación: valorar acciones escasamente representadas requiere inferencias frágiles. Una política nueva puede elegir precisamente esas acciones porque sus errores estimados parecen favorables. Se necesitan métodos conservadores y evaluación fuera de política.

Error frecuente. Evaluar una política exploratoria por su recompensa de entrenamiento sin separar el costo de explorar ni medir una política final. La conducta usada para aprender y la política destinada a operar pueden ser distintas.

8.4.3. Métodos Monte Carlo

Los métodos Monte Carlo aprenden de episodios completos sin modelo. Para una visita al par (s, a) en el tiempo t , calculan el retorno observado

$$G_t = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-t-1} R_T$$

y actualizan una media o una estimación incremental:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[G_t - Q(S_t, A_t)].$$

En Monte Carlo de **primera visita** se usa solo la primera aparición de un estado o par en el episodio; en **cada visita** se usan todas. Ambos convergen bajo condiciones estándar, aunque sus muestras están correlacionadas dentro del episodio.

inicializar Q y una política exploratoria

PARA CADA episodio

 generar un episodio siguiendo la política

 calcular hacia atrás el retorno de cada instante

 PARA CADA visita seleccionada de un par estado-acción

 acercar $Q(\text{estado}, \text{acción})$ al retorno observado

 mejorar la política para favorecer acciones con Q mayor,

 conservando exploración suficiente

DEVOLVER política y Q

Monte Carlo no introduce sesgo de arranque porque usa retornos reales completos, pero puede tener varianza alta. Además, debe esperar al final y se adapta naturalmente a tareas episódicas. En episodios muy largos o sin terminación, el método básico es poco práctico.

La cobertura puede obtenerse mediante “inicios exploratorios”, que suponen poder comenzar en cualquier par estado-acción, o mediante políticas blandas que asignan probabilidad positiva a las acciones. El primer supuesto rara vez es realista en sistemas físicos.

Una recompensa final ruidosa atribuye el mismo retorno general a muchas decisiones, lo que dificulta identificar mérito. Promediar reduce varianza con más episodios, pero no corrige confusión por estados omitidos ni sesgo de datos recolectados bajo otra política.

8.4.4. Aprendizaje por diferencias temporales

El aprendizaje por diferencias temporales (TD) combina muestreo de experiencia con **arranque**: actualiza una estimación usando otra estimación antes de terminar el episodio. TD(0) para evaluar una política usa

$$V(S_t) \leftarrow V(S_t) + \alpha \delta_t,$$

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t).$$

δ_t es el error TD. Si el estado siguiente es terminal, su valor se toma como cero. La actualización ocurre tras cada transición, por lo que TD sirve en tareas continuas y aprende en línea.

Monte Carlo apunta a G_t , una muestra completa generalmente no sesgada del retorno bajo la política; TD(0) apunta a $R_{t+1} + \gamma V(S_{t+1})$, que depende de una estimación y puede ser sesgada. A cambio, suele tener menor varianza y propaga información sin esperar.

Los retornos de n pasos intermedian entre ambos:

$$G_t^{(n)} = R_{t+1} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V(S_{t+n}).$$

Las trazas de elegibilidad TD(λ) mezclan escalas temporales y asignan crédito a estados recientes. Un λ cercano a cero se parece a TD(0); cercano a uno se aproxima a Monte Carlo bajo ciertas condiciones.

La tasa α controla cuánto pesa la observación nueva. Una tasa constante permite adaptarse a cambios, pero mantiene variabilidad; una secuencia decreciente facilita convergencia en entornos estacionarios. Una tasa grande junto con aproximación de funciones puede causar oscilaciones o divergencia.

El error TD es una señal de aprendizaje, no necesariamente una anomalía ni una medida directa de calidad de la política. Puede ser alto por recompensa aleatoria, transición rara o estimación deficiente. Su análisis requiere contexto.

8.4.5. Q-learning

Q-learning es un método TD de control libre de modelos y fuera de política. Actualiza

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right].$$

La política de conducta puede ser ε -codiciosa, pero el objetivo usa la mejor acción estimada en el siguiente estado. Por ello aprende sobre una política codiciosa mientras ejecuta otra exploratoria.

inicializar Q para todos los pares factibles

PARA CADA episodio

 observar estado inicial s

 MIENTRAS s no sea terminal

 elegir a con una política de conducta exploratoria derivada de Q

 ejecutar a y observar recompensa r y siguiente estado s_{nuevo}

 objetivo $\leftarrow r$ si s_{nuevo} es terminal;

 en otro caso, $r + \text{descuento} * \text{máximo } Q(s_{\text{nuevo}}, \text{acción})$

$Q(s, a) \leftarrow Q(s, a) + \text{tasa} * (\text{objetivo} - Q(s, a))$

$s \leftarrow s_{\text{nuevo}}$

DEVOLVER una política codiciosa respecto de Q

En el caso tabular, con recompensas acotadas, visitas suficientes y tasas que cumplen condiciones de aproximación estocástica, Q-learning converge a Q^* . Estas garantías no se trasladan automáticamente a redes neuronales, datos finitos o entornos no estacionarios.

El operador máximo produce sesgo de sobreestimación: entre estimaciones ruidosas tiende a seleccionar errores positivos. Variantes de doble estimación reducen ese efecto separando selección y evaluación. La inicialización optimista puede estimular exploración tabular, pero es ineficaz si estados no se revisitan o si la escala está mal elegida.

Q-learning puede aprender una política que atraviesa estados peligrosos durante entrenamiento porque su objetivo es codicioso, aunque la conducta explore. La seguridad debe imponerse a la conducta real, no confiarse al valor objetivo futuro.

8.4.6. SARSA

SARSA recibe su nombre de la secuencia $(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$. Su actualización es

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)].$$

Es un método **en política**: la acción siguiente usada en el objetivo procede de la misma política de conducta. Si esta es ε -codiciosa, SARSA valora también las consecuencias de sus errores exploratorios. Q-learning, en cambio, valora la continuación codiciosa.

```

inicializar Q
PARA CADA episodio
  observar s y elegir a según la política exploratoria
  MIENTRAS s no sea terminal
    ejecutar a; observar r y s_nuevo
    SI s_nuevo no es terminal
      elegir a_nueva según la misma política exploratoria
      objetivo <- r + descuento * Q(s_nuevo, a_nueva)
    EN OTRO CASO
      objetivo <- r
    actualizar Q(s,a) hacia objetivo
    s <- s_nuevo; a <- a_nueva
DEVOLVER la política deseada derivada de Q

```

En una tarea con un camino corto junto a una zona de gran penalización, Q-learning puede preferir el borde porque supone acciones futuras codiciosas; una conducta exploratoria, sin embargo, puede desviarse y caer. SARSA suele aprender una ruta más alejada mientras $\varepsilon > 0$, porque incorpora ese riesgo. No significa que SARSA sea siempre “más seguro”: si la política de conducta permite acciones catastróficas, también las ejecutará para aprender.

Si ε disminuye hasta cero con exploración suficiente, ambos pueden converger a una política óptima en condiciones tabulares. Con ε persistente, SARSA optimiza el desempeño de esa política blanda, mientras Q-learning apunta a la codiciosa. La comparación experimental debe declarar tanto política de entrenamiento como de evaluación.

8.4.7. Diseño de recompensas

Diseñar recompensas es especificar qué comportamiento se incentiva. Una señal incompleta puede producir **manipulación de la recompensa**: el agente

encuentra un atajo que aumenta el indicador sin cumplir la intención. Si se recompensa solo el nivel alto de un depósito, podría bombear continuamente, desperdiciar energía o superar presiones seguras.

Un proceso disciplinado comienza con resultados deseados, daños inaceptables y actores afectados; después identifica medidas observables y comprueba cómo podrían ser explotadas. Conviene separar:

Elemento	Ejemplo	Tratamiento posible
Objetivo	continuidad del servicio	retorno acumulado
Costo operativo	energía y desgaste	término de recompensa
Restricción dura	presión máxima	filtro de acciones
Indicador sustituto	nivel del depósito	señal auxiliar auditada
Preferencia distributiva	evitar barrios desatendidos	criterio explícito por grupos

El moldeado potencial añade

$$F(s, a, s') = \gamma \Phi(s') - \Phi(s)$$

a la recompensa. Bajo condiciones conocidas, acelera el aprendizaje sin cambiar las políticas óptimas. Bonificaciones arbitrarias no ofrecen esa garantía y pueden redefinir la tarea.

Las escalas relativas importan. Una penalización de seguridad “grande” puede no serlo frente a miles de recompensas pequeñas acumuladas. Se deben calcular retornos máximos plausibles y probar escenarios adversariales. También hay que evitar recompensar acciones en vez de resultados si eso induce actividad innecesaria.

Las preferencias cambian y son objeto de gobernanza. Versionar la recompensa, documentar responsables y conservar evaluaciones por componente permite saber por qué cambió una política. Una recompensa única no resuelve desacuerdos éticos. En decisiones públicas, eficiencia, equidad y derechos requieren deliberación, restricciones y rendición de cuentas.

Error frecuente. Ajustar recompensas hasta que una demostración se vea razonable y declarar éxito. Ese procedimiento sobreajusta escenarios conocidos. La evaluación debe incluir casos no usados en el diseño, perturbaciones y búsqueda deliberada de atajos.

8.4.8. Seguridad, estabilidad y límites de aplicación

Un agente puede causar daño durante entrenamiento, al desplegarse o cuando el entorno cambia. La seguridad no se reduce a una recompensa promedio alta. Debe medir violaciones, colas de pérdida, peor caso plausible, recuperación y efectos sobre grupos vulnerables.

Entre las salvaguardas se encuentran: restringir acciones; usar un supervisor que sustituya decisiones inseguras; entrenar primero en simulación; limitar velocidad de cambio; desplegar gradualmente; detectar estados fuera de distribución;

permitir abstención; mantener anulación humana; registrar transiciones; y definir retorno a una política segura. Cada mecanismo necesita pruebas independientes.

La estabilidad tiene varias dimensiones. El aprendizaje puede oscilar por tasas altas, objetivos móviles o aproximación de funciones. La política puede ser sensible a pequeñas variaciones de observación. El entorno puede reaccionar estratégicamente o cambiar por estacionalidad. Un promedio estable no descarta alternancia perjudicial de acciones, como encendidos y apagados que aceleran desgaste.

La llamada tríada mortal combina aproximación de funciones, arranque y aprendizaje fuera de política; su interacción puede producir divergencia. Incluso cuando la pérdida de entrenamiento disminuye, los valores pueden estar mal calibrados. Las garantías tabulares no deben citarse para justificar sistemas complejos sin verificar sus condiciones.

RL no es apropiado cuando no hay decisiones secuenciales significativas, cuando una regla simple resuelve el problema, cuando la interacción es escasa o no ética, cuando no puede medirse el objetivo, o cuando la organización carece de capacidad para monitorear. Predicción más optimización restringida, control clásico, investigación operativa o supervisión humana pueden ser mejores alternativas.

Persisten limitaciones de causalidad, observabilidad, transferencia de simulación a realidad, eficiencia muestral, reproducibilidad y explicabilidad. Además, una política aprende dentro de instituciones: puede desplazar trabajo, concentrar riesgos y modificar incentivos. La aprobación debe considerar responsabilidad legal, participación de afectados y mecanismos de apelación.

Una lista mínima antes del despliegue pregunta: ¿qué acciones nunca debe realizar?, ¿cómo se detecta una observación inválida?, ¿qué política actúa si falla el agente?, ¿quién puede detenerlo?, ¿qué datos permiten auditar una decisión?, ¿qué cambio activa reentrenamiento o retirada? Si estas respuestas no existen, mejorar la recompensa media no convierte el sistema en aceptable.

8.4.9. Ejemplo práctico guiado: entrenamiento de un agente en un entorno discreto

Considérese una cuadrícula de 4×4 . El agente comienza en la esquina inferior izquierda y debe llegar a una estación de control en la superior derecha. Cada movimiento cuesta -1 , llegar aporta $+20$, entrar en una celda de riesgo aporta -15 y termina el episodio. Las acciones son norte, sur, este y oeste; chocar con un borde deja al agente en el mismo estado. Una franja de riesgo hace que el camino más corto pase cerca de consecuencias graves.

El experimento conceptual compara Q-learning y SARSA con igual inicialización, tasa, descuento y regla ε -codiciosa. La unidad experimental no es un episodio aislado, sino una ejecución completa con semilla independiente. Se separan entrenamiento y evaluación: durante evaluación se fija una política codiciosa, sin actualizaciones, y se prueban también perturbaciones.

Protocolo

1. Definir estados, acciones factibles, terminales, recompensas y convención temporal.

2. Fijar $\gamma = 0,95$, una tasa inicial y un calendario de exploración declarado.
3. Entrenar ambos métodos durante el mismo presupuesto de transiciones, no solo igual número de episodios.
4. Repetir con múltiples semillas y conservar curvas individuales.
5. Evaluar retorno, tasa de llegada, longitud de ruta, entradas en riesgo y peor retorno.
6. Inspeccionar la política en cada celda y no solo la recompensa acumulada.
7. Repetir con ruido de actuación: con probabilidad 0,05 se ejecuta un movimiento lateral.

Se espera que Q-learning tienda al camino nominal más corto junto al riesgo porque su objetivo presupone futuras acciones codiciosas. SARSA, mientras explora, puede valorar el peligro de desviación y aprender una ruta más separada. Con exploración reducida a cero y suficientes visitas, las políticas pueden acercarse. Bajo ruido permanente, la ruta prudente puede seguir teniendo mejor desempeño real.

Métrica	Pregunta que responde	Insuficiencia si se usa sola
Retorno medio	¿qué utilidad promedio obtiene?	oculta colas y fallas
Tasa de éxito	¿con qué frecuencia llega?	ignora costo y longitud
Entradas en riesgo	¿viola seguridad?	no mide eficiencia
Cuantil 5 %	¿cómo son casos desfavorables?	no explica su causa
Pasos por episodio	¿qué tan directa es la ruta?	favorece atajos peligrosos

No debe inferirse convergencia porque una media móvil se aplana. Se revisan cambios de política, dispersión entre semillas y cobertura de pares estado-acción. Tampoco es válido seleccionar la mejor semilla. Si una acción riesgosa es inaceptable, se elimina mediante una restricción en lugar de permitir que el agente la pruebe para descubrir su penalización.

El ejemplo evidencia una tensión esencial: el algoritmo aprende exactamente de la experiencia y del objetivo que se le proporcionan. Una cuadrícula es útil para entender actualizaciones, pero no demuestra seguridad en redes físicas, donde estados son continuos, observaciones fallan y las acciones tienen inercia. La progresión responsable va de pruebas unitarias del entorno a simulación adversarial, evaluación fuera de muestra, piloto supervisado y despliegue reversible.

Síntesis del capítulo

La teoría de decisión separa lo controlable de lo incierto y conecta creencias con preferencias. Las probabilidades describen estados; la utilidad valora consecuencias. La utilidad esperada permite comparar loterías, la curvatura representa actitudes frente al riesgo y los árboles ordenan decisiones e información. El valor de información mide cuánto mejora una decisión por observar antes de actuar, no cuánto resulta interesante un dato.

Los MDP extienden esa lógica a secuencias. Un estado resume la historia relevante; las transiciones describen dinámica; las recompensas formalizan el objetivo; una política prescribe acciones; y horizonte y descuento determinan cómo se acumula

el futuro. Las funciones de valor condensan consecuencias de largo plazo y Bellman expresa su recursión.

Con modelo conocido, evaluación, mejora, iteración de políticas e iteración de valores permiten planificar. Sus garantías dependen de finitud, descuento, exactitud y representación. Con modelo desconocido, Monte Carlo aprende de retornos completos y TD aprende por arranque. Q-learning es fuera de política; SARSA es en política. Ningún algoritmo repara un estado insuficiente o una recompensa mal diseñada.

El aprendizaje por refuerzo introduce una tensión inevitable entre conocer y rendir. Explorar tiene costo y puede ser peligroso. Por ello, seguridad, restricciones, evaluación por escenarios y gobernanza no son complementos posteriores, sino parte de la formulación. La solución técnicamente óptima es siempre óptima respecto de un modelo y un objetivo declarados; la responsabilidad profesional consiste en examinar ambos y reconocer lo que queda fuera.

Errores de razonamiento que deben evitarse

Error	Por qué falla	Corrección
Elegir por el estado más probable	ignora magnitud de consecuencias	calcular utilidad sobre todos los estados
Tratar costo esperado como costo seguro	borra dispersión y extremos	reportar distribución, colas y restricciones
Confundir sensibilidad con posterior	invierte condicionamiento	aplicar Bayes con prevalencia
Considerar una observación como estado	puede faltar memoria relevante	probar suficiencia y ampliar representación
Optimizar recompensa inmediata	desplaza costos al futuro	usar retorno y valor
Descontar dos veces	altera la escala temporal	fijar una convención de retorno
Declarar válido porque convergió	solo prueba estabilidad numérica	validar modelo, objetivo y datos
Llamar "sin supuestos" a un método libre de modelos	aún depende de estado y entorno	explicitar hipótesis y cobertura
Explorar acciones prohibidas	aprender su peligro ya causa daño	restringir y supervisar acciones
Evaluar con episodios de entrenamiento	mezcla exploración y selección	usar protocolo de evaluación separado

Glosario esencial

Acción o alternativa. Intervención que el decisor puede elegir.

Actitud frente al riesgo. Forma en que la utilidad valora dispersión alrededor de una consecuencia esperada.

Arranque (*bootstrapping*). Actualización de una estimación a partir de otra estimación, como en TD.

Consecuencia. Resultado relevante producido por una acción bajo un estado.

Descuento. Peso γ aplicado progresivamente a recompensas futuras.

Entorno. Sistema que recibe acciones y produce estados y recompensas.

Estado. Resumen de información suficiente para predecir y decidir bajo el modelo.

Estado terminal. Estado que finaliza un episodio.

Explotación. Elección de acciones estimadas como mejores.

Exploración. Elección orientada a obtener información sobre acciones o estados.

Función de valor. Retorno esperado desde un estado, o desde un par estado-acción, bajo una política.

Horizonte. Cantidad de etapas consideradas o naturaleza continua del proceso.

MDP. Modelo de decisión secuencial con estados, acciones, transiciones, recompensas y criterio temporal.

Política. Regla determinista o probabilística que asigna acciones a estados.

Propiedad de Markov. Independencia del futuro respecto de la historia una vez conocidos estado y acción actuales.

Recompensa. Señal numérica inmediata que contribuye al retorno.

Retorno. Suma, posiblemente descontada, de recompensas futuras.

Transición. Distribución del próximo estado condicionada al estado y acción actuales.

Utilidad. Representación numérica de preferencias coherentes.

Valor de información. Mejora esperada de la decisión posibilitada por observar información antes de actuar.

Autoevaluación

1. ¿Por qué “fuga” es un estado y “costo de esperar ante una fuga” es una consecuencia?
2. ¿Qué supuestos permiten representar preferencias mediante utilidad esperada?
3. Calcule el umbral de probabilidad que iguala dos alternativas con costos $(20, 8)$ y $(60, 2)$ en los estados adverso y normal.
4. Explique la diferencia entre aversión al riesgo y asignar alta probabilidad a un daño.
5. ¿Por qué el valor de una prueba puede ser cero aunque sea exacta?
6. Formule el VEIP en términos de minimización de costos e interprete cada término.
7. ¿Qué información histórica debería incorporarse al estado de una bomba cuyo riesgo depende de horas acumuladas de uso?
8. Distinga propiedad de Markov de estacionariedad.
9. ¿Por qué una recompensa no es necesariamente el objetivo real?

10. Compare política abierta, política de realimentación y política estocástica.
11. ¿Cómo cambia el horizonte efectivo cuando γ pasa de 0,9 a 0,99?
12. Derive la ecuación de Bellman para Q^π a partir de la definición de retorno.
13. ¿Qué diferencia hay entre evaluación y mejora de una política?
14. ¿Por qué la iteración de valores no es un método libre de modelos?
15. Enumere las cuatro fuentes de error distinguidas en la sección de convergencia.
16. Compare el blanco de actualización de Monte Carlo con el de TD(0).
17. ¿En qué sentido Q-learning es fuera de política y SARSA es en política?
18. ¿Por qué una curva de recompensa estable no demuestra convergencia segura?
19. Proponga un atajo no deseado para una recompensa basada solo en cantidad de agua bombeada.
20. Mencione tres situaciones en las que no usaría aprendizaje por refuerzo.

Actividad integradora de cierre

Situación. Una organización administra dos bombas que abastecen un depósito. La demanda tiene niveles bajo, medio y alto; el precio de energía varía; una bomba presenta desgaste; y una inspección puede revelar con error si requiere mantenimiento. La organización desea evitar interrupciones, controlar energía y no superar límites de presión.

Producto. Elaborar un informe técnico reproducible, sin implementar todavía un agente, que conecte una decisión de inspección con una política secuencial.

1. Definir alternativas iniciales, estados de naturaleza y consecuencias multiatributo de inspeccionar, mantener o esperar.
2. Proponer probabilidades previas y desempeño de la inspección, justificando su origen.
3. Construir el árbol de decisión, calcular posteriores, utilidad esperada, VEIP y VEIM, y realizar sensibilidad sobre dos parámetros.
4. Formular un MDP posterior a la decisión inicial: estado, acciones factibles, transiciones, recompensas, horizonte, descuento y distribución inicial.
5. Justificar por qué el estado propuesto es aproximadamente markoviano e identificar variables ocultas.
6. Escribir las ecuaciones de Bellman de una política base para al menos dos estados.
7. Ejecutar manualmente dos barridos de iteración de valores sobre un subconjunto pequeño y extraer acciones codiciosas.
8. Diseñar un protocolo conceptual para comparar Q-learning y SARSA, incluyendo exploración, presupuesto y múltiples semillas.
9. Separar objetivo, indicadores sustitutos y restricciones duras; proponer dos posibles fallas de especificación de recompensa.
10. Definir métricas de desempeño, seguridad, equidad y estabilidad, además de criterios de suspensión.

Criterios de evaluación. La representación distingue creencias de preferencias; los cálculos respetan condicionamiento y cronología; el MDP es internamente coherente; las recompensas no sustituyen restricciones críticas; la comparación experimental separa entrenamiento de evaluación; y las conclusiones declaran sensibilidad, límites y condiciones de despliegue. Se valorará más una formulación

pequeña y auditable que un modelo extenso cuyos parámetros no puedan justificarse.

Capítulo 9. Formulación y evaluación de problemas de aprendizaje automático

Un sistema de aprendizaje automático no comienza con la elección de un algoritmo, sino con una pregunta precisa: **¿qué regularidad debe aprenderse, a partir de qué información y para apoyar qué decisión?** La formulación transforma una necesidad del mundo real en unidades observables, entradas, resultados esperados y criterios de éxito. La evaluación, a su vez, intenta responder con evidencia si el sistema funcionará sobre casos que todavía no ha visto. Ambas tareas son inseparables: una métrica impecablemente calculada no corrige una etiqueta que representa mal el objetivo, ni una arquitectura sofisticada compensa una partición contaminada.

Este capítulo presenta el vocabulario y el razonamiento experimental necesarios para formular y evaluar problemas de aprendizaje. Primero distingue paradigmas y tipos de tarea; después relaciona pérdida, ajuste y generalización; a continuación diseña particiones que respetan la estructura de los datos; finalmente estudia métricas de regresión y clasificación. El hilo conductor es que el desempeño no es una propiedad absoluta del modelo. Es una estimación condicionada por una población, un horizonte, una muestra, un protocolo, una métrica y una regla de decisión.

9.1. Paradigmas de aprendizaje

Un paradigma especifica de dónde procede la señal con la que aprende un modelo. No debe confundirse con una familia algorítmica: una red neuronal puede entrenarse de forma supervisada, autosupervisada o semisupervisada; un método basado en distancias puede servir para clasificación supervisada o para agrupamiento no supervisado. Tampoco todo problema de datos requiere aprendizaje automático. Si una regla estable, auditable y suficientemente precisa resuelve la tarea, esa regla puede ser preferible.

9.1.1. Aprendizaje supervisado

En aprendizaje supervisado se dispone de observaciones emparejadas

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

donde $\mathbf{x}_i$ reúne las variables de entrada y y_i representa el objetivo conocido. El propósito es aprender una función $f : \mathcal{X} \rightarrow \mathcal{Y}$ que produzca una predicción $\hat{y} = f(\mathbf{x})$ útil para observaciones nuevas. Si y es cuantitativa, suele formularse una regresión; si pertenece a un conjunto de categorías, una clasificación.

«Supervisado» no significa que una persona observa cada paso del entrenamiento. Significa que existe una señal objetivo contra la cual comparar la salida. Esa señal puede proceder de una medición física, un registro administrativo, una anotación experta o un resultado futuro. Su origen determina qué aprende realmente el sistema. Por ejemplo, predecir «hospitalización registrada» no equivale a predecir «gravedad clínica»: intervienen acceso, decisiones médicas y calidad del registro.

Una formulación completa debe declarar la unidad de análisis, el instante de predicción y el horizonte. «Predecir retrasos» es ambiguo; «al momento de la salida programada, predecir si un viaje llegará con más de 15 minutos de retraso» delimita población, información disponible y etiqueta. Las entradas deben existir en ese instante. Incorporar la hora real de llegada produciría una fuga: permitiría reconstruir aquello que se pretende anticipar.

El modelo supervisado aproxima regularidades de la distribución que generó los pares observados. No memoriza una ley universal. Si cambian la población, el proceso de medición o la definición de la etiqueta, puede deteriorarse aun cuando el algoritmo permanezca intacto. Por eso la validez fuera de muestra y el ámbito de aplicación forman parte de la especificación.

9.1.2. Aprendizaje no supervisado

El aprendizaje no supervisado parte de entradas sin una etiqueta objetivo explícita:

$$\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^n.$$

Busca describir estructura: grupos de observaciones parecidas, dimensiones latentes, regiones densas, asociaciones o casos atípicos. El agrupamiento de estaciones por patrones de consumo y la reducción de miles de atributos a unas pocas componentes son ejemplos. «No supervisado» no significa «sin decisiones humanas». La elección de variables, escala, distancia, número de grupos y criterio de interpretación introduce supuestos fuertes.

En ausencia de una verdad objetivo única, evaluar exige especial cautela. Dos particiones distintas pueden ser matemáticamente coherentes y responder a usos diferentes. Un índice interno de cohesión no demuestra que los grupos sean útiles, estables o sustantivamente válidos. Conviene combinar criterios internos, estabilidad ante remuestreo y validación externa por especialistas o por una tarea posterior. Nombrar un grupo después de observar sus rasgos no convierte ese nombre en una clase verdadera.

El análisis no supervisado también puede preceder a una tarea supervisada, por ejemplo para explorar segmentos o construir representaciones. En ese caso, cualquier transformación que use la distribución completa de los datos debe ajustarse solo con la porción de entrenamiento si luego será evaluada predictivamente. La falta de etiquetas no elimina el riesgo de contaminación.

9.1.3. Aprendizaje semisupervisado

El aprendizaje semisupervisado combina un conjunto pequeño de observaciones etiquetadas con otro, normalmente mayor, sin etiquetas:

$$\mathcal{D}_L = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n_L}, \quad \mathcal{D}_U = \{\mathbf{x}_j\}_{j=1}^{n_U}, \quad n_U \gg n_L.$$

Resulta atractivo cuando obtener entradas es barato pero etiquetarlas requiere especialistas, tiempo o pruebas costosas. Un sistema puede aprender primero la geometría de todas las imágenes y después aprovechar las pocas diagnósticamente anotadas. Otros enfoques asignan pseudoetiquetas a predicciones muy confiables o exigen consistencia ante perturbaciones de una misma entrada.

Su beneficio depende de supuestos. Uno frecuente afirma que observaciones cercanas comparten etiqueta; otro, que las fronteras de clase atraviesan zonas de baja densidad. Si los datos no etiquetados proceden de otra población, o si el modelo inicial se equivoca sistemáticamente en una clase minoritaria, las pseudoetiquetas amplifican errores. «Más datos» puede empeorar el resultado cuando su relación con el objetivo es inadecuada.

La evaluación continúa siendo supervisada: validación y prueba necesitan etiquetas fiables y no deben participar en la creación de pseudoetiquetas ni en la selección de confianza. Debe compararse contra un baseline entrenado únicamente con $\mathcal{D}_L$, manteniendo constantes particiones y presupuesto de etiquetado. Así se atribuye la mejora al uso de datos no etiquetados y no a una comparación desigual.

9.1.4. Aprendizaje autosupervisado

En aprendizaje autosupervisado la señal objetivo se deriva de la propia estructura de los datos. Se oculta una parte de una entrada y se predice desde el contexto, se aprende a distinguir vistas relacionadas de no relacionadas o se anticipa un fragmento siguiente. La entrada proporciona tanto el ejemplo como el objetivo pretextual, sin requerir una anotación humana para cada caso.

El objetivo pretextual no suele coincidir con la tarea final. Su función es aprender una representación $h(\mathbf{x})$ que capture regularidades reutilizables. Después puede ajustarse un predictor supervisado con pocas etiquetas para clasificación, regresión u otra tarea. En texto, predecir unidades ocultas puede producir representaciones sensibles al contexto; en imágenes, aproximar vistas transformadas puede capturar forma y contenido visual.

Autosupervisión y semisupervisión no son sinónimos. La primera describe cómo se genera la señal durante una etapa; la segunda, cómo se combinan datos etiquetados y no etiquetados para una tarea objetivo. Un proyecto puede preentrenar autosupervisadamente y luego realizar ajuste supervisado, incluso dentro de un esquema semisupervisado.

Los datos de preentrenamiento pueden contener sesgos, duplicados o ejemplos de prueba. Una representación entrenada con documentos futuros puede violar un experimento temporal, aunque nunca vea explícitamente sus etiquetas. Deben documentarse corpus, fechas y solapamientos. La evaluación final debe corresponder a la tarea y población de destino, no solo al objetivo pretextual.

9.1.5. Regresión, clasificación y agrupamiento

La **regresión** estima una cantidad sobre una escala numérica: demanda, temperatura, duración o concentración. La salida puede ser puntual, $\hat{y}$, o probabilística, como un intervalo o una distribución condicional. Que la etiqueta esté codificada con números no basta para hablar de regresión: códigos postales y categorías 1, 2, 3 siguen siendo cualitativos.

La **clasificación** asigna una o más categorías. Es binaria cuando hay dos clases, multiclase cuando cada caso pertenece a una entre más de dos y multietiqueta cuando varias pueden coexistir. Una salida probabilística $\hat{p}_k = P(Y = k | \mathbf{x})$ permite separar estimación de decisión: primero se estiman puntuaciones o probabilidades y luego una regla determina la acción. Esta distinción será esencial al estudiar umbrales y costos.

El **agrupamiento** construye grupos sin disponer de categorías objetivo. Puede ser particional, jerárquico o permitir pertenencias suaves. Su resultado depende de la representación y de la noción de similitud. No debe evaluarse como clasificación salvo que exista una referencia externa y se resuelva que los grupos intentan recuperarla.

Una necesidad real admite formulaciones alternativas. Para gestionar agua se puede regresar la concentración esperada, clasificar si excederá un límite o agrupar estaciones por perfiles. Cambian las etiquetas, las pérdidas y las decisiones. La elección debe partir de la acción: si el operador necesita asignar capacidad continua, una regresión puede conservar más información; si debe activar un protocolo reglado, una clasificación basada en el umbral puede ser directamente interpretable. Aun así, predecir la cantidad y aplicar después el umbral puede ser mejor si interesa variar ese límite.

9.1.6. Variables de entrada, objetivos y etiquetas

Una **variable de entrada**, atributo o característica es información disponible para producir la predicción. El vector $\mathbf{x} = (x_1, \dots, x_p)$ puede mezclar mediciones numéricas, categorías, texto, imágenes y relaciones. La calidad de una entrada no depende solo de su correlación histórica con el objetivo: debe estar disponible, medirse de forma consistente, ser legítima y conservar significado en el uso previsto.

El **objetivo** es el concepto que interesa anticipar; la **etiqueta** es su representación observable en los datos. Esta diferencia evita confundir un sustituto con el fenómeno. El objetivo podría ser «necesidad de revisión inmediata», pero una etiqueta como «respuesta tardía» no la representa necesariamente. Además, si la respuesta se observa después del ingreso, no puede utilizarse como entrada para decidir al ingreso.

Las etiquetas pueden contener ruido aleatorio, discrepancias entre anotadores o sesgo sistemático. Cuando especialistas discrepan, la incertidumbre no desaparece por mayoría de votos. Conviene documentar instrucciones, acuerdo, procedencia y fecha. En algunos problemas el resultado está censurado o solo se observa para quienes recibieron una intervención; entonces el conjunto etiquetado no es una muestra neutral.

Una ficha de formulación debería responder:

Elemento	Pregunta de control
Unidad	¿Qué representa una fila o ejemplo?
Población	¿Sobre qué casos se pretende usar el sistema?
Entrada	¿Qué se conoce exactamente al predecir?
Objetivo y etiqueta	¿Qué concepto interesa y cómo se observa?
Instante y horizonte	¿Cuándo se predice y hasta cuándo mira el resultado?
Salida	¿Cantidad, clase, probabilidad, grupo o acción?
Error	¿Qué consecuencias tienen los distintos fallos?
Abstención	¿Cuándo debe derivarse el caso a revisión?

Un identificador casi nunca es una entrada legítima. Puede conservarse para trazabilidad y partición. Variables posteriores, agregados calculados con el futuro y codificaciones de la etiqueta son fugas. La pregunta decisiva no es «¿está la columna en el archivo?», sino «¿existiría con el mismo significado al momento de usar el modelo?».

9.1.7. Ejemplo práctico guiado: formulación de cuatro tareas de aprendizaje

Consideremos cuatro dominios que reaparecen en el libro. El propósito no es escoger algoritmos, sino traducir necesidades a tareas verificables.

Dominio	Unidad e instante	Entrada posible	Salida	Formulación
Movilidad	viaje, antes de iniciarse	ruta, calendario, clima disponible, historial anterior	minutos de demora	regresión supervisada
Agua	medición de una estación	variables fisicoquímicas simultáneas y antecedentes	excede/no excede un límite	clasificación supervisada
Reclamos	reclamo CFPB al ingreso	narrativa inicial	Product	clasificación multiclase supervisada
Imágenes vegetales	imagen adquirida	píxeles y metadatos permitidos	representación reutilizable	preentrenamiento autosupervisado; posterior clasificación supervisada

El caso de movilidad exige definir si se predice demora continua o incumplimiento de un umbral. La fecha real de llegada queda excluida. Para agua, si las estaciones producen series repetidas, la evaluación debe considerar dependencia temporal y por estación. En reclamos, una respuesta empresarial posterior no describe lo conocido al ingreso y sería fuga. En imágenes, aprender representaciones

sin diagnóstico no demuestra utilidad clínica o agronómica: la tarea posterior requiere sus propias etiquetas y evaluación.

Podría añadirse una quinta formulación no supervisada: agrupar estaciones de agua por perfiles estacionales. No habría una «etiqueta correcta» por estación; se juzgarían estabilidad, separación, interpretación y utilidad para diseñar muestreos. El mismo dominio admite paradigmas diferentes porque paradigma y objeto de estudio no son equivalentes.

9.2. Ajuste, error y generalización

Entrenar consiste en utilizar datos para elegir una función dentro de un conjunto de candidatos. Evaluar consiste en estimar qué ocurrirá fuera de esos datos. La diferencia entre ambas operaciones parece sencilla, pero organiza casi todo el diseño experimental del aprendizaje automático.

9.2.1. Funciones de pérdida

Una función de pérdida $L(y, \hat{y})$ cuantifica el desacuerdo entre el resultado observado y la predicción para un caso. Es una señal de ajuste, no necesariamente la métrica final del proyecto. Debe ser compatible con la salida del modelo, tratable durante la optimización y razonablemente alineada con el objetivo.

En regresión son habituales la pérdida absoluta y la cuadrática:

$$L_1(y, \hat{y}) = |y - \hat{y}|, \quad L_2(y, \hat{y}) = (y - \hat{y})^2.$$

La segunda penaliza con rapidez los errores grandes y es sensible a valores extremos. La primera crece linealmente y resulta más robusta. Bajo ciertas condiciones, minimizar error cuadrático estima una media condicional y minimizar error absoluto, una mediana condicional. Por tanto, elegir pérdida también define qué aspecto de la distribución se intenta predecir.

En clasificación, la pérdida 0-1 vale 1 cuando la clase es incorrecta y 0 cuando es correcta, pero no distingue grados de confianza y es difícil de optimizar directamente. La entropía cruzada binaria para una probabilidad p es

$$L(y, p) = -[y \log(p) + (1 - y) \log(1 - p)].$$

Asigna gran penalización a errores expresados con confianza extrema. En multiclase, $L = -\sum_k y_k \log(p_k)$ con una codificación indicadora. Una pérdida ponderada puede dar mayor peso a ciertas clases, pero los pesos deben responder a costos o al diseño, no elegirse solo para elevar una cifra.

La pérdida de entrenamiento, la métrica de selección y la utilidad operativa pueden diferir. Un clasificador puede entrenarse con entropía cruzada, seleccionarse por macro-F1 y desplegarse con una política de revisión basada en costos. Esas decisiones deben mantener una relación explícita; de lo contrario, se optimiza una cantidad que no representa el éxito.

9.2.2. Riesgo empírico

El **riesgo esperado** de una función f bajo una distribución poblacional $P(X, Y)$ es

$$R(f) = \mathbb{E}_{(X,Y) \sim P} [L(Y, f(X))].$$

Como P se desconoce, se aproxima mediante el **riesgo empírico** sobre la muestra de entrenamiento:

$$\widehat{R}_{\text{ent}}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

El principio de minimización del riesgo empírico elige, dentro de una familia $\mathcal{F}$, una función con bajo riesgo observado. Con regularización se añade una penalización de complejidad:

$$\hat{f} = \arg \min_{f \in \mathcal{F}} [\widehat{R}_{\text{ent}}(f) + \lambda \Omega(f)].$$

$\Omega(f)$ desalienta soluciones demasiado complejas según una definición concreta y λ controla el compromiso. La penalización no garantiza generalización por sí sola: depende de que la muestra represente el uso futuro y de que la evaluación sea independiente.

El promedio empírico presupone una unidad de muestreo adecuada. Si una persona aporta cien registros casi idénticos y otra uno, promediar por filas da a la primera cien veces más influencia. Puede ser necesario ponderar por entidad, episodio o diseño muestral. Asimismo, minimizar una pérdida promedio puede ocultar desempeño deficiente en subpoblaciones pequeñas.

9.2.3. Error de entrenamiento y error de generalización

El error de entrenamiento se calcula sobre datos empleados para ajustar parámetros. Por construcción suele ser optimista. El error de generalización describe el desempeño esperado sobre nuevos casos de la población objetivo. No puede observarse exactamente; se estima mediante datos no usados en el ajuste.

La **brecha de generalización** puede expresarse como

$$G = \widehat{R}_{\text{eval}}(f) - \widehat{R}_{\text{ent}}(f).$$

Una brecha grande sugiere que el modelo explota peculiaridades del entrenamiento, aunque una brecha pequeña no garantiza buen desempeño: ambos errores pueden ser altos. Además, la estimación de evaluación tiene incertidumbre. Un resultado de 0,82 no es una constante del modelo, sino una estadística de una muestra particular.

«Datos nuevos» debe significar nuevos bajo el escenario declarado. Si el sistema operará el próximo año, una muestra aleatoria de registros del mismo periodo puede ser menos informativa que un corte temporal. Si generalizará a pacientes nuevos, colocar visitas de una misma persona en entrenamiento y prueba sobreestima la capacidad. Generalización siempre requiere completar la frase: a nuevos registros, entidades, lugares, periodos o condiciones.

9.2.4. Sobreajuste y subajuste

Hay **subajuste** cuando el modelo no captura estructura relevante: el error de entrenamiento es alto y el de validación también. Puede deberse a una familia demasiado rígida, entradas poco informativas, exceso de regularización o entrenamiento insuficiente. Añadir datos sin cambiar esas limitaciones no siempre ayuda.

Hay **sobreajuste** cuando el modelo se adapta a fluctuaciones, ruido o particularidades del entrenamiento que no se repiten. El error de entrenamiento sigue disminuyendo mientras el de validación se estanca o empeora. Más capacidad, demasiadas decisiones de hiperparámetros y fugas sutiles aumentan este riesgo. También se sobreajusta la validación: después de cientos de comparaciones, el mejor resultado puede reflejar azar específico de ese conjunto.

Los diagnósticos no deben basarse en una sola cifra. Conviene comparar curvas de entrenamiento y validación, variación entre particiones, desempeño por periodo y errores concretos. Las respuestas posibles incluyen simplificar o regularizar, mejorar atributos, ampliar datos representativos, detener antes el ajuste o reducir la búsqueda. Si la causa es cambio de distribución, regularizar no sustituye una evaluación temporal adecuada.

Un error común consiste en llamar sobreajuste a cualquier desempeño bajo en prueba. También podría existir subajuste, una etiqueta defectuosa, una partición más difícil o deriva real. El diagnóstico compara patrones y formula hipótesis comprobables.

9.2.5. Compromiso entre sesgo y varianza

Para regresión con pérdida cuadrática, y bajo una descomposición idealizada, el error esperado en un punto puede escribirse como

$$\mathbb{E}[(Y - \hat{f}(\mathbf{x}))^2] = \text{Sesgo}[\hat{f}(\mathbf{x})]^2 + \text{Var}[\hat{f}(\mathbf{x})] + \sigma^2.$$

El **sesgo** mide la diferencia sistemática entre la predicción promedio del procedimiento y la función verdadera. La **varianza** mide cuánto cambiaría la predicción si se entrenara con otras muestras de la misma población. σ^2 representa ruido irreducible bajo los supuestos de la descomposición.

Modelos muy rígidos suelen tener sesgo alto y varianza baja; modelos muy flexibles pueden reducir sesgo pero aumentar varianza. No es una ley que obligue a escoger un punto medio fijo: más datos relevantes, mejor regularización o una representación adecuada pueden mejorar ambos componentes. Tampoco el «sesgo» de esta descomposición equivale al sesgo social o de muestreo, aunque pueden coexistir.

La varianza se manifiesta como inestabilidad entre particiones o semillas. Si pequeñas modificaciones de entrenamiento cambian mucho el resultado, una única división ofrece evidencia débil. El sesgo se sospecha cuando incluso el ajuste sobre entrenamiento es insuficiente. Las curvas de aprendizaje ayudan a distinguirlos, pero siempre dentro del dominio observado.

9.2.6. Complejidad del modelo

La complejidad es la capacidad efectiva para representar patrones. No se reduce al número de parámetros: también depende de restricciones, regularización, profundidad, representación de entradas y cantidad de datos. Un modelo con muchos parámetros preentrenados puede comportarse de manera estable al ajustarse poco; uno pequeño con atributos identificadores puede memorizar.

Al aumentar complejidad, el error de entrenamiento normalmente no sube, pero el de validación suele describir una curva con una región óptima. Elegir complejidad es una decisión empírica realizada en validación, no en prueba. Entre alternativas con desempeño indistinguible dentro de la incertidumbre, el modelo más simple puede ofrecer menor costo, mejor auditabilidad y mayor estabilidad.

La complejidad del **proceso de búsqueda** también cuenta. Probar numerosas transformaciones, subconjuntos y semillas equivale a ampliar la familia de hipótesis. Aunque cada modelo individual sea sencillo, escoger el máximo entre muchos resultados puede sobreajustar la validación. Registrar todos los intentos y limitar decisiones posteriores protege la honestidad experimental.

9.2.7. Modelos de referencia o baselines

Un baseline es una referencia sencilla y relevante que establece el nivel mínimo a superar. En regresión puede predecir la media o mediana de entrenamiento; en clasificación, la clase mayoritaria, frecuencias de clase o una regla operativa existente. En series temporales, repetir el último valor o el del mismo periodo anterior suele ser más exigente que una media global.

Debe ajustarse con la misma información permitida y evaluarse en exactamente los mismos casos y métricas. Comparar un modelo complejo en una partición favorable contra un baseline publicado en otra muestra no prueba mejora. Tampoco basta vencer a la clase mayoritaria si existe una regla manual barata y mejor.

Los baselines cumplen tres funciones. Detectan errores de pipeline cuando una solución sofisticada no supera una regla trivial; cuantifican valor incremental; y aportan una alternativa desplegable de bajo costo. Para clases desbalanceadas, la clase mayoritaria puede lograr alta exactitud y macro-F1 muy baja, demostrando por qué una sola métrica engaña. Un baseline aleatorio estratificado puede servir como control adicional, pero debe fijarse su semilla o evaluarse su distribución.

9.2.8. Ejemplo práctico guiado: curvas de aprendizaje

Una curva de aprendizaje representa desempeño de entrenamiento y validación frente al tamaño de la muestra. Para evitar comparaciones confusas, se usan subconjuntos anidados y el mismo protocolo de validación.

ENTRADA: conjunto de desarrollo, tamaños crecientes $m[1..J]$, procedimiento A
PARA cada tamaño $m[j]$:

 PARA cada repetición o partición válida:

 seleccionar $m[j]$ ejemplos solo de la porción de entrenamiento

 ajustar todas las transformaciones y A con esos ejemplos

 medir pérdida en esos ejemplos y en la validación independiente

 resumir media y dispersión de ambas pérdidas

TRAZAR tamaño frente a pérdida de entrenamiento y validación

Supongamos los siguientes errores de clasificación, donde menor es mejor:

Ejemplos	Entrenamiento	Validación
500	0,04	0,24
2 000	0,07	0,17
8 000	0,09	0,13
20 000	0,10	0,12

La brecha disminuye y validación continúa mejorando: más datos representativos probablemente ayuden, aunque con retornos decrecientes. Si ambas curvas se estabilizaran en 0,25, habría indicios de subajuste o entradas insuficientes. Si entrenamiento permaneciera cerca de cero y validación en 0,20, dominaría una brecha compatible con alta varianza, contaminación de categorías raras o cambio entre particiones.

Una curva no identifica automáticamente la causa. Debe acompañarse con intervalos o dispersión, baseline y análisis por clase. Si al aumentar m también se incorporan periodos más recientes, se mezclan tamaño y tiempo; en datos temporales, los subconjuntos deben respetar el orden y la pregunta de generalización.

9.3. Diseño de la evaluación

El diseño de evaluación es un experimento. Su objeto no es producir el número más alto, sino una estimación relevante y reproducible con la menor contaminación posible. Debe escribirse antes de consultar repetidamente los resultados, igual que un protocolo experimental.

9.3.1. Conjuntos de entrenamiento, validación y prueba

El conjunto de **entrenamiento** ajusta parámetros y transformaciones aprendidas: coeficientes, vocabulario, imputación, escalado o selección de atributos. El conjunto de **validación** elige familias, hiperparámetros, umbrales y otras decisiones. El conjunto de **prueba** se reserva para estimar una sola vez el desempeño del procedimiento ya fijado.

Esta separación es funcional, no meramente física. Si se observa prueba y se cambia el modelo, prueba ha pasado a desempeñar el papel de validación. Si se normaliza con la media de todo el archivo antes de dividir, la prueba ya influyó en el entrenamiento. Toda operación que aprende de los datos debe ajustarse dentro de entrenamiento y aplicarse después a validación o prueba.

Un flujo correcto puede expresarse así:

```

definir unidad, población, horizonte, grupos y métrica
reservar PRUEBA sin inspeccionar resultados predictivos
usar ENTRENAMIENTO y VALIDACIÓN para:
    ajustar transformaciones únicamente en ENTRENAMIENTO
    entrenar candidatos
    elegir hiperparámetros y regla de decisión con VALIDACIÓN
fijar procedimiento completo
  
```


reajustar, si estaba previsto, usando datos de desarrollo permitidos evaluar una vez en PRUEBA y reportar incertidumbre y limitaciones

Las proporciones 60/20/20 u 80/10/10 no son universales. Dependen del tamaño, la estructura y la precisión deseada. Prueba debe contener suficientes ejemplos, especialmente de clases poco frecuentes, para estimar métricas con incertidumbre tolerable. En muestras pequeñas puede usarse validación cruzada en el conjunto de desarrollo y conservar una prueba externa.

9.3.2. Muestreo aleatorio y estratificado

Una división aleatoria asigna unidades a subconjuntos mediante azar controlado. Es apropiada cuando las observaciones son aproximadamente intercambiables y el futuro uso se parece a otra muestra de la misma distribución. La aleatorización reduce decisiones arbitrarias, pero no rompe dependencias existentes.

La división **estratificada** conserva aproximadamente la proporción de una variable, normalmente la clase, en cada subconjunto. Resulta útil con clases desbalanceadas para evitar que validación carezca por azar de ejemplos minoritarios. También puede estratificarse por combinaciones relevantes, siempre que haya soporte suficiente. Una estratificación excesivamente fina genera estratos diminutos e inestables.

Ejemplo: con 1 000 incidentes, 900 negativos y 100 positivos, una prueba aleatoria de 100 podría contener por azar pocos positivos. La estratificación 90/10 garantiza alrededor de 10, pero diez casos siguen dando una estimación muy incierta de sensibilidad. Estratificar no crea información; puede ser necesario ampliar prueba o agregar periodos.

Primero debe identificarse la unidad independiente. Dividir filas aleatoriamente es incorrecto si hay mediciones repetidas, duplicados, imágenes del mismo objeto o fragmentos de un mismo documento. En esos casos se asigna el grupo completo, y la estratificación pasa a ser secundaria o aproximada.

9.3.3. Validación cruzada

En validación cruzada de K particiones, el conjunto de desarrollo se divide en K bloques. Cada bloque actúa una vez como validación y los restantes como entrenamiento. Para una métrica M :

$$\overline{M}_{CV} = \frac{1}{K} \sum_{k=1}^K M_k.$$

La dispersión entre M_k informa sensibilidad a la partición, aunque la desviación estándar de los folds no es automáticamente un intervalo de confianza: los entrenamientos se solapan y las estimaciones no son independientes.

Todas las transformaciones deben repetirse dentro de cada fold. Ajustar imputación, escalado, vocabulario o selección de variables antes de la validación cruzada filtra información. El objeto que se valida es el pipeline completo.

crear folds respetando unidad, estratos, grupos o tiempo

PARA cada fold k :

DESARROLLO_ k = todos los folds excepto k

```

VALIDACIÓN_k = fold k
ajustar preprocesamiento con DESARROLLO_k
transformar DESARROLLO_k y VALIDACIÓN_k
entrenar con DESARROLLO_k
calcular métricas en VALIDACIÓN_k
agregar métricas y conservar resultados por fold

```

$K = 5$ o 10 es frecuente, no obligatorio. Más folds aprovechan más datos para cada ajuste pero elevan costo y correlación entre estimaciones. La validación cruzada repetida permite estudiar variación aleatoria. La **validación cruzada anidada** utiliza un ciclo interno para hiperparámetros y uno externo para estimación, reduciendo optimismo cuando no existe prueba abundante. No debe usarse el promedio externo para volver a elegir configuraciones sin reconocer que se reutilizó como validación.

9.3.4. Validación para datos agrupados

Los datos están agrupados cuando varias observaciones comparten una fuente que induce dependencia: persona, hogar, vehículo, estación, empresa, dispositivo, sitio o plantilla. Si registros del mismo grupo aparecen a ambos lados, el modelo puede reconocer al grupo en lugar de aprender una regularidad transferible.

La partición por grupos asigna cada identificador a un único subconjunto. En validación cruzada, cada fold contiene grupos completos. La pregunta estimada es entonces generalización a grupos no vistos. Si el uso real acepta nuevas observaciones de grupos ya conocidos, puede diseñarse otra evaluación, pero debe declararse y quizá incluir ambas: dentro de grupo y fuera de grupo.

Los duplicados exactos y casi duplicados forman grupos de partición aunque no sean entidades naturales. Eliminarlos antes de dividir puede ser válido, pero debe documentarse. Si se conservan para representar frecuencia real, todas sus copias han de permanecer juntas. La detección debe realizarse sin usar la etiqueta como atajo y, cuando corresponda, considerar plantillas con pequeñas variaciones.

Agrupar puede alterar la proporción de clases y producir folds desiguales. No se debe romper grupos para obtener estratificación perfecta. Se buscan asignaciones aproximadas, se reporta soporte por fold y se reconoce la incertidumbre. Un único grupo dominante puede impedir estimar generalización independiente; es una limitación del dato, no un problema que resuelva una semilla distinta.

9.3.5. Validación temporal

Cuando el sistema se entrenará con pasado para operar en futuro, la evaluación debe respetar el tiempo. Un corte simple utiliza fechas tempranas para entrenamiento, un periodo posterior para validación y el más reciente para prueba. Así evita que patrones futuros informen decisiones del pasado y permite observar deriva.

En origen rodante se realizan varios experimentos:

```

ordenar unidades por instante disponible
PARA cada fecha de corte t[k]:
    ENTRENAMIENTO = unidades disponibles hasta t[k]
    VALIDACIÓN = unidades del horizonte posterior definido

```

eliminar o agrupar unidades que cruzan la frontera según el protocolo
ajustar todo con ENTRENAMIENTO y evaluar en VALIDACIÓN
resumir por ventana y periodo; no mezclar el futuro en ajustes anteriores

Debe distinguirse tiempo de entrada, tiempo del resultado y tiempo de disponibilidad. Si una etiqueta tarda 30 días en confirmarse, al corte solo pueden entrenarse casos cuyo resultado ya maduró. Puede requerirse una **brecha** entre entrenamiento y validación para evitar ventanas objetivo solapadas. En pronósticos, el horizonte de evaluación debe coincidir con el operativo.

La estratificación aleatoria no debe imponerse sobre el orden temporal. Que una clase desaparezca en un periodo es información relevante sobre cambio de población. Se reporta soporte y, si el problema deja de ser factible, se revisa la formulación. Tampoco debe escogerse el corte después de mirar cuál produce el mejor resultado.

9.3.6. Selección de modelos e hiperparámetros

Los parámetros se aprenden durante el ajuste; los **hiperparámetros** controlan el procedimiento: fuerza de regularización, profundidad, número de componentes o decisiones de representación. Se seleccionan usando validación o el ciclo interno de validación cruzada.

Antes de buscar se define un espacio plausible, una métrica principal y una regla de desempate. La búsqueda exhaustiva, aleatoria o adaptativa no cambia el principio: cada consulta a validación consume información y aumenta el riesgo de sobreajuste. Deben registrarse configuraciones fallidas, no solo la ganadora.

Si varias configuraciones están cerca, conviene considerar dispersión, costo, latencia, estabilidad por grupo y simplicidad. La regla de «un error estándar», por ejemplo, puede elegir el candidato más simple cuyo desempeño sea compatible con el mejor. No debe proclamarse superioridad a partir de una diferencia minúscula sin cuantificar incertidumbre.

Tras seleccionar, puede reajustarse el procedimiento en entrenamiento más validación antes de prueba, siempre que estuviera previsto y que los hiperparámetros queden congelados. El preprocesamiento también se vuelve a ajustar sobre ese conjunto ampliado. El resultado de prueba evalúa todo el procedimiento fijado, no autoriza otra ronda de selección.

9.3.7. Reproducibilidad y comparación justa

Reproducibilidad significa que otra ejecución, con los mismos datos y decisiones, puede reconstruir el resultado y comprender sus límites. Una semilla es necesaria en procesos aleatorios, pero no suficiente. Deben registrarse versión y procedencia de datos, reglas de inclusión, identificadores de partición, entorno, configuración, orden de transformaciones y definición exacta de métricas.

Una comparación justa mantiene constantes:

- las unidades y particiones;
- la información disponible y el tratamiento de faltantes;
- el presupuesto de búsqueda o, al menos, su transparencia;
- la métrica y regla de selección;
- el conjunto de casos usado para el resultado final.

Reportar únicamente la mejor semilla es selección encubierta. Debe fijarse una semilla o resumir varias ejecuciones predefinidas. La determinación completa puede ser costosa o imposible en ciertos entornos; en ese caso se documentan fuentes de variación.

También importa la trazabilidad conceptual. Cada experimento necesita una hipótesis: «los bigramas mejorarán macro-F1 porque distinguen expresiones compuestas», no «probar opción B». Una tabla de experimentos debe incluir identificador, cambio único, datos, semilla, métrica de validación, costo y observaciones. Comparar versiones que cambian simultáneamente partición, limpieza y modelo impide atribuir diferencias.

9.3.8. Ejemplo práctico guiado: protocolo de evaluación sin contaminación

Supongamos 60 000 registros de incidentes, con 8 % positivos, observaciones repetidas por dispositivo y fechas de dos años. El sistema se desplegará en dispositivos nuevos durante el trimestre siguiente. Una división aleatoria estratificada por filas preservaría el 8 %, pero compartiría dispositivos y mezclaría futuro con pasado: contestaría una pregunta demasiado fácil.

El protocolo apropiado prioriza restricciones:

1. reservar el último trimestre como prueba temporal;
2. asignar cada dispositivo a un único conjunto para medir transferencia a dispositivos no vistos;
3. formar entrenamiento con periodos anteriores y validación con el trimestre inmediatamente anterior a prueba;
4. mantener duplicados y episodios vinculados en el mismo conjunto;
5. ajustar imputación, escalas y cualquier selección solo en entrenamiento;
6. escoger hiperparámetros y umbral en validación mediante una métrica definida;
7. congelar el pipeline y evaluar prueba una vez.

La combinación temporal y grupal puede reducir mucho la muestra y desequilibrar clases. Esa dificultad refleja el uso real. Si ningún dispositivo puede repetirse entre periodos pero muchos existen durante todo el intervalo, se define una cohorte de dispositivos futuros o se evalúan dos escenarios separados. No se debe improvisar una regla que coloque copias del mismo episodio en ambos lados.

Como auditoría de contaminación se comprueba: intersección nula de identificadores y grupos; rangos temporales; ausencia de variables posteriores; ajuste local de transformaciones; distribución de etiquetas y faltantes; y huellas de duplicados. Se conserva una tabla con la asignación de cada unidad. Esta evidencia es tan importante como la métrica resultante.

9.4. Métricas de desempeño

Una métrica reduce muchos resultados a una cantidad interpretable. Esa compresión siempre descarta información. Por ello se define una métrica principal coherente con la decisión, se acompaña con métricas auxiliares y se examinan distribuciones, grupos y errores concretos. Elegir después la cifra más favorable invalida la comparación.

9.4.1. MAE, MSE y RMSE

Para residuos $e_i = y_i - \hat{y}_i$, el error absoluto medio es

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |e_i|.$$

Se expresa en las unidades del objetivo y representa la magnitud absoluta promedio. Todos los errores aumentan su contribución linealmente. Es legible: un MAE de 2,4 minutos significa una desviación absoluta media de 2,4 minutos, aunque no describe dirección ni cuantiles.

El error cuadrático medio y su raíz son

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n e_i^2, \quad \text{RMSE} = \sqrt{\text{MSE}}.$$

MSE usa unidades al cuadrado; RMSE vuelve a la unidad original. Como los residuos se elevan al cuadrado, unos pocos errores grandes pesan mucho. Esto es apropiado si esos fallos tienen costo creciente; es problemático si son errores de medición o si se interpreta RMSE como un «error típico» sin revisar la distribución.

Ejemplo: para valores reales (10, 12, 20, 30) y predicciones (12, 11, 17, 38), los residuos son (-2, 1, 3, -8). Entonces

$$\text{MAE} = \frac{2 + 1 + 3 + 8}{4} = 3,5,$$

$$\text{MSE} = \frac{4 + 1 + 9 + 64}{4} = 19,5, \quad \text{RMSE} \approx 4,42.$$

La diferencia entre MAE y RMSE señala la influencia del error de 8 unidades. Deben compararse contra una referencia y acompañarse con residuos por rango, tiempo y grupo. Ninguna distingue sobrepredicción de subpredicción; para ello se informa error medio firmado u otros resúmenes.

9.4.2. Coeficiente de determinación

El coeficiente de determinación habitual es

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

Compara el error cuadrático del modelo con el de predecir la media de los valores evaluados. $R^2 = 1$ indica predicción perfecta; $R^2 = 0$ iguala esa referencia; un valor negativo significa que el modelo es peor que predecir la media en esa muestra. En prueba, valores negativos son perfectamente posibles.

No significa «porcentaje de predicciones correctas» ni demuestra causalidad. Puede ser alto cuando los errores son operacionalmente intolerables o bajo en un rango restringido aunque MAE sea pequeño. Tampoco permite comparar directamente tareas con poblaciones y variabilidad distintas.

Si se calcula R^2 por grupos pequeños, la varianza del denominador puede ser mínima o nula, volviendo la medida inestable o indefinida. En series temporales, una tendencia común puede inflar el valor aun si los cambios relevantes se predicen mal. Debe informarse junto con MAE o RMSE y con un baseline apropiado al dominio, no como única evidencia.

9.4.3. Matriz de confusión

Para clasificación binaria y una clase declarada positiva, la matriz cruza verdad y decisión:

	Predicción positiva	Predicción negativa
Real positiva	verdaderos positivos (TP)	falsos negativos (FN)
Real negativa	falsos positivos (FP)	verdaderos negativos (TN)

Las denominaciones dependen de cuál clase se define positiva. Un falso positivo no es intrínsecamente peor ni mejor que un falso negativo: su costo depende de la acción. La matriz contiene conteos a un umbral concreto; cambiar el umbral cambia sus celdas.

Supongamos 200 incidentes: 40 positivos y 160 negativos. El sistema identifica 30 positivos, omite 10 y genera 20 alarmas falsas. Entonces $TP = 30$, $FN = 10$, $FP = 20$ y $TN = 140$. Estos números permiten calcular métricas, pero también estimar carga: habrá 50 alarmas para revisar, de las cuales 20 no corresponden a incidentes positivos.

En multiclase, la celda (j, k) cuenta casos de clase real j predichos como k . La diagonal representa aciertos. Conviene mostrar conteos y versiones normalizadas por fila; esta última revela qué proporción de cada clase se confunde, pero oculta soporte. Ordenar o agrupar categorías puede facilitar lectura, siempre sin modificar retrospectivamente la tarea.

9.4.4. Exactitud, precisión y sensibilidad

La **exactitud** o accuracy es

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

En el ejemplo, $(30 + 140)/200 = 0,85$. Resume la fracción de decisiones correctas. Es útil cuando clases y costos son aproximadamente equilibrados, pero puede engañar: predecir siempre negativo obtendría 0,80 sin detectar ningún positivo.

La **precisión** o valor predictivo positivo es

$$\text{Precision} = \frac{TP}{TP + FP}.$$

Responde: de los casos declarados positivos, ¿qué fracción lo era? Aquí $30/50 = 0,60$. Interesa cuando una alarma activa una acción costosa. Depende de la prevalencia: aun con sensibilidad y especificidad constantes, cambia al cambiar la proporción de positivos.

La **sensibilidad**, exhaustividad o recall positivo es

$$\text{Recall} = \frac{TP}{TP + FN}.$$

Responde: de los positivos reales, ¿qué fracción se detectó? Aquí $30/40 = 0,75$. Importa cuando omitir positivos es costoso. Si no se emite ninguna predicción positiva, precisión tiene denominador cero; la convención usada debe declararse, no esconderse asignando un valor conveniente.

En multiclase se calcula cada clase «contra el resto». El promedio **macro** da igual peso a cada clase; el **ponderado** usa su soporte; el **micro** agrega conteos antes de calcular. En clasificación multiclase de una sola etiqueta, micro-F1 coincide con accuracy. Reportar «F1 promedio» sin método de agregación es incompleto.

9.4.5. Especificidad y puntuación F1

La **especificidad** o tasa de verdaderos negativos es

$$\text{Specificity} = \frac{TN}{TN + FP}.$$

En el ejemplo vale $140/160 = 0,875$. Mide qué fracción de negativos se descarta correctamente. Su complemento, $FPR = 1 - \text{especificidad} = FP/(FP + TN)$, es la tasa de falsos positivos.

La puntuación F1 es la media armónica de precisión y sensibilidad:

$$F1 = 2 \frac{\text{Precision Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}.$$

Para el ejemplo, $F1 = 60/(60+20+10) = 0,667$. La media armónica cae cuando una de sus componentes es baja. F1 ignora verdaderos negativos; puede ser apropiada para recuperación de una clase positiva, pero no resume todos los costos. Dos modelos con la misma F1 pueden tener precisión y sensibilidad muy distintas.

En multiclase, **macro-F1** es

$$\text{MacroF1} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Da visibilidad a clases poco frecuentes. También puede volverse inestable si algunas tienen muy pocos ejemplos; por eso se informa soporte y F1 por clase. No debe eliminarse una clase difícil después de ver prueba. Si se agrupan categorías por factibilidad, la regla debe fijarse antes y responder a sentido sustantivo.

9.4.6. Curvas ROC y área ROC-AUC

Un clasificador que produce puntuaciones puede evaluarse a múltiples umbrales. La curva ROC representa sensibilidad o tasa de verdaderos positivos frente a tasa de falsos positivos:

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}.$$

Al bajar el umbral aumentan normalmente ambas. ROC-AUC es el área bajo la curva y puede interpretarse, bajo condiciones habituales y sin empates, como la probabilidad de que un positivo elegido al azar reciba mayor puntuación que un negativo. Un valor 0,5 corresponde a ordenamiento aleatorio y 1 a separación perfecta.

ROC-AUC evalúa ordenamiento a través de todos los umbrales, incluidos algunos que nunca se usarían. No elige un umbral, no garantiza probabilidades calibradas y no incorpora por sí sola costos. Con negativos muy abundantes, una tasa de falsos positivos aparentemente baja puede generar muchos FP absolutos. Deben inspeccionarse las regiones operativas y sus conteos.

En multiclase se usan esquemas uno-contra-resto y promedios macro o ponderados, que deben declararse. Comparar AUC exige los mismos casos. Si las curvas se cruzan, el modelo preferible depende de la región de operación; un único área puede ocultarlo.

9.4.7. Curvas precisión-recall y PR-AUC

La curva precisión-recall (PR) representa precisión frente a sensibilidad a medida que varía el umbral. Se centra en la recuperación de positivos y resulta informativa cuando estos son raros. Su referencia depende de prevalencia: un clasificador sin habilidad tiene precisión esperada cercana a la proporción positiva, no una línea universal de 0,5.

PR-AUC resume la curva, pero existen convenciones de integración distintas, como área trapezoidal y precisión promedio. El reporte debe indicar la utilizada. Al igual que ROC-AUC, no expresa desempeño en un umbral específico ni calidad de calibración.

Supongamos 1 000 casos con 20 positivos. Un punto con sensibilidad 0,80 y FPR 0,05 produce aproximadamente 16 TP y 49 FP: su precisión es solo $16/(16 + 49) \approx 0,246$. ROC puede mostrar un FPR pequeño, mientras PR hace visible que tres de cada cuatro alarmas serían falsas. Este contraste no vuelve «mejor» a PR en todo contexto; responde a una lectura distinta.

Las curvas de modelos deben calcularse sobre la misma prueba y acompañarse con bandas de incertidumbre cuando sea posible. Si interesa una clase minoritaria en multiclase, se examina su curva uno-contra-resto y también las confusiones específicas; el promedio puede esconder el problema.

9.4.8. Umbrales, costos y datos desbalanceados

Una puntuación no es todavía una decisión. En clasificación binaria se decide positivo si $p \geq t$. El umbral $t = 0,5$ no es una ley: solo tiene una justificación particular si las probabilidades están calibradas, la función de costos y las alternativas conducen a ese punto.

Con costos C_{FP} y C_{FN} , el costo observado de un umbral puede estimarse como

$$\widehat{C}(t) = C_{FP} FP(t) + C_{FN} FN(t),$$

posiblemente añadiendo costos de verdaderos positivos, revisión o demora. Los costos pueden ser monetarios, de capacidad, seguridad o equidad; no siempre se reducen de manera responsable a dinero. Deben discutirse con responsables del proceso y analizarse en escenarios.

Si las probabilidades son calibradas y los únicos costos relevantes son un FP y un FN, una regla idealizada predice positivo cuando

$$p > \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Por ejemplo, si omitir cuesta nueve veces una falsa alarma, el umbral teórico es $1/(1+9) = 0,10$. En la práctica se verifica en validación porque costos, calibración y restricciones son imperfectos. Nunca se escoge el umbral final en prueba.

El desbalance no se «soluciona» automáticamente equilibrando datos. Submuestreo, sobremuestreo y ponderación cambian el ajuste y pueden afectar calibración. Deben aplicarse solo dentro de cada entrenamiento, nunca antes de dividir. Para evaluación se conserva, por regla general, la prevalencia del escenario de uso. Se reportan matriz de confusión, soporte, métricas por clase y carga operativa.

En multiclase puede incorporarse una opción de **abstención**: si la mayor probabilidad es baja o el margen entre las dos primeras clases es pequeño, el sistema deriva a revisión. La cobertura es la fracción decidida automáticamente; el riesgo selectivo mide error entre esas decisiones. Una política útil especifica el compromiso entre cobertura, errores y capacidad humana. Ajustar umbrales por clase puede responder a costos diferentes, pero complica interpretación y requiere suficiente validación.

Errores comunes incluyen optimizar accuracy con una clase dominante, informar solo AUC, usar pesos como sustituto de una métrica apropiada, alterar el umbral por cada lote sin gobernanza y asumir que una puntuación de 0,9 es una probabilidad de 90 %. La calibración se evalúa separadamente mediante curvas o puntuaciones propias y con datos no empleados para ajustar el modelo base.

9.4.9. Ejemplo práctico guiado: evaluación de un clasificador de incidentes

Retomemos 200 incidentes con 40 positivos. Dos umbrales producen:

Umbral	TP	FN	FP	TN	Precisión	Sensibilidad	Especificidad	F1
0,30	36	4	48	112	0,429	0,900	0,700	0,581
0,65	28	12	8	152	0,778	0,700	0,950	0,737

El umbral 0,65 tiene mejor F1 y precisión; 0,30 recupera más incidentes. Si un FN cuesta 10 unidades y un FP 1, los costos son:

$$C(0,30) = 10(4) + 1(48) = 88,$$

$$C(0,65) = 10(12) + 1(8) = 128.$$

La decisión por costo preferiría 0,30 pese a su F1 menor. Sin embargo, genera 84 alarmas y quizá el equipo solo pueda revisar 50. Esa restricción convierte capacidad en parte del problema. Podría elegirse el umbral más bajo que no exceda 50 revisiones y luego estimar cuántos FN implica.

Un procedimiento guiado sería:

ENTRADA: puntuaciones y etiquetas de VALIDACIÓN, costos y capacidad
definir una grilla de umbrales antes de consultar PRUEBA

PARA cada umbral:

 construir matriz de confusión

 calcular precisión, sensibilidad, especificidad, F1 y número de alarmas

 calcular costo bajo cada escenario acordado

descartar umbrales que violen capacidad o sensibilidad mínima

elegir mediante la regla predefinida; congelar el umbral

aplicar una sola vez a PRUEBA y reportar todas las métricas y conteos

El ejemplo muestra por qué «mejor clasificador» es una frase incompleta. Puede significar mejor ordenamiento, mejor probabilidad, mayor F1 o menor costo bajo una capacidad dada. El protocolo debe indicar cuál antes de seleccionar.

Actividad EMO [REC-02]: diseñar la evaluación de un clasificador de reclamos

Contexto y propósito. La actividad se integra con el proyecto de reclamos del Apéndice D. La fuente es la base pública de quejas de la Consumer Financial Protection Bureau (CFPB). La unidad es un reclamo publicado, identificado por Complaint ID, con Consumer complaint narrative no vacía. La tarea obligatoria recomendada es predecir la categoría Product a partir de la narrativa inicial para sugerir enrutamiento temático. No se pretende determinar daño, urgencia, legitimidad ni una respuesta financiera.

Capacidad mínima: definir y justificar un protocolo de evaluación antes de entrenar el modelo de texto. El protocolo debe permitir una comparación común en REC-03 y REC-04 y demostrar ausencia de fuga evidente.

Formulación fija. La entrada obligatoria es Consumer complaint narrative; la etiqueta es Product. Complaint ID se conserva solo para trazabilidad. Date received define el corte temporal. La población evaluable queda condicionada a narrativas publicadas con consentimiento, por lo que no representa automáticamente todos los reclamos recibidos por CFPB.

Quedan excluidos como entradas Product, Sub-product, Issue, Sub-issue y cualquier derivado de la etiqueta. También se excluyen Company public response, Date sent to company, Company response to consumer y Timely response?: se producen después del ingreso o de la respuesta y generarían **fuga posterior a la respuesta**. Company no se usa en el baseline obligatorio porque puede actuar como atajo hacia su cartera de productos; ZIP code y Tags se excluyen por privacidad, granularidad o proxies sensibles. No basta eliminar columnas: debe comprobarse que esos campos no hayan sido concatenados a la narrativa analítica.

Partición temporal. Se congela una versión del corpus y se ordenan unidades por Date received. Se definen tres intervalos contiguos antes de entrenar: periodo anterior para entrenamiento, periodo posterior para validación y periodo más reciente para prueba. Las fechas concretas dependen de la versión distribuida,

pero deben ser comunes a toda la cohorte y dejar soporte suficiente por producto. El conjunto de prueba no se usa para armonizar categorías, escoger términos, seleccionar modelos, calibrar confianza ni decidir umbrales.

La temporalidad tiene prioridad sobre conservar idénticas proporciones. Se reporta la distribución de Product por periodo para detectar deriva. Si una categoría tiene soporte insuficiente, el equipo docente puede fijar un mapa de agrupación antes de entregar la consigna. Cada estudiante debe usar el mismo mapa; no se agrupan productos después de ver errores de prueba.

Duplicados y plantillas. Narrativas exactas o casi duplicadas pueden provenir de reenvíos o plantillas. Su presencia en entrenamiento y evaluación inflaría el resultado por memorización textual. Se construye grupo_duplicado durante REC-01 y todas las unidades del grupo quedan en un solo conjunto. Cuando un grupo cruza una frontera temporal, el protocolo debe fijar una solución conservadora común, por ejemplo asignarlo íntegramente al periodo de su primera aparición o excluirlo de la comparación principal y contabilizarlo. Nunca se reparte para mejorar el balance. Deben informarse cantidad de grupos, registros afectados y regla aplicada.

Baselines. El mínimo es la clase mayoritaria estimada solo con entrenamiento. Debe informarse su accuracy y macro-F1 para mostrar cómo el desbalance afecta ambas. Se recomienda además un baseline textual de palabras simples, con vocabulario, frecuencias y pesos ajustados exclusivamente en entrenamiento. Su propósito es establecer una referencia reproducible, no agotar la modelización de REC-03. Cualquier regla por palabras clave debe definirse sin consultar prueba.

Métrica principal y auxiliares. La métrica principal es **macro-F1**, porque cada producto contribuye por igual y los productos menos frecuentes no quedan ocultos por categorías dominantes. Se reportan además accuracy, F1 por clase, precisión y sensibilidad por clase, soporte y matriz de confusión. La matriz debe mostrarse con conteos y normalización por clase real. Si se utilizan probabilidades o confianza para decidir enrutar/revisar, se añade evaluación de calibración o margen, cobertura de automatización y tasa de error entre casos enrutados.

Macro-F1 no elimina la necesidad de interpretación. Una clase con cinco ejemplos puede producir F1 muy variable; el soporte debe acompañarla. Accuracy permite cuantificar rendimiento global, pero no sustituye la métrica principal. Una mejora se acepta solo si procede del mismo conjunto, mapa de etiquetas y protocolo.

Costos y regla de selección. Un producto equivocado puede dirigir el reclamo a un equipo incorrecto y demorar atención; la revisión humana consume capacidad. Antes del entrenamiento, el grupo identifica pares de confusión especialmente costosos y define una regla, por ejemplo: maximizar macro-F1 sujeto a no degradar ninguna clase prioritaria más de una tolerancia y a una cobertura de revisión viable. Si se usa abstención, el umbral se elige en validación. Timely response? no puede convertirse en etiqueta de urgencia: es un resultado posterior y no valida daño ni vulnerabilidad.

Protocolo en pseudocódigo. Este diseño no implementa modelos; ordena las decisiones experimentales:

- congelar corpus, mapa común de Product y fechas de corte
- verificar narrativa no vacía y campos permitidos
- formar grupos de duplicados y plantillas

asignar grupos completos a ENTRENAMIENTO, VALIDACIÓN o PRUEBA respetando tiempo
publicar tabla de conteos, productos, fechas y solapamientos nulos

ajustar baseline mayoritario solo con ENTRENAMIENTO

PARA cada candidato posterior:

ajustar representación y modelo solo con ENTRENAMIENTO

evaluar macro-F1 y auxiliares en VALIDACIÓN

seleccionar con la regla preinscrita

congelar representación, modelo, categorías y política de revisión

evaluar una vez en PRUEBA

documentar errores sin reproducir narrativas completas ni datos identificables

Evidencia individual: ficha experimental. La entrega debe contener:

Campo	Contenido requerido
Versión	fuelle, fecha de descarga, filtros y mapa de productos
Unidad y objetivo	reclamo con narrativa; clasificación de Product al ingreso
Particiones	fechas, conteos y soporte por clase en entrenamiento, validación y prueba
Duplicados	método, regla de asignación y prueba de intersección nula
Entradas excluidas	lista y justificación temporal, ética o de atajo
Baselines	mayoría y baseline textual simple previsto
Métricas	macro-F1 principal; auxiliares y forma de agregación
Selección	regla, costos, tolerancias y eventual umbral de revisión
Prueba	compromiso de uso único y condiciones para abrirla
Limitaciones	consentimiento, cobertura, deriva y clases con poco soporte

Comprobaciones de aprobación. Debe observarse que ningún Complaint ID ni grupo_duplicado aparece en más de una partición; que validación y prueba son posteriores a entrenamiento; que vocabulario y cualquier estadística se ajustarán dentro de entrenamiento; y que no existe campo posterior a la respuesta. La métrica principal ha de responder al desbalance, prueba debe quedar reservada y los ejemplos de error no deben reproducir relatos completos ni información que facilite reidentificación.

Modalidad de trabajo: discusión grupal del caso y de los costos; protocolo y justificación individuales. El protocolo común permite que las diferencias posteriores correspondan a representaciones o modelos y no a particiones oportunistas.

Aporte al laboratorio: REC-02 fija la medición con la que se compararán unigramas, bigramas, decisiones de normalización y clasificadores lineales. REC-03 ajustará TF-IDF sin fuga; REC-04 analizará errores, confianza y abstención.

El producto final sugerirá un producto y podrá derivar casos inciertos a revisión humana, pero no generará respuestas ni tomará decisiones financieras.

Síntesis del capítulo

Formular un problema de aprendizaje exige especificar unidad, población, instante, entradas disponibles, objetivo, etiqueta y consecuencias del error. Supervisión describe el origen de la señal, mientras regresión, clasificación y agrupamiento describen la tarea. El aprendizaje semisupervisado aprovecha entradas no etiquetadas junto con etiquetas escasas; el autosupervisado deriva objetivos de los propios datos para aprender representaciones.

El ajuste minimiza una pérdida empírica, pero el objetivo científico y operativo es generalizar. Sobreajuste, subajuste, sesgo, varianza y complejidad ayudan a diagnosticar la relación entre entrenamiento y datos nuevos. Los baselines convierten una cifra aislada en una comparación con significado.

La evaluación separa entrenamiento, validación y prueba y replica la estructura del uso futuro. Aleatoriedad y estratificación sirven para unidades intercambiables; grupos, duplicados y tiempo requieren particiones específicas. Toda transformación aprendida se ajusta dentro de entrenamiento. La prueba no es un recurso de desarrollo.

MAE, RMSE y R^2 describen aspectos diferentes del error de regresión. En clasificación, la matriz de confusión conecta exactitud, precisión, sensibilidad, especificidad y F1 con conteos reales. ROC-AUC y PR-AUC resumen ordenamiento a través de umbrales, pero la decisión final requiere costos, capacidad, prevalencia y, cuando corresponde, abstención. Una evaluación honesta no busca la métrica más alta: construye evidencia relevante, trazable e incierta sobre una decisión definida.

Glosario esencial

- **Atributo o entrada:** información disponible al momento de producir una predicción.
- **Baseline:** referencia sencilla y reproducible contra la cual se mide valor agregado.
- **Calibración:** correspondencia entre probabilidades pronosticadas y frecuencias observadas.
- **Clase positiva:** categoría elegida como referencia para definir TP, FP, TN y FN.
- **Deriva:** cambio temporal en entradas, etiquetas o su relación.
- **Etiqueta:** representación observable del objetivo en los datos.
- **Fuga de información:** uso durante entrenamiento o selección de información no disponible legítimamente al predecir.
- **Generalización:** desempeño sobre nuevas unidades bajo una población y escenario declarados.
- **Hiperparámetro:** decisión externa al ajuste ordinario que controla el procedimiento de aprendizaje.
- **Macro-F1:** promedio no ponderado del F1 calculado para cada clase.
- **Pérdida:** penalización por el desacuerdo entre resultado y predicción.

- **Prueba:** conjunto reservado para estimar el procedimiento final ya congelado.
- **Riesgo empírico:** pérdida promedio observada en una muestra.
- **Sobreajuste:** adaptación a particularidades del desarrollo que no se sostienen fuera de muestra.
- **Subajuste:** incapacidad para capturar estructura relevante incluso en entrenamiento.
- **Umbral:** punto que transforma una puntuación continua en una decisión.
- **Validación:** datos o procedimiento usado para seleccionar modelos, hiperparámetros y reglas.

Preguntas de autoevaluación

1. ¿Por qué «predecir gravedad» no queda completamente definido sin una etiqueta, un instante y un horizonte?
2. ¿En qué difieren aprendizaje semisupervisado y autosupervisado? Proponga una cadena que use ambos.
3. ¿Por qué un código numérico de categoría no convierte una clasificación en regresión?
4. ¿Qué diferencia existe entre función de pérdida, métrica de selección y costo operativo?
5. ¿Cómo pueden ser simultáneamente bajos el error de entrenamiento y la validez externa?
6. ¿Qué patrones de curvas de aprendizaje sugieren subajuste y alta varianza?
7. ¿Por qué probar muchas configuraciones puede sobreajustar validación aunque cada modelo sea simple?
8. ¿Cuándo una partición aleatoria estratificada resulta inadecuada?
9. ¿Qué información debe ajustarse de nuevo dentro de cada fold de validación cruzada?
10. ¿Por qué la desviación entre folds no es automáticamente un intervalo de confianza?
11. ¿Cómo cambia la pregunta de generalización al dividir por persona en lugar de por fila?
12. ¿Qué diferencia práctica existe entre MAE y RMSE ante valores extremos?
13. ¿Puede R^2 ser negativo en prueba? Interprete ese resultado.
14. Con $TP = 18$, $FP = 6$, $FN = 12$ y $TN = 64$, calcule accuracy, precisión, sensibilidad, especificidad y F1.
15. ¿Por qué ROC-AUC alta no garantiza una carga aceptable de falsas alarmas en una población desbalanceada?
16. ¿Por qué el umbral 0,5 no debe adoptarse automáticamente?
17. En REC-02, ¿qué campos constituirían fuga posterior y por qué Company puede ser un atajo?
18. ¿Qué evidencia demostraría que los duplicados CFPB no contaminan la prueba?

Actividad integradora de cierre

Redacte una ficha de evaluación para uno de estos problemas: regresión de demora de viajes, clasificación de excedencias de agua o clasificación temática de reclamos. No implemente un modelo. La ficha debe incluir unidad, población, instante, horizonte, entradas permitidas, etiqueta, dos riesgos de fuga, baseline,

partición y su justificación, métrica principal, tres métricas auxiliares y costos de dos errores.

Añada un diagrama textual del flujo de datos y una tabla hipotética de resultados para dos candidatos. Decida cuál avanzaría a prueba aplicando una regla escrita antes de la tabla. Después analice qué cambio de población invalidaría la conclusión y qué evidencia de monitoreo permitiría detectarlo. La evaluación se considera completa cuando otra persona puede reproducir la partición, comprender la decisión y señalar con precisión qué afirmación de generalización está respaldada.

Capítulo 10. Ingeniería, selección y reducción de atributos

Los algoritmos de aprendizaje no reciben «la realidad», sino una representación de ella. Una persona, una estación meteorológica o un viaje se convierten en filas; sus propiedades se convierten en columnas; y decisiones como expresar una fecha mediante mes, día o tiempo transcurrido alteran el problema que el modelo puede resolver. Por eso, la representación no es una tarea cosmética anterior al modelado: incorpora supuestos sobre semejanza, escala, invariancias y mecanismos del dominio.

Este capítulo estudia tres operaciones relacionadas, pero distintas. La **ingeniería de características** construye representaciones potencialmente útiles; la **selección de atributos** conserva un subconjunto de las variables disponibles; y la **reducción de dimensionalidad** crea un número menor de variables, generalmente combinando las originales. En los tres casos, cualquier cantidad aprendida de los datos —medias, categorías, cargas, umbrales o subconjuntos— debe estimarse solo con el conjunto de entrenamiento correspondiente. De lo contrario, una representación aparentemente sofisticada puede producir una evaluación optimista por fuga de información.

Al terminar el capítulo, el lector podrá justificar una representación según el fenómeno y el momento de predicción, comparar familias de métodos de selección, derivar y leer un análisis de componentes principales (PCA), y diseñar un pipeline heterogéneo que se ajuste, evalúe y persista como una sola unidad.

10.1. Ingeniería de características

Una característica o *feature* es una magnitud utilizada como entrada de un modelo. Puede proceder directamente de una medición —temperatura—, de una codificación —tipo de vehículo— o de una construcción —demanda media de las cuatro semanas anteriores—. Una buena característica cumple, al menos, cuatro condiciones: tiene significado para la unidad de análisis, está disponible en el instante de decisión, se calcula del mismo modo durante entrenamiento e inferencia y conserva suficiente estabilidad ante cambios operativos.

La ingeniería de características expresa conocimiento previo. No garantiza que una variable sea predictiva, ni convierte una asociación en causalidad. Su utilidad debe contrastarse fuera de muestra y frente a un baseline. Asimismo, más columnas no

implican más información: una expansión indiscriminada puede aumentar varianza, costo, redundancia y superficie de fuga.

El proceso es necesariamente iterativo. Primero se formula qué información debería distinguir casos con resultados diferentes; después se comprueba si esa información existe con calidad y latencia suficientes; finalmente se mide si la representación mejora una decisión fuera de muestra. El análisis de errores vuelve a abrir el ciclo: un fallo concentrado en días festivos puede sugerir una variable de calendario ausente, mientras que un fallo aleatorio no se corrige fabricando transformaciones. Esta disciplina evita confundir creatividad en la construcción de columnas con progreso estadístico.

10.1.1. Representación numérica de observaciones

Supóngase una colección de objetos $o_1, \dots, o_n$. Una representación vectorial es una aplicación $\phi : o_i \mapsto \mathbf{x}_i \in \mathbb{R}^p$. Al apilar los vectores se obtiene la matriz de diseño $X \in \mathbb{R}^{n \times p}$. Elegir ϕ define qué diferencias puede percibir el algoritmo. Dos viajes con vectores próximos serán parecidos para un método basado en distancia, aunque operativamente pertenezcan a contextos distintos.

Antes de construir X deben fijarse:

- **Unidad de observación:** viaje, persona, sensor-hora o zona-día. Mezclar granularidades sin agregación explícita produce filas sin interpretación.
- **Índice y claves:** identifican entidades, pero rara vez representan magnitudes. Un código postal o un identificador de cliente no debe tratarse como número continuo por el mero hecho de contener dígitos.
- **Momento de corte:** instante hasta el cual se permite usar información. Para predecir a las 07:00, una variable publicada a las 07:15 no está disponible.
- **Escala de medición:** nominal, ordinal, de intervalo o de razón. La operación «doble» tiene sentido para una distancia, no para una categoría nominal.
- **Semántica del faltante:** desconocido, no aplicable, no medido o ausencia real pueden requerir representaciones diferentes.

Las unidades afectan a muchos modelos. En una distancia euclídea,

$$d(\mathbf{x}, \mathbf{x}') = \sqrt{\sum_{j=1}^p (x_j - x'_j)^2},$$

una variable expresada en metros puede dominar otra expresada en kilómetros aunque representen escalas físicas comparables. La estandarización $z_{ij} = (x_{ij} - \mu_j)/s_j$ fija media cero y desviación uno; el escalado mínimo-máximo lleva un intervalo observado a otro intervalo; y los escaladores robustos usan mediana y rango intercuartílico. Ninguno es universal: estandarizar una variable indicadora altera su lectura, y un mínimo-máximo es sensible a extremos y a valores futuros fuera del rango.

También importa la precisión. Redondear edad a décadas puede reducir ruido y favorecer privacidad, pero elimina diferencias potencialmente útiles. Una razón como «consumo por habitante» puede ser más comparable que el consumo total, aunque se vuelve inestable cuando el denominador es pequeño. Toda razón debe documentar unidades, denominador y tratamiento de ceros.

La representación debe ser compatible con las invariancias razonables del problema. Si trasladar todo un recorrido cien metros no cambia su dificultad, quizá interesen distancias relativas y no coordenadas absolutas. Si duplicar población y consumo conserva el mismo consumo individual, una razón puede imponer esa invariancia. Imponerla reduce grados de libertad, pero también impide que el modelo aprenda excepciones. Por eso se contrasta la versión absoluta, la normalizada y, cuando tiene sentido, ambas juntas.

Ejemplo de construcción. Para predecir la energía consumida por un lote de producción, una fila bruta contiene hora de inicio, hora de fin, cantidad de piezas, familia de producto y energía acumulada hasta el comienzo. La duración planificada puede representarse en minutos y la familia mediante indicadores; restar directamente las dos horas sin fecha sería incorrecto si el turno cruza medianoche. La razón energía histórica/pieza facilita comparar lotes de tamaños distintos, pero no se calcula cuando la cantidad es cero: ese caso corresponde a preparación o mantenimiento y merece un indicador propio. Vectorizar no consiste en «volver numérico» un archivo, sino en preservar estados operativos que de otro modo quedarían confundidos.

Un diagnóstico útil consiste en recorrer varias filas desde el dato bruto hasta el vector final. Se comprueba que dos objetos conceptualmente iguales reciban representaciones iguales, que una pequeña perturbación válida no provoque un salto injustificado y que casos sustantivamente distintos no colapsen al mismo vector. Esta inspección detecta errores que ninguna medida de escala revela: agregaciones en la entidad equivocada, unidades mezcladas o un cero que unas fuentes usan como ausencia y otras como medición real.

Advertencia de fuga. Medias, desviaciones, cuantiles, límites de recorte e imputaciones se estiman exclusivamente con el entrenamiento. Aplicar primero la normalización a todo el conjunto comunica a las particiones de entrenamiento información sobre la distribución de validación.

10.1.2. Transformaciones lineales y no lineales

Una transformación lineal de un vector tiene la forma $T(\mathbf{x}) = A\mathbf{x}$; una transformación afín añade un desplazamiento, $T(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$. Cambios de unidad, centrado, rotaciones y proyecciones pertenecen a esta familia. Conservan combinaciones lineales: si el modelo posterior también es lineal, encadenar transformaciones lineales no aumenta por sí mismo la clase de fronteras que puede representar, aunque sí mejora condicionamiento, regularización e interpretación.

Las transformaciones no lineales alteran la geometría. Algunas finalidades habituales son:

Finalidad	Transformación conceptual	Precaución
Reducir asimetría positiva	$\log(x)$ o $\log(1 + x)$	El dominio debe ser positivo; sumar una constante cambia la interpretación.
Estabilizar varianza	familia de potencias	El parámetro debe ajustarse dentro del entrenamiento.

Finalidad	Transformación conceptual	Precaución
Modelar curvatura	x^2, x^3 o bases polinómicas	Las potencias elevadas extrapolan mal y pueden ser colineales.
Capturar umbrales	indicadores $I(x > c)$ o intervalos	Discretizar pierde orden fino; c no debe elegirse mirando prueba.
Respetar periodicidad	seno y coseno	Es preciso conocer el período y la convención de fase.
Acotar extremos	recorte o función saturante	Puede ocultar eventos reales; conservar una bandera de recorte.

Considérese una respuesta cuya relación con concentración sea multiplicativa: un aumento de 1% en x se asocia con un cambio aproximadamente constante en y . Usar $\log x$ permite que un modelo lineal represente esa relación. En cambio, aplicar logaritmo solo porque el histograma es asimétrico no constituye una justificación suficiente: el objetivo es facilitar una relación útil y estable con la salida, no hacer que toda entrada parezca normal.

Las bases por tramos ofrecen mayor control que un polinomio global. Pueden expresar pendientes diferentes antes y después de nudos predefinidos, manteniendo continuidad. Sin embargo, cada grado de libertad aumenta capacidad. Nudos, grados y parámetros de transformación son hiperparámetros y se eligen mediante validación, no por desempeño sobre prueba.

La elección también afecta a la extrapolación. Un término cuadrático domina rápidamente fuera del rango observado; una discretización mantiene el último nivel y oculta cuánto se excedió el extremo; una función logarítmica continúa creciendo, pero cada incremento absoluto produce menos cambio. Antes de desplegar conviene preguntar qué hará la transformación con un valor apenas fuera del entrenamiento y con otro físicamente extremo. El comportamiento matemático debe coincidir con una hipótesis operacional, no solo con el ajuste dentro de la muestra.

Las transformaciones monotónicas preservan el orden, pero no las distancias. Esto puede ser suficiente para modelos basados en rangos y decisivo para modelos lineales o métricos. Además, transformar la entrada cambia la escala de interpretación del efecto: si se usa $\log x$, un incremento unitario representa multiplicar x por aproximadamente e , no sumarle una unidad. Una buena especificación declara esa lectura y revisa residuos o errores por intervalos del valor original para comprobar que la transformación no mejora el promedio a costa de los extremos.

Comparación conceptual. Supóngase que el tiempo de mecanizado crece de 10 a 20 minutos y luego de 100 a 110. En escala original ambos cambios valen 10; en escala logarítmica valen $\log(20/10) \approx 0,693$ y $\log(110/100) \approx 0,095$. El logaritmo expresa cambios relativos, de modo que el primer salto pesa mucho más. Si el costo depende de minutos absolutos, esa geometría es desacertada; si depende de multiplicar el tiempo habitual, puede ser apropiada. Se comparan entonces

residuos, calibración y extrapolación de ambas formulaciones, no solo la simetría de sus histogramas.

Una transformación debe ser invertible cuando la interpretación o reconstrucción lo exija, pero no siempre. Una bandera «temperatura sobre umbral de seguridad» sacrifica información para representar una regla operativa. La pregunta correcta es qué distinciones necesita la tarea y qué invariancias conviene imponer.

10.1.3. Interacciones entre variables

Un efecto es aditivo si la contribución de x_1 no depende de x_2 . El modelo

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2$$

incluye una interacción: el efecto marginal de x_1 es $\partial f / \partial x_1 = \beta_1 + \beta_{12} x_2$. Así, la asociación entre temperatura y demanda puede ser mayor en una zona comercial que en una residencial. Las interacciones no se limitan a productos; pueden ser categoría por categoría, variable por intervalo o funciones suaves conjuntas.

El principio de jerarquía recomienda conservar los efectos principales cuando se incluye una interacción, incluso si alguno parece débil de forma aislada. Sin ellos, el coeficiente del producto absorbe cambios de nivel y su interpretación depende de un origen quizá arbitrario. Centrar variables continuas antes de multiplicarlas hace que los efectos principales se interpreten alrededor de valores típicos y suele reducir colinealidad numérica.

La cantidad de interacciones por pares crece como $p(p - 1)/2$. Con 100 variables ya existen 4950 productos posibles. Generarlos todos sin hipótesis aumenta dimensionalidad y facilita hallazgos espurios. Conviene priorizar interacciones sustentadas por mecanismo, costo o conocimiento operativo y compararlas mediante validación.

Una interacción puede detectarse en los errores de un modelo aditivo. Si los residuos son sistemáticamente positivos solo cuando coinciden alta humedad y temperatura, no basta con afirmar que ambas variables son importantes: hay evidencia de que su combinación contiene estructura no representada. El diagnóstico debe repetirse fuera de la muestra usada para formular la hipótesis, porque buscar patrones entre muchos pares también selecciona por azar. Las curvas de efecto estratificadas ayudan a distinguir una interacción real de una extrapolación sostenida por pocas observaciones.

Ejemplo calculado. Si un modelo de demanda usa temperatura centrada t , indicador de fin de semana w y $t w$, con coeficientes 2, -20 y $-1,5$, cada grado adicional se asocia con dos viajes más en días hábiles y con $2 - 1,5 = 0,5$ en fin de semana. El coeficiente -20 compara ambos tipos de día cuando $t = 0$, es decir, a la temperatura media usada para centrar, no necesariamente a 0°C .

Modelos de árboles y redes pueden aprender interacciones sin columnas explícitas, pero no de forma gratuita: necesitan datos, regularización y profundidad suficientes. Una interacción construida con sentido físico puede reducir la complejidad necesaria. A la inversa, imponer una interacción equivocada puede empeorar generalización.

También importa el soporte conjunto. El producto «lluvia $\times$ hora pico» no puede estimarse de modo fiable si casi nunca llueve en los períodos observados de mayor

demanda. En esa situación, un coeficiente existe algebraicamente, pero compara regiones del espacio con pocos datos y será inestable. Antes de conservar una interacción se inspeccionan conteos o densidades de las combinaciones, incertidumbre y desempeño en los estratos relevantes. Si la combinación es rara pero crítica, puede requerir datos adicionales o una restricción basada en dominio, no una estimación libre.

10.1.4. Variables categóricas

Una categoría nominal no posee distancia ni orden intrínsecos. Codificar «norte, centro, sur» como 1, 2, 3 induce que centro está entre norte y sur y que ambas separaciones son iguales. La codificación indicadora crea una columna binaria por nivel. Para un modelo lineal con intercepto se elimina una categoría de referencia o se impone una restricción para evitar dependencia exacta; la elección de referencia cambia coeficientes, no predicciones.

Las variables ordinales, como «bajo, medio, alto», admiten orden, pero no necesariamente intervalos iguales. Una codificación 1, 2, 3 es una hipótesis fuerte. Puede contrastarse con indicadores o con modelos que impongan monotonicidad.

La alta cardinalidad plantea problemas de memoria, rareza y categorías nuevas. Entre las estrategias conceptuales figuran agrupar niveles escasos con criterio previo, representar jerarquías —barrio, distrito, ciudad—, aplicar funciones de dispersión o aprender representaciones densas. La codificación por frecuencia usa cuán común es una categoría, pero pierde su identidad: dos niveles con igual frecuencia se vuelven indistinguibles.

La codificación por objetivo reemplaza una categoría c por una estimación regularizada de $E(Y | C = c)$. Puede ser poderosa, pero también es una fuente clásica de fuga. Si la media de una categoría se calcula incluyendo la etiqueta de la propia fila, los niveles raros casi revelan y . Durante entrenamiento debe obtenerse con predicciones fuera de pliegue; para validación o inferencia se usa el mapeo aprendido sin esas observaciones. El suavizado hacia la media global reduce varianza:

$$\tilde{\mu}_c = \frac{n_c \bar{y}_c + \alpha \bar{y}}{n_c + \alpha},$$

donde n_c es el número de casos de c y α controla la contracción.

Debe existir una política para niveles desconocidos: columna «otro», vector nulo con indicador de desconocido o representación jerárquica. Convertir automáticamente una categoría nueva en la más frecuente oculta un cambio de población. También se debe diferenciar «faltante» de una categoría válida cuyo texto sea «desconocido».

Agrupar niveles no es una operación inocua. Un umbral de frecuencia mejora estabilidad, pero puede reunir categorías de comportamientos opuestos; agrupar por similitud de objetivo es supervisado y exige el mismo aislamiento que una codificación por objetivo. Las jerarquías ofrecen una salida más defendible: un barrio nuevo puede retroceder al efecto del distrito y luego al de la ciudad. Esa estrategia comparte información sin fingir que todos los niveles raros son iguales.

El diagnóstico debe separar cobertura de desempeño. Se registran proporción de niveles vistos, masa asignada a «otro», niveles que dominan cada columna y error por frecuencia de categoría. Una métrica global puede ocultar que categorías comunes funcionan bien y las nuevas fallan sistemáticamente. Además, las categorías cambian por decisiones administrativas: una recodificación de proveedores puede alterar nombres sin cambiar entidades. Normalización, tablas de correspondencia y versionado son parte de la semántica, no mera limpieza de texto.

La codificación también determina qué puede compartir el modelo. Con indicadores, dos proveedores nuevos no comparten señal salvo mediante el intercepto; con una jerarquía sector-país-proveedor pueden heredar información de niveles superiores. Esa ganancia introduce el supuesto de que la jerarquía es estable y pertinente. Para auditarlo se compara contra indicadores simples, se inspecciona error en niveles frecuentes, raros y desconocidos, y se simula el alta de categorías. Una representación que mejora el promedio pero asigna sistemáticamente el riesgo medio a todos los niveles nuevos puede ser inadecuada para una expansión comercial.

10.1.5. Características temporales

Una marca temporal contiene calendario, posición cíclica, tendencia y relación con eventos. Extraer año, mes, día de semana, hora, feriado o temporada puede hacer visibles regularidades. Sin embargo, $\text{mes}=12$ y $\text{mes}=1$ quedan lejos bajo una codificación lineal aunque sean vecinos en el ciclo anual. Para un período P y posición t se usa el par

$$x_{\sin} = \sin(2\pi t/P), \quad x_{\cos} = \cos(2\pi t/P),$$

que preserva circularidad y evita que puntos opuestos del ciclo colapsen. Se necesitan ambas coordenadas: una sola función seno asigna el mismo valor a fases distintas.

Los rezagos y_{t-k} y ventanas móviles resumen historia. Una media causal de amplitud w para predecir y_t es

$$m_t = \frac{1}{w} \sum_{r=1}^w y_{t-r},$$

que excluye y_t y cualquier futuro. Debe aclararse si la ventana contiene períodos de calendario u observaciones. En datos irregulares, «últimas siete filas» no equivale a «últimos siete días». Variables como tiempo desde el último evento, cantidad de eventos recientes y tendencia local también son útiles.

El calendario depende de zona horaria, horario de verano y ámbito geográfico. Una hora UTC puede corresponder a distinto día local; un feriado nacional no representa cierres municipales. El sistema de inferencia debe disponer del mismo calendario futuro y de revisiones versionadas.

Fugas frecuentes: calcular una media móvil centrada; completar un faltante con interpolación que usa el punto posterior; normalizar con estadísticas de todo el horizonte; y construir «demanda diaria final» cuando la decisión ocurre a mitad del

día. La partición aleatoria tampoco repara estas fugas. En problemas temporales, tanto las características como la validación deben respetar el orden.

Los rezagos exigen definir dos tiempos: cuándo ocurrió el fenómeno y cuándo quedó disponible su registro. Una medición de ayer corregida tres días después no era conocida hoy en una simulación histórica, aunque su fecha de evento sea anterior. Una reconstrucción honesta requiere datos con versión temporal o una aproximación conservadora de la latencia. De lo contrario aparece una fuga sutil denominada retrospectiva: se entrena con la versión final de un pasado que el sistema real nunca observó así.

La elección de ventanas codifica una escala del proceso. Una ventana corta responde rápido, pero es ruidosa; una larga estabiliza, pero retrasa cambios de régimen. Comparar media, desviación, mínimo, máximo y pendiente de una misma ventana multiplica atributos correlacionados, por lo que conviene justificar qué aspecto de la historia representa cada resumen. Los diagnósticos incluyen disponibilidad por horizonte, error alrededor de transiciones y sensibilidad a ventanas cercanas. Una mejora que desaparece al pasar de 28 a 27 días suele ser menos confiable que otra estable en un rango razonable.

10.1.6. Características espaciales

Latitud y longitud son coordenadas sobre una superficie, no un plano cartesiano global. Para distancias cortas puede bastar una proyección local apropiada; para puntos sobre la Tierra, la distancia de gran círculo evita errores importantes. Aun así, distancia geométrica y accesibilidad no son equivalentes: dos sitios cercanos pueden estar separados por un río o una red vial deficiente.

Las representaciones espaciales habituales incluyen:

- coordenadas proyectadas y elevación;
- distancia y tiempo de viaje a puntos de interés;
- pertenencia a polígonos administrativos u operativos;
- densidad y conteos en vecindarios;
- conectividad en una red y centralidad de nodos;
- celdas multirresolución o funciones de base espaciales.

La granularidad expresa un compromiso. Una zona grande reduce ruido y protege ubicación, pero mezcla contextos; una celda pequeña genera niveles raros y riesgo de reidentificación. Los límites administrativos también introducen discontinuidades artificiales: viviendas a ambos lados de una calle pueden recibir categorías distintas.

Los agregados vecinales requieren un momento de corte. Para predecir incidentes de mañana, la densidad de incidentes debe calcularse solo con historia disponible. Si se excluye la fila objetivo pero se incluyen incidentes futuros cercanos, sigue existiendo fuga. Además, las observaciones próximas suelen estar correlacionadas; una partición aleatoria puede poner ubicaciones casi idénticas en entrenamiento y prueba. La evaluación espacial por bloques o regiones estima mejor la capacidad de transferir.

La autocorrelación espacial no implica que la ubicación sea una causa. Coordenadas pueden actuar como sustitutos de ingreso, infraestructura o prácticas de medición y reproducir inequidades. Antes de desplegar una

característica geográfica deben evaluarse necesidad, privacidad, estabilidad ante expansión territorial y desempeño por región.

La escala espacial adecuada depende del mecanismo. La contaminación atmosférica puede variar con vientos regionales, mientras el acceso a transporte cambia a escala de calles y barreras. Elegir un único radio supone que todo proceso opera en esa escala. Una alternativa es construir resúmenes multiescala y regularizarlos, pero cada radio adicional aumenta capacidad y correlación. La validación por bloques debe tener un tamaño comparable con la distancia de dependencia; bloques demasiado pequeños siguen compartiendo señal local y ofrecen una falsa impresión de transferencia.

Un control práctico compara tres nociones de cercanía: geométrica, de red y administrativa. Si producen vecinos distintos, debe explicarse cuál puede transportar el fenómeno. También se revisan efectos de borde: una celda periférica tiene menos vecinos observables y una densidad menor puede reflejar falta de cobertura. Normalizar por área accesible o exposición puede corregirlo, siempre que ese denominador sea estable. En aplicaciones sensibles, la resolución mínima necesaria se decide antes de incorporar coordenadas precisas y se verifica el riesgo de reconstruir ubicaciones individuales.

10.1.7. Conocimiento del dominio

El conocimiento del dominio convierte mecanismos plausibles en representaciones comprobables. En energía, el consumo por unidad producida puede ser más informativo que cada magnitud aislada; en movilidad, capacidad disponible por franja contextualiza la demanda; en agricultura, los grados-día acumulados representan desarrollo térmico mejor que una temperatura instantánea. Estas construcciones aportan invariancias y pueden disminuir la cantidad de datos necesaria.

Una ficha de característica debería registrar:

Campo	Pregunta de control
Definición	¿Qué magnitud representa y en qué unidad?
Linaje	¿De qué fuentes y campos se obtiene?
Granularidad	¿A qué entidad y período corresponde?
Disponibilidad	¿Existe realmente en el momento de predicción?
Cálculo	¿Qué ventana, agregación y tratamiento de faltantes usa?
Estabilidad	¿Puede cambiar por una política o sistema de captura?
Riesgo	¿Es un proxy sensible, una variable postresultado o una fuente de fuga?
Validación	¿Qué evidencia fuera de muestra sostiene su utilidad?

Las variables posteriores al resultado suelen parecer extraordinariamente predictivas. «Tratamiento recibido» puede ocurrir después del diagnóstico;

«duración final del viaje» no sirve para predecir su retraso al inicio; «estado de factura: cobrada» revela morosidad futura. Un diagrama temporal del proceso ayuda a separar antecedentes, decisiones intermedias y consecuencias.

El conocimiento experto tampoco es infalible. Puede codificar prácticas históricas sesgadas o reglas que ya cambiaron. Por eso conviene formular cada atributo como hipótesis: «esta razón estabiliza diferencias de escala», «esta interacción representa congestión bajo lluvia». Se compara mediante ablación y validación en períodos, grupos o lugares relevantes. El dominio orienta; la evidencia decide.

Una sesión productiva con especialistas no comienza preguntando qué columnas desean, sino reconstruyendo el proceso: qué ocurre antes del resultado, qué recursos limitan el sistema, qué mediciones responden a una decisión previa y qué excepciones conocen. De ese relato surgen atributos con mecanismo y, a la vez, pruebas de falsación. Si «carga del motor respecto de su potencia nominal» debería anticipar desgaste solo durante producción y no durante calibración, se examina esa interacción y se espera poca utilidad fuera de ese régimen.

Las restricciones físicas ofrecen diagnósticos especialmente valiosos. Una razón negativa imposible, un balance que no cierra o una velocidad incompatible con distancia y tiempo puede señalar error de datos antes que oportunidad predictiva. Puede conservarse una bandera de incoherencia si estará disponible en producción, pero no debe normalizarse silenciosamente un fallo sistemático. La decisión entre corregir, excluir o representar la anomalía depende de si se modela el fenómeno físico, la operación del sistema de medición o ambos.

El paso final es someter la característica experta a una prueba adversarial. Se pregunta qué cambio de política, dispositivo o población rompería su significado; si un operador puede manipularla; y si sigue disponible con la misma latencia. Por ejemplo, «porcentaje de capacidad ocupada» deja de ser comparable si cambia la definición administrativa de capacidad. El diccionario de atributos debe versionar tanto la fórmula como esas dependencias. Así, el conocimiento del dominio no queda congelado como autoridad: se convierte en una hipótesis mantenible, con condiciones explícitas de validez.

10.1.8. Ejemplo práctico guiado: atributos para predecir demanda de transporte

Problema. Una operadora desea predecir a las 05:00 la cantidad de viajes que comenzarán en cada zona y cada franja de 30 minutos del día siguiente. La unidad es zona-franja; la salida $y_{z,t}$ es un conteo; el horizonte varía entre 24 y 48 horas. El momento de corte excluye datos publicados después de las 05:00.

Paso 1: inventario y disponibilidad. Se dispone de validaciones históricas, calendario, pronóstico meteorológico emitido antes del corte, capacidad programada y geometría de zonas. La lluvia observada mañana no puede emplearse, aunque sí el pronóstico disponible hoy. La demanda real de franjas previas del mismo día tampoco existe al preparar todas las predicciones.

Paso 2: representación temporal. Se construyen seno y coseno para hora y día de semana, indicadores de feriado y víspera, días desde inicio del servicio y una etiqueta de período lectivo. Se incluyen rezagos de demanda de 1 y 7 días, siempre alineados con la misma zona y franja. Una media de cuatro semanas usa únicamente los cuatro valores equivalentes anteriores al corte.

Paso 3: representación espacial y operacional. Para cada zona se incluyen área, densidad residencial histórica, distancia de red a centros de actividad, conectividad y capacidad programada. La razón demanda histórica/capacidad puede representar presión, con tratamiento explícito cuando capacidad es cero. Zona no se convierte en un entero ordinal: se codifica nominalmente o mediante una representación espacial regularizada.

Paso 4: contexto e interacciones. El pronóstico aporta temperatura, probabilidad de precipitación y viento. Se proponen interacciones entre lluvia y hora pico, feriado y zona comercial, y temperatura y franja. Solo se conservan si mejoran validación temporal de manera estable.

Una fila conceptual sería:

zona	franja	sen_horas	cos_horas	feriado	rezago_7d	media_4s	capacidad	prob_lluvia	prob_viento	objetivo
Z17	08:00	0,866	-	0	124	119,5	150	0,70	0,70	131
			0,500							

Paso 5: evaluación. Se simulan cortes históricos: en cada pliegue se entrena con pasado y se valida en semanas posteriores. Los agregados, codificaciones y escalas se recalculan dentro de cada pliegue. Se compara contra dos baselines: demanda de la semana anterior y media de cuatro semanas. Además del error global, se examinan zonas periféricas, horas pico y días con lluvia.

Ablación razonada. El conjunto calendario mejora 6% el error respecto del baseline; añadir historia aporta 12% adicional; contexto meteorológico, 2%; e interacciones, 0,5% con alta variación. En vez de declarar que «la lluvia causa demanda», se informa que el pronóstico aporta señal predictiva condicionada a la representación. Si la interacción inestable aumenta costo, puede rechazarse aunque su media sea levemente favorable.

La ablación debe mantener fija la oportunidad experimental: mismas semanas, semillas, métrica y política de faltantes. Retirar historia puede cambiar qué filas son utilizables si algunos rezagos no existen; comparar entonces sobre muestras distintas confunde atributo y población. Se evalúan todas las variantes sobre la intersección pertinente o se informa explícitamente el compromiso de cobertura. También se distingue error del pronóstico meteorológico de error del predictor: entrenar con clima observado y desplegar con pronóstico mediría un problema artificialmente fácil.

Prueba de estrés. Se simulan un feriado no visto, una zona nueva y una interrupción de validaciones durante dos días. El calendario puede calcular el primer caso; la zona debe retroceder a una representación espacial o nivel desconocido; los rezagos del tercero requieren una política de faltantes. Esta prueba muestra que una característica útil no es solo una fórmula: incluye condiciones de disponibilidad y comportamiento degradado. Si el sistema no puede producir una fila válida ante un retraso frecuente, el diseño es operacionalmente frágil aunque su validación media sea buena.

Lista de control del ejemplo: disponibilidad real del pronóstico; zona horaria coherente; ausencia de ventanas centradas; categorías desconocidas; datos revisados después del corte; y diferencias entre demanda registrada y demanda

no satisfecha. Esta última distinción es sustantiva: viajes observados pueden estar limitados por capacidad y no medir toda la necesidad de transporte.

10.2. Selección de atributos

Seleccionar atributos consiste en elegir $S \subseteq \{1, \dots, p\}$ y entrenar con X_S . Puede reducir costo de medición, tiempo de inferencia y varianza, y facilitar interpretación. No garantiza mejor desempeño: un método regularizado puede aprovechar muchas señales débiles, y eliminar variables puede borrar interacciones útiles. La selección debe responder a un objetivo explícito y formar parte del procedimiento evaluado.

10.2.1. Relevancia y redundancia

Una variable es relevante para una tarea si aporta información sobre Y bajo la distribución y el conjunto de variables considerados. La relevancia **marginal** estudia X_j frente a Y por separado; la relevancia **condicional** pregunta si X_j agrega información dado X_{-j} . Ambas pueden diferir. Dos variables XOR tienen asociación marginal nula con la clase, pero juntas determinan perfectamente la respuesta. A la inversa, una variable puede correlacionarse con Y solo porque duplica otra.

La información mutua formaliza dependencia:

$$I(X; Y) = \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy,$$

y vale cero bajo independencia en condiciones regulares. No especifica causalidad, dirección ni utilidad para un modelo particular; además, estimarla en continuas de alta dimensión es difícil.

La redundancia aparece cuando variables contienen señal repetida. Correlación alta es una forma, no la única: $X_2 = X_1^2$ puede ser redundante para cierto modelo con correlación lineal cercana a cero. También existe redundancia operativa: dos sensores distintos pueden medir el mismo fenómeno, pero conservar ambos aporta tolerancia a fallos. Por ello, eliminar uno solo por semejanza estadística puede perjudicar robustez.

Pueden distinguirse tres categorías prácticas: variables fuertemente relevantes, cuya ausencia degrada el mejor predictor; débilmente relevantes, útiles solo en ciertos subconjuntos; e irrelevantes para la tarea. Esta clasificación depende de muestra, modelo, métrica y horizonte. En datos correlacionados, múltiples subconjuntos pueden rendir igual. Reportar una única «lista verdadera» oculta esa incertidumbre; conviene estudiar frecuencia de selección y desempeño al perturbar los datos.

La relevancia debe formularse respecto de una información disponible. Una variable puede agregar señal al conjunto bruto y dejar de hacerlo después de introducir un resumen de dominio que la contiene. Del mismo modo, «irrelevante para este modelo» no equivale a «irrelevante para cualquier predictor»: un método lineal no aprovecha una relación simétrica en U sin una transformación. Por ello, los descartes definitivos requieren distinguir limitación de la variable, de la representación y de la clase de modelo.

Una auditoría comienza con mapas de dependencia por bloques, no con un ranking único. Se agrupan mediciones del mismo sensor, derivados de una misma fuente y variables disponibles al mismo costo. Luego se pregunta qué ocurre al retirar cada bloque y al reemplazarlo por otro. Si diez columnas meteorológicas desaparecen juntas en producción, su redundancia estadística interna no aporta tolerancia. En cambio, dos fuentes independientes con señal parecida pueden ser valiosas precisamente porque una cubre los fallos de la otra.

10.2.2. Métodos de filtro

Los filtros puntúan variables sin entrenar repetidamente el estimador final. Son rápidos y útiles como descarte inicial. Entre sus criterios se encuentran varianza, tasa de faltantes, correlación, pruebas de asociación, información mutua y medidas específicas para clasificación o regresión.

Un filtro por varianza elimina columnas constantes o casi constantes. No debe confundirse variación con utilidad: una alerta rara puede ser decisiva. Los filtros univariados ordenan cada X_j por asociación con Y . Para una entrada continua y salida continua puede usarse una medida lineal o de rangos; para categoría y clase, una tabla de contingencia; para relaciones generales, información mutua estimada. Cada prueba tiene supuestos y sensibilidad al tamaño muestral.

Cuando se examinan miles de variables, algunas parecerán asociadas por azar. Los valores p no son puntuaciones predictivas y requieren control de multiplicidad si se pretende inferencia. Para predicción, el umbral o número k de variables se trata como hiperparámetro y se valida. El objetivo sigue siendo rendimiento fuera de muestra, no significación aislada.

Filtros multivariados simples buscan alta relevancia y baja redundancia. Una regla conceptual puede maximizar

$$\text{puntaje}(S) = \frac{1}{|S|} \sum_{j \in S} I(X_j; Y) - \frac{1}{|S|^2} \sum_{j, k \in S} I(X_j; X_k).$$

El equilibrio evita llenar el conjunto con copias de la misma señal, pero depende de estimaciones imperfectas.

Ventajas: velocidad, independencia del estimador y capacidad para reducir dimensiones extremas. **Limitaciones:** suelen ignorar interacciones y no optimizan la métrica final. Todo filtro supervisado usa Y y, por tanto, debe ajustarse dentro de la validación. Calcular asociaciones una vez con todos los datos antes de particionar es fuga.

Los filtros deben respetar el tipo de variable y la forma de asociación buscada. La correlación lineal responde a cambios proporcionales y es sensible a extremos; una medida de rangos captura relaciones monotónicas, pero no una forma en U; una prueba de contingencia depende de conteos esperados suficientes. Discretizar una continua para aplicar una prueba categórica introduce umbrales y puede crear o borrar asociación. No existe una puntuación que ordene justamente todas las escalas sin supuestos.

Ejemplo diagnóstico. Supónganse 10 000 términos textuales y 400 documentos. Un filtro conserva los 200 términos más asociados con la clase. Variar ligeramente los documentos cambia 80 de ellos, aunque la métrica permanece estable.

Esto sugiere señal distribuida y términos sustituibles, no 200 descubrimientos robustos. Se reportan desempeño y estabilidad del conjunto; se aumenta la frecuencia mínima para eliminar accidentes léxicos, o se prefiere regularización si no hay necesidad operativa de una lista pequeña.

10.2.3. Métodos envolventes

Los métodos envolventes o *wrappers* evalúan subconjuntos entrenando el modelo que finalmente se utilizará. Definen una búsqueda sobre 2^p posibilidades y una función objetivo de validación. La búsqueda exhaustiva solo es viable para p pequeño; en general se usan heurísticas.

La selección hacia adelante comienza sin variables y agrega en cada paso la que más mejora el criterio. La eliminación hacia atrás parte de todas y retira la menos útil. La eliminación recursiva ajusta un modelo, ordena atributos según algún criterio interno, elimina uno o un grupo y repite. También existen búsquedas estocásticas. Ninguna garantiza el óptimo global: una variable débil por sí sola puede ser esencial junto con otra, y una decisión codiciosa temprana puede impedir encontrar esa combinación.

El objetivo puede combinar error y tamaño:

$$J(S) = \widehat{R}_{CV}(S) + \gamma|S|,$$

donde $\widehat{R}_{CV}$ es riesgo de validación y γ representa costo o preferencia por parsimonia. Si dos subconjuntos tienen desempeño indistinguible, la regla de un error estándar favorece el más pequeño dentro de la incertidumbre del mejor.

El costo computacional es elevado y el propio proceso puede sobreajustar la validación: después de probar muchos subconjuntos, el ganador se beneficia del azar. Se necesita evaluación externa —validación anidada o prueba intacta—. También conviene registrar trayectorias y estabilidad. Si pequeñas perturbaciones cambian por completo el conjunto sin cambiar el error, la conclusión correcta es que existen representaciones sustituibles, no que cada variable elegida sea indispensable.

La función objetivo debe reflejar el uso. Penalizar cada columna por igual es inadecuado cuando varias columnas se obtienen de una sola prueba de laboratorio o cuando un atributo categórico se expande en cien indicadores. El costo relevante puede estar asociado a adquirir una fuente, mantener una rama o añadir latencia, por lo que la búsqueda debe operar con grupos indivisibles o costos c_j : $J(S) = \widehat{R}_{CV}(S) + \gamma \sum_{j \in S} c_j$. Esta formulación evita premiar una solución que parece pequeña después de contar columnas transformadas, pero exige el mismo número de sistemas de origen.

Las trayectorias codiciosas también permiten diagnóstico. Si la primera variable reduce mucho el riesgo y las siguientes apenas lo cambian, existe una solución parsimoniosa clara. Si varias candidatas intercambian posiciones entre pliegues, se estudian como un grupo equivalente. Si el riesgo baja en entrenamiento pero no en validación a partir de cierto tamaño, la búsqueda está incorporando ruido. Detenerse por una regla predefinida es más defendible que inspeccionar toda la trayectoria y escoger retrospectivamente el punto visualmente atractivo.

10.2.4. Métodos embebidos

Los métodos embebidos realizan selección durante el ajuste. La penalización L1 puede llevar coeficientes exactamente a cero; ciertos árboles eligen variables al construir divisiones; y otros modelos incluyen mecanismos de compuerta o restricciones estructurales. Al acoplar selección y pérdida, suelen ser más eficientes que los envoltentes y más específicos que los filtros.

En un árbol, una variable puede no aparecer porque otra correlacionada fue elegida primero, no porque carezca de señal. Árboles profundos pueden seleccionar identificadores o niveles raros y sobreajustar. Parámetros como profundidad mínima, número mínimo de casos por hoja o fuerza de penalización controlan simultáneamente capacidad y selección; deben validarse.

En modelos lineales, el resultado depende de escala: si dos columnas se miden en unidades muy diferentes, una misma penalización sobre coeficientes no implica la misma penalización sobre efectos. El escalado debe formar parte del pipeline. Las variables sin penalizar, como un intercepto o covariables obligatorias definidas por protocolo, deben declararse.

La selección embebida no elimina la necesidad de una evaluación honesta. Elegir el hiperparámetro con todos los datos y luego informar validación cruzada del modelo ya fijado omite la incertidumbre de esa elección. El procedimiento evaluado incluye tanto el estimador como su regla de selección.

Que un modelo «use» una variable tampoco implica que la haya seleccionado de forma estable. Un árbol puede dividir por ella en una rama que cubre tres observaciones; un coeficiente puede ser no nulo, pero despreciable en la escala de predicción. Conviene definir selección operacional mediante un umbral, una frecuencia o la pertenencia a cualquier estructura del modelo, y mantener esa definición durante la comparación. Cambiarla después de ver resultados transforma una propiedad descriptiva en otra búsqueda no contabilizada.

Existen restricciones estructurales útiles cuando el dominio las justifica: seleccionar o excluir un grupo completo de indicadores, respetar jerarquía entre efecto principal e interacción, o exigir que ciertas covariables de control permanezcan. Estas reglas reducen soluciones incoherentes y pueden mejorar estabilidad. Sin embargo, una variable obligatoria no debe aparecer como «descubierta» por el algoritmo; se informa por separado su inclusión protocolaria y se evalúa el aporte incremental del resto.

10.2.5. Importancia de variables

«Importancia» no es una propiedad única. Puede significar magnitud de coeficiente, reducción de impureza, pérdida de desempeño al perturbar una columna, contribución local a una predicción o frecuencia de selección. Cada definición responde a una pregunta diferente.

Los coeficientes comparan cambios condicionados al resto bajo la forma funcional del modelo. Su magnitud solo es comparable si escalas y codificaciones son coherentes. Para una categoría con varios indicadores, leer cada columna por separado fragmenta el efecto del atributo original.

La importancia por permutación calcula el aumento de pérdida al romper la relación entre X_j y la salida en datos no usados para ajustar:

$$PI_j = \mathcal{L}(f, X^{II_j}, y) - \mathcal{L}(f, X, y),$$

donde X^{II_j} permuta la columna j . Una importancia grande indica que el predictor depende de esa información bajo esa perturbación. Si dos variables son sustitutas, permutar una puede producir poco daño porque la otra conserva la señal; permutar ambas como grupo revela dependencia conjunta. Además, una permutación independiente puede crear combinaciones imposibles —por ejemplo, ciudad y código postal incompatibles—. Las permutaciones condicionales o por grupos respetan mejor la estructura, aunque son más difíciles.

La reducción de impureza en árboles tiende a favorecer variables continuas o de alta cardinalidad por ofrecer más puntos de corte. Debe complementarse con mediciones fuera de muestra. Las explicaciones locales, por su parte, describen una predicción, no relevancia poblacional ni causalidad.

Toda importancia requiere contexto: modelo, datos de referencia, métrica, incertidumbre y tratamiento de variables correlacionadas. Es recomendable informar intervalos obtenidos por repeticiones o remuestreo y analizar estabilidad por tiempo y subgrupo.

La población de referencia cambia la pregunta. Permutar temperatura durante todo el año mide dependencia promedio; hacerlo solo en invierno mide dependencia dentro de ese régimen. Una variable puede resultar importante porque identifica un subgrupo grande, aunque no diferencie casos dentro de él. Por eso el informe debe declarar sobre qué observaciones y con qué distribución se calcula la pérdida. Reponderar hacia la población de despliegue puede alterar el orden de importancias sin cambiar el modelo.

Un control de plausibilidad compara importancia con ablación y con disponibilidad. Si permutar una variable produce gran daño, pero retirar y reajustar el modelo apenas afecta, otras variables pueden recuperar su función tras el entrenamiento: la primera medida describe dependencia del predictor fijado; la segunda, sustituibilidad para el procedimiento. Ambas son válidas y responden preguntas distintas. Ninguna autoriza afirmar que cambiar físicamente la variable alterará la salida real, porque la perturbación estadística no representa necesariamente una intervención posible.

10.2.6. Regularización L1 y L2

Para un modelo lineal con pérdida cuadrática, ridge o L2 resuelve

$$\hat{\beta}^{L2} = \arg \min_{\beta} \left\{ \frac{1}{n} \|\mathbf{y} - X\beta\|_2^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

La penalización contrae coeficientes, reduce varianza y estabiliza problemas colineales, pero en general no produce ceros exactos. Con columnas centradas y sin penalizar el intercepto, la solución es $(X^T X + n\lambda I)^{-1} X^T \mathbf{y}$. El término diagonal vuelve invertible la matriz incluso cuando $p > n$ o existe multicolinealidad.

Lasso o L1 sustituye cuadrados por valores absolutos:

$$\hat{\beta}^{L1} = \arg \min_{\beta} \left\{ \frac{1}{n} \|\mathbf{y} - X\beta\|_2^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

La geometría con esquinas de la restricción L1 favorece soluciones sobre ejes, es decir, coeficientes nulos. Por ello realiza contracción y selección. Con predictores fuertemente correlacionados puede elegir uno de forma inestable; L2 tiende a repartir peso. Elastic Net combina $\lambda[\alpha\|\beta\|_1 + (1-\alpha)\|\beta\|_2^2]$ y puede conservar grupos correlacionados.

Ejemplo conceptual. Dos acelerómetros casi idénticos miden vibración en una máquina. Sin regularización, sus coeficientes pueden ser grandes y de signo opuesto ante pequeñas perturbaciones. Ridge los estabiliza y distribuye señal. Lasso puede dejar uno en cero, útil si se desea retirar un sensor, pero la identidad elegida puede cambiar entre muestras. Si el costo de medición difiere, una penalización ponderada puede reflejarlo.

$\lambda = 0$ recupera el ajuste no penalizado; al aumentar λ , crece el sesgo y suele caer la varianza. El valor se elige dentro de validación. La estandarización previa es esencial y también se estima en cada pliegue. Un coeficiente cero no prueba ausencia causal, y uno no nulo no prueba causalidad.

La contracción puede verse con un predictor estandarizado y ortogonal a los demás. Si $\hat{\beta}_j^{OLS}$ es su coeficiente no penalizado, ridge lo multiplica por un factor menor que uno; lasso aplica un umbral suave: reduce su magnitud y la hace cero cuando la señal no supera un nivel ligado a λ . Con predictores correlacionados esta lectura componente a componente deja de ser exacta, que es precisamente donde la geometría conjunta explica la inestabilidad de L1.

La trayectoria de coeficientes frente a λ es un diagnóstico, no un método alternativo de selección. Entradas muy tempranas y estables sugieren señal fuerte bajo esa especificación; cruces de signo o sustituciones repetidas revelan colinealidad. El error de validación suele presentar una región plana, por lo que escoger el mínimo numérico exagera precisión. Puede elegirse una penalización mayor dentro de un error estándar si reduce variables y mejora estabilidad, siempre que la regla se haya fijado antes de consultar prueba.

10.2.7. Selección dentro de la validación cruzada

La selección aprende de los datos y debe repetirse en cada pliegue. El protocolo correcto para cada partición es: ajustar preprocesamiento con entrenamiento interno, puntuar o seleccionar usando solo ese entrenamiento, ajustar el modelo sobre las columnas seleccionadas y evaluar en la validación intacta.

ENTRADA: datos D, generador de particiones y conjunto de configuraciones H
PARA cada configuración h en H:

 PARA cada partición (entrenamiento, validación):

 ajustar imputación, codificación y escala con entrenamiento

 ajustar selector de h con entrenamiento transformado y sus etiquetas

 transformar entrenamiento y validación con los objetos ajustados

 ajustar el estimador de h con el entrenamiento seleccionado

 evaluar una vez sobre validación seleccionada

 agregar las métricas de los pliegues

elegir h según la regla predefinida
 reajustar el pipeline completo con todos los datos de desarrollo
 evaluar una vez en prueba o desplegar

El error típico consiste en seleccionar las 20 variables más asociadas con Y usando todo el conjunto y ejecutar validación cruzada solo después. Aunque el estimador nunca vea las etiquetas de validación directamente, la lista de columnas ya las resume. En dimensiones altas, el optimismo puede ser enorme incluso con etiquetas aleatorias.

Si además se quieren estimar sin sesgo el desempeño y la elección de hiperparámetros, se usa validación anidada. El bucle interno elige número de variables, penalización y otros parámetros; el externo evalúa el procedimiento completo. Los subconjuntos pueden cambiar entre pliegues. Para obtener el modelo final se vuelve a ajustar con todos los datos de desarrollo, y su conjunto no tiene por qué coincidir con ninguno de los anteriores.

La frecuencia $\hat{\pi}_j = B^{-1} \sum_{b=1}^B I(j \in S_b)$ resume estabilidad sobre pliegues o remuestras. No es una probabilidad causal, pero revela selecciones frágiles. Deben preservarse grupos, orden temporal y estructura espacial también en estos bucles.

Hay dos niveles de incertidumbre que no deben mezclarse. El bucle interno elige la configuración para cada entrenamiento externo; las métricas externas estiman la generalización del procedimiento. Reutilizar los pliegues internos para reportar desempeño ignora el sesgo de haber escogido al ganador. A su vez, seleccionar una configuración distinta en cada pliegue externo es normal: lo que se evalúa es la regla de elección, no un conjunto fijo decidido con información futura.

El registro por pliegue debería incluir variables candidatas y seleccionadas, umbral, hiperparámetros, número de filas efectivas y fallos de transformación. Así se puede explicar si una frecuencia baja proviene de sustitución estadística o de que una categoría desapareció en ciertos entrenamientos. Cuando existe estructura agrupada, la estabilidad se informa también a nivel de fuente o concepto. Un conjunto de indicadores individuales puede ser inestable mientras el atributo categórico original se conserva siempre.

10.2.8. Ejemplo práctico guiado: selección de variables de calidad del agua

Escenario. Se estudia ahora un problema de mantenimiento industrial: anticipar, al inicio de cada turno, si una máquina requerirá intervención en las 24 horas siguientes. Hay 2400 turnos de 80 máquinas y 46 variables: vibración por bandas, temperatura, potencia, velocidad, antigüedad, familia de producto y resúmenes causales. El costo de no detectar una avería es alto. Todos los turnos de una misma máquina se mantienen juntos en la evaluación externa cuando interesa transferir a equipos no vistos; una segunda evaluación temporal mide generalización a meses futuros en la flota conocida.

Diagnóstico inicial. Se retiran dos columnas constantes mediante una regla no supervisada ajustada en cada entrenamiento. Los indicadores derivados del mismo acelerómetro se tratan como familia y se identifican duplicados expresados en unidades distintas. «Código final de reparación» se excluye porque aparece después de la decisión. La tasa de faltantes puede conservarse como señal del

proceso de captura, pero se comprueba si aumenta después de que el personal sospecha una avería: en ese caso sería un proxy de una decisión humana ya tomada, no un antecedente estable.

Comparación. Se definen cuatro pipelines bajo las mismas particiones y métrica principal:

Estrategia	Hiperparámetro	Resultado ilustrativo PR-AUC	Variables	E
Sin selección, L2	fuerza L2	0,71	44	
Filtro univariado	$k \in \{8, 16, 24, 32\}$	0,69	24	
Eliminación recursiva	tamaño del subconjunto	0,72	16	
Elastic Net embebido	L1/L2 y fuerza	0,73	19	

Los números son didácticos: no bastan las medias. Se inspeccionan intervalos, sensibilidad al umbral operativo, calibración, costo de medición y desempeño por familia de máquina. La diferencia 0,01 entre envolvente y Elastic Net puede estar dentro de la variación entre pliegues. El filtro pierde una interacción entre temperatura del cojinete y carga; la envolvente es costosa e inestable; Elastic Net ofrece un compromiso. Como todos los métodos reciben exactamente los mismos pliegues, también se comparan diferencias de PR-AUC por pliegue, no intervalos de cada media como si fueran experimentos independientes.

Redundancia y costo. Dos acelerómetros están muy correlacionados. El objetivo no es necesariamente eliminar uno: si proceden de posiciones distintas, su concordancia permite detectar fallos de captura y su desacuerdo puede ser una característica de diagnóstico. En cambio, si ambos dependen del mismo controlador y fallan juntos, la redundancia estadística no aporta resiliencia. Se compara el costo por fuente, no solo el número de columnas, porque retirar diez bandas calculadas por un dispositivo puede ahorrar una adquisición mientras retirar nueve y conservar una no reduce ningún costo.

Interpretación. La importancia por permutación agrupada muestra dependencia de vibración, temperatura y carga, pero no demuestra que reducir una lectura cambie el riesgo: podría ser un síntoma. Se reportan frecuencias de selección por variable y por dispositivo; ninguna lista se presenta como verdad única. La envolvente elige alternativamente dos bandas vecinas en distintos pliegues, mientras el bloque de vibración aparece siempre. La conclusión correcta es estabilidad del concepto e inestabilidad de su representante, no que una frecuencia individual de 0,55 vuelva prescindible toda la fuente.

Decisión de umbral. Como los falsos negativos son costosos, la selección no se resuelve maximizando exactitud. Para cada pipeline se elige en el bucle interno un umbral que alcance una sensibilidad mínima y luego se comparan precisión, carga de inspecciones y calibración en el bucle externo. Una estrategia con PR-AUC algo mayor puede ser inviable si concentra falsas alarmas en una línea crítica o si supera la cantidad diaria de revisiones. El umbral no se reutiliza automáticamente al cambiar el subconjunto: contracción, selección y calibración alteran la distribución de puntuaciones.

Prueba de estabilidad operativa. Se repite el análisis ocultando, por turno, familias de sensores y máquinas completas. Si el modelo de 19 variables pierde casi toda capacidad al faltar vibración, esa dependencia se documenta y se diseña una ruta degradada; no se oculta bajo el promedio. Se examina además

si «inspección extraordinaria solicitada» anticipa la etiqueta porque activa el registro posterior de averías. Se la excluye: a la hora de predicción representa una sospecha de especialistas que no estará siempre disponible y mezcla el modelo con el proceso de etiquetado.

Elección final. Elastic Net queda dentro de un error estándar del mejor resultado, conserva familias técnicamente plausibles y presenta mayor estabilidad; se elige sobre la eliminación recursiva. Antes de cerrar, se reajusta el pipeline con desarrollo completo y se evalúa una sola vez en el período reservado. El informe entrega dos configuraciones: una normal con 19 variables y otra degradada sin el acelerómetro principal. Esta decisión evidencia que seleccionar atributos no termina en un ranking; termina en un contrato de medición, un régimen de operación y una estimación honesta de lo que se pierde cuando una fuente deja de estar disponible.

10.3. Reducción de dimensionalidad

La reducción crea una representación $Z = g(X)$ con $q < p$. Puede comprimir, eliminar ruido, facilitar visualización o construir variables latentes. A diferencia de la selección, una coordenada de Z puede combinar muchas columnas originales. El precio es una interpretación menos directa y, si la transformación no se ajusta correctamente, otra oportunidad de fuga.

10.3.1. Maldición de la dimensionalidad

El término «maldición de la dimensionalidad» reúne varios fenómenos que aparecen al crecer p . Si cada eje se divide en m intervalos, una cuadrícula contiene m^p celdas. Con diez intervalos y veinte variables habría 10^{20} regiones: los datos disponibles ocupan una fracción insignificante. Mantener densidad local exige un número de observaciones que crece exponencialmente bajo supuestos generales.

En un hipercubo unitario, el volumen de un vecindario que cubre una fracción r por eje es r^p . Para abarcar 10% del rango en cada una de 20 dimensiones, el volumen es 10^{-20} . Por eso «local» deja de significar cercano con muestras moderadas.

Las distancias también se concentran. Si componentes independientes aportan cantidades similares, la suma de p diferencias cuadráticas tiene variación relativa decreciente: la distancia al vecino más próximo y al más lejano se vuelven comparativamente parecidas. Variables irrelevantes añaden ruido a la noción de similitud. Métodos de vecinos, densidad y agrupamiento son especialmente sensibles, aunque ningún modelo queda inmune al aumento de capacidad.

Puede verse en un caso idealizado. Si $X_j - X'_j$ son diferencias independientes, centradas y con segundo momento m_2 , entonces $E[d^2] = pm_2$. Si además $\text{Var}((X_j - X'_j)^2) = \nu$, resulta $\text{Var}(d^2) = p\nu$ y el coeficiente de variación de d^2 es $\sqrt{\nu}/(m_2\sqrt{p})$. La escala absoluta aumenta, pero la dispersión relativa cae como $p^{-1/2}$. Esta derivación no prueba que toda distancia real se concentre: correlación, dispersión y estructura intrínseca cambian el resultado. Sí explica por qué añadir coordenadas ruidosas puede borrar el contraste que hacía útil a un vecino.

Alta dimensionalidad no siempre significa muchos campos de origen. Una variable categórica de miles de niveles, una expansión polinómica o un vocabulario textual

pueden generar $p \gg n$. El rango de X no supera $\min(n, p)$ y la matriz de covarianza es singular cuando faltan observaciones suficientes. Existen infinitas soluciones lineales que interpolan el entrenamiento sin restricciones.

No obstante, los datos pueden concentrarse cerca de una estructura de dimensión intrínseca menor: imágenes con millones de píxeles están condicionadas por objetos, iluminación y pose. Regularización, selección y representaciones latentes explotan estructura; no «derrotran» la maldición sin supuestos.

10.3.2. Proyecciones y representaciones latentes

Una proyección lineal transforma $X \in \mathbb{R}^{n \times p}$ en $Z = XW$, con $W \in \mathbb{R}^{p \times q}$. Cada columna de W define una dirección y cada coordenada latente es combinación de entradas. Si $W^T W = I_q$, las direcciones son ortonormales. La reconstrucción lineal $\hat{X} = ZW^T$ aproxima los datos en el subespacio.

Las variables latentes no son directamente observadas. Pueden representar factores como «intensidad general de vibración» o «perfil de hora pico», pero ese nombre es una interpretación humana apoyada en cargas y contexto, no una identidad matemática garantizada.

Los objetivos de una representación varían:

- **Reconstrucción:** conservar suficiente información para aproximar X .
- **Separación:** preservar estructura relevante para grupos o clases.
- **Predicción:** conservar información sobre Y .
- **Geometría:** mantener distancias o vecindarios.
- **Compresión:** reducir memoria y costo.

PCA optimiza reconstrucción lineal y varianza, no predicción. Una dirección de baja varianza puede separar perfectamente una clase rara y ser descartada. Los métodos supervisados incorporan Y , pero deben ajustarse dentro de validación y pueden sobreajustar más.

La reducción también puede ser aleatoria. Bajo ciertas condiciones, proyecciones aleatorias a dimensión del orden de $\log n/\varepsilon^2$ preservan aproximadamente distancias entre n puntos. Son rápidas y no aprenden orientaciones, aunque sus coordenadas rara vez son interpretables. Esto muestra que comprimir no siempre requiere descubrir factores semánticos.

Antes de elegir técnica se declara qué pérdida es aceptable. Una proyección puede reconstruir bien señales comunes y borrar eventos raros; otra puede preservar vecinos, pero distorsionar escalas globales. También se distingue **compresión inductiva**, que proporciona una regla para transformar casos nuevos, de una disposición **transductiva**, definida solo para los puntos analizados. La segunda puede servir para una figura exploratoria y resultar inútil en inferencia. Esta distinción prepara la elección de PCA: su regla lineal es inductiva y su objetivo está matemáticamente especificado, aunque no siempre coincide con la tarea final.

10.3.3. Análisis de componentes principales

Sea X una matriz cuyas columnas han sido centradas: $\sum_i x_{ij} = 0$. Se busca una dirección unitaria $\mathbf{w}_1$ tal que las proyecciones $z_i = \mathbf{x}_i^T \mathbf{w}_1$ tengan máxima varianza.

Con covarianza muestral $S = X^T X / (n - 1)$,

$$\mathbf{w}_1 = \arg \max_{\|\mathbf{w}\|_2=1} \mathbf{w}^T S \mathbf{w}.$$

Introduciendo el multiplicador de Lagrange,

$$\mathcal{J}(\mathbf{w}, \lambda) = \mathbf{w}^T S \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{w} - 1).$$

Al derivar e igualar a cero se obtiene $S\mathbf{w} = \lambda\mathbf{w}$. Por tanto, la primera carga es el autovector asociado al mayor autovalor; la varianza de sus puntuaciones es λ_1 . Las direcciones siguientes maximizan varianza sujetas a ortogonalidad con las anteriores y corresponden a autovectores ordenados $\lambda_1 \geq \dots \geq \lambda_p \geq 0$.

Si $W_q = [\mathbf{w}_1, \dots, \mathbf{w}_q]$, las puntuaciones son $Z = XW_q$ y la reconstrucción centrada es $\widehat{X} = ZW_q^T$. Entre todas las aproximaciones lineales de rango q , esta minimiza el error cuadrático

$$\|X - \widehat{X}\|_F^2 = \sum_{j=q+1}^r (n-1)\lambda_j,$$

donde r es el rango. La descomposición en valores singulares $X = U\Sigma V^T$ calcula lo mismo de forma estable: las cargas son columnas de V , las puntuaciones son $U\Sigma$ y $\lambda_j = \sigma_j^2 / (n-1)$.

El centrado es indispensable: sin él, la primera dirección puede apuntar hacia la media respecto del origen. Estandarizar además es una decisión sustantiva. PCA sobre covarianzas da mayor peso a variables con gran varianza y unidad; PCA sobre correlaciones equivale a estandarizar y trata cada columna con varianza uno. Si todas miden lo mismo y la magnitud es significativa, estandarizar puede ser inadecuado; si se mezclan vibración, temperatura y potencia, suele ser necesario.

Ejemplo bidimensional. Para una covarianza $S = \begin{pmatrix} 4 & 3 \\ 3 & 4 \end{pmatrix}$, el polinomio característico es $(4 - \lambda)^2 - 9 = 0$, con autovalores 7 y 1. Las direcciones normalizadas son $(1, 1)/\sqrt{2}$ y $(1, -1)/\sqrt{2}$. PC1 resume el movimiento conjunto de ambas variables y explica $7/(7+1) = 87,5\%$; PC2 representa su contraste. Conservar solo PC1 aproxima bien puntos cercanos a la diagonal, pero elimina precisamente las discrepancias entre sensores. Si esas discrepancias anuncian una descalibración, el componente de menor varianza puede ser operacionalmente decisivo.

10.3.4. Varianza explicada

La varianza total de las columnas centradas es $\text{tr}(S) = \sum_j \lambda_j$. La proporción explicada por el componente j es

$$\text{PVE}_j = \frac{\lambda_j}{\sum_{k=1}^p \lambda_k},$$




Figura 13: Geometría de PCA: ejes principales, proyección y reconstrucción

y la proporción acumulada de q componentes es $\sum_{j=1}^q \text{PVE}_j$. Un gráfico de sedimentación muestra autovalores o proporciones frente al índice y permite buscar un «codo», aunque este criterio puede ser ambiguo.

Ejemplo calculado. Para autovalores (4,2; 2,1; 0,5; 0,2), la varianza total es 7. Los dos primeros componentes explican $4,2/7 = 60\%$ y $2,1/7 = 30\%$; juntos, 90%. Conservarlos produce error medio de reconstrucción asociado al 10% restante. No significa conservar 90% de capacidad predictiva, significado o información en sentido general.

Elegir q depende del objetivo. Para compresión puede fijarse un umbral de varianza y presupuesto. Para predicción, q es un hiperparámetro evaluado con el modelo y métrica final. Para visualización se usan dos o tres dimensiones, reconociendo la pérdida. Para detección de anomalías puede importar tanto una puntuación extrema en componentes retenidos como un gran residuo en el subespacio descartado.

El criterio de autovalores mayores que uno solo tiene una lectura específica cuando se parte de variables estandarizadas, y tampoco es una ley. Comparar con datos nulos o usar validación de reconstrucción aporta referencias más defendibles. La selección debe considerar estabilidad: componentes con autovalores casi iguales pueden rotar mucho entre muestras aunque el subespacio conjunto sea estable.

10.3.5. Interpretación de componentes

Las **cargas** w_{jk} expresan cuánto participa la variable j en el componente k ; las **puntuaciones** z_{ik} ubican la observación i . Confundir ambas conduce a interpretaciones erróneas. Una carga positiva grande y otra negativa grande indican que el componente contrasta esas variables. Su signo global es arbitrario: $(\mathbf{w}, -\mathbf{z})$ representa exactamente la misma solución que $(-\mathbf{w}, \mathbf{z})$.

En datos estandarizados, si el primer componente tiene cargas similares y positivas sobre vibración axial, radial y tangencial, podría describirse como intensidad vibratoria general, siempre que el dominio lo respalde. Si el segundo carga positivamente en temperatura y negativamente en eficiencia energética,

puede expresar un contraste térmico-operativo. Estos nombres son resúmenes, no variables observadas.

Un *biplot* representa puntuaciones y vectores de carga en un mismo plano con una convención de escala. Ángulos pequeños entre vectores sugieren asociación positiva, opuestos asociación negativa y cercanos a 90° baja asociación lineal en la proyección. Las longitudes y distancias solo se interpretan según el escalado elegido.

Debe comprobarse:

- contribución de cada variable y observación;
- calidad de representación en los componentes mostrados;
- sensibilidad a extremos y a escalado;
- estabilidad mediante remuestreo o períodos;
- coherencia con unidades y mecanismos.

PCA es sensible a valores extremos porque usa cuadrados y covarianzas. Un único punto puede rotar los ejes. También una mezcla de grupos puede generar un componente que separa centros sin describir variación interna. Las versiones robustas o análisis estratificados pueden ser necesarios. Una rotación posterior puede facilitar estructura simple, pero modifica el criterio y debe documentarse.

10.3.6. Introducción a métodos no lineales

Si los datos viven cerca de una curva o variedad, una proyección lineal puede necesitar muchas dimensiones. Los métodos no lineales intentan preservar vecindarios, distancias geodésicas, probabilidades de proximidad o reconstrucciones flexibles. Sus objetivos y garantías difieren; «no lineal» no designa un método intercambiable.

Los métodos espectrales construyen un grafo de vecindad y usan autovectores de matrices asociadas. Pueden desplegar estructuras curvas, pero dependen de número de vecinos, métrica y conectividad. Los métodos basados en probabilidades de vecindad producen visualizaciones donde puntos similares quedan próximos; suelen preservar estructura local mejor que distancias globales. Otros optimizan una representación con redes codificador-decodificador, capaces de reconstrucciones complejas a costa de datos, ajuste y menor transparencia.

Una extensión por funciones núcleo aplica implícitamente PCA en un espacio transformado. La elección de núcleo y escala determina qué no linealidad se considera semejante. Como otros hiperparámetros, se eligen sin consultar prueba.

Precauciones esenciales:

- los ejes no suelen tener una interpretación directa;
- distancias entre grupos visuales pueden no reflejar distancia original;
- la forma puede cambiar con semilla e hiperparámetros;
- algunos métodos no definen fácilmente cómo proyectar una observación nueva;
- ajustar sobre todo el conjunto antes de evaluar un modelo supervisado produce fuga.

Una visualización atractiva no demuestra la existencia de grupos. Debe acompañarse con sensibilidad, métricas en el espacio original y conocimiento del

muestreo. Para producción es imprescindible disponer de una transformación de nuevas observaciones o de una política explícita de reajuste.

La elección puede organizarse por pregunta. Si se necesita reconstrucción lineal, una transformación estable de nuevos casos y una referencia interpretable, PCA es un punto de partida. Si interesa preservar vecindarios para exploración, un método no lineal puede revelar curvatura, pero se evalúan continuidad y confianza de vecinos. Si se requiere compresión para predecir, se compara la representación dentro del pipeline supervisado contra selección y regularización sin reducción. Un fallo común es escalar el método hasta producir la figura esperada; la sensibilidad debe mostrar qué conclusiones sobreviven, no qué hiperparámetro dibuja grupos más nítidos.

10.3.7. Visualización de datos de alta dimensión

Visualizar alta dimensión exige varias vistas complementarias. Una proyección 2D siempre omite información. PCA permite mostrar la mayor varianza lineal; pares de componentes revelan estructura adicional; coordenadas paralelas muestran perfiles, aunque se saturan con muchas filas; mapas de calor ordenados revelan bloques; matrices de dispersión sirven para subconjuntos; y pequeñas múltiples comparan grupos o tiempo.

Una práctica responsable informa la varianza representada por cada eje. Si PC1 y PC2 explican 32%, la distancia visible resume menos de un tercio de la variación lineal. Los puntos cercanos en el plano podrían estar lejos en componentes omitidos. Colorear por etiqueta ayuda a explorar, pero también puede inducir a ver separación donde hubo selección o ajuste supervisado.

Las observaciones deben representarse con transparencia, muestreo o agregación cuando existe solapamiento. Conviene marcar centroides e incertidumbre, no solo nubes. En proyecciones no lineales se repite el análisis con varias semillas y valores de vecindad, y se contrasta la preservación de vecinos. Las etiquetas se añaden después de ajustar una proyección no supervisada si se pretende una exploración descriptiva limpia.

La visualización también puede detectar calidad: lotes, dispositivos o períodos separados podrían revelar cambio de captura en lugar de fenómeno. Antes de interpretar un grupo como segmento natural, se colorea por fuente, faltantes y fecha. La pregunta no es solo «¿qué forma tiene?», sino «¿qué proceso pudo producir esa forma?».

Un protocolo de lectura separa observación y explicación. Primero se describen densidad, solapamiento y puntos extremos; después se cuantifica cuánto preserva la vista; por último se contrastan hipótesis con variables que no participaron en la proyección. Si un grupo coincide exactamente con un lote de carga, se revisa el instrumento antes de atribuirle significado sustantivo. Si desaparece al cambiar la semilla o al retirar cinco observaciones influyentes, se informa como artefacto inestable. El gráfico funciona así como instrumento diagnóstico, no como resultado autosuficiente.

10.3.8. Ejemplo práctico guiado: proyección de un dataset multivariado

Datos. Se analizan 300 lotes de una línea de fabricación con ocho variables continuas: temperatura media y máxima, potencia activa, energía específica,

vibración axial y radial, velocidad y duración del ciclo. Las unidades difieren y algunas distribuciones tienen extremos plausibles. El objetivo inicial es compresión exploratoria, no clasificación.

Preparación. Se separa un período posterior para comprobar estabilidad. La imputación robusta y el escalado se ajustan solo con desarrollo. Se examinan extremos antes de decidir transformaciones; energía específica se transforma por su rango multiplicativo, y todas las columnas se estandarizan para que la unidad no determine PCA. Un lote detenido por seguridad no se imputa como un ciclo ordinario: se excluye de este análisis descriptivo y se registra como población distinta.

Cálculo ilustrativo. Los primeros autovalores sobre la matriz de correlación son 3,10; 1,72; 1,05; 0,74; 0,55; 0,40; 0,28 y 0,16. Al sumar ocho, PC1 explica 38,8%, PC2 21,5% y PC3 13,1%; tres componentes acumulan 73,4%. El codo sugiere entre dos y tres. En vez de adoptar automáticamente 80%, se comparan reconstrucción, estabilidad y utilidad de la vista.

Lectura. PC1 carga positivamente sobre potencia, temperatura y energía específica: se propone «intensidad operativa». PC2 contrasta velocidad con duración del ciclo, coherente con distintos regímenes de producción. PC3 está dominado por vibración radial. Se conserva el lenguaje tentativo y se revisan correlaciones originales. Dos lotes extremos en PC3 corresponden a desalineaciones confirmadas; eliminarlos sin análisis borraría un fenómeno real, aunque mantenerlos puede rotar la solución. Se repite PCA con y sin esos lotes y se informa la sensibilidad.

Validación. Las cargas aprendidas en desarrollo transforman el período posterior sin recalcular medias ni ejes. Para cada lote se calcula $Q_i = \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2$, el residuo de reconstrucción, y se comparan su distribución y las puntuaciones con las referencias de desarrollo. Un aumento de Q_i indica comportamiento fuera del subespacio histórico; una puntuación extrema con Q_i bajo describe un caso lejano, pero alineado con un patrón conocido. Ninguna señal diagnostica por sí sola la causa. Si PCA fuera parte de un predictor, q se elegiría dentro de validación según la métrica final, no con el conjunto completo.

Conclusión. Tres componentes ofrecen un resumen razonable, pero no sustituyen las variables originales en informes de mantenimiento que exigen unidades físicas. Se conservan ambos: representación latente para exploración y mediciones trazables para interpretación. El período posterior mantiene el subespacio general, aunque PC3 cambia de signo, lo cual no constituye deriva porque el signo es arbitrario. Para comparar componentes se alinean signos y se estudian ángulos entre subespacios, evitando confundir una convención algebraica con un cambio del proceso.

10.4. Pipelines de representación y modelado

Un pipeline define una función compuesta que va desde el esquema de entrada hasta la predicción. Su propósito no es solo comodidad: establece qué aprende cada etapa, impide aplicar transformaciones inconsistentes y permite evaluar el procedimiento real. Un pipeline correcto conserva linaje, orden, parámetros y contrato de inferencia.

10.4.1. Transformaciones encadenadas

Sean transformaciones $T_1, \dots, T_m$ y estimador f . El predictor completo es

$$\hat{y} = f_{\hat{\theta}_f} \circ T_{m, \hat{\theta}_m} \circ \dots \circ T_{1, \hat{\theta}_1}(x),$$

donde cada $\hat{\theta}$ se aprende con entrenamiento. Imputar, escalar, expandir, seleccionar y reducir no son operaciones independientes: cambiar una altera la entrada de la siguiente.

El orden importa. Imputar antes de estandarizar evita operar sobre faltantes; generar razones puede requerir valores originales y reglas para denominadores; seleccionar antes de una expansión reduce costo, pero puede eliminar variables que solo son útiles por interacción; PCA suele requerir centrado y, según unidades, escalado. No existe un orden universal, pero debe ser explícito y validado.

Cada etapa implementa dos operaciones conceptuales: **ajustar**, que estima parámetros, y **transformar**, que aplica esos parámetros. En inferencia nunca se vuelve a ajustar. Incluso una transformación «simple» puede aprender: lista de categorías, vocabulario textual, mediana, nudos, umbral de selección y componentes principales.

Un pipeline también debe preservar nombres y correspondencia entre columnas. Después de una codificación indicadora o una proyección, el número y significado cambian. Registrar el mapa permite auditar importancias, detectar columnas inesperadas y reproducir una predicción.

El pipeline se prueba como composición, no solo etapa por etapa. Una mediana válida seguida de un logaritmo puede fallar si la imputación produce cero; agrupar niveles antes de dividir por entidad puede convertir identificadores raros en una señal compartida; una selección por nombre puede tomar columnas equivocadas después de reordenarlas. Las pruebas de contrato incluyen una fila nominal, faltantes permitidos, categorías nuevas, extremos físicos y un lote con orden distinto. Para cada caso se verifica dimensión, finitud, nombres y resultado esperado. Esta perspectiva detecta fallos en las interfaces, donde suelen aparecer errores aunque cada transformación aislada parezca correcta.

10.4.2. Columnas numéricas, categóricas y textuales

Los datos heterogéneos requieren ramas por tipo semántico, no solo por tipo de almacenamiento. Un código numérico puede ser categórico; una fecha almacenada como texto es temporal; un comentario libre no debe tratarse como categoría con un nivel por frase.

Rama	Operaciones posibles	Salida	Riesgo principal
Numérica	imputación, banderas, transformación, escala	columnas densas	unidades, extremos y faltantes informativos

Rama	Operaciones posibles	Salida	Riesgo principal
Categorica	normalización, niveles raros, indicadores	matriz a menudo dispersa	categorías nuevas y cardinalidad
Textual	segmentación conceptual, conteos o ponderación	muy alta dimensión dispersa	vocabulario aprendido con datos externos al pliegue
Temporal	calendario, ciclos, rezagos causales	columnas densas	futuro y zona horaria
Espacial	proyección, distancias, vecindarios	densas o categóricas	autocorrelación, privacidad y referencia geográfica

Tras transformar ramas, sus salidas se concatenan. El escalado conjunto requiere cuidado: centrar una matriz dispersa de indicadores puede volverla densa y agotar memoria. Algunas familias de modelos admiten escalas mixtas mejor que otras. Las características textuales pueden dominar por cantidad aunque cada una sea débil; regularización por grupos o pesos de rama pueden equilibrar el problema.

El esquema forma parte del modelo. Debe definir columnas obligatorias, tipos, unidades, valores permitidos y política para extras o ausencias. Una columna que cambia de metros a kilómetros sin cambiar nombre produce predicciones válidas en formato y erróneas en contenido.

Los faltantes merecen una decisión por rama y no una receta uniforme. En una entrada numérica, mediana más indicador puede separar ausencia de valor típico; en texto, una cadena vacía debe distinguirse de un comentario que realmente dice «sin observaciones»; en categorías, un nivel ausente no equivale a uno desconocido. También se controla la densidad resultante. Concatenar miles de términos dispersos con unas pocas columnas densas puede exigir una representación que preserve dispersión; centrarla accidentalmente multiplica memoria. Antes del ajuste se estima dimensión máxima, porcentaje esperado de no ceros y conducta ante vocabularios o cardinalidades crecientes.

10.4.3. Ajuste conjunto con el modelo

«Ajuste conjunto» significa que representación y estimador se consideran un único objeto estadístico en validación. No necesariamente que todos sus parámetros se optimicen por gradiente. En cada pliegue se ajustan imputación, codificación, selección o PCA y luego el modelo usando únicamente el entrenamiento del pliegue.

Esta unidad permite comparar preguntas completas: «imputación robusta + indicadores + PCA de 12 componentes + regresor regularizado» frente a «imputación por mediana + indicadores + selección + otro estimador». Comparar solo estimadores sobre una matriz preprocesada globalmente evalúa algo distinto y puede filtrar información.

Las transformaciones supervisadas requieren atención adicional. Un codificador por objetivo o selector usa Y ; para generar entradas del propio entrenamiento sin

sobreajuste puede necesitar codificación fuera de pliegue interna. En validación recibe únicamente el mapeo ajustado con entrenamiento. Es posible que haya niveles sin estadísticas, resueltos mediante suavizado y regla de desconocidos.

El pipeline final se reajusta sobre todos los datos de desarrollo después de fijar la configuración. La prueba se transforma una vez y no participa de decisiones. En producción, una observación atraviesa exactamente las mismas etapas con parámetros congelados. Si una etapa necesita información de lote —por ejemplo, normalizar respecto de otros casos recibidos juntos—, el contrato debe especificarlo porque una predicción individual podría no ser equivalente.

Existe una distinción útil entre parámetros de representación y estado operacional. Las medias, cargas y vocabulario se congelan con el ajuste; los rezagos de una entidad se consultan en un almacén que evoluciona con el tiempo. Ese estado no puede reconstruirse usando eventos posteriores ni actualizarse dos veces por reintentos. Una simulación histórica debe reproducir el orden «leer estado, predecir, incorporar evento cuando esté disponible». De lo contrario, un pipeline formalmente correcto puede obtener ventaja del futuro a través de su infraestructura de características.

10.4.4. Búsqueda de hiperparámetros

La representación introduce hiperparámetros: estrategia de imputación, frecuencia mínima de categorías, grado de expansión, número de variables, q de PCA, fuerza L1/L2 y parámetros del modelo. Deben buscarse de manera coordinada porque interactúan. Un modelo lineal puede necesitar interacciones explícitas; un árbol quizá no. El mejor número de componentes depende de regularización y métrica.

Una grilla enumera combinaciones; búsqueda aleatoria explora con mayor eficiencia cuando pocas dimensiones importan; métodos adaptativos asignan más evaluaciones a regiones prometedoras. Cualquiera puede sobreajustar la validación si se prueban suficientes configuraciones. Se predefine presupuesto, espacio y regla de selección, y se reserva una evaluación externa.

definir particiones externas respetando tiempo, grupos o espacio

PARA cada partición externa:

 reservar su bloque como evaluación

 sobre el resto, comparar pipelines completos mediante particiones internas

 elegir una configuración con métrica y regla predefinidas

 reajustar esa configuración sobre todo el bloque interno

 evaluar una vez en el bloque externo

agregar resultados externos e incertidumbre

elegir configuración final y ajustarla con todos los datos de desarrollo

Es incorrecto elegir PCA por varianza usando todo el conjunto, optimizar el modelo por validación y llamar «anidado» al resultado. También lo es revisar prueba repetidamente mientras se cambia el espacio. El conjunto de prueba se consume: después de orientar decisiones deja de ser una estimación independiente.

Además del promedio, se consideran dispersión, costo, latencia y complejidad. Una configuración levemente inferior pero estable y simple puede ser preferible. La regla de un error estándar formaliza parte de este criterio.

El espacio de búsqueda expresa supuestos y debe ser coherente. Probar q de PCA

mayor que el rango disponible en ciertos pliegues, combinar centrado denso con una rama textual dispersa o pedir más atributos de los que sobreviven a un filtro produce configuraciones inválidas, no resultados malos. Se definen dependencias condicionales y una política para fallos antes de ejecutar la búsqueda. También se guarda la trayectoria completa: si el ganador está en el borde del intervalo de λ , quizá el espacio quedó truncado; si muchas configuraciones empatan, la incertidumbre favorece la más simple y no justifica una exploración retrospectiva ilimitada.

10.4.5. Interpretabilidad frente a capacidad predictiva

La ingeniería de atributos puede aumentar simultáneamente capacidad e interpretabilidad cuando expresa una magnitud de dominio. Pero expansiones masivas, interacciones automáticas y representaciones latentes suelen dificultar explicar el modelo. No existe un eje único: un modelo complejo puede tener explicaciones locales, mientras un modelo lineal sobre variables filtradas puede ser engañoso si hay sesgo, colinealidad o transformaciones opacas.

La interpretabilidad debe definirse por usuario y decisión. Un operador puede necesitar razones accionables; una persona auditora, linaje y estabilidad; una científica, efectos con incertidumbre; una persona afectada, factores comprensibles y vías de impugnación. Una puntuación PCA puede ser útil para compresión pero insuficiente si una regulación exige reportar magnitudes físicas.

La capacidad se controla mediante número de variables, grados de libertad, regularización y cantidad de configuraciones probadas. Añadir una transformación no lineal permite relaciones nuevas, pero también aumenta el espacio de hipótesis. La comparación justa usa las mismas particiones y considera incertidumbre.

Una estrategia pragmática consiste en comenzar con representación defendible y baseline regularizado; añadir complejidad por bloques; medir mejora por ablación; y conservarla solo si el beneficio es estable y operativo. Si una representación compleja gana, se documenta su comportamiento por subgrupo, sensibilidad y casos de fallo. La explicación nunca debe convertir importancia predictiva en efecto causal.

La decisión puede formalizarse como una frontera de Pareto entre error, costo e interpretabilidad: una alternativa queda dominada si otra es al menos igual en todos esos criterios y mejor en alguno. Entre las no dominadas no existe una elección puramente estadística. Por ejemplo, una representación textual puede reducir dos puntos el error y duplicar latencia, dificultar impugnación y depender de datos sensibles. El informe debe presentar ese intercambio y un nivel mínimo aceptable de desempeño, no esconder una decisión de gobernanza dentro de una única métrica agregada.

10.4.6. Persistencia de transformaciones

Persistir un modelo sin sus transformaciones hace imposible reproducir la predicción. El artefacto desplegable debe incluir o referenciar de forma inmutable:

- esquema, nombres, tipos, unidades y orden de columnas;
- estadísticas de imputación y escalado;
- categorías y política de niveles desconocidos;

- vocabulario o mapas de codificación;
- selección, orden final, cargas y medias de PCA;
- parámetros del estimador y umbral de decisión;
- versiones de código, dependencias y datos de entrenamiento;
- fecha, zona horaria, sistema de coordenadas y fuentes externas;
- métricas, población de validación y limitaciones conocidas.

Serializar objetos arbitrarios puede implicar riesgos de seguridad y compatibilidad. El formato elegido debe validarse, controlarse por versión y cargarse solo desde fuentes confiables. Una prueba de ida y vuelta verifica que una entrada de referencia produce la misma salida antes y después de persistir. Otra prueba compara procesamiento por lotes e individual.

La reproducibilidad no significa congelar para siempre. Cambios de categorías, unidades o población pueden requerir reajuste. Se monitorizan calidad de esquema, tasa de desconocidos, distribución de variables y puntuaciones latentes, error cuando llegan etiquetas, y desempeño por grupo. El plan de actualización especifica disparadores, ventana, aprobación y posibilidad de volver a una versión anterior.

Persistir también exige gobernanza: quién autorizó el artefacto, qué datos sensibles contiene y cuánto tiempo se conserva. Medias o vocabularios pueden revelar información; un almacén de características debe aplicar acceso, linaje y caducidad.

La compatibilidad se valida en ambos sentidos. Un productor nuevo no debe enviar campos que una versión antigua interprete con otro significado, y un artefacto nuevo no debe asumir categorías o unidades ausentes en registros históricos. Por eso el identificador de versión acompaña cada predicción y cada conjunto de características. Una migración se ensaya en modo sombra: ambas versiones procesan las mismas entradas, se explican diferencias de cobertura y puntuación, y solo después se cambia el tráfico. Poder volver a una versión previa exige conservar también su esquema y dependencias, no únicamente el archivo del estimador.

10.4.7. Ejemplo práctico guiado: pipeline completo para datos heterogéneos

Objetivo. Predecir si una incidencia de transporte excederá 30 minutos, usando al momento de registro: distancia estimada, temperatura, tipo de vehículo, zona, hora, descripción breve y antecedentes del corredor. La etiqueta llega al cierre. Los datos se dividen por semana y corredor para evitar compartir eventos casi duplicados.

Contrato de entrada. Distancia está en kilómetros y temperatura en °C; tipo y zona son nominales; fecha incluye zona horaria; texto puede faltar. No se admite duración final, código de resolución ni notas agregadas después del cierre.

Ramas de representación. La rama numérica imputa con estadísticas del entrenamiento, agrega indicadores de faltante y escala. La categórica agrupa niveles infrecuentes según umbral validado, codifica indicadores y reserva desconocido. La temporal crea ciclo horario, día de semana y feriado disponible. La textual aprende su vocabulario únicamente con entrenamiento y produce una matriz dispersa. Los antecedentes del corredor usan ventanas cerradas antes del

registro.

Las salidas se concatenan. Un filtro elimina términos extremadamente raros y un selector supervisado limita dimensión dentro de cada pliegue. El estimador regularizado produce una probabilidad; el umbral se define según capacidad de intervención y costo de falsos negativos, sin usar prueba.

Búsqueda conjunta. Se comparan frecuencia mínima de categoría, tamaño del vocabulario, número de atributos seleccionados, fuerza de regularización y dos representaciones temporales. El bucle interno selecciona; semanas externas evalúan. También se compara contra un baseline sin texto para cuantificar si el costo de esa rama se justifica.

Auditoría de fuga. Se descubre que «cantidad histórica de incidentes» fue calculada al final de cada semana, incluyendo días posteriores. Se reemplaza por una ventana causal por evento. La métrica baja de 0,84 a 0,76: la caída no es un empeoramiento del sistema, sino la eliminación de una ventaja imposible en producción.

Persistencia y operación. Se guarda el pipeline completo con esquema y umbral. Casos de referencia prueban equivalencia. Se monitorizan niveles nuevos, proporción de texto vacío, deriva de puntuación, latencia y sensibilidad por zona. Una nueva categoría no desencadena reajuste silencioso; se procesa según el contrato y se registra para revisión.

Fallo y degradación. Si no llega el texto, el sistema puede usar una configuración validada sin esa rama en lugar de imputar silenciosamente miles de ceros y fingir equivalencia. Si faltan antecedentes del corredor, devuelve una predicción con indicador de baja cobertura o se abstiene según el riesgo. Las dos rutas se evalúan antes del despliegue. Además, una prueba retrospectiva reproduce eventos en su orden de llegada para comprobar que una corrección tardía no reescribe características ya utilizadas. El registro conserva versión, valores derivados y motivo de cualquier abstención.

El ejemplo ilustra la regla central del capítulo: no se despliega una matriz, sino un proceso versionado que convierte datos disponibles en decisiones reproducibles.

Errores frecuentes y cómo evitarlos

Error	Consecuencia	Prevención
Tratar identificadores numéricos como cantidades	distancias y tendencias artificiales	declarar semántica y excluir o codificar apropiadamente
Estandarizar antes de particionar	fuga de distribución	ajustar transformaciones dentro de cada pliegue
Construir rezagos con ventanas centradas	uso del futuro	fijar momento de corte y probar alineación temporal
Crear todas las interacciones posibles	explosión dimensional y sobreajuste	priorizar hipótesis y validar bloques
Codificar objetivo con la propia etiqueta	desempeño ficticio	codificación fuera de pliegue y suavizado

Error	Consecuencia	Prevención
Seleccionar variables una vez antes de CV	estimación optimista	incluir selector en el pipeline
Interpretar L1 como verdad causal	conclusiones no identificadas e inestables	reportar objetivo predictivo y estabilidad
Elegir PCA solo por «80% de varianza»	criterio arbitrario para la tarea	validar q según reconstrucción, predicción y uso
Leer grupos en una proyección como clases reales	sobreinterpretación visual	revisar sensibilidad y espacio original
Reajustar transformaciones en producción por lote	predicciones inconsistentes	cargar parámetros persistidos y monitorizar
Persistir solo el estimador	imposibilidad de reproducir entradas	versionar pipeline, esquema y dependencias
Confundir faltante con cero	cambia el fenómeno representado	documentar semántica e indicadores pertinentes

Glosario

Ablación: comparación que retira una variable o bloque para medir su contribución al procedimiento completo.

Atributo o característica: representación medible usada como entrada de un modelo.

Carga: coeficiente que relaciona una variable original con una dirección de PCA.

Codificación fuera de pliegue: construcción de una característica supervisada para cada fila sin usar su propia etiqueta ni las de su pliegue.

Componente principal: dirección ortonormal de máxima varianza residual en datos centrados.

Dimensión intrínseca: número efectivo de grados de libertad de la estructura que genera los datos.

Fuga de información: uso, durante ajuste o diseño, de información no disponible en el momento real de predicción o perteneciente a evaluación.

Importancia por permutación: aumento de pérdida al romper la información de una variable en datos de evaluación.

Ingeniería de características: diseño de representaciones a partir de datos y conocimiento del dominio.

Método embebido: selección realizada como parte del ajuste del estimador.

Método envolvente: búsqueda de subconjuntos evaluándolos con un modelo.

Método de filtro: selección mediante propiedades estadísticas previas al estimador final.

Pipeline: composición ordenada y persistente de transformaciones y estimación.

Puntuación: coordenada de una observación en un componente o dimensión latente.

Redundancia: información repetida o sustituible entre atributos respecto de una tarea.

Regularización: restricción o penalización que controla complejidad del ajuste.

Representación latente: coordenadas no observadas directamente, construidas para resumir estructura.

Varianza explicada: fracción de varianza total asociada a uno o varios componentes principales.

Preguntas de revisión

1. ¿Por qué definir la unidad de observación y el momento de corte precede a toda ingeniería de características?
2. ¿En qué situación estandarizar podría empeorar la interpretación de PCA?
3. Explique por qué una variable sin asociación marginal puede ser relevante en presencia de otra.
4. ¿Qué hipótesis introduce codificar una variable ordinal como 1, 2 y 3?
5. Construya conceptualmente una codificación cíclica para los siete días y explique por qué necesita dos coordenadas.
6. Distinga relevancia, redundancia e importancia para un modelo concreto.
7. Compare filtros, envolventes y embebidos en costo, dependencia del modelo e interacciones.
8. ¿Por qué L1 puede seleccionar una variable arbitraria entre sensores correlacionados mientras L2 reparte peso?
9. Describa la fuga que aparece al seleccionar atributos antes de validación cruzada.
10. Derive la ecuación de autovectores a partir del problema de máxima varianza de PCA.
11. ¿Por qué 90% de varianza explicada no equivale a 90% de información predictiva?
12. ¿Qué diferencia existe entre cargas y puntuaciones de PCA?
13. Mencione tres razones por las que un gráfico no lineal 2D puede inducir conclusiones falsas sobre grupos.
14. ¿Qué objetos aprendidos, además del estimador, deben persistirse para reproducir una predicción?
15. Diseñe una prueba que detecte discrepancias entre el pipeline de entrenamiento y el de inferencia.

Actividad integradora: representación auditable para demanda urbana

Una administración dispone de dos años de registros de viajes, estaciones, clima, calendario, texto de incidencias y capacidad. Debe predecir demanda por estación-hora con 24 horas de anticipación y justificar el proceso ante personal técnico y operativo.

Consigna. Diseñar, sin implementar código, un pipeline completo que compare: a) representación de dominio con selección; b) representación con PCA; y c) baseline mínimo. El diseño debe especificar unidad, horizonte, momento de corte, ramas por tipo, particiones, espacio de hiperparámetros, métrica, criterios de interpretación y persistencia.

Entregables:

1. Diccionario de al menos doce características con fórmula conceptual, unidad, disponibilidad y riesgo de fuga.
2. Diagrama del pipeline que diferencie qué se ajusta y qué solo se transforma.
3. Protocolo de validación temporal, con bucles interno y externo si hay búsqueda.
4. Tabla comparativa de filtro, método embebido y PCA, incluyendo estabilidad, costo y desempeño.
5. Interpretación de dos componentes a partir de cargas hipotéticas y advertencias sobre signo y varianza.
6. Lista de artefactos persistidos, controles de esquema y señales de deriva.
7. Recomendación final que separe evidencia predictiva, conocimiento de dominio y afirmaciones causales.

Criterios de evaluación: coherencia temporal; ausencia de fuga; justificación matemática de selección y reducción; tratamiento adecuado de datos heterogéneos; comparación bajo particiones idénticas; reconocimiento de incertidumbre y redundancia; y capacidad para reproducir la transformación en inferencia.

Síntesis

La representación determina qué regularidades puede aprender un modelo. Construir características exige respetar unidad, escala, disponibilidad y mecanismo; seleccionar atributos exige distinguir asociación marginal, aporte condicional, redundancia e importancia dependiente del modelo; reducir dimensionalidad exige declarar qué propiedad se conserva y qué interpretación se pierde.

PCA proyecta datos centrados sobre autovectores de su covarianza, ordenados por varianza. Ofrece la mejor reconstrucción lineal de rango dado, pero no garantiza relevancia predictiva ni causal. Los métodos no lineales amplían la capacidad para representar geometrías curvas, a cambio de sensibilidad y menor transparencia.

La garantía transversal es procedimental: toda media, categoría, selección, carga y configuración se aprende dentro del entrenamiento correspondiente. El pipeline completo —incluidos esquema, transformaciones, modelo y umbral— es la unidad que se valida, persiste, monitoriza y gobierna. Una representación valiosa no es la que produce más columnas, sino la que convierte información disponible en una decisión útil, estable y auditable.

Capítulo 11. Regresión y clasificación: modelos fundamentales

Los modelos lineales ocupan un lugar central en la ciencia de datos. No son únicamente algoritmos sencillos con los que iniciar una comparación: proporcionan un lenguaje preciso para separar señal, ruido, incertidumbre y decisión. Una regresión lineal permite expresar cómo cambia una respuesta continua al variar unas características, manteniendo constantes las demás. La regresión logística traslada esa estructura a probabilidades de clase. Ridge, Lasso y Elastic Net muestran, además, cómo introducir preferencias explícitas por soluciones estables o parsimoniosas.

Su aparente simplicidad exige disciplina. Una recta puede predecir bien y, sin embargo, no justificar una lectura causal; un coeficiente puede cambiar de signo por colinealidad; una exactitud elevada puede esconder probabilidades mal calibradas; y un umbral de 0,5 puede ser incompatible con los costos reales. En estos modelos, la formulación, los supuestos y la regla de decisión son tan importantes como el ajuste numérico.

El capítulo adopta dos perspectivas complementarias. La perspectiva **predictiva** pregunta cuánto generaliza el procedimiento a observaciones nuevas. La perspectiva **inferencial** pregunta qué puede sostenerse sobre parámetros, asociaciones e incertidumbre bajo determinados supuestos. Ambas usan fórmulas semejantes, pero no son intercambiables. La validación fuera de muestra es indispensable para predicción; la identificación del diseño, los supuestos probabilísticos y los errores estándar son indispensables para inferencia.

Al finalizar, el lector podrá formular problemas de regresión y clasificación, derivar mínimos cuadrados, interpretar su geometría, especificar categorías e interacciones, diagnosticar incumplimientos, explicar el compromiso sesgo-varianza de la regularización y convertir probabilidades logísticas calibradas en decisiones justificadas.

11.1. Regresión lineal

11.1.1. Formulación del problema de regresión

En regresión, la variable objetivo Y toma valores numéricos y se desea aproximar su comportamiento a partir de un vector de características $X = (X_1, \dots, X_p)^T$. El objeto poblacional natural bajo pérdida cuadrática es la **función de regresión**

$$m(\mathbf{x}) = \mathbb{E}(Y \mid X = \mathbf{x}).$$

Esta definición no supone linealidad. Afirma que, entre todas las predicciones puntuales posibles para un mismo $\mathbf{x}$, la media condicional minimiza el error cuadrático esperado. En efecto, para cualquier número a ,

$$\mathbb{E}[(Y - a)^2 \mid X = \mathbf{x}] = \text{Var}(Y \mid X = \mathbf{x}) + [m(\mathbf{x}) - a]^2,$$

por lo que el mínimo se alcanza en $a = m(\mathbf{x})$. La regresión lineal restringe esa función a la familia afín

$$f_{\beta}(\mathbf{x}) = \beta_0 + \sum_{j=1}^p \beta_j x_j.$$

Para la observación i se escribe

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \varepsilon_i,$$

donde ε_i reúne variación no explicada, variables omitidas, ruido de medición y posible error de especificación. Conviene distinguir tres entidades: el valor observado y_i , la media modelada $\mu_i = \mathbb{E}(Y_i \mid X_i)$ y la predicción ajustada $\hat{y}_i$. El residuo $e_i = y_i - \hat{y}_i$ es observable después del ajuste; el error $\varepsilon_i = y_i - \mu_i$ no lo es.

Formular bien el problema requiere declarar la unidad de análisis, el instante de predicción, el horizonte, las entradas disponibles entonces y la pérdida relevante. Para demanda energética horaria, una fila podría ser edificio-hora; predecir una hora después no admite mediciones que lleguen al finalizar esa hora. Si los errores grandes son especialmente costosos, el error cuadrático medio puede ser adecuado; si se busca robustez frente a extremos, puede preferirse pérdida absoluta. La elección de pérdida define qué resumen condicional se estima y no debe decidirse por costumbre.

La muestra de aprendizaje es $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$. El riesgo poblacional de un predictor f bajo pérdida L es

$$R(f) = \mathbb{E}[L(Y, f(X))],$$

mientras que el riesgo empírico promedia sobre la muestra. Ajustar minimiza una versión empírica; evaluar estima comportamiento futuro. Confundir ambos produce sobreajuste. También debe fijarse el dominio de generalización: otro turno de la misma planta, una campaña agrícola posterior o una región no observada plantean distribuciones y particiones diferentes.

Asociación no es intervención. Un coeficiente predictivo describe una relación condicionada a las variables incluidas y a la población observada. Para afirmar que modificar X_j causará un cambio en Y se necesitan supuestos adicionales sobre asignación, confundidores, temporalidad y consistencia. La regresión es una herramienta de estimación; no crea por sí sola un diseño causal.

11.1.2. Regresión lineal simple

La regresión lineal simple usa un solo predictor:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

β_0 es la media modelada cuando $x = 0$ y β_1 es el cambio medio de Y asociado con una unidad adicional de x . La palabra «asociado» es deliberada. Si x es temperatura exterior y Y consumo eléctrico diario, la pendiente resume una tendencia en los datos, no necesariamente el efecto aislado de elevar físicamente la temperatura.

Al minimizar $S(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$ y anular derivadas se obtienen las ecuaciones normales. La primera implica que la recta pasa por $(\bar{x}, \bar{y})$; la segunda conduce a

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Así, la pendiente es covarianza dividida por varianza del predictor. También puede escribirse $\hat{\beta}_1 = r_{xy} s_y / s_x$: correlación y pendiente comparten signo, pero la primera no tiene unidades y la segunda sí. Si x se expresa en centenas en lugar de unidades, el coeficiente cambia aunque las predicciones no.

Ejemplo calculado. Para cinco jornadas de una línea de fabricación se registran horas de operación $x = (2, 4, 6, 8, 10)$ y consumo energético $y = (18, 25, 29, 36, 42)$ MWh. Se tiene $\bar{x} = 6$, $\bar{y} = 30$,

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 118, \quad \sum (x_i - \bar{x})^2 = 40.$$

Por tanto, $\hat{\beta}_1 = 2,95$ MWh/h y $\hat{\beta}_0 = 12,3$ MWh. Para siete horas, $\hat{y} = 12,3 + 2,95(7) = 32,95$ MWh. El intercepto representa consumo a cero horas solo si ese punto tiene sentido y la relación sigue siendo válida allí. Como cero está fuera de los valores observados, su interpretación física requiere cautela; centrar x en seis horas convertiría el intercepto en el consumo esperado para una jornada típica.

Los residuos suman cero cuando hay intercepto, y son ortogonales al predictor centrado: $\sum e_i = 0$ y $\sum (x_i - \bar{x})e_i = 0$. Estas propiedades son consecuencias algebraicas del ajuste, no evidencia de que los errores poblacionales tengan media cero o sean independientes.

Interpolar dentro del rango observado suele ser menos arriesgado que extrapolar. Una recta estimada entre 2 y 10 horas no garantiza comportamiento a 20: saturación, turnos adicionales o cambios de tarifa pueden alterar el mecanismo. Siempre deben comunicarse el rango de soporte y la incertidumbre, y compararse las predicciones con un baseline, por ejemplo $\hat{y} = \bar{y}$.

11.1.3. Regresión lineal múltiple

La regresión múltiple introduce varios predictores:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i.$$

Al añadir una columna de unos para el intercepto, se usa la notación matricial

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

con $X \in \mathbb{R}^{n \times (p+1)}$, $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$ y $\mathbf{y} \in \mathbb{R}^n$. Cada fila describe una observación; cada columna, un término del modelo. «Lineal» significa lineal en los parámetros, no necesariamente en las entradas originales. El modelo $\beta_0 + \beta_1 t + \beta_2 t^2$ sigue siendo lineal en $\boldsymbol{\beta}$.

El valor de múltiples predictores no consiste solamente en elevar R^2 . Permiten comparar observaciones a igualdad de otras características y reducir error si aportan información complementaria. En consumo de un edificio podrían intervenir temperatura, ocupación, superficie, día laboral y una tendencia temporal. La lectura de β_j es parcial: cambio esperado por una unidad de x_j , **manteniendo fijas** las demás columnas. Esa comparación puede ser poco realista si las variables casi nunca varían por separado.

El teorema de Frisch-Waugh-Lovell aclara esta lectura. Para estimar el efecto de x_j , primero se elimina de x_j la parte linealmente explicada por las otras columnas; se hace lo mismo con y ; después se regresa el residuo de y sobre el residuo de x_j . La pendiente resultante es exactamente $\hat{\beta}_j$. Por tanto, el coeficiente usa solo la variación de x_j que no es redundante con el resto.

Agregar variables nunca aumenta la suma de cuadrados residual sobre entrenamiento, porque el modelo ampliado puede asignar cero a los nuevos coeficientes. Sin embargo, puede aumentar el error futuro, ensanchar intervalos e introducir variables disponibles demasiado tarde. El R^2 ,

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2},$$

mide fracción de variación muestral explicada respecto de la media. No mide causalidad, calibración individual ni desempeño fuera de muestra. El R^2 ajustado penaliza grados de libertad, pero tampoco sustituye una validación adecuada.

La especificación exige decidir forma funcional. Una relación curva puede representarse con transformaciones, polinomios de grado moderado o bases por tramos; una periodicidad, con seno y coseno; un efecto condicionado, con interacciones. Cada término amplía la hipótesis y debe justificarse por dominio y validación. Un modelo con menos columnas, unidades claras y comportamiento de extrapolación plausible puede ser preferible aunque su ajuste interno sea ligeramente peor.

11.1.4. Estimación por mínimos cuadrados

Mínimos cuadrados ordinarios, OLS por sus siglas en inglés, elige

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} S(\boldsymbol{\beta}), \quad S(\boldsymbol{\beta}) = \|\mathbf{y} - X\boldsymbol{\beta}\|_2^2.$$

Al expandir,

$$S = \mathbf{y}^T \mathbf{y} - 2\beta^T X^T \mathbf{y} + \beta^T X^T X \beta.$$

Su gradiente es $-2X^T \mathbf{y} + 2X^T X \beta$. Igualarlo a cero produce las **ecuaciones normales**

$$X^T X \hat{\beta} = X^T \mathbf{y}.$$

Si las columnas de X son linealmente independientes, $X^T X$ es invertible y

$$\hat{\beta} = (X^T X)^{-1} X^T \mathbf{y}.$$

Esta expresión sirve para derivar propiedades, pero no prescribe calcular explícitamente la inversa: factorizaciones QR o SVD suelen ser más estables. Si X no tiene rango completo, las predicciones proyectadas pueden ser únicas aunque los coeficientes no; la pseudoinversa selecciona una solución de norma mínima.

La geometría es especialmente reveladora. Los vectores predichos pertenecen al espacio columna $\mathcal{C}(X)$. OLS proyecta ortogonalmente $\mathbf{y}$ sobre ese subespacio:

$$\hat{\mathbf{y}} = H\mathbf{y}, \quad H = X(X^T X)^{-1} X^T.$$

H es la matriz sombrero, simétrica e idempotente. El residuo $\mathbf{e} = (I - H)\mathbf{y}$ es ortogonal a cada columna de X , porque $X^T \mathbf{e} = 0$. Se obtiene la descomposición pitagórica, si hay intercepto,

$$\sum_i (y_i - \bar{y})^2 = \sum_i (\hat{y}_i - \bar{y})^2 + \sum_i e_i^2.$$

Bajo el modelo condicional $\mathbb{E}(\varepsilon | X) = 0$ y $\text{Var}(\varepsilon | X) = \sigma^2 I$,

$$\mathbb{E}(\hat{\beta} | X) = \beta, \quad \text{Var}(\hat{\beta} | X) = \sigma^2 (X^T X)^{-1}.$$

La varianza se estima con $\hat{\sigma}^2 = SSE/(n - p - 1)$. Si además los errores son normales, pueden obtenerse pruebas e intervalos exactos en muestra finita. La normalidad no es necesaria para que OLS minimice cuadrados ni para la insesgadez; sí facilita inferencia paramétrica exacta. Con muestras grandes, resultados asintóticos pueden ser suficientes bajo condiciones más generales.

El teorema de Gauss-Markov establece que, con linealidad en parámetros, esperanza condicional cero, rango completo y errores homocedásticos no correlacionados, OLS es el estimador lineal insesgado de menor varianza. No afirma que sea el mejor predictor entre todos los métodos ni que los errores sean normales.

Pseudocódigo conceptual de ajuste y evaluación:

ENTRADA: datos de desarrollo, especificación y particiones válidas

PARA cada partición:

aprender transformaciones solo con el entrenamiento

construir matrices de diseño de entrenamiento y validación

resolver las ecuaciones de mínimos cuadrados en entrenamiento
 predecir una sola vez sobre validación
 registrar pérdida y diagnósticos por grupos relevantes
 AGREGAR resultados y compararlos con el baseline
 REAJUSTAR la especificación elegida con todos los datos de desarrollo
 EVALUAR una vez en prueba intacta o iniciar monitorización prospectiva

11.1.5. Interpretación de coeficientes

En un modelo aditivo, β_j representa el cambio en la media condicional de Y por cada unidad adicional de X_j , manteniendo las restantes columnas constantes. Las unidades son «unidades de Y por unidad de X_j ». Si el objetivo está en kWh y superficie en m^2 , un coeficiente de 0,8 se lee como 0,8 kWh adicionales por m^2 bajo la comparación condicionada especificada.

El intercepto es el valor esperado cuando todas las columnas valen cero. Puede ser sustantivo, como demanda base a cero producción, o solo algebraico. Centrar $x_j^c = x_j - c_j$ desplaza el punto de referencia sin cambiar las predicciones. Con c_j igual a una media o valor operativo, el intercepto se vuelve más interpretable y las interacciones suelen ser numéricamente más estables.

Las transformaciones cambian la lectura:

Especificación	Interpretación aproximada de β_1
$Y = \beta_0 + \beta_1 X$	una unidad más de X cambia Y en β_1
$Y = \beta_0 + \beta_1 \log X$	1% más de X cambia Y en $0,01\beta_1$
$\log Y = \beta_0 + \beta_1 X$	una unidad más de X cambia Y aproximadamente en $100\beta_1\%$
$\log Y = \beta_0 + \beta_1 \log X$	1% más de X se asocia con $\beta_1\%$ más de Y

La aproximación porcentual es precisa para coeficientes pequeños; en un modelo log-lineal, el cambio exacto por una unidad es $100(e^{\beta_1} - 1)\%$. Si se retransfieren predicciones desde $\log Y$, exponenciar la media logarítmica no recupera automáticamente $E(Y | X)$ debido a la desigualdad de Jensen; se necesita considerar la distribución residual.

Un intervalo de confianza para un coeficiente, bajo los supuestos correspondientes, tiene forma

$$\hat{\beta}_j \pm t_{1-\alpha/2, n-p-1} \widehat{se}(\hat{\beta}_j).$$

No es la probabilidad posterior de que ese parámetro fijo esté dentro del intervalo. Tampoco un valor p pequeño cuantifica importancia predictiva o magnitud práctica. Con muestras enormes, efectos irrelevantes pueden ser estadísticamente distinguibles de cero; con colinealidad, efectos sustantivos pueden tener intervalos amplios.

La interpretación depende del conjunto de ajuste. El coeficiente de temperatura puede cambiar al incluir ocupación porque responde otra pregunta condicionada. Si ocupación es consecuencia de temperatura o de una decisión relacionada,

ajustarla puede incluso introducir sesgo para una pregunta causal. Deben informarse la especificación, la población y el rango de datos junto al coeficiente. Comparar magnitudes solo es razonable con escalas compatibles; coeficientes estandarizados ayudan, pero una desviación estándar puede no representar un cambio factible ni igualmente costoso.

11.1.6. Variables categóricas e interacciones

Una categoría nominal no debe codificarse como entero con distancia artificial. Si turno tiene niveles mañana, tarde y noche, con intercepto se elige una referencia y se incluyen $K - 1$ indicadores:

$$Y = \beta_0 + \beta_T I(\text{tarde}) + \beta_N I(\text{noche}) + \varepsilon.$$

β_0 es la media modelada de mañana; β_T y β_N son diferencias respecto de ella. Cambiar la referencia modifica coeficientes, no valores ajustados ni comparaciones globales. Incluir los K indicadores junto al intercepto crea dependencia lineal perfecta, conocida como trampa de variables ficticias. También puede emplearse una codificación con suma cero, útil para comparar cada nivel con una media global, siempre que se documente.

Para una categoría ordinal, asignar 1, 2, 3 impone efectos igualmente espaciados. Esa restricción puede ser razonable o no; los indicadores permiten diferencias libres. Categorías raras producen estimaciones inestables y niveles nuevos requieren una política definida antes del despliegue. Agruparlos por observar su objetivo en todo el conjunto genera fuga.

Una interacción expresa que el efecto de una variable depende de otra:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{12} X_1 X_2 + \varepsilon.$$

Ahora $\partial \mathbb{E}(Y | X) / \partial X_1 = \beta_1 + \beta_{12} X_2$. Por ello, β_1 es el efecto de X_1 cuando $X_2 = 0$, no un promedio universal. Centrar continuas sitúa ese cero en un valor relevante. El principio de jerarquía recomienda conservar ambos efectos principales al incluir el producto, salvo justificación fuerte.

Ejemplo. Un modelo de tiempo de mecanizado usa tamaño de lote centrado L , indicador A para aleación especial y $L \times A$:

$$\hat{Y} = 42 + 1,8L + 9A + 0,7LA.$$

Para material estándar, cada unidad de lote agrega 1,8 minutos; para aleación especial, agrega $1,8 + 0,7 = 2,5$. A tamaño medio ($L = 0$), la aleación especial requiere 9 minutos adicionales. Afirmar simplemente que «el coeficiente de lote es 1,8» omitiría la interacción.

Las interacciones categoría-categoría generan diferencias entre combinaciones; las continuas pueden usar productos o superficies por tramos. Su número crece rápido y muchas combinaciones tienen poco soporte. No se deben generar miles de términos y seleccionar mirando la prueba. Antes de incluir una interacción conviene formular el mecanismo, revisar cobertura conjunta, evaluar fuera de muestra y representar efectos predichos con incertidumbre. Un coeficiente de interacción tampoco es, por sí solo, evidencia de mecanismo causal.

11.1.7. Ejemplo práctico guiado: predicción de consumo o demanda

Una empresa administra edificios comerciales y desea anticipar a las 18:00 el consumo eléctrico total del día siguiente, en MWh. La unidad de observación es edificio-día. Están disponibles superficie, ocupación programada, temperatura media pronosticada, indicador de día laboral y consumo de los siete días anteriores. Se dispone de tres años de historia; el último trimestre se reserva como prueba temporal.

1. Baseline y métrica. El baseline predice el consumo del mismo día de la semana anterior. Se eligen MAE para expresar desviación típica en MWh y RMSE como medida secundaria sensible a errores grandes. El objetivo no es superar la media de entrenamiento, sino una regla operacional razonable.

2. Especificación. El análisis del dominio sugiere una respuesta térmica en U: calefacción bajo una temperatura de confort y refrigeración sobre ella. En vez de forzar una sola pendiente, se crean grados-día de frío $C = (18 - T)_+$ y calor $H = (T - 22)_+$, donde $(a)_+ = \max(a, 0)$. Se incluye interacción $H \times D$, con $D = 1$ para día laboral, porque la refrigeración puede crecer con ocupación. El modelo es

$$Y = \beta_0 + \beta_S S + \beta_O O + \beta_C C + \beta_H H + \beta_D D + \beta_{HD} HD + \beta_L L + \varepsilon,$$

donde S es superficie en miles de m^2 , O ocupación programada en centenas y L consumo de la semana previa.

3. Ajuste temporal. Las transformaciones y cualquier imputación se aprenden en cada ventana de entrenamiento. Se usan validaciones que avanzan en el tiempo, pues una partición aleatoria mezclaría estaciones y versiones operativas. Tras comparar especificaciones sin consultar prueba, se obtiene en una ventana representativa:

Término	Coefficiente estimado	Lectura condicionada
intercepto	4,10	demanda base en los valores de referencia
superficie	0,62	MWh por cada 1000 m^2
ocupación	0,28	MWh por cada 100 personas programadas
frío	0,19	MWh por grado bajo 18 °C
calor	0,24	MWh por grado sobre 22 °C en día no laboral
laboral	1,35	diferencia laboral a $H = 0$
calor $\times$ laboral	0,11	incremento adicional por grado en laboral
semana previa	0,57	MWh por MWh del día comparable previo

Para un edificio de 12 000 m^2 , ocupación 800, temperatura pronosticada 27 °C, día laboral y consumo previo de 20 MWh, $C = 0$, $H = 5$:

$$\hat{Y} = 4,10 + 0,62(12) + 0,28(8) + 0,24(5) + 1,35 + 0,11(5) + 0,57(20) = 28,28 \text{ MWh.}$$

La pendiente térmica en laboral es $0,24 + 0,11 = 0,35$ MWh/°C. Esta lectura no afirma que modificar la temperatura exterior cause exactamente ese cambio.

4. Resultados. En prueba, el baseline logra MAE 2,8 y RMSE 4,1 MWh; el modelo, MAE 2,1 y RMSE 3,4. La mejora relativa de MAE es $(2,8 - 2,1)/2,8 = 25\%$. También

se revisan errores por edificio, estación y días de alta ocupación. En edificios nuevos sin rezago, la cobertura cae: el modelo necesita una política explícita, como una variante sin L , y no una imputación futura.

5. Límites. La temperatura empleada durante entrenamiento debe ser la pronosticada históricamente, no la observada al final del día. De lo contrario se evalúa una tarea artificialmente fácil. Una ampliación de superficie o un cambio de equipos rompe estabilidad. Se monitorizan distribución de entradas, residuo medio, MAE por segmento y frecuencia de extrapolación. El modelo se acepta porque supera el baseline de manera estable y sus fallos son compatibles con el uso, no porque todos sus coeficientes sean «significativos».

11.2. Supuestos y diagnóstico del modelo lineal

11.2.1. Linealidad

El supuesto de linealidad relevante es

$$\mathbb{E}(Y | X) = X\beta,$$

es decir, la media condicional está bien representada por los términos incluidos. No exige que cada variable bruta tenga una relación recta: bases polinómicas, logaritmos, tramos e interacciones siguen formando un modelo lineal en parámetros. Tampoco exige que el histograma de Y sea normal.

Si la especificación omite curvatura, los residuos frente a valores ajustados o frente a un predictor pueden mostrar arcos. Por ejemplo, modelar consumo con una sola pendiente de temperatura puede producir residuos positivos en días muy fríos y muy cálidos y negativos en días templados. La suma residual puede seguir siendo cero; el patrón local revela el problema.

El diagnóstico combina conocimiento del mecanismo, gráficos y validación. Se pueden superponer suavizados de residuos, comparar especificaciones anidadas y observar error por intervalos de cada entrada. Un patrón en entrenamiento podría ser azar; una mejora debe repetirse en datos no usados para proponerla. Añadir un polinomio de grado alto hasta eliminar cualquier ondulación suele sobreajustar y extrapola de forma extrema.

La solución no siempre es transformar. Puede faltar una interacción, existir un cambio de régimen o haberse medido mal una entrada. Si la variable objetivo es un conteo pequeño o está acotada, otra familia probabilística puede representar mejor varianza y soporte. Para predicción, cierta no linealidad puede tolerarse si el error externo satisface el uso; para inferencia sobre una pendiente, una forma incorrecta invalida su interpretación incluso con buen promedio predictivo.

Una revisión responsable pregunta: ¿en qué rango hay datos?, ¿la pendiente local conserva signo?, ¿qué predice el modelo fuera del rango?, ¿hay soporte para comparar casos manteniendo lo demás fijo? La linealidad es una hipótesis aproximada y localizada, no una propiedad que un único gráfico pueda certificar.

11.2.2. Independencia

El supuesto clásico considera errores no correlacionados:

$$\text{Cov}(\varepsilon_i, \varepsilon_j | X) = 0, \quad i \neq j.$$

Se viola cuando observaciones comparten tiempo, entidad, ubicación, lote o documento de origen. Mediciones horarias del mismo edificio se parecen; piezas del mismo lote comparten materia prima; rendimientos de parcelas vecinas comparten clima. Aumentar el número de filas no crea la misma información que añadir unidades independientes.

Con autocorrelación positiva, OLS puede conservar coeficientes insesgados si la esperanza condicional es correcta, pero los errores estándar clásicos suelen ser demasiado pequeños. Además, una partición aleatoria produce validaciones optimistas al situar casos casi duplicados en ambos lados. El problema afecta tanto a inferencia como a evaluación.

En series ordenadas se inspeccionan residuos en el tiempo, autocorrelaciones por rezago y patrones de rachas. En datos agrupados se comparan residuos dentro y entre entidades. Una estadística aislada no sustituye entender el muestreo. La dependencia puede tratarse mediante características temporales, errores estándar robustos por conglomerado, mínimos cuadrados generalizados, efectos aleatorios o modelos dinámicos, según la pregunta. Ninguna corrección recupera información independiente inexistente.

El diseño de validación debe imitar el despliegue. Si se predice el futuro de edificios conocidos, se separa por tiempo manteniendo edificios; si se generaliza a edificios nuevos, se retienen edificios completos; si ambas cosas importan, se evalúan ambos escenarios. Agrupar solo en el cálculo de errores estándar y luego mezclar grupos en prueba no resuelve fuga predictiva.

La independencia se refiere a errores condicionados, no a que las variables de entrada sean independientes entre sí. Predictores correlacionados plantean multicolinealidad, un asunto diferente. También debe distinguirse dependencia serial de deriva: la primera relaciona errores cercanos; la segunda cambia la distribución o el mecanismo con el tiempo.

11.2.3. Homocedasticidad

La homocedasticidad establece varianza condicional constante:

$$\text{Var}(\varepsilon_i | X) = \sigma^2.$$

Cuando la dispersión depende de X existe heterocedasticidad. En ventas, variación absoluta suele crecer con tamaño de tienda; en manufactura, lotes grandes pueden acumular más variación total. Un gráfico de residuos contra ajustados con forma de embudo es una señal habitual.

Con esperanza condicional correcta, la heterocedasticidad no sesga por sí misma los coeficientes OLS, pero los vuelve ineficientes y hace incorrecta la fórmula clásica $\sigma^2(X^T X)^{-1}$. Los intervalos de predicción también deben ensancharse donde la variabilidad sea mayor. Reportar una banda constante en todo el rango oculta riesgo precisamente en observaciones grandes.

Las respuestas posibles dependen del origen. Los errores estándar robustos a heterocedasticidad corrigen inferencia asintótica sin cambiar coeficientes.

Mínimos cuadrados ponderados usa pesos inversamente proporcionales a la varianza si esta puede modelarse: minimizar $\sum_i w_i e_i^2$. Una transformación logarítmica puede estabilizar variación multiplicativa, pero cambia el objetivo y requiere cuidado al volver a escala original. Modelar directamente media y dispersión puede ser más honesto.

No conviene ponderar por intuición sin definir el estimando. Dar menos peso a edificios grandes puede mejorar error relativo y empeorar error absoluto total. La pérdida debe reflejar la decisión. Asimismo, una prueba formal puede detectar desviaciones minúsculas con n grande o tener poca potencia con n pequeño. Importan magnitud, patrón y consecuencia.

Para predicción se comparan MAE, RMSE o error porcentual por bandas de escala, evitando porcentajes cuando Y se aproxima a cero. Para inferencia se declara la corrección de varianza usada. La homocedasticidad no significa que los residuos observados tengan exactamente igual dispersión en cada grupo: es una afirmación poblacional aproximada.

11.2.4. Distribución de residuos

El modelo clásico completo suele añadir

$$\varepsilon | X \sim \mathcal{N}(\mathbf{0}, \sigma^2 I).$$

La normalidad permite derivar distribuciones t y F exactas en muestras finitas. No es necesaria para calcular OLS ni para que, bajo esperanza condicional cero, sus coeficientes sean insesgados. En muestras grandes, aproximaciones asintóticas suelen funcionar si no dominan extremos y existen momentos apropiados.

Un gráfico cuantíl-cuantíl compara cuantiles residuales con los normales. Desviaciones en colas sugieren extremos frecuentes; asimetría, una cola más larga; escalones, una respuesta discreta o redondeada. Sin embargo, los residuos no son errores independientes idénticos: su varianza es $\sigma^2(1 - h_{ii})$. Para comparar casos se usan residuos estudentizados, aunque tampoco convierten un diagnóstico en prueba definitiva.

Los extremos pueden proceder de errores de captura, eventos válidos, mezcla de poblaciones o una distribución de cola pesada. Eliminar observaciones solo para aproximarse a una campana falsea la población. Primero se verifica linaje; después se evalúa sensibilidad con y sin el caso, se consideran pérdidas robustas o una distribución adecuada y se informa la decisión. Un evento raro pero operativo debe formar parte del riesgo, no desaparecer del análisis.

También se distingue intervalo para la media e intervalo para una observación futura. En $\mathbf{x}_0$, bajo el modelo clásico,

$$\hat{y}_0 \pm t^* \hat{\sigma} \sqrt{\mathbf{x}_0^T (X^T X)^{-1} \mathbf{x}_0}$$

estima incertidumbre de la media; para una observación nueva se añade 1 dentro de la raíz. El segundo es más ancho porque incorpora ruido irreducible. Fuera del soporte, ambos pueden dar una falsa apariencia de precisión si la forma lineal deja de ser válida.

11.2.5. Multicolinealidad

Existe multicolinealidad cuando columnas de X están fuertemente relacionadas; es perfecta si una es combinación exacta de otras. En el caso perfecto, $X^T X$ no es invertible y los coeficientes no son identificables. En el caso aproximado, la inversión amplifica pequeñas perturbaciones: coeficientes grandes, signos inesperados e intervalos amplios pueden coexistir con predicciones razonables.

De la varianza

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$$

se observa que poca variación independiente de una columna implica alta incertidumbre. El factor de inflación de varianza para X_j es

$$VIF_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 procede de regresar X_j sobre las demás. Un VIF alto señala que queda poca variación exclusiva, pero no existe un umbral universal. Los valores dependen de codificación, interacciones y población.

Correlaciones por pares no detectan toda dependencia multivariada. También se examinan valores singulares y número de condición después de considerar escalas. Términos polinómicos sin centrar pueden ser altamente correlacionados por construcción; centrar mejora estabilidad interpretativa, pero no agrega información. Eliminar una variable puede ser razonable si es redundante y costosa, pero peligroso si era un control necesario para una pregunta causal.

Las soluciones incluyen recolectar observaciones con combinaciones más variadas, combinar mediciones justificadamente, reformular el estimando, usar componentes o regularizar. Ridge estabiliza predicciones al aceptar sesgo. Lasso puede seleccionar arbitrariamente entre sustitutos. Si el objetivo es interpretar efectos separados de dos temperaturas casi idénticas, ningún algoritmo reemplaza falta de soporte experimental.

Multicolinealidad no sesga automáticamente OLS ni reduce siempre capacidad predictiva dentro de la distribución. Su principal efecto es dificultar atribución y estabilidad. Por ello deben reportarse predicciones y coeficientes bajo perturbaciones o remuestreos, no una única tabla como verdad fija.

11.2.6. Observaciones influyentes

Una observación puede ser atípica en Y , extrema en las entradas o influyente sobre el ajuste. Son conceptos distintos. El **apalancamiento** es h_{ii} , elemento diagonal de H ; mide cuán lejos está la fila en el espacio de predictores. Como $\sum_i h_{ii} = p + 1$, su promedio es $(p + 1)/n$. Un caso de alto apalancamiento puede tener residuo pequeño precisamente porque arrastra la recta hacia sí.

La influencia combina apalancamiento y discrepancia. La distancia de Cook puede expresarse como

$$D_i = \frac{e_i^2}{(p+1)\widehat{\sigma}^2} \frac{h_{ii}}{(1-h_{ii})^2}.$$

Cuantifica cuánto cambiaría globalmente el ajuste al retirar el caso. DFBETAS estudia cambios en coeficientes concretos; residuos eliminados comparan cada punto con un modelo ajustado sin él. Los umbrales difundidos son guías de inspección, no reglas automáticas.

Ejemplo conceptual. Una planta registra producción diaria entre 80 y 120 unidades, salvo un día de 300 por una campaña especial. Ese día tiene alto apalancamiento. Si sigue exactamente la tendencia, puede no ser influyente; si usa otra configuración de maquinaria, puede cambiar mucho la pendiente. La pregunta sustantiva es si pertenece a la población futura. Si sí, excluirlo oculta un régimen; si no, tal vez convenga modelar campañas por separado.

El protocolo es: verificar la observación en la fuente, comprender por qué es extrema, calcular sensibilidad del resultado, considerar una variable o régimen omitido y documentar cualquier exclusión. Ajustar con y sin casos influyentes muestra dependencia, pero elegir la versión que favorece una conclusión es selección sesgada.

En dimensiones altas, casi toda fila puede tener apalancamiento apreciable y las medidas clásicas pierden simplicidad. También hay influencia colectiva: varios casos similares se enmascaran mutuamente. Diagnósticos por grupos, tiempo y fuentes complementan índices individuales.

11.2.7. Análisis gráfico de residuos

Los gráficos de residuos son instrumentos de falsación: buscan estructura que el modelo no capturó. No prueban que los supuestos se cumplan cuando no muestran patrones. Un conjunto mínimo incluye:

Gráfico	Patrón buscado	Hipótesis posible
residuos vs. ajustados	curva, embudo, bandas	no linealidad, varianza cambiante, grupos omitidos
residuos vs. predictor	tendencia local	forma funcional incorrecta o interacción
Q-Q	asimetría o colas	distribución no normal, extremos
escala-localización residuos vs. apalancamiento	dispersión creciente casos aislados	heterocedasticidad influencia elevada
residuos vs. tiempo	rachas, ciclos, saltos	dependencia o deriva

Se prefieren residuos estudentizados para comparar observaciones con varianzas distintas. El eje horizontal debe mostrar también densidad o soporte: un suavizado llamativo sostenido por tres puntos no equivale a un patrón en una región poblada. Colorear por turno, tipo de producto o estación puede revelar una variable omitida, pero explorar muchos grupos aumenta riesgo de descubrir azar.

Los gráficos deben construirse tanto en entrenamiento como sobre predicciones fuera de muestra. Los residuos de entrenamiento han sido minimizados y tienden a ser optimistas; los de validación reflejan mejor generalización. En validación temporal, representar errores por fecha permite separar estacionalidad residual y cambio de régimen.

Una secuencia diagnóstica razonable es:

COMPROBAR unidades, faltantes, rangos y momento de disponibilidad
 GRAFICAR residuos frente a ajustados, entradas clave, tiempo y grupos
 IDENTIFICAR un patrón concreto y formular una explicación de dominio
 PROPONER una sola modificación interpretable
 EVALUARLA en particiones no usadas para descubrir el patrón
 CONSERVARLA solo si mejora estabilidad, riesgo y coherencia operacional
 DOCUMENTAR los patrones que permanezcan y sus consecuencias

No debe perseguirse una nube «perfectamente aleatoria» añadiendo términos hasta agotar grados de libertad. El propósito es conocer dónde falla la aproximación y si ese fallo compromete la decisión.

11.2.8. Ejemplo práctico guiado: diagnóstico y mejora de una regresión

Una fábrica predice minutos de mecanizado por lote a partir de número de piezas, dureza media, antigüedad de la máquina y turno. El modelo aditivo inicial logra MAE de validación 14,2 minutos. El equipo desea reducir error y obtener intervalos útiles para programar capacidad.

Diagnóstico inicial. Residuos contra ajustados presentan embudo: la variación crece con tamaño de lote. Residuos contra número de piezas muestran curvatura; los lotes grandes tardan más que la recta. En el tiempo aparecen rachas positivas durante dos semanas, coincidentes con una herramienta desgastada. Dos lotes experimentales tienen alto apalancamiento. El Q-Q revela cola derecha, pero gran parte procede de esos períodos de desgaste.

Interpretación. Hay al menos tres mecanismos: economía de preparación para lotes pequeños y saturación para grandes, dispersión proporcional a duración y estado temporal de herramienta omitido. Eliminar los lotes experimentales no resuelve ninguno. La variable «estado final de herramienta» no está disponible antes del mecanizado y sería fuga; sí está disponible el número acumulado de ciclos desde el último reemplazo.

Modificación. Se añade una base por tramos para piezas con un nudo operativo en 100, y ciclos desde reemplazo. Se conserva turno como categoría. Para estabilizar error relativo se compara modelar $\log Y$ con mantener Y y usar inferencia robusta. La validación avanza por semanas y todas las elecciones se hacen antes de la prueba final.

El modelo en escala original con tramo queda conceptualmente

$$Y = \beta_0 + \beta_1 P + \beta_2 (P - 100)_+ + \beta_3 D + \beta_4 C + \gamma^T \text{turno} + \varepsilon.$$

Si $\hat{\beta}_1 = 0,72$ y $\hat{\beta}_2 = 0,31$, cada pieza adicional se asocia con 0,72 minutos hasta 100 piezas y 1,03 minutos después. No hay discontinuidad en el nudo.

Comparación. El modelo inicial obtiene MAE 14,2 y RMSE 23,8; el modelo por tramos, MAE 10,9 y RMSE 17,6; el logarítmico, MAE 11,1 y mejor error relativo, pero subestima algunos lotes largos al retransformarse. Se elige el modelo por tramos porque el costo operativo es absoluto y sus intervalos con varianza modelada alcanzan cobertura más uniforme.

Influencia y límites. Los lotes experimentales se conservan y se etiquetan como régimen; el resultado cambia poco al retirarlos después de introducir el tramo. Persisten rachas leves, por lo que se declara dependencia y se calculan incertidumbres agrupadas por semana. El error final se reporta por tamaño, turno y antigüedad. La mejora no se atribuye a «normalizar residuos», sino a representar mecanismos disponibles al momento de decisión y validar su utilidad.

11.3. Modelos lineales regularizados

11.3.1. Complejidad y sobreajuste

Un modelo flexible reduce error de entrenamiento, pero puede aprender fluctuaciones particulares de la muestra. La diferencia entre buen ajuste interno y mal riesgo futuro es sobreajuste. En modelos lineales, la complejidad aumenta con predictores, bases, interacciones y libertad de sus coeficientes. Cuando p se acerca a n , OLS puede tener varianza enorme; si $p \geq n$, incluso puede interpolar los datos sin identificar una solución única.

El compromiso sesgo-varianza se ilustra, para error cuadrático en un punto $\mathbf{x}$, mediante

$$\mathbb{E}[(Y - \hat{f}(\mathbf{x}))^2] = \sigma^2 + \text{Sesgo}[\hat{f}(\mathbf{x})]^2 + \text{Var}[\hat{f}(\mathbf{x})].$$

OLS busca poco sesgo bajo una especificación correcta, pero puede ser muy variable. Regularizar restringe coeficientes, introduce sesgo deliberado y puede reducir varianza más que suficiente para disminuir riesgo total.

La complejidad no es solo cantidad de columnas. Escalas, colinealidad y rango de X determinan cuánto puede oscilar una predicción. La norma de β sirve como control: coeficientes grandes permiten respuestas sensibles a perturbaciones. Las penalizaciones agregan a la pérdida un costo por esa magnitud:

$$\text{objetivo} = \text{error de ajuste} + \lambda \text{ complejidad}.$$

$\lambda = 0$ recupera OLS; al crecer λ , aumenta contracción. No es un parámetro que deba optimizarse sobre prueba. El procedimiento completo, incluida transformación, selección de λ y reajuste, se evalúa fuera de muestra.

Regularizar no corrige etiquetas erróneas, fuga, muestreo sesgado ni forma funcional absurda. Tampoco garantiza interpretabilidad causal. Es una herramienta contra varianza y mal condicionamiento. La curva de aprendizaje ayuda a distinguir problemas: una brecha grande entre entrenamiento y validación sugiere varianza; errores altos en ambos pueden indicar sesgo, variables insuficientes o ruido.

11.3.2. Regresión Ridge

Ridge minimiza pérdida cuadrática con penalización L2:

$$\hat{\beta}^R = \arg \min_{\beta} \left\{ \frac{1}{n} \|\mathbf{y} - X\beta\|_2^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\},$$

donde el intercepto suele excluirse de la suma. Con columnas centradas, la solución es

$$\hat{\beta}^R = (X^T X + n\lambda I)^{-1} X^T \mathbf{y}.$$

Agregar $n\lambda$ a la diagonal mejora condicionamiento y garantiza invertibilidad para $\lambda > 0$. Ridge no suele producir ceros exactos: conserva señales débiles, pero contraídas.

La SVD muestra qué hace. Si $X = UDV^T$, con valores singulares d_k , OLS multiplica cada componente por $1/d_k$; Ridge usa

$$\frac{d_k}{d_k^2 + n\lambda}.$$

Las direcciones con d_k pequeño, mal determinadas por los datos, sufren mayor contracción. Esto explica su eficacia con predictores correlacionados. Si dos sensores energéticos casi duplican información, OLS puede asignarles coeficientes opuestos inestables; Ridge tiende a repartir el efecto.

Existe una forma restringida equivalente: minimizar SSE sujeto a $\|\beta\|_2^2 \leq t$. Geométricamente, las elipses de pérdida tocan una esfera suave. Como la frontera no tiene esquinas, el contacto rara vez ocurre exactamente en un eje; de ahí que no seleccione variables.

El sesgo de Ridge invalida aplicar sin más la inferencia clásica de OLS. Su objetivo usual es predicción estable. Los grados de libertad efectivos son

$$df(\lambda) = \text{tr}\{X(X^T X + n\lambda I)^{-1} X^T\},$$

que decrecen continuamente con la penalización. Ridge es particularmente útil cuando muchas variables aportan efectos pequeños y correlacionados, como términos de texto o indicadores económicos. Si se necesita retirar fuentes completas, coeficientes pequeños no equivalen a selección operacional.

11.3.3. Regresión Lasso

Lasso emplea la norma L1:

$$\hat{\beta}^L = \arg \min_{\beta} \left\{ \frac{1}{n} \|\mathbf{y} - X\beta\|_2^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

La región restringida $\|\beta\|_1 \leq t$ posee esquinas sobre los ejes. Las elipses de pérdida suelen tocarla en una esquina, generando coeficientes exactamente cero. Lasso combina contracción y selección embebida.

Con predictores ortonormales, la solución se entiende mediante umbral suave. Si z_j es el coeficiente OLS en la escala correspondiente,

$$\hat{\beta}_j^L = \text{sign}(z_j)(|z_j| - c\lambda)_+,$$

con c dependiente de la convención de escala. Señales bajo el umbral desaparecen; las restantes se acercan a cero. En general no hay fórmula cerrada conjunta y se usan métodos de optimización como descenso por coordenadas, pero el objetivo es convexo.

La selección no convierte los términos no nulos en «variables verdaderas». Con dos predictores muy correlacionados, Lasso puede elegir uno y descartar otro ante una mínima perturbación. La predicción puede ser estable mientras la lista no lo es. Se deben examinar frecuencias de selección en remuestreos, trayectorias y grupos de variables originales, especialmente cuando una categoría produce varios indicadores.

Lasso es atractivo cuando existe una representación potencialmente grande y se espera esparsidad, como miles de términos textuales con pocos relevantes por tarea. Puede seleccionar como máximo un número limitado de variables en ciertos regímenes y sesga efectos grandes por la misma penalización lineal. Tras seleccionar y volver a ajustar OLS se reduce contracción, pero se reintroduce varianza y la inferencia ingenua ignora que la selección miró Y .

Si el fin es inferencial, se necesitan procedimientos postselección específicos o una separación confirmatoria. Para predicción, lo esencial es que toda selección ocurra dentro de validación. Un coeficiente cero significa que esa variable no fue necesaria para esa solución penalizada, escala y muestra; no prueba ausencia de asociación ni de efecto causal.

11.3.4. Elastic Net

Elastic Net combina L1 y L2:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \left\{ \frac{1}{n} \|\mathbf{y} - X\beta\|_2^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right] \right\}.$$

$\alpha = 1$ corresponde a Lasso y $\alpha = 0$ a Ridge, según esta parametrización. λ controla fuerza global; α , mezcla. La parte L1 produce ceros y la L2 estabiliza grupos correlacionados.

Supóngase que un modelo financiero incluye tasas a 3, 6 y 12 meses, altamente correlacionadas. Ridge conserva las tres con pesos repartidos; Lasso puede escoger una de modo inestable; Elastic Net puede retener un subconjunto conjunto con menor sensibilidad. El «efecto de agrupamiento» no garantiza seleccionar grupos semánticos completos, pero reduce la competición extrema de Lasso.

Elastic Net es útil cuando $p > n$, hay bloques de variables relacionadas y se desea alguna esparsidad. Añade un hiperparámetro, por lo que aumenta búsqueda y riesgo de sobreajustar la validación. Se evalúa una cuadrícula razonable de (α, λ) dentro de cada pliegue, no una exploración ilimitada sobre el conjunto de prueba.

La elección entre las tres familias responde al objetivo. Si muchas señales pequeñas son plausibles y se prioriza estabilidad, Ridge. Si se espera una solución escasa y retirar variables tiene valor, Lasso, verificando estabilidad. Si ambas condiciones coexisten, Elastic Net. Estas son hipótesis que la validación puede refutar, no recetas automáticas.

También existen penalizaciones estructuradas: Group Lasso selecciona grupos, y otras variantes respetan jerarquía o suavidad. No deben introducirse solo por sofisticación. Si una categoría se representa con diez indicadores, penalizarlos como grupo puede ser más coherente que permitir que sobrevivan niveles aislados, pero requiere definir esa unidad antes de observar resultados.

11.3.5. Estandarización y regularización

Las penalizaciones actúan sobre coeficientes, por lo que dependen de unidades. Si X_1 se expresa en euros y X_2 en miles de euros, idéntico efecto predictivo requiere coeficientes de magnitudes distintas y recibe penalizaciones distintas. Se estandarizan las continuas:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

usando media y desviación aprendidas solo en entrenamiento. El objetivo se centra de modo similar; el intercepto queda sin penalizar. Tras ajustar, puede recuperarse la escala original para interpretación.

La estandarización no vuelve comparables todos los cambios. Una desviación estándar de ingreso quizá sea un cambio amplio, mientras una de temperatura sea habitual. Tampoco corrige asimetría, extremos ni unidades equivocadas. Para distribuciones de cola pesada puede considerarse una escala robusta, pero debe formar parte del procedimiento validado.

Las variables binarias plantean una decisión. Estandarizarlas iguala varianza y puede penalizar menos los niveles raros en escala original; dejarlas en 0/1 conserva lectura, pero la fuerza efectiva difiere. No hay regla universal: se documenta la convención y, para variables categóricas, puede usarse una penalización por grupos. Nunca se estandariza el intercepto.

Fuga frecuente. Calcular $\bar{x}_j$ y s_j sobre todo el conjunto antes de validación comunica información de validación al entrenamiento. Aunque no use directamente Y , altera la representación y puede optimizar resultados. En cada pliegue se ajustan imputación, codificación, escala y modelo únicamente con la parte de entrenamiento.

La estandarización también mejora optimización, pues evita contornos extremadamente alargados. Una columna de varianza cero no puede escalarse y debe tratarse explícitamente. En producción se persisten los parámetros del entrenamiento; recalculas medias con cada lote cambiaría silenciosamente el modelo. Si la

distribución deriva, se monitoriza y se decide un reentrenamiento completo, no una normalización improvisada.

11.3.6. Selección del parámetro de penalización

λ se elige para minimizar una estimación de riesgo futuro, no SSE de entrenamiento. Se define una secuencia logarítmica desde penalización casi nula hasta una que contrae fuertemente. Para cada valor se repite el pipeline en los mismos pliegues y se agrega la métrica operacional.

DEFINIR particiones coherentes con el despliegue y una rejilla de penalizaciones PARA cada lambda (y cada alpha, si corresponde):

PARA cada pliegue:

ajustar preprocesamiento con entrenamiento interno

ajustar el modelo penalizado

evaluar en validación interna intacta

calcular media, dispersión y estabilidad de coeficientes

ELEGIR según una regla predefinida

REAJUSTAR el pipeline con todos los datos de desarrollo

EVALUAR una vez en prueba externa

La curva de validación suele ser plana cerca del mínimo. Elegir el valor con menor decimal aparenta precisión inexistente. La regla de un error estándar selecciona la mayor penalización cuyo error está dentro de un error estándar del mínimo; favorece parsimonia y estabilidad. Debe declararse de antemano y el error estándar debe respetar dependencia entre pliegues.

Una validación aleatoria no sirve para toda tarea. En movilidad temporal se usan cortes futuros; en agricultura regional, grupos geográficos; en texto, documentos de la misma fuente pueden necesitar agruparse. Si se comparan muchos hiperparámetros, el ganador sobreajusta los pliegues. Una validación anidada estima el procedimiento completo: el bucle interno elige λ y el externo evalúa.

Además de pérdida media se examinan error por subgrupo, número de coeficientes no nulos, estabilidad de selección y sensibilidad a valores vecinos. La penalización óptima puede cambiar si cambia la métrica. Un λ que minimiza RMSE no necesariamente minimiza costo de adquisición de variables.

Después de reajustar, no se informa el error interno como rendimiento definitivo. La prueba intacta o evaluación prospectiva mantiene la separación entre selección y estimación. En despliegue, λ no se adapta continuamente mirando resultados futuros sin versionar y reevaluar todo el procedimiento.

11.3.7. Ejemplo práctico guiado: comparación de regresiones regularizadas

Una entidad financiera predice pérdida mensual de una cartera a partir de 180 indicadores: saldos, atrasos por ventana, tasas, variables macroeconómicas y decenas de razones correlacionadas. Hay 900 meses-segmento de desarrollo. El objetivo es predicción estable; una lista corta es deseable, pero no a costa de perder grupos de señales.

Se separa el último año como prueba y se valida con ventanas temporales. En cada

pliegue se imputan medianas, se estandarizan continuas y se ajustan OLS, Ridge, Lasso y Elastic Net. El baseline usa la pérdida del mes anterior. Para Elastic Net se prueban pocos valores predefinidos de α ; para cada familia se aplica la regla de un error estándar.

Modelo	RMSE de prueba	Coefficientes no nulos	Estabilidad cualitativa
baseline	1,00	—	alta, pero rezagado ante cambios
OLS	0,94	180	baja; signos cambian entre ventanas
Ridge	0,78	180	alta
Lasso	0,83	24	baja entre indicadores sustitutos
Elastic Net	0,79	51	media-alta

Los errores están normalizados respecto del baseline. OLS mejora poco y presenta grandes coeficientes opuestos para atrasos a 30 y 60 días. Ridge los contrae y obtiene el mejor RMSE. Lasso produce la solución más escasa, pero el conjunto cambia: selecciona atraso a 30 días en unas ventanas y a 60 en otras. Elastic Net conserva ambos con pesos moderados y casi iguala Ridge.

La trayectoria muestra que, con λ pequeño, la varianza entre pliegues es alta; una región intermedia estabiliza error; penalización excesiva aproxima el intercepto y empeora. Elegir solo por cantidad de ceros habría favorecido Lasso, ignorando 6% de pérdida relativa frente a Ridge. Como mantener 180 columnas no implica 180 fuentes distintas, el ahorro operacional de Lasso era menor de lo supuesto.

Se elige Elastic Net aunque Ridge tenga una ventaja mínima: su error queda dentro de incertidumbre, reduce términos y mantiene grupos. Se conservan como bloque todas las columnas necesarias para calcular una razón seleccionada; no se afirma que las 51 sean causas de pérdida. Una prueba de estrés con subida abrupta de tasas revela subestimación común a todos los modelos, señal de cambio fuera del soporte, no problema resoluble ajustando λ .

El informe incluye curvas de validación, distribución temporal del error, frecuencia de selección y parámetros de escalado. La conclusión es comparativa: regularizar mejora estabilidad frente a OLS; Lasso aporta esparsidad inestable; Elastic Net ofrece el compromiso más útil bajo el costo declarado.

11.4. Regresión logística y clasificación

11.4.1. Formulación de la clasificación binaria

En clasificación binaria, $Y \in \{0, 1\}$. El objetivo estadístico puede ser estimar

$$p(\mathbf{x}) = P(Y = 1 \mid X = \mathbf{x}),$$

y el objetivo decisonal, tomar una acción a partir de esa probabilidad. Son etapas distintas. Una probabilidad bien estimada permite múltiples políticas; una etiqueta rígida oculta incertidumbre y costos.

La codificación de la clase positiva debe declararse. En detección de incumplimiento financiero, $Y = 1$ podría significar impago; sensibilidad y precisión se referirán entonces a ese evento. Cambiar etiquetas transforma interpretaciones aunque no la información.

Una regla de clase $a(\mathbf{x}) \in \{0, 1\}$ tiene riesgo esperado según una matriz de costos. Si un falso negativo cuesta C_{FN} y un falso positivo C_{FP} , sin otros costos se elige clase 1 cuando

$$C_{FP}[1 - p(\mathbf{x})] < C_{FN}p(\mathbf{x}),$$

equivalentemente $p(\mathbf{x}) > C_{FP}/(C_{FP} + C_{FN})$. Por tanto, el umbral 0,5 solo es óptimo con costos simétricos y probabilidades aplicables a la población de decisión.

La prevalencia $P(Y = 1)$ condiciona métricas y baselines. Con 1% de positivos, predecir siempre cero logra 99% de exactitud y ninguna utilidad para detectar positivos. Se reportan matriz de confusión, sensibilidad, especificidad, precisión, métricas de ranking y pérdidas probabilísticas según el uso. Precisión depende especialmente de prevalencia; no se transporta sin más a otra población.

La partición debe impedir fuga. En clasificación de documentos, versiones del mismo texto no pueden repartirse entre entrenamiento y prueba; en crédito, variables posteriores al incumplimiento no son entradas válidas. También se define una ventana para observar la etiqueta: casos recientes cuyo resultado aún no maduró no son negativos, sino censurados o desconocidos.

11.4.2. Función logística

Un modelo lineal aplicado directamente a etiquetas puede producir valores fuera de $[0, 1]$ y asumir varianza constante, incompatible con Bernoulli. La regresión logística modela un puntaje lineal $\eta = \beta_0 + \mathbf{x}^T \beta$ y lo transforma mediante la sigmoide:

$$\sigma(\eta) = \frac{1}{1 + e^{-\eta}}, \quad p(\mathbf{x}) = \sigma(\eta).$$

La función es monótona, está acotada y satisface $\sigma(0) = 0,5$ y $\sigma(-\eta) = 1 - \sigma(\eta)$. Su derivada es

$$\frac{dp}{d\eta} = p(1 - p),$$

máxima en $p = 0,5$ y pequeña cerca de 0 o 1. Por eso un mismo cambio en el puntaje produce mayor cambio absoluto de probabilidad en casos inciertos que en extremos.

La frontera para umbral 0,5 es $\eta = 0$, un hiperplano en las características transformadas. El modelo puede representar fronteras curvas si X incluye términos polinómicos o interacciones, aunque sigue siendo lineal en parámetros. El umbral no cambia el ranking; desplaza la frontera paralelamente para otros valores.

Ejemplo. Si $\eta = -3 + 0,8x$ y $x = 4$, entonces $\eta = 0,2$ y $p = 1/(1 + e^{-0,2}) \approx 0,55$. Para $x = 5$, $\eta = 1$ y $p \approx 0,731$. El incremento de probabilidad no es constante: depende del punto inicial.

Numéricamente, probabilidades extremas deben manejarse en escala estable, pero la teoría no cambia. La sigmoide no garantiza calibración: solo restringe la forma.

Si faltan no linealidades, cambia la prevalencia o se seleccionó la muestra, las probabilidades pueden ser sistemáticamente erróneas.

11.4.3. Odds y log-odds

Los **odds** o momios de un evento son

$$\text{odds}(p) = \frac{p}{1-p}.$$

Una probabilidad de 0,75 corresponde a odds 3:1; una de 0,20, a 1:4. Probabilidad y odds no son lo mismo: aumentar odds en 50% no suma 50 puntos porcentuales.

La transformación logit es el logaritmo de los odds:

$$\text{logit}(p) = \log \frac{p}{1-p} = \beta_0 + \sum_j \beta_j x_j.$$

Convierte (0, 1) en toda la recta real. En esta escala, cada coeficiente es aditivo. Si x_j aumenta una unidad manteniendo el resto fijo, los log-odds aumentan β_j y los odds se multiplican por e^{β_j} . e^{β_j} es la razón de odds.

Si $\beta_j = 0,40$, la razón de odds es $e^{0,40} \approx 1,49$: los odds son 49% mayores. No significa que la probabilidad aumente 49% ni 0,40. Si la probabilidad inicial es 0,10, los odds pasan de 0,111 a 0,166 y la probabilidad a 0,142; si era 0,70, pasa a aproximadamente 0,777. El efecto en puntos porcentuales depende de todas las entradas.

Para comunicar efectos se pueden mostrar probabilidades predichas en perfiles representativos o efectos marginales

$$\frac{\partial p}{\partial x_j} = \beta_j p(1-p).$$

El promedio de estos efectos sobre la muestra resume una escala de probabilidad, pero sigue condicionado al modelo y población. Con interacción, β_j deja de ser una razón de odds constante para todos los valores del modificador.

La razón de odds también requiere cautela en eventos frecuentes: puede parecer mucho mayor que la razón de riesgos. Un odds ratio de 2 no implica duplicar probabilidad. En estudios observacionales, ni siquiera una razón ajustada demuestra causalidad sin identificación adecuada.

11.4.4. Estimación e interpretación de coeficientes

Condicionado a X , se modela $Y_i \sim \text{Bernoulli}(p_i)$ con $p_i = \sigma(\mathbf{x}_i^T \beta)$. La verosimilitud es

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1-p_i)^{1-y_i}.$$

Tomar logaritmos da

$$\ell(\beta) = \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

Maximizar ℓ equivale a minimizar log-loss o entropía cruzada. Sustituyendo la sigmoide,

$$-\ell = \sum_i [\log(1 + e^{\eta_i}) - y_i \eta_i].$$

El gradiente es $X^T(\mathbf{p} - \mathbf{y})$ y la Hessiana $X^T W X$, con W diagonal y $w_i = p_i(1 - p_i)$. No existe, en general, solución cerrada; algoritmos iterativos como Newton-Raphson o mínimos cuadrados ponderados convergen al óptimo convexo si el problema está bien planteado.

En el máximo, $X^T(\mathbf{y} - \mathbf{p}) = 0$. Con intercepto, $\sum y_i = \sum p_i$: la cantidad esperada total coincide con la observada en entrenamiento, propiedad que no garantiza calibración fuera de muestra.

La varianza asintótica se estima mediante $(X^T \widehat{W} X)^{-1}$ bajo especificación correcta. Puede construirse un intervalo para β_j y exponenciar extremos para obtener uno de la razón de odds. Valores p , intervalos y coeficientes sufren los mismos problemas de multiplicidad, colinealidad y selección que en regresión lineal.

Un problema especial es la **separación**: una característica o combinación distingue perfectamente clases. La verosimilitud aumenta al llevar ciertos coeficientes a infinito y el MLE finito no existe. Coeficientes enormes y errores de convergencia son síntomas. Reunir más datos con solapamiento, revisar fuga o aplicar regularización son soluciones; eliminar arbitrariamente casos difíciles no lo es.

La regularización logística añade L1, L2 o Elastic Net a la log-loss. Mejora estabilidad en alta dimensión, como clasificación textual, pero exige estandarización y selección de hiperparámetros dentro de validación. La interpretación corresponde al modelo penalizado y no hereda automáticamente inferencia clásica.

11.4.5. Probabilidades y umbrales de decisión

Una probabilidad es una estimación de riesgo; un umbral la convierte en acción:

$$\hat{y}_t = I(\hat{p} \geq t).$$

Al bajar t aumentan verdaderos positivos y falsos positivos; al subirlo, disminuyen ambos. La matriz de confusión contiene TP , FP , TN y FN . De ella se derivan

$$\text{sensibilidad} = \frac{TP}{TP + FN}, \quad \text{especificidad} = \frac{TN}{TN + FP}, \quad \text{precisión} = \frac{TP}{TP + FP}.$$

La curva ROC representa sensibilidad frente a tasa de falsos positivos para todos los umbrales; su AUC es la probabilidad de ordenar un positivo al azar por encima de un negativo al azar. No mide calibración ni utilidad en un umbral concreto. Con

clases raras, la curva precisión-recall suele mostrar mejor el compromiso sobre la clase positiva.

El umbral se elige con datos de validación y costos definidos, nunca maximizando retrospectivamente una métrica en prueba. Si revisar una alerta cuesta 5 unidades y omitir un caso prioritario cuesta 80, la política minimiza costo esperado y puede estar lejos de 0,5. También hay restricciones: «revisar como máximo 200 casos diarios» induce seleccionar los mayores riesgos hasta agotar capacidad; el umbral variará con volumen.

F1 armoniza precisión y sensibilidad, pero ignora verdaderos negativos y fija implícitamente una valoración. La exactitud balanceada pondera clases, pero tampoco representa todos los costos. Una política defendible informa métrica, prevalencia, capacidad y costo.

Puede existir una zona de abstención: aceptar por debajo de t_b , revisar manualmente entre t_b y t_a , actuar automáticamente por encima de t_a . La abstención no elimina errores; redistribuye casos y requiere medir cobertura, desempeño y carga humana. Los umbrales por grupo pueden satisfacer restricciones distintas, pero plantean cuestiones legales y de equidad y deben evaluarse cuidadosamente.

Tras desplegar, cambios de prevalencia alteran precisión y costo aunque ROC permanezca similar. Se monitorizan probabilidades, decisiones, resultados demorados y capacidad. Reoptimizar el umbral sin recalibrar ni considerar nueva población puede empeorar el sistema.

11.4.6. Clasificación multiclase

Cuando $Y \in \{1, \dots, K\}$, se necesitan probabilidades que sumen uno. La regresión logística multinomial usa *softmax*:

$$P(Y = k | \mathbf{x}) = \frac{\exp(\eta_k)}{\sum_{r=1}^K \exp(\eta_r)}, \quad \eta_k = \beta_{0k} + \mathbf{x}^T \beta_k.$$

Como sumar la misma constante a todos los puntajes no cambia probabilidades, se fija una clase de referencia o una restricción. Respecto de referencia K ,

$$\log \frac{P(Y = k | X)}{P(Y = K | X)} = \beta_{0k} + X^T \beta_k.$$

Cada coeficiente modifica log-odds de clase k frente a la referencia, condicionado a las demás. Cambiar referencia altera tablas, no probabilidades.

Otra estrategia es uno contra el resto: se ajustan K clasificadores binarios. Es flexible, pero sus probabilidades no suman necesariamente uno y cada tarea enfrenta prevalencia distinta. Uno contra uno ajusta pares y combina votos; resulta costoso cuando K crece. Softmax aprende las clases conjuntamente y suele ser la opción lineal coherente cuando son mutuamente excluyentes.

No debe confundirse multiclase con multietiqueta. Un documento puede pertenecer simultáneamente a «finanzas» y «regulación»; entonces se estiman eventos binarios relacionados y no se fuerza suma uno. Si las clases tienen orden, una regresión ordinal puede aprovecharlo en vez de tratarlas como nominales.

La evaluación incluye matriz de confusión y métricas por clase. El promedio macro da igual peso a clases; el micro agrega decisiones y favorece clases frecuentes; el ponderado queda entre ambos. Top- k es útil si se muestran varias alternativas, pero debe corresponder a la interfaz. Log-loss multiclase evalúa probabilidades y penaliza confianza equivocada.

En producción pueden aparecer clases nuevas. Forzarlas a una categoría conocida genera errores confiados. Detección de fuera de distribución, una clase «otro» entrenada con ejemplos representativos o abstención son políticas posibles, ninguna garantizada solo por softmax.

11.4.7. Calibración de probabilidades

Un predictor está calibrado si, entre casos a los que asigna probabilidad q , aproximadamente una fracción q resulta positiva:

$$P(Y = 1 \mid \hat{p} = q) = q.$$

Calibración y discriminación son diferentes. Un modelo puede ordenar perfectamente riesgos pero asignar 0,9 donde ocurre 0,6; otro puede estar calibrado prediciendo la prevalencia a todos, sin discriminar. Las decisiones basadas en costos necesitan ambas.

El **Brier score** es

$$BS = \frac{1}{n} \sum_i (\hat{p}_i - y_i)^2,$$

y combina calibración y resolución. Log-loss penaliza con fuerza probabilidades extremas erróneas. Un diagrama de confiabilidad agrupa predicciones y compara promedio predicho con frecuencia observada; debe acompañarse de cantidad de casos por intervalo e incertidumbre. Pocos casos en 0,9 no permiten afirmar mala calibración por una diferencia aislada.

El intercepto de calibración detecta sesgo global y una pendiente de calibración menor que uno suele indicar probabilidades demasiado extremas. Métricas como error esperado de calibración dependen del binning y pueden ocultar compensaciones; no deben reportarse solas.

La calibración se evalúa en datos no usados para ajustar el modelo. Si se corrige, se necesita una partición adicional o predicciones fuera de pliegue. El escalado de Platt ajusta una transformación logística del puntaje; la regresión isotónica aprende una función monótona más flexible y necesita más datos. La calibración por temperatura es común en multiclase. Ajustar y evaluar el calibrador sobre los mismos casos produce optimismo.

Cambios de prevalencia y de relación $P(Y \mid X)$ degradan calibración. Un modelo de prioridad entrenado durante una campaña puede sobreestimar riesgo después. Recalibrar intercepto puede bastar bajo cambio de prevalencia simple; si cambian relaciones, se requiere revisión mayor. La calibración debe comprobarse globalmente, por tiempo y en grupos con suficiente tamaño, sin asumir que calibración total implica calibración en cada subpoblación.

11.4.8. Ejemplo práctico guiado: clasificación de reclamos prioritarios

Una plataforma financiera recibe reclamos escritos y debe priorizar cuáles revisar en menos de dos horas. Un comité define $Y = 1$ cuando el caso combina posible perjuicio económico inmediato y plazo regulatorio breve. La etiqueta procede de revisión posterior, no de la prioridad histórica, para evitar copiar decisiones anteriores. La unidad es reclamo inicial; mensajes posteriores no están disponibles al ingreso.

Datos y representación. Se usan canal, producto, antigüedad de la cuenta, importe discutido, hora, historial agregado anterior y términos del texto inicial. Identidad personal se excluye salvo necesidad justificada. Reclamos del mismo expediente permanecen en el mismo grupo. Los últimos dos meses constituyen prueba temporal; dentro del desarrollo, validaciones avanzan en el tiempo. Un baseline asigna la prevalencia y otro usa una regla vigente por palabras clave.

Modelo. Una regresión logística con Elastic Net resulta apropiada para miles de términos correlacionados y variables estructuradas. Escala, vocabulario, ponderaciones y penalización se aprenden dentro de cada pliegue. El modelo entrega $\hat{p}$, no prioridad automática. En prueba obtiene ROC-AUC 0,88, PR-AUC 0,54 frente a prevalencia 0,12, Brier 0,083 y log-loss 0,286. La regla previa alcanza PR-AUC 0,31.

Calibración. El diagrama muestra sobreconfianza: casos predichos alrededor de 0,8 son prioritarios en 0,68. Se ajusta un calibrador con predicciones fuera de pliegue, sin tocar prueba. Tras calibrar, Brier baja a 0,075; ROC-AUC casi no cambia, como es esperable porque el ranking se conserva. En el período de prueba, el intervalo 0,6–0,7 contiene 64% positivos con muestra suficiente.

Umbral operacional. Revisar cuesta 8 unidades; omitir un prioritario, 120. El umbral teórico con esos costos sería $8/(8 + 120) = 0,0625$, pero la capacidad diaria limita revisiones al 35%. Se simulan políticas en validación. El umbral 0,18 usa 34% de capacidad, logra sensibilidad 0,91 y precisión 0,32. El umbral 0,50 usa 11%, sensibilidad 0,58 y precisión 0,61. El primero evita más omisiones y satisface capacidad, por lo que se elige. No se selecciona sobre prueba.

Se establece además una política de tres zonas:

Probabilidad calibrada	Acción
$p < 0,18$	cola ordinaria, con muestreo de auditoría
$0,18 \leq p < 0,65$	revisión prioritaria humana
$p \geq 0,65$	revisión inmediata; nunca resolución automática adversa

La auditoría aleatoria de la cola baja permite estimar falsos negativos y descubrir deriva. La zona alta acelera atención, pero una explicación textual no reemplaza el expediente.

Interpretación. Razones de odds elevadas aparecen para plazos próximos y determinados términos de urgencia; importes y antigüedad interactúan. No se publican palabras como causas ni reglas: el significado depende de coocurrencias y las personas podrían adaptar lenguaje. Se revisan falsos positivos, como usos negados de términos urgentes, y falsos negativos, como mensajes breves sin vocabulario explícito.

Equidad y seguimiento. Se evalúan sensibilidad, precisión y calibración por canal y tipo de producto. Diferencias pueden surgir por calidad textual o acceso digital. No se corrigen ocultando un atributo sin estudiar sus proxies. Cada semana se monitorizan prevalencia madura, capacidad, distribución de puntajes, tasa de abstención y desempeño por grupo; las etiquetas retrasadas se analizan por cohorte. Un cambio normativo activa reevaluación y versionado.

El resultado final es un sistema de apoyo: una probabilidad validada, una política de umbral ligada a costo y capacidad, revisión humana y auditoría. El éxito no se resume en AUC; incluye calibración, cobertura, tiempo de atención y consecuencias de los errores.

Síntesis

La regresión lineal aproxima una media condicional mediante una combinación de características. OLS puede entenderse algebraicamente, como solución de ecuaciones normales, y geométricamente, como proyección de y sobre el espacio columna de X . Esta geometría explica ortogonalidad de residuos, apalancamiento y sensibilidad al condicionamiento. Los coeficientes tienen una interpretación condicionada por unidades, transformaciones, categorías, interacciones y población; no adquieren significado causal automáticamente.

Los supuestos cumplen funciones diferentes. Esperanza condicional lineal sostiene la especificación; independencia y homocedasticidad sustentan la varianza clásica; normalidad permite inferencia exacta en muestras finitas; rango completo identifica coeficientes. Una violación no conduce siempre a descartar el modelo, pero sí obliga a determinar qué conclusión afecta. Gráficos, sensibilidad, diseño de validación y conocimiento del dominio se complementan.

Ridge, Lasso y Elastic Net controlan complejidad mediante normas L2, L1 y mixtas. Su utilidad surge del compromiso sesgo-varianza, especialmente con muchas variables o colinealidad. Escalar dentro de cada pliegue y elegir penalización sin consultar prueba forman parte del estimador. Esparsidad no equivale a verdad y estabilidad predictiva no garantiza estabilidad de selección.

La regresión logística modela log-odds lineales y estima parámetros por máxima verosimilitud. Sus probabilidades deben distinguirse de la decisión: umbrales dependen de costos, capacidad, prevalencia y restricciones. Ranking, calibración y utilidad son propiedades distintas. En multiclase, softmax coordina probabilidades; en cualquier caso, evaluación y recalibración deben reflejar la población de uso.

La lección transversal es metodológica: especificar primero la pregunta y el momento de información; ajustar sin fuga; comparar con un baseline; diagnosticar dónde falla; cuantificar incertidumbre; y separar una descripción estadística de una acción operacional.

Glosario

- **Apalancamiento:** singularidad de una observación en el espacio de predictores, medida en OLS por h_{ii} .
- **Calibración:** concordancia entre probabilidades predichas y frecuencias observadas.

- **Coefficiente:** parámetro que cuantifica un cambio en la escala lineal o de enlace, condicionado a los demás términos.
- **Elastic Net:** regularización que combina penalizaciones L1 y L2.
- **Error:** diferencia no observable entre respuesta y media poblacional modelada.
- **Heterocedasticidad:** variación de la varianza condicional del error entre observaciones.
- **Influencia:** grado en que una observación altera coeficientes o predicciones ajustadas.
- **Interacción:** término que permite que el efecto de una variable dependa de otra.
- **Lasso:** regresión penalizada por norma L1, capaz de producir coeficientes cero.
- **Logit:** logaritmo de los odds, $\log[p/(1 - p)]$.
- **Máxima verosimilitud:** elección de parámetros que hace más compatibles los datos observados con el modelo probabilístico.
- **Mínimos cuadrados ordinarios:** estimación que minimiza la suma de residuos al cuadrado.
- **Multicolinealidad:** dependencia lineal fuerte o exacta entre columnas de la matriz de diseño.
- **Odds:** cociente entre probabilidad de evento y de no evento, $p/(1 - p)$.
- **Regularización:** restricción o penalización que controla complejidad y estabiliza estimaciones.
- **Residuo:** diferencia observable $y_i - \hat{y}_i$ después del ajuste.
- **Ridge:** regresión penalizada por norma L2, que contrae coeficientes sin hacerlos usualmente cero.
- **Sigmoide:** función $1/(1 + e^{-z})$ que transforma un puntaje real en probabilidad.
- **Umbral:** punto de corte que convierte una probabilidad en una acción o clase.
- **Verosimilitud:** función de los parámetros inducida por la probabilidad de los datos observados.

Preguntas de revisión

1. ¿Por qué la media condicional minimiza el error cuadrático esperado? Derive la descomposición correspondiente.
2. ¿Qué diferencia hay entre error poblacional y residuo? ¿Cuál puede observarse?
3. Derive $\hat{\beta}_0$ y $\hat{\beta}_1$ en regresión simple a partir de las ecuaciones normales.
4. Explique la solución OLS como una proyección. ¿Qué significa $X^T \mathbf{e} = 0$?
5. ¿Por qué invertir explícitamente $X^T X$ puede ser numéricamente desaconsejable?
6. Interprete un coeficiente de una variable continua, uno categórico y uno de interacción, indicando sus referencias.
7. ¿Qué supuestos requiere Gauss-Markov y qué conclusión permite? ¿Exige normalidad?
8. Distinga las consecuencias de heterocedasticidad para coeficientes, errores estándar e intervalos predictivos.
9. ¿Por qué la multicolinealidad puede perjudicar interpretación sin arruinar predicciones internas?
10. Compare apalancamiento, residuo e influencia mediante un caso conceptual.
11. Explique cómo Ridge modifica las direcciones asociadas con valores

- singulares pequeños.
12. ¿Por qué Lasso genera ceros y por qué esos ceros pueden ser inestables?
 13. ¿Qué información debe aprenderse dentro de cada pliegue al validar un modelo regularizado?
 14. Derive el gradiente de la log-verosimilitud logística y explique por qué no hay fórmula cerrada usual.
 15. Con probabilidad inicial 0,20 y coeficiente logístico 0,7, calcule la nueva probabilidad tras aumentar una unidad el predictor.
 16. ¿Por qué AUC alta no implica buena calibración ni una política útil?
 17. Obtenga el umbral óptimo con costos $C_{FP} = 10$ y $C_{FN} = 90$, bajo los supuestos del texto.
 18. Compare softmax, uno contra el resto y clasificación multietiqueta.
 19. Diseñe una partición válida para predecir demanda futura y otra para clasificar textos con versiones duplicadas.
 20. Enumere tres afirmaciones que un coeficiente predictivo no autoriza a realizar.

Actividad integradora

Una cooperativa agrícola desea estimar el rendimiento de una próxima cosecha y clasificar parcelas con riesgo alto de rendimiento insuficiente. Dispone de superficie, variedad, fecha de siembra, análisis de suelo, pronósticos disponibles al inicio de campaña, historial de rendimientos y prácticas declaradas. Algunas parcelas pertenecen a la misma explotación y las campañas están ordenadas temporalmente.

Elabore un informe técnico, sin implementar software, que contenga:

1. Definición de unidad, momento de corte, horizonte, objetivo continuo y etiqueta binaria. Identifique al menos tres fugas posibles.
2. Un baseline de regresión y otro de clasificación, con métricas justificadas.
3. Una matriz de diseño conceptual con continuas, una categoría, una transformación y una interacción. Escriba ambos modelos mediante fórmulas.
4. Interpretación completa de cinco coeficientes hipotéticos, incluidas unidades y condiciones «manteniendo constante».
5. Derivación matricial de OLS y explicación geométrica para esa matriz.
6. Plan diagnóstico que trate linealidad, dependencia por explotación, heterocedasticidad, residuos, colinealidad e influencia.
7. Comparación razonada de OLS, Ridge, Lasso y Elastic Net. Anticipe qué ocurrirá con variables climáticas correlacionadas.
8. Pseudocódigo de validación temporal y agrupada en el que preprocesamiento y selección de penalización ocurran sin fuga.
9. Para el clasificador, una tabla con probabilidades hipotéticas y resultados que permita calcular log-loss, Brier, sensibilidad, precisión y especificidad en dos umbrales.
10. Una política de decisión basada en costos de inspección, costo de omisión y capacidad máxima. Incluya opción de abstención.
11. Un diagrama de calibración conceptual y una propuesta de recalibración que preserve un conjunto de evaluación intacto.
12. Una sección final de límites: extrapolación climática, cambio de variedades, retraso de etiquetas, equidad entre explotaciones y monitorización.

La evaluación de la actividad debe valorar coherencia entre pregunta, datos, modelo, validación y decisión. No basta con presentar fórmulas correctas: cada elección debe corresponder al momento real de uso, reconocer incertidumbre y distinguir predicción, asociación e intervención.

Capítulo 12. Métodos supervisados avanzados y ensambles

Los modelos lineales expresan una relación mediante una forma funcional relativamente rígida. Este capítulo estudia métodos capaces de representar interacciones, umbrales y fronteras no lineales sin que el analista deba especificarlas una por una. Esa flexibilidad no elimina la necesidad de formular el problema, construir un protocolo de validación y relacionar las métricas con decisiones reales. Por el contrario, cuanto mayor es la capacidad del modelo, más importante resulta distinguir ajuste de generalización.

Se considerará un conjunto de aprendizaje $D = \{(x_i, y_i)\}_{i=1}^n$, con $x_i \in \mathbb{R}^p$. En clasificación, y_i pertenece a una de K clases; en regresión, $y_i \in \mathbb{R}$. El objetivo empírico general es encontrar una función f que minimice una pérdida regularizada,

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \left[\frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) + \lambda \Omega(f) \right],$$

donde $\mathcal{F}$ representa la familia de modelos, L cuantifica el desacuerdo con los datos, Ω controla complejidad y λ regula el compromiso entre ajuste y simplicidad. Árboles, máquinas de soporte vectorial y ensambles implementan este principio de maneras diferentes. Las técnicas de explicabilidad permiten estudiar el resultado, pero no convierten por sí solas una asociación predictiva en una explicación causal. Finalmente, el aprendizaje federado modifica el lugar donde se ajusta el modelo, no los fundamentos estadísticos de su evaluación.

Al terminar el capítulo se espera que el lector pueda: derivar criterios de partición y margen; reconocer el papel de la regularización; comparar bagging, Random Forest, boosting y stacking; diagnosticar sobreajuste, inestabilidad y fuga de información; interpretar herramientas globales y locales con sus supuestos; y diseñar conceptualmente un sistema federado consciente de sus riesgos.

12.1. Árboles de decisión

Un árbol de decisión representa una función mediante una secuencia jerárquica de preguntas. Cada nodo interno evalúa una condición, cada rama corresponde a una respuesta y cada hoja produce una predicción. Su atractivo reside en que puede aproximar relaciones no lineales, descubrir interacciones y admitir variables en

escalas distintas. Su principal debilidad es la inestabilidad: cambios pequeños en los datos pueden alterar las primeras divisiones y, con ellas, buena parte de la estructura.

12.1.1. Particiones recursivas

Un árbol induce una partición del espacio de atributos en regiones disjuntas $R_1, \dots, R_M$. Para variables numéricas, una división típica de una región R usa el atributo j y el umbral s :

$$R_{\text{izq}}(j, s) = \{x \in R : x_j \leq s\}, \quad R_{\text{der}}(j, s) = \{x \in R : x_j > s\}.$$

El algoritmo voraz examina divisiones candidatas y elige la que más reduce una función de impureza o pérdida. Después repite el procedimiento en cada región hija. Se denomina *recursivo* porque cada hija se trata como un problema del mismo tipo, y *binario* cuando toda división genera dos ramas. El árbol no busca simultáneamente la mejor estructura global: esa optimización combinatoria sería muy costosa. Una elección local óptima puede impedir una estructura posterior mejor.

En clasificación, si p_{mk} es la proporción de la clase k en el nodo m , la predicción de la hoja suele ser $\hat{k}_m = \arg \max_k p_{mk}$. También pueden conservarse las proporciones como estimaciones de probabilidad, aunque las hojas pequeñas producen estimaciones extremas e inestables. En regresión cuadrática, la constante que minimiza la suma de cuadrados en R_m es la media:

$$\hat{c}_m = \arg \min_c \sum_{i: x_i \in R_m} (y_i - c)^2 = \frac{1}{n_m} \sum_{i: x_i \in R_m} y_i.$$

La función resultante es constante por regiones: $\hat{f}(x) = \sum_{m=1}^M \hat{c}_m \mathbf{1}(x \in R_m)$. Esto explica las predicciones escalonadas de un árbol de regresión y su incapacidad para extrapolar tendencias más allá de los valores observados.

Pseudocódigo: crecimiento recursivo

```

CRECER_NODO(datos D, restricciones):
    si se cumple un criterio de detención:
        devolver HOJA con la predicción calculada en D
    para cada atributo j:
        para cada división candidata s permitida:
            separar D en D_izq y D_der
            calcular reducción de impureza
        elegir (j*, s*) con mayor reducción válida
    si ninguna reducción es suficiente:
        devolver HOJA
    devolver NODO(j*, s*,
                  CRECER_NODO(D_izq, restricciones),
                  CRECER_NODO(D_der, restricciones))

```

Los valores ausentes, las variables categóricas de alta cardinalidad y las restricciones de tamaño requieren decisiones explícitas. Imputar antes del ajuste, crear una categoría informativa o emplear divisiones sustitutas son

alternativas distintas y deben formar parte del protocolo de validación. Una categoría con muy pocos casos puede generar una regla aparentemente perfecta que no se reproduce.

12.1.2. Entropía y ganancia de información

La entropía de un nodo con distribución de clases $p_1, \dots, p_K$ es

$$H(R) = - \sum_{k=1}^K p_k \log_2 p_k,$$

con la convención $0 \log 0 = 0$. Es cero si todos los ejemplos pertenecen a una clase y alcanza su máximo $\log_2 K$ cuando las clases son equiprobables. En el caso binario, $H(p) = -p \log_2 p - (1-p) \log_2 (1-p)$; es simétrica respecto de $p = 0.5$ y aumenta con la incertidumbre.

Una división de un nodo padre R en hijas $R_1, \dots, R_q$ se evalúa mediante la entropía posterior ponderada:

$$H_{\text{post}} = \sum_{r=1}^q \frac{n_r}{n} H(R_r).$$

La ganancia de información es

$$IG = H(R) - H_{\text{post}}.$$

Esta expresión puede interpretarse como la reducción esperada de incertidumbre sobre la clase al conocer la rama. El peso n_r/n evita que una hija pura pero diminuta domine la decisión.

Supóngase un lote de 100 piezas, 40 defectuosas y 60 conformes. La entropía inicial es $H(0.4) \approx 0.971$ bits. Una división por vibración produce una rama de 30 piezas con 24 defectuosas y otra de 70 con 16 defectuosas. Sus entropías son aproximadamente 0.722 y 0.776. Por tanto,

$$IG \approx 0.971 - [0.30(0.722) + 0.70(0.776)] = 0.211.$$

Otra división debe compararse con la misma base. No basta observar que una rama quedó pura. Además, una variable categórica con muchas categorías puede ofrecer numerosas oportunidades de separar accidentalmente los datos; limitar divisiones, agrupar categorías raras o validar fuera de muestra reduce este sesgo de selección.

La base del logaritmo cambia la unidad, no el orden entre divisiones. La ganancia tampoco es una prueba de asociación ni mide impacto causal. Solo informa cuánto mejora una partición en la muestra y el nodo actuales.

12.1.3. Índice de Gini

El índice de Gini para clasificación se define como

$$G(R) = 1 - \sum_{k=1}^K p_k^2 = \sum_{k=1}^K p_k(1 - p_k).$$

Puede interpretarse como la probabilidad de etiquetar incorrectamente una observación si se asigna una clase al azar según la distribución del nodo. En clasificación binaria, $G(p) = 2p(1 - p)$, con máximo 0.5 en $p = 0.5$ y mínimo cero en nodos puros. La reducción es

$$\Delta G = G(R) - \sum_r \frac{n_r}{n} G(R_r).$$

Para el ejemplo anterior, $G(R) = 1 - (0.4^2 + 0.6^2) = 0.48$. Las impurezas hijas son 0.32 y aproximadamente 0.353, de modo que $\Delta G \approx 0.137$. El valor no es comparable numéricamente con la ganancia entrópica porque las escalas difieren, pero ambos criterios suelen ordenar de manera parecida las divisiones.

Entropía penaliza con algo más de intensidad los cambios cerca de probabilidades extremas; Gini evita logaritmos y es computacionalmente simple. En la práctica, la elección entre ambos suele importar menos que profundidad, tamaño mínimo de hoja, calidad de atributos y validación. Si cambiar Gini por entropía transforma radicalmente el desempeño, conviene examinar inestabilidad, tamaño muestral y reglas seleccionadas, no declarar automáticamente superior a uno.

La llamada *importancia Gini* de un atributo suma las reducciones ponderadas de impureza obtenidas por sus divisiones. No debe confundirse con el índice de una sola región ni con la importancia por permutación. Está sesgada hacia variables continuas o con muchos cortes posibles y puede repartir o concentrar importancia arbitrariamente entre predictores correlacionados. Es una descripción interna del árbol, no evidencia de que intervenir sobre ese atributo cambie el resultado.

12.1.4. Árboles de clasificación y regresión

Los árboles de clasificación optimizan pureza y producen clases o probabilidades. Si el costo de confundir una pieza crítica con una conforme es mayor que el error inverso, puede introducirse una matriz de costos o decidir con probabilidades y umbrales posteriores. La clase mayoritaria no siempre representa la acción óptima. Para costos $C(a, k)$, la acción recomendada en una hoja es

$$a^* = \arg \min_a \sum_k C(a, k) \hat{p}(k | R_m).$$

Los árboles de regresión suelen elegir la división que minimiza la suma de errores cuadrados:

$$(j^*, s^*) = \arg \min_{j, s} \left[\sum_{i: x_i \in R_{\text{izq}}} (y_i - \bar{y}_{\text{izq}})^2 + \sum_{i: x_i \in R_{\text{der}}} (y_i - \bar{y}_{\text{der}})^2 \right].$$

La reducción equivale a la variabilidad del padre menos la variabilidad ponderada de las hijas. Con pérdida absoluta, la constante óptima sería la mediana; con una pérdida de cuantiles pueden estimarse percentiles condicionales útiles para inventarios de energía o tiempos de viaje.

Considérese la duración de una operación industrial: para temperaturas menores o iguales a 70 grados, los tiempos son 8, 9 y 10 minutos; por encima, 14, 15 y 16. Sin división, la media es 12 y la suma de cuadrados es 46. Con el corte, las medias son 9 y 15, y la suma residual es 4. La reducción de 42 justifica la partición en la muestra. Aun así, el salto exacto en 70 puede ser un artefacto; un fenómeno físico suave se aproxima mediante escalones.

Las ventajas comunes son: captura automática de interacciones, invariancia ante transformaciones monótonas del orden de una variable y poca necesidad de escalado. Las limitaciones incluyen discontinuidad, baja precisión para relaciones suaves, mala extrapolación e inestabilidad. En clasificación con fuerte desbalance, la exactitud y la pureza pueden ocultar una sensibilidad insuficiente; deben revisarse métricas por clase, calibración y costos.

12.1.5. Profundidad y complejidad

Un árbol profundo tiene baja restricción estructural: puede aislar observaciones y alcanzar error de entrenamiento casi nulo. Esa capacidad reduce sesgo, pero aumenta varianza. Un árbol poco profundo es más estable e interpretable, aunque puede omitir interacciones relevantes. La profundidad máxima, el mínimo de observaciones para dividir, el mínimo por hoja, la reducción mínima de impureza y el máximo de hojas son formas de *pre-poda*.

La complejidad efectiva no depende solo de la profundidad. Un árbol binario completo de profundidad d puede tener hasta 2^d hojas, pero uno desbalanceado puede tener muchas menos. Hojas con pocos casos ofrecen medias o proporciones de alta varianza. Si una hoja binaria contiene n_m observaciones y la probabilidad estimada es $\hat{p}_m$, su error estándar aproximado es $\sqrt{\hat{p}_m(1 - \hat{p}_m)/n_m}$; una predicción de 0.9 basada en diez casos es mucho menos precisa que la misma proporción basada en mil.

Las curvas de aprendizaje ayudan a diagnosticar. Error bajo en entrenamiento y alto en validación sugiere exceso de complejidad; errores altos y cercanos sugieren sesgo, variables insuficientes o señal débil. Debe observarse el desempeño medio y su dispersión entre particiones. Una profundidad elegida por una única división entrenamiento/prueba puede responder al azar de esa división.

La selección correcta anida el ajuste dentro de validación: para cada pliegue se construyen todas las transformaciones usando solo el entrenamiento, se ajustan complejidades candidatas y se evalúa en datos no vistos. Si se exploran muchas configuraciones y se reporta la mejor sobre el mismo conjunto de prueba, ese conjunto deja de ser una evaluación independiente. En datos temporales o agrupados por planta, conductor o cliente, los pliegues deben respetar la estructura para evitar que observaciones relacionadas aparezcan a ambos lados.

12.1.6. Poda

La poda posterior permite crecer un árbol amplio y retirar ramas cuya contribución no compensa su complejidad. En la poda por costo-complejidad se define, para un

subárbol T ,

$$R_{\alpha}(T) = R(T) + \alpha|T|,$$

donde $R(T)$ es el error o impureza total de las hojas, $|T|$ su número de hojas y $\alpha \geq 0$ el precio de cada región terminal. Cuando $\alpha = 0$ se favorece el ajuste; al aumentarlo, estructuras más pequeñas pueden minimizar el objetivo.

Para un nodo interno t , sea T_t la rama que nace en él. Comparar reemplazar toda la rama por una hoja conduce al valor

$$g(t) = \frac{R(t) - R(T_t)}{|T_t| - 1}.$$

Este cociente es el aumento de error por hoja eliminada. La estrategia de *enlace más débil* poda primero el nodo con menor $g(t)$ y genera una secuencia anidada de subárboles. Validación cruzada selecciona α . La regla de un error estándar puede preferir el árbol más simple cuyo error esté a una desviación estándar del mínimo, favoreciendo estabilidad e interpretación.

Pseudocódigo: poda costo-complejidad

```

PODAR(árbol grande T, datos de validación):
    secuencia <- [T]
    mientras T tenga nodos internos:
        calcular g(t) para cada nodo interno
        eliminar la rama con menor g(t), reemplazándola por una hoja
        agregar el nuevo T a secuencia
    evaluar cada subárbol con validación apropiada
    elegir el subárbol según error, incertidumbre y simplicidad
    devolver subárbol elegido

```

La poda no repara fuga de información, etiquetas defectuosas ni una partición de evaluación inadecuada. Tampoco garantiza que reglas cercanas al nodo raíz sean estables. Conviene repetir el ajuste en remuestras y registrar con qué frecuencia aparecen atributos y umbrales similares. Si la finalidad es comunicar reglas operativas, una pequeña pérdida predictiva puede ser aceptable; esa decisión debe explicitarse, no ocultarse bajo una métrica agregada.

12.1.7. Interpretación de reglas

Cada camino desde la raíz hasta una hoja es una conjunción de condiciones. Por ejemplo:

Si vibración RMS > 4.2, temperatura > 78 y antigüedad del componente > 18 meses, entonces riesgo estimado de defecto crítico = 0.73.

La regla describe una región de asociación predictiva. No afirma que elevar la temperatura cause el defecto, porque temperatura puede representar carga, turno o tipo de máquina. Para interpretar responsablemente una hoja deben comunicarse la predicción, el número de casos, la distribución de clases, el periodo de referencia y el comportamiento en validación. Un porcentaje sin denominador induce falsa precisión.

Las reglas también requieren verificar cobertura y consistencia. Cobertura es la proporción de observaciones que cumple la regla; precisión o confianza es la proporción de resultados objetivo dentro de ella. Una regla con 100% de precisión y 0.1% de cobertura puede ser irrelevante o espuria. Dos hojas pueden recomendar la misma acción y simplificarse conceptualmente, aunque el árbol las mantenga separadas.

Los umbrales son sensibles a medición. Una diferencia entre 4.19 y 4.21 no necesariamente justifica acciones opuestas si el sensor tiene error de ± 0.1 . Deben realizarse análisis de sensibilidad alrededor de cortes, revisar muestras próximas y, cuando proceda, definir una zona de abstención. Restricciones monotónicas o revisión experta pueden ser necesarias si las reglas contradicen conocimiento físico, pero nunca deben imponerse para maquillar datos problemáticos.

Una lectura disciplinada sigue cuatro preguntas: ¿qué población llega a la hoja?, ¿qué evidencia sostiene la estimación?, ¿se reproduce fuera de muestra?, ¿qué decisión y costo están asociados? La legibilidad de un árbol pequeño es una propiedad de representación; no equivale automáticamente a transparencia del sistema completo, que incluye selección de datos, variables, umbrales y procedimientos de actualización.

12.1.8. Ejemplo práctico guiado: árbol para priorización de incidentes

Una empresa manufacturera debe priorizar incidentes de maquinaria para inspección en las próximas dos horas. La unidad de análisis es un incidente registrado; la etiqueta vale 1 si, después de una revisión independiente, se confirmó riesgo de parada crítica. Se dispone de vibración, temperatura, variación de corriente, edad del componente, tipo de máquina y carga. El costo de omitir un incidente crítico supera al de inspeccionar uno no crítico.

Paso 1: contrato y partición. Se fija como tiempo de predicción el instante de alerta. Se excluyen variables creadas después de la inspección, como código final de avería. Se separan periodos: meses anteriores para desarrollo y un mes posterior para prueba. Incidentes de una misma secuencia operativa no se reparten entre pliegues. Se comparará contra reglas actuales y contra un clasificador que siempre predice la prevalencia.

Paso 2: crecimiento. En un nodo con 200 incidentes, 50 críticos, $G = 2(0.25)(0.75) = 0.375$. Un corte de vibración produce una hija alta con 60 casos y 36 críticos, $G_A = 0.48$, y una baja con 140 casos y 14 críticos, $G_B = 0.18$. La impureza posterior es $0.3(0.48) + 0.7(0.18) = 0.27$ y la reducción, 0.105. Aunque la rama alta no es pura, concentra riesgo y mejora la decisión.

Paso 3: control y poda. Se crece una secuencia de árboles restringiendo hojas diminutas. Validación temporal compara sensibilidad, precisión, área precisión-recall, costo esperado y calibración. El árbol de mínimo error tiene 18 hojas; otro de 9 queda dentro de un error estándar y muestra menor variabilidad entre meses. Se elige este último si satisface la sensibilidad mínima.

Paso 4: decisión. Las probabilidades no se convierten automáticamente en prioridad. Para costo de falso negativo C_{FN} y falso positivo C_{FP} , con costos constantes, el umbral teórico es $C_{FP}/(C_{FP} + C_{FN})$, sujeto a capacidad de inspección y calibración. Si solo pueden atenderse 20 alertas por turno, también

se evalúa precisión entre las 20 primeras.

Paso 5: diagnóstico. Se revisan hojas por planta y tipo de máquina, estabilidad de umbrales, errores cerca de cortes y deriva mensual. Si temperatura domina pero su sensor cambió, el aparente progreso puede no ser transportable. Se documentan falsos negativos críticos y condiciones de abstención ante valores fuera de rango.

El resultado no es solo un diagrama: es un árbol podado, un umbral operativo, intervalos de desempeño, reglas de monitoreo y un registro de limitaciones. La claridad se evalúa junto con generalización, no en sustitución de ella.

12.2. Máquinas de soporte vectorial

Las máquinas de soporte vectorial (SVM) construyen fronteras usando geometría y regularización. En su forma lineal buscan un hiperplano que separe clases con el mayor margen posible. En su forma kernel representan fronteras no lineales mediante productos internos en un espacio de características, sin calcular explícitamente todas sus coordenadas. Son especialmente útiles en espacios de dimensión alta y muestras medianas, pero exigen escalado, selección cuidadosa de hiperparámetros y atención al costo computacional.

12.2.1. Hiperplanos y fronteras de decisión

Para clasificación binaria se codifica $y_i \in \{-1, +1\}$. Un hiperplano es el conjunto

$$\{x : w^T x + b = 0\},$$

donde w es normal a la superficie y b desplaza la frontera. La función de decisión es $f(x) = w^T x + b$ y la clase predicha, $\text{sign}(f(x))$. La magnitud de f no es una probabilidad: es una puntuación cuya escala depende de w .

La distancia perpendicular de un punto x al hiperplano se deriva proyectando sobre el vector normal:

$$d(x, H) = \frac{|w^T x + b|}{\|w\|_2}.$$

Si $y_i(w^T x_i + b) > 0$, el punto está correctamente clasificado. El *margen funcional* $y_i f(x_i)$ cambia si w y b se multiplican por una constante; el *margen geométrico* $y_i f(x_i)/\|w\|$ no cambia. Esta distinción permite fijar una escala conveniente al formular la optimización.

En dos dimensiones, el hiperplano es una recta; en tres, un plano; en p dimensiones conserva la misma definición. Muchas fronteras pueden separar perfectamente una muestra. Una que pase muy cerca de observaciones es vulnerable a pequeñas perturbaciones. SVM selecciona la de mayor separación geométrica bajo una penalización determinada.

Para más de dos clases suelen combinarse clasificadores binarios: uno contra el resto entrena K modelos; uno contra uno entrena $K(K - 1)/2$ y agrega votos o puntuaciones. La evaluación debe incluir confusiones por clase. Un esquema multiclase puede tener buen promedio y fallar sistemáticamente en una categoría minoritaria de reclamaciones.

12.2.2. Margen máximo

Si los datos son linealmente separables, puede elegirse la escala de modo que los puntos más cercanos satisfagan $y_i(w^T x_i + b) = 1$. Los planos de soporte son $w^T x + b = 1$ y $w^T x + b = -1$; la distancia entre ellos es $2/\|w\|$. Maximizarla equivale a minimizar $\|w\|^2/2$:

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 \quad \text{sujeto a} \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n.$$

Es un problema convexo: cualquier óptimo local es global. La norma actúa como regularizador, pues una norma pequeña produce una función menos sensible a perturbaciones. Sin embargo, separabilidad perfecta puede deberse a alta dimensión, error de medición o fuga, no a una estructura generalizable.

La formulación dual introduce multiplicadores $\alpha_i \geq 0$ y conduce a

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j x_i^T x_j,$$

sujeto a $\sum_i \alpha_i y_i = 0$. La solución cumple $w = \sum_i \alpha_i y_i x_i$. Por tanto, los datos aparecen solo mediante productos internos y los puntos con $\alpha_i > 0$ determinan la frontera. Esta propiedad dará lugar al truco kernel.

El margen máximo no optimiza directamente exactitud, AUC o costo comercial. Optimiza una función sustituta con propiedades matemáticas favorables. Si los errores tienen costos asimétricos, pueden usarse penalizaciones de clase o ajustar el umbral de la puntuación en validación. Además, para reportar probabilidades se necesita calibración posterior con datos que no hayan sido utilizados para ajustar la frontera.

12.2.3. Vectores de soporte

Los vectores de soporte son observaciones con multiplicadores duales positivos. En el caso separable y en posición general se encuentran sobre los planos del margen. Los puntos alejados de la frontera tienen $\alpha_i = 0$ y no modifican la solución mientras permanezcan correctamente ubicados. La predicción puede escribirse como

$$f(x) = \sum_{i \in SV} \alpha_i y_i x_i^T x + b.$$

Esto muestra que SVM es una expansión basada en ejemplos críticos. No significa que todos esos ejemplos sean prototipos típicos: suelen ser precisamente los más ambiguos. Una alta proporción de vectores de soporte puede indicar solapamiento, ruido, regularización fuerte o una representación inadecuada. También aumenta el costo de predicción en modelos kernel, porque debe evaluarse la similitud con cada soporte.

Las condiciones de Karush-Kuhn-Tucker conectan geometría y optimización. En margen duro, la complementariedad exige

$$\alpha_i [y_i(w^T x_i + b) - 1] = 0.$$

Si una restricción es estricta, el multiplicador es cero; si influye, la observación toca el margen. En margen blando aparecen casos dentro del margen o mal clasificados con multiplicadores limitados por C .

Un diagnóstico útil consiste en revisar qué tipos de observaciones se convierten repetidamente en soporte a través de pliegues. Si predominan registros duplicados, errores de etiqueta o una planta con sensores descalibrados, la frontera puede estar modelando problemas de calidad. Eliminar puntos solo porque son soportes sería incorrecto: debe investigarse su procedencia. La robustez se comprueba perturbando mediciones dentro de tolerancias plausibles y reentrenando, no interpretando la lista como anomalías automáticas.

12.2.4. Margen blando

Los datos reales rara vez son separables sin errores. El margen blando incorpora variables de holgura $\xi_i \geq 0$:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i, \quad y_i(w^T x_i + b) \geq 1 - \xi_i.$$

Si $\xi_i = 0$, el punto está fuera o sobre el margen correcto; si $0 < \xi_i \leq 1$, está bien clasificado pero dentro del margen; si $\xi_i > 1$, está mal clasificado. Para w, b fijos, la menor holgura es $\max(0, 1 - y_i f(x_i))$. Sustituyendo se obtiene la pérdida bisagra:

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y_i f(x_i)).$$

La pérdida es cero solo cuando el margen funcional alcanza uno; por ello no solo penaliza errores, sino también aciertos demasiado próximos a la frontera. Frente a la pérdida 0-1, es convexa y optimizable.

C controla el compromiso. Un C grande castiga fuertemente violaciones, tiende a un margen estrecho y puede ajustarse al ruido. Un C pequeño tolera violaciones, ensancha el margen y aumenta regularización. La escala depende de la convención: algunas formulaciones promedian la pérdida y usan un parámetro inverso. Debe interpretarse la definición concreta, no memorizar que un número tiene igual efecto en todo sistema.

Con desbalance, asignar el mismo costo a todos los ejemplos puede favorecer la clase mayoritaria. Una extensión usa C_i por clase u observación. Esto modifica el objetivo, pero no reemplaza la evaluación con precisión-recall, sensibilidad, especificidad, calibración y costo esperado. Una ponderación estimada usando la prueba constituye fuga; debe fijarse con entrenamiento y conocimiento operativo.

12.2.5. Funciones kernel

Una transformación $\phi(x)$ puede convertir una relación no lineal en lineal en un espacio de características. El dual requiere solo productos $\phi(x_i)^T \phi(x_j)$. Un kernel válido calcula

$$K(x, z) = \langle \phi(x), \phi(z) \rangle$$

sin construir explícitamente ϕ . La función de decisión pasa a ser

$$f(x) = \sum_{i \in SV} \alpha_i y_i K(x_i, x) + b.$$

Kernels frecuentes son:

$$K_{\text{lineal}}(x, z) = x^T z,$$

$$K_{\text{polinómico}}(x, z) = (\gamma x^T z + r)^d,$$

$$K_{\text{RBF}}(x, z) = \exp(-\gamma \|x - z\|^2).$$

El kernel lineal es apropiado cuando la dimensión es alta o se busca una referencia simple. El polinómico representa interacciones hasta cierto grado, pero puede ser sensible a escala y parámetros. RBF mide similitud local: con γ pequeño, la influencia de cada punto se extiende ampliamente y la frontera es suave; con γ grande, la influencia es estrecha y la frontera puede formar islas alrededor de observaciones.

No toda función de similitud es un kernel admisible. Una condición fundamental es que la matriz de Gram $K_{ij} = K(x_i, x_j)$ sea semidefinida positiva para cualquier conjunto finito, lo que preserva la interpretación como producto interno y la convexidad. En aplicaciones especializadas pueden definirse kernels para secuencias o grafos, siempre justificando sus propiedades.

El truco kernel no hace gratuita la alta dimensión. La matriz de Gram ocupa orden n^2 y entrenar puede ser costoso. Asimismo, una frontera flexible no garantiza que existan datos cercanos a cada predicción. Deben identificarse casos fuera del soporte de entrenamiento y evitar extrapolaciones confiadas.

12.2.6. Parámetros de regularización y kernel

En una SVM RBF, C y γ interactúan. C grande y γ grande permiten fronteras muy irregulares: bajo error de entrenamiento, muchos bolsillos locales y alta varianza. C pequeño y γ pequeño pueden producir subajuste. No es correcto ajustar uno y congelarlo antes de explorar el otro sin comprobar interacción.

La búsqueda suele realizarse en escala logarítmica porque cambios multiplicativos son más informativos: por ejemplo, una malla conceptual de $C \in \{10^{-3}, \dots, 10^3\}$ y $\gamma \in \{10^{-4}, \dots, 10^2\}$. Los valores concretos dependen del escalado y tamaño. Una búsqueda aleatoria puede cubrir mejor espacios amplios; una estrategia sucesiva asigna más presupuesto a candidatos prometedores. Cualquier estrategia debe vivir dentro de los pliegues de validación.

El mapa de desempeño medio y dispersión es más útil que una única combinación ganadora. Una meseta amplia indica robustez; un pico estrecho puede ser selección por ruido. Si varios candidatos son estadísticamente indistinguibles, se prefiere menor complejidad, menor costo o mejor estabilidad. Para clasificación financiera temporal, los pliegues deben simular meses futuros y no barajar indiscriminadamente transacciones.

La calibración es otro hiperproceso. Puntuaciones SVM pueden transformarse en probabilidades con una función logística o un ajuste isotónico. El calibrador debe entrenarse sobre predicciones fuera de muestra o un subconjunto separado; ajustarlo sobre las mismas puntuaciones con las que se entrenó SVM produce optimismo. Se evalúan Brier, pérdida logarítmica y diagramas de confiabilidad, además de discriminación.

Finalmente, el umbral es una decisión, no un hiperparámetro geométrico. Puede cambiarse según costos o capacidad sin reentrenar la SVM, siempre que se valide. Mezclar selección de C , calibración y umbral sobre un único conjunto pequeño aumenta sobreajuste de selección.

12.2.7. Escalado y costo computacional

SVM se basa en productos y distancias. Si un atributo energético varía entre 0 y 100 000 y una proporción entre 0 y 1, el primero dominará $\|x - z\|^2$ aunque no sea más relevante. La estandarización $z_j = (x_j - \mu_j)/\sigma_j$ o un escalado robusto son pasos esenciales. Los parámetros se estiman solo con el pliegue de entrenamiento y luego se aplican a validación; calcularlos con todos los datos filtra información.

Variables categóricas codificadas generan otra geometría. Una codificación ordinal impone distancias quizá inexistentes; una codificación indicadora aumenta dimensión. Atributos ausentes e indicadores de ausencia deben tratarse dentro del mismo flujo. Outliers pueden distorsionar media y desviación; el escalado robusto y la investigación de calidad son alternativas, no la eliminación automática.

En SVM kernel, almacenar la matriz de similitudes requiere $O(n^2)$ memoria y la optimización puede acercarse a costos entre cuadráticos y cúbicos según datos y solucionador. La predicción cuesta aproximadamente $O(|SV|p)$ para RBF. Para millones de observaciones pueden ser preferibles SVM lineales, aproximaciones de kernel, muestreo cuidadosamente diseñado o ensambles escalables. Entrenar sobre una muestra sesgada para ahorrar costo altera el problema.

Los diagnósticos incluyen tiempo y memoria por pliegue, número y proporción de soportes, sensibilidad a escalado, estabilidad de métricas y latencia de predicción. También debe comprobarse el rango: RBF tiende a puntuaciones determinadas por similitudes pequeñas ante puntos muy lejanos. Un detector de novedad o una política de abstención puede ser necesario.

La comparación de costo debe ser integral: preparación, búsqueda, calibración, inferencia y mantenimiento. Un modelo que mejora mínimamente AUC pero multiplica latencia y dificulta actualización puede no ser la mejor decisión de ingeniería.

12.2.8. Ejemplo práctico guiado: clasificación no lineal con SVM

Una entidad financiera estudia reclamaciones de transacciones para decidir cuáles requieren revisión especializada. La etiqueta indica fraude confirmado, y los atributos disponibles al decidir incluyen importe normalizado respecto del historial, desviación geográfica, hora, velocidad de transacciones recientes y antigüedad de la cuenta. No se usa el resultado posterior de investigación.

Hipótesis geométrica. El riesgo puede aumentar cuando coinciden importe atípico y alta velocidad, pero no con cualquiera por separado. Una frontera lineal

sirve como referencia; una RBF puede capturar esa interacción local. Se reserva el trimestre más reciente como prueba y se valida por bloques temporales.

Preparación. En cada pliegue se imputan valores, codifican categorías y escalan atributos usando solo el pasado. La búsqueda conjunta explora kernel lineal y RBF, C y γ . Se registran área precisión-recall, sensibilidad a capacidad fija de revisión, costo, calibración, proporción de soportes y tiempo.

Supóngase que los resultados medios son:

Modelo	PR-AUC	Sensibilidad en 200 revisiones	Soportes	Observación
Lineal, $C = 0.1$	0.41	0.62	38%	estable
RBF, $C = 10$, $\gamma = 0.5$	0.49	0.71	44%	meseta robusta
RBF, $C = 1000$, $\gamma = 20$	0.55 entrenamiento / 0.38 validación	0.54	81%	sobreajuste

El tercer modelo ilustra que una frontera visualmente detallada y un excelente ajuste interno no implican generalización. Se selecciona el segundo si mantiene su ventaja en la prueba temporal y su latencia es admisible. Después se calibra con predicciones fuera de pliegue y se determina un umbral acorde con la capacidad diaria.

Análisis de fallos. Se examinan falsos negativos por tipo de comercio y antigüedad, casos cercanos al umbral, registros fuera del rango histórico y deriva. Si el desempeño cae tras una campaña comercial, quizá cambió la población y no el algoritmo. Una auditoría comprueba que ningún atributo sea una consecuencia del proceso de investigación.

Conclusión. Comparar kernels implica más que escoger la métrica máxima: exige un baseline lineal, validación temporal, mapa de hiperparámetros, calibración y costo computacional. La SVM RBF se adopta solo si la mejora no lineal persiste bajo ese protocolo.

12.3. Métodos de ensamble

Un ensamble combina modelos base para obtener una predicción más precisa o estable. La mejora surge cuando los componentes cometen errores no perfectamente correlacionados y el mecanismo de combinación aprovecha esa diversidad. Bagging reduce varianza mediante paralelismo y remuestreo; Random Forest añade aleatoriedad de atributos; boosting construye modelos secuenciales que corrigen errores; stacking aprende cómo combinar modelos heterogéneos.

12.3.1. Combinación de modelos

Sean $\hat{f}_1(x), \dots, \hat{f}_B(x)$ predictores. En regresión, un promedio simple es

$$\bar{f}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x).$$

Si cada estimador tiene varianza σ^2 y correlación de error común ρ , entonces

$$\text{Var}(\bar{f}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Al crecer B , desaparece el componente no correlacionado, pero permanece $\rho\sigma^2$. La diversidad es por ello tan importante como la calidad individual. Promediar copias casi idénticas aporta poco.

En clasificación pueden promediarse probabilidades o votar clases. Promediar probabilidades conserva información para ajustar umbrales, pero exige verificar calibración. El voto mayoritario puede ocultar que tres modelos tienen confianza apenas superior a 0.5. Con pesos $w_b \geq 0$, $\sum_b w_b = 1$, se obtiene $\hat{p} = \sum_b w_b \hat{p}_b$; estimar pesos sobre prueba causaría optimismo.

La descomposición sesgo-varianza explica parte del comportamiento. Bagging suele mantener sesgo y reducir varianza; boosting puede reducir ambos, aunque se vuelve sensible a hiperparámetros, ruido y pérdida. Ningún ensamble garantiza mejora: modelos base sesgados en la misma dirección pueden reforzarse; una fuga compartida produce una combinación convincentemente incorrecta.

La comparación justa requiere idéntica definición de objetivo, atributos disponibles, divisiones, métricas y presupuesto de búsqueda. También debe incluir un baseline simple. Si un ensamble gana solo porque recibió más ingeniería o más oportunidades de ajuste, no se ha aislado el valor del método.

12.3.2. Bagging

Bootstrap aggregating genera B muestras bootstrap de tamaño n mediante selección con reemplazo, ajusta un modelo en cada una y agrega predicciones. La probabilidad de que una observación no aparezca en una remuestra es $(1 - 1/n)^n \approx e^{-1} \approx 0.368$. Así, cada modelo utiliza alrededor de 63.2% de observaciones únicas y deja otras *out-of-bag* (OOB).

Pseudocódigo: bagging

```
BAGGING(D, B, algoritmo_base):
    modelos <- lista vacía
    para b = 1 hasta B:
        D_b <- muestra con reemplazo de D, de tamaño |D|
        modelo_b <- ajustar algoritmo_base sobre D_b
        agregar modelo_b a modelos
    para predecir x:
        agregar las B predicciones por media o voto
```

Para estimar error OOB, cada observación se predice solo con modelos que no la incluyeron. Esto ofrece una evaluación interna eficiente y permite estudiar convergencia al aumentar B . No reemplaza una prueba externa cuando existen tiempo, grupos, deriva o múltiples decisiones de diseño. El bootstrap ordinario

rompe dependencias temporales y puede ser inadecuado para series o eventos agrupados.

Bagging funciona especialmente bien con aprendices de alta varianza, como árboles profundos. Aumentar B no suele causar sobreajuste clásico por sí solo: el promedio converge, aunque costo y memoria crecen. El beneficio se estabiliza, por lo que debe observarse la curva OOB frente al número de modelos.

Si las muestras son muy similares y un predictor fuerte domina siempre el árbol, los modelos permanecen correlacionados. Random Forest aborda este problema restringiendo candidatos por nodo. En datos desbalanceados pueden diseñarse remuestras estratificadas, pero alterar prevalencias afecta probabilidades; se requiere corrección o calibración sobre la distribución objetivo.

12.3.3. Random Forest

Random Forest combina bootstrap con selección aleatoria de atributos. En cada nodo se considera un subconjunto de m_{try} variables en lugar de las p disponibles. Un predictor dominante no puede participar en todas las divisiones, lo que aumenta diversidad entre árboles y puede reducir la correlación del ensamble.

Pseudocódigo: Random Forest

```
BOSQUE_ALEATORIO(D, B, m_try):
  para b = 1 hasta B:
    D_b <- remuestra bootstrap de D
    crecer un árbol amplio sobre D_b:
      en cada nodo seleccionar al azar m_try atributos
      elegir la mejor división solo entre esos atributos
      continuar hasta cumplir restricciones de hoja
  agregar predicciones de todos los árboles
```

m_{try} pequeño aumenta diversidad pero puede elevar sesgo; grande aproxima bagging de árboles. El mínimo de hoja controla suavidad: hojas mayores estabilizan probabilidades y regresión. El número de árboles se aumenta hasta que error y métricas se estabilicen. La profundidad, remuestreo y pesos de clase completan el ajuste.

La predicción OOB permite error e importancia por permutación sin un conjunto adicional, bajo supuestos de independencia. Aun así, datos agrupados requieren remuestreo por grupo. La importancia por disminución de impureza favorece atributos con numerosos cortes. La permutación es preferible para medir dependencia predictiva, aunque también se complica con correlación.

Random Forest es robusto y suele ser un baseline tabular fuerte: modela interacciones, requiere poco preprocesamiento geométrico y paraleliza. Sus desventajas son tamaño, latencia, menor interpretabilidad directa y escasa extrapolación. En regresión energética, una predicción forestal es un promedio de valores de hojas observados; no prolongará automáticamente una tendencia física fuera del rango.

Un bosque no corrige etiquetas contaminadas ni cambio de concepto. Si el OOB es excelente pero la prueba futura falla, deben investigarse estructura temporal, variables posteriores al evento y deriva antes de ajustar más árboles.

12.3.4. Boosting

Boosting construye una suma secuencial de aprendices débiles. En AdaBoost binario, cada observación tiene un peso w_i . Al inicio son iguales. En la iteración m se ajusta un clasificador $h_m(x) \in \{-1, +1\}$, se calcula su error ponderado

$$e_m = \frac{\sum_i w_i \mathbf{1}[y_i \neq h_m(x_i)]}{\sum_i w_i},$$

y se asigna

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}.$$

Los pesos se actualizan como $w_i \leftarrow w_i \exp[-\alpha_m y_i h_m(x_i)]$ y se normalizan. Casos mal clasificados aumentan peso. La predicción final es $\text{sign}(\sum_m \alpha_m h_m(x))$.

Pseudocódigo: boosting adaptativo

```

inicializar pesos uniformes sobre observaciones
para m = 1 hasta M:
    ajustar aprendiz débil h_m usando los pesos actuales
    calcular error ponderado e_m
    si h_m no supera el azar, detener o revisar
    calcular peso del modelo alpha_m
    aumentar peso de errores y reducir peso de aciertos
    normalizar pesos
devolver suma ponderada de aprendices
  
```

AdaBoost puede verse como minimización progresiva de pérdida exponencial $\sum_i \exp[-y_i F(x_i)]$. Esta pérdida enfatiza observaciones con margen negativo. La concentración ayuda a corregir casos difíciles, pero también puede perseguir etiquetas erróneas y outliers. Diagnosticar qué registros acumulan peso es esencial.

Los aprendices suelen ser árboles pequeños. Tocones de una división representan efectos aditivos; profundidades mayores permiten interacciones. El número de iteraciones y complejidad base regulan capacidad. A diferencia de bagging, los modelos no son independientes y no se entrenan todos en paralelo. Boosting también puede operar con pérdidas distintas mediante Gradient Boosting.

12.3.5. Gradient Boosting

Gradient Boosting construye una función aditiva

$$F_M(x) = F_0(x) + \sum_{m=1}^M \nu \rho_m h_m(x),$$

donde h_m suele ser un árbol, ρ_m un tamaño de paso y $0 < \nu \leq 1$ la tasa de aprendizaje. La idea es descenso de gradiente en el espacio de funciones. En la iteración m se calculan los seudoresiduos

$$r_{im} = - \left. \frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right|_{F=F_{m-1}},$$

se ajusta h_m para predecirlos y se actualiza F .

Con pérdida cuadrática, $L = (y - F)^2/2$, el gradiente negativo es $y_i - F(x_i)$: residuos ordinarios. Para clasificación logística, los residuos se relacionan con $y_i - p_i$, de modo que cada etapa corrige discrepancias probabilísticas.

Pseudocódigo: Gradient Boosting

```
elegir F_0 que minimice la pérdida constante
para m = 1 hasta M:
    calcular gradiente negativo de la pérdida para cada caso
    ajustar árbol h_m a esos seudoresiduos
    encontrar tamaño de paso rho_m, si corresponde
    F_m <- F_(m-1) + tasa_aprendizaje * rho_m * h_m
devolver F_M
```

Una tasa pequeña suele requerir más árboles y puede generalizar mejor. Profundidad controla orden de interacción; submuestrear filas o columnas introduce aleatoriedad y regularización. Restricciones L1/L2, mínimo de hoja y penalización de nuevas divisiones son comunes en implementaciones optimizadas, pero el principio sigue siendo minimizar una pérdida regularizada de forma secuencial.

El monitoreo de pérdida de validación frente a iteraciones permite parada temprana. La iteración de parada debe decidirse sin mirar prueba. Fallos frecuentes son árboles demasiado profundos, búsqueda extensa sobre un único pliegue, probabilidades no calibradas, categorías codificadas con información futura y optimización de una métrica desconectada del costo. En ruido de etiquetas, pérdidas robustas o revisión de datos pueden ser más valiosas que más iteraciones.

12.3.6. Stacking

Stacking aprende un metamodelo que combina predicciones de modelos base heterogéneos. Si $f_1, \dots, f_L$ son modelos de nivel 0, el nivel 1 recibe $z_i = (\hat{f}_1(x_i), \dots, \hat{f}_L(x_i))$ y aprende $g(z_i)$. La predicción final es $g(f_1(x), \dots, f_L(x))$.

El riesgo central es fuga. Si z_i se genera con un modelo entrenado usando (x_i, y_i) , el metamodelo ve predicciones demasiado optimistas. Deben usarse predicciones *out-of-fold* (OOF): cada fila es predicha por un modelo que no la vio.

Pseudocódigo: stacking sin fuga

```
dividir desarrollo en K pliegues
para cada modelo base l:
    para cada pliegue k:
        ajustar modelo l con los otros K-1 pliegues
        predecir el pliegue k y guardar predicciones OOF
ajustar metamodelo g con todas las predicciones OOF y etiquetas
reajustar cada modelo base sobre todo desarrollo
para un caso nuevo:
```

obtener predicciones de los modelos reajustados
 pasarlas al metamodelo g

Un metamodelo lineal regularizado es a menudo suficiente y fácil de auditar. Pesos no negativos y suma uno pueden reducir extrapolaciones. Un metamodelo muy flexible puede sobreajustar un conjunto OOF pequeño. Añadir atributos originales al nivel 1 aumenta capacidad y riesgo.

La diversidad debe ser real: combinar cinco configuraciones casi idénticas de boosting quizá aporte menos que combinar modelo lineal, bosque y SVM con errores complementarios. Se estudian correlaciones de residuos y rendimiento por subgrupo. Stacking puede aprender a ignorar un modelo, lo cual no es un fallo.

La evaluación externa repite el proceso completo. Preprocesamiento, calibración y ajuste de cada base ocurren dentro de sus pliegues. Este costo hace que stacking solo se justifique si la mejora es estable y operativamente relevante. También complica despliegue: todos los modelos, versiones y latencias pasan a ser dependencias.

12.3.7. Ajuste de hiperparámetros

Los ensambles poseen hiperparámetros interdependientes. En Random Forest destacan número de árboles, m_{try} , profundidad y mínimo de hoja. En boosting: iteraciones, tasa de aprendizaje, profundidad, submuestreo y regularización. En stacking: integrantes, generación OOF y complejidad del metamodelo. Ajustarlos sin un protocolo predefinido produce una competencia de sobreajuste.

Un proceso recomendable es:

1. Definir unidad, horizonte, métrica primaria, métricas de seguridad y presupuesto.
2. Reservar una prueba final que reproduzca despliegue.
3. Construir un baseline simple y una configuración razonable por familia.
4. Realizar búsqueda dentro de validación, con transformaciones internas a cada pliegue.
5. Comparar media, dispersión, costo y curvas de aprendizaje, no solo el máximo.
6. Seleccionar la configuración más simple dentro de una región competitiva.
7. Reajustar con desarrollo completo y evaluar una sola vez en prueba.

La optimización multiobjetivo reconoce que precisión, memoria, latencia, energía, equidad y explicabilidad pueden competir. El frente de Pareto contiene modelos para los que ningún objetivo mejora sin empeorar otro. Elegir en ese frente requiere prioridades institucionales, no una fórmula puramente estadística.

La incertidumbre de la comparación importa. Diferencias pequeñas entre métricas calculadas sobre los mismos casos deben analizarse de forma pareada y con intervalos adecuados. La selección entre cientos de candidatos aumenta el sesgo del ganador. Una validación externa o anidada reduce este efecto.

Diagnósticos esenciales son: brecha entrenamiento-validación, variabilidad entre pliegues y semillas, evolución con número de árboles, calibración, matrices de error por segmento, latencia y sensibilidad a deriva. Si el ranking cambia con cada semilla, no existe evidencia robusta de superioridad.

12.3.8. Ejemplo práctico guiado: competencia controlada de modelos

Una red de movilidad urbana predice si un trayecto programado llegará con más de diez minutos de demora. La decisión se toma 30 minutos antes de la salida y habilita reasignación preventiva. Se comparan un árbol podado, Random Forest y Gradient Boosting. Las variables incluyen franja horaria, zona, duración planificada, congestión reciente disponible y características del vehículo.

Protocolo común. Se usa expansión temporal: entrenar en semanas 1-8 y validar en 9; luego 1-9 y validar en 10, y así sucesivamente. La semana 13 queda como prueba. Todos reciben la misma información al mismo tiempo de corte. Se evalúan PR-AUC, sensibilidad a un máximo de 100 intervenciones diarias, Brier, latencia y estabilidad por zona.

Modelo	PR-AUC validación	Sensibilidad@100	Brier	Latencia relativa
Árbol podado	0.36 ± 0.03	0.51	0.171	1
Random Forest	0.44 ± 0.02	0.63	0.154	7
Gradient Boosting	0.46 ± 0.04	0.65	0.149	4

Boosting tiene mejor media, pero su ventaja sobre el bosque es pequeña y más variable. Se revisan curvas por semana: una caída coincide con un cambio de rutas. El bosque resulta algo más estable en zonas con pocos trayectos. La elección dependerá de si la mejora de dos puntos en sensibilidad compensa la variabilidad y el mantenimiento.

Controles. Se compara contra prevalencia y regla operativa. Las transformaciones se reajustan en cada ventana. Se repiten semillas, se calibran candidatos usando predicciones temporales OOF y el umbral se fija por capacidad. La prueba final se abre después de congelar todo el flujo.

Análisis de errores. Se inspeccionan falsos negativos en eventos especiales, diferencias por zona y vehículos nuevos. Si el modelo usa congestión registrada después del tiempo de decisión, se elimina aunque eleve métricas. Si las zonas periféricas muestran peor sensibilidad por menor cobertura de sensores, se documenta y se considera abstención o inversión en datos.

Una competencia controlada no busca coronar un algoritmo universal. Busca estimar qué sistema satisface mejor el contrato bajo incertidumbre y recursos reales. El árbol conserva valor como referencia interpretable incluso si no se despliega.

12.4. Explicabilidad y aprendizaje distribuido

La explicabilidad estudia cómo describir el comportamiento de modelos y predicciones. Puede ser intrínseca, como las reglas de un árbol pequeño, o posterior al ajuste, como permutación, dependencia parcial y SHAP. Estas herramientas responden preguntas distintas y dependen de una población de referencia. El aprendizaje federado, por su parte, permite colaborar sin centralizar datos brutos, pero introduce heterogeneidad, comunicación y nuevas superficies de riesgo.

12.4.1. Interpretabilidad global y local

La interpretación global pregunta cómo se comporta el modelo en una población: qué variables utiliza, qué formas promedio aprende, qué interacciones existen y dónde falla. La local pregunta por qué produjo una puntuación para un caso concreto. Una tercera escala, la interpretación por cohortes, estudia subpoblaciones como plantas, regiones o periodos. Confundir escalas genera contradicciones aparentes: un atributo puede ser importante globalmente y casi irrelevante para un individuo.

También debe distinguirse entre explicación del modelo y explicación del fenómeno. Una explicación fiel describe $\hat{f}$; no demuestra el mecanismo que genera Y . Si el modelo usa consumo energético nocturno para predecir averías, una atribución alta indica dependencia predictiva bajo los datos observados. No prueba que reducir consumo evite averías. Para afirmaciones causales se necesitan supuestos, diseño e identificación específicos.

Las propiedades deseables incluyen fidelidad, estabilidad, alcance, comprensibilidad y utilidad. Pueden entrar en tensión: una regla local simple es comprensible pero solo aproximada; una descomposición exacta puede depender de una referencia poco intuitiva. La explicación debe acompañarse de predicción, incertidumbre, población de referencia y advertencias.

Un protocolo de interpretación comienza por una pregunta: ¿auditar fuga?, ¿comunicar una decisión?, ¿descubrir fallos?, ¿verificar una restricción física? Luego selecciona herramienta y conjunto de referencia, contrasta más de un método, realiza análisis de sensibilidad y valida con conocimiento del dominio. Una visualización atractiva sin pregunta definida favorece narrativas posteriores.

La interpretabilidad no compensa un modelo inválido. Primero se verifica generalización, calibración, subgrupos y deriva. Después se explica. Una explicación estable de una predicción sistemáticamente errónea sigue siendo un fracaso.

12.4.2. Importancia por permutación

La importancia por permutación mide cuánto empeora una métrica cuando se rompe la asociación entre un atributo y el resultado, manteniendo fijo el modelo. Sobre un conjunto de evaluación D_{eval} , sea $S(D, f)$ una puntuación donde mayor es mejor. Para el atributo j :

$$I_j = S(D_{eval}, f) - S(D_{eval}^{\pi_j}, f),$$

donde D^{π_j} permuta los valores de x_j entre filas. Se repite la permutación para obtener media y dispersión. Si se usa una pérdida donde menor es mejor, se invierte la resta.

Pseudocódigo: importancia por permutación

```

calcular desempeño base del modelo en evaluación
para cada atributo j:
    para r = 1 hasta R:
        copiar evaluación
        permutar solo la columna j

```

calcular deterioro respecto del desempeño base
reportar media e intervalo de los R deterioros

La medición debe hacerse fuera del entrenamiento. Puede calcularse con la métrica operativa y por cohortes. Una importancia cercana a cero significa que permutar esa variable no degrada el modelo en esa población; no significa ausencia de relación real. Una importancia negativa puede aparecer por azar, sobreajuste o porque romper una señal perjudicial mejora desempeño.

La correlación es el principal desafío. Si dos sensores contienen información redundante, permutar uno deja disponible el otro y ambos parecen poco importantes. A la inversa, permutar una variable genera combinaciones irreales, exagerando el deterioro. La permutación condicional intenta reorganizar dentro de grupos similares o según una distribución condicional, pero cambia la pregunta y requiere estimación adicional.

La importancia depende de modelo, datos, métrica y momento. No es un ranking universal ni tiene dirección de efecto. Deben reportarse incertidumbre y grupos correlacionados, contrastarse con ablation o conocimiento experto y evitar frases causales como “el atributo produce el resultado”.

12.4.3. Gráficos de dependencia parcial

La dependencia parcial del atributo X_j se define como

$$PD_j(z) = \mathbb{E}_{X_{-j}}[\hat{f}(z, X_{-j})] \approx \frac{1}{n} \sum_{i=1}^n \hat{f}(z, x_{i,-j}).$$

Para cada valor z , se reemplaza x_{ij} de todas las filas por z , se predice y se promedia. El gráfico muestra el efecto promedio del modelo al variar X_j sobre la distribución marginal de los demás atributos. Para dos atributos puede visualizar interacciones, aunque la superficie es más difícil de estimar e interpretar.

La curva ICE (*individual conditional expectation*) conserva una línea por observación: $ICE_i(z) = \hat{f}(z, x_{i,-j})$. El PDP es su promedio. ICE revela heterogeneidad que el promedio oculta: un efecto creciente en una planta y decreciente en otra puede producir una línea plana. Centrar las curvas facilita comparar formas.

Si X_j está correlacionado con X_{-j} , sustituirlo globalmente crea casos improbables. Por ejemplo, combinar una elevada producción con configuraciones de maquinaria usadas solo a baja producción. Debe marcarse la densidad de datos, restringir el rango, usar perfiles acumulados locales o análisis condicional, y no interpretar regiones sin soporte.

Para clasificación, conviene indicar si se grafica puntuación, logit o probabilidad; el promedio en cada escala difiere. Las curvas no son causales: mantienen matemáticamente fijos atributos que en el mundo podrían cambiar juntos. Tampoco cuantifican importancia; una curva con gran amplitud puede corresponder a una región rara.

Un buen informe incluye distribución del atributo, intervalos por remuestreo, ICE o subgrupos, y comparación entre periodos. Saltos abruptos pueden reflejar árboles, pocos datos o una interacción. Se investigan antes de traducirlos en política.

12.4.4. Valores SHAP

Los valores SHAP se inspiran en valores de Shapley de teoría de juegos. Los atributos son “jugadores”, la predicción es el pago y cada contribución promedia el aporte marginal del atributo sobre todas las coaliciones posibles. Para p atributos,

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [\nu(S \cup \{j\}) - \nu(S)],$$

donde $\nu(S)$ es la predicción esperada cuando se conocen atributos de S . La descomposición satisface aditividad local:

$$\hat{f}(x) = \phi_0 + \sum_{j=1}^p \phi_j,$$

con ϕ_0 como valor esperado de referencia, en la escala explicada.

El cálculo exacto requiere 2^p coaliciones en general; se usan algoritmos especializados o aproximaciones. La definición de “atributo ausente” es decisiva. Un enfoque marginal integra sobre la distribución de los otros atributos y puede generar combinaciones irreales; uno condicional respeta dependencias, pero reparte crédito entre correlacionados de manera dependiente del modelo condicional. No existe una única atribución neutral.

Ejemplo: un modelo de riesgo de reclamación produce log-odds base -2.0 . Para una transacción, importe atípico aporta $+0.8$, velocidad $+0.5$, antigüedad de cuenta -0.3 y otros $+0.1$. La suma -0.9 se transforma a probabilidad logística aproximada 0.289 . Las contribuciones explican el desplazamiento del modelo desde la referencia; no son cambios causales de probabilidad ni necesariamente están expresadas en puntos porcentuales.

Agregando $|\phi_j|$ se obtiene una relevancia global basada en explicaciones locales. Los gráficos de dependencia SHAP ayudan a observar forma e interacción. Los riesgos incluyen seleccionar una referencia inadecuada, ocultar correlación, confundir escala y construir una historia plausible para un caso fuera de distribución. Siempre deben declararse datos de fondo, versión del modelo y estabilidad ante referencias alternativas.

12.4.5. Motivación del aprendizaje federado

En aprendizaje centralizado, los datos de distintas fuentes se trasladan a un repositorio común. Esto puede ser inviable por regulación, confidencialidad, soberanía, volumen o latencia. El aprendizaje federado (FL) coordina entrenamiento entre clientes que conservan datos locales y comparten actualizaciones del modelo. Ejemplos incluyen plantas de empresas distintas, instituciones financieras o dispositivos energéticos.

El objetivo idealizado con K clientes es

$$\min_w F(w) = \sum_{k=1}^K \frac{n_k}{N} F_k(w), \quad F_k(w) = \frac{1}{n_k} \sum_{i \in D_k} \ell(w; x_i, y_i),$$

donde $N = \sum_k n_k$. En *Federated Averaging* (FedAvg), el servidor distribuye w_t , clientes seleccionados realizan varias actualizaciones locales y devuelven $w_{t+1}^{(k)}$. El servidor agrega

$$w_{t+1} = \sum_{k \in S_t} \frac{n_k}{\sum_{r \in S_t} n_r} w_{t+1}^{(k)}.$$

Pseudocódigo: FedAvg

```

inicializar modelo global w
para cada ronda t:
    seleccionar clientes disponibles S_t
    enviar w a cada cliente seleccionado
    en cada cliente, en paralelo:
        entrenar localmente durante E pasos sobre sus datos
        devolver actualización protegida
    verificar y agregar actualizaciones ponderadas
    evaluar el modelo global con protocolo federado

```

FL minimiza transferencia de datos brutos, pero no garantiza privacidad. Gradientes y parámetros pueden filtrar información. Tampoco resuelve automáticamente sesgo, consentimiento ni mala calidad. Su adopción se justifica tras comparar con alternativas como entrenamiento local, datos agregados, enclaves seguros o centralización autorizada.

12.4.6. Arquitecturas federadas

La federación horizontal ocurre cuando clientes comparten el espacio de atributos pero poseen filas distintas: varias plantas registran las mismas señales para máquinas diferentes. En federación vertical, organizaciones comparten entidades pero tienen atributos distintos, como una entidad financiera y una aseguradora con bases legales para colaborar. La transferencia federada aborda escasa coincidencia tanto de filas como de atributos y es más compleja.

Según escala se distingue *cross-silo*, con pocas organizaciones relativamente estables, de *cross-device*, con muchos dispositivos intermitentes y limitados. Cross-silo facilita control de versiones y conectividad; cross-device exige selección masiva, tolerancia a fallos y compresión. Una topología central usa servidor coordinador; una descentralizada intercambia actualizaciones entre pares, reduciendo un punto único pero complicando consenso y confianza.

La personalización reconoce que un único modelo global puede ser inadecuado. Puede ajustarse una cabeza local, agrupar clientes similares, usar regularización hacia un centro global o aprender representaciones compartidas. La evaluación debe comparar modelo global, local y personalizado por cliente; un promedio favorable puede ocultar daño en participantes pequeños.

Una arquitectura incluye más que agregación: identidad y autorización, registro de versiones, selección de clientes, distribución segura, entrenamiento local reproducible, agregación, monitoreo y recuperación. El esquema de atributos y la semántica deben alinearse. “Temperatura máxima” medida en ventanas distintas no se vuelve comparable por federar.

La partición de datos determina el protocolo. En vertical se requieren técnicas de alineación privada de entidades y cálculo seguro. En horizontal, el desafío dominante suele ser distribución no idéntica. La arquitectura se elige por estructura, amenaza y gobernanza, no por popularidad algorítmica.

12.4.7. Privacidad, comunicación y limitaciones

Las actualizaciones pueden revelar pertenencia, ejemplos o propiedades del cliente. La agregación segura permite que el servidor vea solo la suma, no contribuciones individuales. La privacidad diferencial limita influencia individual mediante recorte y ruido, y proporciona un presupuesto (ϵ, δ) ; mayor privacidad suele reducir utilidad. El cifrado homomórfico y el cómputo multipartito ofrecen protecciones adicionales con costo de cálculo y comunicación.

El modelo de amenaza debe especificar adversarios: servidor curioso, clientes maliciosos, observadores de red o colusión. Agregación segura no impide que un cliente envenene el modelo; privacidad diferencial no garantiza equidad; cifrado en tránsito no protege actualizaciones una vez descifradas. Se requieren autenticación, agregación robusta, límites de actualización, auditoría y respuesta a incidentes.

La heterogeneidad estadística (*non-IID*) aparece cuando prevalencias o relaciones difieren entre clientes. Múltiples pasos locales pueden hacer que modelos deriven en direcciones incompatibles. Clientes grandes dominan un promedio por n_k , mientras ponderación uniforme puede sobrerrepresentar sitios pequeños. La función objetivo debe reflejar equidad y propósito, no solo tamaño.

La comunicación puede dominar el costo. Número de rondas, tamaño del modelo, disponibilidad, ancho de banda y energía condicionan viabilidad. Compresión, cuantización, actualizaciones dispersas y más trabajo local reducen transferencia, pero pueden afectar convergencia. Clientes lentos generan *stragglers*; excluirlos sistemáticamente sesga la población participante.

Otros límites son deriva asincrónica, borrado de datos difícil de propagar, reproducibilidad, depuración sin acceso central y cumplimiento entre jurisdicciones. La evaluación necesita métricas globales y por cliente, tasa de participación, rondas, bytes, consumo, ataques simulados y presupuesto de privacidad. Decir que “los datos nunca salen” es insuficiente y potencialmente engañoso: sale información transformada cuyo riesgo debe medirse.

12.4.8. Ejemplo práctico guiado: explicación de una predicción individual

Un ensamble de Gradient Boosting predice la probabilidad de que una pieza de una línea de plantas requiera reproceso. El modelo se ha validado por planta y periodo. Para una pieza concreta devuelve 0.68, frente a una prevalencia de referencia de 0.12. La decisión es inspeccionar cuando la probabilidad supera 0.45.

Explicación local. En escala log-odds, SHAP usa una referencia de -1.99 (probabilidad 0.12). Vibración aporta $+1.10$, variación térmica $+0.65$, proveedor del material $+0.35$, velocidad de línea $+0.22$ y humedad ambiental -0.18 ; otros aportes suman $+0.61$. El total 0.76 corresponde aproximadamente a 0.68. Se comunica que son contribuciones del modelo respecto de la población de fondo, no causas independientes.

Contraste global. La permutación muestra que vibración es primera, velocidad segunda, variación térmica cuarta y proveedor séptimo. No hay contradicción: proveedor puede ser poco importante en promedio y relevante para este caso. Se repite permutación por planta; proveedor gana importancia en la planta de la pieza, lo que sugiere heterogeneidad a investigar.

Forma y soporte. Un PDP de vibración crece a partir de cierto rango, pero las curvas ICE revelan que el aumento es mayor a velocidades altas. La pieza se encuentra dentro de una región con suficientes observaciones. Se evita afirmar que reducir vibración por sí sola llevará la probabilidad a un valor específico, pues alterar una variable puede crear una combinación no realista y no establece intervención causal.

Sensibilidad. Se recalculan SHAP con dos fondos razonables: toda la red y la planta local. Cambian magnitudes, no el conjunto principal. Pequeñas perturbaciones dentro del error de sensor mantienen la decisión. Si la explicación cambiara de signo por ruido mínimo, se marcaría baja estabilidad.

Vínculo federado. Si las plantas entrenan federadamente, el modelo global puede explicarse localmente en cada sitio sin centralizar filas. Sin embargo, compartir explicaciones detalladas también puede revelar propiedades. Se agregan estadísticas con umbrales de tamaño y controles de privacidad. El informe final contiene puntuación, umbral, referencia, contribuciones, soporte, advertencias y versión.

Este ejercicio muestra que una explicación responsable triangula escala local, importancia global, forma promedio, subgrupos y estabilidad. Ninguna herramienta aislada responde todas las preguntas.

Síntesis

Los árboles convierten el espacio de atributos en regiones mediante divisiones voraces. Entropía y Gini cuantifican impureza; la pérdida cuadrática guía regresión. Profundidad, tamaño de hoja y poda costo-complejidad controlan el compromiso sesgo-varianza. Sus reglas son legibles, pero siguen siendo asociaciones sensibles a muestra, medición y cobertura.

Las SVM eligen hiperplanos de margen máximo. El margen blando expresa la regularización mediante pérdida bisagra y C ; los kernels reemplazan productos internos para obtener fronteras no lineales. Escalado, búsqueda conjunta, calibración y costo son partes del sistema. Los vectores de soporte revelan qué casos condicionan la frontera, no qué casos deben eliminarse.

Los ensambles explotan diversidad. Bagging y Random Forest reducen varianza; boosting optimiza secuencialmente una pérdida; stacking combina modelos mediante predicciones fuera de pliegue. Una comparación válida comparte datos, divisiones, métricas y presupuesto, e incluye estabilidad y costo. El ganador de entrenamiento no es el objetivo: lo es el sistema que generaliza bajo restricciones reales.

Permutación, PDP y SHAP responden preguntas diferentes y dependen de correlación, referencia y población. Explicar un modelo no identifica causas. El aprendizaje federado descentraliza datos brutos, pero agrega heterogeneidad,

comunicación y amenazas. Privacidad requiere mecanismos y un modelo explícito, no solo una arquitectura distribuida.

Glosario

- **Agregación segura:** protocolo que permite combinar actualizaciones sin revelar al coordinador cada contribución individual.
- **Bagging:** ajuste de modelos sobre remuestras y agregación de sus predicciones para reducir varianza.
- **Boosting:** construcción secuencial de modelos que corrigen errores o gradientes previos.
- **Calibración:** correspondencia entre probabilidades predichas y frecuencias observadas.
- **Dependencia parcial:** efecto promedio del modelo al fijar uno o más atributos y promediar sobre los restantes.
- **Entropía:** medida de incertidumbre de una distribución de clases.
- **Ganancia de información:** reducción de entropía producida por una división.
- **Gradient Boosting:** boosting entendido como descenso de gradiente en el espacio de funciones.
- **Índice de Gini:** medida de impureza basada en probabilidades cuadráticas de clase.
- **Kernel:** función que calcula un producto interno implícito en un espacio de características.
- **Margen:** separación geométrica entre una frontera SVM y los casos más próximos.
- **Non-IID:** distribuciones locales que no son idénticas ni necesariamente independientes entre clientes.
- **Out-of-bag:** observación no incluida en una remuestra bootstrap concreta.
- **Out-of-fold:** predicción generada por un modelo que no entrenó con esa observación.
- **Poda:** eliminación regularizada de ramas de un árbol.
- **Privacidad diferencial:** garantía probabilística que limita cuánto cambia una salida por la presencia de una observación.
- **Random Forest:** bagging de árboles con selección aleatoria de atributos en cada nodo.
- **SHAP:** atribuciones basadas en valores de Shapley que descomponen una predicción respecto de una referencia.
- **Stacking:** combinación aprendida de predicciones OOF mediante un metamodelo.
- **Vector de soporte:** observación con multiplicador dual positivo que participa en la frontera SVM.

Preguntas de revisión y discusión

1. ¿Por qué una partición que produce una hoja pura puede tener poca ganancia de información?
2. Derive la constante óptima de una hoja de regresión bajo pérdida cuadrática y explique qué cambiaría con pérdida absoluta.

3. Compare Gini y entropía. ¿Qué factores suelen ser más importantes que elegir entre ambos?
4. ¿Por qué un árbol profundo puede tener bajo error de entrenamiento y mala calibración futura?
5. Explique la relación entre poda costo-complejidad, α y número de hojas.
6. ¿Qué información debe acompañar una regla de árbol para evitar una interpretación engañosa?
7. Derive la distancia de un punto a un hiperplano y la anchura $2/\|w\|$ del margen.
8. Interprete $\xi_i = 0.4$ y $\xi_i = 1.4$ en una SVM de margen blando.
9. ¿Cómo interactúan C y γ en una SVM RBF?
10. ¿Por qué el escalado debe estimarse dentro de cada pliegue?
11. Use la fórmula de varianza del promedio para explicar el propósito de m_{try} en Random Forest.
12. ¿Cuándo la estimación OOB puede ser optimista o inadecuada?
13. Relacione los seudoresiduos de Gradient Boosting con descenso de gradiente.
14. Dibuje un caso donde boosting persiga etiquetas erróneas.
15. ¿Por qué las predicciones de nivel 0 de stacking deben ser OOF?
16. Distinga importancia por disminución de impureza e importancia por permutación.
17. ¿Cómo afectan predictores correlacionados a permutación, PDP y SHAP?
18. ¿Por qué una explicación local fiel no constituye una explicación causal?
19. Compare federación horizontal, vertical, cross-silo y cross-device.
20. ¿Qué amenazas permanecen si se utiliza agregación segura?
21. Proponga métricas para evaluar utilidad, equidad, privacidad y comunicación en FL.
22. ¿Qué señales indicarían deriva y qué componentes deberían reajustarse?

Actividad integradora

Título: priorización de inspecciones de calidad en una red de plantas.

Una organización dispone de registros históricos de varias plantas: mediciones previas al cierre de lote, tipo de producto, proveedor, turno, antigüedad de máquina y etiqueta de defecto crítico confirmada. Cada planta conserva sus datos por acuerdos de confidencialidad. La capacidad permite inspeccionar como máximo el 8% de los lotes.

El equipo debe entregar un diseño, sin código de implementación, que contenga:

1. Un contrato predictivo con unidad de análisis, tiempo de decisión, horizonte, acción, costo de falsos negativos y variables prohibidas por temporalidad.
2. Una división de desarrollo, validación y prueba que respete periodo, planta y posibles lotes relacionados.
3. La derivación manual de Gini o entropía para dos cortes candidatos en un nodo proporcionado por el docente.
4. Un árbol amplio y su estrategia conceptual de poda, incluyendo la regla de selección por validación.
5. Una SVM lineal y una RBF, con justificación de escalado, malla logarítmica, calibración y diagnóstico de soportes.
6. Una competencia entre árbol podado, Random Forest y Gradient Boosting bajo idéntico protocolo, con tabla de media, dispersión, sensibilidad al 8%,

calibración, latencia y memoria.

7. Un diseño opcional de stacking que detalle exactamente cómo producir predicciones OOF y cómo evitar fuga.
8. Importancia por permutación global y por planta, un PDP acompañado de ICE y una explicación SHAP individual con dos poblaciones de referencia.
9. Una crítica explícita de correlación, combinaciones sin soporte, inestabilidad y límites causales.
10. Una arquitectura federada cross-silo con esquema de FedAvg, gestión de clientes, agregación segura, privacidad diferencial si corresponde, amenazas y presupuesto de comunicación.
11. Un plan de monitoreo con métricas por planta, deriva, calibración, participación, incidentes de seguridad y condiciones de retirada del modelo.
12. Una recomendación final que identifique un modelo elegido y otro descartado, cuantifique el intercambio y declare incertidumbre y limitaciones.

La evaluación de la actividad ponderará corrección metodológica, ausencia de fuga, coherencia entre métrica y decisión, calidad de diagnósticos, interpretación prudente y viabilidad distribuida. No se premiará el modelo más complejo, sino la argumentación reproducible que conecte datos, objetivo, validación y operación.

Capítulo 13. Aprendizaje no supervisado y descubrimiento de estructuras

El aprendizaje no supervisado estudia observaciones para las que no se dispone de una variable objetivo que indique la respuesta correcta. Su propósito no es adivinar etiquetas ocultas, sino construir representaciones, detectar regularidades, resumir heterogeneidad y formular hipótesis que luego deberán contrastarse. Agrupar clientes, documentos o zonas de operación puede ayudar a describir un sistema; no demuestra, por sí solo, que existan clases naturales ni explica por qué se formaron los grupos.

Esta diferencia cambia el criterio de éxito. En una tarea supervisada puede medirse el error frente a respuestas conocidas. En una tarea no supervisada existen muchas particiones matemáticamente válidas y la calidad depende de la representación, la métrica, el algoritmo, los hiperparámetros y el uso previsto. Una solución compacta según una métrica puede ser inestable, trivial o irrelevante para la decisión. Por ello, este capítulo trata el agrupamiento como un proceso de modelado y validación, no como la ejecución aislada de un algoritmo.

Al finalizar el capítulo, se espera que el estudiante pueda:

- formular una pregunta no supervisada con unidad de análisis y propósito explícitos;
- elegir distancias y transformaciones coherentes con variables numéricas, categóricas o mixtas;
- explicar y diagnosticar K-means, agrupamiento jerárquico, DBSCAN y mapas autoorganizados;
- combinar métricas internas, referencias externas, estabilidad y utilidad para seleccionar una solución;
- caracterizar grupos sin convertir resultados algorítmicos en categorías esenciales;
- distinguir una observación atípica, el ruido del algoritmo y un evento que requiere investigación;
- documentar límites de cobertura, sensibilidad y consecuencias de uso.

13.1. Distancias, similitudes y representación

Todo método de agrupamiento incorpora una definición de semejanza. A veces aparece de forma explícita como una matriz de distancias; otras queda implícita en una función objetivo. Antes de elegir un algoritmo debe definirse qué significa

que dos unidades sean parecidas, qué diferencias importan y cuáles son artefactos de escala o codificación. La distancia es, por tanto, una hipótesis de dominio expresada matemáticamente.

Sea una matriz de datos $X \in \mathbb{R}^{n \times p}$, con n observaciones y p variables. La fila $\mathbf{x}_i$ representa una unidad de análisis. Esta notación sencilla oculta decisiones importantes: una fila podría representar una persona, una compra, una zona o un día; las columnas podrían ser mediciones originales, proporciones, indicadores o resúmenes temporales. Cambiar cualquiera de esas decisiones cambia el problema aun cuando el algoritmo conserve el mismo nombre.

13.1.1. Objetivos del aprendizaje no supervisado

Los objetivos más frecuentes pueden organizarse en cuatro familias. La primera es el **descubrimiento de grupos**, que busca particiones con alta semejanza interna y diferencia entre grupos. La segunda es la **representación**, que resume observaciones mediante prototipos, componentes o mapas de menor dimensión. La tercera es la **detección de estructura local**, que identifica vecindades, regiones densas y observaciones aisladas. La cuarta es la **exploración generadora de hipótesis**, donde los patrones sugieren preguntas para estudios posteriores.

Estos objetivos no son equivalentes. Si el propósito es comprimir datos, puede aceptarse una representación que preserve bien el promedio aunque simplifique casos raros. Si el propósito es investigar anomalías, esos mismos casos raros son centrales. Si se pretende asignar recursos, importan además la estabilidad de los segmentos, su tamaño y la posibilidad de describirlos con variables disponibles al momento de decidir.

Una formulación adecuada responde antes del ajuste:

1. ¿Cuál es la unidad de análisis?
2. ¿Qué periodo, población y mecanismo de observación cubren los datos?
3. ¿Qué significa semejanza para el problema?
4. ¿Se requiere una partición exhaustiva o se admite ruido sin asignar?
5. ¿Cómo se utilizará y revisará el resultado?

No disponer de etiquetas no significa carecer de conocimiento. Restricciones físicas, taxonomías parciales, auditorías humanas y variables contextuales pueden validar una solución sin usarse para construirla. Conviene separar variables de **formación**, que determinan los grupos, de variables de **caracterización**, que ayudan a interpretarlos después. Así se evita fabricar una conclusión al introducirla previamente en la representación.

Una precaución conceptual es hablar de *segmentos encontrados bajo una representación y un método*, no de clases verdaderas. Dos algoritmos pueden responder preguntas distintas: K-means busca centroides que reduzcan dispersión cuadrática; DBSCAN busca componentes conectados por densidad. El desacuerdo puede revelar geometrías diferentes en lugar de señalar automáticamente que uno de ellos está equivocado.

13.1.2. Distancia euclídea

Para dos vectores numéricos $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$, la distancia euclídea es

$$d_2(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{j=1}^p (x_j - z_j)^2}.$$

Es la longitud del segmento recto entre ambos puntos. Satisface no negatividad, identidad, simetría y desigualdad triangular, por lo que es una métrica. Elevar las diferencias al cuadrado hace que las discrepancias grandes pesen más. Por ejemplo, entre $A = (2, 3)$ y $B = (5, 7)$ se obtiene $d_2(A, B) = \sqrt{3^2 + 4^2} = 5$.

La distancia euclídea es coherente cuando las variables son cuantitativas, comparables y las diferencias poseen significado aproximadamente lineal. Está ligada a K-means: el centro que minimiza la suma de distancias euclídeas al cuadrado dentro de un grupo es la media aritmética. También se relaciona con la suposición de grupos aproximadamente esféricos y con varianzas similares cuando se interpreta probabilísticamente.

Sus limitaciones son decisivas. Una variable expresada en miles puede dominar a otra expresada entre cero y uno. Los valores extremos se amplifican por el cuadrado. En muchas dimensiones, las distancias tienden a concentrarse: la diferencia relativa entre vecinos cercanos y lejanos disminuye, y el concepto de vecindad pierde contraste. Variables redundantes cuentan varias veces el mismo fenómeno. Además, la geometría recta no es apropiada para todos los dominios: dos horas cercanas a medianoche parecen lejanas si se codifica la hora como un número lineal.

El diagnóstico debe incluir distribución de distancias, contribución de cada variable y sensibilidad al retirar variables correlacionadas. Si casi todos los pares están a distancias similares, no basta con ejecutar un método; hay que reconsiderar representación, dimensión o métrica. Una transformación no se justifica porque mejore una cifra, sino porque aproxima mejor la noción sustantiva de diferencia.

13.1.3. Distancia Manhattan

La distancia Manhattan, L_1 o de bloques, suma diferencias absolutas:

$$d_1(\mathbf{x}, \mathbf{z}) = \sum_{j=1}^p |x_j - z_j|.$$

Para los puntos anteriores, $d_1(A, B) = |2 - 5| + |3 - 7| = 7$. A diferencia de la euclídea, no eleva las discrepancias al cuadrado. Un cambio de cuatro unidades en una variable aporta lo mismo que cuatro cambios de una unidad distribuidos entre variables. Esto puede reducir la influencia relativa de diferencias extremas, aunque no elimina la necesidad de escalar ni convierte el método en inmune a valores atípicos.

La geometría inducida por L_1 favorece contornos en forma de rombo y puede ser adecuada cuando los atributos representan cantidades aditivas o cuando la ruta conceptual solo permite cambios por coordenadas. En espacios dispersos, como perfiles con muchas entradas cero, puede conservar contrastes distintos de los de L_2 . El representante que minimiza desviaciones absolutas en una dimensión es la mediana; esta relación motiva métodos de medoides o variantes basadas en

L_1 , pero no autoriza a reemplazar la distancia de K-means estándar sin cambiar también su actualización y su objetivo.

Un ejemplo simple ilustra el cambio de vecino. Considérese un punto origen $O = (0, 0)$ y candidatos $P = (3, 0)$ y $Q = (2, 2)$. Según Euclídea, $d_2(O, P) = 3$ y $d_2(O, Q) = \sqrt{8} \approx 2,83$, por lo que Q está más cerca. Según Manhattan, $d_1(O, P) = 3$ y $d_1(O, Q) = 4$, por lo que P está más cerca. Ningún resultado es universalmente correcto: cada uno expresa un costo de desplazamiento distinto.

Conviene comparar matrices de vecinos bajo L_1 y L_2 , observar qué unidades cambian de vecindad y explicar el cambio variable por variable. Si una conclusión desaparece al alternar métricas igualmente defendibles, debe reportarse como sensible y no como estructura robusta.

13.1.4. Similitud coseno

La similitud coseno compara orientación y no distancia absoluta:

$$s_{\cos}(\mathbf{x}, \mathbf{z}) = \frac{\mathbf{x}^T \mathbf{z}}{\|\mathbf{x}\|_2 \|\mathbf{z}\|_2},$$

si ambos vectores tienen norma no nula. Para datos no negativos toma valores usualmente entre 0 y 1; en general, entre -1 y 1 . Una distancia derivada frecuente es $d_{\cos} = 1 - s_{\cos}$, aunque no todas las transformaciones de similitud conservan todas las propiedades métricas.

Dos vectores proporcionales tienen coseno uno. Así, perfiles $A = (2, 4, 2)$ y $B = (20, 40, 20)$ poseen la misma composición relativa aunque magnitudes muy diferentes. Esto resulta útil al comparar distribuciones horarias, frecuencias de términos o preferencias relativas. Pero sería inadecuado si el volumen total fuera sustantivo: dos zonas con el mismo patrón horario y cien veces distinta cantidad de observaciones no deberían tratarse necesariamente como equivalentes.

La decisión puede resolverse separando **forma** y **nivel**. Las proporciones normalizadas describen la forma del perfil, mientras una variable adicional transformada, como el logaritmo del volumen, conserva información de magnitud. Su peso debe declararse. Centrar variables cambia radicalmente el significado del coseno, porque pasa de comparar direcciones desde el origen a comparar direcciones respecto de otro punto. La correlación de Pearson se relaciona con el coseno de vectores centrados, pero no es idéntica al coseno de los datos originales.

Los vectores nulos requieren una regla explícita: no tienen dirección y su coseno no está definido. Tampoco debe interpretarse un coseno alto como cercanía causal o equivalencia general. Solo indica orientación semejante en las variables incluidas. El diagnóstico mínimo compara similitud, normas y volumen; de ese modo se detectan pares que parecen idénticos por composición pero difieren operacionalmente en escala.

13.1.5. Escalas y ponderación de variables

Supóngase que una variable varía entre 0 y 10 000 y otra entre 0 y 1. Sin transformación, la primera dominará casi cualquier distancia euclídea o Manhattan. Estandarizar por media y desviación típica produce

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Esta operación asigna a cada variable varianza unitaria, pero no es neutral: afirma que una desviación típica representa una diferencia comparable en todas las dimensiones. Si una variable tiene una distribución muy asimétrica o valores extremos, la media y la desviación pueden ser poco representativas. Una alternativa robusta usa mediana y rango intercuartílico:

$$r_{ij} = \frac{x_{ij} - \text{mediana}(X_j)}{Q_{0.75}(X_j) - Q_{0.25}(X_j)}.$$

El escalado mínimo-máximo sitúa valores observados en un intervalo, por lo común $[0, 1]$, pero es sensible a extremos y a nuevos valores fuera del rango de ajuste. Las transformaciones logarítmicas pueden comprimir colas derechas para cantidades no negativas. Las proporciones necesitan tratamiento cuidadoso: sus componentes suman uno y no constituyen dimensiones independientes. Incluir cuatro proporciones horarias y además su suma agrega redundancia perfecta.

La distancia ponderada explicita prioridades:

$$d_w(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{j=1}^p w_j (x_j - z_j)^2}, \quad w_j \geq 0.$$

Los pesos no deben elegirse solo para obtener grupos visualmente atractivos. Pueden derivarse de confiabilidad, relevancia operativa o equilibrio entre bloques. Por ejemplo, si se incluyen doce proporciones temporales y dos variables de diversidad, el bloque temporal puede dominar por cantidad de columnas aunque cada una esté estandarizada. Asignar peso total comparable a cada bloque evita que la dimensionalidad sustituya al juicio sustantivo.

Todo transformador debe ajustarse con el conjunto que corresponde al análisis y conservarse para nuevas observaciones. En estudios de estabilidad temporal, usar información futura para escalar el pasado introduce una dependencia innecesaria. Se recomienda documentar parámetros, inspeccionar distribuciones antes y después, y repetir el análisis con transformaciones plausibles. Una segmentación que cambia completamente ante pequeñas modificaciones de escalado carece de solidez para usos persistentes.

13.1.6. Datos mixtos

Muchos problemas combinan variables numéricas, binarias, nominales, ordinales y posiblemente fechas. Convertir categorías nominales a enteros crea distancias ficticias: codificar rojo, verde y azul como 1, 2 y 3 implica un orden y hace que rojo-azul sea el doble de distante que rojo-verde. La codificación one-hot evita ese orden, pero puede sobrerrepresentar variables con muchas categorías y modifica la geometría.

La distancia de Gower ofrece una estrategia para datos mixtos. Para dos observaciones i y l , calcula una disimilitud parcial δ_{ilj} por variable y las combina:

$$d_G(i, l) = \frac{\sum_{j=1}^p w_{ilj} \delta_{ilj}}{\sum_{j=1}^p w_{ilj}}.$$

Para una variable numérica, $\delta_{ilj} = |x_{ij} - x_{lj}|/R_j$, donde R_j es un rango documentado. Para una nominal, vale cero si coincide y uno si difiere. Para una ordinal, se transforman categorías a rangos normalizados respetando el orden. El peso w_{ilj} puede ser cero si falta uno de los valores, lo que permite comparar con la información disponible; sin embargo, dos distancias calculadas con conjuntos de variables distintos no poseen necesariamente la misma confiabilidad.

Las variables binarias merecen distinguir presencia y ausencia. En una binaria simétrica, coincidencias en cero y en uno cuentan por igual. En una asimétrica, como presencia de una característica rara, dos ausencias conjuntas aportan poca evidencia de semejanza; índices como Jaccard ignoran esa coincidencia. La elección debe responder al significado, no al tipo de almacenamiento.

Una matriz de Gower puede alimentar métodos que aceptan disimilitudes, como clustering jerárquico o k-medoids. K-means no es directamente apropiado porque requiere medias en un espacio euclídeo. Para categorías puras existen métodos basados en modas, y para datos mixtos hay extensiones, pero sus objetivos deben explicarse.

Los faltantes no son una categoría por defecto. “Desconocido” puede describir el proceso de captura y formar un grupo artificial. Antes de agrupar se evalúan patrón de ausencia, comparabilidad y calidad. Un buen diagnóstico informa cuántas variables contribuyeron a cada distancia y prueba si los grupos separan principalmente niveles de faltantes.

13.1.7. Ejemplo práctico guiado: comparación de similitudes entre observaciones

Considérense cuatro establecimientos descritos por visitas semanales, duración mediana de la visita en minutos y proporción de visitas de fin de semana:

Unidad	Visitas	Duración	Proporción fin de semana
A	100	20	0,20
B	120	22	0,70
C	300	21	0,22
D	105	45	0,19

Sin escalar, la diferencia de visitas domina la distancia euclídea. Para A, B parece cercano por volumen y C lejano, aunque A y C se parecen en duración y composición semanal. Tras estandarizar, las tres dimensiones tienen influencia comparable: la gran proporción de fin de semana aleja a B y la duración aleja a D. No se ha “corregido” una respuesta: se ha cambiado la definición de semejanza.

El análisis guiado sigue estos pasos:

1. **Definir el propósito.** Si interesa capacidad total, el volumen no debe desaparecer. Si interesa únicamente la forma de uso, puede normalizarse o analizarse por separado.

2. **Auditar variables.** Visitas es una cuenta con posible asimetría; duración puede contener extremos; la proporción está acotada.
3. **Comparar representaciones.** Se contrastan datos originales, estandarización y transformación logarítmica de visitas seguida de escalado robusto.
4. **Comparar métricas.** Para cada alternativa se ordenan los vecinos de A con Euclídea y Manhattan.
5. **Explicar cambios.** Se descompone la distancia en aportes por variable, no solo se presenta el vecino final.

Supóngase que, después de una transformación defendible, A tiene como vecino a C bajo ambas métricas, mientras B y D intercambian posiciones. La coincidencia A-C es evidencia local de robustez; el orden B-D es sensible. Con solo cuatro unidades no corresponde declarar segmentos estables. El ejemplo sirve para mostrar que el preprocesamiento forma parte del modelo.

Un informe breve incluiría una tabla de vecinos bajo cada escenario, histogramas de variables, matriz de distancias y una conclusión condicional: “A y C son similares respecto de composición y duración; no son equivalentes en volumen”. También registraría qué ocurriría si la proporción de fin de semana tuviera error de medición. Este análisis de sensibilidad es más informativo que escoger automáticamente la alternativa con separación visual mayor.

13.2. Agrupamiento particional y jerárquico

Los métodos particionales asignan observaciones a un número de grupos definido o seleccionado mediante un criterio. Los jerárquicos construyen relaciones anidadas y permiten examinar soluciones a distintas escalas. Ambos dependen de la representación y ninguno garantiza recuperar una taxonomía verdadera. La elección se fundamenta en la geometría buscada, el tamaño de los datos, la necesidad de prototipos y la estabilidad.

13.2.1. Algoritmo K-means

K-means divide n observaciones numéricas en K grupos $C_1, \dots, C_K$ minimizando la suma de cuadrados dentro de grupos:

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \mu_k\|_2^2, \quad \mu_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i.$$

El algoritmo alterna dos operaciones. Con centroides fijos, asigna cada observación al centro más cercano. Con asignaciones fijas, reemplaza cada centro por la media de su grupo. Cada operación no aumenta J , de modo que el procedimiento converge en un número finito de asignaciones, aunque puede hacerlo a un mínimo local.

Pseudocódigo conceptual de K-means

Entrada: observaciones X , número de grupos K , criterio de parada

Inicializar K centroides

Repetir:

asignar cada observación al centroide más cercano

recalcular cada centroide como media de sus observaciones

tratar cualquier grupo vacío con una regla documentada
 Hasta que no cambien las asignaciones o la mejora sea menor que la tolerancia
 Salida: asignaciones, centroides e inercia

K-means produce una partición exhaustiva: incluso una observación muy alejada queda asignada. Sus fronteras son regiones de Voronoi y, por ello, los grupos resultantes son convexos en el espacio transformado. Funciona mejor con grupos compactos, aproximadamente esféricos, de dispersión y tamaño no demasiado diferentes. Puede dividir un grupo alargado o fusionar grupos de densidades distintas.

Los centroides no siempre corresponden a observaciones reales. Son perfiles promedio y pueden ser imposibles si se aplican a variables binarias o categorías. El método requiere datos numéricos y distancia euclídea al cuadrado coherente con la media; cambiar arbitrariamente la métrica rompe la correspondencia entre asignación, actualización y objetivo.

El costo por iteración es aproximadamente $O(nKp)$, lo que lo hace escalable. Esa eficiencia no compensa una geometría inadecuada. Los diagnósticos incluyen tamaño por grupo, distancias al centro, contribución por variable, observaciones fronterizas y comparación entre reinicios.

13.2.2. Inicialización y convergencia

La función de K-means no es convexa conjuntamente en asignaciones y centroides. Dos inicializaciones pueden conducir a soluciones diferentes. Elegir al azar K observaciones como centros es sencillo, pero puede ubicar varios centros en una región densa y dejar otras mal representadas. El método K-means++ selecciona el primer centro al azar y favorece luego puntos con gran distancia cuadrática al centro más cercano ya elegido. Esto tiende a dispersar los centros iniciales y suele mejorar velocidad y calidad, sin garantizar el óptimo global.

Una práctica esencial es ejecutar múltiples reinicios y conservar la solución con menor inercia. Sin embargo, si varias soluciones poseen inercias casi iguales y asignaciones muy distintas, elegir solo la menor oculta ambigüedad estructural. Deben compararse las particiones, por ejemplo mediante índice de Rand ajustado entre corridas, y contar cuántas veces aparece cada solución.

La convergencia puede definirse por ausencia de cambios, desplazamiento de centroides menor que una tolerancia, reducción mínima del objetivo o máximo de iteraciones. Alcanzar el criterio solo significa que el algoritmo dejó de mejorar localmente; no demuestra validez de los grupos. Una tolerancia excesiva puede detenerlo antes de tiempo y una muy estricta puede añadir costo sin cambio relevante.

Los grupos vacíos aparecen cuando ningún punto queda asociado a un centro. Posibles reglas son reinicializar ese centro en una observación distante o dividir el grupo con mayor dispersión. La regla afecta el resultado y debe registrarse. Duplicados numerosos también pueden producir menos de K puntos distintos efectivos.

El diagnóstico de convergencia reporta, como mínimo, número de reinicios, estrategia inicial, distribución de inercias finales, iteraciones y acuerdo entre particiones. Para evaluar estabilidad no basta cambiar la semilla sobre los mismos datos: también se remuestran observaciones, se perturban mediciones dentro de

su incertidumbre o se repite por periodos. La semilla mide variabilidad algorítmica; el remuestreo aproxima sensibilidad a la muestra.

13.2.3. Selección del número de grupos

K-means exige K , pero los datos rara vez contienen un valor inequívoco. La inercia disminuye siempre al aumentar K y llega a cero si cada observación distinta constituye su propio grupo. El método del codo busca un punto a partir del cual añadir grupos produce mejoras marginales menores. Es una heurística visual y puede no mostrar un codo claro.

Silhouette, Davies-Bouldin y otras métricas internas comparan compactación y separación, pero favorecen determinadas geometrías. El máximo de silhouette no debe adoptarse mecánicamente. Una solución con dos grupos puede separar volumen alto y bajo de manera estable, mientras una de cuatro revela patrones temporales útiles aunque tenga una cifra algo menor. La decisión depende del propósito y del costo de mantener segmentos.

Un protocolo razonable es:

1. definir un rango de K compatible con el tamaño muestral y el uso;
2. ejecutar múltiples inicializaciones para cada K ;
3. comparar inercia, silhouette, Davies-Bouldin y tamaños;
4. medir estabilidad ante semillas, remuestreo, periodos y transformaciones plausibles;
5. caracterizar las soluciones candidatas sin usar nombres valorativos;
6. elegir la solución más simple que aporte distinciones estables y accionables.

Los grupos diminutos requieren investigación. Pueden representar un patrón legítimo, errores, extremos o la fragmentación forzada por K . Un grupo con una observación hace indefinidas algunas medidas y no es automáticamente una anomalía válida. Del mismo modo, exigir tamaños iguales puede ocultar una estructura real, pero aceptar cualquier desequilibrio puede producir segmentos inoperantes.

La estabilidad de K puede estudiarse observando si grupos de una solución se subdividen de manera coherente al aumentar K . Un diagrama de flujo entre particiones muestra continuidad o reorganización completa. Si pasar de tres a cuatro grupos cambia casi todas las asignaciones, la jerarquía conceptual es débil. La selección final debe presentar alternativas descartadas y explicar el compromiso, no solo anunciar un entero.

13.2.4. Clustering jerárquico

El agrupamiento jerárquico representa relaciones anidadas entre observaciones. En el enfoque aglomerativo, cada observación comienza como un grupo y se fusionan repetidamente los dos grupos más próximos. En el divisivo, todas comienzan juntas y el conjunto se divide. El resultado se visualiza mediante un dendrograma.

El método aglomerativo requiere una disimilitud entre observaciones y una regla de enlace para convertir distancias entre puntos en distancias entre grupos. Su pseudocódigo conceptual es:

Entrada: matriz de disimilitudes y regla de enlace

Crear un grupo por observación

Mientras exista más de un grupo:

identificar el par de grupos con menor disimilitud de enlace

fusionar ese par

actualizar las disimilitudes entre el nuevo grupo y los restantes

registrar la altura de fusión

Salida: secuencia de fusiones y dendrograma

Una vez realizada una fusión aglomerativa no se deshace. Una decisión local temprana puede propagarse por toda la jerarquía. No existe una función objetivo única compartida por todos los enlaces. Por ello debe examinarse la coherencia entre métrica y enlace.

La jerarquía es útil cuando interesa explorar distintos niveles de granularidad, cuando no se desea fijar K inicialmente o cuando una matriz de distancias permite datos mixtos. Su costo de memoria suele ser $O(n^2)$ por la matriz de pares, lo que limita muestras grandes. Para datos masivos puede aplicarse a prototipos o a una muestra, aclarando que la jerarquía resultante corresponde a esa aproximación.

El dendrograma no prueba que el mundo sea jerárquico. Siempre puede construirse uno, incluso con ruido sin grupos. La validación evalúa alturas, estabilidad de ramas y asociación con perfiles interpretables. El orden horizontal de hojas puede cambiar sin alterar la jerarquía; no debe interpretarse como una escala adicional.

13.2.5. Métodos aglomerativos y divisivos

Los métodos **aglomerativos** siguen una estrategia ascendente. Empiezan con n grupos y realizan $n - 1$ fusiones. Son los más difundidos por su formulación sencilla y disponibilidad de enlaces. Resultan apropiados para reconocer pequeñas unidades muy similares que luego forman conjuntos mayores. Su debilidad es la irreversibilidad: una fusión errónea al inicio permanece.

Los métodos **divisivos** siguen una estrategia descendente. Comienzan con un único conjunto y seleccionan un grupo para dividirlo, a menudo buscando la división que más reduce heterogeneidad. Pueden concentrar esfuerzo en separaciones globales importantes, pero explorar todas las divisiones posibles es combinatoriamente costoso. En la práctica se utilizan heurísticas, por ejemplo una partición binaria repetida.

Ambas estrategias pueden generar árboles diferentes porque optimizan decisiones locales opuestas. Considérese un conjunto con dos nubes grandes unidas por pocos puntos intermedios. Un método aglomerativo con enlace simple puede encadenarlas temprano a través del puente. Uno divisivo podría reconocer primero la separación global si su criterio penaliza el corte de regiones densas.

La elección debe atender a la pregunta. Si interesan microgrupos de alta similitud que se integran progresivamente, la perspectiva ascendente es natural. Si existe una división global justificable y luego se desean subtipos, la descendente puede comunicar mejor el análisis. En ambos casos se deben revisar ramas pequeñas, sensibilidad a observaciones extremas y estabilidad por remuestreo.

Para comparar árboles completos pueden usarse correlaciones cofenéticas, que contrastan distancias originales con alturas de fusión, o medidas de similitud entre dendrogramas. Una correlación alta indica que el árbol conserva razonablemente

disimilitudes pares; no certifica utilidad ni una cantidad de grupos. La comparación más directa para una decisión concreta consiste en cortar ambos árboles a granularidades candidatas y evaluar asignaciones, perfiles y estabilidad.

13.2.6. Tipos de enlace

La regla de enlace define distancia entre grupos A y B .

Enlace simple:

$$D_{\text{simple}}(A, B) = \min_{i \in A, l \in B} d(i, l).$$

Une grupos si al menos un par está cerca. Puede descubrir formas alargadas, pero sufre el efecto de encadenamiento: una sucesión de puntos puente conecta regiones distintas.

Enlace completo:

$$D_{\text{completo}}(A, B) = \max_{i \in A, l \in B} d(i, l).$$

Exige que los puntos más alejados sean relativamente próximos y favorece grupos compactos. Es sensible a extremos, pues un solo punto distante controla el enlace.

Enlace promedio:

$$D_{\text{promedio}}(A, B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{l \in B} d(i, l).$$

Equilibra los criterios anteriores y usa toda la información entre pares. Puede ser más estable, aunque el costo y la interpretación dependen de la disimilitud.

Enlace de Ward: fusiona los grupos que producen el menor incremento en suma de cuadrados dentro de grupos:

$$\Delta(A, B) = \frac{|A||B|}{|A| + |B|} \|\mu_A - \mu_B\|_2^2.$$

Favorece grupos compactos y de tamaño parecido. Su interpretación clásica corresponde a datos numéricos con geometría euclídea; combinar Ward con una disimilitud arbitraria de datos mixtos carece de la misma justificación.

No hay un enlace universalmente superior. Debe evaluarse con datos simulados de geometría conocida o análisis de sensibilidad. Si simple produce una cadena gigante, se inspeccionan puentes. Si completo aísla extremos, se auditan esas observaciones. Si Ward divide principalmente por volumen, se reconsideran escalas. El acuerdo de un núcleo de observaciones entre enlaces fortalece la evidencia; las unidades que cambian se etiquetan como fronterizas en vez de forzarlas a una narrativa inequívoca.

13.2.7. Dendrogramas

Un dendrograma muestra hojas, fusiones y alturas. Cada hoja representa una observación o grupo inicial. La altura vertical de una unión indica la disimilitud de enlace a la que se fusionaron sus ramas. Trazar un corte horizontal induce una partición: el número de ramas interceptadas es el número de grupos.

Las alturas deben leerse según el enlace. En Ward representan incrementos de heterogeneidad, no necesariamente distancias directas entre puntos. Grandes saltos verticales sugieren cortes posibles, pero no constituyen una prueba. Con datos continuos sin separación clara también habrá un salto máximo. Además, la apariencia depende de escala, transformaciones y cantidad de observaciones.

Tres errores son frecuentes. Primero, interpretar proximidad horizontal entre hojas como distancia: las ramas pueden rotarse sin cambiar el árbol. Segundo, escoger un corte solo porque produce un número deseado. Tercero, describir cada rama como categoría real sin examinar perfiles. Un dendrograma con cientos de hojas necesita recursos complementarios, como colores de corte, mapa de calor de variables ordenadas y resúmenes por rama.

La estabilidad puede visualizarse con soporte de ramas obtenido por remuestreo. Si una rama aparece en una proporción alta de muestras, su composición es relativamente estable. Aun así, el soporte depende del esquema de remuestreo y de cómo se emparejan grupos. También puede calcularse una matriz de coasignación P_{il} : proporción de ejecuciones en que i y l quedan juntos. Bloques nítidos indican núcleos estables; bandas difusas revelan fronteras.

Antes de aceptar un corte se revisan tamaños, alturas vecinas, silhouette por observación, variables que distinguen ramas y sensibilidad a enlaces. El dendrograma es una herramienta de exploración multiescala, no una máquina automática para contar grupos.

13.2.8. Ejemplo práctico guiado: segmentación de patrones de consumo

Una organización desea resumir patrones de compras mensuales de productos de oficina para planificar inventario. La unidad es una cuenta activa y el periodo comprende doce meses completos. Las variables de formación son proporciones de gasto en cuatro familias, frecuencia mensual, variabilidad entre meses y valor mediano por compra. No se incluyen nombres de empresa ni resultados comerciales; esas variables, si fueran pertinentes y legítimas, se reservarían para caracterización.

Primero se audita cobertura. Cuentas con un solo mes observado no son comparables con cuentas de doce meses y se tratan por separado. El gasto total tiene cola derecha, por lo que se transforma logarítmicamente. Las proporciones describen composición y la frecuencia describe intensidad; se ponderan ambos bloques para evitar que las cuatro proporciones dominen por número de columnas.

Se comparan K-means y clustering aglomerativo de Ward, ambos sobre la misma representación euclídea estandarizada. Para K-means se exploran $K = 2, \dots, 8$, con múltiples inicializaciones. Para Ward se examina el dendrograma y se cortan las mismas granularidades. Una tabla de diagnóstico podría ser:

Solución	Silhouette	Grupo mínimo	Estabilidad por remuestreo	Observación
K-means, $K = 3$	0,48	18 %	0,86	perfiles amplios y
K-means, $K = 4$	0,45	7 %	0,72	separa compras es
Ward, 3 grupos	0,46	16 %	0,83	concordancia alta
Ward, 4 grupos	0,39	4 %	0,58	rama pequeña sen

Los valores son didácticos, no umbrales universales. La solución de tres grupos se prefiere por parsimonia, estabilidad y acuerdo entre métodos. Se caracterizan con medianas e intervalos: “frecuencia alta y composición diversificada”, “frecuencia baja y compras concentradas” y “frecuencia intermedia con mayor variabilidad”. Estos nombres describen las variables observadas, no calidad, rentabilidad ni identidad esencial.

El diagnóstico individual detecta cuentas con silhouette negativa y revisa si son errores, transiciones o fronteras legítimas. Después se repite el ajuste retirando una variable por vez y sobre dos subperiodos. Si el primer grupo persiste pero el tercero cambia mucho, se reportan distintos niveles de confianza.

La conclusión no es “existen tres tipos de clientes”, sino: “bajo esta ventana, representación y métrica, una partición de tres perfiles resume de manera estable los patrones observados y resulta suficiente para comparar escenarios de inventario”. Nuevos periodos requieren reasignación con el transformador conservado y vigilancia de deriva.

13.3. Métodos basados en densidad y representaciones neuronales

Los grupos no siempre son compactos ni esféricos. Los métodos de densidad describen regiones con muchas observaciones separadas por regiones escasas y pueden dejar puntos sin asignar. Los mapas autoorganizados, en cambio, aprenden prototipos ordenados sobre una rejilla y facilitan explorar relaciones no lineales. Ambas familias amplían la mirada, pero introducen hiperparámetros y diagnósticos propios.

13.3.1. Concepto de densidad

Intuitivamente, una región es densa cuando contiene muchas observaciones en poco volumen. En una esfera de radio ε alrededor de $\mathbf{x}$,

$$N_{\varepsilon}(\mathbf{x}) = \{\mathbf{z} : d(\mathbf{x}, \mathbf{z}) \leq \varepsilon\},$$

el conteo $|N_{\varepsilon}(\mathbf{x})|$ actúa como estimación local simple. “Muchas” y “poco” dependen de ε , dimensión, escala y métrica. Por eso la densidad no es una propiedad absoluta del registro.

Los métodos basados en densidad separan regiones densas conectadas por zonas de baja densidad. Pueden encontrar anillos, bandas y otras formas no convexas que K-means dividiría. También reconocen ruido. Sin embargo, presentan dificultades cuando los grupos tienen densidades muy distintas: un único radio puede fusionar una región densa o fragmentar otra dispersa.

En alta dimensión, el volumen de una esfera y la concentración de distancias complican la estimación local. Variables irrelevantes diluyen vecindades. Reducir dimensión puede ayudar, pero agrupar únicamente una proyección bidimensional puede fabricar proximidades que no existían en el espacio original. Si se usa una reducción, deben declararse su objetivo, parámetros y pérdida de información.

El concepto de densidad está ligado al mecanismo de muestreo. Una zona con pocos registros puede ser realmente poco activa o estar subobservada. Una región con alta frecuencia puede reflejar duplicación. Antes de interpretar densidad se revisan cobertura y proceso de captura. Los diagnósticos incluyen distribución de distancias al vecino k , número de vecinos por punto y estabilidad al variar radio y muestra.

13.3.2. DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) utiliza dos parámetros: radio ε y número mínimo de observaciones minPts . Un punto es **núcleo** si su vecindad de radio ε contiene al menos minPts observaciones, contando según la convención adoptada. Un punto es **frontera** si no es núcleo pero cae en la vecindad de uno. Un punto es **ruido** si no satisface ninguna condición anterior.

Un punto q es directamente alcanzable por densidad desde un núcleo p si $q \in N_\varepsilon(p)$. La alcanzabilidad por densidad extiende esa relación mediante una cadena de núcleos. Dos puntos pertenecen al mismo grupo si están conectados por densidad. Esta construcción permite seguir formas arbitrarias.

Pseudocódigo conceptual de DBSCAN

Entrada: observaciones X , distancia, radio epsilon y minPts

Marcar todas las observaciones como no visitadas

Para cada observación no visitada:

 obtener su vecindad de radio epsilon

 si no alcanza minPts , marcar provisionalmente como ruido

 si es núcleo, iniciar un grupo y expandirlo:

 incorporar vecinos alcanzables

 si un vecino también es núcleo, incorporar su vecindad

Salida: grupos, puntos frontera y puntos etiquetados como ruido

La etiqueta de ruido puede cambiar durante la expansión si el punto resulta frontera de un núcleo posterior. En casos donde un punto frontera toca dos grupos, la asignación puede depender del orden de visita, aunque los núcleos conectados sean estables. Conviene distinguir núcleos de fronteras en los resultados.

DBSCAN no exige K y puede dejar observaciones sin grupo. Esto es ventajoso si la noción de ruido tiene sentido. No obstante, imponer que cierto porcentaje sea ruido para obtener una narrativa deseada es una selección circular. La complejidad puede acercarse a $O(n \log n)$ con índices espaciales eficaces en dimensiones moderadas; en alta dimensión o con métricas complejas puede aproximarse a $O(n^2)$.

13.3.3. Ruido y formas arbitrarias

El término **ruido** en DBSCAN es una etiqueta geométrica: indica que el punto no está conectado a una región suficientemente densa con los parámetros elegidos. No equivale a error, fraude, evento relevante ni observación prescindible. Un registro correcto de un patrón raro puede ser ruido; un error repetido muchas veces puede formar un grupo denso.

Esta distinción obliga a una investigación posterior. Para cada punto aislado se comprueba integridad, cobertura, unidades, periodo y variables que explican su distancia. Luego se consulta evidencia contextual independiente. Las acciones automáticas basadas solo en la etiqueta deben evitarse, especialmente si afectan a personas o servicios.

La ventaja geométrica puede ilustrarse con dos semicírculos entrelazados. K-means traza fronteras lineales entre centroides y corta ambos arcos. DBSCAN puede recorrer cada arco mediante vecindades locales y recuperar dos componentes. Sin embargo, si puntos espurios forman un puente con separaciones menores que ε , el algoritmo unirá los arcos. Si ε es demasiado pequeño, fragmentará cada uno.

El porcentaje de ruido es un diagnóstico, no una métrica a maximizar o minimizar. Cero ruido puede indicar un radio tan grande que todo se fusionó. Mucho ruido puede indicar radio pequeño, minPts alto, escala deficiente o ausencia real de regiones densas. También se revisan tamaños de grupos y proporción de núcleos frente a fronteras. Un grupo compuesto casi enteramente por fronteras suele ser frágil.

Las observaciones de ruido pueden analizarse colectivamente, pero reagruparlas repetidamente hasta asignarlas a algo contradice el propósito de permitir no asignación. Es preferible mantener una categoría operacional de “sin perfil denso bajo esta configuración” y revisarla con el tiempo.

13.3.4. Sensibilidad a parámetros

minPts establece la evidencia mínima local. Como regla exploratoria suele relacionarse con la dimensión, pero no existe una fórmula universal. Un valor pequeño acepta cadenas frágiles y grupos diminutos; uno grande exige regiones más pobladas y puede convertir patrones válidos en ruido. El tamaño muestral y la presencia de duplicados influyen en su significado.

Para un minPts dado, el gráfico de distancia al vecino k ordena para cada punto la distancia a su vecino correspondiente. Un cambio de pendiente puede sugerir ε . El codo rara vez es inequívoco y no sustituye el conocimiento de escala. Seleccionar visualmente el radio y luego reportar la misma curva como confirmación sobrestima la evidencia.

Se recomienda construir un mapa de sensibilidad sobre una rejilla de valores plausibles. Para cada par $(\varepsilon, \text{minPts})$ se registra número de grupos, proporción de ruido, tamaños, núcleos y similitud con soluciones vecinas. Las **mesetas** donde la estructura cambia poco son más confiables que un punto aislado con una métrica óptima.

El escalado es parte de los parámetros efectivos: multiplicar una variable por diez cambia las vecindades aunque ε conserve su valor numérico. Por ello, el radio

debe expresarse respecto de una representación documentada. También debe repetirse el análisis por submuestras o periodos. Una estructura estable solo ante parámetros, pero no ante nuevas observaciones, sigue siendo débil.

Cuando existen densidades muy variables, puede considerarse una extensión de densidad jerárquica, pero no debe ocultarse que responde a otro algoritmo. Para DBSCAN estándar, la limitación se informa. La respuesta profesional ante la ausencia de un rango estable puede ser concluir que el método no identifica una segmentación defendible, en lugar de forzar parámetros.

13.3.5. Mapas autoorganizados

Un mapa autoorganizado o SOM (*Self-Organizing Map*) es una red de prototipos dispuestos normalmente en una rejilla bidimensional. Cada nodo m posee un vector de pesos $\mathbf{w}_m \in \mathbb{R}^P$. Para una observación $\mathbf{x}$ se identifica la unidad de mejor coincidencia, BMU:

$$c = \arg \min_m \|\mathbf{x} - \mathbf{w}_m\|_2.$$

Durante el entrenamiento se actualizan la BMU y sus vecinas en la rejilla:

$$\mathbf{w}_m(t+1) = \mathbf{w}_m(t) + \alpha(t)h_{cm}(t)[\mathbf{x}(t) - \mathbf{w}_m(t)],$$

donde $\alpha(t)$ es la tasa de aprendizaje y $h_{cm}(t)$ disminuye con la distancia topológica entre nodos y con el tiempo. Al principio, un vecindario amplio organiza globalmente el mapa; luego uno más estrecho refina prototipos locales.

Pseudocódigo conceptual de SOM

Entrada: datos escalados, dimensiones de rejilla y calendario de aprendizaje

Inicializar los vectores prototipo

Para cada época:

presentar observaciones en orden aleatorio

localizar la unidad de mejor coincidencia de cada observación

acercar a la observación la BMU y sus vecinas de rejilla

reducir tasa de aprendizaje y radio según el calendario

Salida: prototipos, asignaciones a BMU y relaciones de vecindad

El SOM realiza cuantización vectorial y busca preservar vecindades aproximadas, no todas las distancias. La rejilla es discreta y puede distorsionar la topología. Su entrenamiento depende de inicialización, tamaño y forma del mapa, tasa, radio y número de épocas. No produce automáticamente grupos: segmentar los prototipos es una etapa adicional que debe validarse.

Es útil para explorar muchas variables mediante componentes sobre una superficie común. No obstante, una visualización atractiva no garantiza fidelidad. Deben reportarse error de cuantización, error topográfico y estabilidad entre entrenamientos.

13.3.6. Proyección y visualización de prototipos

Cada nodo del SOM resume las observaciones asignadas y ocupa una posición fija en la rejilla. Un **mapa de componentes** colorea cada nodo según una

variable de su prototipo. Comparar mapas permite detectar asociaciones: zonas altas coincidentes en dos componentes sugieren relación en los prototipos, no causalidad.

La **matriz U** representa distancias entre prototipos vecinos. Regiones claras u oscuras, según la convención, pueden señalar fronteras; áreas homogéneas sugieren continuidad. Un mapa de conteos muestra cuántas observaciones caen en cada nodo y revela nodos vacíos o sobrecargados. Las etiquetas externas pueden superponerse solo para validación, dejando claro que no entrenaron el mapa.

Dos medidas básicas son:

$$E_Q = \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{w}_{c(i)}\|_2,$$

el error de cuantización, y

$$E_T = \frac{1}{n} \sum_{i=1}^n u_i,$$

donde $u_i = 1$ si la primera y segunda BMU no son vecinas en la rejilla. Un error de cuantización bajo puede obtenerse con muchos nodos y sobreajuste; el error topográfico evalúa otro aspecto. Ambos deben analizarse junto con ocupación y estabilidad.

El tamaño de rejilla controla resolución. Una rejilla pequeña mezcla patrones; una muy grande contiene numerosos nodos vacíos y presenta detalle aparente. Para comparar configuraciones se conservan el preprocesamiento y el protocolo de reinicios. También se alinean mapas, porque rotaciones o reflexiones pueden representar la misma organización.

Si después se agrupan prototipos, las métricas deben ponderar por cantidad de observaciones representadas para que un nodo vacío o poco ocupado no tenga el mismo peso que uno denso. La caracterización final vuelve a las observaciones originales: el prototipo es un resumen, no una unidad real.

13.3.7. Ejemplo práctico guiado: detección de zonas de movilidad atípicas

Se analizan zonas de ascenso mediante perfiles de conteos observados por franja, proporción de fin de semana, variabilidad diaria y diversidad de destinos. La unidad es la zona durante un periodo fijo. Antes del análisis se exige cobertura mínima y se separan volumen y composición temporal. No se incorporan atributos demográficos ni se interpretan los resultados como rasgos de quienes habitan una zona.

Los perfiles se escalan de forma robusta y se aplica DBSCAN. El gráfico de vecino k sugiere un intervalo de radios, no un único valor. En una rejilla de sensibilidad aparece una meseta con tres grupos y entre 6 % y 10 % de ruido. Dos grupos permanecen casi intactos; el tercero se fragmenta al reducir el radio. La conclusión debe conservar esa diferencia de confianza.

Las zonas etiquetadas como ruido se auditan una por una:

- cobertura por día y archivo;
- correspondencia válida con el catálogo de zonas;
- volumen total y efecto de la transformación;
- componente de distancia que causa aislamiento;
- persistencia del patrón por mes.

Una zona puede aislarse por una concentración nocturna persistente; otra, por datos presentes solo en parte del periodo. La primera es un perfil operativo infrecuente. La segunda es un problema de comparabilidad y debería excluirse o marcarse, no presentarse como anomalía de movilidad. Una tercera puede dejar de ser ruido con un cambio mínimo de ε y debe clasificarse como fronteriza.

Se compara luego con K-means. Si K-means asigna todos los casos raros al grupo más cercano, se examinan sus distancias al centro. El desacuerdo ilustra los objetivos: K-means ofrece una partición total; DBSCAN permite expresar que algunas zonas no pertenecen a una región densa. Ninguna etiqueta demuestra un evento ni una causa.

El producto final es una tabla con identificación de zona, etiqueta, condición núcleo/frontera/ruido, variables responsables, estabilidad paramétrica y estado de revisión. Los mapas muestran perfiles de pickups reportados, no intensidad general de movilidad. Toda explicación causal requiere fuentes y diseño adicionales.

Actividad EMO [MOV-03]: segmentar zonas por patrón de movilidad

Capacidad mínima: construir y validar segmentos útiles a partir de variables geotemporales.

Pregunta realizable. ¿Qué zonas TLC muestran perfiles semejantes de pickups de taxi amarillo reportados durante febrero, marzo y abril de 2026?

Fuente y alcance. Se utilizan los archivos `yellow_tripdata_2026-02.parquet`, `yellow_tripdata_2026-03.parquet` y `yellow_tripdata_2026-04.parquet` de NYC Taxi and Limousine Commission indicados en el Apéndice D, junto con Taxi Zone Lookup y, si se elaboran mapas, Taxi Zone Shapefile. La fila original es un viaje reportado; la unidad de esta actividad es la zona de ascenso `PULocationID`, derivada de agregaciones zona-franja con cortes temporales comunes. La fuente no representa toda la movilidad, demanda insatisfecha, vehículos libres ni actividad total de cada zona.

Preparación común. Antes de formar perfiles se aplican las reglas del Apéndice D: pickup dentro del periodo declarado; drop-off posterior cuando se usa duración; distancia no negativa revisada junto con duración; zonas presentes en el lookup o marcadas como desconocidas; control de filas, faltantes, proveedor y mes; revisión de coincidencias en claves compuestas sin eliminación automática; zona horaria y franjas idénticas. Las zonas con cobertura insuficiente se excluyen con una regla previa o se mantienen marcadas fuera del ajuste. Toda exclusión informa cantidad y sensibilidad.

Variables derivadas mínimas por zona:

- pickups medios por hora;
- proporción de pickups en mañana, tarde, noche y madrugada, con cortes documentados;

- proporción de fin de semana;
- variabilidad entre días;
- cantidad de destinos distintos o entropía OD;
- duración o distancia mediana de viajes originados, tras controles de validez.

Las cuatro proporciones de franja son composicionales y suman uno; el equipo debe reconocer su redundancia y justificar cómo las representa. Volumen y forma temporal se analizan por separado o se ponderan explícitamente. Borough, Zone y service_zone sirven para identificación y caracterización, no deben dominar la formación de grupos por codificación arbitraria.

Consigna. Definir características comparables por zona, aplicar al menos dos estrategias de agrupamiento y caracterizar los segmentos según demanda observada, temporalidad, diversidad de destinos u otra dimensión operativa permitida. Una comparación válida podría enfrentar K-means con jerárquico sobre una representación euclídea común, o K-means con DBSCAN explicando que el segundo admite ruido. No es suficiente ejecutar dos algoritmos con sus valores predeterminados.

Protocolo mínimo:

1. construir una tabla reproducible de una fila por zona y mostrar cobertura;
2. auditar distribuciones, faltantes, extremos, correlaciones y bloques de variables;
3. ajustar escalado dentro del pipeline y justificar métrica y ponderación;
4. explorar hiperparámetros en rangos razonables, sin usar una sola métrica como respuesta;
5. comparar inercia cuando corresponda, silhouette, Davies-Bouldin, tamaños y casos fronterizos;
6. medir variabilidad por inicialización y estabilidad por remuestreo o por mes;
7. caracterizar cada segmento con estadísticas robustas y perfiles horarios;
8. revisar zonas inestables, sin correspondencia y etiquetadas como ruido;
9. documentar elección, alternativas descartadas y límites.

Estabilidad temporal. Una opción es ajustar la definición y el transformador en febrero-marzo, asignar o reevaluar abril y comparar perfiles. Otra es repetir todo el procedimiento por mes y emparejar grupos según centroides o coasignación. La etiqueta numérica no tiene identidad: el “grupo 1” de dos ejecuciones no se compara por número, sino por composición o prototipo. Debe distinguirse estabilidad de centroides, de miembros y de caracterización.

Ficha interpretativa obligatoria por segmento:

Campo	Contenido esperado
Nombre descriptivo	Patrón observable, por ejemplo “volumen alto con concentración diurna”
Tamaño	Número y proporción de zonas
Perfil central	Medianas, intervalos y perfil temporal
Diferencias	Variables que lo separan, con magnitud
Variabilidad interna	Dispersión y observaciones fronterizas
Estabilidad	Inicialización, remuestreo y meses

Campo	Contenido esperado
Cobertura	Registros y periodos representados
Uso posible	Insumo descriptivo para pronóstico o prioridad didáctica
Límite	Qué no puede inferirse de ese segmento

Modalidad de trabajo: definición común de variables; ajuste, validación e interpretación individuales.

Evidencia individual: notebook con preprocesamiento, selección razonada de hiperparámetros, visualización de grupos, análisis de estabilidad y ficha interpretativa de cada segmento. El capítulo desarrolla teoría y pseudocódigo; la implementación reproducible corresponde a la actividad.

Criterios de aprobación:

- las escalas y métricas son coherentes con las variables;
- la selección de grupos combina métricas, estabilidad y utilidad;
- las dos estrategias se comparan bajo un protocolo defendible;
- zonas con cobertura insuficiente y ruido reciben tratamiento explícito;
- la interpretación no confunde separación algorítmica con categorías reales;
- nombres, mapas y conclusiones describen exclusivamente perfiles operativos de pickups reportados.

Restricción interpretativa. Los grupos son perfiles algorítmicos de viajes de taxi amarillo observados, no categorías socioeconómicas de barrios, residentes, pasajeros o conductores. No se permiten inferencias sobre ingreso, vulnerabilidad, necesidad social, seguridad, calidad urbana ni composición demográfica. Borough y Zone localizan y describen cobertura; no explican causalmente los grupos. Cualquier extensión contextual requiere una fuente, contrato y pregunta nuevos.

Aporte al laboratorio: define perfiles de zonas que podrán utilizarse como insumo en el pronóstico y en una regla didáctica de prioridad. No constituye una optimización de flota porque los datos no observan oferta disponible ni ubicación de vehículos libres.

13.4. Evaluación, interpretación y anomalías

Evaluar clustering requiere triangular evidencia. Las métricas internas usan la misma geometría que generó los grupos y pueden premiar sus supuestos. La evaluación externa compara con información independiente, pero una referencia puede ser incompleta o responder a otra pregunta. La estabilidad estudia cuánto cambia el resultado. La caracterización y la utilidad determinan si las diferencias pueden explicarse y usarse responsablemente.

13.4.1. Inercia

La inercia de K-means es su función objetivo:

$$W_K = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mu_k\|_2^2.$$

Mide dispersión cuadrática dentro de grupos en el espacio transformado. Un valor menor indica que los centroides resumen mejor las observaciones bajo esa geometría. No posee escala universal: cambia con unidades, cantidad de observaciones, dimensión y varianza. Solo es comparable entre soluciones sobre exactamente los mismos datos y preprocesamiento.

W_K nunca aumenta al incrementar K . El cociente o reducción $W_{K-1} - W_K$ puede mostrar rendimientos decrecientes. En el gráfico del codo se busca una transición entre mejora sustancial y refinamiento pequeño. Si la curva es suave, no debe inventarse un quiebre. Métodos geométricos para detectar el codo formalizan una heurística, no convierten la curva en verdad.

La inercia favorece grupos compactos y penaliza fuertemente extremos. Puede preferir subdividir una nube grande antes que representar un grupo pequeño separado. Tampoco evalúa separación directamente: dos centroides cercanos podrían producir baja dispersión si los grupos son muy compactos. Una inercia baja con un grupo de una observación no implica una segmentación útil.

Se recomienda reportar la distribución de inercia entre reinicios, no solo el mínimo. Una dispersión amplia revela sensibilidad de optimización. También puede normalizarse descriptivamente por inercia total respecto de la media global:

$$R_K^2 = 1 - \frac{W_K}{T}, \quad T = \sum_i \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2,$$

interpretándola como proporción de dispersión representada, no como desempeño predictivo. Su aumento monótonico mantiene el problema de selección.

13.4.2. Coeficiente Silhouette

Para una observación i , sea $a(i)$ la distancia media a las demás observaciones de su grupo. Sea $b(i)$ la menor distancia media desde i a cualquier otro grupo. El coeficiente silhouette es

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

Toma valores entre -1 y 1 . Valores cercanos a 1 sugieren buena cohesión y separación; alrededor de cero indican frontera; negativos señalan que, en promedio, la observación está más cerca de otro grupo. Para un grupo unitario suele definirse $s(i) = 0$ por convención.

La media $\bar{s}$ resume una solución, pero oculta heterogeneidad. Un gráfico por grupo ordena silhouettes individuales y muestra grupos compactos, solapados o pequeños. Deben reportarse media, mediana, proporción negativa y distribución por grupo. Una media alta impulsada por un grupo grande no compensa necesariamente otro incoherente.

Silhouette depende de la métrica y tiende a favorecer grupos convexos y bien separados. Puede penalizar estructuras de densidad no convexas que son válidas para DBSCAN. Para soluciones con ruido hay varias convenciones: excluir el ruido, tratarlo como grupo o asignar cero. Cada una responde algo distinto y debe declararse; excluir muchos puntos puede inflar artificialmente la cifra.

La métrica puede orientar el diagnóstico. Observaciones con $s(i) < 0$ se revisan como fronteras, errores potenciales o transiciones. Comparar silhouette bajo la métrica de formación y una métrica alternativa defendible informa sensibilidad. No es correcto elegir representación y K explorando muchas opciones y presentar el máximo como si proviniera de una prueba independiente.

13.4.3. Índice Davies-Bouldin

El índice Davies-Bouldin compara dispersión de grupos con separación entre representantes. Sea

$$S_k = \frac{1}{|C_k|} \sum_{i \in C_k} \|\mathbf{x}_i - \mu_k\|_2$$

la dispersión del grupo k , y $M_{kl} = \|\mu_k - \mu_l\|_2$ la distancia entre centroides. Entonces

$$DB = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} \frac{S_k + S_l}{M_{kl}}.$$

Valores menores son preferibles: indican dispersiones pequeñas respecto de la separación. El máximo selecciona para cada grupo su rival más problemático. Examinar esos pares aporta más información que la media final: revela qué segmentos se confunden.

El índice no tiene un umbral universal y solo compara soluciones sobre la misma representación. Favorece grupos aproximadamente esféricos descritos por centroides. Puede valorar mal formas arbitrarias y es sensible a extremos. Si dos centroides coinciden, el denominador plantea un caso degenerado que señala una partición problemática.

Davies-Bouldin y silhouette no son pruebas independientes de la representación: ambos reutilizan distancias. Pueden discrepar porque resumen cohesión y separación de modo distinto. Frente a una discrepancia se inspeccionan tamaños, pares rivales y observaciones fronteras; no se promedian métricas sin fundamento. Una tabla multicriterio conserva direcciones: inercia y Davies-Bouldin se minimizan; silhouette se maximiza.

La selección responsable no consiste en buscar la fila que gana todas las columnas. Puede no existir. Se identifican soluciones dominadas, se conserva un conjunto de candidatas y se decide según estabilidad, interpretabilidad y uso. Las diferencias pequeñas entre valores no deberían presentarse como decisivas sin cuantificar variabilidad por remuestreo.

13.4.4. Evaluación externa

La evaluación externa compara la partición con etiquetas o relaciones que no determinaron el ajuste. No supone que las etiquetas sean la verdad del clustering:

pueden representar otra taxonomía. Su valor radica en responder si la estructura recupera una referencia relevante.

Una tabla de contingencia n_{kr} cruza grupo k y clase externa r . La **pureza** asigna a cada grupo su clase mayoritaria:

$$\text{pureza} = \frac{1}{n} \sum_k \max_r n_{kr}.$$

Es fácil de interpretar, pero aumenta al crear más grupos y alcanza uno con grupos unitarios. No corrige coincidencia aleatoria.

El índice de Rand considera pares juntos o separados en ambas particiones. Su versión ajustada, ARI, corrige el acuerdo esperado por azar y suele tomar valor 0 bajo acuerdo aleatorio, 1 en coincidencia perfecta y a veces valores negativos. La información mutua normalizada compara dependencia entre etiquetas con normalizaciones que deben especificarse. Estas medidas son invariantes a permutar nombres de grupos, propiedad indispensable porque las etiquetas numéricas son arbitrarias.

También puede existir evaluación externa sin clases. Expertos pueden juzgar pares “deberían estar juntos” o “deberían estar separados”; eventos posteriores pueden evaluar si los segmentos anticipan comportamientos sin haberlos usado para formarlos. Se debe evitar fuga: si la variable externa entró en la distancia, ya no valida externamente.

Una referencia imperfecta exige análisis de desacuerdos. Un ARI moderado puede indicar que el algoritmo encontró subestructura útil o que la representación ignoró una distinción importante. La matriz de contingencia y ejemplos concretos aclaran cuál. Si se prueban numerosas referencias y solo se reporta la más favorable, se incurre en selección oportunista.

La validez externa no autoriza causalidad. Que un grupo coincida con una categoría administrativa solo demuestra asociación bajo la muestra. Además, cualquier uso sensible requiere examinar impacto, representatividad y legitimidad de las variables, no solo acuerdo numérico.

13.4.5. Caracterización de clusters

Caracterizar significa describir qué distingue a cada grupo y cuánta heterogeneidad contiene. El perfil incluye tamaño, medidas centrales, dispersión, distribuciones y observaciones representativas. Para variables asimétricas se prefieren mediana y cuantiles; para proporciones se informa su estructura conjunta; para categorías, frecuencias con denominadores.

Conviene separar tres conjuntos de variables:

- **formación**, utilizadas por el algoritmo;
- **caracterización**, reservadas para comprender los grupos;
- **resultado**, observadas después y usadas para evaluación prospectiva cuando sea legítimo.

Las diferencias en variables de formación son esperables y no constituyen descubrimiento independiente. Una variable de caracterización puede aportar contexto, pero si se examinan cientos aparecerán asociaciones por azar. Deben

informarse magnitudes y, cuando corresponda, incertidumbre y corrección por multiplicidad, no solo significación.

Los centroides son útiles, pero el promedio puede no representar a nadie. Se pueden presentar medoides, observaciones reales con menor distancia media a su grupo, junto con casos fronterizos. Un nombre como “grupo 2” es neutral pero poco informativo; uno como “frecuencia alta y variabilidad baja” es descriptivo. Etiquetas como “buenos”, “problemáticos” o “vulnerables” añaden juicios no contenidos en los datos.

Una ficha de segmento debería responder: qué observaciones contiene, qué variables lo distinguen, cuánto se solapa, qué tan estable es, qué casos no representa y para qué decisión podría servir. Visualizaciones recomendables son perfiles normalizados con intervalos, distribuciones completas y mapas solo cuando la dimensión espacial tenga sentido. Los ejes deben conservar unidades interpretables además de valores estandarizados.

La caracterización debe repetirse en submuestras o periodos. Un grupo cuya descripción cambia aunque sus etiquetas parezcan estables puede haber sufrido deriva interna. Por el contrario, centroides similares con miembros intercambiables pueden seguir siendo útiles para una política agregada. Estabilidad de miembros y estabilidad de perfil son propiedades distintas.

13.4.6. Detección no supervisada de anomalías

Una anomalía es una observación incompatible con un patrón de referencia bajo una representación, escala y contexto. Puede ser **global**, alejada del conjunto; **contextual**, extraña dadas condiciones como hora o estación; o **colectiva**, normal individualmente pero inusual como secuencia o grupo. La definición debe preceder al método.

Una puntuación simple basada en centro es

$$A_i = \|\mathbf{x}_i - \mu_{C_i}\|,$$

pero solo detecta desviaciones respecto de grupos compactos. La distancia robusta de Mahalanobis incorpora covarianza:

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)},$$

aunque requiere estimación estable y es sensible si media y covarianza no son robustas. DBSCAN etiqueta puntos fuera de regiones densas, y otros métodos usan densidad local, aislamiento o error de reconstrucción. Sus puntuaciones no son intercambiables.

Elegir un umbral define la carga de revisión y el balance entre omisiones y falsas alarmas. Sin etiquetas, puede usarse una cuota operativa o cuantiles, pero esto garantiza una cantidad, no una tasa de error. Si existe una muestra auditada, precisión entre los primeros casos, cobertura y tiempo de detección son más relevantes.

El flujo recomendado separa **detección** de **decisión**. Primero se genera una puntuación; luego se verifica calidad, se busca contexto, se registra una

resolución humana y se retroalimenta el sistema. Nunca se borran observaciones automáticamente porque sean raras. Los errores repetidos pueden ser densos y pasar inadvertidos, mientras casos válidos poco frecuentes pueden aparecer arriba.

La estabilidad de ranking se evalúa ante transformaciones, ventanas y remuestreo. Una anomalía persistente con explicación consistente merece mayor prioridad que un caso que oscila cerca del umbral. También debe vigilarse deriva: si el patrón normal cambia, un umbral histórico pierde significado.

13.4.7. Riesgos de sobreinterpretación

El primer riesgo es la **reificación**: tratar grupos calculados como entidades naturales. Los límites pueden ser continuos y depender de K . El segundo es la **causalidad espuria**: una separación describe asociación, no su mecanismo. El tercero es la **falacia ecológica**: atribuir a individuos propiedades observadas en unidades agregadas. El cuarto es convertir falta de cobertura en comportamiento.

Otros riesgos incluyen:

- escoger retrospectivamente la representación que confirma una expectativa;
- asignar nombres valorativos o estigmatizantes;
- ocultar observaciones fronterizas detrás de una etiqueta única;
- confundir alta estabilidad con relevancia: una división trivial por volumen puede ser estable;
- confundir baja estabilidad con inutilidad: una frontera continua puede requerir puntuaciones en vez de grupos;
- aplicar segmentos fuera del periodo o población de ajuste sin evaluar deriva;
- usar pertenencia grupal como sustituto de variables que no fueron observadas.

Las visualizaciones también engañan. Una proyección en dos dimensiones puede separar puntos que estaban cercanos o superponer los lejanos. Colores categóricos acentúan fronteras aunque las transiciones sean graduales. Deben acompañarse con métricas en el espacio de modelado y advertencias de proyección.

En aplicaciones con consecuencias, la agrupación puede crear bucles: una decisión basada en un segmento cambia la observación futura y parece confirmar el segmento. Se requiere registro de intervenciones y reevaluación. También se examina si variables proxy producen impactos desiguales, incluso cuando no se incluyeron atributos sensibles.

Una redacción prudente usa expresiones condicionales: “en los datos observados”, “bajo esta representación” y “el perfil se caracteriza por”. Declara incertidumbre, cobertura y alternativas. El objetivo no es debilitar el resultado, sino hacer explícito exactamente qué evidencia aporta.

13.4.8. Ejemplo práctico guiado: validación de una segmentación

Retomemos una segmentación de perfiles operativos con cuatro soluciones candidatas: K-means con tres o cuatro grupos y jerárquico con tres o cuatro. La validación se realiza sin seleccionar primero la opción visualmente más atractiva.

Paso 1: integridad y representación. Se verifica unidad de análisis, periodo, faltantes, transformaciones y contribución de bloques. Se repite con escalado

estándar y robusto. Si una variable domina más de la mitad de la distancia en la mayoría de pares, se revisa su peso.

Paso 2: evaluación interna. Se calculan inercia para K-means, silhouette y Davies-Bouldin para las cuatro alternativas. Se observan distribuciones por grupo y pares rivales. Las diferencias pequeñas se consideran empates prácticos hasta estudiar variabilidad.

Paso 3: estabilidad algorítmica. Cada K-means se reinicia muchas veces. Se comparan inercias y ARI entre corridas después de alinear particiones implícitamente mediante una medida invariante. Una solución cuya mejor corrida es excepcional pero rara no se considera robusta.

Paso 4: estabilidad muestral y temporal. Se remuestran observaciones, se reajusta todo el pipeline y se calcula una matriz de coasignación. Luego se repite por periodos. Se examinan estabilidad de miembros, centroides y fichas, no solo un promedio.

Paso 5: caracterización ciega a nombres. Se elaboran perfiles con medianas, cuantiles y tamaños antes de asignar etiquetas narrativas. Expertos del proceso valoran si las diferencias son comprensibles y relevantes, sin conocer qué algoritmo produjo cada opción.

Paso 6: casos problemáticos. Se revisan silhouettes negativas, grupos diminutos y observaciones que cambian frecuentemente. Estas unidades pueden recibir una puntuación de pertenencia o marca fronteriza en vez de una asignación tajante.

Supóngase que cuatro grupos mejora levemente silhouette, pero uno contiene 3 % de observaciones, cambia mucho por periodo y no posee descripción estable. La solución de tres grupos presenta métricas apenas inferiores, coasignación más nítida y perfiles reproducibles. Se elige tres por parsimonia y estabilidad, dejando constancia de que la cuarta división es una hipótesis exploratoria.

El informe final contiene una tabla de evidencia, fichas, análisis de sensibilidad, lista de casos no representados y condiciones de actualización. La conclusión evita decir que las métricas “demuestran” tres grupos: sostiene que, entre las alternativas evaluadas, tres ofrece el compromiso más defendible para el uso declarado.

Síntesis

El aprendizaje no supervisado no elimina la necesidad de formular una pregunta; la hace más visible. La unidad de análisis, las variables, el escalado y la métrica definen qué significa semejanza. K-means resume grupos compactos mediante centroides y exige atender a inicialización, mínimos locales y elección de K . El clustering jerárquico muestra estructuras anidadas cuya forma depende del enlace. DBSCAN busca conectividad por densidad, admite ruido y requiere estudiar sensibilidad a ε y $\minPts$. Los SOM organizan prototipos en una rejilla y necesitan diagnósticos de cuantización, topología y estabilidad.

Ninguna métrica basta por sí sola. Inercia disminuye al aumentar grupos; silhouette y Davies-Bouldin incorporan supuestos geométricos; una referencia externa puede responder a otra taxonomía. La validación combina evidencia interna, estabilidad algorítmica, remuestreo, repetición temporal, caracterización

y utilidad. Una anomalía es relativa al contexto y activa investigación, no una eliminación automática.

La principal competencia es sostener una conclusión proporcional a la evidencia: describir patrones sin esencializarlos, reconocer casos fronterizos y declarar dónde deja de ser válida la solución.

Glosario

Agrupamiento o clustering: proceso de organizar observaciones según una noción explícita o implícita de semejanza.

Anomalía contextual: observación inusual dadas ciertas condiciones, aunque pueda ser normal en otro contexto.

BMU: unidad del mapa autoorganizado cuyo prototipo está más cerca de una observación.

Centroide: media vectorial de las observaciones de un grupo; no tiene que ser una observación real.

Coasignación: frecuencia con que dos observaciones aparecen en el mismo grupo a través de ejecuciones.

Conectividad por densidad: relación que une puntos mediante cadenas de vecindades densas.

Dendrograma: árbol que representa fusiones o divisiones y sus alturas de disimilitud.

Distancia: función que cuantifica diferencia; su elección expresa una hipótesis sobre semejanza.

Enlace: regla para calcular disimilitud entre grupos en clustering jerárquico.

Estabilidad: grado de conservación de una solución ante semillas, muestras, periodos o decisiones plausibles de modelado.

Grupo frontera: expresión descriptiva para observaciones con pertenencia inestable o cercanía comparable a varios grupos.

Inercia: suma de distancias euclídeas al cuadrado entre observaciones y centroides en K-means.

Medoide: observación real que representa un grupo por su posición central según una disimilitud.

Métrica interna: criterio calculado con datos y partición, sin referencia externa.

Prototipo: vector que resume una región del espacio, como un centroide o nodo de SOM.

Ruido en DBSCAN: punto no conectado a una región densa bajo parámetros dados; no equivale necesariamente a error.

Silhouette: medida individual de cohesión respecto del grupo propio y separación respecto del grupo alternativo más próximo.

Preguntas de revisión

1. ¿Por qué la selección de variables y el escalado forman parte del modelo no supervisado?
2. ¿En qué situación Manhattan y Euclídea pueden producir vecinos diferentes? Construya un ejemplo.
3. ¿Qué información ignora la similitud coseno y cuándo podría ser importante conservarla?
4. ¿Por qué codificar una categoría nominal mediante enteros puede fabricar distancias?
5. ¿Qué significa asignar pesos iguales a variables estandarizadas? ¿Es siempre deseable?
6. Explique por qué K-means converge sin garantizar el óptimo global.
7. ¿Qué diferencia existe entre variabilidad por semilla y estabilidad por remuestreo?
8. ¿Por qué la inercia no selecciona por sí sola el número de grupos?
9. Compare el efecto de enlace simple, completo, promedio y Ward ante un punto extremo.
10. ¿Qué información del dendrograma cambia al rotar una rama y cuál permanece?
11. Distinga punto núcleo, frontera y ruido en DBSCAN.
12. ¿Por qué un único ε puede fallar cuando las densidades son muy distintas?
13. ¿Qué representan el error de cuantización y el error topográfico de un SOM?
14. ¿Cómo puede una proyección bidimensional inducir una interpretación errónea de separación?
15. ¿Por qué silhouette y Davies-Bouldin no son evidencia independiente de la representación?
16. ¿En qué se diferencian pureza y Rand ajustado frente al aumento del número de grupos?
17. Proponga una ficha de segmento que exprese incertidumbre y casos fronterizos.
18. ¿Por qué una etiqueta de ruido no autoriza a eliminar una observación?
19. Distinga estabilidad de miembros, estabilidad de centroides y estabilidad de caracterización.
20. ¿Qué afirmaciones están prohibidas al interpretar los segmentos de MOV-03 y por qué?

Actividad integradora del capítulo

Diseñe, sin implementar, un protocolo de segmentación para un conjunto de unidades descritas por dos variables numéricas, una ordinal, una nominal y una proporción temporal. El documento debe contener:

1. pregunta, unidad de análisis, cobertura y uso previsto;
2. tratamiento de faltantes y codificación de cada tipo de variable;
3. dos representaciones alternativas y la hipótesis de semejanza de cada una;
4. selección justificada de dos algoritmos entre K-means, jerárquico, DBSCAN y SOM;
5. pseudocódigo del flujo completo, desde auditoría hasta caracterización;
6. plan de selección de hiperparámetros sin depender de una única métrica;
7. evaluación de estabilidad ante semillas, remuestreo y un cambio plausible de

- escala;
- 8. estrategia para observaciones fronterizas y anomalías;
- 9. ficha de segmentos con nombres puramente descriptivos;
- 10. tres límites interpretativos y una condición que obligaría a reajustar el modelo.

La evaluación prioriza coherencia entre pregunta, representación y algoritmo; calidad de diagnósticos; capacidad para distinguir estructura de artefactos; y prudencia de las conclusiones. Una respuesta excelente puede concluir que ninguna partición es suficientemente estable si sustenta esa decisión con evidencia.

Capítulo 14. Análisis y pronóstico de series temporales

Una serie temporal es una colección de observaciones ordenadas por el instante en que se producen. Esta definición parece sencilla, pero modifica de manera profunda el análisis estadístico: dos observaciones cercanas pueden depender entre sí, la distribución puede cambiar con el calendario y el futuro no está disponible al construir una predicción. Mezclar aleatoriamente los registros, como se haría en muchos problemas supervisados, destruye justamente la estructura que se desea aprender.

El propósito de este capítulo es desarrollar un lenguaje riguroso para describir, modelar y evaluar series. Se distinguirán frecuencia, tendencia, estacionalidad, ciclo, ruido, faltantes y valores atípicos; se estudiarán dependencia, estacionariedad, autocorrelación y transformaciones; se derivará la familia ARIMA; y se establecerá un protocolo de evaluación temporal. Los ejemplos proceden de movilidad, energía, comercio minorista y manufactura. El objetivo no es elegir un algoritmo por prestigio, sino formular un pronóstico reproducible para un horizonte, una información disponible y una decisión concretos.

Sea y_t el valor observado en el instante o intervalo t , con $t = 1, \dots, n$. En una serie de conteos, y_t puede ser la cantidad de pickups de taxi en una zona durante una hora; en energía, la demanda eléctrica de un edificio cada quince minutos; en comercio, las unidades vendidas por día. El origen de tiempo, la zona horaria, la frecuencia y la regla de agregación forman parte de la definición de la variable. Sin ellos, la sucesión de números no constituye un objeto analítico bien especificado.

Convenciones de lectura. Una letra mayúscula, como Y_t , denota una variable aleatoria; la minúscula y_t , su realización observada. $\hat{y}_{t+h|t}$ es el pronóstico emitido al terminar t para el objetivo $t + h$, y $\mathcal{F}_t$ representa toda la información legítimamente disponible en ese origen. El rezago k siempre se mide en pasos de la frecuencia declarada: en una serie horaria, $k = 24$ equivale a un día solo si la cuadrícula y el tratamiento del horario civil están bien definidos. Los parámetros verdaderos se distinguen de sus estimaciones cuando ello afecta la derivación; en explicaciones operativas se omite el sombrero si no existe ambigüedad.

Pronosticar no equivale a explicar causalmente. Un modelo puede aprovechar que la demanda de energía a las 10:00 se parece a la de las 9:00 sin afirmar que una lectura cause la siguiente. Tampoco equivale a reconstruir datos: la imputación estima un valor no observado dentro de una historia, mientras el pronóstico anticipa un valor todavía no realizado. Ambas tareas pueden compartir métodos, pero poseen conjuntos de información y criterios diferentes.

La secuencia recomendada a lo largo del capítulo es: definir el objeto temporal;

auditar su medición; proponer estructura; transformar solo si existe una razón; ajustar candidatos parsimoniosos; simular pronósticos históricos; y conectar error e incertidumbre con una decisión. Saltar directamente al ajuste suele producir una curva numéricamente correcta para una pregunta mal definida. Por eso cada ejemplo explicita unidad, origen y horizonte antes de mencionar el modelo.

14.1. Estructura de las series temporales

El primer análisis debe responder qué se observó, cuándo y mediante qué proceso de medición. Una gráfica temporal es indispensable, aunque no suficiente. Conviene acompañarla con perfiles por hora, día de semana o mes; distribuciones condicionadas por calendario; cobertura; y anotaciones de eventos conocidos. La estructura visual sugiere hipótesis, no las demuestra. Una oscilación puede ser estacionalidad real, un cambio del sistema de captura o la combinación de ambas.

14.1.1. Índice temporal y frecuencia

El índice temporal ordena las observaciones y define distancias entre ellas. Puede ser regular, cuando $t_{i+1} - t_i = \Delta$ para todo i , o irregular, cuando los intervalos varían. ARIMA y muchas herramientas de descomposición presuponen una cuadrícula regular. Por ello, antes de modelar eventos individuales suele agregarse su cantidad o magnitud en intervalos fijos.

La **frecuencia de muestreo** es el ritmo al que se obtienen observaciones: cada minuto, hora, día o semana. La **frecuencia de un patrón** es la cantidad de repeticiones por unidad de tiempo. Su inversa es el periodo. Si un perfil se repite cada 24 observaciones horarias, su periodo es $m = 24$ y su frecuencia discreta es $1/24$ ciclos por observación. En una serie horaria también puede existir un periodo semanal $m = 168$. Debe evitarse confundir la granularidad del dato con la periodicidad de un fenómeno.

Agregar modifica la pregunta. Si x_i son pickups individuales y I_t es la hora t , el conteo horario es

$$y_t = \sum_i \mathbf{1}(x_i \text{ ocurre en } I_t).$$

Una suma conserva volúmenes; una media representa nivel medio; un máximo representa carga pico. Ninguna agregación es universal. El intervalo debe ser suficientemente corto para la decisión y suficientemente largo para evitar una serie casi enteramente nula o dominada por ruido de captura.

Una cuadrícula regular exige distinguir un **cero observado** de un **intervalo sin cobertura**. En una tienda abierta y correctamente medida, cero ventas puede ser un valor legítimo. Si el sistema dejó de transmitir, completar con cero inventa una caída. También deben fijarse zona horaria, horario de verano, límites inclusivos de los intervalos y calendario comercial. Dos registros con la misma hora local durante un cambio de horario pueden corresponder a instantes diferentes.

Fallo frecuente. Inferir la frecuencia solo porque las marcas de tiempo “parecen horarias”. Deben calcularse diferencias, duplicados y huecos. Si una planta registra solo cuando cambia el sensor, la ausencia de fila no significa valor cero ni frecuencia regular.

14.1.2. Tendencia

La tendencia T_t representa una evolución suave del nivel a largo plazo respecto de la escala estudiada. Puede ser creciente, decreciente, aproximadamente lineal, curvada o presentar cambios de pendiente. Una formulación local sencilla es

$$T_t = \beta_0 + \beta_1 t,$$

pero una recta no debe extrapolarse mecánicamente. La expansión de una cadena minorista puede impulsar ventas durante meses y luego saturarse; una mejora de eficiencia puede reducir gradualmente el consumo energético por unidad producida; una obra puede cambiar de forma abrupta los flujos de movilidad.

La tendencia depende de la ventana. Una subida durante dos semanas puede ser parte de un ciclo mensual, mientras que en una ventana de tres años podría resultar irrelevante. Para reconocerla se emplean medias o medianas móviles, suavizado y descomposición. Una media móvil centrada de ancho impar $2k + 1$ es

$$\tilde{T}_t = \frac{1}{2k+1} \sum_{j=-k}^k y_{t+j}.$$

Es útil para descripción retrospectiva, pero usa futuro respecto de t y no puede convertirse sin más en una característica predictiva. En operación se utiliza una versión rezagada calculada únicamente con $y_{t-k}, \dots, y_t$.

Tendencia no significa causalidad. Una serie creciente no prueba que el tiempo cause el cambio; el tiempo resume factores omitidos. Tampoco garantiza continuación. Para pronosticar debe preguntarse qué mecanismo podría sostenerla y hasta qué horizonte. Los cambios estructurales, como una nueva tarifa eléctrica o una modificación de turnos de producción, obligan a reestimar el nivel.

Ejemplo. Las ventas semanales de una familia de productos aumentan tras ampliar el número de locales. Si se modela el total, aparece tendencia; si se divide por locales activos, puede desaparecer. Ambas series son válidas, pero responden preguntas diferentes: volumen total frente a productividad media.

14.1.3. Estacionalidad

La estacionalidad es una variación sistemática asociada a posiciones conocidas de un calendario y repetida con periodo aproximadamente fijo. Ejemplos son las puntas de demanda eléctrica a ciertas horas, la reducción de actividad manufacturera durante fines de semana o el perfil semanal de pickups. Si el periodo es m , una representación aditiva escribe $S_{t+m} = S_t$ y suele imponer $\sum_{j=1}^m S_j = 0$ para identificar el nivel.

Una serie puede tener varias estacionalidades: intradiaria, semanal y anual. Con datos horarios, $m = 24$ describe posición horaria y $m = 168$ combinación de hora y día. La estacionalidad de calendario no siempre ocupa igual número de observaciones: meses y festividades móviles tienen duración variable. En esos casos son preferibles indicadores de calendario o modelos con múltiples componentes antes que forzar un único periodo.

La amplitud puede ser constante o proporcional al nivel. En el primer caso, una estructura aditiva

$$y_t = T_t + S_t + R_t$$

es razonable. Si los picos crecen al crecer el nivel, puede ser más apropiada una estructura multiplicativa

$$y_t = T_t S_t R_t,$$

con componentes positivos. Al tomar logaritmos, esta última se vuelve aditiva: $\log y_t = \log T_t + \log S_t + \log R_t$.

Reconocer estacionalidad requiere varias repeticiones. Dos semanas horarias permiten ver indicios semanales, pero ofrecen poca evidencia sobre estabilidad; tres meses no sostienen una estacionalidad anual. Además, una media por hora calculada con todo el conjunto filtraría información futura si se usa como entrada del modelo. Dentro de cada corte de validación debe aprenderse solo con el pasado.

Fallo frecuente. Llamar “estacional” a cualquier onda. Si su duración y fecha no son relativamente previsibles, puede tratarse de un ciclo. Una promoción que cambia de semana cada año requiere una variable de promoción conocida, no necesariamente un término estacional fijo.

14.1.4. Ciclos

Los ciclos son movimientos de expansión y contracción con duración o amplitud no estrictamente fijas. Se diferencian de la estacionalidad porque no están anclados de manera estable a una posición del calendario. Los ciclos de pedidos industriales, reposición de inventario o actividad económica pueden extenderse durante periodos variables y cambiar de forma.

Una representación conceptual es

$$y_t = T_t + C_t + S_t + R_t,$$

donde C_t varía más lentamente que el ruido, pero no satisface necesariamente $C_{t+m} = C_t$. En ventanas cortas, ciclo y tendencia pueden ser inseparables. Lo que parece una tendencia descendente puede ser apenas la fase descendente de un ciclo largo. Por ello, atribuir componentes requiere contexto y longitud suficiente.

El ciclo no debe estimarse escogiendo a posteriori una onda que ajuste bien. Esa práctica produce una explicación visual sin capacidad predictiva. Resultan más defendibles variables vinculadas al mecanismo: cartera de pedidos, inventario, precio o índice de actividad, siempre que su valor futuro sea conocido o pueda pronosticarse honestamente.

Ejemplo. Una fábrica recibe lotes grandes cada cuatro a siete semanas según contratos. La carga de máquinas exhibe máximos recurrentes, pero no un periodo fijo. Tratarla como estacionalidad mensual genera pronósticos desfasados. Incorporar pedidos confirmados puede explicar el ciclo mejor que imponer $m = 30$.

En series breves, conviene describir el movimiento como fluctuación de baja frecuencia y reconocer incertidumbre, en vez de bautizarlo como ciclo económico. La distinción tiene consecuencias: una estacionalidad estable admite un baseline estacional; un ciclo irregular exige información adicional o intervalos más amplios.

14.1.5. Ruido

El ruido R_t reúne variación no explicada por los componentes considerados. No es sinónimo de dato inútil. Puede contener fluctuación aleatoria inherente, error de medición, factores omitidos o estructura que el modelo aún no capturó. Solo después del ajuste se evalúa si el residuo se aproxima a una innovación impredecible.

En un modelo elemental,

$$y_t = \mu + \varepsilon_t, \quad E(\varepsilon_t) = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2,$$

y el ruido blanco satisface además $\text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0$ para $k \neq 0$. Incorrelación no implica independencia, salvo bajo supuestos adicionales como normalidad conjunta. Un residuo puede tener autocorrelación nula y conservar cambios de varianza o colas pesadas.

La relación señal-ruido depende de la frecuencia. El consumo energético minuto a minuto puede ser muy irregular; al agregar por hora se atenúan fluctuaciones, aunque también se pierden picos operativos. El alisado mejora legibilidad, no crea información. Además, el ruido de conteos suele aumentar con el nivel: una aproximación de Poisson tiene media y varianza iguales, por lo que asumir varianza constante puede ser inadecuado.

No debe “limpiarse” toda desviación. Un pico de ventas durante una campaña es señal para un sistema que deba anticipar campañas, aunque sea ruido para un análisis de demanda ordinaria. La clasificación depende del objetivo y de la información disponible. El procedimiento correcto conserva el dato original, registra cualquier tratamiento y evalúa sensibilidad con y sin él.

14.1.6. Valores faltantes y atípicos temporales

Un faltante temporal puede aparecer como celda vacía dentro de una cuadrícula o como intervalo completamente ausente. Primero se determina su causa: falta de actividad, interrupción de captura, cierre planificado o error de integración. El mecanismo afecta el tratamiento. Completar siempre con cero sesga nivel y estacionalidad; interpolar siempre suaviza picos y reduce artificialmente el error.

Las opciones incluyen mantener el faltante y usar métodos compatibles, imputar con último valor, interpolación, mediana estacional o modelo. Toda imputación para pronóstico debe ser **causal**: al instante t no puede consultar y_{t+1} . La interpolación bilateral es válida para reconstrucción histórica claramente etiquetada, pero no para simular operación en una validación.

Un atípico temporal es una observación incompatible con su contexto. Puede ser:

- **puntual**, como una lectura extrema aislada;
- **contextual**, normal a mediodía pero anómala de madrugada;
- **colectiva**, una secuencia moderada cuya duración es excepcional;

- **cambio de nivel**, desde el cual la serie adopta otro régimen.

Para detectarlos se comparan residuos robustos, mediana y desviación absoluta mediana, bandas por posición estacional o modelos de intervención. Si r_t es un residuo y $M = \text{mediana}(r_t)$, una puntuación robusta puede ser

$$z_t^{(r)} = \frac{0.6745(r_t - M)}{\text{mediana } |r_t - M|}.$$

El umbral identifica candidatos, no errores confirmados. Un pico de pickups tras un evento puede ser real; una caída simultánea en muchas zonas y proveedores puede sugerir cobertura. Sustituir atípicos sin auditoría elimina precisamente los eventos de mayor interés.

Regla práctica: conservar una columna de valor original, otra de valor tratado y una bandera con motivo, método y momento de detección. Evaluar el modelo tanto en condiciones ordinarias como ante episodios extremos.

14.1.7. Descomposición

Descomponer consiste en representar la serie mediante componentes interpretables. En el esquema aditivo,

$$y_t = T_t + S_t + R_t,$$

la magnitud estacional no depende del nivel. En el multiplicativo, $y_t = T_t S_t R_t$, las variaciones son relativas. La elección debe apoyarse en gráficos y estabilidad de varianza, no en una preferencia automática.

La descomposición clásica con periodo m sigue, conceptualmente, estos pasos:

1. estimar tendencia-ciclo mediante una media móvil de longitud relacionada con m ;
2. quitar tendencia, restando o dividiendo;
3. promediar los valores destendenciados en cada posición estacional;
4. normalizar los índices estacionales;
5. definir el resto como lo no explicado.

Los extremos pierden estimaciones cuando la media es centrada y los atípicos contaminan promedios. Métodos robustos y suavizados locales toleran mejor cambios graduales en tendencia y estacionalidad. Aun así, la descomposición no identifica causas y sus componentes dependen del método, periodo y ventana.

Una descomposición retrospectiva puede usar observaciones a ambos lados de t para explicar el pasado. Un sistema de pronóstico no dispone de ese futuro. Esta diferencia es crucial: las componentes utilizadas como características deben recalcularse causalmente en cada origen de validación. De otro modo, la curva de tendencia cerca del corte transmite el comportamiento posterior.

La utilidad práctica es triple: revelar estructura, construir baselines y diagnosticar residuos. Si el resto conserva picos cada 24 rezagos, la estacionalidad no se eliminó. Si su amplitud aumenta con el nivel, puede faltar una transformación. Una descomposición bonita no prueba que el patrón sea estable fuera de muestra.

14.1.8. Ejemplo práctico guiado: descomposición de una serie de demanda

Considérese la demanda eléctrica horaria de una planta durante dieciséis semanas. La unidad es kWh por hora; la planta opera tres turnos de lunes a viernes y uno reducido los fines de semana. El objetivo es anticipar las próximas seis horas para programar cargas flexibles.

Inspección. La cuadrícula revela cuatro huecos por mantenimiento del medidor, que se marcan como falta de cobertura y no como consumo cero. La gráfica muestra un nivel lentamente creciente, máximos diurnos y mínimos dominicales. Los perfiles por hora y día sugieren periodos $m_1 = 24$ y $m_2 = 168$. Un pico aislado coincide con una prueba documentada de maquinaria y se conserva.

Hipótesis de estructura. Como la amplitud diaria crece con el nivel, se compara una descomposición aditiva sobre y_t con otra sobre $\log y_t$. La segunda produce una estacionalidad relativa más estable. Conceptualmente,

$$\log y_t = L_t + S_{24,t} + S_{168,t} + R_t.$$

El componente L_t aumenta tras incorporar una nueva línea; $S_{24,t}$ separa turnos; $S_{168,t}$ recoge el fin de semana. El resto muestra variación mayor durante cambios de turno, señal de que la varianza condicional aún no es uniforme.

Qué podría predecirse. El calendario de turnos y los perfiles diarios son parcialmente repetibles; el nuevo nivel puede extrapolarse con cautela durante seis horas. La prueba excepcional de maquinaria no es predecible sin agenda. Los huecos no deben enseñar falsas caídas. Si los turnos futuros son conocidos, constituyen una variable exógena legítima.

Contraste. Un baseline estacional $\hat{y}_{t+h|t} = y_{t+h-168}$ ofrece una referencia fuerte. Si el modelo complejo no lo supera en varios orígenes, la descomposición no justifica mayor complejidad.

Preguntas de diagnóstico: ¿cambia la conclusión al excluir la semana de incorporación de la línea?, ¿el residuo mantiene autocorrelación?, ¿los intervalos cubren las horas de cambio de turno?, ¿una decisión a seis horas necesita modelar también el máximo, además del promedio?

14.2. Dependencia temporal y estacionariedad

La estructura temporal permite que el pasado informe sobre el futuro, pero invalida la suposición de observaciones intercambiables. Esta sección formaliza la dependencia y las condiciones bajo las cuales puede aprenderse una relación relativamente estable. Estacionarizar no es un ritual: es una estrategia para que los patrones estimados en el pasado sean transferibles al horizonte de interés.

14.2.1. Dependencia serial

Existe dependencia serial cuando la distribución de Y_t condicionada por valores pasados difiere de su distribución marginal. En términos simples, conocer $Y_{t-1}, Y_{t-2}, \dots$ cambia lo que se espera de Y_t . Una forma lineal se expresa

mediante covarianza; dependencias no lineales pueden existir aun con covarianza cero.

La dependencia puede originarse en inercia física, hábitos, inventarios, calendario o agregación. La temperatura de un edificio cambia gradualmente; las ventas de hoy afectan el inventario de mañana; la movilidad a las 9:00 se parece a la de otras mañanas. También puede ser espuria: dos observaciones comparten una tendencia y parecen correlacionadas sin interacción dinámica.

La esperanza condicional de un proceso de primer orden puede escribirse

$$E(Y_t | Y_{t-1}, Y_{t-2}, \dots) = g(Y_{t-1}).$$

Si, dado Y_{t-1} , el pasado más remoto no añade información, el proceso cumple una propiedad de Markov de orden uno. ARIMA no exige interpretar esa propiedad como causalidad; modela regularidades predictivas lineales.

La dirección temporal importa. Una correlación entre ventas y publicidad no indica si la publicidad anticipa ventas o fue decidida tras observarlas. Para usar una variable en $t + h$, debe conocerse en el origen t . La dependencia útil se define respecto del conjunto de información $\mathcal{F}_t$, no solo respecto de columnas disponibles retrospectivamente.

14.2.2. Estacionariedad

Un proceso es **estrictamente estacionario** si la distribución conjunta de $(Y_{t_1}, \dots, Y_{t_k})$ es igual a la de $(Y_{t_1+h}, \dots, Y_{t_k+h})$ para todo conjunto de tiempos y desplazamiento h . Es una condición fuerte. En práctica se usa estacionariedad débil o de segundo orden:

$$E(Y_t) = \mu, \quad \text{Var}(Y_t) = \sigma^2, \quad \text{Cov}(Y_t, Y_{t-k}) = \gamma_k,$$

donde media y varianza no dependen de t y la covarianza depende solo del rezago k .

Una serie con tendencia determinista no es estacionaria en media. Un paseo aleatorio

$$Y_t = Y_{t-1} + \varepsilon_t$$

tampoco lo es: aunque los incrementos tengan media cero, $\text{Var}(Y_t) = t\sigma_\varepsilon^2$ crece. Ambos casos pueden parecer ascendentes, pero requieren tratamientos distintos.

Las pruebas de raíz unitaria ayudan, pero tienen potencia limitada, dependen de términos deterministas y no sustituyen gráficos ni contexto. Una prueba puede no rechazar raíz unitaria en una serie corta; otra puede rechazarla debido a un cambio estructural. La pregunta operativa es si las relaciones usadas por el modelo permanecen suficientemente estables durante entrenamiento y uso.

La estacionalidad tampoco equivale a no estacionariedad irresoluble. Puede modelarse explícitamente o eliminarse mediante diferencias estacionales. En una serie con cambios de régimen, transformar no basta: conviene acortar ventana, añadir intervenciones o revisar el proceso generador.

14.2.3. Autocorrelación

La autocovarianza de rezago k es

$$\gamma_k = \text{Cov}(Y_t, Y_{t-k}),$$

y la autocorrelación es $\rho_k = \gamma_k / \gamma_0$. Para una muestra de media $\bar{y}$ se estima, según una convención habitual,

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2}.$$

La función de autocorrelación (ACF) representa $\hat{\rho}_k$ para distintos rezagos. Un máximo en $k = 24$ en datos horarios sugiere repetición diaria; máximos en múltiplos de 168 sugieren patrón semanal. Una caída muy lenta desde valores próximos a uno puede indicar tendencia o raíz unitaria, no necesariamente memoria de muchos órdenes.

Las bandas aproximadas $\pm 1.96/\sqrt{n}$ sirven como referencia bajo ruido blanco, pero no son pruebas independientes: se observan muchos rezagos y los estimadores están relacionados. Buscar un único punto que cruce la banda favorece falsos hallazgos.

Antes de interpretar la ACF deben tratarse tendencia y estacionalidad. Una serie minorista creciente mostrará correlaciones altas aun si las desviaciones alrededor de la tendencia son independientes. También importa la longitud: estimaciones a rezagos grandes utilizan menos pares y son inestables.

La ACF es descriptiva, no causal. Puede guiar órdenes y diagnosticar residuos, pero la elección final se valida fuera de muestra. Para residuos, autocorrelaciones importantes indican que queda información lineal aprovechable.

14.2.4. Autocorrelación parcial

La autocorrelación parcial de orden k mide la asociación lineal entre Y_t y Y_{t-k} después de controlar los rezagos intermedios $Y_{t-1}, \dots, Y_{t-k+1}$. Puede definirse como el coeficiente ϕ_{kk} de Y_{t-k} en la regresión

$$Y_t = c + \phi_{k1}Y_{t-1} + \dots + \phi_{kk}Y_{t-k} + u_t.$$

La función PACF grafica esos coeficientes. En un proceso AR(p) ideal, la PACF se corta tras p , mientras la ACF decae. En un MA(q), la ACF se corta tras q y la PACF decae. "Corte" significa que los valores poblacionales posteriores son cero; en muestras finitas nunca se observa una frontera perfecta.

La PACF distingue correlación directa de asociación transmitida. Si Y_t depende de Y_{t-1} y este de Y_{t-2} , la ACF en rezago 2 puede ser alta aunque Y_{t-2} no aporte efecto lineal adicional. La PACF intenta retirar ese camino intermedio.

No debe seleccionarse un orden contando barras significativas de manera automática. Diferenciación excesiva, atípicos, mezcla de estacionalidades y muestras pequeñas distorsionan ambos gráficos. Se combinan conocimiento del

periodo, ACF/PACF, criterios de información, parsimonia, diagnóstico residual y validación temporal.

14.2.5. Transformaciones de varianza

Muchos modelos lineales presuponen innovaciones de varianza aproximadamente constante. En demanda y conteos, la dispersión suele crecer con el nivel. Una transformación monótona puede estabilizarla, hacer aditivos efectos multiplicativos y reducir la influencia de extremos.

Para valores positivos, la transformación de Box-Cox es

$$g_{\lambda}(y) = \begin{cases} (y^{\lambda} - 1)/\lambda, & \lambda \neq 0, \\ \log y, & \lambda = 0. \end{cases}$$

$\lambda = 1$ se aproxima a la escala original, $\lambda = 1/2$ a raíz cuadrada y $\lambda = 0$ a logaritmo. La raíz es frecuente en conteos; el logaritmo interpreta diferencias como cambios relativos. Si existen ceros, $\log y$ no está definido. Sumar una constante altera especialmente valores pequeños y debe justificarse. Transformaciones que admiten cero y negativos pueden ser alternativas, pero sus parámetros se aprenden solo con entrenamiento.

Pronosticar en escala transformada y aplicar la inversa no produce necesariamente la media en escala original. Por desigualdad de Jensen,

$$g^{-1}\{E[g(Y)]\} \neq E(Y).$$

Con logaritmos y error normal de varianza σ_h^2 , la media aproximada es $\exp(\widehat{z}_{t+h} + \sigma_h^2/2)$, mientras $\exp(\widehat{z})$ se relaciona con la mediana. La corrección debe reflejar el objetivo.

Una transformación no corrige dependencia ni cambios estructurales. Debe verificarse si mejora estabilidad, residuos, calibración e interpretación. En conteos bajos, un modelo probabilístico discreto puede resultar más natural que forzar normalidad.

14.2.6. Diferenciación regular y estacional

El operador de rezago B se define por $BY_t = Y_{t-1}$. La diferencia regular es

$$\nabla Y_t = (1 - B)Y_t = Y_t - Y_{t-1}.$$

Si $Y_t = Y_{t-1} + \varepsilon_t$, entonces $\nabla Y_t = \varepsilon_t$: la diferencia elimina la raíz unitaria. Una segunda diferencia es $(1 - B)^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2}$ y puede retirar una tendencia estocástica de orden mayor, aunque rara vez debe aplicarse sin evidencia.

La diferencia estacional de periodo m es

$$\nabla_m Y_t = (1 - B^m)Y_t = Y_t - Y_{t-m}.$$

En datos horarios, $m = 24$ compara con la misma hora del día anterior; $m = 168$, con la misma hora de la semana anterior. Las diferencias pueden combinarse: $(1 - B)(1 - B^m)Y_t$.

Diferenciar reduce longitud, modifica interpretación y aumenta incertidumbre al reintegrar. La **sobrediferenciación** introduce dependencia artificial, eleva varianza y puede producir una ACF muy negativa en rezago uno. Si una tendencia determinista puede representarse explícitamente, no siempre hace falta diferenciarla. Si hay cambio de nivel, una diferencia genera un pulso, pero no garantiza estabilidad del régimen.

Para recuperar niveles, los pronósticos de diferencias se acumulan. Si $w_t = Y_t - Y_{t-1}$,

$$\hat{Y}_{t+h|t} = Y_t + \sum_{j=1}^h \hat{w}_{t+j|t}.$$

Los errores también se acumulan; por eso los intervalos suelen ensancharse con h . Toda decisión sobre d y D debe tomarse dentro de cada ventana de entrenamiento, no mirando la serie futura completa.

14.2.7. Ejemplo práctico guiado: transformación de una serie no estacionaria

Supóngase una serie diaria de unidades vendidas por una cadena durante dos años. El nivel crece, la variabilidad aumenta y existe un patrón semanal. El objetivo es pronosticar siete días.

1. La gráfica original muestra picos cada sábado y dispersión proporcional al nivel. La ACF decae lentamente y tiene máximos en múltiplos de siete.
2. Se aplica $z_t = \log(y_t + 1)$ porque hay algunos ceros legítimos. La constante y su impacto se documentan. La amplitud semanal queda más uniforme.
3. Se calcula $w_t = (1 - B^7)z_t = z_t - z_{t-7}$. Esto elimina gran parte del perfil semanal, pero persiste una evolución lenta.
4. Se compara añadir diferencia regular, $v_t = (1 - B)w_t$, frente a modelar una deriva. La doble transformación deja una autocorrelación negativa fuerte en rezago uno y peor validación: indicio de sobrediferenciación. Se conserva solo $D = 1$.

La secuencia conceptual es:

para cada origen temporal de evaluación:

estimar parámetros de transformación con el pasado disponible
transformar el pasado
decidir diferencias regulares y estacionales sin consultar el futuro
ajustar el modelo en la serie resultante
pronosticar y reintegrar hasta la escala original
guardar errores por horizonte

comparar estabilidad, residuos y desempeño fuera de muestra

La transformación seleccionada no se acepta porque la gráfica “parezca estacionaria”. Se exige que la media y varianza locales sean más estables, que ACF/PACF sean interpretables, que los residuos mejoren y que MAE o una métrica escalada no empeoren. La inversión del logaritmo debe distinguir

mediana y media. Una campaña futura no conocida seguirá siendo impredecible: transformar no reemplaza información.

14.3. Modelos ARIMA

ARIMA reúne modelos lineales parsimoniosos para la dinámica de una serie. Su fortaleza reside en representar dependencia y diferenciación con pocos parámetros, producir pronósticos probabilísticos bajo supuestos y ofrecer diagnósticos claros. No es una única receta ni garantiza superioridad frente a un baseline. La notación se entiende mejor usando innovaciones ε_t , errores nuevos que no eran previsibles con $\mathcal{F}_{t-1}$.

14.3.1. Modelos autorregresivos

Un modelo AR(p) expresa el valor actual como combinación lineal de sus p rezagos:

$$Y_t = c + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2).$$

Para AR(1), $Y_t = c + \phi Y_{t-1} + \varepsilon_t$. Si $|\phi| < 1$, su media estacionaria se obtiene tomando esperanzas:

$$\mu = c + \phi \mu \quad \Rightarrow \quad \mu = \frac{c}{1 - \phi}.$$

Al centrar $X_t = Y_t - \mu$, $X_t = \phi X_{t-1} + \varepsilon_t$. Sustituciones sucesivas producen $X_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$, y por tanto

$$\text{Var}(Y_t) = \frac{\sigma^2}{1 - \phi^2}, \quad \rho_k = \phi^k.$$

Si ϕ está cerca de uno, los choques persisten; si es negativo, aparecen alternancias. Con $\phi = 1$ se obtiene un paseo aleatorio, no un AR estacionario.

El pronóstico AR(1) a un paso es $\hat{Y}_{t+1|t} = c + \phi Y_t$. A h pasos,

$$\hat{Y}_{t+h|t} = \mu + \phi^h (Y_t - \mu),$$

que converge a la media. Para AR(p), la estacionariedad requiere que las raíces del polinomio $1 - \phi_1 z - \dots - \phi_p z^p$ estén fuera del círculo unitario.

Un orden alto puede memorizar ruido y generar coeficientes inestables por colinealidad entre rezagos. La interpretación es predictiva: ϕ_i es un efecto parcial lineal condicionado por otros rezagos, no un mecanismo causal.

14.3.2. Modelos de medias móviles

Un modelo MA(q) representa el valor mediante innovaciones actuales y pasadas:

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

El nombre “medias móviles” puede inducir a error: no es la media móvil usada para suavizar observaciones, sino una combinación de errores no observados. Durante el ajuste, las innovaciones se infieren de manera recursiva.

Para MA(1), $Y_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$. Su varianza es $\sigma^2(1 + \theta^2)$ y

$$\rho_1 = \frac{\theta}{1 + \theta^2}, \quad \rho_k = 0 \quad (k > 1).$$

Esta ACF truncada motiva su identificación. Un choque afecta Y_t y hasta q valores posteriores; luego desaparece explícitamente del modelo.

La condición de **invertibilidad** permite expresar innovaciones como función convergente de observaciones y escoger una representación única. Para MA(1) exige, con esta convención de signos, $|\theta| < 1$. Distintas convenciones escriben signos opuestos; deben comprobarse al interpretar software.

El pronóstico MA(1) a un paso usa el residuo estimado: $\hat{Y}_{t+1|t} = \mu + \theta\hat{\varepsilon}_t$. Para $h > 1$ vuelve a μ , porque las innovaciones futuras tienen esperanza cero. En series donde los choques se disipan rápidamente, esta memoria finita es útil.

14.3.3. Modelos ARMA

ARMA(p, q) combina persistencia autorregresiva y choques de media móvil:

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

Con operadores,

$$\phi(B)Y_t = c + \theta(B)\varepsilon_t,$$

donde $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ y $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$. El componente AR ofrece memoria potencialmente infinita con decaimiento; MA modela el efecto corto de innovaciones.

ARMA presupone una serie estacionaria. Aplicarlo directamente a un nivel con raíz unitaria produce relaciones espurias y pronósticos mal calibrados. Sus parámetros suelen estimarse conjuntamente por máxima verosimilitud, no mediante regresión ordinaria, porque los errores pasados son latentes y dependen de parámetros.

La parsimonia importa. Un ARMA pequeño puede aproximar la dinámica que requeriría muchos términos AR. No obstante, combinaciones AR y MA pueden casi cancelarse, dificultando identificación. Se revisan convergencia, raíces, incertidumbre de coeficientes y sensibilidad a inicialización.

Fallo frecuente. Elegir p y q para maximizar ajuste dentro de muestra. Añadir parámetros reduce residuos de entrenamiento, pero puede deteriorar pronóstico. Los criterios de información penalizan complejidad y la validación temporal comprueba transferencia.

14.3.4. Modelos ARIMA

ARIMA(p, d, q) aplica un ARMA a una serie diferenciada d veces:

$$\phi(B)(1 - B)^d Y_t = c + \theta(B)\varepsilon_t.$$

p es el orden autorregresivo, d el número de diferencias regulares y q el orden de medias móviles. ARIMA(0,1,0) es el paseo aleatorio:

$$(1 - B)Y_t = \varepsilon_t, \quad \text{de donde} \quad \widehat{Y}_{t+h|t} = Y_t.$$

Por ello, el baseline de último valor no es ingenuo en sentido despectivo: corresponde a un modelo probabilístico coherente. Si se añade deriva c a las diferencias, $Y_t = Y_{t-1} + c + \varepsilon_t$ y $\widehat{Y}_{t+h|t} = Y_t + hc$.

Para ARIMA(1,1,0), $\Delta Y_t = \phi \Delta Y_{t-1} + \varepsilon_t$. Primero se pronostican cambios y luego se acumulan. La incertidumbre crece porque cada nivel futuro incorpora innovaciones. Bajo paseo aleatorio,

$$\text{Var}(Y_{t+h} - \widehat{Y}_{t+h|t}) = h\sigma^2.$$

El intercepto cambia de significado según d . En un modelo sin diferencias se relaciona con nivel medio; con una diferencia puede implicar deriva. Esta distinción evita interpretar una constante como media universal.

ARIMA modela relaciones lineales en la escala elegida. Puede funcionar muy bien con series cortas y patrones estables, pero no impone no negatividad y puede pronosticar conteos negativos. Transformación, modelos de conteo o truncamiento cuidadosamente evaluado son alternativas; recortar a cero cambia sesgo e intervalos y no debe ocultarse.

14.3.5. Componentes estacionales

SARIMA extiende ARIMA mediante operadores estacionales. Se denota

$$\text{ARIMA}(p, d, q)(P, D, Q)_m$$

y satisface

$$\Phi(B^m)\phi(B)(1 - B)^d(1 - B^m)^D Y_t = \Theta(B^m)\theta(B)\varepsilon_t.$$

P, D, Q son órdenes AR, de diferenciación y MA estacionales; m es el periodo. Un término AR estacional de orden uno relaciona Y_t con Y_{t-m} ; un MA estacional relaciona innovaciones separadas por m .

Por ejemplo, SARIMA(0, 0, 0)(0, 1, 0)₁₆₈ implica $Y_t - Y_{t-168} = \varepsilon_t$ y su pronóstico es el último valor de la misma hora semanal. Es el baseline estacional expresado como modelo. Un modelo con factores regulares y estacionales genera también términos cruzados. Si

$$(1 - \phi B)(1 - \Phi B^m)Y_t = \varepsilon_t,$$

al expandir aparece $Y_t - \phi Y_{t-1} - \Phi Y_{t-m} + \phi \Phi Y_{t-m-1}$.

Elegir m exige dominio y evidencia. En series horarias con patrones diario y semanal, un SARIMA estándar representa cómodamente un periodo principal; forzar órdenes enormes para ambos puede ser costoso. Variables de calendario, términos armónicos o métodos de estacionalidad múltiple constituyen alternativas.

No se estima estacionalidad anual con tres meses de observaciones. Tampoco debe confundirse una festividad única con componente estacional. Los componentes estacionales consumen datos: una diferencia semanal pierde 168 observaciones iniciales y requiere suficientes repeticiones para estimación estable.

14.3.6. Selección de órdenes

La selección de $(p, d, q)(P, D, Q)_m$ combina razonamiento y comparación. Un flujo defendible es:

1. fijar frecuencia y periodos plausibles con conocimiento del proceso;
2. estabilizar varianza si es necesario;
3. elegir d y D mínimos mediante gráficos, pruebas y señales de sobrediferenciación;
4. proponer órdenes pequeños con ACF/PACF de la serie estacionarizada;
5. estimar modelos candidatos y comprobar raíces, convergencia y residuos;
6. comparar criterios de información y, sobre todo, validación temporal.

El AIC se define como

$$\text{AIC} = -2 \log L + 2k,$$

donde L es la verosimilitud maximizada y k el número de parámetros. BIC penaliza más con $\text{BIC} = -2 \log L + k \log n$. AICc corrige AIC para muestras pequeñas. Solo son comparables entre modelos ajustados a la misma respuesta, periodo y observaciones; cambiar transformación o pérdida rompe una comparación directa ingenua.

La búsqueda exhaustiva puede seleccionar accidentalmente peculiaridades del conjunto. Debe limitarse a una región parsimoniosa, registrar candidatos fallidos y reservar evaluación fuera de muestra. Si dos modelos tienen rendimiento semejante, se prefiere el más simple, estable y rápido de actualizar.

Señales de alarma: coeficientes enormes con errores estándar grandes, raíces casi canceladas, órdenes cercanos a la longitud estacional, no convergencia y resultados muy sensibles a pocas observaciones. Automatizar órdenes no elimina la responsabilidad de diagnosticar.

14.3.7. Variables exógenas

Una regresión dinámica o ARIMAX combina predictores x_t con errores ARIMA:

$$Y_t = \beta_0 + \beta^\top \mathbf{x}_t + n_t, \quad \phi(B)(1-B)^d n_t = \theta(B)\varepsilon_t.$$

Los coeficientes explican asociación en la escala y condicionamiento especificados; no se vuelven causales por incluir dinámica. Pueden incorporarse turnos programados, festivos, precios anunciados o promociones aprobadas. Para pronosticar Y_{t+h} se necesitan x_{t+h} o escenarios de ellos.

La disponibilidad es más restrictiva que la existencia retrospectiva. El total cobrado al terminar un viaje no puede predecir pickups antes de que ocurran. Una temperatura futura observada en el dataset histórico tampoco estaba disponible; debe usarse el pronóstico meteorológico que habría existido en cada origen, o declararse un escenario.

Los indicadores de calendario son conocidos de antemano, pero su efecto puede cambiar. Las variables altamente correlacionadas generan coeficientes inestables. Rezagos exógenos deben respetar causalidad: x_{t-1} puede ser válido, mientras x_{t+1} es fuga salvo que sea una programación conocida.

Hay dos incertidumbres: la del modelo de respuesta y la de los predictores futuros. Condicionar intervalos a un único escenario exógeno suele subestimar incertidumbre. Es preferible presentar escenarios o propagar distribuciones cuando los predictores también se pronostican.

14.3.8. Diagnóstico de residuos

El residuo de un paso es $e_t = y_t - \hat{y}_{t|t-1}$. Un modelo adecuado deja residuos de media cercana a cero, sin autocorrelación aprovechable, varianza razonablemente estable y distribución compatible con el procedimiento de intervalos. Ajuste visual de la serie no basta.

Se examinan:

- residuos en el tiempo, para nivel, régimen, varianza y extremos;
- histograma y cuantiles, para asimetría y colas;
- ACF residual, para dependencia remanente;
- residuos frente a ajustados y calendario;
- errores por horizonte y subgrupo operativo.

La prueba de Ljung-Box contrasta conjuntamente autocorrelaciones hasta h :

$$Q = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}.$$

Los grados de libertad deben considerar parámetros estimados. No rechazar no demuestra independencia; con pocas observaciones hay baja potencia. Rechazar con una muestra enorme puede señalar desviaciones pequeñas sin impacto operativo. El gráfico y la validación complementan la prueba.

Normalidad no es necesaria para que el pronóstico puntual sea útil, pero afecta intervalos gaussianos. Heterocedasticidad y extremos producen cobertura insuficiente. Se pueden transformar datos, usar intervalos empíricos, bootstrap compatible con dependencia o modelos de varianza.

Un residuo grande no debe borrarse para “aprobar” el diagnóstico. Se investiga si representa error, evento o cambio de régimen; luego se evalúa una intervención y se informa sensibilidad. El diagnóstico busca descubrir límites, no certificar perfección.

14.3.9. Ejemplo práctico guiado: pronóstico de consumo de agua

Una planta de alimentos necesita anticipar su consumo agregado diario de agua de proceso durante los próximos cinco días para coordinar producción, almacenamiento y compras de insumos. Hay dieciocho meses de datos, un patrón de cinco días laborables, cierres programados y una ampliación de capacidad a mitad del periodo. Se define y_t como el volumen total utilizado en limpieza, cocción y enfriamiento durante el día t . El ejercicio estudia planificación de recursos dentro de la planta; no intenta localizar pérdidas ni representar una red de distribución.

Preparación. Se construye un calendario diario regular. Un día de cierre programado puede tener un consumo basal pequeño y legítimo; una interrupción del medidor queda faltante y no debe convertirse en cero. La varianza aumenta con el nivel de producción, por lo que se considera una transformación de raíz cuadrada. La ampliación se representa mediante un indicador de intervención y se discute si su efecto seguirá activo durante el horizonte.

Identificación. Tras una diferencia estacional $m = 7$, la ACF conserva señal en rezago uno y la PACF decae. Se comparan un baseline del mismo día de la semana, modelos SARIMA de órdenes pequeños y una regresión dinámica con calendario de producción y cierres programados. No se elige por ajuste total: se ejecutan orígenes semanales sobre los últimos cuatro meses.

Estimación y pronóstico conceptual:

definir origen, horizonte de cinco días y datos disponibles
para cada origen:

- ajustar transformación, intervención y modelo solo con fechas anteriores
- proporcionar calendario de producción conocido para los cinco días
- generar pronóstico puntual e intervalos
- invertir transformación con corrección coherente con media o mediana
- comparar cada paso con baseline estacional

agrupar métricas, cobertura y residuos por horizonte y tipo de día

Resultados interpretables. El SARIMA reduce MAE en días 1 y 2, pero no en día 5. Los intervalos al 90 % cubren solo el 78 % de las observaciones durante semanas de producción extraordinaria: están subcalibrados. Los residuos no muestran señal semanal fuerte, aunque sí asimetría positiva. La conclusión no es que el modelo haya “resuelto” el consumo, sino que mejora decisiones muy cortas y exige una reserva adicional cuando el programa incluye lotes atípicos.

Fallas que deben discutirse: utilizar el volumen producido definitivo cuando solo se conoce al cerrar el día; rellenar una interrupción de medición con cero; estimar el efecto de la ampliación usando toda la serie; confundir consumo observado con necesidad inevitable; y elegir el mejor orden tras mirar repetidamente el bloque final.

14.4. Evaluación de pronósticos

Evaluar pronósticos es reproducir cómo se habrían emitido en el pasado. Deben fijarse origen, horizonte, frecuencia, información disponible, regla de actualización, baseline, métrica y unidad de decisión antes de observar resultados.

Una cifra agregada sin ese contrato puede ocultar fuga, degradación con horizonte o fallas en periodos críticos.

14.4.1. Horizonte de predicción

En el origen t , el pronóstico a horizonte h es $\hat{y}_{t+h|t}$, construido con $\hat{f}_t$. El horizonte puede expresarse en pasos o tiempo civil: seis pasos horarios, siete días o cuatro semanas. Debe coincidir con la anticipación necesaria para actuar.

Hay estrategias de múltiples pasos. La **recursiva** ajusta un modelo de un paso y alimenta sus propios pronósticos; acumula error. La **directa** ajusta un modelo para cada h ; evita recursión, pero usa menos pares efectivos y puede generar trayectorias incoherentes. La estrategia múltiple predice todo el vector y modela dependencias entre horizontes.

El error se define por origen y horizonte:

$$e_{t,h} = y_{t+h} - \hat{y}_{t+h|t}.$$

Promediar todos los h puede esconder que un método es excelente a una hora y deficiente a un día. Se informan métricas por horizonte y, si se resume, pesos ligados a la decisión.

Horizonte y frecuencia interactúan. Pronosticar 24 pasos horarios no equivale necesariamente a pronosticar el total diario: la suma de pronósticos horarios tiene una distribución conjunta y errores correlacionados. También deben declararse vacíos entre entrenamiento y prueba cuando los datos llegan con retraso.

14.4.2. Pronósticos puntuales e intervalos

Un pronóstico puntual resume una distribución predictiva. La media minimiza pérdida cuadrática esperada; la mediana minimiza pérdida absoluta; un cuantil τ minimiza pérdida de pinball. Por tanto, “el mejor valor” depende del costo de sobrestimar y subestimar.

Un intervalo predictivo $(L_{t,h}, U_{t,h})$ de nivel nominal $1 - \alpha$ busca

$$P(L_{t,h} \leq Y_{t+h} \leq U_{t,h} \mid \hat{f}_t) = 1 - \alpha.$$

No afirma que un parámetro fijo tenga esa probabilidad ni que cada intervalo individual contenga el futuro. Bajo errores gaussianos, puede aproximarse por

$$\hat{y}_{t+h|t} \pm z_{1-\alpha/2} \hat{\sigma}_h.$$

$\hat{\sigma}_h$ debe incluir propagación temporal y, cuando corresponda, incertidumbre paramétrica y exógena. Los intervalos suelen ampliarse con el horizonte, aunque estacionalidad y restricciones pueden producir patrones no monótonos.

Se evalúan **cobertura** y **anchura**. Un intervalo infinito cubre todo y no sirve; uno estrecho que cubre poco transmite falsa precisión. La puntuación de intervalo penaliza ambas propiedades. La cobertura debe revisarse por horizonte, nivel de demanda y régimen, no solo globalmente.

Para conteos, límites negativos carecen de interpretación. Truncarlos después del cálculo cambia cobertura. Son preferibles distribuciones o transformaciones compatibles, o una calibración empírica declarada.

14.4.3. MAE, RMSE, MAPE y métricas escaladas

Para N errores, el error absoluto medio es

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

Mantiene la unidad original y corresponde a pérdida absoluta. La raíz del error cuadrático medio,

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2},$$

penaliza más los errores grandes. No es “mejor” por ser más sofisticada; es adecuada cuando grandes desviaciones son desproporcionadamente costosas.

El MAPE,

$$\text{MAPE} = \frac{100}{N} \sum_i \left| \frac{y_i - \hat{y}_i}{y_i} \right|,$$

no está definido con $y_i = 0$, explota cerca de cero y penaliza asimétricamente. El sMAPE reduce algunos problemas, pero conserva ambigüedades y no debe presentarse como solución universal.

MASE escala el MAE por el error de un baseline ingenuo en entrenamiento. Para estacionalidad m ,

$$\text{MASE} = \frac{N^{-1} \sum |e_i|}{(n-m)^{-1} \sum_{t=m+1}^n |y_t - y_{t-m}|}.$$

Valores menores que uno superan, en promedio, la escala del baseline usado. RMSSE aplica cuadrados y raíz. Las métricas escaladas permiten comparar series de niveles distintos, pero el denominador debe calcularse sin prueba y puede ser cero en series constantes.

También se informa sesgo medio $N^{-1} \sum e_i$: un MAE bajo puede coexistir con subpronóstico sistemático. Para intervalos se añaden cobertura, anchura y puntuaciones propias. Seleccionar una métrica después de ver qué método gana es una forma de sesgo analítico.

14.4.4. Validación walk-forward

La validación *walk-forward* crea múltiples simulaciones de pronóstico. En cada origen se ajusta con pasado y se evalúa el bloque futuro inmediato. La ventana

puede ser **expansiva**, que conserva toda la historia, o **deslizante**, que mantiene longitud fija para adaptarse a cambios de régimen.

Sean $t_1 < \dots < t_K$ los orígenes y H el horizonte. El conjunto de errores es $e_{t_k, h}$ para $k = 1, \dots, K$ y $h = 1, \dots, H$. Un pseudocódigo seguro es:

```
fijar primer origen, último origen, horizonte y regla de ventana
para cada origen t:
    entrenamiento = observaciones disponibles hasta t
    ajustar en entrenamiento imputación, escalado, transformación y modelo
    construir predictores futuros disponibles en t
    emitir pronósticos para  $h = 1, \dots, H$ 
    guardar pronóstico, intervalo, observado, origen y horizonte
    avanzar el origen según la cadencia operativa
resumir errores por horizonte, fecha, régimen y serie
comparar todos los métodos en exactamente los mismos pares origen-objetivo
```

Reajustar en cada origen imita actualización completa; mantener parámetros y actualizar estado imita otro sistema. La validación debe copiar la política prevista. Orígenes solapados generan errores dependientes, de modo que la incertidumbre de diferencias entre modelos no debe calcularse como si fueran observaciones independientes.

Un único corte final es mejor que mezcla aleatoria, pero puede depender de una semana atípica. Múltiples orígenes revelan variación. Aun así, debe conservarse si es posible un periodo final para confirmación, evitando usarlo repetidamente en selección.

14.4.5. Prevención de fuga temporal

Hay fuga temporal cuando el proceso de entrenamiento utiliza información que no habría estado disponible al emitir el pronóstico. Puede ser directa, como incluir y_{t+1} , o sutil, como normalizar con media de toda la serie.

Fuentes comunes son:

- imputación o suavizado centrado que consulta valores posteriores;
- selección de variables y órdenes usando el bloque final;
- medias estacionales calculadas con todo el periodo;
- variables publicadas con retraso tratadas como contemporáneas;
- resultados del evento, como monto final o hora de cierre;
- agregaciones cuya ventana aún no terminó en el origen;
- mezcla aleatoria de filas temporalmente cercanas;
- ajuste de transformación, escalador o descomposición antes de dividir.

La prevención parte de una **tabla de disponibilidad**: para cada variable se registra instante del evento, instante de publicación y revisiones. El conjunto $\widehat{F}_t$ contiene solo lo disponible en producción. Los pipelines completos se ajustan dentro de cada ventana.

La fuga también cruza entidades. Si se pronostican zonas y se usa el total de ciudad de la misma hora, ese total aún no se conoce. Una característica agregada debe rezagarse o construirse con un pronóstico. Duplicados de un mismo evento en entrenamiento y prueba constituyen otra contaminación.

Una puntuación extraordinariamente alta merece auditoría antes que celebración. Comparar con un baseline, desplazar deliberadamente variables y ejecutar una prueba de disponibilidad ayuda a detectar relaciones imposibles.

14.4.6. Comparación con modelos de machine learning

Un modelo de aprendizaje automático convierte la serie en tabla supervisada. Para cada instante puede usar rezagos y_{t-1} , y_{t-24} , y_{t-168} , estadísticas móviles causales y calendario. Árboles, *boosting* o redes aprenden relaciones no lineales e interacciones, pero no conocen el tiempo si no se lo representa.

La comparación justa exige misma variable objetivo, orígenes, horizontes, información y métrica. ARIMA integra dependencia y distribución mediante una estructura parsimoniosa; ML suele requerir más datos, diseño de características e intervalos adicionales. Ninguna familia domina siempre.

Ventajas potenciales de ML son no linealidad, muchas covariables y aprendizaje global entre numerosas series. Riesgos son sobreajuste, discontinuidades, dificultad de extrapolar tendencia y fuga en características. Un bosque no extrapola naturalmente fuera del rango observado; un modelo lineal con deriva sí puede hacerlo, aunque quizá de manera errónea.

La media móvil causal de ancho w para predecir t debe ser

$$\bar{y}_{t-1}^{(w)} = \frac{1}{w} \sum_{j=1}^w y_{t-j},$$

no una ventana que incluya y_t . Para múltiples pasos, debe decidirse si los rezagos futuros se reemplazan recursivamente, se entrenan modelos directos o se emite el vector completo.

Se incluyen baselines de último valor, estacional y media estacional. Si ML gana solo marginalmente y exige gran mantenimiento, el método simple puede ser preferible. La decisión incorpora latencia, explicabilidad, calibración, costo de actualización y robustez, no solo RMSE.

14.4.7. Incertidumbre y actualización del modelo

La incertidumbre procede de innovaciones, parámetros estimados, predictores futuros, elección de modelo y cambios del proceso. Los intervalos ARIMA estándar suelen representar bien la primera y parcialmente la segunda bajo supuestos; no cubren automáticamente una pandemia, una nueva política comercial o un sensor reemplazado.

Actualizar puede significar incorporar la observación al estado con parámetros fijos, reestimar parámetros, reentrenar características o volver a seleccionar modelo. La cadencia debe corresponder a la velocidad de cambio y al costo. Reentrenar cada hora puede ser innecesario; no reentrenar durante meses puede ignorar deriva.

Se monitorizan error, sesgo, cobertura, anchura, distribución de entradas, faltantes y desempeño frente al baseline. Un esquema de control compara métricas en ventana reciente con límites definidos en validación. La alarma inicia revisión; no ordena automáticamente un cambio.

Ante deriva se puede acortar ventana, ponderar observaciones recientes, añadir una intervención o cambiar especificación. Cada respuesta tiene riesgo: una ventana corta adapta rápido pero aumenta varianza; una larga estabiliza pero tarda. Se conserva una versión anterior y se evalúa el candidato en paralelo.

Los intervalos deben recalibrarse. Si un intervalo nominal del 90 % cubre 70 % en las últimas semanas, la incertidumbre comunicada es insuficiente aun si MAE no cambió. Para decisiones asimétricas se publican cuantiles: inventario puede basarse en un cuantil alto, mientras planificación central usa media.

14.4.8. Ejemplo práctico guiado: comparación de métodos de pronóstico

Una cadena minorista pronostica ventas diarias de una categoría a siete días. Se comparan: último valor, valor de hace siete días, media por día de semana, SARIMA y *gradient boosting* con rezagos y calendario. El periodo de entrenamiento inicial es un año; luego se ejecutan 20 orígenes semanales con ventana expansiva.

Todos los métodos reciben las mismas observaciones. La media estacional, escalado, transformación y características se recalculan por origen. Las promociones solo se incluyen si estaban aprobadas en la fecha de emisión. Se guardan $e_{t,h}$, intervalos o cuantiles y tiempo de ajuste.

Una tabla hipotética resume:

Método	MAE	RMSE	MASE	Cobertura 90 %	Observación
Último valor	18,4	26,7	1,21	No aplica	Ignora semana
Estacional 7 días	15,2	22,9	1,00	No aplica	Baseline fuerte
Media estacional	14,8	22,1	0,97	No aplica	Suaviza extremos
SARIMA	13,9	20,8	0,91	0,87	Mejor en $h \leq 3$
<i>Boosting</i>	13,6	21,5	0,89	0,80	Falla en promociones raras

La menor MAE global de *boosting* no resuelve la elección. SARIMA tiene menor RMSE, mejor cobertura y costo inferior; *boosting* mejora días ordinarios pero subestima picos. A $h = 7$, ambos empatan al baseline. Si la decisión penaliza faltantes de inventario, se comparan cuantiles y no solo medias.

Conclusión defendible. Se adopta SARIMA para tres días y baseline estacional para días 4 a 7, o se mantiene un único modelo si la simplicidad operativa pesa más. Se revisa cobertura mensualmente. No se afirma superioridad universal: el resultado corresponde a esa categoría, ventana y protocolo.

Actividad EMO [MOV-04]: pronosticar demanda por zona y franja horaria

Alineación obligatoria con el Apéndice D. La fuente es NYC TLC Yellow Taxi Trip Records y la instantánea común contiene `yellow_tripdata_2026-02.parquet`, `yellow_tripdata_2026-03.parquet` y `yellow_tripdata_2026-04.parquet`. La unidad original es un viaje reportado; la unidad derivada es zona TLC-franja. La variable objetivo es la cantidad de pickups válidos por PULocationID e intervalo. Representa pickups de taxi amarillo reportados, no toda la movilidad, vehículos disponibles ni demanda insatisfecha.

Pregunta realizable. ¿Cuántos pickups se observarán en la siguiente hora, en las próximas horas o en el día siguiente para una zona o segmento? Con solo febrero-abril de 2026, el horizonte debe ser corto y no se puede exigir estacionalidad anual.

Consigna. Seleccionar una zona TLC o un segmento definido de manera reproducible. Construir una serie regular, fijar un horizonte operativo y comparar como mínimo un baseline de último valor o estacional con ARIMA, SARIMA u otra alternativa pertinente mediante validación *walk-forward*.

Construcción de la serie. Usar `tpep_pickup_datetime`, `PULocationID` y el Taxi Zone Lookup. Aplicar los mismos filtros, zona horaria y cortes en los tres meses. Los intervalos con cobertura confirmada y ningún viaje reciben cero explícito; los periodos sin cobertura quedan faltantes y se tratan sin usar futuro. Las zonas desconocidas se documentan. Variables conocidas al finalizar el viaje, como tipo de pago, cargos, propina u hora de descenso, no son predictores válidos de pickups futuros.

Protocolo mínimo:

elegir zona, frecuencia y horizonte corto antes de evaluar
reservar una historia inicial suficiente para al menos varios ciclos semanales
definir múltiples orígenes entre febrero y abril de 2026
para cada origen:

- usar exclusivamente registros publicados y agregados hasta ese instante
- ajustar tratamientos y modelos dentro de la ventana
- emitir baseline y modelo alternativo para idénticos horizontes
- guardar punto, intervalo, observado y banderas de cobertura
- calcular MAE o RMSE y una métrica escalada por horizonte
- auditar sesgo, cobertura de intervalos y residuos o errores temporales
- traducir el resultado a una regla prudente de prioridad de zona

Baseline. Para serie horaria, comparar al menos con la misma hora del día anterior o de la semana anterior, según evidencia; también puede incluirse último valor. Si se modela demanda diaria, usar día anterior o mismo día de semana. El baseline debe calcularse con pasado y permanecer idéntico entre candidatos.

Validación temporal. La ventana expansiva aprovecha los tres meses; una deslizante puede adaptarse a cambios entre meses. Justificar el primer origen, número de repeticiones, cadencia de emisión y si los horizontes se solapan. Ningún escalado, imputación, perfil horario, selección de orden o entrenamiento puede consultar fechas posteriores al origen.

Producto individual. Entregar notebook reproducible con contrato de datos, controles de cobertura, particiones temporales, pronósticos e intervalos, métricas por horizonte, análisis de residuos o errores y comparación con baseline. Incluir una tabla con origen, objetivo, horizonte, observado y predicciones para permitir auditoría.

Interpretación operativa. Una regla didáctica puede priorizar una zona si su pronóstico supera el baseline, ponderando conectividad definida en el laboratorio. No debe presentarse como despacho óptimo: TLC no informa la ubicación de vehículos libres ni toda la demanda de transporte. Una caída puede reflejar demanda, cobertura o cambio del servicio.

Criterios de aprobación:

- serie zona-franja regular con ceros y faltantes correctamente diferenciados;
- horizonte corto compatible con febrero-abril de 2026;
- baseline adecuado y evaluación sobre los mismos orígenes;
- ausencia demostrable de fuga temporal;
- MAE o RMSE por horizonte, más sesgo o métrica escalada;
- intervalos interpretados mediante cobertura y anchura;
- limitaciones de representatividad y decisión explícitas.

Fallos que invalidan la evidencia. Mezclar filas aleatoriamente; usar abril para aprender transformaciones evaluadas en febrero o marzo; rellenar toda ausencia con cero; utilizar atributos de fin de viaje; comparar modelos en cortes diferentes; informar solo ajuste dentro de muestra; afirmar estacionalidad anual; o confundir pickups reportados con demanda total.

Glosario

ACF: función de autocorrelación; asociación lineal de una serie con sus rezagos.

AR: modelo autorregresivo que combina valores pasados de la respuesta.

ARIMA: modelo ARMA aplicado tras diferenciación regular.

Baseline: regla simple y reproducible que fija el nivel mínimo de comparación.

Ciclo: fluctuación de duración no estrictamente fija y no anclada al calendario.

Cobertura: proporción de valores futuros contenidos en sus intervalos predictivos.

Diferenciación: operación que resta observaciones separadas por uno o varios rezagos.

Estacionariedad débil: constancia de media y varianza, con covarianza dependiente solo del rezago.

Estacionalidad: patrón recurrente asociado a una posición conocida del calendario.

Frecuencia: ritmo de observación; en patrones, cantidad de ciclos por unidad temporal.

Horizonte: distancia entre el origen del pronóstico y el instante objetivo.

Innovación: componente nuevo no predecible con la información pasada del modelo.

MA: modelo que combina innovaciones actuales y pasadas.

MAE: promedio de errores absolutos, en la unidad de la variable.

MASE: error absoluto escalado por el desempeño ingenuo de entrenamiento.

PACF: autocorrelación parcial después de controlar rezagos intermedios.

Periodo: número de observaciones requerido para completar una repetición.

Residuo: diferencia entre valor observado y ajustado o pronosticado.

RMSE: raíz del promedio de errores cuadrados, sensible a errores grandes.

SARIMA: ARIMA con operadores autorregresivos, de diferencia y de media móvil estacionales.

Serie regular: serie cuyos intervalos consecutivos siguen una cuadrícula fija.

Tendencia: cambio suave del nivel a largo plazo respecto de la ventana analizada.

Walk-forward: evaluación que avanza orígenes y entrena siempre con el pasado disponible.

Preguntas de revisión y discusión

1. ¿Por qué un cero observado y un intervalo sin cobertura producen consecuencias distintas al modelar demanda?
2. Distinga frecuencia de muestreo, frecuencia de un patrón y periodo con una serie horaria.
3. ¿Qué evidencia separaría estacionalidad semanal de un ciclo irregular de pedidos?
4. ¿Por qué una media móvil centrada puede describir el pasado, pero causar fuga al predecir?
5. Explique la diferencia entre estacionariedad estricta y débil.
6. ¿Cómo puede una tendencia crear autocorrelación alta sin dinámica de corto plazo?
7. ¿Qué patrones ideales muestran ACF y PACF en $AR(p)$ y $MA(q)$, y por qué no deben aplicarse mecánicamente?
8. Derive la media y la varianza de un $AR(1)$ estacionario.
9. ¿Qué significa que un MA sea invertible?
10. Compare diferencia regular y estacional. ¿Qué síntomas produce sobrediferenciar?
11. ¿Por qué invertir un pronóstico logarítmico puede estimar una mediana y no una media?
12. Interprete cada orden de $SARIMA(p, d, q)(P, D, Q)_m$.
13. ¿Cuándo una variable exógena histórica no es válida para pronosticar?
14. ¿Qué demuestra y qué no demuestra una prueba de Ljung-Box no significativa?
15. Compare estrategias recursiva y directa para varios pasos.
16. ¿Por qué MAPE es problemático en series de conteos con ceros?
17. Diseñe una validación *walk-forward* para pronósticos horarios a seis pasos.
18. Enumere cuatro fugas temporales que pueden ocurrir antes de ajustar el modelo.
19. ¿En qué condiciones un método de ML puede superar a ARIMA y qué costo adicional introduce?
20. En MOV-04, ¿por qué tres meses no permiten exigir estacionalidad anual y qué baselines sí son defendibles?

Actividad integradora de razonamiento

Un centro de distribución observa despachos horarios durante doce semanas y debe dimensionar personal para las próximas ocho horas. Hay turnos conocidos, faltantes por una interrupción de captura, ceros durante cierres y dos picos por campañas. Sin implementar código, redacte un protocolo técnico que incluya:

1. definición de unidad, frecuencia, origen y horizonte;
2. auditoría que distinga ceros, faltantes y atípicos reales;
3. hipótesis de tendencia, estacionalidad diaria/semanal y ciclos;

4. transformación y diferenciación candidatas con riesgos;
5. dos modelos ARIMA/SARIMA parsimoniosos y un baseline;
6. variables exógenas disponibles en cada origen;
7. diseño *walk-forward* con ventana y cadencia justificadas;
8. MAE, RMSE, MASE, sesgo y evaluación de intervalos por horizonte;
9. controles concretos contra fuga;
10. regla de actualización y condición para retirar el modelo.

La entrega debe incluir un diagrama temporal, las fórmulas de los candidatos, pseudocódigo del protocolo y una discusión de al menos tres modos de falla. Se evaluará la coherencia entre decisión, información y validación, no la complejidad del método.

Síntesis

Una serie temporal está definida tanto por sus valores como por frecuencia, calendario, cobertura y disponibilidad. Tendencia, estacionalidad, ciclos y ruido son hipótesis útiles, pero dependen de escala y método. Faltantes y atípicos exigen investigar el proceso de observación antes de transformar datos.

La dependencia serial hace posible pronosticar y obliga a respetar orden. Estacionariedad, ACF, PACF, transformaciones y diferencias permiten formular dinámicas relativamente estables. AR, MA, ARMA, ARIMA y SARIMA ofrecen una familia coherente cuya complejidad debe ser parsimoniosa, cuyos predictores futuros deben estar disponibles y cuyos residuos necesitan diagnóstico.

Un pronóstico solo es defendible para un horizonte y una decisión definidos. Puntos sin intervalos ocultan incertidumbre; métricas sin baseline ocultan dificultad; particiones aleatorias ocultan fuga. La validación *walk-forward*, las métricas por horizonte y el seguimiento de cobertura acercan la evaluación al uso real. En MOV-04, esta disciplina se concreta al pronosticar pickups reportados de NYC TLC entre febrero y abril de 2026 mediante horizonte corto, baseline explícito y validación temporal reproducible.

Capítulo 15. Redes neuronales, aprendizaje profundo y visión artificial

Las redes neuronales son modelos paramétricos que aprenden representaciones mediante la composición de transformaciones simples. Su importancia no proviene de imitar con fidelidad un cerebro, sino de ofrecer una familia flexible de funciones diferenciables que puede ajustarse con datos. Cuando la composición contiene numerosas capas se habla de **aprendizaje profundo**. En visión artificial, esa profundidad permite pasar de valores de píxeles a bordes, texturas, partes y configuraciones útiles para una tarea.

La flexibilidad tiene un costo. Una red puede memorizar ejemplos, explotar señales espurias, asignar confianza excesiva o fallar ante imágenes distintas de las observadas. Por eso el capítulo estudia conjuntamente representación, optimización, evaluación y condiciones de uso. Las fórmulas se expresan sin depender de una biblioteca. Los ejemplos prácticos se conectan con un clasificador educativo de imágenes vegetales y respetan el protocolo del Apéndice D: PlantVillage, configuración color, un cultivo seleccionado, particiones agrupadas por `leaf_id`, prueba oficial reservada y abstención cuando la evidencia no permite clasificar responsablemente.

15.1. Fundamentos de redes neuronales

15.1.1. Neurona artificial

Una neurona artificial recibe un vector de características $\mathbf{x} = (x_1, \dots, x_d)^\top$, calcula una combinación afín y aplica una función de activación:

$$z = \mathbf{w}^\top \mathbf{x} + b = \sum_{j=1}^d w_j x_j + b, \quad a = \phi(z).$$

Los pesos $\mathbf{w}$ determinan cuánto y en qué dirección contribuye cada entrada; el sesgo b desplaza la respuesta, y a es la salida. La palabra “neurona” es una metáfora histórica: el objeto matemático es una unidad de cálculo parametrizada. No debe inferirse de ella equivalencia biológica.

La combinación z recibe el nombre de **preactivación**. Si dos entradas tienen escalas muy diferentes, el peso numéricamente menor no es necesariamente menos importante: peso y escala actúan juntos. Por ello las entradas suelen

normalizarse. En una imagen, una unidad no suele recibir inicialmente conceptos como “mancha” o “borde”; recibe números. Durante el aprendizaje, los pesos se organizan para producir respuestas útiles según el objetivo y los datos.

Geométricamente, $\mathbf{w}^T \mathbf{x} + b = 0$ define un hiperplano. El vector $\mathbf{w}$ es normal a ese hiperplano y b controla su posición. La distancia con signo de un punto al plano es proporcional a $z/\|\mathbf{w}\|_2$. La activación transforma esa cantidad: puede introducir un umbral, comprimirla en un intervalo o conservar únicamente su parte positiva.

Una neurona aislada tiene capacidad limitada. Su utilidad aparece al disponer muchas unidades en paralelo y componer capas. Tampoco “descubre” por sí sola causalidad. Ajusta asociaciones que reducen una función de pérdida; si un fondo, una marca o un artefacto correlaciona con la etiqueta, puede aprenderlo aunque carezca de significado para la tarea real.

15.1.2. Perceptrón

El perceptrón clásico es un clasificador binario lineal. Con etiquetas $y \in \{-1, +1\}$ predice

$$\hat{y} = \text{sign}(\mathbf{w}^T \mathbf{x} + b).$$

Ante un ejemplo mal clasificado, actualiza $\mathbf{w} \leftarrow \mathbf{w} + \eta y \mathbf{x}$ y $b \leftarrow b + \eta y$, donde $\eta > 0$ es la tasa de aprendizaje. La corrección mueve el plano hacia una orientación que favorece la clase verdadera. Si los datos son linealmente separables, el teorema de convergencia del perceptrón garantiza que el procedimiento encuentra una separación en un número finito de errores, aunque no necesariamente la de mayor margen.

La condición de error puede escribirse $y(\mathbf{w}^T \mathbf{x} + b) \leq 0$. Este producto es el margen con signo: positivo indica clasificación correcta y negativo, incorrecta. Una versión con margen deseado también actualiza ejemplos correctos pero demasiado próximos a la frontera.

El límite esencial es representacional. Problemas como XOR no pueden separarse con una sola recta en dos dimensiones. Añadir iteraciones no resuelve una incapacidad de la familia de funciones. Una capa oculta no lineal sí puede construir regiones intermedias y combinarlas. Esta distinción entre **optimización** y **capacidad** será recurrente: un modelo puede fallar porque no expresa la solución, porque no se optimiza adecuadamente o porque los datos no permiten identificarla.

El perceptrón usa una decisión discontinua y no genera por sí mismo probabilidades calibradas. Las redes modernas reemplazan el escalón durante el entrenamiento por activaciones diferenciables casi en todas partes y pérdidas que proporcionan gradientes informativos. Aun así, el perceptrón conserva valor pedagógico: muestra que aprender consiste en modificar parámetros a partir del desacuerdo entre predicción y etiqueta.

15.1.3. Capas de entrada, ocultas y de salida

Una **capa** agrupa unidades que procesan una misma representación. Para una capa densa l :

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \phi^{(l)}(\mathbf{z}^{(l)}),$$

con $\mathbf{a}^{(0)} = \mathbf{x}$. Si la capa anterior tiene n_{l-1} unidades y la actual n_l , entonces $\mathbf{W}^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$ y $\mathbf{b}^{(l)} \in \mathbb{R}^{n_l}$. Esta comprobación dimensional detecta muchos errores conceptuales y de implementación.

La **capa de entrada** no suele ejecutar aprendizaje: especifica la forma de los datos. Las **capas ocultas** producen representaciones intermedias. La **capa de salida** debe corresponder con la tarea. Una salida lineal es habitual en regresión; una sigmoide, en clasificación binaria o multietiqueta; y una distribución softmax de K componentes, en clasificación multiclase mutuamente excluyente.




Figura 14: Esquema de red neuronal

Profundidad y anchura describen aspectos distintos. La anchura es la cantidad de unidades o canales; la profundidad, la cantidad de transformaciones sucesivas. Una red profunda puede reutilizar cálculos y representar ciertas funciones de manera más eficiente que una red superficial extremadamente ancha. Sin embargo, más capas no garantizan mejor generalización: aumentan costo, dificultad de optimización y oportunidades de explotar ruido.

La representación aprendida es distribuida: un concepto no tiene por qué residir en una sola unidad. Distintos patrones de activación pueden codificar propiedades complementarias. Tampoco es correcto asignar automáticamente significado semántico a cada unidad. El significado operativo se evalúa por su efecto, estabilidad y relación con los datos, no mediante una etiqueta intuitiva elegida después de observar unos pocos casos.

15.1.4. Pesos y sesgos

Los parámetros entrenables de una capa densa son sus pesos y sesgos. Una red con tamaños $n_0, n_1, \dots, n_L$ contiene, solo en capas densas,

$$\sum_{l=1}^L (n_l n_{l-1} + n_l)$$

parámetros. Contarlos permite anticipar memoria, tiempo y riesgo de sobreajuste. Aplanar una imagen de $224 \times 224 \times 3$ y conectarla con 512 unidades exigiría más de 77 millones de pesos en la primera capa; una convolución evita esa explosión mediante conectividad local y pesos compartidos.

Un peso positivo favorece una activación cuando aumenta la entrada, uno negativo la inhibe y uno nulo elimina una conexión, pero esta interpretación local depende de las activaciones y capas posteriores. Reescalar una capa y compensar la siguiente puede conservar la misma función. Por tanto, magnitud de un peso aislado no equivale siempre a importancia global.

El sesgo permite responder aunque las entradas sean cero y desplazar umbrales. Omitirlo obliga a que todas las fronteras lineales pasen por el origen. En capas seguidas de ciertas operaciones de normalización puede resultar redundante, pero esa es una decisión arquitectónica, no una regla universal.

Los parámetros se distinguen de los **hiperparámetros**. Los primeros se estiman por gradiente: matrices, sesgos y, según la arquitectura, escalas de normalización. Los segundos se eligen mediante diseño y validación: profundidad, anchura, tasa de aprendizaje, regularización o tamaño de lote. Ajustar hiperparámetros mirando la prueba transforma de hecho esa prueba en validación y produce una estimación optimista.

15.1.5. Funciones de activación

Sin activaciones no lineales, la composición de capas afines sigue siendo afín:

$$\mathbf{W}^{(2)}(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}) + \mathbf{b}^{(2)} = \tilde{\mathbf{W}}\mathbf{x} + \tilde{\mathbf{b}}.$$

La profundidad no añadiría entonces fronteras curvas. La activación aporta no linealidad y determina propiedades del gradiente.

La sigmoide $\sigma(z) = 1/(1 + e^{-z})$ devuelve valores entre 0 y 1. Su derivada es $\sigma(z)(1 - \sigma(z))$. Es apropiada para una probabilidad binaria de salida, pero en capas ocultas satura cuando $|z|$ es grande y su gradiente se aproxima a cero. La tangente hiperbólica, $\tanh(z)$, está centrada en cero pero también satura.

La unidad lineal rectificadora, $\text{ReLU}(z) = \max(0, z)$, es simple y mantiene derivada uno para $z > 0$. Para $z < 0$ su derivada es cero; una unidad que recibe siempre preactivaciones negativas puede quedar “muerta”. Variantes con pendiente negativa pequeña mitigan ese riesgo. Otras activaciones suaves combinan comportamiento lineal y compuertas; su conveniencia es empírica y arquitectónica.

Para clases excluyentes, softmax transforma logits z_k en

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad \sum_k p_k = 1.$$

Por estabilidad numérica se resta $\max_j z_j$ antes de exponenciar, operación que no cambia el resultado. Los p_k son puntuaciones normalizadas y solo deben llamarse probabilidades confiables si el protocolo y la calibración lo sustentan. Un softmax siempre reparte masa entre clases conocidas, incluso ante una entrada ajena al dominio; de ahí la necesidad de controles de semejanza y abstención.

15.1.6. Propagación hacia adelante

La **propagación hacia adelante** (*forward pass*) evalúa la red desde la entrada hasta la salida. Para L capas, cada salida alimenta la siguiente. Al entrenar se conservan preactivaciones y activaciones necesarias para calcular derivadas; al inferir solo se requiere producir la salida, aunque algunas técnicas interpretativas guardan estados intermedios.

Pseudocódigo de propagación

```
ENTRADA: lote  $X$ , parámetros  $\{(W[l], b[l]) \text{ para } l = 1, \dots, L\}$ 
 $A[0] \leftarrow X$ 
PARA  $l \leftarrow 1$  HASTA  $L$ :
     $Z[l] \leftarrow W[l] A[l-1] + b[l]$ 
     $A[l] \leftarrow \text{activación}_l(Z[l])$ 
DEVOLVER  $A[L]$  y, durante entrenamiento, la memoria  $\{Z[l], A[l]\}$ 
```

La dimensión de lote suele añadirse como primer eje. Las mismas operaciones se aplican simultáneamente a varios ejemplos; no significa que unos deban influir en la predicción de otros, salvo operaciones explícitas dependientes del lote. El vector final antes de softmax se denomina **logits**. La clase predicha es normalmente $\arg \max_k z_k$, equivalente a maximizar softmax, pero el vector completo contiene información sobre competencia entre clases.

Entrenamiento e inferencia no siempre ejecutan exactamente lo mismo. Dropout se desactiva en inferencia y las capas de normalización dependientes del lote usan estadísticas acumuladas. Olvidar este cambio causa resultados variables o degradados. También debe aplicarse la misma normalización determinista de entradas definida con entrenamiento.

El costo del forward depende de arquitectura, resolución y tamaño de lote. Medir solo cantidad de parámetros no basta: una operación con pocos filtros aplicada sobre mapas grandes puede requerir muchas multiplicaciones. Latencia, memoria y rendimiento por lote son criterios distintos y deben evaluarse en el entorno de uso previsto.

15.1.7. Capacidad de representación

Los teoremas de aproximación universal establecen, bajo ciertas condiciones, que una red con una capa oculta suficientemente ancha puede aproximar funciones continuas en dominios compactos. No indican cuántas unidades se requieren, que el entrenamiento encuentre esa función, ni que generalice con datos finitos. Son resultados de existencia, no garantías prácticas.

La profundidad introduce una preferencia por composiciones jerárquicas. En visión, operaciones locales pueden formar bordes; los bordes, motivos; y los motivos, estructuras de mayor escala. Esa descripción es útil, aunque no todas las redes siguen una jerarquía semántica limpia. Las representaciones dependen del objetivo, la arquitectura y los sesgos del conjunto.

Capacidad insuficiente produce **subajuste**: pérdidas altas tanto en entrenamiento como en validación. Capacidad excesiva facilita reducir mucho el error de entrenamiento y puede producir **sobreajuste**. Sin embargo, el número de parámetros no determina por sí solo la generalización de redes modernas. Optimización, regularización implícita, aumento y estructura de datos también importan.

Debe distinguirse memorizar de aprender invariancias pertinentes. Si todas las imágenes de una clase comparten un fondo particular, una red de alta capacidad puede lograr excelentes métricas internas usando el fondo. Una prueba construida con la misma procedencia no revelará el problema. Auditorías, particiones por unidad independiente, galerías de errores y validación externa son complementos indispensables.

Un buen diseño introduce **sesgos inductivos** compatibles con el problema. Las convoluciones presuponen localidad y reutilización espacial; el aumento expresa transformaciones que deberían conservar etiqueta; la transferencia aporta representaciones aprendidas en otra colección. Ningún sesgo es universalmente correcto. Por ejemplo, un cambio fuerte de color no es inocuo si la coloración forma parte de la señal visual.

15.1.8. Ejemplo práctico guiado: construcción de una red neuronal mínima

Considérese un problema didáctico bidimensional con dos clases y una frontera no lineal. El propósito no es obtener un producto, sino relacionar geometría, activaciones y entrenamiento. Se generan puntos con semilla registrada, se reservan conjuntos antes de ajustar y se estandarizan ambas coordenadas usando solo entrenamiento. Una red mínima puede tener dos entradas, una capa oculta pequeña con ReLU y dos logits de salida.

Antes de entrenar se visualizan datos y se prueba una frontera lineal. Si el patrón exige combinar varias regiones, el error persistente del modelo lineal ilustra su sesgo, no un fallo de iteraciones. Luego se inicializa la red y se evalúa una cuadrícula. Cada punto de la cuadrícula atraviesa el forward; el color representa la clase o probabilidad resultante.

El experimento debe variar un único factor por vez: número de unidades, activación o tasa. Una red demasiado estrecha puede generar una frontera rígida; otra muy ancha puede crear contornos que persiguen observaciones aisladas. Con activación lineal, varias capas colapsan a una transformación lineal. Con una no lineal aparecen regiones por tramos.

Procedimiento práctico

```
fijar semilla y generar datos
separar entrenamiento y validación
ajustar normalización solo con entrenamiento
inicializar una red 2 -> H -> 2
REPETIR por época:
    ejecutar forward sobre mini-lotes
    calcular entropía cruzada
    retropropagar y actualizar parámetros
    registrar pérdidas de entrenamiento y validación
```

seleccionar la época según validación
dibujar frontera y marcar errores

El informe debe incluir frontera antes y después, curvas y tres ejemplos cercanos a la decisión. No basta afirmar que “la red aprendió”: hay que explicar qué cambió y si el patrón se sostiene fuera de entrenamiento. Este ejemplo autoriza implementación por su finalidad práctica; la teoría precedente permanece independiente del lenguaje.

Actividad EMO [VEG-01]: preparar un dataset de imágenes vegetales

Capacidad mínima: organizar imágenes, clases y particiones reproducibles sin contaminación.

La actividad inicia la cadena del Apéndice D. Se usa PlantVillage en configuración obligatoria color, con versión o fecha de descarga registrada. Cada equipo selecciona un cultivo con al menos tres clases, por ejemplo papa, manzana, maíz, uva o tomate, y mantiene ese alcance durante las actividades VEG-01 a VEG-04. No se mezclan color, grayscale y segmented: representan derivaciones de las mismas hojas y no observaciones independientes.

La unidad física relevante es la hoja, identificada por `leaf_id`. Se conserva intacta la prueba oficial. A partir del entrenamiento oficial se crean entrenamiento y validación agrupando por `leaf_id` y estratificando por clase en la medida compatible con ese agrupamiento. Si la versión no expone el identificador, se recupera del mapa oficial `leaf_grouping/leaf-map.json`; dividir aleatoriamente por imagen no es aceptable. Deben verificarse intersecciones vacías de identificadores entre conjuntos.

La auditoría incluye dimensiones, canales, formatos, archivos corruptos, distribución por label, crop y disease, número de imágenes por hoja, hashes exactos y perceptuales, y galerías por clase. `image_path` se conserva para trazabilidad, pero no entra al modelo porque su texto puede revelar carpetas o clases. Las decisiones sobre exclusión se documentan sin alterar silenciosamente la prueba.

Evidencia individual: notebook práctico, manifiesto de particiones con semilla y listas de `leaf_id`, tabla de imágenes y hojas por clase, galería de control y reglas de inclusión. El notebook puede contener el código necesario para realizar la actividad.

Criterios de aprobación: prueba oficial sin uso durante desarrollo; ausencia demostrada de fuga por hoja; transformaciones que preservan la señal; desbalance y procedencia documentados. Debe constar desde ahora que el objetivo es clasificar clases PlantVillage bajo imágenes semejantes a sus condiciones controladas. No es diagnóstico de campo, no estima severidad y no recomienda tratamiento.

15.2. Entrenamiento de redes profundas

15.2.1. Funciones de pérdida

La pérdida convierte la discrepancia entre objetivo y predicción en un escalar optimizable. Para n ejemplos, el riesgo empírico regularizado suele escribirse

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(\mathbf{x}_i), y_i) + \lambda \Omega(\theta).$$

ℓ mide error por ejemplo, Ω penaliza ciertas soluciones y θ reúne parámetros. Minimizar J no equivale a minimizar cualquier costo real; la pérdida es una aproximación y debe corresponder al tipo de salida.

En regresión, el error cuadrático medio $\ell = (y - \hat{y})^2$ penaliza intensamente errores grandes y corresponde a una hipótesis gaussiana con varianza constante. El error absoluto es más robusto pero no diferenciable en cero, donde se usa un subgradiente. En clasificación binaria, con $p = \sigma(z)$,

$$\ell = -[y \log p + (1 - y) \log(1 - p)].$$

Para K clases excluyentes, la entropía cruzada es $\ell = -\sum_k y_k \log p_k = -\log p_y$. Conviene calcularla directamente desde logits mediante una operación log-sum-exp estable, no tomar logaritmos de probabilidades redondeadas.

Una pérdida decreciente no asegura una métrica de decisión creciente. Accuracy ignora confianza y puede ocultar clases minoritarias; macro-F1 pondera clases por igual pero no es una pérdida suave habitual. Se entrena con una función diferenciable y se selecciona con métricas alineadas al uso. Los pesos de clase pueden compensar representación desigual, aunque alteran el objetivo y no crean información ausente.

Las etiquetas también pueden ser inciertas o erróneas. Una red de gran capacidad puede terminar memorizándolas. Pérdidas robustas, suavizado de etiquetas y auditoría ayudan, pero no sustituyen revisar el proceso de anotación. En el caso vegetal, una etiqueta PlantVillage define una clase del dataset, no una confirmación clínica individual.

15.2.2. Descenso del gradiente

El gradiente $\nabla_{\theta} J$ apunta hacia el crecimiento local más rápido. El descenso actualiza en dirección opuesta:

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} J(\theta_t),$$

donde η_t es la tasa de aprendizaje. La aproximación de Taylor $J(\theta + \Delta) \approx J(\theta) + \nabla J^{\top} \Delta$ explica por qué $\Delta = -\eta \nabla J$ reduce localmente la función para pasos pequeños.

En redes, el paisaje no es convexo. Hay puntos silla, regiones planas, simetrías y curvaturas muy distintas. No se espera hallar un mínimo global único; se busca una solución con buen desempeño de validación. Además, permutar unidades ocultas puede representar exactamente la misma función, de modo que parámetros diferentes no implican modelos funcionalmente distintos.

Una tasa demasiado alta causa oscilación o divergencia; una demasiado baja hace lento el avance y puede quedar en mesetas. Métodos con momento acumulan una media de gradientes para amortiguar ruido y avanzar por direcciones persistentes. Optimizadores adaptativos reescalan coordenadas según momentos

recientes. Son herramientas de optimización, no garantías de generalización, y sus hiperparámetros deben registrarse.

Diagnósticos útiles incluyen pérdida no finita, norma del gradiente, norma de parámetros, porcentaje de activaciones nulas y sensibilidad a varias semillas. Si la pérdida aumenta de inmediato, se revisan tasa, escala de entradas, fórmula y etiquetas. Si no cambia, se comprueba que parámetros reciban gradiente y sean actualizados. Recortar gradientes puede controlar explosiones, pero si se activa constantemente quizá oculte una causa estructural.

15.2.3. Retropropagación

La retropropagación calcula eficientemente derivadas aplicando la regla de la cadena desde la pérdida hacia capas anteriores. No es el optimizador: produce gradientes; el optimizador decide la actualización.

Para una red densa, definamos $\delta^{(l)} = \partial \ell / \partial \mathbf{z}^{(l)}$. En la última capa softmax con entropía cruzada se obtiene una simplificación central. Como

$$\frac{\partial p_j}{\partial z_k} = p_j (\mathbb{1}[j = k] - p_k),$$

y $\ell = -\sum_j y_j \log p_j$, entonces

$$\frac{\partial \ell}{\partial z_k} = p_k - y_k, \quad \delta^{(L)} = \mathbf{p} - \mathbf{y}.$$

Para una capa oculta:

$$\delta^{(l)} = (\mathbf{W}^{(l+1)})^\top \delta^{(l+1)} \odot \phi'(\mathbf{z}^{(l)}),$$

donde $\odot$ es producto elemento a elemento. Por la derivada de la transformación afín,

$$\frac{\partial \ell}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} (\mathbf{a}^{(l-1)})^\top, \quad \frac{\partial \ell}{\partial \mathbf{b}^{(l)}} = \delta^{(l)}, \quad \frac{\partial \ell}{\partial \mathbf{a}^{(l-1)}} = (\mathbf{W}^{(l)})^\top \delta^{(l)}.$$

En un lote se suman o promedian contribuciones. Si la pérdida usa media, cambiar tamaño de lote no debería multiplicar mecánicamente la escala del gradiente.

Pseudocódigo de retropropagación

```
delta[L] <- derivada de la pérdida respecto de Z[L]
PARA l <- L HASTA 1:
  grad_W[l] <- promedio_lote(delta[l] por A[l-1]^T)
  grad_b[l] <- promedio_lote(delta[l])
  SI l > 1:
    delta[l-1] <- W[l]^T delta[l] * activación'_(l-1)(Z[l-1])
DEVOLVER todos los gradientes
```

Productos repetidos por pesos y derivadas pueden desvanecer o explotar gradientes. Inicialización, activaciones, normalización y conexiones residuales buscan mejorar ese flujo. Una verificación por diferencias finitas, $(J(\theta + \epsilon) - J(\theta -$

$\epsilon)/(2\epsilon)$, es útil en componentes pequeños, aunque costosa y sensible al valor de ϵ .

15.2.4. Mini-batches, épocas y tasa de aprendizaje

El gradiente completo usa todos los ejemplos; el estocástico usa uno; un **mini-batch** usa un subconjunto. Si B es el lote,

$$\widehat{\nabla} J_B = \frac{1}{|B|} \sum_{i \in B} \nabla \ell_i$$

estima el gradiente empírico. Su ruido puede ayudar a salir de regiones desfavorables y actúa como regularización implícita, mientras el cálculo vectorizado aprovecha el hardware.

Una **época** es un recorrido por el conjunto de entrenamiento, no una cantidad fija de actualizaciones: aproximadamente hay $\lceil n/|B| \rceil$ pasos. Comparar entrenamientos por épocas puede ser engañoso si cambian tamaño del dataset o lote; deben registrarse pasos y ejemplos procesados.

El lote se baraja en entrenamiento, salvo que la estructura del problema exija otro muestreo. En imágenes relacionadas, el agrupamiento de particiones evita fuga, pero los lotes pueden mezclar hojas dentro del entrenamiento. Muestreos balanceados cambian la distribución observada y deben documentarse. Validación no se aumenta ni se baraja por necesidad estadística.

La tasa puede seguir un calendario: calentamiento inicial, disminución por pasos, coseno o reducción ante meseta. El calentamiento evita cambios bruscos al inicio, especialmente con lotes grandes. Reducir la tasa permite refinar una solución, pero hacerlo muy pronto puede congelar un modelo subajustado.

Una prueba de rango, aumentando temporalmente la tasa mientras se observa la pérdida, puede sugerir escalas plausibles. No reemplaza validación. También importa la tasa efectiva al ajustar una base preentrenada: capas ya útiles suelen requerir cambios menores que una cabeza nueva.

15.2.5. Inicialización y normalización

Inicializar todos los pesos ocultos en cero conserva simetría: las unidades reciben iguales gradientes y siguen aprendiendo lo mismo. Se usan valores aleatorios con varianza controlada. Si una capa tiene fan_in entradas, inicializaciones adecuadas para activaciones rectificadas emplean una varianza del orden de $2/\text{fan_in}$; para activaciones simétricas se considera también fan_out . El objetivo es mantener escalas razonables de activaciones y gradientes a través de capas.

La normalización de entrada se calcula únicamente con entrenamiento. En imágenes puede reescalar intensidades y estandarizar canales. Si se usa transferencia, se respeta el preprocesamiento esperado por la base preentrenada. Estimar medias con prueba constituye una fuga pequeña pero evitable.

La normalización por lote transforma activaciones usando media y varianza del mini-batch y luego aprende escala y desplazamiento. Durante inferencia utiliza estadísticas acumuladas. Puede acelerar la optimización, pero lotes pequeños producen estimaciones ruidosas y datos no idénticamente distribuidos

pueden volver problemáticas sus estadísticas. Otras técnicas normalizan por características de cada ejemplo y no dependen del resto del lote.

Normalizar no elimina la necesidad de una tasa correcta ni garantiza calibración. Tampoco debe confundirse con regularización: aunque el ruido de estadísticas puede regularizar, su finalidad principal es acondicionar la optimización. Un fallo frecuente ocurre cuando se evalúa manteniendo el modo de entrenamiento; las predicciones pasan a depender de qué otras imágenes integran el lote.

Varias semillas permiten evaluar sensibilidad a inicialización y orden. Si pequeñas variaciones producen resultados muy dispares, informar solo la mejor ejecución oculta inestabilidad. Se reportan media, dispersión y criterio de selección cuando el costo lo permite.

15.2.6. Regularización y dropout

Regularizar significa introducir preferencias que reduzcan sobreajuste. La penalización L_2 , $\lambda \|\mathbf{W}\|_2^2$, desalienta pesos grandes. Su gradiente añade $2\lambda\mathbf{W}$. La **decadencia de pesos** implementa una contracción durante la actualización; coincide con L_2 en descenso simple, pero no necesariamente en optimizadores adaptativos. L_1 favorece ceros, aunque no siempre genera modelos computacionalmente dispersos sin soporte específico.

Dropout multiplica activaciones por una máscara Bernoulli durante entrenamiento. Con probabilidad de conservación q :

$$\tilde{\mathbf{a}} = \frac{\mathbf{m} \odot \mathbf{a}}{q}, \quad m_j \sim \text{Bernoulli}(q).$$

El factor $1/q$ conserva la esperanza y permite usar las activaciones sin máscara en inferencia. Dropout impide depender siempre de coadaptaciones específicas, pero una tasa alta destruye señal y ralentiza convergencia. En redes convolucionales modernas puede ser menos decisivo que aumento, decadencia y diseño arquitectónico.

También regularizan la reducción de capacidad, el aumento válido, el ruido, el suavizado de etiquetas y la detención temprana. No se aplican todos por reflejo. Un modelo que subajusta no mejora agregando más penalización. La elección se basa en la brecha entre entrenamiento y validación, estabilidad y errores.

La regularización no corrige una partición contaminada. Si imágenes de la misma hoja aparecen en entrenamiento y validación, el resultado será optimista incluso con dropout. Tampoco corrige cambio de dominio. Es una herramienta para generalizar dentro de supuestos, no una licencia para ignorar procedencia.

15.2.7. Early stopping

La detención temprana interrumpe el entrenamiento cuando una métrica de validación deja de mejorar. Se define de antemano una métrica, dirección, mejora mínima y **paciencia**. Se conserva el estado de la mejor época, no necesariamente el último.

```
mejor <- infinito
espera <- 0
PARA cada época:
```

```
entrenar una época
evaluar pérdida de validación
SI mejora al menos delta:
    guardar parámetros y estado
    mejor <- valor actual; espera <- 0
EN OTRO CASO:
    espera <- espera + 1
SI espera >= paciencia: detener
restaurar el mejor estado
```

La paciencia evita reaccionar a ruido. Una validación pequeña puede producir curvas erráticas; detenerse sobre cada fluctuación aumenta la varianza de selección. Si se prueban muchas configuraciones contra la misma validación, también se sobreajusta a ella. En ese caso se limita la búsqueda, se usan repeticiones o se dispone de una validación final adicional.

Early stopping tiene efecto regularizador porque restringe cuánto se ajustan parámetros a detalles del entrenamiento. Sin embargo, una meseta puede deberse a tasa inadecuada. Un calendario que reduzca tasa antes de detener puede distinguir falta de refinamiento de sobreajuste. La prueba oficial nunca decide la época.

15.2.8. Aceleración mediante GPU

Una GPU ejecuta numerosas operaciones aritméticas en paralelo, especialmente multiplicaciones de matrices y convoluciones. El beneficio crece cuando hay suficiente trabajo vectorizado. Modelos diminutos, lotes pequeños o pipelines limitados por lectura y decodificación pueden no acelerarse sustancialmente.

La memoria almacena parámetros, gradientes, estados del optimizador y activaciones. Durante entrenamiento, estas últimas suelen dominar. Reducir lote, resolución o precisión puede aliviar memoria. La precisión mixta combina formatos numéricos para aumentar rendimiento; requiere escalado de pérdida u otros controles para evitar subdesbordamiento. Resultados NaN exigen revisar estabilidad, no culpar automáticamente al dispositivo.

La transferencia de datos entre CPU y GPU puede ser cuello de botella. Carga paralela, almacenamiento adecuado y transformaciones eficientes ayudan. Se mide utilización y tiempo por etapa antes de optimizar. Acumular gradientes simula un lote efectivo mayor cuando la memoria es limitada, aunque las operaciones dependientes del lote pueden comportarse de otro modo.

Algunas operaciones paralelas no son deterministas. Registrar hardware, versiones, semillas y opciones mejora reproducibilidad, pero reproducibilidad bit a bit puede costar rendimiento y no siempre es posible. Reproducibilidad científica exige además datos, particiones y protocolo, no solo una semilla.

Una GPU acelera tanto un experimento válido como uno defectuoso. No corrige etiquetas, fuga, objetivos ambiguos o evaluación reiterada sobre prueba. El costo energético y material también debe reportarse de forma proporcionada: tiempo, dispositivo, número de ejecuciones y criterio para detener búsquedas.

15.2.9. Ejemplo práctico guiado: diagnóstico del entrenamiento

Se entrena una red pequeña sobre el subconjunto PlantVillage ya preparado, usando únicamente entrenamiento y validación. El objetivo es interpretar curvas, no elegir todavía la arquitectura más potente. Se comparan dos configuraciones que difieren en un solo factor, por ejemplo tasa de aprendizaje o fuerza de regularización, y se repiten con semillas registradas.

Cuatro patrones orientan el diagnóstico. Primero, pérdidas altas y próximas indican subajuste: revisar capacidad, tasa, representaciones o errores del pipeline. Segundo, entrenamiento mejora mientras validación empeora: sobreajuste; considerar aumento válido, regularización, menos capacidad o early stopping. Tercero, ambas pérdidas oscilan violentamente o divergen: tasa alta, entradas mal escaladas o gradientes inestables. Cuarto, pérdida casi constante: tasa baja, parámetros congelados, etiquetas incorrectas o gradiente interrumpido.

No toda separación es sobreajuste. La pérdida de entrenamiento puede incluir dropout y aumento mientras validación no, por lo que incluso puede aparecer mayor. Se comparan métricas bajo modo de evaluación y se inspeccionan ejemplos. Accuracy alta con macro-F1 baja sugiere dominio de clases frecuentes. Una pérdida que mejora sin cambio de accuracy puede estar aumentando márgenes o calibración.

El registro mínimo contiene época, paso, tasa, pérdidas, accuracy, macro-F1, tiempo, norma de gradiente y mejor época. La prueba oficial permanece cerrada. El diagnóstico escrito debe vincular evidencia y acción: “la brecha comienza después de la época 12; se restaura esa época y se ensaya regularización”, no “el modelo parece malo”.

Actividad EMO [VEG-02]: entrenar y diagnosticar un baseline neuronal

Capacidad mínima: interpretar entrenamiento y aplicar controles básicos de generalización.

Sobre las particiones congeladas en VEG-01, se implementan dos referencias: clase mayoritaria y una red visual pequeña o representación sencilla. La primera establece una dificultad mínima; la segunda permite observar gradientes y curvas. Se registran pérdida, accuracy y macro-F1 por época, además de tasa, tiempo y mejor estado.

Cada estudiante compara al menos dos configuraciones de tasa, regularización o early stopping, manteniendo constantes arquitectura, datos, semilla inicial y presupuesto cuando sea posible. La validación decide configuración y época. La prueba oficial no se consulta. Las métricas por clase son obligatorias porque un promedio puede esconder una condición vegetal con recall bajo.

Evidencia individual: notebook de implementación, configuración reproducible, historial completo, curvas comparables y diagnóstico de subajuste, sobreajuste o inestabilidad con una corrección plausible. Se documenta cualquier ponderación o muestreo de clases.

Fallo deliberado recomendado: ejecutar una tasa claramente excesiva durante pocas iteraciones seguras, detener ante divergencia y contrastar normas y curvas.

El propósito es reconocer señales, no buscar una buena puntuación. Nunca se selecciona el “mejor” resultado entre muchas semillas sin informar el proceso.

El producto sigue limitado a clases del cultivo seleccionado en imágenes semejantes a PlantVillage. La confianza de este baseline no habilita diagnóstico de campo ni severidad. El aporte es establecer una referencia y criterios de entrenamiento para juzgar la CNN posterior.

15.3. Imágenes digitales y redes convolucionales

15.3.1. Píxeles, canales y resolución

Una imagen digital muestrea una escena sobre una cuadrícula. Cada píxel contiene intensidades por canal. En RGB hay tres canales, pero sus números dependen de espacio de color, profundidad de bits y transformaciones previas. Un valor no es una propiedad absoluta del objeto: iluminación, sensor, compresión y balance de blancos intervienen.

La resolución espacial $H \times W$ determina cuántas muestras se conservan. Redimensionar reduce costo, pero puede borrar lesiones pequeñas o deformar proporciones si no se preserva la relación de aspecto. Recortar puede eliminar contexto o señal. Rellenar conserva proporciones, aunque introduce bordes artificiales. Estas decisiones son parte del modelo y deben validarse.

La cuantización representa intensidades con niveles discretos. Convertir enteros a valores reales no crea información; facilita operaciones. Compresión con pérdida introduce bloques y halos que una red puede explotar. Si clases o particiones provienen de procesos de compresión distintos, el modelo puede aprender procedencia.

Color y fondo son simultáneamente señal y posible confusor. En PlantVillage color, la coloración puede ser relevante para distinguir condiciones, mientras el fondo controlado limita generalización. Convertir a gris o segmentar fondo cambia la tarea; no se mezclan esas configuraciones como observaciones nuevas. Una comparación opcional debe emparejar las mismas hojas mediante `leaf_id`.

La inspección visual no se reemplaza por estadísticas. Galerías aleatorias y por clase revelan orientación, escalas, bordes, etiquetas dudosas y artefactos. A la vez, una galería pequeña no demuestra representatividad: se acompaña con distribuciones, hashes y trazabilidad.

15.3.2. Tensores de imágenes

Una colección de imágenes se representa como tensor. Una imagen puede usar orden $H \times W \times C$ o $C \times H \times W$; un lote añade N . Ningún orden es matemáticamente superior, pero mezclar convenciones provoca errores silenciosos. Deben declararse ejes y comprobarse formas en cada etapa.

Para un lote $\mathbf{X} \in \mathbb{R}^{N \times C \times H \times W}$, $X_{n,c,i,j}$ es la intensidad del ejemplo n , canal c , fila i y columna j . Las transformaciones geométricas actúan sobre ejes espaciales; la normalización por canal actúa sobre c . Normalizar accidentalmente cada imagen de forma que elimine diferencias relevantes puede alterar la señal.

El almacenamiento suele usar enteros; el cálculo, punto flotante. Reescalar a $[0, 1]$ y estandarizar son operaciones distintas. Si μ_c y s_c se estiman en entrenamiento,

$$X'_{n,c,i,j} = \frac{X_{n,c,i,j} - \mu_c}{s_c + \epsilon}.$$

La misma transformación se aplica a validación, prueba e inferencia. Con una red preentrenada se usa la convención correspondiente a su preentrenamiento.

La resolución afecta memoria aproximadamente en proporción a HW para activaciones de una capa, pero capas sucesivas y gradientes amplifican el efecto. Duplicar alto y ancho cuadriplica posiciones. Por eso la selección de resolución equilibra detalle, cómputo y tamaño efectivo de muestra.

15.3.3. Convolución y filtros

Una convolución discreta en redes suele implementarse como correlación cruzada. Para una entrada X y un kernel K de tamaño $r \times s$:

$$Y_{i,j} = b + \sum_{u=0}^{r-1} \sum_{v=0}^{s-1} K_{u,v} X_{i+u,j+v}.$$

Con varios canales de entrada, cada filtro tiene forma $C_{in} \times r \times s$ y suma sobre canales. Con C_{out} filtros se producen C_{out} mapas. La cantidad de parámetros es $C_{out}(C_{in}rs + 1)$, independiente del alto y ancho de entrada.

Dos ideas definen la convolución: **conectividad local**, porque cada salida mira un vecindario, y **pesos compartidos**, porque el mismo filtro se aplica en todas las posiciones. Esto expresa que un patrón puede ser útil donde aparezca y reduce drásticamente parámetros. La equivariancia a traslación es aproximada: desplazar la entrada tiende a desplazar el mapa, pero bordes, stride y pooling la alteran.

Un filtro no se programa necesariamente como detector de borde; sus coeficientes se aprenden por retropropagación. Capas iniciales suelen responder a contrastes y orientaciones, pero interpretar cada kernel aislado puede ser difícil. El campo receptivo efectivo crece al apilar capas: una unidad profunda integra regiones mayores aunque cada kernel sea pequeño.

Filtros 1×1 combinan canales en cada posición y cambian dimensión sin mezclar vecinos espaciales. Convoluciones separables reducen cálculo descomponiendo mezcla espacial y de canales. Estas variantes conservan la idea general, pero imponen factorizaciones diferentes que pueden favorecer eficiencia.

15.3.4. Mapas de características

La salida de un filtro es un **mapa de características**. Cada posición indica respuesta del filtro en su campo receptivo. Tras activación y normalización, mapas sucesivos forman una representación espacial. Un canal no equivale de manera estable a un concepto; puede participar en varios patrones y su función depende de los demás.

El campo receptivo teórico puede calcularse recursivamente. Si una capa usa kernel k_l y stride s_l , el salto entre posiciones respecto de la entrada se actualiza $j_l = j_{l-1}s_l$, y el campo $r_l = r_{l-1} + (k_l - 1)j_{l-1}$. Esto ayuda a saber si una salida puede integrar una lesión completa o solo textura local. El campo efectivo observado suele concentrarse en una parte del teórico.

Visualizar mapas puede detectar canales inactivos o respuestas a bordes del fondo, pero seleccionar solo ejemplos convincentes produce una narrativa sesgada. Se usan conjuntos predefinidos, capas y escalas comparables. Las activaciones grandes no prueban causalidad: para ello se estudian perturbaciones, gradientes y desempeño bajo controles.

Reducir resolución mientras aumentan canales es un patrón frecuente. Las primeras capas preservan ubicación fina; las profundas resumen semántica. Para clasificación, una agregación espacial global puede convertir cada canal en un valor y alimentar la salida, reduciendo parámetros frente a aplanar todo.

15.3.5. Padding y stride

El **padding** añade posiciones alrededor de la entrada. Sin relleno, una convolución válida reduce dimensiones. Con tamaño de entrada H , padding total simétrico P por lado, kernel K , dilatación D y stride S , la salida es

$$H_{out} = \left\lfloor \frac{H + 2P - D(K - 1) - 1}{S} \right\rfloor + 1.$$

La misma fórmula se aplica al ancho. Un padding “same” con stride uno suele conservar dimensión para kernels impares. El relleno con ceros crea un contexto artificial; reflexión u otras alternativas cambian el supuesto. Los píxeles cercanos al borde reciben un tratamiento distinto y pueden aparecer artefactos.

El **stride** es el salto del kernel. Un stride mayor que uno reduce resolución y cómputo, pero submuestrea. Patrones pequeños pueden desaparecer o cambiar ante desplazamientos mínimos. Una operación suavizante antes de submuestrear puede reducir aliasing. Pooling y convolución con stride son dos formas de reducir mapas, con propiedades distintas.

La dilatación separa elementos del kernel para ampliar campo receptivo sin aumentar tanto parámetros. Puede dejar patrones de muestreo en rejilla. Ninguna combinación debe elegirse solo porque produce formas convenientes: se considera tamaño de señal, invariancia deseada y costo.

Comprobar dimensiones a mano para una arquitectura pequeña evita errores. También permite identificar cuándo la red comprime demasiado pronto. Si una característica relevante ocupa pocos píxeles, varias reducciones sucesivas pueden eliminarla antes de que capas profundas la representen.

15.3.6. Pooling

Pooling resume un vecindario por canal. Max pooling conserva el máximo; average pooling, la media. Con ventana 2×2 y stride 2 reduce aproximadamente a la mitad cada dimensión. No añade pesos y aporta cierta robustez a desplazamientos locales, pero pierde ubicación precisa.

En retropropagación, max pooling dirige el gradiente a la posición que produjo el máximo; average pooling lo reparte. Empates requieren una convención. La selección del máximo puede amplificar activaciones espurias y ser sensible al ruido; la media puede diluir señales pequeñas. El comportamiento apropiado depende de la tarea.

La invariancia no es gratuita. Clasificación suele tolerar parte de la ubicación, mientras segmentación necesita detalle espacial. Arquitecturas densas conservan mapas o recuperan resolución mediante rutas de decodificación y conexiones desde capas tempranas. Para clasificación global, el promedio global sobre cada mapa reduce parámetros y vincula canales con evidencia distribuida.

Hoy se usan también convoluciones con stride aprendibles en lugar de pooling. No existe obligación de incluir pooling. Se compara por desempeño, estabilidad y costo. Una reducción demasiado agresiva puede explicar que el modelo confunda clases cuya diferencia está en patrones pequeños.

15.3.7. Arquitecturas convolucionales

Una CNN de clasificación típica repite bloques de convolución, normalización y activación, reduce gradualmente resolución, agrega espacialmente y produce logits. Las arquitecturas profundas incorporan conexiones residuales:

$$\mathbf{y} = F(\mathbf{x}; \theta) + \mathbf{x},$$

que ofrecen una ruta directa para información y gradiente. Si cambian dimensiones, la ruta se proyecta. Estas conexiones facilitan entrenar profundidad, pero no eliminan la necesidad de datos y regularización.

Bloques con cuellos de botella y convoluciones separables buscan eficiencia. La calidad debe evaluarse junto con parámetros, operaciones, memoria y latencia real. Un modelo con menos operaciones teóricas puede ser más lento en cierto dispositivo por patrones de acceso o soporte incompleto.

La cabeza de clasificación define el número de clases del cultivo elegido. Su salida no debe incluir clases ausentes como si fueran posibles. En transferencia, la base extrae características y la cabeza nueva se inicializa para la tarea. Una CNN desde cero permite estudiar el sesgo convolucional; una preentrenada suele ser más eficiente con datos limitados.

Los fallos frecuentes incluyen reducción espacial prematura, cabeza enorme, normalización incorrecta, uso de resolución distinta entre entrenamiento e inferencia y fuga a través del pipeline. Una arquitectura más famosa no compensa un protocolo inválido. Se empieza por una red verificable, se supera la clase mayoritaria y se aumenta complejidad solo con evidencia.

15.3.8. Ejemplo práctico guiado: clasificación de imágenes vegetales

Se construye una CNN sencilla para el cultivo seleccionado en VEG-01. Las particiones y clases no cambian. Entrenamiento puede recibir aumentos previamente justificados; validación recibe solo redimensionamiento y normalización deterministas. La prueba oficial sigue reservada.

Antes de entrenar, una pasada de un lote comprueba formas, rango, etiquetas y pérdida finita. Luego se intenta sobreajustar un subconjunto diminuto. Si la CNN no logra reducir fuertemente su pérdida, hay indicios de fallo en datos, salida, gradientes o capacidad. Superar esta prueba no demuestra generalización, pero evita gastar recursos en un pipeline roto.

La arquitectura base puede usar tres bloques convolucionales, reducción gradual, promedio global y una cabeza pequeña. Se registran dimensiones y parámetros. La comparación con la red superficial usa mismos conjuntos y métricas. Se selecciona por validación y solo entonces se evalúa una vez sobre prueba.

La matriz de confusión se acompaña con precisión, recall, F1 y soporte por clase. La galería de validación incluye aciertos de alta y baja confianza, errores de alta confianza y abstenciones potenciales. Cada imagen se comenta con hipótesis comprobables: calidad, recorte, semejanza entre clases, orientación o fondo. No se afirma que una zona “causó” la predicción solo por una visualización.

El ejemplo termina con una ficha provisional: cultivo, clases, versión, preprocesamiento, particiones por `leaf_id`, métricas, errores y uso permitido. El nombre correcto del resultado es clasificador de imágenes semejantes a PlantVillage, no detector clínico de enfermedades.

Actividad EMO [VEG-03]: construir y evaluar una CNN

Capacidad mínima: implementar una red convolucional y analizar su comportamiento por clase.

Cada estudiante entrena una CNN sencilla sobre el manifiesto congelado y la compara con clase mayoritaria y baseline neuronal. La arquitectura base puede compartirse, pero entrenamiento, trazabilidad y análisis son individuales. Cambiar particiones para mejorar resultados invalida la comparación.

Evidencia individual: notebook práctico con arquitectura y formas, número de parámetros, hiperparámetros, curvas, matriz de confusión, accuracy, macro-F1, precisión, recall y F1 por clase, más una galería comentada de aciertos y errores. Durante desarrollo la galería usa validación. La prueba oficial se abre solo tras fijar arquitectura, época, preprocesamiento y criterio de selección.

El análisis distingue confusiones entre condiciones del mismo cultivo y examina si calidad, escala, orientación o fondo se asocian con errores. También comprueba si hay hojas con varias imágenes que dominan una clase. Las explicaciones son hipótesis y deben marcarse como tales.

Criterios de aprobación: superar o explicar la relación con baselines; usar exclusivamente particiones establecidas; informar desempeño por clase; relacionar fallos con cobertura sin extrapolar. Un resultado alto en prueba oficial no valida fotografías de campo, ni autoriza severidad o tratamiento. El aporte es un clasificador específico y auditable dentro del dominio educativo.

15.4. Transferencia, evaluación y tareas avanzadas de visión

15.4.1. Aumento de datos

El aumento genera variantes durante entrenamiento mediante transformaciones que deberían conservar etiqueta. Expresa invariancias y expande la diversidad observada, pero no crea nueva diversidad de procedencia. Rotaciones moderadas, reflejos, recortes, cambios suaves de escala o color pueden ser plausibles; su validez depende de la tarea.

Una transformación es peligrosa si elimina la región informativa, altera color diagnóstico, introduce bordes irreales o convierte una clase en otra. La intensidad se decide observando ejemplos transformados y desempeño de validación. La composición puede ser mucho más agresiva que cada operación aislada.

Solo entrenamiento se aumenta estocásticamente. Validación y prueba usan transformaciones deterministas necesarias. Generar varias vistas de prueba y promediar es una técnica distinta, que debe fijarse antes de abrir prueba y reportar su costo. Duplicar archivos aumentados antes de dividir puede filtrar casi copias; primero se divide por unidad y luego se aumenta en línea.

El aumento no corrige el fondo controlado de PlantVillage ni simula adecuadamente un dominio de campo. Para demostrar generalización externa se necesita un conjunto externo documentado. En el laboratorio, el propósito es robustez dentro de imágenes semejantes a PlantVillage.

Se puede formular el objetivo como esperanza sobre transformaciones T :

$$J(\theta) = \mathbb{E}_{(x,y)} \mathbb{E}_{T \sim \mathcal{T}} [\ell(f_{\theta}(T(x)), y)].$$

Así, la distribución $\mathcal{T}$ forma parte del modelo. Debe versionarse junto con probabilidades y rangos.

15.4.2. Transfer learning

La transferencia reutiliza parámetros aprendidos en una tarea fuente para una tarea objetivo. En visión, una base preentrenada en una colección amplia puede ofrecer filtros y representaciones útiles. Se reemplaza la cabeza por otra compatible con las clases objetivo y se respeta el preprocesamiento esperado.

En **extracción de características**, la base queda congelada y solo se entrena la cabeza. Reduce costo y riesgo de sobreajuste, y sirve como baseline fuerte. Congelar parámetros no siempre implica congelar estadísticas de normalización: el modo de esas capas debe decidirse explícitamente. Si se actualizan con pocos datos pueden degradar representaciones.

La transferencia funciona mejor cuando fuente y objetivo comparten regularidades, pero no garantiza neutralidad. El preentrenamiento puede incorporar sesgos, licencias y contenidos no documentados. Se registra procedencia de pesos, versión y condiciones de uso. Un mejor desempeño no borra esas obligaciones.

La semejanza visual con la fuente no sustituye validación objetivo. También puede haber **transferencia negativa**: rasgos fuente interfieren o inducen atajos. Comparar con una CNN desde cero y analizar errores permite detectarla. En PlantVillage, una base general se adapta a un cultivo seleccionado; no se atribuye conocimiento agronómico a la red por haber sido preentrenada.

15.4.3. Ajuste fino

El ajuste fino descongela parte o toda la base y continúa entrenamiento en el objetivo. Un procedimiento prudente entrena primero la cabeza, luego descongela bloques superiores y usa una tasa menor. Las capas iniciales suelen capturar patrones generales; las superiores, representaciones más específicas, aunque esto no es una ley absoluta.

Pueden usarse tasas discriminativas, menores en capas tempranas. Un cambio brusco con tasa alta produce **olvido catastrófico**: se destruyen características útiles antes de que la cabeza se adapte. Curvas de validación y normas de actualización ayudan a controlarlo. Al cambiar qué parámetros son entrenables, el estado del optimizador debe manejarse conscientemente.

Se comparan extracción y ajuste bajo mismos datos, aumento y presupuesto razonable. Además de métrica se consideran variabilidad, tiempo, memoria y tamaño. Una mejora mínima e inestable quizá no justifique el costo. El umbral de abstención se vuelve a estimar porque ajustar logits cambia confianza.

El ajuste fino no autoriza evaluar reiteradamente prueba. Todas las decisiones, incluido número de bloques, tasa y época, se toman con validación. Una vez fijado el pipeline se restaura el mejor estado y se ejecuta la prueba oficial una vez.

15.4.4. Métricas para clasificación visual

Para cada clase, verdaderos positivos TP , falsos positivos FP y falsos negativos FN definen

$$\text{precisión} = \frac{TP}{TP + FP}, \quad \text{recall} = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}.$$

Accuracy es la proporción total correcta. El promedio macro calcula cada métrica por clase y promedia sin ponderar; el ponderado usa soportes; el micro agrega conteos. Deben indicarse convención y soporte. En multiclase de etiqueta única, micro-F1 coincide con accuracy, por lo que no aporta una perspectiva independiente.

La matriz de confusión muestra qué clases se confunden. Normalizar por filas facilita leer recall; por columnas, composición de predicciones. Se conserva también la matriz de conteos. Intervalos por remuestreo deben respetar `leaf_id`; remuestrear imágenes como independientes subestima incertidumbre cuando hay varias vistas de una hoja.

La confianza requiere evaluar calibración. Un modelo está calibrado si, entre predicciones con confianza cercana a 0,8, aproximadamente 80% son correctas. Diagramas de confiabilidad, error de calibración y puntuación de Brier aportan evidencia, aunque dependen de binning y muestra. Escalado de temperatura ajustado en validación puede calibrar logits sin cambiar la clase máxima.

Para abstención, se estudia **cobertura** frente a riesgo. Con umbral τ , se acepta si $\max_k p_k \geq \tau$. Cobertura es la fracción aceptada y riesgo, el error entre aceptadas. Un umbral se elige en validación según costo y objetivo; no se inventa ni se optimiza sobre prueba. También se revisa por clase, porque una regla global puede abstenerse desproporcionadamente en clases difíciles.

15.4.5. Interpretación de modelos visuales

Interpretar busca entender evidencias y fallos, no convertir una predicción en explicación causal. Mapas de saliencia usan $\partial z_k / \partial X$ para estimar sensibilidad local. Métodos basados en activaciones ponderan mapas profundos; oclusión mide cuánto cambia la salida al ocultar regiones. Cada método responde una pregunta distinta y puede ser inestable.

Una explicación plausible puede ser incorrecta. Gradientes se saturan, mapas tienen baja resolución y el postprocesamiento visual influye. Se realizan controles: aleatorizar pesos, cambiar etiqueta objetivo, comparar varios métodos, perturbar regiones destacadas y usar ejemplos negativos. Si el mapa permanece igual tras aleatorizar el modelo, quizá refleja la imagen y no el razonamiento aprendido.

Las galerías deben incluir errores de alta confianza, aciertos, baja confianza y distintas clases. En hojas de PlantVillage interesa verificar si la respuesta se concentra en tejido o fondo, pero una concentración sobre tejido no prueba que reconozca una enfermedad. El modelo puede usar color o textura correlacionados sin conocimiento clínico.

Interpretabilidad no repara sesgo ni sustituye métricas. Es una herramienta de auditoría para formular pruebas y comunicar límites. Las visualizaciones destinadas a usuarios deben evitar apariencia de precisión anatómica que el método no posee.

15.4.6. Introducción a detección de objetos

Clasificación asigna etiquetas a una imagen completa; detección localiza instancias mediante cajas y clases. Un detector debe resolver qué hay y dónde. Arquitecturas de una etapa predicen densamente; las de dos etapas generan propuestas y luego las refinan. Ambas combinan pérdidas de clasificación y localización.

La intersección sobre unión entre cajas A y B es

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

Un umbral de IoU ayuda a definir coincidencias. Precisión y recall varían con confianza; average precision resume la curva, y mAP promedia clases y, según protocolo, umbrales de IoU. Debe especificarse la convención, porque cifras con protocolos distintos no son comparables.

La supresión de no máximos elimina cajas redundantes con gran solapamiento. Puede borrar objetos próximos; otras variantes suavizan puntuaciones. Objetos pequeños, ocluidos o fuera de escala son fallos habituales. Las anotaciones de caja son más costosas y ambiguas que etiquetas de imagen.

PlantVillage no aporta cajas de lesiones como objetivo. Por tanto, las actividades VEG no pueden entrenar ni validar un detector de lesión con esas etiquetas. La detección sería una extensión con otro dataset que incluya cajas y un protocolo apropiado.

15.4.7. Introducción a segmentación

La segmentación semántica asigna una clase a cada píxel; la de instancias separa objetos individuales; la panóptica combina ambas perspectivas. Redes codificador-decodificador reducen resolución para contexto y la recuperan, frecuentemente mediante conexiones que conservan detalle.

Para una clase, Dice e IoU son

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}, \quad \text{IoU} = \frac{|P \cap G|}{|P \cup G|}.$$

Accuracy por píxel puede ser engañosa si domina el fondo. Se reportan métricas por clase, bordes y tamaño cuando sea pertinente. Las máscaras contienen incertidumbre de anotación; desacuerdo entre anotadores debe documentarse.

Interpolar máscaras requiere vecino más cercano para no crear clases fraccionarias. Aumentos geométricos deben transformar imagen y máscara de manera idéntica. Recortes que excluyen la clase cambian distribución y requieren manejo consciente.

La configuración segmented de PlantVillage muestra hojas separadas del fondo, pero no constituye una máscara supervisada de enfermedad o severidad. No permite localizar lesiones ni cuantificar área afectada. Para esas tareas se necesitan máscaras específicas y validación clínica o agronómica según el propósito.

15.4.8. TensorFlow, Keras y PyTorch

TensorFlow y PyTorch son marcos de cálculo tensorial y diferenciación automática; Keras ofrece una interfaz de alto nivel, habitualmente sobre un motor. Implementan grafos de operaciones, dispositivos, módulos, optimizadores y pipelines. No son métodos científicos ni garantizan un protocolo correcto.

Los conceptos se traducen entre marcos: módulo o capa, forward, cálculo automático de gradientes, actualización, modo de entrenamiento/evaluación y serialización. Las diferencias de orden de ejes, valores por defecto, reducción de pérdidas, padding e inicialización pueden producir resultados distintos. Migrar requiere comparar formas y salidas, no solo nombres.

Una ejecución reproducible registra versión del marco, controladores, hardware, pesos preentrenados, configuración, semilla, manifiesto de datos y transformaciones. Guardar solo parámetros no basta: se necesita arquitectura, mapeo de clases, normalización y regla de abstención. Para reanudar entrenamiento se conserva también optimizador y calendario.

La elección del marco depende del entorno docente, despliegue, soporte y experiencia, no de afirmaciones universales de superioridad. La teoría del capítulo permanece independiente. El código se reserva para prácticas autorizadas y debe reflejar explícitamente las decisiones metodológicas, no ocultarlas tras valores predeterminados.

15.4.9. Ejemplo práctico guiado: transferencia para diagnóstico de enfermedades

El título histórico de este ejemplo usa “diagnóstico”, pero su alcance metodológico se restringe: se clasifica la etiqueta PlantVillage de una imagen del cultivo seleccionado. No se realiza diagnóstico agronómico de campo, no se estima severidad y no se recomienda tratamiento.

Se elige una base preentrenada cuya licencia y preprocesamiento estén documentados. Primero se reemplaza la cabeza y se congela la base. Después de entrenar y validar esa cabeza, una segunda configuración descongela los últimos bloques con tasa menor. Ambas usan idéntico aumento solo en entrenamiento, mismo manifiesto y presupuesto registrado.

La comparación incluye macro-F1, métricas por clase, calibración, tiempo, memoria, tamaño y variabilidad entre semillas. Se ajusta calibración, si procede, únicamente con validación. Luego se construye una curva cobertura-riesgo y se elige τ para la regla:

```
SI la imagen no satisface los controles de entrada:
    acción <- REVISAR
SI NO, obtener puntuaciones calibradas
SI confianza máxima < tau:
    acción <- REVISAR
SI NO:
    acción <- CLASIFICAR y mostrar clase PlantVillage sugerida
mostrar siempre alcance, confianza y advertencia
```

Los controles pueden marcar formato inválido, resolución insuficiente o falta evidente de semejanza, pero detectar fuera de distribución es un problema abierto; una puntuación alta no demuestra pertenencia al dominio. La interfaz muestra “Válido solo para imágenes semejantes a PlantVillage”. Los casos revisados se remiten a evaluación experta, sin sugerir tratamiento.

Una vez fijados modelo, calibración y umbral, se abre la prueba oficial una vez. Se reportan desempeño total, por clase y selectivo, incluyendo cobertura y errores aceptados. No se reajusta τ después de ver prueba. Si el ajuste fino no supera de forma estable al extractor congelado, se prefiere el modelo más simple o se declara ausencia de mejora.

Actividad EMO [VEG-04]: aplicar transferencia y definir condiciones de uso

Capacidad mínima: adaptar un modelo preentrenado y decidir cuándo requiere revisión humana.

Se comparan extracción de características y ajuste fino parcial o completo sobre el mismo cultivo, clases, configuración color y particiones por leaf_id. El aumento actúa solo en entrenamiento. Cada estudiante documenta procedencia de pesos, preprocesamiento, capas entrenables, tasas, costo y estabilidad.

Con validación se evalúa calibración o, como mínimo, relación entre confianza y error. La regla de abstención se deriva de la curva cobertura-riesgo y de errores observados; no de un umbral arbitrario. Puede combinar confianza con controles de calidad. Se analiza cobertura por clase para evitar que la automatización excluya silenciosamente una condición.

Evidencia individual: notebook comparativo, matriz de confusión, métricas por clase, diagrama de confianza, curva cobertura-riesgo, umbral justificado y ficha del modelo. El producto devuelve cultivo configurado, clase PlantVillage sugerida, confianza, acción clasificar/revisar y la advertencia “Válido solo para imágenes semejantes a PlantVillage”.

La prueba oficial reservada se utiliza una vez al final. No se modifica modelo, calibración ni umbral a partir de ella. Una confianza alta no reemplaza consulta experta. Quedan expresamente fuera del uso permitido el diagnóstico de campo, la estimación de severidad, la localización de lesiones y la recomendación de tratamientos.

Criterios de aprobación: comparación controlada; aumento exclusivo de entrenamiento; abstención fundada en validación; costos y estabilidad considerados; limitaciones explícitas. Esta actividad produce un modelo candidato educativo, no una herramienta clínica o agronómica validada.

Diseño experimental, incertidumbre y documentación

El desarrollo de una red neuronal es un experimento comparativo, no una sucesión de cambios hasta obtener una cifra atractiva. La pregunta útil adopta una forma explícita: dada una partición, un presupuesto y una métrica, ¿qué efecto tiene modificar un factor? La unidad experimental puede ser una ejecución completa con una semilla. Si al mismo tiempo cambian arquitectura, aumento, resolución y optimizador, no es posible atribuir la diferencia observada a uno de ellos.

Un protocolo comienza antes del primer entrenamiento. Especifica población objetivo, unidad independiente, variables disponibles, clases, regla de partición, preprocesamiento, baselines, métricas, presupuesto, semillas y criterio de selección. También define qué decisiones pueden cambiar con validación y cuándo se abre prueba. Este registro previo no impide explorar; separa exploración de confirmación. Durante la fase exploratoria se formulan hipótesis y se descartan fallos. La evaluación confirmatoria congela el pipeline y estima su comportamiento sobre datos no usados para decidir.

La comparación debe ser justa en los factores relevantes. Dos modelos pueden recibir el mismo número de épocas y, sin embargo, presupuestos distintos si uno procesa resoluciones mayores o converge antes. Conviene reportar ejemplos procesados, tiempo, dispositivo y cantidad de actualizaciones, además de épocas. Para comparar capacidad representacional se intenta igualar el entrenamiento; para comparar soluciones operativas se permite que cada alternativa use su mejor protocolo validado, pero se incluye el costo total de búsqueda.

La variación entre semillas no es un detalle administrativo. Cambian inicialización, orden de lotes, máscaras de dropout y aumentos. Si las diferencias entre alternativas son menores que esa variación, afirmar superioridad requiere cautela. Se ejecutan varias semillas cuando sea viable y se informa distribución, no solo máximo. Elegir la mejor semilla usando validación añade otra capa de selección; si se hace, debe declararse y evaluarse el modelo resultante sin escoger de nuevo sobre prueba.

La incertidumbre de una métrica tiene varias fuentes. El conjunto de evaluación es una muestra finita; el entrenamiento es estocástico; las etiquetas pueden contener desacuerdo; y la población futura puede cambiar. Un intervalo de confianza por remuestreo aborda principalmente la primera fuente. En imágenes agrupadas, el remuestreo se realiza por unidad independiente. Para PlantVillage se remuestran `leaf_id`, no imágenes sueltas, y se conservan juntas sus vistas. La dispersión entre entrenamientos se presenta por separado, porque mezclar ambas fuentes sin explicar el procedimiento dificulta la interpretación.

Las diferencias de métricas globales deben acompañarse con diferencias emparejadas. Si dos modelos se evalúan sobre exactamente las mismas hojas, se observa en cuáles difieren, qué clases ganan o pierden y si el cambio se concentra en unos pocos grupos. Una mejora de macro-F1 puede coexistir con reducción de recall en una clase. No hay una única ordenación correcta sin objetivos y costos

definidos.

Una **ablación** elimina o sustituye un componente para estimar su aporte. Se puede comparar sin aumento frente a aumento validado, cabeza congelada frente a ajuste fino, o promedio global frente a una cabeza densa. La ablación mantiene lo demás constante y no necesita abarcar todas las combinaciones. Su función es contrastar una hipótesis. Probar numerosas variantes y publicar solo las favorables produce sesgo de selección aun cuando la prueba permanezca cerrada.

Los registros deben permitir reconstruir cada resultado. Una ejecución queda vinculada a identificador de datos y partición, configuración, versión de transformaciones, estado inicial o semilla, pesos fuente, entorno, historial, estado seleccionado y métricas. La tabla final no se completa manualmente desde recuerdos: se deriva de artefactos trazables. Los nombres de archivos no deben contener información usada accidentalmente como entrada, y los manifiestos deben conservar rutas relativas o identificadores estables.

Una ficha de modelo resume el artefacto, pero no reemplaza el informe. Debe indicar tarea, clases, procedencia y licencia de datos, arquitectura, preprocesamiento, protocolo de evaluación, métricas con incertidumbre, usos permitidos, usos excluidos, riesgos, regla de abstención y responsabilidades. También registra condiciones que invalidan la salida y procedimiento para actualizar. Si cambia el mapeo de clases, la resolución o la normalización, existe una versión distinta aunque la base conserve el mismo nombre.

La evaluación de robustez comienza con perturbaciones plausibles definidas sin mirar prueba. Se examinan cambios moderados de brillo, compresión, escala o encuadre que no deberían modificar la etiqueta. Robustez no significa invariancia a cualquier transformación: alterar de forma intensa el color puede eliminar información relevante. Los resultados se desglosan por perturbación y magnitud. Una caída permite caracterizar límites; entrenar sobre cada perturbación después de verla convierte el conjunto robusto en otra validación.

El cambio de dominio requiere evidencia independiente. Una colección interna con el mismo proceso de captura puede medir generalización entre ejemplos, no entre contextos. Para afirmar validez bajo otro sensor, fondo o población se necesita una evaluación externa diseñada para ello. El error externo puede surgir por covariables, prevalencia, nuevas clases o cambio en el significado de etiquetas. Recalibrar corrige algunas diferencias de confianza, pero no necesariamente errores de representación.

La detección fuera de distribución intenta reconocer entradas alejadas de entrenamiento mediante energía, distancias, conjuntos auxiliares o modelos especializados. Ningún puntaje ofrece una frontera universal entre conocido y desconocido. Se evalúa con tipos de cambio relevantes y se combina con controles de entrada y revisión. Una política segura no dice “el detector garantiza que la imagen pertenece”; dice qué señales activan abstención y qué cambios no fueron evaluados.

La confianza también puede estimarse con conjuntos de modelos, muestreo estocástico u otras aproximaciones, pero mayor complejidad no garantiza mejor calibración. Se compara con softmax calibrado y se mide costo. La incertidumbre **aleatoria** asociada a ambigüedad de la observación se distingue conceptualmente de la **epistémica** asociada a falta de conocimiento o cobertura; en redes prácticas ambas no siempre se separan limpiamente. La interfaz no debe presentar esa

distinción con una precisión que el método no valida.

El monitoreo posterior, si existiera un despliegue autorizado, observa distribución de entradas, tasa de abstención, cobertura por clase, calidad de datos, latencia y muestras revisadas. Sin etiquetas oportunas, la deriva de entradas no demuestra caída de accuracy, pero indica necesidad de auditoría. Las etiquetas obtenidas después deben tener un proceso de revisión y no incorporarse automáticamente: las predicciones previas pueden contaminar la anotación y crear ciclos de confirmación.

Actualizar un modelo exige una evaluación de regresión. Se conserva un conjunto de casos representativos y fallos conocidos, sin usarlo indefinidamente para ajustar. La nueva versión debe compararse con la anterior sobre protocolo común, documentar mejoras y degradaciones, y mantener posibilidad de retorno. Un cambio del marco, pesos preentrenados o biblioteca de imágenes puede alterar resultados aunque el código de alto nivel parezca idéntico.

En el caso VEG, estas reglas se concretan con una frontera inequívoca. El entrenamiento oficial origina entrenamiento y validación agrupados; la prueba oficial permanece confirmatoria. La configuración es color; el cultivo y las clases quedan congelados; las derivaciones de una misma hoja no incrementan la muestra independiente. Las métricas internas, incluso si son elevadas y estables, respaldan solamente clasificación de imágenes semejantes a PlantVillage. Para otro dominio se diseñaría un estudio nuevo, no una frase más ambiciosa en la ficha.

Diagnóstico sistemático de fallos

Las redes requieren una secuencia de comprobaciones. Ante un resultado inesperado conviene evitar cambios simultáneos y recorrer niveles:

1. **Datos:** abrir ejemplos y etiquetas, verificar rangos, formas, mapeo de clases, duplicados y separación por unidad.
2. **Cálculo:** comprobar salida, pérdida finita, gradientes no nulos y actualización de parámetros.
3. **Prueba mínima:** intentar memorizar un lote pequeño sin aumento ni regularización fuerte.
4. **Optimización:** observar tasa, normas, oscilaciones y sensibilidad a inicialización.
5. **Generalización:** comparar curvas, clases, subgrupos pertinentes y galerías predefinidas.
6. **Dominio:** comprobar procedencia y no extrapolar una prueba interna a condiciones externas.

Una métrica sospechosamente perfecta invita a buscar fuga: rutas con clase, duplicados, vistas de la misma unidad o transformaciones aplicadas antes de dividir. Una predicción constante invita a revisar mapeo, desbalance y gradientes. Errores de alta confianza requieren calibración y auditoría de atajos. Degradación al desplegar exige comparar preprocesamiento, modo de evaluación y dominio.

Las pruebas unitarias conceptuales incluyen identidad de formas, invariancia de etiquetas bajo aumentos, intersección vacía de grupos y reproducibilidad del manifiesto. Las pruebas de integración atraviesan desde archivo hasta salida. La revisión visual complementa, no reemplaza, controles automáticos.

Riesgos, ética y uso responsable

Un sistema visual hereda decisiones sobre quién produjo datos, qué se etiquetó y qué quedó fuera. Desempeño promedio puede ocultar fallos sistemáticos por dispositivo, iluminación, procedencia o clase. En aplicaciones sensibles, esos fallos distribuyen costos. Deben definirse población objetivo, exclusiones, responsables y vía de revisión antes de desplegar.

La confianza matemática no es certeza epistemológica. Softmax puede ser extremo fuera de distribución. La abstención reduce automatización para limitar riesgo, pero transfiere trabajo a personas; hay que medir carga, tiempos y calidad de revisión. Una explicación visual tampoco legitima una decisión.

Privacidad y propiedad importan incluso en imágenes no humanas: metadatos pueden revelar ubicación o identidad; licencias limitan reutilización; pesos preentrenados tienen procedencia. Se minimizan datos, se conservan trazas necesarias y se documentan versiones y licencias. El costo computacional se ajusta al valor educativo y se evitan búsquedas indiscriminadas.

En el proyecto vegetal, el lenguaje es parte del control de riesgo. “Clasificación PlantVillage sugerida” describe el producto; “diagnóstico de enfermedad en campo” lo sobrestima. El dataset no aporta lote, clima, manejo, severidad ni confirmación clínica por imagen. Un resultado no debe inducir tratamiento. Para extender el uso se necesitarían datos de campo representativos, protocolo externo, participación experta y reevaluación de daños.

Síntesis

Una red compone transformaciones afines y no lineales. El forward produce predicciones; una pérdida formaliza el objetivo; retropropagación calcula gradientes; y un optimizador actualiza parámetros en mini-batches. Inicialización, normalización, regularización, dropout y early stopping actúan sobre dificultades distintas. La GPU acelera operaciones, no la validez metodológica.

Las CNN incorporan localidad y pesos compartidos para procesar tensores de imagen. Convolución, padding, stride y pooling controlan mapas y campos receptivos. Aumento y transferencia pueden mejorar eficiencia, pero deben respetar etiquetas y dominio. Evaluar exige métricas por clase, incertidumbre, calibración, análisis de errores y comparación con baselines.

La cadena VEG concreta estos principios con un protocolo auditable: color, cultivo seleccionado, particiones por leaf_id, prueba oficial cerrada durante desarrollo, confianza validada y abstención. El resultado reconoce clases de PlantVillage bajo condiciones semejantes. Ese límite no es una nota secundaria, sino parte del modelo.

Glosario esencial

- **Activación:** transformación, generalmente no lineal, aplicada a una preactivación.
- **Ajuste fino:** actualización de parte o toda una red preentrenada en la tarea objetivo.

- **Backpropagation:** cálculo eficiente de gradientes por regla de la cadena.
- **Calibración:** correspondencia entre confianza declarada y frecuencia empírica de acierto.
- **Canal:** componente de una imagen o mapa de características.
- **CNN:** red que emplea convoluciones y estructura espacial.
- **Cobertura:** proporción de casos que un sistema selectivo decide clasificar.
- **Convolución:** operación local con pesos compartidos aplicada sobre una cuadrícula.
- **Dropout:** enmascaramiento aleatorio de activaciones durante entrenamiento.
- **Early stopping:** selección y detención basadas en desempeño de validación.
- **Época:** recorrido completo por el conjunto de entrenamiento.
- **Forward pass:** evaluación de la red desde entrada hasta salida.
- **Gradiente:** vector de derivadas parciales de una función respecto de parámetros.
- **In-distribution:** entrada compatible con la distribución objetivo documentada.
- **Logit:** salida no normalizada anterior a sigmoide o softmax.
- **Mapa de características:** respuesta espacial de un canal aprendido.
- **Mini-batch:** subconjunto usado para estimar un gradiente y actualizar parámetros.
- **Padding:** relleno alrededor de una entrada antes de una operación espacial.
- **Pooling:** resumen local o global de activaciones.
- **Regularización:** preferencia o restricción destinada a mejorar generalización.
- **Riesgo selectivo:** error calculado entre casos aceptados por una regla de abstención.
- **Stride:** paso espacial con que se desplaza una ventana.
- **Transfer learning:** reutilización de representaciones aprendidas en otra tarea.

Preguntas de revisión y discusión

1. ¿Por qué varias capas lineales sin activación equivalen a una sola transformación afín?
2. Derive $\partial \ell / \partial z_k = p_k - y_k$ para softmax y entropía cruzada.
3. ¿Qué diferencia existe entre incapacidad representacional, optimización deficiente y falta de información?
4. ¿Cómo afectan tasa de aprendizaje y tamaño de lote al ruido de actualización?
5. ¿Por qué inicializar todos los pesos ocultos en cero impide diversificar unidades?
6. Compare normalización, regularización y dropout: ¿qué problema principal aborda cada uno?
7. ¿Qué patrón de curvas caracteriza subajuste, sobreajuste e inestabilidad?
8. Calcule la salida espacial de una convolución para varios valores de kernel, padding y stride.
9. ¿Qué se gana y qué se pierde al reducir resolución mediante pooling?
10. ¿Por qué una CNN puede aprender el fondo aunque su objetivo nominal sea una hoja?
11. ¿En qué condiciones preferiría extracción de características frente a ajuste fino?
12. ¿Por qué accuracy puede ser insuficiente ante clases desbalanceadas?
13. Explique calibración y la diferencia entre confianza alta y certeza.
14. ¿Cómo se elige un umbral de abstención sin contaminar la prueba?

15. ¿Qué controles usaría para auditar un mapa de saliencia?
16. Distinga clasificación, detección y segmentación por salida y anotación requerida.
17. ¿Por qué segmented de PlantVillage no es una máscara de lesión?
18. ¿Qué fuga ocurre si imágenes de una misma hoja aparecen en conjuntos distintos?
19. ¿Por qué la configuración color no debe mezclarse con sus derivaciones como nuevas observaciones?
20. Formule una ficha de límites que impida presentar el clasificador como diagnóstico de campo o estimador de severidad.

Actividad integradora de cierre

Elaborar una **auditoría de afirmaciones** del producto VEG-01 a VEG-04. El equipo entrega una tabla con cada afirmación técnica, evidencia que la sostiene, conjunto usado y límite. Como mínimo debe incluir: ausencia de fuga por leaf_id; comparación con clase mayoritaria, red pequeña y CNN; selección sin prueba; desempeño por clase; calibración; curva cobertura-riesgo; costo; y estabilidad.

Cada integrante elige cinco errores finales y reconstruye su trayectoria: imagen y hoja, clase real, predicción, confianza antes y después de calibrar, decisión clasificar/revisar, explicación visual con controles y una hipótesis de fallo. Las hipótesis se agrupan en calidad, similitud entre clases, señal espuria, cobertura o incertidumbre de etiqueta. No se cambia el modelo tras observar la prueba.

El cierre consiste en una defensa oral breve. El equipo debe explicar por qué su umbral proviene de validación, qué fracción queda para revisión, qué clases concentran riesgo y qué evidencia adicional exigiría para cambiar el dominio. La pantalla final debe decir “Válido solo para imágenes semejantes a PlantVillage” y excluir diagnóstico de campo, severidad, localización de lesión y tratamiento. Se evalúa la coherencia entre afirmaciones y evidencia, no la competición por la cifra más alta.

Capítulo 16. Procesamiento del lenguaje natural y grandes modelos de lenguaje

El lenguaje es simultáneamente un sistema de signos, una práctica social y una fuente de datos. Un texto no es una tabla que simplemente espera ser analizada: su interpretación depende del contexto, de quién habla, del género discursivo, de convenciones culturales y del momento histórico. El procesamiento del lenguaje natural (PLN) estudia métodos para representar, analizar y generar lenguaje mediante sistemas computacionales. Combina lingüística, estadística, aprendizaje automático, recuperación de información e ingeniería de software.

Este capítulo presenta una progresión desde representaciones dispersas y modelos clásicos hasta embeddings contextuales, Transformers y grandes modelos de lenguaje. Esa progresión no implica que lo más reciente sea siempre lo más apropiado. Una representación TF-IDF y un clasificador lineal pueden ser más económicos, auditables y eficaces que un modelo generativo para una taxonomía estable. La elección depende de la tarea, los datos, el costo de error, la latencia y los requisitos de control.

Al terminar el capítulo, el lector podrá distinguir decisiones de preparación que conservan o eliminan información; construir representaciones Bag of Words y TF-IDF sin fuga; formular tareas de similitud, clasificación, sentimiento y extracción; interpretar atención y Transformer; explicar preentrenamiento, ajuste fino, prompting y RAG; y diseñar evaluaciones que contemplen alucinaciones, sesgos, privacidad, propiedad intelectual y supervisión humana.

Un marco de análisis para todo el capítulo. Un sistema de PLN puede estudiarse en cinco niveles. El nivel lingüístico pregunta qué fenómeno interesa y qué contexto hace falta para interpretarlo. El nivel estadístico define población, muestra, variable objetivo e incertidumbre. El nivel computacional concreta representación, algoritmo, recursos y latencia. El nivel operativo transforma una salida en una acción con costos y responsables. El nivel sociotécnico examina quién se beneficia, quién queda excluido y qué mecanismos de reparación existen. Confundir niveles produce afirmaciones desmedidas: una correlación léxica no es una explicación lingüística; una probabilidad del modelo no es una decisión; una demostración técnica no prueba beneficio social.

La unidad de evaluación debe coincidir con la unidad de uso. Si el sistema clasifica documentos, dividir oraciones del mismo documento entre entrenamiento y prueba produce dependencia. Si una misma persona aporta varios documentos, una partición por documento puede medir reconocimiento de estilo personal en

lugar de generalización a personas nuevas. Si el uso ocurre en el futuro, una partición aleatoria mezcla épocas y oculta cambios de vocabulario, productos o políticas. Tiempo, fuente, autor y duplicados son estructuras de dependencia, no simples columnas descriptivas.

También debe distinguirse entre **constructo**, **etiqueta** y **decisión**. El constructo es el concepto de interés; la etiqueta, su operacionalización observable; la decisión, el uso de la predicción. Una etiqueta administrativa puede ser consistente sin representar el fenómeno que el nombre sugiere. El modelo aprende la etiqueta disponible, incluidos errores y convenciones históricas. Antes de atribuirle comprensión, se debe justificar por qué esa etiqueta es una aproximación válida y por qué la decisión propuesta admite sus limitaciones.

La reproducibilidad exige más que una semilla. Deben conservarse versión del corpus, reglas de exclusión, particiones, normalizador, tokenizador, vocabulario, parámetros, dependencias, artefactos y entorno. En servicios externos también se registran identificador del modelo, fecha, configuración y plantilla. La repetibilidad exacta puede no ser posible en sistemas no deterministas; en ese caso se exige estabilidad estadística y pruebas de regresión con tolerancias explícitas.

Convenciones matemáticas. En las fórmulas siguientes, los escalares aparecen en minúscula, los vectores en negrita y las matrices en mayúscula. N denota cantidad de documentos, T longitud de una secuencia, $|V|$ tamaño de vocabulario y d dimensión de una representación. Estas cantidades no son intercambiables: aumentar vocabulario eleva columnas de una matriz dispersa, mientras ampliar contexto aumenta posiciones procesadas y, en atención estándar, costo cuadrático. Las probabilidades condicionadas representan el comportamiento de un modelo bajo sus datos y supuestos; no deben interpretarse automáticamente como frecuencias causales o grados de verdad.

Las fórmulas describen familias de métodos y no sustituyen decisiones de implementación. Dos bibliotecas pueden usar suavizados, normalizaciones, tratamiento de bordes o promedios diferentes bajo el mismo nombre. Por ello, un informe debe registrar definición y configuración, no solo “se aplicó TF-IDF” o “se usó atención”. También debe comprobar dimensiones: si $Q \in \mathbb{R}^{T_q \times d_k}$ y $K \in \mathbb{R}^{T_k \times d_k}$, entonces $QK^\top \in \mathbb{R}^{T_q \times T_k}$ y puede ponderar $V \in \mathbb{R}^{T_k \times d_v}$. El resultado tiene dimensión $T_q \times d_v$.

Finalmente, una igualdad matemática puede convivir con incertidumbre empírica. La fórmula de una métrica es exacta para conteos dados, pero los conteos varían con la muestra. Una arquitectura está definida algebraicamente, pero sus parámetros se estiman. El razonamiento académico debe separar propiedades del método, resultados observados y conjeturas sobre las causas de esos resultados.

16.1. Preparación y representación clásica de textos

La preparación convierte objetos lingüísticos en unidades analizables. Cada transformación expresa una hipótesis. Pasar a minúsculas supone que la capitalización no es decisiva; borrar signos supone que no aportan significado; eliminar palabras frecuentes supone que su valor discriminativo es bajo. Ninguna de estas decisiones es universal. Una cadena reproducible debe conservar el texto original, registrar cada transformación y aprender del conjunto de entrenamiento toda estadística dependiente de datos.

16.1.1. Corpus, documentos, oraciones y tokens

Un **corpus** es una colección delimitada de producciones lingüísticas reunidas con un propósito. Puede contener artículos, transcripciones, mensajes, contratos o reclamos. No es una muestra neutral del idioma: refleja un mecanismo de selección, una población, un periodo, canales de registro y criterios de exclusión. Antes de modelar deben documentarse procedencia, licencia, fecha de adquisición, idiomas, cobertura, unidad de análisis y posibles ausencias sistemáticas.

Un **documento** es la unidad que recibe una representación o una predicción. Según el problema puede ser un informe completo, un párrafo o una intervención. La **oración** es una unidad sintáctica aproximada, pero su detección computacional resulta ambigua: un punto puede cerrar una oración, abreviar un título o formar un número decimal. Un **token** es una unidad producida por un procedimiento de segmentación. Puede coincidir con una palabra, parte de palabra, signo, carácter o byte. Por ello, token y palabra no son sinónimos.

Sea el corpus $\mathcal{D} = \{d_1, \dots, d_N\}$. Una función de tokenización τ transforma cada documento en una secuencia:

$$\tau(d_i) = (x_{i1}, x_{i2}, \dots, x_{iT_i}),$$

donde T_i es la longitud tokenizada. El vocabulario V reúne los tipos distintos observados. **Tipo** designa una forma única; **ocurrencia** designa cada aparición. En “dato, datos, dato” hay tres ocurrencias y, si no se normaliza, dos tipos.

La granularidad afecta costo y generalización. Tokens de palabra son interpretables, pero sufren vocabularios grandes y formas desconocidas. Caracteres toleran variaciones ortográficas, aunque generan secuencias largas. Subpalabras equilibran ambos extremos: reutilizan fragmentos frecuentes para formar expresiones nuevas. Además, la longitud documental puede ser una señal útil o un artefacto del canal. Conviene reportar su distribución, documentos vacíos después del filtrado, idiomas, duplicados y cobertura del vocabulario.

Fallo frecuente. Definir el corpus como “todos los registros disponibles” oculta selección. Si solo algunas personas autorizan publicar su texto, el corpus representa ese subconjunto, no todas las interacciones de la institución. La validez externa comienza por describir esta diferencia.

16.1.2. Limpieza y normalización

La **limpieza** corrige o excluye elementos incompatibles con el objetivo; la **normalización** reduce variantes mediante reglas explícitas. Operaciones habituales incluyen unificar codificación Unicode, espacios y saltos de línea; normalizar mayúsculas; tratar URLs, correos y números; reparar secuencias escapadas; y detectar documentos vacíos, corruptos o duplicados. Debe mantenerse una columna inmutable con el texto original y otra derivada para modelado.

Normalizar no equivale a “quitar ruido”. La puntuación transmite límites, énfasis e intención; las mayúsculas distinguen nombres y siglas; los acentos diferencian formas; emoticonos y repetición gráfica pueden expresar afecto. “No autorizado” cambia si se elimina no; “US” y “us” no son equivalentes en inglés; una cifra puede ser esencial en un contrato. El tratamiento correcto depende de la tarea y del

idioma, incluso cuando la teoría y el algoritmo sean independientes de una lengua particular.

La equivalencia Unicode merece atención. Un mismo grafema visible puede representarse mediante un punto de código precompuesto o una letra seguida de marca combinante. Formas como NFC o NFKC reducen inconsistencias, pero NFKC también fusiona caracteres cuya distinción tipográfica podría importar. La transliteración y la eliminación de diacríticos pueden aumentar coincidencias, a costa de ambigüedad y pérdida de identidad lingüística.

Marcadores abstractos preservan clases sin conservar valores: una URL puede reemplazarse por <URL> y un importe por <MONTO>. Esa sustitución permite aprender que cierto tipo de elemento aparece, limita el vocabulario y reduce exposición accidental. Sin embargo, no constituye anonimización completa: nombres, relatos singulares y combinaciones de atributos pueden reidentificar personas.

Las reglas deben fijarse con entrenamiento o conocimiento previo. Mirar errores de prueba para decidir qué términos borrar convierte la limpieza en selección supervisada indirecta. Una comparación válida cambia una decisión por vez, conserva las mismas particiones y mide tanto desempeño como consecuencias semánticas.

16.1.3. Tokenización

Tokenizar es establecer las unidades sobre las que se contarán frecuencias o se aprenderán representaciones. Una regla basada en espacios es sencilla, pero falla ante puntuación adyacente, escrituras sin espacios, contracciones, palabras compuestas, hashtags y números. Los tokenizadores lingüísticos incorporan reglas; los estadísticos aprenden un inventario de subpalabras a partir del corpus.

Entre los métodos de subpalabras se encuentran BPE, WordPiece y unigram language model. En términos generales, parten de unidades pequeñas y seleccionan fragmentos que permiten codificar el corpus con un vocabulario limitado. Una palabra infrecuente puede dividirse en segmentos conocidos. Así se evita un token desconocido único y se comparten patrones morfológicos, aunque la segmentación no necesariamente coincide con morfemas lingüísticos.

Un tokenizador define un mapeo entre texto e identificadores enteros. En modelos neuronales suele agregar símbolos de control para inicio, fin, separación, relleno o enmascaramiento. Estos símbolos tienen semántica arquitectónica. El relleno debe acompañarse de una máscara para que posiciones artificiales no intervengan en atención o pérdida.

La calidad no se evalúa solo por tamaño de vocabulario. Son relevantes la cantidad media de tokens por documento, la tasa de fragmentación por idioma o grupo, la estabilidad ante errores tipográficos y el límite de contexto. Un grupo cuyos textos requieran sistemáticamente más tokens consume más cómputo y alcanza antes la truncación. Este es un posible mecanismo de desigualdad de desempeño.

Ejemplo conceptual. Dos tokenizaciones de “microcrédito” podrían producir un token completo o tres subunidades. La primera es compacta si la forma fue frecuente durante el aprendizaje; la segunda generaliza componentes a vocablos nuevos. Ninguna es intrínsecamente correcta. La decisión se juzga por cobertura, eficiencia y rendimiento fuera de muestra.

16.1.4. Palabras vacías

Las **palabras vacías** o *stopwords* son términos muy frecuentes que algunos pipelines excluyen por considerar que aportan poca discriminación. Artículos, preposiciones y auxiliares suelen integrar listas genéricas. Su eliminación reduce dimensionalidad y puede favorecer recuperación temática, pero no es una regla lingüística universal ni un requisito de TF-IDF.

Una lista externa puede eliminar información crítica. Negaciones, modales y pronombres contribuyen a polaridad, compromiso, estilo y referencia. “Acepto” y “no acepto” se aproximarían peligrosamente si se descarta la negación. En atribución o análisis de interacción, los pronombres pueden ser centrales. En modelos contextuales, remover palabras funcionales rompe la sintaxis con la cual fueron preentrenados y normalmente no resulta conveniente.

También pueden definirse términos demasiado frecuentes en un corpus particular mediante frecuencia documental. Si $df(t)$ es el número de documentos que contienen t , un filtro podría excluir términos con $df(t)/N > \alpha$. Como df es una estadística aprendida, el umbral se calcula solo en entrenamiento. Los términos excluidos, el criterio y la proporción de tokens removidos deben quedar registrados.

La alternativa prudente es comparar: sin eliminación; con una lista lingüística revisada; o con límites de frecuencia. La evaluación debe observar clases minoritarias, porque un término globalmente frecuente puede ser informativo para ellas. Una lista de palabras vacías es una decisión del modelo, no una etapa de higiene automática.

16.1.5. Stemming y lematización

El **stemming** reduce formas mediante reglas de recorte. Puede unir variantes flexivas, pero su salida no tiene que ser una palabra válida. La **lematización** busca el lema de diccionario usando análisis morfológico y, a menudo, categoría gramatical y contexto. La misma forma superficial puede requerir lemas diferentes según su función.

Ambos procedimientos intentan disminuir dispersión: si múltiples formas comparten raíz o lema, sus evidencias se acumulan. Esto puede beneficiar corpus pequeños y lenguas con morfología rica. La contrapartida es la **sobreconflación**, que fusiona términos semánticamente diferentes, y la **subconflación**, que deja separadas variantes relacionadas. Nombres propios, tecnicismos, errores y cambio de código entre idiomas complican el análisis.

Para medir su efecto se comparan tamaño de vocabulario, colisiones entre formas, ejemplos cualitativos y desempeño temporal. El ahorro dimensional no garantiza mejor predicción. N-gramas de caracteres y modelos subléxicos ofrecen otra forma de robustez morfológica. En embeddings contextuales, la tokenización en subpalabras y el contexto suelen volver innecesario un preprocesamiento morfológico explícito.

La lematización depende de recursos y convenciones lingüísticas; por eso un pipeline multilingüe debe declarar cobertura por idioma. Aplicar un lematizador equivocado puede deformar sistemáticamente un subconjunto. La regla metodológica es simple: usar stemming o lematización solo cuando una

hipótesis clara y evaluación fuera de muestra justifiquen la pérdida de forma superficial.

16.1.6. N-gramas

Un **n-grama** es una secuencia contigua de n unidades. Si las unidades son tokens, unigramas, bigramas y trigramas corresponden a $n = 1, 2, 3$. También existen n-gramas de caracteres. Para una secuencia de longitud T hay $T - n + 1$ n-gramas contiguos de orden n .

Los unigramas ignoran orden. Los bigramas distinguen parcialmente expresiones como “sin autorización” y capturan colocaciones; órdenes mayores representan más contexto local, pero crecen combinatoriamente y se vuelven escasos. El vocabulario potencial de n-gramas de tokens es $|V|^n$, aunque solo se materializan secuencias observadas. Filtros de frecuencia mínima y máxima controlan dimensionalidad.

Los n-gramas de caracteres son robustos a variantes, prefijos, sufijos y errores de escritura. Pueden ayudar en identificación de idioma o textos breves, pero ofrecen unidades menos interpretables y también pueden memorizar identificadores. Los límites de palabra cambian su significado: incluir espacios o marcadores de frontera permite distinguir prefijos de secuencias internas.

Fallo frecuente. Agregar bigramas y seleccionar los que aparecen en todo el corpus filtra información del futuro. La enumeración, frecuencia documental y selección deben aprenderse únicamente en entrenamiento. Otro fallo consiste en interpretar un n-grama correlacionado como causa: un término puede reflejar una plantilla, un canal o una política temporal.

16.1.7. Bag of Words

Bag of Words (BoW) representa cada documento por conteos de vocabulario e ignora, salvo que se incluyan n-gramas, el orden global. Sea $V = \{v_1, \dots, v_M\}$ aprendido en entrenamiento. La matriz documento-término $X \in \mathbb{R}^{N \times M}$ tiene entradas

$$X_{ij} = c(v_j, d_i),$$

donde $c(v_j, d_i)$ es el número de apariciones. Una variante binaria usa $X_{ij} = \mathbb{1}[c(v_j, d_i) > 0]$. La matriz suele ser dispersa: cada documento contiene una fracción pequeña del vocabulario, por lo que debe almacenarse en formatos que solo registren valores no nulos.

BoW es interpretable y constituye un baseline sólido. Permite inspeccionar coeficientes de modelos lineales, funciona con pocos datos etiquetados y tiene inferencia eficiente. Sus limitaciones son polisemia, sinonimia, sensibilidad al vocabulario y pérdida de relaciones a distancia. “La entidad rechazó la operación” y “la operación rechazó la entidad” comparten conteos aunque expresen estructuras diferentes.

Los conteos favorecen documentos largos. Puede aplicarse normalización L_1 o L_2 , frecuencia relativa o transformación logarítmica. Estas opciones alteran la geometría. En clasificación, la longitud puede ser predictiva, de modo que

normalizarla puede eliminar una señal, quizá legítima o quizá dependiente del canal. Debe evaluarse por separado.

El vocabulario forma parte del modelo. En producción, tokens no vistos se ignoran o se canalizan mediante una estrategia prevista. Si aparecen muchos términos nuevos, la cobertura cae y puede indicar deriva. Conservar versión del vectorizador, orden de columnas y reglas de normalización es indispensable para reproducir predicciones.

16.1.8. TF-IDF

TF-IDF pondera un término por su frecuencia dentro del documento y su rareza en el corpus. Una definición básica es

$$\text{tfidf}(t, d) = \text{tf}(t, d) \text{idf}(t), \quad \text{idf}(t) = \log \frac{N}{df(t)}.$$

La frecuencia local puede ser el conteo, la frecuencia relativa o $1 + \log c(t, d)$ para conteos positivos. Para evitar divisiones y valores extremos se usa suavizado, por ejemplo

$$\text{idf}_s(t) = \log \left(\frac{1 + N}{1 + df(t)} \right) + 1.$$

Después suele normalizarse cada vector con norma euclídea:

$$\hat{\mathbf{x}}_d = \frac{\mathbf{x}_d}{\|\mathbf{x}_d\|_2}.$$

La intuición es que una repetición local aporta evidencia, mientras que un término presente en casi todos los documentos discrimina poco. TF-IDF no comprende significado: pondera distribución. Un identificador raro puede recibir gran peso sin ser semánticamente útil; por ello se combinan filtros de frecuencia, controles de privacidad y evaluación.

N , $df(t)$, vocabulario, límites de frecuencia y selección de atributos son parámetros aprendidos. Se estiman con entrenamiento y se aplican sin reajuste a validación, prueba y producción. Ajustar TF-IDF antes de dividir produce fuga, aun sin usar etiquetas, porque informa qué formas existen y cuán frecuentes son en periodos futuros.

TF-IDF funciona especialmente bien con clasificadores lineales y similitud coseno. No resuelve por sí solo negación, contexto ni sinónimos, aunque bigramas pueden mitigar parte del problema. Su transparencia, eficiencia y facilidad de versionado justifican mantenerlo como referencia incluso al evaluar representaciones densas.

16.1.9. Ejemplo práctico guiado: representación de reclamos financieros

El caso sigue el proyecto de reclamos del Apéndice D. La fuente es **CFPB Consumer Complaint Database**. La unidad es un reclamo publicado con Consumer complaint narrative no vacía; esas narrativas se publican con consentimiento y después de medidas de supresión de información personal.

Esta selección no representa automáticamente todos los reclamos recibidos. La etiqueta es Product, y el propósito es sugerir enrutamiento temático, no inferir daño, mérito, fraude o urgencia.

Se congela una versión y se ordena por Date received. Los periodos contiguos anterior, posterior y más reciente forman entrenamiento, validación y prueba. Duplicados y plantillas quedan en un solo conjunto. Complaint ID sirve solo para trazabilidad. Se excluyen predictores que revelan la etiqueta o el futuro: Product, Sub-product, Issue, Sub-issue, Company public response, Date sent to company, Company response to consumer y Timely response?. También se excluyen del baseline Company, ZIP code y Tags por atajos, privacidad o proxies.

El objetivo de esta práctica es comparar BoW y TF-IDF con las mismas particiones y un mismo clasificador. El siguiente pseudocódigo describe el orden, no una biblioteca específica:

```
congelar versión, mapa de Product y fechas de corte
seleccionar narrativas consentidas no vacías; conservar original protegido
agrupar duplicados; asignar cada grupo completo por regla temporal
```

```
PARA cada variante en {BoW unigramas, TF-IDF unigramas,
                      TF-IDF unigramas+bigrams}:
    ajustar normalizador, vocabulario, df y selección SOLO en entrenamiento
    transformar entrenamiento y validación sin reajustar
    entrenar el mismo clasificador lineal
    registrar dimensión, densidad, cobertura y macro-F1 de validación
```

```
elegir variante con la regla definida en REC-02
congelar pipeline; transformar prueba una vez
```

La inspección de términos debe evitar narrativas completas. Pueden presentarse n-gramas agregados y fragmentos mínimos revisados. Un término de peso alto no es una explicación causal: puede capturar una categoría, una plantilla o una práctica histórica. Si una variante con bigramas mejora validación pero empeora productos de poco soporte, la decisión debe considerar macro-F1, F1 por clase, dimensión y costo, no solo accuracy.

Actividad EMO [REC-03]: representar textos con TF-IDF

Capacidad mínima. Transformar textos en atributos numéricos sin utilizar información de evaluación.

Consigna. Sobre el corpus CFPB fijado en REC-01 y el protocolo temporal de REC-02, construir un pipeline TF-IDF cuya única entrada predictiva obligatoria sea Consumer complaint narrative y cuya etiqueta sea Product. Comparar unigramas con unigramas más bigramas, o dos decisiones justificadas de normalización. No se exige stemming o lematización salvo hipótesis lingüística explícita.

Implementación permitida. El notebook práctico puede utilizar bibliotecas de preparación, vectorización y modelos. Debe hacer explícito el orden:

```
recibir índices temporales ya congelados
ajustar cada candidato con textos de ENTRENAMIENTO
obtener X_entrenamiento = ajustar_y_transformar(textos_entrenamiento)
obtener X_validación = transformar(textos_validación)
```


verificar que validación no altera vocabulario ni idf
 comparar candidatos con el mismo baseline o clasificador
 conservar el candidato elegido sin consultar PRUEBA

Controles obligatorios. El vocabulario, df , pesos IDF, filtros y selección se ajustan solo en entrenamiento o dentro de cada fold de entrenamiento. No se incorporan campos posteriores a la respuesta ni texto concatenado desde ellos. Se informa fecha de congelamiento, cantidad excluida por narrativa ausente, dimensión, densidad, términos de alto peso, cobertura y palabras fuera de vocabulario. Los duplicados no cruzan particiones.

Modalidad de trabajo. Vocabulario y variantes se discuten en equipo; ajuste, comprobación de fuga y análisis son individuales.

Evidencia individual. Notebook reproducible, tabla comparativa, configuración completa y prueba automatizada o comprobación documentada de que el vectorizador nunca recibe validación o prueba durante fit.

Criterios de aprobación. La normalización se justifica; las variantes usan idénticas particiones; se interpretan ganancias y pérdidas; no se exhiben narrativas completas; y las conclusiones se limitan al subconjunto de narrativas consentidas.

Aporte al laboratorio. Produce la representación clásica y el baseline textual que REC-04 utilizará sin modificar el conjunto de prueba.

16.2. Modelado y evaluación de textos

Representar no basta: hace falta vincular la representación con una tarea y una decisión. La evaluación debe simular el uso, separar desarrollo de prueba y combinar métricas agregadas con examen responsable de errores. En texto son comunes la deriva temporal, duplicados, plantillas y diferencias por idioma, canal y longitud.

16.2.1. Similitud entre documentos

La similitud cuantifica proximidad bajo una representación. Para vectores no nulos $\mathbf{x}$ e $\mathbf{y}$, la similitud coseno es

$$\cos(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}.$$

Mide el ángulo y reduce el efecto de magnitud. Con TF-IDF no negativo toma habitualmente valores entre cero y uno. Con embeddings centrados puede ser negativa. Distancia coseno suele definirse como $1 - \cos$, pero no siempre satisface todas las propiedades métricas en cualquier implementación.

La similitud depende por completo del espacio. TF-IDF aproxima coincidencia léxica; embeddings pueden acercar paráfrasis, aunque también recuperar textos tópicamente próximos pero incompatibles. Jaccard compara conjuntos, $|A \cap B| / |A \cup B|$; distancia de edición mide operaciones sobre cadenas; modelos aprendidos pueden estimar relevancia de pares.

Recuperar los k vecinos más cercanos sirve para búsqueda, apoyo a etiquetado, detección de duplicados o evidencia para RAG. Deben evaluarse precisión en k ,

exhaustividad, rango recíproco o nDCG con juicios de relevancia. Un umbral no se elige mirando ejemplos de prueba. En colecciones grandes, índices aproximados intercambian velocidad por exhaustividad y requieren medir latencia y pérdida de vecinos.

Fallo frecuente. Interpretar cercanía como equivalencia. Dos documentos pueden compartir vocabulario porque uno niega al otro. Antes de usar vecinos para decisión, debe definirse qué significa “similar”: mismo tema, misma intención, misma resolución o duplicado casi exacto.

La geometría permite comprender otros efectos. En dimensiones altas, muchas distancias pueden concentrarse y algunos vectores convertirse en **hubs**, vecinos de numerosos documentos sin ser relevantes para todos. La normalización, el entrenamiento del embedding y la distribución del corpus afectan ese fenómeno. Un resultado de búsqueda debe compararse con alternativas léxicas y evaluarse por tipo de consulta. Consultas con términos específicos pueden favorecer TF-IDF; paráfrasis pueden favorecer embeddings; consultas con nombres raros pueden requerir recuperación híbrida.

La similitud asimétrica también importa. Una consulta breve puede ser pertinente para un documento largo aunque representen cantidades distintas de información. Modelos bi-encoder codifican consulta y documento por separado y permiten indexación eficiente; cross-encoders procesan el par conjuntamente y suelen capturar mejor interacción, a mayor costo. Una arquitectura habitual recupera muchos candidatos con bi-encoder y reordena pocos con cross-encoder. Esta separación debe evaluarse por etapas para no atribuir al generador un fallo originado en recuperación.

16.2.2. Clasificación de textos

La clasificación asigna una o varias etiquetas. En multiclase, cada documento tiene una clase entre K ; en multietiqueta puede tener varias; en clasificación jerárquica las etiquetas respetan una taxonomía. Un modelo estima puntajes $s_k(\mathbf{x})$ o probabilidades $P(Y = k | \mathbf{x})$ y una política transforma esos valores en acción.

Los modelos lineales son referencias fuertes para vectores dispersos. La regresión logística multiclase usa

$$P(Y = k | \mathbf{x}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x} + b_k)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x} + b_j)}.$$

La regularización limita coeficientes y ayuda ante alta dimensión. Máquinas de vectores de soporte optimizan márgenes y suelen rendir bien, aunque sus puntajes no son probabilidades calibradas. Naive Bayes impone independencia condicional simplificadora y ofrece un baseline económico.

Los coeficientes indican asociación controlada por el modelo, no causa. Tokens correlacionados con una clase pueden reflejar plantillas o periodos. Para explicaciones locales, contribuciones lineales son transparentes, pero no garantizan que el modelo sea justo ni que el atributo sea conceptualmente válido.

La taxonomía condiciona el máximo alcanzable. Etiquetas inconsistentes, clases superpuestas y cambios históricos generan un techo de desempeño. Conviene

estimar acuerdo humano y revisar una muestra. La salida operativa puede incluir clase principal, alternativa, confianza y abstención. Una predicción no debe convertirse automáticamente en decisión cuando el caso está fuera de distribución.

16.2.3. Análisis de sentimiento

El análisis de sentimiento intenta identificar polaridad, emoción, postura o valoración. Estas tareas no son equivalentes. Un texto puede narrar una experiencia negativa con tono neutral, citar una opinión ajena o expresar satisfacción irónica. “Positivo/negativo” debe definirse respecto de un objeto y un esquema de anotación.

Hay enfoques léxicos, supervisados y generativos. Los léxicos suman orientaciones asociadas a palabras y reglas para negación o intensificación. Son auditables, pero sensibles al dominio. Los clasificadores aprenden patrones etiquetados; los modelos contextuales capturan composicionalidad mejor, aunque heredan sesgos y pueden fallar ante sarcasmo, citas o cambio de dominio.

La evaluación requiere clases y subgrupos, no solo promedio. Deben revisarse negación, intensificadores, lenguaje figurado, mezcla de idiomas y referencias culturales. Si las etiquetas proceden de estrellas o reacciones, son proxies y pueden no coincidir con el sentimiento textual. Inferir estado psicológico, vulnerabilidad o intención desde lenguaje puede ser inválido y riesgoso.

En el laboratorio CFPB, sentimiento no sustituye Product ni valida urgencia. Un relato muy negativo no prueba daño o prioridad sustantiva. Si se explora como análisis secundario, debe quedar fuera de la regla de enrutamiento obligatoria y documentarse su validez limitada.

16.2.4. Extracción de información

La extracción transforma texto en estructuras: entidades, atributos, relaciones, eventos o respuestas localizadas. El reconocimiento de entidades suele etiquetar cada token con esquemas como BIO: B inicia una entidad, I continúa y O queda fuera. La extracción de relaciones vincula entidades; la de eventos identifica desencadenante, participantes, tiempo y lugar.

La evaluación puede ser estricta, exigiendo coincidencia exacta de límites y tipo, o parcial. Precisión y sensibilidad responden preguntas diferentes: ¿cuántas extracciones son correctas? y ¿cuántas menciones reales se encontraron? En documentos largos debe distinguirse rendimiento por mención y por entidad consolidada.

Expresiones ambiguas, entidades anidadas, abreviaturas y correferencia dificultan el problema. Una fecha puede referir al evento o a una cita; el mismo nombre puede designar entidades distintas. Normalizar entidades contra un catálogo agrega otra fuente de error. La propagación importa: una entidad omitida impide relaciones posteriores.

La extracción generativa puede producir estructuras flexibles, pero requiere validación de esquema, restricción de tipos y cotejo con el texto fuente. Un campo bien formado no implica que esté respaldado. En aplicaciones sensibles se conserva el tramo de evidencia y se ofrece revisión, en lugar de tratar la salida como hecho confirmado.

16.2.5. Clases desbalanceadas en NLP

Existe desbalance cuando las clases tienen prevalencias muy diferentes. Un clasificador que siempre elige la mayoría puede alcanzar accuracy elevada y ser inútil para clases raras. El problema no se resuelve automáticamente ponderando: primero deben verificarse soporte, calidad de etiquetas, cobertura y significado operativo.

Estrategias comunes son pesos inversos a frecuencia, sobremuestreo, submuestreo, pérdidas focales, agrupación taxonómica justificada y ajuste de umbrales por clase. La generación sintética de texto puede introducir artefactos o filtraciones y no reemplaza ejemplos reales. Toda resampling se aplica dentro de entrenamiento, nunca antes de partir.

En multiclase, pesos extremos pueden reducir calibración o perjudicar clases intermedias. Deben compararse macro-F1, F1 por clase, matrices normalizadas y curvas de cobertura-error. Si una clase tiene muy pocos casos, una estimación puntual es inestable; intervalos por bootstrap agrupado o repetición temporal ayudan a expresar incertidumbre, respetando dependencias.

El desbalance operativo también cambia. Una clase rara durante entrenamiento puede crecer en producción. Monitorear prevalencia predicha no basta porque el modelo puede equivocarse; se necesita una muestra etiquetada con demora conocida. La política de revisión debe asignar capacidad a clases de alto costo sin presentar rareza como sinónimo de gravedad.

16.2.6. Métricas de clasificación

Para una clase tratada como positiva, precisión, sensibilidad y F1 son

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN},$$

$$F_1 = 2 \frac{\text{Precision Recall}}{\text{Precision} + \text{Recall}}.$$

En multiclase, **macro-F1** promedia el F1 de cada clase y da igual peso a categorías; **micro-F1** agrega conteos y queda dominado por clases frecuentes; el promedio ponderado usa soporte. Accuracy es la proporción total correcta. Todas deben acompañarse de soporte y matriz de confusión.

La matriz C tiene C_{ij} casos de clase real i predichos como j . Normalizar por fila revela destinos de error de cada clase; mostrar conteos conserva escala. Top- k accuracy puede ser pertinente si una persona revisa alternativas, pero no reemplaza la exactitud de la ruta principal.

Cuando se usan probabilidades, la pérdida logarítmica evalúa confianza asignada a la clase real:

$$\mathcal{L}_{\log} = -\frac{1}{N} \sum_{i=1}^N \log p_{i, y_i}.$$

Calibración pregunta si predicciones con probabilidad aproximada p aciertan cerca de esa frecuencia. Diagramas de confiabilidad, Brier score y error esperado

de calibración aportan perspectivas distintas. La calibración debe ajustarse en entrenamiento/validación, no en prueba.

Para abstención se reportan **cobertura**, proporción enrutada automáticamente, y **riesgo selectivo**, error entre casos enrutados. Aumentar el umbral suele reducir cobertura y riesgo, pero puede distribuir la revisión de forma desigual. La política se selecciona en validación según costos y capacidad; la prueba se abre una vez.

16.2.7. Evaluación cualitativa de errores

Las métricas dicen cuánto falla; el análisis cualitativo ayuda a entender cómo. Una taxonomía útil distingue ambigüedad legítima, etiqueta discutible, vocabulario nuevo, negación, documento multitemático, truncación, plantilla, texto insuficiente, idioma no cubierto y caso fuera de alcance. Cada categoría debe conducir a una acción: revisar datos, reformular taxonomía, mejorar representación o abstenerse.

La muestra de errores no debe elegirse solo por interés. Conviene seleccionar falsos positivos y negativos por clase, nivel de confianza, longitud, periodo y canal; incluir aciertos de baja y alta confianza; y registrar el denominador. Buscar únicamente ejemplos espectaculares produce una narrativa sesgada.

La revisión debe proteger privacidad. Se asignan identificadores internos, se presentan fragmentos mínimos anonimizados y se eliminan nombres, direcciones, números y combinaciones reidentificables. La anonimización automatizada no basta: una persona revisa cada ejemplo antes de divulgarlo. Si el sentido depende de información sensible, puede describirse el patrón sin citar texto.

Los errores revelan límites del rótulo. Si personas expertas discrepan, mejorar el algoritmo quizá no resuelva el problema. Debe separarse error del modelo, error de referencia y ambigüedad. Documentar estas proporciones evita atribuir toda discrepancia a incapacidad predictiva.

Del desempeño a la decisión. Un clasificador se evalúa en al menos tres planos. La capacidad discriminativa indica si ordena o separa clases; la calibración indica si sus puntajes permiten interpretar riesgo; la utilidad mide consecuencias bajo una política. Dos modelos con macro-F1 semejante pueden producir cargas de revisión muy distintas. A su vez, un modelo bien calibrado puede ser inaceptable si la taxonomía perjudica a un grupo o si el error más costoso queda oculto por el promedio.

Sea $a \in \{\text{enrutar, revisar}\}$ una acción y $C(a, y, \hat{y})$ su costo. La política ideal minimiza costo esperado condicionado por información disponible:

$$a^*(\mathbf{x}) = \arg \min_a \sum_y C(a, y, \hat{y}) P(y | \mathbf{x}).$$

Esta expresión aclara que el umbral no es propiedad natural del modelo. Depende de costos, capacidad y probabilidades suficientemente calibradas. Los costos pueden ser difíciles de monetizar; aun así pueden ordenarse, establecer restricciones o analizar escenarios. No corresponde inventar una cifra precisa para producir apariencia de objetividad.

La incertidumbre tiene fuentes distintas. La **aleatoria** procede de ambigüedad inherente; la **epistémica**, de datos o conocimiento insuficientes; la **distributiva**,

de diferencias entre entrenamiento y uso. Un margen bajo puede revelar ambigüedad, pero un modelo puede estar muy seguro fuera de distribución. Detectores de idioma, distancia a entrenamiento, reglas de alcance y monitoreo complementan el umbral. Ninguno es infalible.

La evaluación de subgrupos requiere denominadores suficientes y categorías justificadas. Buscar muchas diferencias sin control genera hallazgos espurios; agrupar de más oculta heterogeneidad. Deben predefinirse cortes pertinentes, mostrar intervalos y evitar conclusiones sobre grupos con soporte mínimo. Cuando se comparan periodos, es útil descomponer cambios en prevalencia, vocabulario, relación entre texto y etiqueta, y calidad de anotación.

Finalmente, la prueba es un instrumento de confirmación, no una reserva inagotable. Si los resultados de prueba impulsan cambios y se vuelve a medir en la misma prueba, esta pasa de hecho a ser validación. Hace falta una nueva cohorte, un periodo posterior o una evaluación prospectiva. Esta disciplina es especialmente importante en PLN, donde inspeccionar ejemplos permite adaptar reglas con rapidez y producir sobreajuste humano difícil de rastrear.

16.2.8. Ejemplo práctico guiado: clasificación automática de reclamos

Se reutiliza sin cambios el pipeline elegido en REC-03. El baseline mínimo predice la clase mayoritaria estimada en entrenamiento; el baseline textual y un clasificador lineal se comparan con macro-F1 principal, accuracy, F1 y soporte por producto, matriz de confusión y calibración o margen.

La decisión simulada solo tiene dos acciones: enrutar, cuando la confianza validada permite sugerir una cola temática, y revisar, cuando hay baja confianza, margen pequeño, clase fuera de alcance o alto costo de confusión. “Priorizar” significa priorizar revisión humana, no afirmar urgencia. Timely response? es posterior a la respuesta y no es una etiqueta válida de urgencia inicial.

ajustar baseline y clasificador SOLO con entrenamiento
obtener puntajes en validación

PARA cada umbral candidato:

 calcular cobertura, error entre enrutados y revisión requerida

 calcular métricas por Product, longitud, canal y periodo

seleccionar umbral con costo y capacidad predefinidos

congelar vectorizador, clasificador, calibración y política

evaluar una vez en prueba

muestrear errores estratificados; anonimizar y revisar fragmentos

Un margen puede definirse como diferencia entre los dos mayores puntajes. Un margen bajo indica competencia entre rutas, no necesariamente probabilidad baja. Si se requieren probabilidades, se calibra sin tocar prueba. La salida incluye producto sugerido, segunda opción, confianza documentada, acción y advertencia de cobertura.

Un fallo posible es que el modelo aprenda menciones explícitas de productos y parezca excelente, pero degrade ante nuevas formas de redacción. Otro es que Company actúe como atajo. El análisis temporal y por canal ayuda a detectarlo. Ninguna explicación por término debe presentarse como motivo real del reclamo.

Actividad EMO [REC-04]: clasificar, priorizar y analizar errores

Capacidad mínima. Entrenar un clasificador de texto, evaluarlo con REC-02 y convertir su incertidumbre en una regla limitada de uso.

Consigna. Comparar mayoría y baseline textual con al menos un clasificador lineal apropiado para TF-IDF. La entrada es solo la narrativa inicial consentida y la etiqueta es Product. Examinar errores por producto, longitud, canal y periodo. Seleccionar en validación un umbral o margen para enrutar/revisar; no ajustar nada con prueba.

Implementación permitida. El notebook puede entrenar, calibrar y graficar métricas:

```
recibir representación REC-03 congelada
entrenar candidatos en ENTRENAMIENTO
seleccionar modelo y calibración con VALIDACIÓN
definir revisar si confianza < umbral 0 margen < mínimo
congelar política
predecir PRUEBA una única vez
exportar solo métricas agregadas e identificadores protegidos para auditoría
```

Resultados mínimos. Macro-F1, accuracy, precisión, sensibilidad y F1 por clase, soporte, matriz de confusión en conteos y normalizada, cobertura, tasa de error entre enrutados y carga de revisión. Si las probabilidades no están calibradas se las denomina puntajes o se usa margen.

Análisis de errores. Construir una muestra estratificada de falsos enrutamientos, abstenciones y aciertos. Los ejemplos deben ser fragmentos estrictamente necesarios, anonimizados y revisados; nunca narrativas completas. Distinguir ambigüedad, etiqueta posiblemente inconsistente, vocabulario nuevo, texto insuficiente y fallo del modelo.

Restricciones. No usar Company public response, Date sent to company, Company response to consumer, Timely response? ni otros campos posteriores. No inferir urgencia, daño, legitimidad o vulnerabilidad. El sistema sugiere ruta o revisión; no toma decisiones financieras ni genera respuesta al consumidor.

Evidencia individual. Notebook reproducible, comparación contra baseline, política de umbral defendida con validación, galería anonimizada de errores y recomendación de supervisión.

Criterios de aprobación. Se respeta REC-02, prueba tiene uso único, las métricas incluyen clases minoritarias, la regla refleja costos de enrutamiento y los límites de cobertura y consentimiento quedan explícitos.

16.3. Embeddings, atención y Transformers

Las representaciones densas aprenden coordenadas continuas en las que la proximidad refleja regularidades de los datos. Los embeddings contextuales permiten que una misma forma tenga vectores diferentes según su entorno. Atención y Transformer hacen posible combinar información a larga distancia y preentrenar modelos reutilizables.

16.3.1. Limitaciones de las representaciones dispersas

BoW y TF-IDF asignan una dimensión a cada término. Cuando $|V|$ es grande, los vectores son dispersos y dos paráfrasis sin términos comunes pueden tener similitud cero. La representación tampoco distingue sentidos de una forma ni modela fácilmente dependencias distantes. Agregar n-gramas incorpora orden local, pero multiplica dimensionalidad y escasez.

Estas limitaciones no anulan sus ventajas: escalan bien, son inspeccionables y requieren pocos datos. “Disperso” no significa inferior. En dominios donde palabras específicas definen categorías, TF-IDF puede superar modelos densos. Además, una dimensión identificable facilita depuración y cumplimiento.

Los embeddings densos comprimen información en $m \ll |V|$ dimensiones. Esta compresión comparte evidencia entre términos, pero las coordenadas individuales suelen carecer de interpretación. La cercanía aprendida depende del corpus y puede codificar asociaciones sociales indeseables. También puede borrar distinciones raras relevantes. La comparación debe usar la misma partición y tarea, e incluir costo, latencia y estabilidad.

16.3.2. Embeddings distribucionales

La hipótesis distribucional sostiene que unidades usadas en contextos semejantes tienden a tener significados relacionados. Un embedding asigna a cada token w un vector $\mathbf{e}_w \in \mathbb{R}^m$. Métodos predictivos aprenden a anticipar una palabra desde contexto o contexto desde palabra; métodos basados en conteos factorizan matrices de coocurrencia transformadas.

En skip-gram, de forma simplificada, se maximiza la probabilidad de contextos c cercanos a una palabra central w :

$$\sum_{(w,c)} \log P(c | w), \quad P(c | w) = \frac{\exp(\mathbf{u}_c^\top \mathbf{v}_w)}{\sum_{c'} \exp(\mathbf{u}_{c'}^\top \mathbf{v}_w)}.$$

El denominador es costoso y suele aproximarse con muestreo negativo. Vectores cercanos reflejan sustituibilidad o asociación, que no siempre equivale a sinonimia: antónimos pueden compartir contextos.

Para representar documentos se pueden promediar embeddings, ponderarlos o aprender un codificador. El promedio pierde orden y diluye palabras raras. Palabras fuera del vocabulario requieren subpalabras o un símbolo desconocido. La evaluación intrínseca mediante analogías o similitud humana no garantiza utilidad en la tarea final; la evidencia principal debe ser extrínseca y por subgrupo.

16.3.3. Representaciones contextuales

Un embedding estático asigna un único vector a una forma. Una representación contextual calcula $\mathbf{h}_t = f(x_1, \dots, x_T, t)$: el vector de la posición t depende de toda o parte de la secuencia. Así, una forma ambigua puede ocupar regiones distintas según contexto.

El contexto disponible depende del objetivo. Un codificador bidireccional utiliza tokens a ambos lados; un modelo causal solo observa el prefijo durante predicción

autoregresiva. En ambos casos se combinan embeddings de token y posición, y pueden añadirse segmentos u otros marcadores.

Para clasificación de documentos se usa un token especial, pooling medio o atención sobre posiciones. La elección influye en truncación y sensibilidad a longitud. Para similitud, no todo embedding contextual es directamente comparable con coseno: algunos modelos se entrenan específicamente para producir vectores de oración.

Las representaciones contextuales siguen limitadas por ventana, datos y tokenización. Información al final de un documento truncado desaparece; lenguaje nuevo o minoritario puede fragmentarse más; prompts pequeños pueden alterar el vector. La contextualidad reduce polisemia, no garantiza comprensión factual ni razonamiento correcto.

16.3.4. Modelos secuenciales

Los modelos recurrentes procesan una secuencia actualizando un estado:

$$\mathbf{h}_t = \phi(W_x \mathbf{x}_t + W_h \mathbf{h}_{t-1} + \mathbf{b}).$$

El estado resume el prefijo y puede alimentar clasificación o predicción del siguiente token. RNN simples sufren gradientes que se desvanecen o explotan. LSTM y GRU incorporan compuertas que regulan conservación, escritura y olvido, mejorando dependencias largas.

Los modelos bidireccionales combinan lectura hacia adelante y atrás cuando toda la secuencia está disponible. Para generación causal no pueden consultar el futuro. Arquitecturas encoder-decoder convierten una entrada en estado y generan una salida; un único estado fijo crea un cuello de botella para secuencias largas.

La recurrencia impone dependencia computacional entre pasos y limita paralelización. También comprime progresivamente información distante. Atención surgió para permitir acceso directo a estados de entrada. No obstante, modelos recurrentes siguen siendo útiles en flujos, dispositivos limitados y problemas donde el procesamiento incremental es natural.

16.3.5. Mecanismos de atención

La atención recupera una combinación de valores según compatibilidad entre una consulta y claves. Sean $X \in \mathbb{R}^{T \times d}$ las representaciones. Proyecciones aprendidas producen

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V,$$

con consultas y claves de dimensión d_k . Para la posición i , el puntaje con j es $s_{ij} = \mathbf{q}_i^\top \mathbf{k}_j$. Si componentes tienen varianza unitaria, el producto escalar suma d_k términos y su varianza crece aproximadamente con d_k . Dividir por $\sqrt{d_k}$ mantiene puntajes en una escala que evita saturar softmax:

$$\alpha_{ij} = \frac{\exp(s_{ij}/\sqrt{d_k})}{\sum_{\ell=1}^T \exp(s_{i\ell}/\sqrt{d_k})}.$$

La salida es una esperanza ponderada de valores:

$$\mathbf{z}_i = \sum_{j=1}^T \alpha_{ij} \mathbf{v}_j,$$

y en forma matricial

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V.$$

M vale cero en conexiones permitidas y un valor muy negativo en las prohibidas. Una máscara causal impide atender posiciones futuras; una máscara de relleno excluye tokens artificiales.

La atención multi-cabeza calcula este proceso con proyecciones distintas, concatena resultados y los proyecta. Diferentes cabezas pueden especializarse, pero los pesos no constituyen por sí solos explicaciones fieles: indican distribución interna de acceso, no causalidad ni razonamiento humano.

El costo de autoatención estándar es cuadrático en T por la matriz $T \times T$. Variantes dispersas, por bloques o aproximadas buscan ampliar contexto. Más contexto tampoco garantiza usar bien evidencia lejana; deben realizarse pruebas de recuperación y posición.

16.3.6. Arquitectura Transformer

Un Transformer apila bloques de atención y redes feed-forward por posición. Cada bloque incluye conexiones residuales y normalización. Una forma pre-normalizada es

$$H' = H + \text{MHA}(\text{LN}(H)),$$

$$H'' = H' + \text{FFN}(\text{LN}(H')),$$

donde

$$\text{FFN}(\mathbf{h}) = W_2 \sigma(W_1 \mathbf{h} + b_1) + b_2.$$

La atención mezcla información entre posiciones; la FFN transforma cada posición con pesos compartidos; residuales facilitan flujo de información y gradientes. Como autoatención no conoce orden por sí misma, se agregan codificaciones posicionales absolutas, relativas o rotatorias.

Hay tres familias principales. Un **encoder** usa atención bidireccional y es apropiado para comprensión y clasificación. Un **decoder** usa máscara causal y genera secuencias. Un **encoder-decoder** codifica entrada y el decoder incorpora atención cruzada hacia ella, útil en traducción o resumen condicionado.

La figura sintetiza el flujo, pero una implementación completa también gestiona tokenización, máscaras, caché de claves y valores, precisión numérica y estrategia




Figura 15: Flujo de un Transformer

de decodificación. Durante inferencia autoregresiva, la caché evita recalcular todo el prefijo, aunque memoria crece con contexto.

Fallo frecuente. Atribuir toda capacidad a atención. Datos, objetivo, escala, optimización y alineación posterior son igualmente decisivos. La arquitectura ofrece un mecanismo; no garantiza actualidad, veracidad o conducta segura.

16.3.7. Preentrenamiento y ajuste fino

El preentrenamiento aprende representaciones a partir de grandes colecciones mediante objetivos autosupervisados. En modelado causal se predice el siguiente token; en modelado enmascarado se reconstruyen tokens ocultos; encoder-decoders pueden reconstruir fragmentos corruptos. Los datos aportan simultáneamente entradas y objetivos, pero su origen, licencia y calidad siguen siendo relevantes.

El **ajuste fino** adapta parámetros con ejemplos de una tarea. Puede actualizar todo el modelo o emplear métodos eficientes en parámetros, como adaptadores o matrices de bajo rango. Otra opción congela el codificador y entrena una cabeza. Menos parámetros reduce costo, no elimina necesidad de validación ni riesgo de olvido catastrófico.

La adaptación por instrucciones usa pares de instrucciones y respuestas; la alineación con preferencias optimiza salidas valoradas por personas o modelos de recompensa. Estas etapas alteran comportamiento, pero no crean una base de conocimiento verificable. Una respuesta fluida puede seguir siendo falsa.

Debe separarse conjunto de preentrenamiento, adaptación y evaluación. La contaminación ocurre cuando preguntas o equivalentes aparecen en entrenamiento. En dominios temporales, una prueba posterior al corte reduce, sin eliminar, memorización. La comparación con TF-IDF debe controlar particiones y costo total.

Qué aprende una representación. Un objetivo autosupervisado define qué regularidades reciben recompensa. Predecir tokens favorece sintaxis, asociaciones y conocimiento repetido; contrastar pares favorece invariancia entre ejemplos considerados equivalentes. Ningún objetivo captura “semántica” de manera neutral. Las similitudes del espacio expresan datos, arquitectura, muestreo y pérdida. Cambiar positivos y negativos puede cambiar qué diferencias se conservan.

En aprendizaje contrastivo, una formulación típica acerca una pareja positiva (i, j) y la distingue de candidatos k mediante

$$\mathcal{L}_i = -\log \frac{\exp(\text{sim}(\mathbf{h}_i, \mathbf{h}_j)/\tau)}{\sum_k \exp(\text{sim}(\mathbf{h}_i, \mathbf{h}_k)/\tau)}.$$

La temperatura τ controla concentración. Los negativos falsos, textos que en realidad son semánticamente compatibles, empujan representaciones en una dirección errónea. Los positivos fáciles pueden enseñar atajos de formato. El diseño de pares es tan importante como la arquitectura.

La transferencia puede ser positiva o negativa. Es positiva cuando regularidades del preentrenamiento reducen datos necesarios; negativa cuando sesgos o dominio desajustado perjudican. La adaptación continuada a un corpus de dominio puede mejorar vocabulario, pero requiere derechos sobre datos, cómputo y pruebas de olvido. El ajuste con pocos ejemplos también puede memorizar. Curvas de aprendizaje ayudan a decidir si recolectar etiquetas, cambiar representación o corregir la tarea.

Hay varias formas de utilizar un modelo preentrenado: extracción fija de embeddings, ajuste de una cabeza, ajuste total, adaptación eficiente o prompting. No son intercambiables. Aumentan progresivamente flexibilidad y, por lo general, costo y riesgo de sobreajuste. La comparación debe incluir número de ejemplos, parámetros actualizados, energía o tiempo, memoria, latencia y variabilidad entre ejecuciones.

Las leyes empíricas de escala describen mejoras promedio al aumentar parámetros, datos o cómputo bajo ciertas condiciones. No prometen mejora monótona en cada tarea ni resuelven calidad de datos. Duplicación excesiva puede favorecer memorización; contenido sintético puede amplificar errores; filtros pueden remover variedades lingüísticas. La gobernanza del conjunto de preentrenamiento sigue siendo central aunque el usuario final no tenga acceso a él.

16.3.8. Ejemplo práctico guiado: comparación de representaciones de texto

La comparación enfrenta TF-IDF con un embedding contextual para la misma tarea Product, sin cambiar fechas, duplicados ni métricas. El embedding se obtiene de un modelo documentado; si se ajusta, solo recibe entrenamiento. La selección de pooling, truncación, modelo y clasificador se hace con validación.

congelar particiones CFPB y etiquetas usadas en REC-03

RUTA A: transformar con TF-IDF ya ajustado; entrenar clasificador lineal

RUTA B: obtener embeddings sin usar etiquetas de validación/prueba;

entrenar la misma familia de cabeza o clasificador documentado

comparar macro-F1, clases, latencia, memoria y cobertura por longitud

revisar pares donde contexto cambia sentido y donde coincidencia léxica ayuda

TF-IDF puede ganar cuando nombres temáticos son explícitos. El embedding puede ayudar con paráfrasis o vocabulario variable, pero sufrir truncación o desajuste de dominio. Se analizan documentos largos y periodos recientes. No se publican narrativas: se usan fragmentos anonimizados o ejemplos sintéticos claramente rotulados.

La conclusión no debe reducirse a una cifra. Una mejora pequeña puede no justificar mayor latencia, opacidad o mantenimiento. A la inversa, mejor cobertura semántica puede ser valiosa si reduce confusiones costosas. El experimento debe declarar versión del modelo, tokenizador, longitud máxima y si los datos pudieron formar parte de su preentrenamiento.

16.4. Grandes modelos de lenguaje y aplicaciones generativas

Los grandes modelos de lenguaje (LLM) producen o transforman texto mediante distribuciones aprendidas a gran escala. Pueden resumir, extraer, programar, dialogar y usar herramientas, pero no son bases de datos ni autoridades epistémicas. Una aplicación responsable separa generación, evidencia, permisos, evaluación y decisión.

16.4.1. Grandes modelos de lenguaje

“Grande” describe escala relativa de parámetros, datos y cómputo, no una frontera científica fija. Muchos LLM son Transformers decoder-only entrenados para predecir tokens. Sus capacidades surgen de arquitectura, diversidad de datos, escala y adaptación. El modelo opera sobre tokens y produce distribuciones; la interfaz conversacional es una capa de producto.

Los parámetros almacenan regularidades distribuidas, no registros confiables con procedencia. El conocimiento puede estar desactualizado, ser contradictorio o reflejar repeticiones del corpus. El contexto de entrada permite condicionar la respuesta, pero tiene límite y puede contener instrucciones hostiles.

La selección de un LLM considera calidad por tarea, idiomas, ventana, latencia, costo, residencia de datos, licencia, soporte, posibilidad de despliegue local y controles. El número de parámetros no reemplaza evaluación. Modelos pequeños especializados pueden resultar preferibles.

Una aplicación incluye más que el modelo: plantillas, recuperación, herramientas, filtros, caché, registros, interfaz y revisión. Cada componente tiene versión y superficie de ataque. Por ello se evalúa el sistema completo y también sus partes.

16.4.2. Generación autoregresiva

Un modelo causal factoriza la probabilidad de una secuencia:

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t | x_{<t}).$$

Durante entrenamiento minimiza entropía cruzada del token real. Durante generación, transforma logits z_i en probabilidades con temperatura τ :

$$P(x_t = i | x_{<t}) = \frac{\exp(z_i/\tau)}{\sum_j \exp(z_j/\tau)}.$$

Temperatura baja concentra la distribución; alta aumenta diversidad. Decodificación voraz elige el máximo; beam search conserva hipótesis; top- k restringe a k tokens; nucleus o top- p conserva el menor conjunto cuya masa supera p . Ninguna estrategia garantiza hechos correctos.

La generación es secuencial: una elección temprana condiciona las siguientes y puede producir cascadas de error. La probabilidad de token no es confianza factual de una afirmación. Un texto falso frecuente puede recibir alta probabilidad; uno verdadero pero raro, baja.

Longitud máxima, criterio de parada y penalizaciones cambian resultados. La reproducibilidad requiere guardar modelo, parámetros de muestreo, prompt, herramientas y, cuando exista, semilla, aunque servicios remotos pueden seguir siendo no deterministas.

16.4.3. Diseño de instrucciones o prompting

Un prompt eficaz explicita tarea, contexto autorizado, audiencia, formato, criterios y límites. Debe distinguir instrucciones de datos no confiables mediante delimitadores. Pedir “sé preciso” es menos verificable que exigir un esquema, citas y una salida de abstención cuando falte evidencia.

Una plantilla robusta contiene: rol funcional limitado; objetivo; fuentes permitidas; pasos de validación; formato; prohibiciones; y política ante incertidumbre. No debe incluir secretos. El texto recuperado o aportado por usuarios se trata como datos, no como instrucciones, porque puede contener *prompt injection*.

La ingeniería de prompts es desarrollo de software: se versiona y prueba con casos normales, límites y adversariales. Cambiar una palabra puede alterar comportamiento, por lo que optimizar con ejemplos de prueba sobreajusta. Se usa un conjunto de desarrollo y se reserva prueba.

Pedir razonamientos extensos no garantiza fidelidad y puede exponer información. Es preferible solicitar resultados verificables, evidencia y campos estructurados. La aplicación valida sintaxis, tipos, rangos y citas; nunca confía únicamente en que el modelo “siga” una prohibición.

16.4.4. Aprendizaje en contexto

El aprendizaje en contexto condiciona al modelo mediante ejemplos incluidos en la entrada, sin actualizar parámetros. **Zero-shot** presenta solo la tarea; **one-shot**, un ejemplo; **few-shot**, varios. Los ejemplos enseñan formato, categorías y fronteras, pero consumen ventana y pueden sesgar por orden.

La selección debe representar casos y contraejemplos. Etiquetas inconsistentes inducen errores. Recuperar ejemplos similares puede ayudar, aunque crea riesgo de copiar datos sensibles o resultados incorrectos. Los ejemplos se separan de la consulta y se etiquetan como demostraciones, no evidencia factual.

El desempeño puede variar con orden, redacción y nombres arbitrarios de etiquetas. Deben ensayarse permutaciones y plantillas. El modelo puede inferir patrones superficiales en vez de la regla pretendida. El aprendizaje en contexto tampoco “aprende” permanentemente: fuera del contexto no conserva la adaptación, salvo que el proveedor use datos bajo otra política.

Para tareas estables y masivas, ajuste fino o clasificador específico puede ser más económico. Para tareas cambiantes con pocos ejemplos, in-context ofrece flexibilidad. La decisión requiere comparar calidad, latencia, privacidad y mantenibilidad.

16.4.5. Generación aumentada con recuperación

RAG combina recuperación de documentos con generación condicionada. Su objetivo es aportar evidencia actualizable y trazable sin confiar solo en parámetros. Una cadena típica ingiere fuentes, segmenta, representa, indexa, recupera candidatos, reordena y construye un contexto para responder con citas.

Formalmente, para consulta q , un recuperador aproxima $P(d | q)$ y el generador produce $P(y | q, d)$. Una idealización marginaliza documentos:

$$P(y | q) = \sum_{d \in \mathcal{D}} P(y | q, d) P(d | q).$$

En práctica se usan pocos fragmentos. El fracaso puede venir de cobertura documental, segmentación, consulta, recuperación, ranking, contexto o generación. Por ello se evalúan por separado recall@k de evidencia, ranking, fidelidad de citas, completitud y corrección de respuesta.

La segmentación equilibra contexto y precisión. Fragmentos pequeños pierden dependencias; grandes introducen ruido. Se conservan metadatos, versión, fecha, permisos y enlace. Recuperación híbrida combina coincidencia léxica y embeddings. Un re-ranker mejora orden con mayor costo.

RAG no elimina alucinaciones. El modelo puede ignorar evidencia, mezclar fuentes o citar un fragmento que no respalda la afirmación. Debe abstenerse si no hay evidencia suficiente y expresar conflictos. Los documentos son entrada no confiable: una instrucción incrustada no adquiere autoridad por ser recuperada.

16.4.6. Integración mediante APIs y aplicaciones

Una API expone el modelo mediante solicitudes y respuestas. La integración define autenticación, cuotas, reintentos, tiempos de espera, streaming, versiones, formatos y manejo de errores. Una respuesta HTTP exitosa solo indica comunicación técnica, no calidad semántica.

Las entradas se minimizan antes de salir del perímetro. Deben conocerse retención, uso para entrenamiento, ubicación, subprocesadores y mecanismos de borrado del proveedor. Claves se almacenan en gestores de secretos, nunca en prompts, código cliente o registros. Los logs separan metadatos necesarios de contenido sensible y aplican acceso y caducidad.

Las salidas estructuradas se validan contra un esquema. Herramientas se exponen mediante listas permitidas y privilegio mínimo. El modelo propone una llamada; software determinista verifica identidad, argumentos, autorización e impacto antes de ejecutarla. Acciones irreversibles requieren confirmación humana o controles transaccionales.

La aplicación debe tolerar límites, cambios de modelo y fallos parciales. Caché puede reducir costo, pero crea problemas de datos obsoletos y separación entre

usuarios. Se versionan prompt, modelo, índice y política. Pruebas de integración incluyen inyección, desbordamiento de contexto, indisponibilidad y respuesta malformada.

16.4.7. Alucinaciones y evaluación de respuestas

Una alucinación es contenido presentado sin respaldo suficiente en evidencia o realidad pertinente. Puede ser intrínseca, cuando contradice la fuente, o extrínseca, cuando agrega algo no verificable allí. También existen omisiones, citas incorrectas, instrucciones incumplidas y respuestas inseguras.

Evaluar texto generativo requiere una rúbrica por tarea. Dimensiones habituales son corrección, fidelidad, cobertura, relevancia, formato, seguridad, utilidad y abstención. Métricas de solapamiento sirven cuando existe referencia estable, pero penalizan paráfrasis y pueden premiar textos incorrectos. Evaluadores automáticos basados en LLM escalan, aunque tienen sesgo, variabilidad y conflictos de interés; se calibran contra evaluación humana.

Un conjunto de prueba incluye casos frecuentes, raros, ambiguos, sin respuesta, contradictorios y adversariales. Para RAG se marca evidencia necesaria. Cada afirmación verificable se vincula con una fuente y se comprueba si la cita implica realmente la afirmación. Se reportan intervalos y desacuerdo entre evaluadores.

Mitigaciones incluyen recuperación, restricciones, herramientas, verificación posterior y abstención. Ninguna reduce riesgo a cero. La interfaz debe evitar presentar generación como autoridad y permitir denunciar errores. En dominios de alto impacto, un humano competente revisa antes de actuar.

16.4.8. Sesgos, privacidad y propiedad intelectual

Los LLM reproducen y amplifican asociaciones de datos y decisiones de diseño. El sesgo puede manifestarse como calidad desigual, estereotipos, trato dispar o invisibilización. Se evalúa por idioma, variedad, grupo pertinente y situación, sin inferir atributos sensibles cuando no existe base legal y metodológica. Igualar una métrica no garantiza justicia contextual.

La privacidad abarca datos enviados, memorizados, inferidos y registrados. La desidentificación reduce riesgo, pero texto libre puede revelar identidad mediante narrativa. Se aplican minimización, control de acceso, cifrado, retención limitada, evaluación de impacto y procedimientos para incidentes. No se solicita al modelo que “anonimice” como única salvaguarda.

La propiedad intelectual afecta datos de entrenamiento, entradas, salidas y fuentes recuperadas. Deben respetarse licencias, atribución, límites de reproducción, secretos comerciales y políticas institucionales. Una salida nueva puede parecerse a material protegido; no debe asumirse titularidad o libertad de uso sin análisis correspondiente. RAG facilita procedencia, pero también puede reproducir fragmentos extensos.

Estos riesgos interactúan: auditar sesgo puede requerir atributos sensibles, lo cual exige controles de privacidad. La documentación debe justificar necesidad, acceso y eliminación. Las decisiones legales dependen de jurisdicción y no se sustituyen con una regla técnica general.

16.4.9. Documentación de limitaciones y supervisión humana

La documentación convierte supuestos en información operable. Una ficha de modelo registra propósito, población, datos, métricas, usos previstos y prohibidos, subgrupos, límites, versiones y contacto. Una ficha de sistema agrega prompts, fuentes RAG, herramientas, políticas, monitoreo e incidentes.

Supervisión humana no significa colocar una persona al final sin tiempo ni autoridad. Debe definirse qué revisa, qué evidencia recibe, cuándo puede rechazar, cómo escala y cómo se mide su carga. La automatización puede generar sesgo de confirmación; por ello la interfaz presenta incertidumbre y alternativas, no solo una respuesta destacada.

El monitoreo observa calidad, deriva, cobertura, abstención, latencia, costo, seguridad y distribución de errores. Las señales automáticas se complementan con muestras auditadas y retroalimentación. Una actualización de modelo, tokenizador, prompt o índice requiere evaluación de regresión y posibilidad de reversión.

Se mantienen trazas proporcionales: versiones y decisiones, evitando guardar contenido sensible innecesario. Un registro de incidentes describe impacto, causa, corrección y prevención. Criterios de suspensión deben existir antes del despliegue. La responsabilidad permanece en la organización, no se delega al modelo ni al proveedor.

Ciclo de vida y defensa en profundidad. El análisis comienza antes de adquirir un modelo. Durante diseño se determina si la tarea necesita generación o puede resolverse con búsqueda, reglas o clasificación. Se realiza una evaluación de impacto proporcional al daño posible, se consulta a personas afectadas y se definen usos prohibidos. Durante desarrollo se separan datos, se construyen baselines y se ensayan fallos. Antes del despliegue se efectúan pruebas de seguridad, privacidad, carga y recuperación. En operación se monitorea, audita y mantiene una vía de apelación. Al retirar el sistema se eliminan datos y credenciales conforme a política y se preserva solo la evidencia exigida.

La defensa en profundidad asume que cada control puede fallar. Una instrucción del sistema puede ser ignorada; un filtro puede omitir una variante; un recuperador puede traer contenido hostil; una persona puede aprobar por rutina. Por eso se combinan minimización de datos, aislamiento, permisos deterministas, validación, límites de acciones, revisión y monitoreo. Los controles críticos viven fuera del modelo. Por ejemplo, el acceso a un documento se decide con identidad y lista de permisos, no preguntando al LLM si el usuario parece autorizado.

El modelado de amenazas identifica activos, adversarios, superficies y consecuencias. Entre las amenazas están extracción de instrucciones, exfiltración de contexto, envenenamiento del índice, abuso de herramientas, denegación por entradas largas y filtración entre sesiones. También existen fallos no adversariales: configuración errónea, fuente vencida, dependencia caída o traducción defectuosa. Cada amenaza necesita prevención, detección, respuesta y propietario.

La observabilidad debe evitar convertirse en vigilancia. Métricas agregadas suelen bastar para disponibilidad y costo; muestras de contenido requieren finalidad, acceso restringido y retención corta. Los mecanismos de retroalimentación informan a usuarios qué se guarda. Si las conversaciones se usan para mejora, el consentimiento y la base jurídica deben estar claros; ocultarlo tras condiciones

genéricas erosiona confianza.

La revisión humana debe evaluarse como componente. Se miden acuerdo, tiempo, tasa de corrección, fatiga y escalamiento. Si el volumen supera capacidad, el control es ficticio. La interfaz puede ocultar la sugerencia inicialmente en una muestra para estimar automatización sesgada, o mostrar evidencia antes que conclusión. Capacitación, guías y rotación reducen errores, pero no sustituyen dotación adecuada.

La documentación de cambios es esencial en APIs que evolucionan. Una versión nueva puede modificar seguridad, estilo o tokenización sin alterar el nombre visible. Se mantienen pruebas centinela, umbrales de regresión y despliegue gradual. Si un indicador crítico empeora, se revierte o suspende. El proceso de excepción debe registrar quién autorizó, por cuánto tiempo y con qué compensaciones.

Por último, la evaluación previa no agota legitimidad. Un sistema puede ser preciso y aun así resultar innecesario, desproporcionado o incompatible con derechos. Preguntar “¿podemos construirlo?” debe acompañarse de “¿debemos hacerlo?”, “¿quién puede objetar?” y “¿qué alternativa menos intrusiva existe?”. La calidad de un sistema de lenguaje se mide tanto por las respuestas que produce como por las decisiones que se niega justificadamente a automatizar.

16.4.10. Ejemplo práctico guiado: asistente para consulta de reclamos

Este ejemplo es una extensión conceptual separada del clasificador REC-04. No genera respuestas financieras ni decide sobre consumidores. Su función es ayudar a personal autorizado a consultar documentación institucional y antecedentes anonimizados, con citas y derivación a revisión. Los reclamos CFPB no se usan como autoridad normativa.

La base documental contiene políticas aprobadas, glosario y procedimientos versionados con permisos. El índice conserva fuente, fecha y alcance. La consulta se minimiza y se bloquean datos identificables. El recuperador combina búsqueda léxica y semántica; un re-ranker selecciona fragmentos. El generador solo puede responder desde ellos y debe declarar insuficiencia o conflicto.

```
recibir consulta de usuario autenticado
detectar y minimizar datos personales; comprobar autorización
recuperar fragmentos dentro de fuentes y permisos vigentes
SI no hay evidencia suficiente:
    devolver "sin evidencia suficiente" y ruta de revisión
SI hay conflicto entre fuentes:
    mostrar conflicto, fechas y derivar a revisión
generar borrador estructurado con cita por afirmación
validar esquema, enlaces, citas y prohibiciones
requerir aprobación humana antes de cualquier uso externo
registrar versiones y decisión sin conservar texto sensible innecesario
```

La evaluación crea consultas con evidencia conocida, casos sin respuesta, fuentes contradictorias, instrucciones maliciosas dentro de documentos y solicitudes fuera de permiso. Se mide recall@k de evidencia, precisión de citas, fidelidad por afirmación, cobertura, abstención correcta, filtración, latencia y carga de revisión.

Evaluadores humanos califican utilidad sin ver datos personales.

Fallos esperables incluyen recuperar una política obsoleta, citar un fragmento irrelevante, obedecer una instrucción incrustada, mezclar dos casos o completar un dato ausente. Cada fallo tiene control: vigencia, evaluación de implicación, delimitación de fuentes, aislamiento por permisos y abstención. Una API no convierte el borrador en verdad; la evidencia y el procedimiento de revisión sostienen su uso.

Síntesis

El PLN convierte lenguaje en representaciones, predicciones y textos, pero cada etapa conserva unas señales y elimina otras. Corpus, tokenización y normalización definen la población observable. BoW y TF-IDF ofrecen baselines dispersos, eficaces y auditables; su vocabulario y estadísticas deben ajustarse solo con entrenamiento. Similitud, clasificación, sentimiento y extracción requieren objetivos distintos, métricas acordes y análisis cualitativo protegido.

Embeddings distribucionales comparten información entre formas; representaciones contextuales dependen de posición y entorno. Atención calcula combinaciones de valores según consultas y claves, y Transformer la integra con redes por posición, residuales y codificación de orden. Preentrenamiento ofrece capacidad reutilizable; ajuste fino adapta conducta sin garantizar veracidad.

Los LLM modelan secuencias autoregresivamente. Prompting, aprendizaje en contexto, RAG y APIs permiten construir aplicaciones, pero introducen riesgos propios. La evaluación debe separar recuperación de generación y contemplar alucinación, seguridad, sesgos, privacidad, propiedad intelectual y costo. Documentación, trazabilidad, abstención y supervisión con autoridad son componentes del sistema, no anexos.

En el proyecto CFPB, el objetivo es limitado y verificable: clasificar Product desde narrativas consentidas para sugerir enrutamiento o revisión. La partición es temporal, TF-IDF se ajusta solo con entrenamiento, se excluyen campos posteriores a la respuesta y los errores se presentan anonimizados. No existe base para inferir urgencia, daño o mérito.

Glosario esencial

- **Alucinación:** afirmación generada sin respaldo suficiente en la evidencia pertinente.
- **Atención:** operación que combina valores según compatibilidad normalizada entre consultas y claves.
- **Bag of Words:** representación por presencia o conteo de términos, sin orden global.
- **Calibración:** correspondencia entre confianza pronosticada y frecuencia observada.
- **Corpus:** colección delimitada y documentada de producciones lingüísticas.
- **Documento:** unidad de análisis, representación o predicción.
- **Embedding:** vector denso aprendido para una unidad lingüística.
- **Extracción de información:** transformación de texto en entidades, relaciones, eventos o campos.

- **Fuga de información:** uso durante desarrollo de información no disponible en el momento simulado de predicción.
- **Generación autoregresiva:** producción secuencial que condiciona cada token en el prefijo.
- **In-context learning:** adaptación temporal mediante ejemplos dentro de la entrada, sin actualizar parámetros.
- **Lema:** forma canónica asociada a variantes flexivas.
- **LLM:** modelo de lenguaje de gran escala entrenado sobre grandes colecciones y cómputo.
- **Macro-F1:** promedio no ponderado del F1 de cada clase.
- **N-grama:** secuencia contigua de n unidades.
- **Palabra vacía:** término frecuente candidato a exclusión según tarea y corpus.
- **Prompt:** entrada estructurada que contiene instrucciones, contexto y restricciones.
- **RAG:** generación condicionada por evidencia recuperada desde una colección externa.
- **Representación contextual:** vector de una posición condicionado por su contexto.
- **Stemming:** reducción heurística de formas mediante recorte o reglas.
- **Subpalabra:** unidad menor que una palabra aprendida o definida para tokenización.
- **TF-IDF:** ponderación que combina frecuencia local y rareza documental.
- **Token:** unidad producida por un procedimiento de segmentación.
- **Transformer:** arquitectura basada en atención, transformaciones por posición, residuales y posición.
- **Vocabulario:** conjunto ordenado de tipos que una representación puede codificar.

Preguntas de revisión

1. ¿Por qué un corpus no puede describirse como una muestra neutral del lenguaje?
2. ¿Qué diferencia hay entre palabra, token, tipo y ocurrencia?
3. Proponga una tarea donde eliminar puntuación ayude y otra donde perjudique.
4. ¿Por qué el vocabulario y $df(t)$ deben aprenderse solo con entrenamiento?
5. ¿Qué información preservan bigramas que no preservan unigramas?
6. Compare BoW binario, conteos y TF-IDF en documentos de distinta longitud.
7. ¿En qué sentido la similitud coseno depende de la representación?
8. ¿Por qué accuracy puede ocultar fallos en clases minoritarias?
9. Distinga probabilidad calibrada, margen y confianza factual.
10. ¿Cómo organizaría una revisión de errores que proteja privacidad y evite selección anecdótica?
11. ¿Qué diferencia un embedding estático de uno contextual?
12. Derive la forma matricial de atención a partir de α_{ij} y $\mathbf{z}_i$.
13. ¿Por qué se divide el producto consulta-clave por $\sqrt{d_k}$?
14. Compare encoder, decoder y encoder-decoder según visibilidad del contexto.
15. ¿Qué información debe acompañar una comparación entre TF-IDF y embeddings?
16. ¿Por qué la probabilidad del siguiente token no es una medida de verdad?

17. ¿Qué riesgos introduce el texto recuperado en un sistema RAG?
18. Diseñe una rúbrica que separe fidelidad, corrección, cobertura y seguridad.
19. ¿Qué significa supervisión humana efectiva y qué condiciones la vuelven meramente nominal?
20. En el caso CFPB, ¿por qué Timely response? no puede definir urgencia al ingreso?

Actividad integradora de cierre

Objetivo. Diseñar, sin desplegar, dos soluciones para una colección documental autorizada: un clasificador TF-IDF y un asistente RAG. La actividad debe mostrar que una tecnología se elige por la decisión y la evidencia, no por novedad.

Parte A: formulación. Definir población, unidad, instante de uso, entradas permitidas, salida, costo de error y prohibiciones. Identificar selección del corpus, datos sensibles y derechos sobre fuentes.

Parte B: clasificador. Proponer partición que reproduzca uso futuro, baseline, representación, métricas, análisis de errores y política de abstención. Señalar qué estadísticas se ajustan en entrenamiento.

Parte C: RAG. Dibujar ingestión, segmentación, permisos, recuperación, ranking, generación, validación y revisión. Definir pruebas de evidencia ausente, conflicto, inyección y acceso no autorizado.

Parte D: comparación. Elaborar una tabla con calidad esperada, trazabilidad, costo, latencia, privacidad, mantenimiento y posibilidad de revisión. Recomendar una solución, ambas o ninguna.

Producto. Informe técnico con fórmulas pertinentes, pseudocódigo de alto nivel, registro de riesgos, conjunto de casos de prueba y ficha de supervisión. No se requiere código de implementación fuera de las actividades prácticas autorizadas.

Criterios. Coherencia entre objetivo y métrica; ausencia de fuga; evaluación por clase y periodo; fuentes y permisos trazables; abstención verificable; tratamiento explícito de alucinación, sesgo, privacidad y propiedad intelectual; y responsabilidades humanas definidas.

Apendices

A. Fundamentos matematicos

El algebra lineal proporciona vectores, matrices, productos internos, normas y autovectores. El calculo permite derivadas y gradientes; la optimizacion busca minimos o maximos bajo restricciones. La notacion probabilistica distingue eventos, variables aleatorias, distribuciones, esperanza y condicionamiento. Estos conceptos sustentan regresion, PCA, redes y aprendizaje por refuerzo.

B. Guia de programacion cientifica

El codigo practico debe separar entrada, transformacion, analisis y salida; usar funciones pequeñas; validar tipos y rangos; registrar errores; fijar dependencias y probar invariantes. Los notebooks son documentos de comunicacion, no sustitutos de una estructura reproducible.

C. Etica, gobernanza y documentacion

Documentar poblacion objetivo, datos, etiquetas, cambios de distribucion, limitaciones, riesgos, responsables, controles y mecanismo de apelacion. Una ficha de datos y una tarjeta de modelo deben indicar usos permitidos y prohibidos. Equidad requiere definir grupos, metricas y trade-offs, no solo declarar ausencia de sesgo.