Parcial 1: Ciencia de Datos 2026

Nombre: _____

Apellido: _____

Fecha: ____/____/_____

Seleccione la única alternativa correcta en cada pregunta.

1. En la taxonomía de preguntas analíticas, la pregunta «¿Qué acción conviene?» corresponde al objetivo de:

a) Prescribir.
b) Describir.
c) Diagnosticar.

2. En el proceso KDD (Knowledge Discovery in Databases), la minería de datos es:

a) Una etapa dentro del proceso completo.
b) Un sinónimo del proceso KDD completo.
c) La etapa final de despliegue del modelo.

3. La unidad de análisis (U) de un problema es:

a) La entidad elemental descrita, predicha o decidida, que define el significado de una fila.
b) El conjunto de unidades sobre las que se desea generalizar o actuar.
c) El periodo temporal que abarca el proyecto.

4. La dimensión de calidad «Oportunidad» pregunta si el dato:

a) Cumple dominio, formato y rango.
b) Tiene una clave que identifica una única fila.
c) Llega antes de usarlo.

5. Un duplicado de clave consiste en registros que:

a) Coinciden en todas sus columnas.
b) Coinciden en la clave y difieren en otros atributos.
c) Representan el mismo objeto y carecen de una clave común.

6. El valor «00123», almacenado como texto y usado como código postal, tiene tipo semántico de:

a) Cantidad de razón.
b) Categoría ordinal.
c) Identificador nominal.

7. Frente a valores extremos, la mediana es:

a) Más sensible que la media.
b) Menos sensible que la media.
c) Igual de sensible que la media.

8. El coeficiente de correlación de Pearson mide:

a) La asociación lineal estandarizada, entre -1 y 1.
b) La asociación de orden monotónica, basada en rangos.
c) La variación lineal conjunta, en producto de unidades.

9. Una celda vacía en la precipitación registrada por NOAA debe interpretarse como:

a) Precipitación igual a cero.
b) Una unidad ausente del marco.
c) Una medición faltante.

10. ¿Cuál de las siguientes es una función del análisis exploratorio de datos (EDA)?

a) Generar hipótesis y controles.
b) Confirmar relaciones causales.
c) Reparar automáticamente los datos.

11. La afirmación «El 3 % de las muestras registradas tuvo detección» es:

a) Predictiva.
b) Descriptiva.
c) Prescriptiva.

12. En un muestreo aleatorio simple de tamaño n:

a) La población se divide en estratos y se sortea dentro de cada uno.
b) Se eligen las unidades de acceso más sencillo.
c) Cada conjunto posible de n unidades tiene la misma probabilidad de ser elegido.

13. Una muestra muy grande obtenida con un mecanismo de selección sesgado produce:

a) Una estimación libre de sesgo.
b) Una estimación con alta variabilidad.
c) Una estimación estable que puede seguir sesgada.

14. Al calcular P(A | B):

a) El universo se restringe a los casos donde ocurrió B.
b) El denominador es el total de casos observados.
c) Se multiplica P(A) por P(B).

15. Un falso positivo y un falso negativo que ocurren con la misma frecuencia:

a) Tienen siempre el mismo costo.
b) Se compensan entre sí en el costo esperado.
c) Pueden tener importancias muy distintas.

16. El error estándar de una proporción disminuye con el tamaño de muestra n según:

a) Una relación lineal: duplicar la muestra lo reduce a la mitad.
b) La raíz cuadrada de n: cuadruplicar la muestra lo reduce aproximadamente a la mitad.
c) Una relación constante: se mantiene igual para cualquier n.

17. El costo esperado de una acción se obtiene:

a) Tomando el mayor costo posible de la acción.
b) Promediando los costos de todas las celdas con igual peso.
c) Ponderando el costo de cada estado por su probabilidad y sumando.

18. Un parámetro es:

a) Una cantidad fija pero desconocida de la población.
b) Una función calculable a partir de los datos observados.
c) El tamaño de la muestra.

19. Estimar la concentración de un contaminante en mg/L corresponde a una tarea de:

a) Clasificación.
b) Regresión.
c) Clustering.

20. El conjunto de validación se usa para:

a) Ajustar los parámetros del modelo.
b) Elegir variables, configuración y umbral.
c) Medir una única vez el procedimiento congelado.

21. Si el modelo se usará para predecir otra fila independiente de la misma población, la partición recomendada es:

a) Temporal dentro de cada grupo.
b) Aleatoria o estratificada.
c) Por grupos.

22. Para imputar faltantes con la media, el procedimiento correcto es:

a) Calcular la media con todos los datos antes de separar.
b) Calcular la media con el conjunto de prueba.
c) Separar primero y ajustar el imputador solo con entrenamiento.

23. Un baseline es:

a) El mejor modelo obtenido en validación.
b) Una referencia simple y reproducible, disponible con la misma información que el modelo.
c) El modelo final que se despliega.

24. En clasificación, la métrica precisión (precision) responde a la pregunta:

a) De las alertas emitidas, ¿cuántas eran correctas?
b) De los eventos reales, ¿cuántos se detectaron?
c) Del total de casos, ¿qué fracción fue acertada?

25. En las curvas de pérdida, el sobreajuste se reconoce cuando:

a) La pérdida de entrenamiento sigue bajando, la de validación deja de mejorar y la separación aumenta.
b) Ambas pérdidas, de entrenamiento y de validación, son altas.
c) La pérdida de validación alcanza su mínimo.