Parcial 1: Ciencia de Datos 2026

Nombre: _____

Apellido: _____

Fecha: ____/____/_____

Seleccione la única alternativa correcta en cada pregunta.

1. En la taxonomía de preguntas analíticas, la pregunta «¿Qué está cambiando? ¿Se degradó la cobertura o el modelo?» corresponde al objetivo de:

a) Predecir.
b) Monitorear.
c) Describir.

2. El ciclo CRISP-DM comienza por:

a) La comprensión del problema.
b) El modelado.
c) La preparación de los datos.

3. En la especificación compacta P = (U, R, O, X, Y, A, H, C), la letra H representa:

a) El horizonte temporal.
b) La hipótesis del modelo.
c) El historial de datos disponible.

4. La dimensión de calidad «Unicidad» controla que:

a) Los campos concuerden entre fuentes.
b) La clave identifique una única fila.
c) El dato represente la población, el lugar y el periodo.

5. Si muchas ventas pertenecen a una misma tienda, la unión ventas → tiendas es:

a) many-to-one.
b) one-to-many.
c) many-to-many.

6. La granularidad de una tabla indica:

a) La proporción de valores faltantes.
b) El número de columnas.
c) El nivel de detalle temporal, espacial y de entidad.

7. El rango intercuartílico (IQR) resume:

a) La diferencia entre el máximo y el mínimo.
b) La extensión del 50 % central de los datos.
c) La distancia típica respecto de la media.

8. Una correlación de Pearson cercana a cero:

a) Es compatible con una dependencia fuerte de tipo curvo.
b) Demuestra que las variables son independientes.
c) Indica un error de medición.

9. La apariencia de un histograma depende de:

a) El orden en que se registraron las observaciones.
b) El ancho, el origen y los límites de los intervalos (bins).
c) El nombre asignado a la variable.

10. Un valor marcado como atípico por la regla de Tukey:

a) Es un error y debe eliminarse.
b) Indica una falla del instrumento de medición.
c) Requiere investigación o contexto antes de decidir qué hacer con él.

11. La afirmación «Conviene revisar este sitio» es:

a) Descriptiva.
b) Predictiva.
c) Prescriptiva.

12. El muestreo estratificado:

a) Realiza un único sorteo sobre toda la población.
b) Divide la población en grupos mutuamente excluyentes y sortea dentro de cada uno.
c) Selecciona las unidades por orden de llegada.

13. Aumentar el tamaño de una muestra mal seleccionada:

a) Elimina el sesgo.
b) Reduce la variabilidad, pero mantiene el sesgo.
c) Aumenta la variabilidad.

14. Las probabilidades P(alerta | detección) y P(detección | alerta):

a) Usan denominadores distintos y, en general, difieren.
b) Son siempre iguales.
c) Suman siempre 1.

15. Dos eventos mutuamente excluyentes, ambos con probabilidad positiva:

a) Son independientes.
b) Tienen probabilidad conjunta igual al producto de sus marginales.
c) Son dependientes, porque si ocurre uno el otro es imposible.

16. El bootstrap aproxima la variabilidad de un estadístico mediante:

a) La división de los datos en entrenamiento y prueba.
b) Remuestreo con reemplazo del mismo tamaño que la muestra original.
c) Una fórmula cerrada del error estándar.

17. El cálculo del costo esperado de cada acción:

a) Predice qué ocurrirá en un caso concreto.
b) Determina la probabilidad de cada estado.
c) Compara consecuencias promedio bajo probabilidades y costos explícitos.

18. El estadístico $\hat{p} = x/n$:

a) Se calcula con la muestra y se usa como estimación del parámetro p.
b) Coincide siempre con el parámetro p.
c) Se calcula sobre la población completa.

19. Determinar si una medición supera un límite para activar una inspección corresponde a una tarea de:

a) Clasificación.
b) Regresión.
c) Clustering.

20. El conjunto de prueba se usa para:

a) Medir una única vez el procedimiento congelado.
b) Elegir los hiperparámetros.
c) Ajustar las transformaciones de los datos.

21. Si la evaluación debe medir la transferencia del modelo hacia sitios distintos de los usados en el entrenamiento, la partición recomendada es:

a) Temporal dentro de cada grupo.
b) Aleatoria o estratificada.
c) Por grupos.

22. La selección de atributos basada en datos debe realizarse:

a) Usando el conjunto de prueba.
b) Dentro de entrenamiento o de cada fold.
c) Con todos los datos antes de particionar.

23. Un baseline posible para una serie temporal es:

a) Predecir la clase mayoritaria.
b) Asignar todas las observaciones a un único grupo.
c) Repetir el último valor o el del mismo periodo anterior.

24. En clasificación, la métrica recall (sensibilidad) responde a la pregunta:

a) De los eventos reales, ¿cuántos se detectaron?
b) De las alertas emitidas, ¿cuántas eran correctas?
c) Del total de casos, ¿qué fracción fue acertada?

25. En las curvas de pérdida, el subajuste se reconoce cuando:

a) La pérdida de entrenamiento baja y la de validación aumenta.
b) La pérdida de validación alcanza su mínimo.
c) Ambas pérdidas, de entrenamiento y de validación, son altas.